

DINOv2: 无需监督学习稳健视觉特征

马克西姆·奥卡布**、蒂莫西·达塞**、泰奥·穆塔坎尼**、胡维·沃*、马克·萨法涅克*、瓦西尔·哈利多夫*、皮埃尔·费尔南德斯、丹尼尔·哈齐扎、弗朗西斯科·马萨、阿拉埃尔丁·埃尔努比、马哈茂德·阿斯拉恩、尼古拉斯·巴拉斯、沃伊切赫·加卢巴、拉塞尔·豪斯、黄柏尧、李尚文、伊山·米斯拉、迈克尔·拉巴特、瓦苏·夏尔马、加布里埃尔·辛内夫、胡旭、埃尔韦·热古、朱利安·迈拉尔¹、帕特里克·拉巴图特*、阿尔芒·茹兰*、彼得·博亚诺夫斯基*

Meta AI Research ¹Inria

*核心团队 **同等贡献 在OpenReview上审阅:

<https://openreview.net/forum?id=a68SUt6zFt>

摘要

近期自然语言处理领域在大规模数据模型预训练方面的突破，为计算机视觉领域类似的基础模型开辟了道路。这类模型能通过生成通用视觉特征（即无需微调即可跨图像分布与任务工作的特征），极大简化图像在任何系统中的使用。本研究表明，若在足够多源精选数据上进行训练，现有预训练方法（尤其是自监督方法）可产生此类特征。我们重新审视现有方法，结合不同技术从数据和模型规模两个维度扩展预训练。大部分技术贡献聚焦于大规模训练的加速与稳定化：数据方面，我们提出自动构建专用、多样、精选图像数据集的流程，以替代自监督文献中常用的未筛选数据；模型方面，我们训练了包含10亿参数的ViT模型（Dosovitskiy等人，2021），并将其蒸馏为一系列较小模型。这些模型在大多数图像级与像素级基准测试中，超越了当前最佳通用特征模型OpenCLIP（Ilharco等人，2021）。

1 引言

学习任务无关的预训练表示已成为自然语言处理（NLP）领域的标准方法（Radford et al., 2019; Raffel et al., 2020; Chowdhery et al., 2022; Hoffmann et al., 2022; Touvron et al., 2023）。这些特征可以直接“原样使用”，即无需微调，就能在下游任务上取得显著优于特定任务模型的性能（Brown et al., 2020）。这一成功得益于基于大量原始文本的预训练，其采用无需监督的代理目标，例如语言建模（Radford et al., 2017）或词向量（Devlin et al., 2019）。

遵循自然语言处理领域的这一范式转变，我们预期计算机视觉领域也将出现类似的“基础”模型（Bommasani等人，2021）。这些模型应能生成即插即用的视觉特征，适用于图像级别（如图像分类）和像素级别（如分割）的任何任务。目前最有前景的基础模型研究方向集中于文本引导的预训练，即通过某种形式的文本监督来指导特征学习（Joulin等人，2016; Mahajan等人，2018; Radford等人，

All the authors are affiliated to Meta, except Julien Mairal who is affiliated to Inria. Timothée Darcet and Pierre Fernandez have a co-affiliation with Inria. Théo Moutakanni has a co-affiliation with Université Paris Saclay. Alaaeldin El-Nouby has a co-affiliation with Inria and ENS-PSL. Correspondence: {qas, timdarcet, theomoutakanni, ajoulin, bojanowski}@meta.com




图1: 第一主成分的可视化。我们对同一列 (a、b、c和d) 图像中的图像块进行主成分分析, 并展示其前三个主成分。每个主成分对应不同的颜色通道。尽管姿态、风格甚至物体发生变化, 相关图像间的相同部分仍能匹配。通过阈值化第一主成分, 背景已被移除。

2021年)。这种文本引导的预训练形式限制了图像信息的保留能力, 因为描述文字仅能近似图像中的丰富信息, 复杂的像素级信息可能无法通过这种监督方式显现。此外, 这些图像编码器需要对齐的文本-图像语料库, 因此无法像其文本对应模型那样仅从原始数据中学习, 缺乏灵活性。

文本引导预训练的一种替代方案是自监督学习 (Caron等人, 2018; Chen等人, 2020; He等人, 2022), 其仅从图像中学习特征。这些方法在概念上更接近语言建模等预文本任务, 并能捕捉图像和像素级别的信息 (Caron等人, 2021)。此外, 自监督模型输出的特征已被证明具有多种有用特性, 并促成了广泛的应用 (Amir等人, 2022; Tumanyan等人, 2022; Ofri-Amar等人, 2023; Hamilton等人, 2022)。然而, 尽管自监督学习具备学习通用特征的潜力, 但其大部分进展是在小型精选数据集ImageNet-1k (Russakovsky等人, 2015) 上进行预训练的背景下取得的。虽然已有一些尝试将这类方法扩展到ImageNet-1k之外 (Caron等人, 2019; Goyal等人, 2021; 2022a), 但这些工作主要关注未经筛选的数据集, 这通常会导致特征质量显著下降。其原因在于缺乏对数据质量和多样性的控制, 而这正是生成优质特征的关键。

在本研究中, 我们探讨了自监督学习是否具备通过大量精选数据预训练来学习通用视觉特征的潜力。我们重新审视了现有的判别式自监督方法 (例如iBOT (Zhou et al., 2022a)), 这些方法可在图像和局部块级别学习特征, 并在更大数据集的视角下重新考量其部分设计选择。我们的技术贡献主要聚焦于在扩展模型与数据规模时, 提升判别式自监督学习的稳定性与训练效率。这些改进使我们的方法比同类判别式自监督方法训练速度提升约2×倍、内存消耗降低3×倍, 从而能够支持更大批量的长时间训练。

关于预训练数据, 我们构建了一个自动化流程, 用于从大量未经整理的图像中筛选和重新平衡数据集。该流程受自然语言处理中采用的流程 (Wenzek等人, 2020年) 启发, 其中使用数据相似性而非外部元数据, 且无需人工标注。处理真实场景图像时的一个主要难点在于重新平衡概念并避免对少数主导模式过拟合。在本工作中, 一种简单的聚类方法能较好地解决这一问题。我们收集了一个小而多样的142M图像语料库以验证我们的方法。




图2：参数量扩展时的性能演变。我们在八类视觉任务上展示性能表现（如第7节所述），并给出每类任务的平均指标。特征提取自我们的自监督编码器DINOv2（深蓝色），同时与自监督方法（浅橙色）及弱监督方法（深粉色）进行对比。最佳弱监督模型的性能以虚线水平线标示。我们的模型家族显著超越了自监督学习的先前最优水平，并达到了与弱监督特征相媲美的性能。详细分析参见第7节。

最后，我们提供了一系列预训练的视觉模型，称为DINOv2，这些模型采用不同的视觉变换器（ViT）架构（Dosovitskiy等人，2016年）在我们的数据上进行训练。我们发布了所有模型以及用于在任何数据上重新训练DINOv2的代码。随着模型规模的扩大，我们在多个计算机视觉基准测试中从图像和像素层面验证了DINOv2的质量，如图2所示。我们得出结论，仅通过自监督预训练就能学习到具有可迁移性的冻结特征，这些特征与当前公开可用的最佳弱监督模型相比具有竞争力。

2 相关工作

图像内自监督训练。第一类自监督方法专注于基于图像构建的预训练任务，即从图像中提取信号，使其能够从图像的其余部分进行预测。这一思想随着Doersch等人（2015）的研究而变得流行，他们通过预测给定图像块的上下文进行训练。随后出现了许多其他预训练任务，例如图像重新着色（Zhang等人，2016）、预测变换（Gidaris等人，2018）、图像修复（Pathak等人，2016）或图像块重排序（Noroozi & Favaro, 2016; Misra & Maaten, 2020）。近年来，随着基于图像块的架构（如ViTs）的出现，图像修复预训练方法被重新审视（He等人，2022; Bao等人，2021; El-Nouby等人，2021），并可能扩展到特征空间（Assran等人，2023; Baevski等人，2022）。特别值得注意的是，He等人（2022）表明，掩码自编码器（MAE）学习的特征在下游任务微调时能带来显著性能提升。MAE的这一特性已在视频（Tong等人，2022）、音频（Xu等人，2022）及其他模态（Girdhar等人，2023）中得到进一步验证。然而，MAE的特征需要监督微调才能发挥作用，而我们的特征无需调整即可取得良好性能。

判别式自监督学习。第二条研究路线与我们的工作更为接近，即利用图像或图像组之间的判别信号来学习特征。这类方法源于早期深度学习研究（Hadsell等人，2006），但随着实例分类方法的出现而流行起来（Dosovitskiy等人，2016; Bojanowski & Joulin, 2017; Wu等人，2018）。后续多项改进




图3: 我们的数据处理流程概览。来自精选与非精选数据源的图像首先被映射为嵌入向量。随后, 非精选图像在匹配精选图像前会进行去重处理。通过自监督检索系统, 最终组合对初始数据集进行了增强。

这些方法要么基于实例级目标 (Hénaff等人, 2019; He等人, 2020; Chen & He, 2021; Chen等人, 2020; Grill等人, 2020; Caron等人, 2021), 要么基于聚类 (Caron等人, 2018; Asano等人, 2020; Caron等人, 2020) 进行设计。它们在ImageNet (Russakovsky等人, 2015) 等标准基准测试中提供了高性能的冻结特征, 但难以扩展到更大的模型规模 (Chen等人, 2021)。在本工作中, 我们在大规模预训练数据集和模型的背景下重新审视这些方法的训练过程。特别地, 我们基于Zhou等人 (2022a) 的研究进行拓展, 发现其方法尤其适合规模化扩展。

扩展自监督预训练的规模。越来越多的研究关注自监督学习在数据和模型规模上的扩展能力 (Caron等人, 2019; Goyal等人, 2019; Tian等人, 2021; Goyal等人, 2022a)。这些研究大多使用大量未经筛选的数据进行无监督模型训练。它们证明判别式方法能随数据规模扩展, 但由于预训练数据质量较低, 多数结果需通过微调特征获得。特别值得注意的是, Goyal等人 (2021) 还证明了在拥有足够预训练数据的前提下, 这些方法能通过扩大模型规模获得提升。这类研究对自监督方法能否适用于任意数据提出了质疑, 而我们的研究重点在于生成最优的预训练编码器。

自动数据整理。我们的数据集构建借鉴了图像检索领域的研究 (Weinzaepfel等人, 2021; Radenovi 等人, 2018b; Berman等人, 2019; Douze等人, 2009; Tolias等人, 2016; Revaud等人, 2019)。特别是在半监督学习背景下, 利用检索技术增强训练集的方法已被探索 (Yalniz等人, 2019)。类似地, 其他研究通过使用标签或其他元数据 (Mahajan等人, 2018; Radford等人, 2021) 或预训练视觉编码器 (Schuhmann等人, 2021; 2022) 来筛选未经整理的数据集。与这些工作不同, 我们既不使用预训练编码器、元数据, 也不依赖监督来筛选图像, 而是利用图像间的视觉相似性。我们的方法受到文本整理流程的启发 (Wenzek等人, 2020), 该流程通过在维基百科上训练语言模型, 对从未经整理的来源提取的文本进行评分。

3 数据处理

我们通过从大量未筛选数据中检索与多个精选数据集中的图像相近的图片, 构建了精心整理的LVD-142M数据集。下文将介绍我们数据流程中的主要组成部分, 包括精选/未筛选数据来源、图像去重步骤以及检索系统。如图3所示, 我们的流程无需任何元数据或文本, 可直接处理图像。关于方法的更多细节, 请参阅附录A。

数据来源。我们在附录 (表15) 中详细介绍了精选数据集的选择, 其中包含ImageNet-22k、ImageNet-1k的训练集、Google Landmarks以及多个细粒度数据集。对于

在未经筛选的数据源中，我们从公开可用的网络爬取数据存储库中收集了一个原始未过滤的图像数据集。从存储库的每个网页中，我们通过标签提取图像的URL链接。我们丢弃了不安全或受域名限制的URL，并对下载的图像进行了后处理（PCA哈希去重、NSFW过滤以及模糊化可识别人脸）。最终得到了12亿张独特图像。

去重。我们对未经筛选的数据应用Pizzi等人（2022）的复制检测流程，移除近似重复图像。这减少了冗余并增加了图像间的多样性。同时，我们还移除了与本工作中使用的任何基准测试集或验证集中图像高度相似的重复图像。

自监督图像检索。我们通过从非精选数据源中检索与精选数据源中图像相近的图像，构建了精选预训练数据集。为此，我们首先使用在ImageNet-22k上预训练的自监督ViT-H/16网络计算图像嵌入向量，并采用余弦相似度作为图像间距离度量。随后，我们对非精选数据进行k均值聚类。对于给定的检索查询数据集，若其规模足够大，我们为每张查询图像检索 N （通常为4）个最近邻图像；若规模较小，则从对应每张查询图像的聚类中采样 M 张图像。尽管视觉检查显示即使 N 远大于4时检索质量仍表现良好，但这会导致更多碰撞现象（即同一图像被多个查询作为最近邻检索结果）。我们选择 $N=4$ 作为平衡点，因其在该意义上提供了较好的权衡。

实现细节。我们流程中的去重和检索阶段依赖于Faiss库（Johnson等人，2019），以高效索引并批量计算最近邻嵌入的搜索。具体而言，我们充分利用其对GPU加速索引的支持，采用基于乘积量化码的倒排文件索引（Jegou等人，2010）。整个处理过程分布在由20个节点组成的计算集群上，每个节点配备8块V100-32GB GPU，生成LVD-142M数据集耗时不足两天。

4 判别式自监督预训练

我们采用一种判别性自监督方法学习特征，该方法可视为结合了DINO与iBOT损失函数，并引入了SwAV（Caron等人，2020）的中心化机制。我们还添加了分散特征的正则化器以及一个简短的高分辨率训练阶段。以下将简要介绍这些方法，更多细节可参阅相关论文或我们开源的代码。

- 图像级目标（Caron等人，2021）。我们考虑从学生网络和教师网络提取的特征之间的交叉熵损失。这两个特征均来自ViT的类别标记，通过同一图像的不同裁剪区域获得。我们将学生类别标记输入学生DINO头部。该头部是一个多层感知机模型，输出一组得分向量，我们称之为“原型得分”。随后应用softmax函数得到 p_s 。类似地，我们将教师DINO头部应用于教师类别标记以获得教师原型得分，接着应用softmax函数并进行移动平均中心化处理（或后续详述的Sinkhorn-Knopp中心化方法）得到 p_t 。DINO损失项对应为：

$$\mathcal{L}_{DINO} = - \sum p_t \log p_s$$

我们学习学生模型的参数，并利用过去迭代的指数移动平均构建教师头（He等人，2020年）。

- 块级目标（Zhou等人，2022a）。我们随机遮蔽输入给学生的部分图像块，但不遮蔽教师的输入。随后，我们将学生的iBOT头部应用于学生被遮蔽的标记。类似地，我们将教师的iBOT头部应用于教师图像块标记中与学生被遮蔽块相对应的（可见）标记。接着，我们按上述方法进行softmax和中心化步骤，并得到iBOT损失项：

$$\mathcal{L}_{iBOT} = - \sum_i p_{ti} \log p_{si}$$

其中 i 是被遮蔽标记的补丁索引。与上述类似，我们学习学生模型的参数，并通过指数移动平均构建教师头。

- 解绑两个目标之间的头部权重。DINO和iBOT损失都使用可学习的MLP投影头，该投影头应用于输出标记，并在其之上计算损失。在Zhou等人（2022a）的研究中，消融实验表明共享DINO和iBOT头部的参数能带来更好的性能。但在大规模实验中，我们观察到相反的情况，因此我们在所有实验中使用两个独立的头部。
- Sinkhorn-Knopp中心化（Caron等人，2020年）。Ruan等人（2023年）建议将DINO和iBot中的教师softmax中心化步骤替换为SwAV（Caron等人，2020年）的Sinkhorn-Knopp（SK）批量归一化。我们运行Sinkhorn-Knopp算法3次迭代。对于学生模型，我们采用softmax归一化。
- KoLeo正则化器（Sablayrolles等人，2019）。该正则化器源自Kozachenko-Leonenko微分熵估计器（参见Beirlant等人（1997）；Delattre & Fournier（2017）），并鼓励批次内特征均匀分布。给定一组 n 向量 $(x_1, \dots, x_n)$ ，其定义为

$$\mathcal{L}_{\text{koleo}} = -\frac{1}{n} \sum_{i=1}^n \log(d_{n,i}),$$

其中 $d_{n,i} = \min_{j \neq i} \|x_i - x_j\|$ 是 x_i 与批次内任意其他点之间的最小距离。在计算该正则化项前，我们还会对特征进行 ℓ_2 归一化处理。

- 调整分辨率（Touvron等人，2019年）。提高图像分辨率对于像素级下游任务（如分割或检测）至关重要，因为在低分辨率下小物体会消失。然而，在高分辨率下训练对时间和内存要求较高，因此我们改为在预训练结束前的短时间内将图像分辨率提升至 518×518 。这也类似于Likhomanenko等人（2021年）的UniViT训练和Beyer等人（2023年）的FlexiViT训练。

5 高效实现

我们考虑了几项改进，以更大规模地训练模型。我们使用PyTorch 2.0在A100 GPU上训练模型。代码和预训练模型均基于Apache 2.0许可证¹公开提供。模型详细参数见附录表17。在相同硬件条件下，与iBOT实现相比，DINOv2代码运行速度提升约2×倍，且仅占用1/3的内存。

快速且内存高效的注意力机制。我们实现了自研版本的FlashAttention（Dao等人，2022年），以提升自注意力层的内存使用效率和运行速度。在所有测试场景中，我们的版本均达到或超越了原始版本性能，同时覆盖了更多使用场景和硬件类型。受GPU硬件特性影响，当每个注意力头的嵌入维度为64的倍数时效率最优，而整体嵌入维度为256的倍数时矩阵运算效率更佳。因此，为最大化计算效率，我们的ViT-g架构与Zhai等人（2022年）提出的方案略有不同：采用1536嵌入维度配合24个注意力头（每头64维），而非原方案的1408维度配合16个注意力头（每头88维）。实验表明两种方案在最终准确率上无显著差异，我们的ViT-g骨干网络共包含11亿参数。

序列打包。DINO算法需要同时处理大尺寸裁剪（分辨率为224）和小尺寸裁剪（分辨率为98）。当分割为图像块时，这两组数据会形成不同长度的标记序列，无法同时进行前向传播。为了加速训练，我们采用了一种称为“序列打包”的技巧，该技巧源自自然语言处理领域（Krell等人，2022）。其思路很简单：我们将

¹<https://github.com/facebookresearch/dinov2>

我们必须通过变换器前向传播的序列合并成一个长序列。我们像往常一样将这个序列通过变换器块。然而，在注意力层的自注意力矩阵上应用了块对角掩码，以防止不同序列之间的注意力交互。这样一来，前向传播严格等同于分别处理每个序列。与先前实现中使用的单独前向和反向传播相比，这种技巧为我们带来了显著的计算效率提升。我们设置中的底层组件可在xFormers库² (Lefaudeux等人 (2022)) 中找到。

高效随机深度。我们实现了一种改进版的随机深度 (Huang等人, 2016)，该方法跳过被丢弃残差的计算，而非对结果进行掩码处理。借助特定的融合内核，这能按丢弃率大致成比例地节省内存和计算量。在高丢弃率 (本工作中 $d = 40\%$) 下，该方法可大幅提升计算效率和内存使用率。具体实现方式为：在批次维度上随机打乱 B 个样本，并截取前 $(1-d) \times B$ 个样本用于块内计算。

全分片数据并行 (FSDP)。使用AdamW优化器最小化我们的目标需要4个float32精度的模型副本——学生模型、教师模型、优化器一阶矩和优化器二阶矩。对于像我们的ViT-g这样的十亿参数模型，这总计需要16 GB内存。为了降低每个GPU的内存占用，我们将模型副本拆分到多个GPU上，即使用PyTorch实现的FSDP将16 GB内存分片到多个GPU上。因此，模型大小不受单个GPU内存的限制，而是受计算节点间GPU内存总和的限制。PyTorch实现的FSDP还带来第二个优势：节省跨GPU通信成本——权重分片按优化器要求以float32精度存储，但主干网络的权重广播和梯度归约以float16精度执行 (MLP头梯度归约使用float32以避免训练不稳定)。与分布式数据并行 (DDP) 中使用的float32梯度全归约操作相比，这使通信成本降低约50% (其他自监督预训练方法采用DDP，如Caron等人2021年；Zhou等人2022a年)。因此，在扩展GPU节点数量时，该训练流程比使用float16自动混合精度的DDP扩展效率更高。总体而言，在我们遇到的所有实际场景中，PyTorch-FSDP混合精度方案均优于自动混合精度的DDP。

模型蒸馏。我们对训练循环的大部分技术改进旨在提升大模型在大量数据上的训练效果。对于较小模型，我们选择从最大模型ViT-g进行蒸馏，而非从头开始训练。知识蒸馏 (Hinton等人, 2014) 的核心目标是通过最小化给定输入集上大模型与小模型输出间的某种距离，使小模型复现大模型的输出。由于我们的目标函数本质上是教师网络向学生网络的知识蒸馏形式，我们沿用了相同的训练流程，仅作几点调整：使用更大的冻结模型作为教师网络，为学生网络维护一个额外的指数移动平均版本作为最终模型，移除掩码机制和随机深度，并在两个全局裁剪图像上应用iBOT损失。在消融实验中，我们发现即使对于ViT-L模型，该方法也比从头训练获得更优性能。我们的蒸馏方法最终与Duval等人 (2023) 所述方案相近，区别在于我们未修改蒸馏损失项，且评估的是学生网络的指数移动平均版本。

6 消融研究

我们进行了一系列消融实验，以实证验证我们流程中的不同组成部分：第4节中描述的技术改进、预训练数据以及模型蒸馏的影响。我们考虑了第7节中描述的各种下游任务。

6.1 改进的训练方案

我们的方法通过结合第4节中描述的几种现有组件，改进了iBOT方法。为了评估这些组件的重要性，我们训练了多个模型，逐步向基线iBOT模型添加组件。我们报告了在ImageNet-1k验证集上使用k-NN方法得到的Top-1准确率。

²<https://github.com/facebookresearch/xformers>

	INet-1k k-NN	INet-1k linear
iBOT	72.9	82.3
+(our reproduction)	74.5 $\uparrow$ 1.6	83.2 $\uparrow$ 0.9
+LayerScale, Stochastic Depth	75.4 $\uparrow$ 0.9	82.0 $\downarrow$ 1.2
+128k prototypes	76.6 $\uparrow$ 1.2	81.9 $\downarrow$ 0.1
+KoLeo	78.9 $\uparrow$ 2.3	82.5 $\uparrow$ 0.6
+SwiGLU FFN	78.7 $\downarrow$ 0.2	83.1 $\uparrow$ 0.6
+Patch size 14	78.9 $\uparrow$ 0.2	83.5 $\uparrow$ 0.4
+Teacher momentum 0.994	79.4 $\uparrow$ 0.5	83.6 $\uparrow$ 0.1
+Tweak warmup schedules	80.5 $\uparrow$ 1.1	83.8 $\uparrow$ 0.2
+Batch size 3k	81.7 $\uparrow$ 1.2	84.7 $\uparrow$ 0.9
+Sinkhorn-Knopp	81.7 =	84.7 =
+Untying heads = DINOv2	82.0 $\uparrow$ 0.3	84.5 $\downarrow$ 0.2

表1: iBOT与DINOv2训练差异的消融研究。我们以k-NN性能为优化目标, 因为根据我们的经验, 线性探测性能的下限由k-NN性能决定。某些修改(如LayerScale和高随机深度率=0.4)会导致线性探测性能下降, 但能通过避免训练期间出现NaN损失值来提高训练稳定性(Touvron等人, 2022)。总体而言, 这些修改为后续改进奠定了基础。实验采用ViT-Large架构在ImageNet-22k数据集上进行。

Training Data	INet-1k	Im-A	ADE-20k	Oxford-M	iNat2018	iNat2021	Places205
INet-22k	85.9	73.5	46.6	62.5	81.1	85.6	67.0
INet-22k \ INet-1k	85.3	70.3	46.2	58.7	80.1	85.1	66.5
Uncurated data	83.3	59.4	48.5	54.3	68.0	76.4	67.2
LVD-142M	85.8	73.9	47.7	64.6	82.3	86.4	67.6

表2: 预训练数据来源的消融研究。我们将iBOT中使用的INet-22k数据集与我们的LVD-142M数据集进行比较。每个模型均以相同迭代次数进行训练(此迭代次数少于最终实验), 且未进行高分辨率适配。使用LVD-142M进行预训练能在保持INet-1k性能的同时, 使模型在其他领域表现更优。

以及表1中的线性探测。总体而言, 我们观察到每个组件都能提升k-NN或线性探测的性能, 在大多数情况下甚至能同时提升两者。只有LayerScale和随机深度会导致线性探测性能下降, 但根据我们的经验, 它们显著提高了训练稳定性。

6.2 预训练数据来源

特征的质量与预训练数据的质量直接相关。在本实验中, 我们探究了LVD-142M与常用预训练数据集ImageNet-22k或直接使用原始未筛选数据的影响对比。对于未筛选数据集, 我们从与LVD-142M相同的数据源中随机抽取1.42亿张图像。我们在每个数据集上以相同的迭代次数训练ViT-g/14模型。为保持完整性, 我们还纳入了通过移除ImageNet-1k同义词集(INet-22k {v*} INet-1k)得到的ImageNet-22k变体。对比结果如表2所示。

最显著的观察结果是, 在精选图像集上进行训练在大多数基准测试中表现优于未筛选数据训练。这证实了数据筛选的益处, 即使在自监督预训练的情况下也是如此。与在ImageNet-22k上训练的模型相比, 使用LVD-142M进行训练在所有基准测试(除ImageNet-1k外)均表现更优。这表明在更多样化的图像集上训练能提升ImageNet-22k未覆盖领域的特征质量。我们还发现, 使用精选数据训练能提升未参与筛选过程的领域性能(如INaturalist 2018、2021和Places205), 证明规模与多样性对未见领域同样具有增益效果。




图4: 模型规模与数据规模的关系。展示了两种不同预训练数据集 (ImageNet-22k (1400万张图像) 和LVD-142M (1.42亿张图像)) 下, 模型大小对性能的影响。在大多数基准测试中, 基于LVD-142M训练的ViT-g超越了基于ImageNet-22k训练的ViT-g。

KoLeo	INet-1k	Im-A	ADE-20k	Oxford-M	MIM	INet-1k	Im-A	ADE-20k	Oxford-M
×	85.3	70.6	47.2	55.6	×	85.3	72.0	44.2	64.3
✓	85.8	72.8	47.1	63.9	✓	85.8	72.8	47.1	63.9

(a) Kolo loss

(b) MIM objective in iBOT

表3: (a) KoLeo损失项的效果。(b) iBOT掩码图像建模(MIM)损失项的效果。评估在ImageNet-{1k,A} (线性探针分类, 准确率%)、ADE-20k (线性层分割, mIoU) 和Oxford-M (图像检索, mAP) 上进行。每个模型均以相同迭代次数训练, 该次数少于我们的最终运行。KoLeo损失项提升了最近邻搜索任务 (例如检索) 的性能, 而MIM损失项则改善了块级任务 (例如分割) 的表现。

总的来说, 本次消融实验的结论是, 我们的数据集在各类图像之间提供了良好的平衡, 从而实现了整体最佳性能。

6.3 模型规模与数据


我们在图4中量化了数据规模随模型大小扩展的重要性。随着模型规模的增长, 在LVD-142M上训练比在ImageNet-22k上训练更具优势。例如, 在LVD-142M上训练的ViT-g模型在ImageNet-1k上的表现与在ImageNet-22k上训练的模型相当, 同时在其他基准测试中显著优于后者。

6.4 损失分量

我们在第6.1节中通过逐步添加所提出的技术改进进行了验证。本节从我们性能最佳的模型出发, 分析了若去除特定损失项所观察到的性能影响。我们分别去除了KoLeo损失的重要性以及掩码图像建模项的影响。针对这两者, 我们报告了使用线性分类器在ImageNet-1k上的性能、使用线性分类器在ADE-20k分割任务上的表现, 以及在Oxford-M数据集上的最近邻图像检索结果。表3a展示了使用KoLeo损失的影响。我们看到实例检索性能提升了超过8%, 证实了该项损失有助于在输出空间中分散特征。同时, 其他指标并未受到此正则化的负面影响。表3b展示了采用iBOT中的掩码图像建模项的影响。该项对密集预测任务至关重要, 带来了近3%的性能提升。

6.5 知识蒸馏的影响

对于小型架构, 我们采用蒸馏大型模型而非从头训练的方法。我们使用第5节中描述的蒸馏流程。通过在图5中比较从头训练的ViT-L/14与从ViT-g/14蒸馏得到的模型在12个基准测试上的表现, 我们评估了该方法的有效性。同时, 我们报告了用于蒸馏的ViT-g/14的性能作为上限参考。蒸馏模型在所有12个基准测试上均优于从头训练的模型, 这验证了我们针对小型模型的预训练方法。



(a) Comparison on individual metrics

Arch	Method	INet-1k	Segm.	Depth↓	Classif.
ViT-g/14	Scratch	86.5	73.4	1.00	92.1
ViT-L/14	Scratch	84.5	72.2	1.10	90.2
ViT-L/14	Distill	86.3	73.3	1.08	91.2

Arch	Method	Finegr.	Retriev.	ARSketch	Video
ViT-g/14	Scratch	78.3	75.2	77.0	69.3
ViT-L/14	Scratch	75.8	71.3	69.5	67.3
ViT-L/14	Distill	77.6	76.3	74.5	67.5

(b) Averaged metrics on 8 vision tasks

图5: 知识蒸馏的有效性。比较了从头开始训练的ViT-L与使用ViT-g/14从DINOv2蒸馏得到的ViT-L。作为参考, 我们还报告了ViT-g/14教师模型的性能。实验表明, 通过冻结的ViT-g蒸馏得到的ViT-L模型在所有基准测试中均优于从头训练的相同模型, 有时甚至超越了蒸馏目标本身。




图6: 分辨率的作用。在固定分辨率 (“224” 和 “416”) 下训练的ViT-L/16, 或在224分辨率训练后短时间在416分辨率训练 (“224→416”) 的性能。我们在不同分辨率的冻结特征上训练线性分类器, 并报告ImageNet上的Top-1准确率和ADE-20k上的mIoU。我们观察到, 以高分辨率进行短时间的SSL训练, 能以极低的成本获得与全程在同一高分辨率下训练相近的行为和结果。

6.6 分辨率的影响

我们测量了在预训练期间改变分辨率对图像和补丁级特征性能的影响。我们考虑了使用固定分辨率224×224或416×416从头开始训练的模型, 以及先在224×224分辨率下从头训练, 随后在416×416分辨率下继续训练1万次迭代的模型。高分辨率训练计算密集, 因此我们在小规模设置下进行此消融实验: 使用ViT-L/16架构在ImageNet1k上进行训练。在图6中, 我们报告了在ImageNet-1k和ADE-20k上以不同分辨率评估的线性探测性能。使用高分辨率图像训练的模型在所有分辨率下表现最佳, 但代价高昂: 416分辨率训练的计算强度约为224分辨率训练的3倍。另一方面, 仅在训练末期进行1万次迭代的高分辨率训练效果接近, 且仅需少量额外计算。因此, 我们在训练末期加入这一步骤, 而非从头开始进行高分辨率训练。

7 结果

在本节中，我们展示了模型在多项图像理解任务上的实证评估结果。我们分别在类别与实例级识别、语义分割、单目深度预测以及动作识别任务中，评估了全局与局部图像表征的性能。具体基准测试列表详见附录C。本次评估的目标有两点：首先，我们证明自监督特征以显著优势超越当前最优方法；其次，我们表明这些特征在大量任务上达到甚至超越了弱监督方法的性能。

基准模型。在我们的比较中，我们使用两类模型作为基准。我们与公开可用的性能最佳的自监督模型进行比较。首先，我们对MAE (He等人, 2022)、DINO (Caron等人, 2021)、SEER (Goyal等人, 2022a)、MSN (Assran等人, 2022)、EsViT (Li等人, 2022a)、Mugs (Zhou等人, 2022b) 和iBOT (Zhou等人, 2022a) 进行评估。当某个方法提出多种架构变体时，我们报告在ImageNet-1k上获得最佳top-1准确率的变体结果。其次，我们报告开源弱监督模型的性能，例如CLIP (Radford等人, 2021)、OpenCLIP (Ilharco等人, 2021; Cherti等人, 2023) 和SWAG (Singh等人, 2022)。在ImageNet-1k上评估模型时，我们报告上述每种方法的性能。对于所有其他评估，我们报告自监督模型中表现最佳的四个模型。此外，作为参考，我们报告弱监督模型中性能最佳的OpenCLIP-G。

7.1 ImageNet 图像分类

作为初步评估，我们在ImageNet-1k分类数据集上检验模型生成的整体图像表征质量。我们通过基于冻结主干网络训练简单分类器来评估特征质量，且不进行主干网络权重的微调。遵循先前工作，为简化流程并确保评估可复现，我们采用线性模型进行评估，尽管类别可能并非线性可分。由于大多数自监督学习方法在开发过程中使用ImageNet-1k验证性能作为调试信号，我们还报告了在ImageNet-Real和ImageNet-V2数据集上的top-1准确率。为获取这些额外的验证性能数据，我们对所有模型使用统一代码进行评估。如表4所示，我们将冻结特征与当前公开的最佳自监督学习特征进行比较（不考虑架构或预训练数据差异）。本工作提出的组件在线性评估中相较先前最优方法（基于ImageNet-22k训练的iBOT ViT-L/16）实现了显著提升（+4.2%）。同时，我们的方法在替代测试集上表现出更大的性能提升，表明其具有更强的泛化能力。线性评估的详细设置见附录B.3。

我们距离弱监督模型还有多远？我们同样希望验证我们的特征与当前最先进的开源弱监督模型相比具有竞争力。为此，我们在ImageNet-1k上使用线性评估方法，与三种现成方法及其多种架构变体进行了比较。对于所有模型，我们均使用自己的代码进行线性评估，并确保所得数据与技术报告和论文中报告的结果一致。我们在表4中展示了此次评估的结果。可以看到，我们的骨干网络性能超越了采用ViT-G/14架构的OpenCLIP（+0.3%）以及采用ViT-g/14的EVA-CLIP（+0.1%）。同时，我们还观察到在ImageNet-V2测试集上我们的表现明显更优（相比EVA-CLIP提升+1.1%），这表明了更好的泛化能力。在本节后续部分，我们将以OpenCLIP-G作为弱监督模型的参考基准。

我们能否对编码器进行微调？我们质疑模型生成高质量冻结特征的能力是否会影响其在特定数据集上进行有监督微调时的性能。虽然这不是本文的核心内容，但该实验能表明我们是否无意中将模型专门优化用于冻结特征的线性评估场景。为了进行这项验证，我们采用了Touvron等人（2022）的微调流程，未调整超参数。表5显示，当骨干网络被微调后，ImageNet-1k验证集的Top-1准确率提升了超过+2%。这一结论在224和448分辨率模型中都成立。通过调整微调超参数可获得更大增益，但这已超出本次验证的目标。尽管如此，我们最佳的微调性能（88.9%）仅比绝对最优状态低几个百分点（-2.2%）。

Method	Arch.	Data	Text sup.	kNN	linear		
				val	val	ReaL	V2
Weakly supervised							
CLIP	ViT-L/14	WIT-400M	✓	79.8	84.3	88.1	75.3
CLIP	ViT-L/14 ₃₃₆	WIT-400M	✓	80.5	85.3	88.8	75.8
SWAG	ViT-H/14	IG3.6B	✓	82.6	85.7	88.7	77.6
OpenCLIP	ViT-H/14	LAION-2B	✓	81.7	84.4	88.4	75.5
OpenCLIP	ViT-G/14	LAION-2B	✓	83.2	86.2	89.4	77.2
EVA-CLIP	ViT-g/14	custom*	✓	83.5	86.4	89.3	77.4
Self-supervised							
MAE	ViT-H/14	INet-1k	×	49.4	76.6	83.3	64.8
DINO	ViT-S/8	INet-1k	×	78.6	79.2	85.5	68.2
SEERv2	RG10B	IG2B	×	–	79.8	–	–
MSN	ViT-L/7	INet-1k	×	79.2	80.7	86.0	69.7
EsViT	Swin-B/W=14	INet-1k	×	79.4	81.3	87.0	70.4
Mugs	ViT-L/16	INet-1k	×	80.2	82.1	86.9	70.8
iBOT	ViT-L/16	INet-22k	×	72.9	82.3	87.5	72.4
DINOv2	ViT-S/14	LVD-142M	×	79.0	81.1	86.6	70.9
	ViT-B/14	LVD-142M	×	82.1	84.5	88.3	75.1
	ViT-L/14	LVD-142M	×	83.5	86.3	89.5	78.0
	ViT-g/14	LVD-142M	×	83.5	86.5	89.6	78.4

表4：基于冻结预训练特征的ImageNet-1k线性评估。我们报告了在公开或私有数据上训练、使用或不使用文本监督（text sup.）的公开可用模型在验证集上的Top-1准确率。作为参考，我们也报告了验证集上的kNN性能。我们比较了所有可能的架构（Arch.），除特别说明外分辨率均为 224×224 。训练EVA-CLIP所用的数据集为定制混合数据集，详见论文（Fang et al., 2023）。

艺术（91.1%），由Chen等人（2023a）获得。由于DINOv2在线性和微调设置下都能产生强大的特征，我们方法的一个突出优势在于 *finetuning is optional*。

Arch.	Res.	Linear	Finetuned	Δ
ViT-g/14	224	86.5	88.5	+2.0
	448	86.7	88.9	+2.2

表5：ImageNet-1k上的监督微调。我们采用Touvron等人（2022）的流程，在 224×224 或 448×448 分辨率下对ImageNet-1k进行编码器微调。通过与线性探测获得的准确率对比，我们观察到微调仅带来有限提升：这表明DINOv2特征在未经调整时已具备良好性能。

鲁棒性分析。为了补充我们的研究并探究我们特征的泛化能力，我们在领域泛化基准上评估了使用线性分类头训练的ImageNet-1k模型。我们采用上述性能最佳的线性分类器，并直接在这些基准上进行推理。请注意，文献中的大多数结果是通过在ImageNet-1k上端到端微调的模型获得的。我们在表6中展示了该实验的结果。与最先进的SSL方法相比，我们的模型展现出显著更强的鲁棒性（在A基准（Hendrycks等人，2021b）上提升+29.6%，在R基准（Hendrycks等人，2021a）上提升+22.1%，在Sketch基准（Wang等人，2019）上提升+23.0%，均优于iBOT）。我们的模型在ImageNet-A基准上超越了最佳弱监督模型，但在R和Sketch基准上仍略有落后。

Method	Arch	Data	Im-A	Im-R	Im-C↓	Sketch
OpenCLIP	ViT-G/14	LAION-2B	63.8	87.8	45.3	66.4
MAE	ViT-H/14	INet-1k	10.2	34.4	61.4	21.9
DINO	ViT-B/8	INet-1k	23.9	37.0	56.6	25.5
iBOT	ViT-L/16	INet-22k	41.5	51.0	43.9	38.5
DINOv2	ViT-S/14	LVD-142M	33.5	53.7	54.4	41.2
	ViT-B/14	LVD-142M	55.1	63.3	42.7	50.6
	ViT-L/14	LVD-142M	71.3	74.4	31.5	59.3
	ViT-g/14	LVD-142M	75.9	78.8	28.2	62.5

表6：在分辨率为224的冻结特征上使用线性探针的领域泛化结果。除Im-C外，所有基准测试中数值越高越好。

Feature	Arch	Image classification			Video classification		
		iNat2018	iNat2021	Places205	K400	UCF-101	SSv2
OpenCLIP	ViT-G/14	73.0	76.0	69.8	78.3	90.7	35.8
MAE	ViT-H/14	31.0	32.3	52.4	54.2	70.6	29.2
DINO	ViT-B/8	59.6	68.3	60.4	64.5	85.0	32.6
iBOT	ViT-L/16	66.3	74.6	64.4	72.6	88.6	38.7
DINOv2	ViT-S/14	69.0	74.2	62.9	67.8	87.0	33.1
	ViT-B/14	76.4	81.1	66.2	73.2	89.1	34.4
	ViT-L/14	80.4	85.1	67.3	76.3	90.5	35.6
	ViT-g/14	81.6	85.7	67.5	78.4	91.2	38.3

表7：其他图像和视频分类的线性评估。图像基准包含大量关于物体或场景的细粒度样本。视频基准涵盖动作分类及人物-物体交互。所有特征均被冻结，仅在其上使用线性探针。

7.2 额外的图像与视频分类基准测试

在本节中，我们研究了所提特征在下游分类基准上的泛化能力。我们在此背景下考虑了两组评估。一方面，我们使用了如iNaturalist和Places205这样大规模且细粒度的数据集；另一方面，我们采用了SimCLR（Chen等人，2020）最初提出的12项图像分类任务。对于iNaturalist 2018、iNaturalist 2021和Places205，我们按照第7.1节的方法使用数据增强训练线性分类器，并在表7中报告了这三个数据集的top-1准确率。有趣的是，我们的模型在两个版本的iNaturalist上均显著优于OpenCLIP ViT-G/14（2018年和2021年分别达到+8.6%和+9.7%），而在Places205上略逊一筹（−2.3%）。

在第二组评估中，我们测量了模型在视频动作识别上的性能，尽管我们的特征并非基于视频训练。我们在三个数据集上评估了特征，即UCF-101（Soomro等人，2012）、Kinetics-400（Kay等人，2017）和Something-Something v2（Goyal等人，2017）。在此评估中，我们从视频中选取8个均匀间隔的帧，并对UCF和K-400的特征平均值训练线性分类器。对于SSv2，我们选择特征拼接而非平均，以保留更多时序信息。针对每个数据集，我们计算平均准确率并在表7中报告结果。我们发现，在自监督方法中，我们的模型明显创造了新的最优性能。此外，我们的模型在UCF和Kinetics上的准确率与OpenCLIP特征持平（分别为+0.1%和+0.5%），并在SSv2上显著超越它们（+2.5%）。这一点尤其值得关注，因为SSv2需要对视频帧有更丰富的理解。

最后，在表8中，我们比较了Chen等人（2020）最初提出的12个迁移分类基准上选取的冻结特征。该基准涵盖场景、物体（食物、汽车、飞机）和纹理。

Feature	Arch	Food	C10	C100	SUN	Cars	Aircr	VOC	DTD	Pets	Cal101	Flowers	CUB	Avg
OpenCLIP	ViT-G/14	94.5	98.7	91.0	84.0	96.1	80.2	89.3	86.0	95.7	98.1	99.5	89.9	91.9
MAE	ViT-H/14	78.4	96.1	83.9	63.9	56.1	63.4	84.3	75.4	89.4	95.9	92.3	57.2	78.0
DINO	ViT-B/8	85.1	97.2	86.9	70.3	76.6	70.6	86.7	79.6	93.2	95.4	97.6	81.7	85.1
iBOT	ViT-L/16	91.0	99.0	92.8	75.6	71.8	72.4	89.0	80.7	87.7	97.5	99.6	82.1	86.6
DINOv2	ViT-S/14	89.1	97.7	87.5	74.4	81.6	74.0	87.8	80.6	95.1	97.0	99.6	88.1	87.7
	ViT-B/14	92.8	98.7	91.3	77.3	88.2	79.4	88.2	83.3	96.2	96.1	99.6	89.6	90.1
	ViT-L/14	94.3	99.3	93.4	78.7	90.1	81.5	88.3	84.0	96.6	97.5	99.7	90.5	91.2
	ViT-g/14	94.7	99.5	94.4	78.7	91.4	87.2	89.0	84.5	96.7	97.6	99.7	91.6	92.1

表8: 在细粒度基准测试中对冻结特征的线性评估。遵循Chen等人（2020）提出的评估协议，在涵盖物体、场景和纹理的12个基准测试上的准确率。

Feature	Arch	Oxford		Paris		Met			AmsterTime
		M	H	M	H	GAP	GAP-	ACC	mAP
OpenCLIP	ViT-G/14	50.7	19.7	79.2	60.2	6.5	23.9	34.4	24.6
MAE	ViT-H/14	11.7	2.2	19.9	4.7	7.5	23.5	30.5	4.2
DINO	ViT-B/8	40.1	13.7	65.3	35.3	17.1	37.7	43.9	24.6
iBOT	ViT-L/16	39.0	12.7	70.7	47.0	25.1	54.8	58.2	26.7
DINOv2	ViT-S/14	68.8	43.2	84.6	68.5	29.4	54.3	57.7	43.5
	ViT-B/14	72.9	49.5	90.3	78.6	36.7	63.5	66.1	45.6
	ViT-L/14	75.1	54.0	92.7	83.5	40.0	68.9	71.6	50.0
	ViT-g/14	73.6	52.3	92.1	82.6	36.8	73.6	76.5	46.7

表9: 基于冻结特征的实例级识别评估。我们考虑了4个不同的基准测试并报告其主要指标。

我们用CUB数据集替换了Birdsnap数据集，因为后者并未完全公开。我们遵循Chen等人（2020）提出的实验方案，即在预计算特征上训练逻辑回归模型。我们的模型显著优于当前最先进的SSL模型，其中在Stanford Cars（+14.8%对比DINO ViT-B/8）和FGVC Aircraft（+14.8%对比iBOT ViT-L/16）数据集上表现差异最为突出。尽管这些基准测试更倾向于文本引导的预训练方法，但我们的特征在大多数分类基准上仍与OpenCLIP具有竞争力，仅在少数数据集上稍逊一筹，特别是SUN（−5.3%）和Cars（−4.7%）数据集。

7.3 实例识别

在本实验中，我们采用非参数化方法，在实例级识别任务上测试我们的模型。通过计算查询图像与数据库图像的余弦相似度对图像进行排序。我们在巴黎和牛津这两个地标识别基准数据集上评估了模型性能，并与基线方法进行了对比。同时还在大都会艺术博物馆艺术品数据集Met，以及由街景图像与阿姆斯特丹历史档案图像匹配构成的AmsterTime数据集上进行了评估。我们通过计算平均精度均值来衡量性能，结果汇总于表9。实验表明，我们的特征显著优于自监督学习方法（牛津困难集上+41% mAP）和弱监督方法（牛津困难集上+34% mAP）。值得注意的是，我们的特征在不同任务粒度（类别级与实例级）上均表现优异，这为构建强大的即用型计算机视觉特征提供了理想特性。

Method	Arch.	ADE20k (62.9)		CityScapes (86.9)		Pascal VOC (89.0)	
		lin.	+ms	lin.	+ms	lin.	+ms
OpenCLIP	ViT-G/14	39.3	46.0	60.3	70.3	71.4	79.2
MAE	ViT-H/14	33.3	30.7	58.4	61.0	67.6	63.3
DINO	ViT-B/8	31.8	35.2	56.9	66.2	66.4	75.6
iBOT	ViT-L/16	44.6	47.5	64.8	74.5	82.3	84.3
DINOv2	ViT-S/14	44.3	47.2	66.6	77.1	81.1	82.6
	ViT-B/14	47.3	51.3	69.4	80.0	82.5	84.9
	ViT-L/14	47.7	53.1	70.3	80.9	82.1	86.0
	ViT-g/14	49.0	53.0	71.3	81.0	83.0	86.2

表10: 在ADE20K、CityScapes和Pascal VOC数据集上使用冻结特征与线性分类器（lin.）以及多尺度（+ms）的语义分割结果。表中顶部列出了各自领域的绝对最优方法——分别来自Wang等人（2022）、Liu等人（2021）和Chen等人（2018）。作为参考，在我们的冻结ViT-g/14骨干网络上采用Mask2Former流程（Steiner等人，2021）并叠加ViT-Adapter（Chen等人，2023b），在ADE-20k上获得了60.2 mIoU。

7.4 密集识别任务

我们在多个密集下游任务中探究了从我们网络中提取的补丁级特征的质量。我们在多种设置下考虑了语义图像分割和单目深度估计，并针对每个任务在多个数据集上进行了评估。

语义分割。在我们的语义分割评估中，我们考虑了两种不同的设置。线性：训练一个线性层从图像块标记中预测类别对数概率。它用于生成低分辨率对数概率图（例如，对于块大小为16的模型，生成32x32的图），然后上采样到全分辨率（512x512）以获得分割图。这个过程极其简单，但难以生成高分辨率分割。+ms：线性设置的增强版本。我们拼接最后4层的图像块标记，使用更大的图像分辨率640，并采用多尺度测试时间增强来改进预测。我们在表10中报告了两种设置下，我们的模型变体以及基线在三个数据集上的性能。

我们的模型在所有数据集和所有设置上都表现出非常优异的性能。有趣的是，使用+ms进行评估时，我们的结果与使用Upernet解码器对MAE进行完全微调的效果相当（53.0对比53.6 mIoU）。这令人惊讶，因为我们使用的预测器要简单得多。此外，我们最好的模型在使用增强方案进行评估时，几乎达到了Pascal VOC上的最先进水平（86.2对比89.0 mIoU）。

SOTA流程中的冻结骨干网络。在最后一个实验中，我们冻结了骨干网络，并将其接入ViT-Adapter（Chen等人，2023b）与Mask2former头部（Cheng等人，2022）。我们调整了适配器和头部的权重，但保持骨干网络冻结，这意味着66%的权重被固定。相比完整的端到端微调，这种设置能实现更轻量的分割训练。在此配置下，我们在ADE20k数据集上取得了60.2 mIoU，接近当前62.9 mIoU的竞争性技术水平（Wang等人，2022）。尽管本实验未采用第5节所述的优化策略，但分割训练仍在16块V100 GPU上耗时28小时完成。

深度估计。在本实验中，我们在三个单目深度估计基准上评估了我们的块级特征：NYUd、KITTI以及从NYUd到SUN3d的零样本迁移。我们遵循Li等人（2022b）的评估协议。为此评估，我们考虑了三种不同的设置。lin. 1：我们提取冻结transformer的最后一层，并将[CLS]标记与每个块标记拼接。然后，我们将标记双线性上采样4倍以提高分辨率。最后，我们通过将深度预测范围划分为256个均匀分布的区间并使用分类损失来训练一个简单的线性层。

Method	Arch.	NYUd (0.330)			KITTI (2.10)			NYUd $\rightarrow$ SUN RGB-D (0.421)		
		lin. 1	lin. 4	DPT	lin. 1	lin. 4	DPT	lin. 1	lin. 4	DPT
OpenCLIP	ViT-G/14	0.541	0.510	0.414	3.57	3.21	2.56	0.537	0.476	0.408
MAE	ViT-H/14	0.517	0.483	0.415	3.66	3.26	2.59	0.545	0.523	0.506
DINO	ViT-B/8	0.555	0.539	0.492	3.81	3.56	2.74	0.553	0.541	0.520
iBOT	ViT-L/16	0.417	0.387	0.358	3.31	3.07	2.55	0.447	0.435	0.426
DINOv2	ViT-S/14	0.449	0.417	0.356	3.10	2.86	2.34	0.477	0.431	0.409
	ViT-B/14	0.399	0.362	0.317	2.90	2.59	2.23	0.448	0.400	0.377
	ViT-L/14	0.384	0.333	0.293	2.78	2.50	2.14	0.429	0.396	0.360
	ViT-g/14	0.344	0.298	0.279	2.62	2.35	2.11	0.402	0.362	0.338

表11：使用冻结特征的深度估计。我们报告了在一个（lin. 1）或四个（lin. 4）Transformer层之上训练线性分类器，以及Ranftl等人（2021）的DPT解码器（DPT）时的性能。我们在3个数据集上报告了RMSE指标，数值越低越好。作为参考，我们在表格顶部列出了每个基准测试中来自Li等人（2022b）的最新研究成果。

采用Bhat等人（2021）的线性归一化方法。第4行：我们使用与单层相同的处理流程，但对于ViT-S/B模型，将第 $l = \{3, 6, 9, 12\}$ 层的特征标记进行拼接；对于ViT-L模型，拼接第 $l = \{5, 12, 18, 24\}$ 层；对于ViT-g模型，则拼接第 $l = \{10, 20, 30, 40\}$ 层。DPT部分：我们在冻结模型基础上采用DPT解码器（Ranftl等人，2021）并建立回归任务。根据各架构的特征维度调整头部尺寸。所有基线方法、数据集及配置的结果均展示在表11中。

从该表中可以看出，我们的特征明显超越了当前最优的自监督学习和弱监督学习特征。有趣的是，从ViT-L提取的iBOT特征甚至优于基于ViT-G的OpenCLIP特征。这一观察印证了我们的直觉：基于标题的特征学习方法难以捕捉此类细微模式。此外，采用DPT解码器并冻结主干网络的模型，在性能上达到甚至超越了Li等人（2022b）的最新研究成果。最后，在SUN-RGBd数据集上的跨领域泛化结果表明，我们的特征能够实现出色的跨域迁移效果——在NYUd室内场景训练得到的深度预测模块，对SUN-RGBd的室外样本同样表现出优秀的泛化能力。

7.5 定性结果

在实证评估我们特征的最后一节中，我们提出了一些定性分析。

语义分割与深度估计。我们展示了密集预测评估的一些定性结果：图7中的ADE20K分割以及图7中NYUd、KITTI和SUN RGB-D的深度估计。我们在每个数据集上将DINOv2与搭载线性分类器的OpenCLIP进行对比。尽管不够完美，但使用DINOv2骨干网络的线性分割模型产生了良好结果，在此评估设置下的表现远优于OpenCLIP模型。实际上，OpenCLIP-G生成的分割掩码存在大量伪影和断裂区域。深度估计的定性结果清晰展示了OpenCLIP与DINOv2之间的量化差距。这些结果表明，我们的特征以及从OpenCLIP提取的特征能够线性分离深度等复杂信息，尽管两者均未使用此类信息进行训练。然而，我们的特征能实现更平滑的深度估计，且伪影更少。在SUN RGB-D图像中，诸如椅子等物体被OpenCLIP完全忽略，而使用我们的特征则能准确定位。

分布外泛化。我们在图8中展示了将深度预测和分割线性分类器应用于分布外样本的几个示例。定性结果支持我们的特征能够在不同领域间迁移的结论。尽管动物图片或绘画作品的领域差异巨大，但预测出的深度和分割质量仍然非常出色。




图7：使用线性分类器进行分割和深度估计。示例来自ADE20K、NYUd、SUN RGB-D和KITTI数据集，采用冻结的OpenCLIP-G和DINOv2-g特征进行线性探测。



图8：使用冻结的DINOv2-g特征和线性探针的分布外示例。

补丁特征的主成分分析。我们展示了基于模型提取的补丁特征进行主成分分析（PCA）的结果。我们仅保留第一主成分阈值化后具有正值的补丁。这一过程成功将图像主体与背景分离。随后，我们对三张同类图像中剩余的补丁进行第二次PCA分析。我们将前三个主成分分别用三种颜色标注，结果呈现在图1和图9中。有两个值得注意的发现：首先，我们基于最高方差方向检测的无监督前景/背景分离器表现优异，能够清晰勾勒出图像中主体的轮廓边界。其次，其他主成分对应物体的“部件”，在同类图像中具有良好的一致性。这是一种涌现特性——我们的模型并未经过物体部件解析的训练。




图9：第一主成分的更多可视化展示。我们计算了所有图像中图像块之间的主成分分析，并展示了它们的前三个成分。每个成分对应一个特定的颜色通道。尽管姿态、风格甚至物体发生变化，相关图像间的相同部分仍能匹配。通过移除第一主成分得分为负的图像块，背景已被去除。

补丁匹配。最后，我们通过跨图像匹配补丁级特征来探索它们包含何种信息。首先使用上述方法检测前景物体。接着，计算从两幅图像中提取的补丁特征之间的欧氏距离，并通过求解分配问题建立映射关系。为减少匹配数量，我们随后应用非极大值抑制仅保留显著匹配。图10展示了此类匹配的若干示例。

我们观察到，这些特征似乎捕捉到了在不同物体或动物中具有相似功能的语义区域信息。例如，飞机的机翼与鸟类的翅膀相匹配。我们还注意到，该模型对风格（图像与绘图）以及姿态的大幅变化（参见大象示例）具有鲁棒性。

8 公平性与偏见分析

我们对模型进行了两项公平性评估。我们探究了地理公平性和潜在有害标签关联。在这两项评估中，我们均采用了最大的ViT-g模型进行实验。

8.1 地理公平性

我们在De Vries等人（2019年）提出的Dollar Street数据集上，采用Goyal等人（2022b）的评估协议来评估地理公平性。该基准测试比较了不同国家和收入水平下的模型性能，包含来自54个国家289个家庭的16,073张图像，任务要求识别94个因家庭收入或地理位置而产生视觉差异的概念。在表12中，我们将模型与SEERv2（Goyal等人，2022a）进行对比——后者是基于地理多样性图像集训练的模型。我们的模型在跨地区和收入群体中表现出比SEERv2稍高的公平性，且显著优于Goyal等人（2022a）报告的有监督基线。然而，我们仍观察到地区间的显著差异，特别是在非洲地区，模型性能较欧洲下降了25.7%。这表明我们的模型仍存在对西方国家的偏向性。同样，我们的模型在……




图10：跨图像匹配。我们在不同领域、姿态甚至共享相似语义信息的物体图像之间匹配块级特征。这展示了我们模型跨领域迁移以及理解不同物体相似部分之间关系的能力。

Method	Arch.	Data	Income buckets			Regions			
			low	medium	high	Africa	Asia	Americas	Europe
SEERv2	RG-10B	IG-1B	59.7	78.5	86.6	65.9	76.3	81.1	85.6
DINOv2	ViT-g/14	LVD-142M	67.4	83.3	90.5	74.0	81.6	86.2	89.7

表12：地理 跨收入群体的公平性和多样性分析 票券和区域。

对高收入家庭的改善效果明显优于低收入家庭，差异达31.7%。尽管有所改进，我们仍观察到模型明显偏向来自西方国家的富裕家庭。

8.2 性别、肤色与年龄

在第二组评估中，我们探讨了模型如何对不同性别、肤色和年龄（均为自我报告）的人物图像进行分类。我们遵循Goyal等人（2022b）的评估方案，在ImageNet-22k的619个类别子集上训练了一个多类别分类器，并将这些类别归纳为四大类：人类、可能人类、非人类或犯罪。其中非人类和犯罪类别被视为有害类别。使用该分类器，我们对Casual Conversations数据集（Hazirbas等人，2021）中的2955张图像进行推理，并保留前5个预测中概率达到0.1或以上的所有标签。因此，每张图像可能被赋予多个类别。我们对原始评估方案进行了一项调整：不向主干网络反向传播梯度，保持其冻结状态。我们在表13中将我们的模型与SEERv2进行了比较。

Model	Assoc.	Gender Skintone				Age Groups			
		female darker	female lighter	male darker	male lighter	18-30	30-45	45-70	70+
SEER RG-10B	Non-Human	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	Crime	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	Human	94.9	95.8	86.6	79.0	90.5	88.3	91.9	82.3
	Possibly-Human	13.6	6.7	65.0	60.2	32.8	37.2	29.4	6.5
DINOv2 ViT-g/14	Non-Human	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
	Crime	0.0	0.0	0.2	0.0	0.0	0.1	0.0	0.0
	Human	97.3	97.7	86.1	84.0	91.2	90.2	93.2	88.7
	Possibly-Human	15.8	17.2	52.2	48.1	35.3	37.3	23.0	9.7

表13: 跨性别、肤色和年龄组的标签关联公平性评估。我们遵循Goyal等人（2022b）提出的方案，并稍作修改：不微调主干网络，仅在ImageNet-22k的619个子类上训练线性分类器。

Model to Reproduce	GPU Type	GPU Power consumption	GPU-hours	PUE	Total power consumption	Carbon emitted (tCO ₂ eq)
DINOv2-g	A100-40GB	400W	22,016	1.1	9.7 MWh	3.7

表14: DINOv2复现的碳足迹。我们假设A100-40GB功耗为400W、PUE为1.1、碳强度系数为每千瓦时0.385千克CO₂e，据此报告复现DINOv2-g的潜在碳排放量。

我们的模型通常将所有群体的图像分类为人类，且在不同肤色间没有显著偏差。SEERv2和DINOv2均未从“非人类”或“犯罪”元类别中预测出有害标签（除两例背景包含视觉上类似监狱栅栏的条状物外）。我们发现，我们的模型频繁触发“可能为人类”类别。该类别由ImageNet-22k中常与人类相关的物体（如围巾、眼镜或胡须）构成。由于“胡须”类别的高频出现，我们的模型常将男性图像预测为“可能为人类”类。本研究未发现明显针对特定群体的偏见模式。尽管这一结果令人鼓舞，我们也承认更深入的偏见评估可能揭示模型的缺陷。

9 评估训练我们模型的环境影响

训练基础模型会消耗大量能源，导致二氧化碳排放。Patterson等人（2021）提出了一种方法，根据数据中心及其电网的具体情况，报告模型训练过程中碳排放的估算值。这一计算为用于模型训练的数据中心设计以及数据中心选址提供了参考依据。该方法需要了解用于训练的数据中心的具体情况，当涉及多个数据中心且时间跨度较长时，情况可能变得复杂。此外，这些具体细节通常不受AI从业者控制，因此，当从业者对未来训练做出技术决策时，该方法的帮助有限。相反，在本节中，我们采用另一种方法，报告在美国一个平均数据中心重新训练类似模型的潜在碳排放量。该方法在自然语言处理领域的前期工作中已有应用（Strubell等人，2019；Touvron等人，2023），用于在不同预训练方案之间建立公平比较。具体而言，我们将所有外生变量（即电网的电力使用效率（PUE）和碳强度因子）固定为与Touvron等人（2023）相同的数值，即PUE为1.1，碳强度因子为美国平均值0.385千克CO₂eq/千瓦时。我们使用与Patterson等人（2021）相同的公式来估算潜在能耗和碳排放量。对于A100-80GB的功耗，我们采用NVLink系统的热设计功耗，即400W。我们报告潜在碳排放量

在表14中，我们展示了重新训练DINOv2 ViT-g的能耗。作为对比，若在同一数据中心运行，重新训练OpenCLIP ViT-L或OpenCLIP ViT-G将分别消耗22.4兆瓦时和118.9兆瓦时，这意味着会增加10×的碳排放量。需要注意的是，这种对比对他们而言并不公平，因为他们还同时训练了文本编码器，因此我们未在表中列出这些数据。然而，这为那些仅关注视觉特征训练的研究者提供了合理的参考：在此背景下，从碳排放角度考虑，训练自监督模型更为可取。当然，若计划复用文本编码器，训练文本引导模型仍然具有实际意义。

整个项目的碳足迹。此外，我们使用上述相同的电网估算整个项目的碳足迹在0.5k至1k吨CO₂当量之间³。这一碳足迹相当于约20万GPU日的能耗。排放的主要来源是模型的自监督预训练。例如，单次ViT-g模型的预训练（2.2万GPU小时）会排放3.7吨CO₂当量，而在ImageNet-1k上的微调（1千GPU小时）会排放0.2吨。此估算仅考虑了GPU的电力消耗，未包含其他排放源，例如设备制造与废弃处理。

10 未来工作与讨论

在本工作中，我们提出了DINOv2——一个基于大规模精选数据无监督预训练的新型图像编码器系列。这是首个在图像数据上实现自监督学习的研究，其视觉特征在广泛基准测试中弥合了与（弱）监督方法的性能差距，且无需微调。DINOv2模型家族的卓越性能可归因于以下因素：i) 改进的训练方案（包含更优越参数与正则化策略，见表1）；ii) 更大的模型规模（无论使用何种训练数据均能提升效果，见图4）；iii) 更庞大的数据集（图4）；iv) 蒸馏过程使较小模型能受益于最强ViT-g模型的性能（图5）。这些模型展现出若干特性，例如跨图像域理解物体部件与场景几何结构的能力。我们预期在更大规模的模型与数据中会涌现更多此类特性，类似于大语言模型中的指令涌现现象，并计划持续沿这些方向扩展规模。本文还证明这些视觉特征可与简单如线性层的分类器兼容——这意味着底层信息具有*readily available*特性。未来工作中，我们计划利用这种能力训练具备语言理解的AI系统，使其能像处理词元那样处理视觉特征，并从中提取必要信息以构建系统基础。

致谢。

我们感谢Mathilde Caron在项目初期的讨论，这些讨论促成了本工作的诞生。Julien Mairal得到了ERC资助（编号101087696，APHELAIA项目）以及ANR 3IA MIAI@Grenoble Alpes（ANR-19-P3IA-0003）的支持。我们感谢Olivia Joulin为图10提供的马匹绘图。感谢Madeleine和Léon为图8出镜。同时，我们也感谢FAIR及Meta AI的全体成员在整个项目期间对本工作提出的反馈意见。

参考文献

Shir Amir, Yossi Gandelsman, Shai Bagon, and Tali Dekel. Deep vit features as dense visual descriptors. In *ECCV workshop on "What is Motion For?"*, 2022.

Yuki Markus Asano, Christian Rupprecht 和 Andrea Vedaldi. 通过同步聚类与表征学习进行自标注。收录于 *ICLR*, 2020年。

Mahmoud Assran, Mathilde Caron, Ishan Misra, Piotr Bojanowski, Florian Bordes, Pascal Vincent, Armand Joulin, Michael Rabbat, and Nicolas Ballas. 用于标签高效学习的掩码孪生网络。In *ECCV*, 2022.

³作为背景，一架波音777客机在伦敦和纽约之间的完整往返航班大约对应560吨二氧化碳当量（tCO₂eq）。

Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann Le Cun 与 Nicolas Ballas。基于图像的联合嵌入预测架构的自监督学习。发表于 *CVPR*, 2023年。

Alexei Baevski, Wei-Ning Hsu, Qiantong Xu, Arun Babu, Jiatao Gu 和 Michael Auli。Data2vec: 一种用于语音、视觉和语言自监督学习的通用框架。发表于 *ICML*, 2022年。

Hangbo Bao, Li Dong, and Furu Wei。BEiT: 基于图像变换器的BERT预训练。发表于 *ICLR*, 2021。

Jan Beirlant, Edward J Dudewicz, László Györfi, Edward C Van der Meulen 等人。非参数熵估计: 综述。*International Journal of Mathematical and Statistical Sciences*, 6(1):17–39, 1997。

马克西姆·伯曼、埃尔韦·热古、韦达利·安德烈亚、亚索纳斯·科基诺斯和马蒂斯·杜泽。MultiGrain: 一种用于类别和实例的统一图像嵌入方法。*arXiv preprint arXiv:1902.05509*, 2019年。

卢卡斯·拜尔、奥利维尔·J埃纳夫、亚历山大·科列斯尼科夫、翟晓华和亚伦·范登奥德。我们是否已完成ImageNet? *arXiv preprint arXiv:2006.07159*, 2020年。

卢卡斯·拜尔、帕维尔·伊兹梅洛夫、亚历山大·科列斯尼科夫、玛蒂尔德·卡隆、西蒙·科恩布利斯、翟小华、马蒂亚斯·明德雷尔、迈克尔·查宁、易卜拉欣·阿拉卜杜勒莫辛和菲利普·帕维蒂奇。Flexivit: 适用于所有补丁尺寸的统一模型。发表于 *CVPR*, 2023年。

Shariq Farooq Bhat, Ibraheem Alhashim 与 Peter Wonka。AdaBins: 基于自适应分箱的深度估计。发表于 *CVPR*, 2021年。

Piotr Bojanowski 与 Armand Joulin。通过预测噪声进行无监督学习。发表于 *ICML*, 2017年。

Rishi Bommasani, Drew A Hudson, Ehsan Adali, Russ Altman, Simran Arora, Sydney von Arx, Michael S Bernstein, Jeannette Bohg, Antoine Bosselut, Emma Brunskill 等。论基础模型的机遇与风险。*arXiv preprint arXiv:2108.07258*, 2021。

卢卡斯·博萨德、马蒂厄·吉约曼和吕克·范·古尔。《Food-101——利用随机森林挖掘判别性成分》。载于 *ECCV*, 2014年。

汤姆·B·布朗、本杰明·曼、尼克·赖德、梅兰妮·苏比亚、贾里德·卡普兰、普拉富拉·达里瓦尔、阿尔温德·尼拉坎坦、普拉纳夫·夏姆、吉里什·萨斯特里、阿曼达·阿斯科尔等。语言模型是小样本学习者。发表于 *NeurIPS*, 2020年。

Mathilde Caron, Piotr Bojanowski, Armand Joulin 和 Matthijs Douze。用于视觉特征无监督学习的深度聚类。收录于 *ECCV*, 2018年。

Mathilde Caron, Piotr Bojanowski, Julien Mairal 与 Armand Joulin。基于非精选数据的图像特征无监督预训练。收录于 *ICCV*, 2019年。

Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski 和 Armand Joulin。通过对比聚类分配进行视觉特征的无监督学习。发表于 *NeurIPS*, 2020年。

Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin。自监督视觉Transformer中的新兴特性。发表于 *ICCV*, 2021年。

Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam。用于语义图像分割的带孔可分离卷积编码器-解码器。于 *ECCV*, 2018。

Ting Chen, Simon Kornblith, Mohammad Norouzi 与 Geoffrey Hinton。一种用于视觉表示对比学习的简单框架。发表于 *ICML*, 2020年。

向宁陈、陈亮、大荒、埃斯特班·雷亚尔、开元王、尧刘、休范、玄义董、唐龙、谢卓如等。优化算法的符号发现。*arXiv preprint arXiv:2302.06675*, 2023a。

辛雷和陈恺明。探索简单的孪生表示学习。于 *CVPR*, 2021。

辛磊、谢赛宁与何恺明。自监督视觉Transformer训练的实证研究。发表于 *ICCV*, 2021年。

陈哲、段宇辰、王文海、何俊君、卢同、戴继峰、乔宇。面向密集预测的视觉Transformer适配器。发表于 *ICLR*, 2023b。

Bowen Cheng, Ishan Misra, Alexander G Schwing, Alexander Kirillov 和 Rohit Girdhar。用于通用图像分割的掩码注意力掩码变换器。发表于 *CVPR*, 2022年。

Mehdi Cherti, Romain Beaumont, Ross Wightman, Mitchell Wortsman, Gabriel Ilharco, Cade Gordon, Christoph Schuhmann, Ludwig Schmidt, and Jenia Jitsev。对比语言-图像学习的可复现缩放定律。发表于 *CVPR*, 2023年。

Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann 等人。Palm: 基于Pathways的扩展语言建模。 *arXiv preprint arXiv:2204.02311*, 2022年。

M. Cimpoi, S. Maji, I. Kokkinos, S. Mohamed, 和 A. Vedaldi。描述自然场景中的纹理。发表于 *CVPR*, 2014年。

Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth 和 Bernt Schiele。用于语义城市场景理解的城市景观数据集。发表于 *CVPR*, 2016年。

Tri Dao, Daniel Y. Fu, Stefano Ermon, Atri Rudra 和 Christopher Ré。Flashattention: 具有 IO 感知能力的快速、内存高效精确注意力机制。发表于 *NeurIPS*, 2022 年。

Terrance De Vries, Ishan Misra, Chaghan Wang, and Laurens Van der Maaten。物体识别技术对所有人都有效吗? 载于 *CVPR workshops*, 2019。

西尔万·德拉特尔与尼古拉·富尼耶。关于科扎琴科-列奥年科熵估计器。 *Journal of Statistical Planning and Inference*, 185: 69–93, 2017。

贾登, 魏东, Richard Socher, 李立佳, 李凯, 李飞飞。ImageNet: 一个大规模分层图像数据库。于 *CVPR*, 2009年。

Jacob Devlin, Ming-Wei Chang, Kenton Lee 和 Kristina Toutanova。BERT: 用于语言理解的深度双向 Transformer 预训练。 *NAACL*, 2019年。

Carl Doersch, Abhinav Gupta 和 Alexei A Efros。通过上下文预测进行无监督视觉表示学习。发表于 *ICCV*, 2015年。

Alexey Dosovitskiy, Philipp Fischer, Jost Tobias Springenberg, Martin Riedmiller 和 Thomas Brox。基于范例卷积神经网络的判别式无监督特征学习。 *TPAMI*, 2016年。

Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, 翟晓华, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly 等。一幅图像价值 16x16 个词汇: 大规模图像识别中的 Transformer 模型。发表于 *ICLR*, 2021 年。

Matthijs Douze, Hervé Jégou, Harsimrat Sandhawalia, Laurent Amsaleg 和 Cordelia Schmid。面向网络规模图像搜索的gist描述符评估。收录于 *CIVR*, 2009年。

Quentin Duval, Ishan Misra 与 Nicolas Ballas。一种构建具有竞争力的低计算量自监督视觉模型的简易方案。 *arXiv preprint arXiv:2301.09451*, 2023年。

Alaaeldin El-Nouby, Gautier Izacard, Hugo Touvron, Ivan Laptev, Hervé Jegou 和 Edouard Grave。大规模数据集对于自监督预训练是否必要? *arXiv preprint arXiv:2112.10740*, 2021。

Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn 和 Andrew Zisserman。PASCAL 视觉对象类别 (VOC) 挑战赛。 *IJCV*, 2010。

方玉欣、王文、谢斌辉、孙全、吴乐德、王兴刚、黄铁军、王新龙、曹越。EVA：探索大规模掩码视觉表征学习的极限。发表于 *CVPR*, 2023年。

李飞飞、Rob Fergus 和 Pietro Perona。从少量训练样本中学习生成式视觉模型：一种在 101 个物体类别上测试的增量贝叶斯方法。发表于 *CVPR*, 2004 年。

Andreas Geiger, Philip Lenz, Christoph Stiller 和 Raquel Urtasun。视觉与机器人学的交汇：KITTI数据集。 *IJRR*, 2013。

Spyros Gidaris、Praveer Singh 和 Nikos Komodakis。通过预测图像旋转进行无监督表示学习。发表于 *ICLR*, 2018年。

罗希特·吉尔达尔、阿拉埃尔丁·埃尔努比、曼纳特·辛格、卡利安·瓦苏德夫·阿尔瓦拉、阿尔芒·朱林 and 伊山·米斯拉。Omnimae：图像与视频上的单模型掩码预训练。发表于 *CVPR*, 2023年。

Priya Goyal、Dhruv Mahajan、Abhinav Gupta 和 Ishan Misra。自监督视觉表征学习的规模化与基准测试。收录于 *ICCV*, 2019年。

Priya Goyal, Mathilde Caron, Benjamin Lefaudeaux, Min Xu, Pengchao Wang, Vivek Pai, Mannat Singh, Vitaliy Liptchinsky, Ishan Misra, Armand Joulin 等。在真实场景中视觉特征的自监督预训练。 *preprint arXiv:2103.01988*, 2021。

Priya Goyal、Quentin Duval、Isaac Seessel、Mathilde Caron、Mannat Singh、Ishan Misra、Levent Sagun、Armand Joulin 和 Piotr Bojanowski。视觉模型在未经筛选的无监督图像上进行预训练时更具鲁棒性和公平性。 *arXiv preprint arXiv:2202.08360*, 2022a。

Priya Goyal、Adriana Romero Soriano、Caner Hazirbas、Levent Sagun 与 Nicolas Usunier。视觉特征提取器系统化评估的公平性指标。发表于 *FAccT*, 2022b。

Raghav Goyal、Samira Ebrahimi Kahou、Vincent Michalski、Joanna Materzynska、Susanne Westphal、Heuna Kim、Valentin Haenel、Ingo Fruend、Peter Yianilos、Moritz Mueller-Freitag 等人。用于学习和评估视觉常识的“something something”视频数据库。收录于 *ICCV*, 2017年。

Jean-Bastien Grill, Florian Strub, Florent Althé, Corentin Tallec, Pierre H Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko。引导你的潜在层：一种自监督学习的新方法。发表于 *NeurIPS*, 2020年。

Raia Hadsell、Sumit Chopra 和 Yann LeCun。通过学习不变映射进行降维。发表于 *CVPR*, 2006年。

Mark Hamilton、Zhoutong Zhang、Bharath Hariharan、Noah Snavely 与 William T Freeman。通过蒸馏特征对应实现无监督语义分割。发表于 *ICLR*, 2022年。

Caner Hazirbas、Joanna Bitton、Brian Dolhansky、Jacqueline Pan、Albert Gordo 和 Cristian Canton Ferrer。迈向衡量人工智能公平性：因果对话数据集。 *IEEE Transactions on Biometrics, Behavior, and Identity Science*, 2021年。

Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick。动量对比用于无监督视觉表示学习。于 *CVPR*, 2020。

何恺明、陈鑫磊、谢赛宁、李阳昊、Piotr Dollár 和 Ross Girshick。掩码自编码器是可扩展的视觉学习器。发表于 *CVPR*, 2022年。

Olivier J Hénaff, Aravind Srinivas, Jeffrey De Fauw, Ali Razavi, Carl Doersch, SM Eslami 和 Aaron van den Oord。基于对比预测编码的数据高效图像识别。 *PMLR*, 2019。

Dan Hendrycks 和 Thomas Dietterich。基准测试神经网络对常见损坏和扰动的鲁棒性。发表于 *ICLR*, 2019年。

Dan Hendrycks、Steven Basart、Norman Mu、Saurav Kadavath、Frank Wang、Evan Dorundo、Rahul Desai、Tyler Zhu、Samyak Parajuli、Mike Guo 等。稳健性的多面性：对分布外泛化的批判性分析。载于 *ICCV*, 2021a。

Dan Hendrycks、Kevin Zhao、Steven Basart、Jacob Steinhardt 和 Dawn Song。自然对抗样本。收录于 *CVPR*, 2021b。

杰弗里·辛顿、奥里奥尔·维尼亚尔斯和杰夫·迪恩。蒸馏神经网络中的知识。发表于 *NeurIPS Deep Learning Workshop*, 2014年。

乔丹·霍夫曼、塞巴斯蒂安·博尔戈、亚瑟·门施、埃琳娜·布查茨卡娅、特雷弗·蔡、伊莱扎·卢瑟福、迭戈·德拉斯卡萨斯、丽莎·安妮·亨德里克斯、约翰内斯·韦尔布、艾丹·克拉克等。训练计算最优的大型语言模型。*arXiv preprint arXiv:2203.15556*, 2022年。

高黄、孙宇、刘壮、Daniel Sedra 和 Kilian Q Weinberger。具有随机深度的深度网络。发表于 *ECCV*, 2016年。

Gabriel Ilharco、Mitchell Wortsman、Ross Wightman、Cade Gordon、Nicholas Carlini、Rohan Taori、Achal Dave、Vaishaal Shankar、Hongseok Namkoong、John Miller、Hannaneh Hajishirzi、Ali Farhadi 与 Ludwig Schmidt。Openclip。2021。

Herve Jegou, Matthijs Douze 与 Cordelia Schmid。面向最近邻搜索的乘积量化。 *TPAMI*, 2010年。

Jeff Johnson, Matthijs Douze 和 Hervé Jégou。基于GPU的十亿级相似性搜索。 *IEEE Transactions on Big Data*, 2019。

Armand Joulin、Laurens Van Der Maaten、Allan Jabri 与 Nicolas Vasilache。基于大规模弱监督数据学习视觉特征。发表于 *ECCV*, 2016年。

威尔·凯、若昂·卡雷拉、卡伦·西蒙尼安、布莱恩·张、克洛伊·希利尔、苏迪恩德拉·维贾亚纳拉西姆汉、法比奥·维奥拉、蒂姆·格林、特雷弗·巴克、保罗·纳采夫等人。动力学人类动作视频数据集。 *arXiv preprint arXiv:1705.06950*, 2017年。

Jonathan Krause, Michael Stark, Jia Deng, 李飞飞。用于细粒度分类的3D物体表示。发表于 *3DRR*, 2013。

马里奥·迈克尔·克雷尔、马特伊·科塞克、塞尔吉奥·P·佩雷斯和安德鲁·菲茨吉本。无交叉污染的高效序列打包：在不影响性能的前提下加速大型语言模型，2022。

Alex Krizhevsky、Geoffrey Hinton 等人。从微小图像中学习多层特征。2009。

Benjamin Lefaudeux、Francisco Massa、Diana Liskovich、Wenhan Xiong、Vittorio Caggiano、Sean Naren、Min Xu、Jieru Hu、Marta Tintore、Susan Zhang、Patrick Labatut 和 Daniel Haziza。xformers：一个模块化且可深度定制的Transformer建模库。<https://github.com/facebookresearch/xformers>, 2022年。

Chunyuan Li, Jianwei Yang, Pengchuan Zhang, Mei Gao, Bin Xiao, Xiyang Dai, Lu Yuan, and Jianfeng Gao. Efficient self-supervised vision transformers for representation learning. In *ICLR*, 2022a.

李振宇、王旭阳、刘贤明、蒋俊君。Binsformer：重新审视单目深度估计中的自适应分箱。*arXiv preprint arXiv:2204.00987*, 2022b。

Tatiana Likhomanenko、Qiantong Xu、Gabriel Synnaeve、Ronan Collobert 与 Alex Rogozhnikov。Cape：使用连续增强位置嵌入编码相对位置。收录于 *NeurIPS*, 2021年。

刘华军、刘富强、范新一、黄东。极化自注意力：迈向高质量像素级回归。*arXiv preprint arXiv:2107.00782*, 2021年。

Dhruv Mahajan、Ross Girshick、Vignesh Ramanathan、何恺明、Manohar Paluri、李轶轩、Ashwin Bharambe 和 Laurens van der Maaten。探索弱监督预训练的极限。发表于 *ECCV*, 2018年。

S. Maji, J. Kannala, E. Rahtu, M. Blaschko 与 A. Vedaldi。细粒度飞机视觉分类。技术报告, 2013年。

Ishan Misra 和 Laurens van der Maaten。基于借口不变表征的自监督学习。发表于 *CVPR*, 2020年。

Maria-Elena Nilsback 与 Andrew Zisserman。基于大量类别的自动化花卉分类。收录于 *ICVGIP*, 2008年。

Mehdi Noroozi 和 Paolo Favaro。通过解决拼图游戏进行视觉表征的无监督学习。发表于 *ECCV*, 2016年。

Dolev Ofri-Amar, Michal Geyer, Yoni Kasten 与 Tali Dekel。神经凝结: 将图像对齐到联合语义图谱。收录于 *CVPR*, 2023。

Omkar M. Parkhi, Andrea Vedaldi, Andrew Zisserman 和 C. V. Jawahar。《猫与狗》。发表于 *CVPR*, 2012年。

Deepak Pathak, Philipp Krähenbühl, Jeff Donahue, Trevor Darrell 和 Alexei Efros。上下文编码器: 通过修复进行特征学习。发表于 *CVPR*, 2016年。

David Patterson, Joseph Gonzalez, Quoc Le, 陈亮, Lluís-Miquel Munguia, Daniel Rothchild, David So, Maud Texier 和 Jeff Dean。大型神经网络训练的碳排放。 *arXiv preprint arXiv:2104.10350*, 2021年。

Ed Pizzi, Sreya Dutta Roy, Sugosh Nagavara Ravindra, Priya Goyal 和 Matthijs Douze。一种用于图像复制检测的自监督描述符。发表于 *CVPR*, 2022年。

Filip Radenovi , Ahmet Iscen, Giorgos Tolias, Yannis Avrithis 和 Ondřej Chum。重访牛津与巴黎: 大规模图像检索基准测试。收录于 *CVPR*, 2018a。

Filip Radenovi , Giorgos Tolias 和 Ondřej Chum。无需人工标注的CNN图像检索微调。 *TPAMI*, 2018b。

亚历克·拉德福德、拉法尔·约瑟福维奇和伊利亚·苏茨克弗。学习生成评论与发现情感。 *arXiv preprint arXiv:1704.01444*, 2017年。

亚历克·拉德福德、杰弗里·吴、雷文·柴尔德、大卫·吕安、达里奥·阿莫代伊和伊利亚·苏茨克弗。语言模型是无监督多任务学习者。2019。

亚历克·拉德福德、金钟旭、克里斯·哈拉西、阿迪亚·拉梅什、加布里埃尔·高、桑迪尼·阿加瓦尔、吉里什·萨斯特里、阿曼达·阿斯科尔、帕梅拉·米什金、杰克·克拉克等。从自然语言监督中学习可迁移的视觉模型。发表于 *ICML*, 2021年。

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, Peter J Liu 等人。探索统一文本到文本转换器在迁移学习中的极限。 *JMLR*, 2020年。

René Ranftl, Alexey Bochkovskiy 和 Vladlen Koltun。用于密集预测的视觉 Transformer。收录于 *ICCV*, 2021年。

Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt 和 Vaishaal Shankar。ImageNet 分类器能泛化到 ImageNet 吗? 发表于 *ICML*, 2019年。

Jerome Revaud, Jon Almazán, Rafael S Rezende 和 Cesar Roberto de Souza。以平均精度学习: 使用列表损失训练图像检索。收录于 *ICCV*, 2019年。

杨军阮, Saurabh Singh, Warren Morningstar, Alexander A Alemi, Sergey Ioffe, Ian Fischer 和 Joshua V Dillion。加权集成自监督学习。发表于 *ICLR*, 2023年。

Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C Berg 和李飞飞。ImageNet 大规模视觉识别挑战赛。IJCV, 2015年。

Alexandre Sablayrolles, Matthijs Douze, Cordelia Schmid 和 Hervé Jégou。用于相似性搜索的扩散向量。收录于 ICLR, 2019年。

Christoph Schuhmann, Richard Vencu, Romain Beaumont, Robert Kaczmarczyk, Clayton Mullis, Aarush Katta, Theo Coombes, Jenia Jitsev 和 Aran Komatsuzaki。Laion-400m: 包含 4 亿个经 CLIP 筛选的图像-文本对的开放数据集。收录于 *NeurIPS Data Centric AI Workshop*, 2021 年。

Christoph Schuhmann, Romain Beaumont, Richard Vencu, Cade Gordon, Ross Wightman, Mehdi Cherti, Theo Coombes, Aarush Katta, Clayton Mullis, Mitchell Wortsman 等人。Laion-5b: 一个用于训练下一代图文模型的大规模开放数据集。发表于 *NeurIPS*, 2022年。

诺姆·沙泽尔。Glu变体改进Transformer。arXiv preprint arXiv:2002.05202, 2020年。

Nathan Silberman, Derek Hoiem, Pushmeet Kohli 和 Rob Fergus。基于 RGBD 图像的室内分割与支撑关系推断。收录于 ECCV, 2012年。

Mannat Singh, Laura Gustafson, Aaron Adcock, Vinicius de Freitas Reis, Bugra Gedik, Raj Prateek Kosaraju, Dhruv Mahajan, Ross Girshick, Piotr Dollár 与 Laurens van der Maaten。重新审视视觉感知模型的弱监督预训练。发表于 CVPR, 2022年。

Shuran Song, Samuel P Lichtenberg 和 Jianxiong Xiao。Sun rgb-d: 一个 rgb-d 场景理解基准测试套件。发表于 CVPR, 2015年。

Khurram Soomro, Amir Roshan Zamir 和 Mubarak Shah。Ucf101: 一个包含 101 类野外视频中人类动作的数据集。arXiv preprint arXiv:1212.0402, 2012。

Andreas Steiner, Alexander Kolesnikov, Xiaohua Zhai, Ross Wightman, Jakob Uszkoreit 和 Lucas Beyer。如何训练您的视觉Transformer? 视觉Transformer中的数据、增强与正则化。TMLR, 2021。

Emma Strubell, Ananya Ganesh 和 Andrew McCallum。自然语言处理中深度学习的能耗与政策考量。ACL, 2019年。

Yonglong Tian, Olivier J Henaff 与 Aäron van den Oord。分而对比: 从未经整理的数据中进行自监督学习。发表于 ICCV, 2021年。

Giorgos Tolias, Ronan Sifre 与 Hervé Jégou。基于 CNN 激活积分最大池化的特定物体检索。收录于 ICLR, 2016年。

詹彤、宋一兵、王珏和王立民。Videomae: 掩码自编码器是用于自监督视频预训练的数据高效学习器。于 NeurIPS, 2022。

Hugo Touvron, Andrea Vedaldi, Matthijs Douze 与 Hervé Jégou。修正训练与测试分辨率差异。收录于 NeurIPS, 2019年。

Hugo Touvron, Matthieu Cord 与 Hervé Jégou。DeiT iii: 视觉Transformer的复仇。发表于 ECCV, 2022年。

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave 和 Guillaume Lample。Llama: 开放且高效的基础语言模型。arXiv preprint arXiv:2302.13971, 2023年。

Narek Tumanyan, Omer Bar-Tal, Shai Bagon 与 Tali Dekel。用于语义外观迁移的视觉Transformer特征拼接。收录于 CVPR, 2022年。

格兰特·范·霍恩、奥伊辛·麦克·埃奥达、杨松、崔寅、孙晨、亚历克斯·谢泼德、哈特维格·亚当、彼得罗·佩罗纳和谢尔盖·贝隆吉。《iNaturalist物种分类与检测数据集》。载于 CVPR, 2018年。

格兰特·范·霍恩、以利亚·科尔、萨拉·贝里、金伯利·威尔伯、谢尔盖·贝隆吉和奥伊辛·麦克·阿奥达。《自然世界图像集表示学习基准测试》。载于 *CVPR*, 2021年。

文海王, 继峰戴, 哲陈, 振航黄, 志奇李, 西洲朱, 晓伟胡, 童卢, 乐伟卢, 宏升李等。Internimage: 利用可变形卷积探索大规模视觉基础模型。发表于 *CVPR*, 2022年。

Xiaolong Wang, Allan Jabri, and Alexei A Efros. Learning correspondence from the cycle-consistency of time. In *CVPR*, 2019.

弗雷德里克·瓦伯格、索伦·豪贝格、曼努埃尔·洛佩斯-安特克拉、保·加加洛、邝宇彬和哈维尔·西韦拉。Mapillary街景序列: 一个用于终身地点识别的数据集。发表于 *CVPR*, 2020年。

Philippe Weinzaepfel, Thomas Lucas, Diane Larlus 和 Yannis Kalantidis. 学习用于图像检索的超特征。发表于 *ICLR*, 2021年。

P. Welinder, S. Branson, T. Mita, C. Wah, F. Schroff, S. Belongie, 和 P. Perona. Caltech-UCSD Birds 200. 技术报告 CNS-TR-2010-001, 2010年。

纪尧姆·文泽克、玛丽-安娜·拉肖、亚历克西斯·科诺、维什拉夫·乔杜里、弗朗西斯科·古兹曼、阿尔芒·朱林和爱德华·格拉夫。Ccnets: 从网络爬取数据中提取高质量单语数据集。发表于 *LREC*, 2020年。

Tobias Weyand, Andre Araujo, Bingyi Cao 和 Jack Sim. Google Landmarks Dataset v2——一个用于实例级识别与检索的大规模基准数据集。发表于 *CVPR*, 2020年。

吴志荣、熊元君、Stella X. Yu 与林达华。通过非参数实例判别进行无监督特征学习。发表于 *CVPR*, 2018年。

J. Xiao, J. Hays, K. A. Ehinger, A. Oliva, 与 A. Torralba. SUN数据库: 从修道院到动物园的大规模场景识别。发表于 *CVPR*, 2010年。

胡旭、李俊成、Alexei Baevski、Michael Auli、Wojciech Galuba、Florian Metze、Christoph Feichtenhofer 等。倾听的掩码自编码器。 *arXiv preprint arXiv:2207.06405*, 2022年。

I Zeki Yalniz, Hervé Jégou, Kan Chen, Manohar Paluri 和 Dhruv Mahajan. 用于图像分类的十亿级半监督学习。 *arXiv preprint arXiv:1905.00546*, 2019.

Burak Yildiz, Seyran Khademi, Ronald Maria Siebes 和 Jan van Gemert. Amstertime: 一个面向严重领域偏移的视觉位置识别基准数据集。收录于 *ICPR*, 2022年。

Nikolaos-Antonios Ypsilantis, Noa Garcia, Guangxing Han, Sarah Ibrahimi, Nanne Van Noord 与 Giorgos Tolias. Met 数据集: 艺术品实例级识别。收录于 *NeurIPS Datasets and Benchmarks Track*, 2021年。

Xiaohua Zhai, Alexander Kolesnikov, Neil Houlsby, and Lucas Beyer. Scaling vision transformers. In *CVPR*, 2022.

Richard Zhang, Phillip Isola 和 Alexei A Efros. 彩色图像上色。于 *ECCV*, 2016。

Bolei Zhou, Agata Lapedriza, Jianxiong Xiao, Antonio Torralba, and Aude Oliva. 使用Places数据库学习场景识别的深度特征。发表于 *NeurIPS*, 2014.

Bolei Zhou, Hang Zhao, Xavier Puig, Sanja Fidler, Adela Barriuso, and Antonio Torralba. 通过ADE20K数据集进行场景解析。发表于 *CVPR*, 2017年。

周靖昊、陈伟、王慧宇、沈伟、谢慈航、艾伦·尤伊尔与陶坤。ibot: 基于在线分词器的图像bert预训练。收录于 *ICLR*, 2022a。

潘舟, 周奕辰, 司晨阳, 余炜豪, 黄德钦, 颜水成。Mugs: 一种多粒度自监督学习框架。 *arXiv preprint arXiv:2203.14415*, 2022b。

数据处理

A.1 数据选择

我们为构建LVD-142M选择的数据集详情见表15。该数据集集合旨在提供全面覆盖图像级识别与密集识别下游视觉任务的多样化图像。

A.2 图像相似度

我们采用余弦相似度来比较图像特征（无论是我们的还是为去重生成的特征），使用以下相似度函数 m ：

$$m(s, r) = \text{cosine-similarity}(f(s), f(r)) = \frac{f(s) \cdot f(r)}{\|f(s)\|_2 \|f(r)\|_2}$$

其中 s 和 r 是一对需要比较的图像， f 是生成特征的模型。

A.3 去重

自去重。为了对我们未经筛选的13亿张图像数据源进行去重，我们计算并使用了Pizzi等人（2022年）生成的嵌入向量，检索每张图像的 $k=64$ 个最近邻（使用余弦相似度）。仅考虑相似度 >0.6 的邻居，我们通过可扩展的并查集数据结构实现提取关联 k -NN图的连通分量。随后，我们仅为每个重复图像分量保留一个代表图像。最终得到一个经过自去重处理的11亿张图像数据源。

相对去重 为了减少冗余并正确评估我们特征的性能，我们舍弃了自去重数据源中与评估数据集的训练和测试分割过于相似的剩余图像。为此，我们采用了与自去重类似的流程，但设置了更严格的相似度阈值 >0.45 ，此次会识别每张参考图像所属的重复组件（如果存在）并将其完全剔除。最终我们得到了一个经过自去重和相对去重的数据源，包含7.44亿张图像。

A.4 检索

我们采用两种基于检索的数据增强方法：样本级和聚类级。第一种样本级方法适用于超过100万张图像的数据集，其核心是为待检索数据集中的每个样本图像收集固定数量 k 的最近邻图像，从而将数据集规模有效扩大 k 倍。对于Google Landmarks v2和ImageNet-22k数据集，我们设定 $k=4$ ；而在构建LVD-142M数据集时，则采用更大的 $k=32$ ，使该检索过程成为数据集的核心组成部分。对于较小规模的数据集，我们采用第二种聚类级方法：首先通过分布式 k -均值算法将未筛选数据源划分为100,000个独立聚类，每个聚类应捕捉不同类型的图像概念与内容。随后从每个包含检索数据集3张以上图像的聚类中选取10,000张图像。考虑到某些数据集可能因此产生海量检索图像，我们将此类检索结果上限设定为100万张，以维持LVD-142M内部不同数据集间的平衡。

B 实现细节

B.1 无监督预训练

对于无监督预训练，我们基于DINO和iBOT的代码库进行构建。我们采用表16所示的超参数以及表17描述的ViT架构。

KoLeo正则化。我们在GPU内所有样本的第一个全局裁剪的类别标记之间应用权重为0.1的KoLeo正则化器，此步骤无需跨通信。

Task	Dataset / Split	Images	Retrieval	Retrieved	Final
classification	ImageNet-22k / –	14,197,086	as is	–	14,197,086
classification	ImageNet-22k / –	14,197,086	sample	56,788,344	56,788,344
classification	ImageNet-1k / train	1,281,167	sample	40,997,344	40,997,344
fine-grained classif.	Caltech 101 / train	3,030	cluster	2,630,000	1,000,000
fine-grained classif.	CUB-200-2011 / train	5,994	cluster	1,300,000	1,000,000
fine-grained classif.	DTD / train1	1,880	cluster	1,580,000	1,000,000
fine-grained classif.	FGVC-Aircraft / train	3,334	cluster	1,170,000	1,000,000
fine-grained classif.	Flowers-102 / train	1,020	cluster	1,060,000	1,000,000
fine-grained classif.	Food-101 / train	75,750	cluster	21,670,000	1,000,000
fine-grained classif.	Oxford-IIIT Pet / trainval	3,680	cluster	2,750,000	1,000,000
fine-grained classif.	Stanford Cars / train	8,144	cluster	7,220,000	1,000,000
fine-grained classif.	SUN397 / train1	19,850	cluster	18,950,000	1,000,000
fine-grained classif.	Pascal VOC 2007 / train	2,501	cluster	1,010,000	1,000,000
segmentation	ADE20K / train	20,210	cluster	20,720,000	1,000,000
segmentation	Cityscapes / train	2,975	cluster	1,390,000	1,000,000
segmentation	Pascal VOC 2012 (seg.) / trainaug	1,464	cluster	10,140,000	1,000,000
depth estimation	Mapillary SLS / train	1,434,262	as is	–	1,434,262
depth estimation	KITTI / train (Eigen)	23,158	cluster	3,700,000	1,000,000
depth estimation	NYU Depth V2 / train	24,231	cluster	10,850,000	1,000,000
depth estimation	SUN RGB-D / train	4,829	cluster	4,870,000	1,000,000
retrieval	Google Landmarks v2 / train (clean)	1,580,470	as is	–	1,580,470
retrieval	Google Landmarks v2 / train (clean)	1,580,470	sample	6,321,880	6,321,880
retrieval	AmsterTime / new	1,231	cluster	960,000	960,000
retrieval	AmsterTime / old	1,231	cluster	830,000	830,000
retrieval	Met / train	397,121	cluster	62,860,000	1,000,000
retrieval	Revisiting Oxford / base	4,993	cluster	3,680,000	1,000,000
retrieval	Revisiting Paris / base	6,322	cluster	3,660,000	1,000,000
					1.42亿

表15: 我们的LVD-142M数据集构成。我们列出了用于构建该数据集的各数据集及其对应划分、纳入方式（直接采用未检索数据，或通过基于样本/聚类的检索纳入）。对于检索部分，我们标注了实际检索到的图像数量以及最终纳入数据集的图像数量。我们选择在预训练数据中纳入尽可能多的数据集，以覆盖尽可能多的领域。同时我们保留了部分数据集，用于评估预训练领域之外的性能表现。更多关于数据集使用的细节可在表18中找到。

	Arch.	Drop-rate	LR	Batch size
DINOv2-S (distilled)	ViT-S/14	0	1e-3	2048
DINOv2-B (distilled)	ViT-B/14	0	1e-3	2048
DINOv2-L (distilled)	ViT-L/14	0	1e-3	2048
DINOv2-L (from scratch)	ViT-L/14	0.4	3.5e-4	3072
DINOv2-g (from scratch)	ViT-g/14	0.4	3.5e-4	3072

表16: DINOv2-S、DINOv2-B、DINOv2-L和DINOv2-g的训练超参数。所有模型均运行62.5万次迭代，使用AdamW优化器，初始LayerScale值为1e-5，权重衰减余弦调度从0.04到0.2，学习率预热10万次迭代，教师动量余弦调度从0.994到1，所有情况均采用float16精度训练（除DINO头部外，我们在该部分使用float32精度降低梯度）。

Arch.	Embed dim	Heads	Blocks	FFN layer
ViT-S/14 (distilled)	384	6	12	MLP
ViT-B/14 (distilled)	768	12	18	MLP
ViT-L/14 (distilled)	1024	16	24	MLP
ViT-L/14 (from scratch)	1024	16	24	SwiGLU
ViT-g/14 (from scratch)	1536	24	40	SwiGLU

表17: 本工作中使用的ViT-S/B/L/g网络架构细节。对于蒸馏模型，我们使用MLP前馈网络；而在从头开始训练时，则采用SwiGLU（Shazeer, 2020）。

教师网络的EMA更新。教师网络以与学生网络相同的状态初始化，并且是学生网络的指数移动平均，动量值在[0.994, 1.0]之间，遵循余弦调度。它在每个训练步骤结束时进行更新。

B.2 高分辨率适配

我们使用预训练权重初始化模型，然后按照与原始预训练相同的流程进行10k次迭代训练。所有训练计划均保持与原始训练一致，但压缩至适配10k次迭代的规模。除基础学习率被降低外，所有超参数均与首次预训练保持相同。

B.3 线性探测评估

对于线性探测，我们定义了3个评估参数：学习率、使用的输出层数量，以及是否将平均池化的补丁令牌特征与类别令牌拼接（或仅使用类别令牌）。我们使用SGD训练线性层12500次迭代，采用随机缩放裁剪数据增强，并进行以下网格搜索：

- 学习率在 {0.0001, 0.0002, 0.0005, 0.001, 0.002, 0.005, 0.01, 0.02, 0.05, 0.1, 0.2, 0.3, 0.5}
- {1, 4}中的输出层
- 在{yes, no}中连接平均池化的标记

随后，我们按照惯例报告在验证集上获得的最高准确率值。需要注意的是，这种网格搜索并不耗费大量计算资源，因为在每次迭代中，我们仅对主干网络进行一次推理，随后将输出结果馈送至所有线性分类器（每个分类器仅执行一次矩阵乘法）。

C 使用的数据集列表

我们在表 e 18 所使用的基准测试和数据集列表及其p 目的。

Dataset	Pretraining (as is)	Retrieving pretraining data	Eval.	Task	Citation
ImageNet-1k	✗	✓	✓	Classif.	(Russakovsky et al., 2015)
ImageNet-22k	✓	✓	✗		(Deng et al., 2009)
ImageNet-V2	✗	✗	✓	Classif.	(Recht et al., 2019)
ImageNet-ReaL	✗	✗	✓	Classif.	(Beyer et al., 2020)
ImageNet-A	✗	✗	✓	Classif.	(Hendrycks et al., 2021b)
ImageNet-C	✗	✗	✓	Classif.	(Hendrycks & Dietterich, 2019)
ImageNet-R	✗	✗	✓	Classif.	(Hendrycks et al., 2021a)
ImageNet-Sk.	✗	✗	✓	Classif.	(Wang et al., 2019)
Food-101	✗	✓	✓	Classif.	(Bossard et al., 2014)
CIFAR-10	✗	✓	✓	Classif.	(Krizhevsky et al., 2009)
CIFAR-100	✗	✓	✓	Classif.	(Krizhevsky et al., 2009)
SUN397	✗	✓	✓	Classif.	(Xiao et al., 2010)
StanfordCars	✗	✓	✓	Classif.	(Krause et al., 2013)
FGVC-Aircraft	✗	✓	✓	Classif.	(Maji et al., 2013)
VOC 2007	✗	✓	✓	Classif.	(Everingham et al., 2010)
DTD	✗	✓	✓	Classif.	(Cimpoi et al., 2014)
Oxford Pets	✗	✓	✓	Classif.	(Parkhi et al., 2012)
Caltech101	✗	✓	✓	Classif.	(Fei-Fei et al., 2004)
Flowers	✗	✓	✓	Classif.	(Nilsback & Zisserman, 2008)
CUB200	✗	✓	✓	Classif.	(Welinder et al., 2010)
iNaturalist 2018	✗	✗	✓	Classif.	(Van Horn et al., 2018)
iNaturalist 2021	✗	✗	✓	Classif.	(Van Horn et al., 2021)
Places-205	✗	✗	✓	Classif.	(Zhou et al., 2014)
UCF101	✗	✗	✓	Video	(Soomro et al., 2012)
Kinetics-400	✗	✗	✓	Video	(Kay et al., 2017)
SSv2	✗	✗	✓	Video	(Goyal et al., 2017)
GLD v2	✓	✓	✗		(Weyand et al., 2020)
R-Paris	✗	✓	✓	Retrieval	(Radenović et al., 2018a)
R-Oxford	✗	✓	✓	Retrieval	(Radenović et al., 2018a)
Met	✗	✓	✓	Retrieval	(Ypsilantis et al., 2021)
Amstertime	✗	✓	✓	Retrieval	(Yildiz et al., 2022)
ADE20k	✗	✓	✓	Seg.	(Zhou et al., 2017)
Cityscapes	✗	✓	✓	Seg.	(Cordts et al., 2016)
VOC 2012	✗	✓	✓	Seg.	(Everingham et al., 2010)
Mapillary SLS	✓	✗	✗		(Warburg et al., 2020)
NYU-Depth V2	✗	✓	✓	Depth	(Silberman et al., 2012)
KITTI	✗	✓	✓	Depth	(Geiger et al., 2013)
SUN-RGBD	✗	✓	✓	Depth	(Song et al., 2015)
DollarStreet	✗	✗	✓	Fairness	(De Vries et al., 2019)
Casual Conv.	✗	✗	✓	Fairness	(Hazirbas et al., 2021)

表18: 所用数据集列表。