

5
2
0
2
g
u
A
3
1
J
V
C
s
c
l
1
v
4
0
1
0
1
8
0
5
2
:
v
i
X
r
a

DINOv3

奥里安·西梅奥尼* 胡伊·沃* 马克西米利安·塞策尔* 费德里科·巴尔达萨雷* 马克西姆·奥夸布* 西乔·何塞·瓦西尔·哈利多夫 马克·萨法涅克 承恩·李 米夏埃尔·拉马蒙吉苏阿 弗朗西斯科·马萨 丹尼尔·哈齐扎 卢卡·韦尔施泰特 王建元 蒂莫泰·达尔塞 泰奥·穆塔坎尼 莱昂内尔·森塔纳 克莱尔·罗伯茨 安德烈亚·韦达尔迪 杰米·托兰 约翰·勃兰特¹ 卡米耶·库普里 朱利安·迈拉尔² 埃尔韦·热古 彼得·博亚诺夫斯基

Meta AI Research ¹WRI²Inria

*corresponding authors: {osimeoni,huyvu,seitzer,baldassarre,qas}@meta.com

摘要

自监督学习有望消除手动数据标注的需求，使模型能够轻松扩展到海量数据集和更大规模的架构。由于不针对特定任务或领域进行定制，这种训练范式具备从多样化来源（从自然图像到航拍图像）学习视觉表征的潜力——仅需使用单一算法。本技术报告介绍了DINOv3，这是通过利用简单而有效的策略实现这一愿景的重要里程碑。首先，我们通过精细的数据准备、设计和优化，充分发挥数据集与模型规模扩展的优势。其次，我们提出了一种称为Gram锚定的新方法，有效解决了长期训练过程中密集特征图退化这一已知但尚未解决的问题。最后，我们应用事后策略，进一步增强了模型在分辨率、模型规模以及与文本对齐方面的灵活性。最终，我们提出了一个通用的视觉基础模型，在无需微调的情况下，于广泛场景中超越了专门化的现有最优模型。DINOv3生成的高质量密集特征在各种视觉任务中实现了卓越性能，显著超越了先前的自监督和弱监督基础模型。我们还开源了DINOv3系列视觉模型，旨在通过为不同资源限制和部署场景提供可扩展的解决方案，推动广泛任务与数据领域的技术进步。

1 引言

基础模型已成为现代计算机视觉的核心构建模块，通过单一可复用的模型实现了跨任务和跨领域的广泛泛化能力。自监督学习（SSL）是训练此类模型的有效方法，它直接从原始像素数据中学习，并利用图像中模式的自然共现关系。与需要图像配对高质量元数据的弱监督及全监督预训练方法（Radford等人，2021；Dehghani等人，2023；Bolya等人，2025）不同，SSL能够利用海量原始图像集合进行训练。由于训练数据几乎无限可得，这种方法对训练大规模视觉编码器尤为有效。DINOv2（Oquab等人，2024）集中体现了这些优势，在图像理解任务（Wang等人，2025）中取得显著成果，并支持复杂领域（如组织病理学（Chen等人，2024））的预训练。基于SSL训练的模型还展现出更多理想特性：对输入分布偏移具有鲁棒性，能提供强全局与局部特征，并生成促进物理场景理解的丰富嵌入表示。由于SSL模型并非针对特定下游任务训练，其产生的通用特征兼具多功能性与鲁棒性。例如DINOv2模型无需任务特定微调即可在多样化任务和领域中保持优异性能，使单个冻结主干网络能够服务于多重用途。值得注意的是，自监督学习特别适用于利用海量可获取的观测数据进行训练。




图1: (a) 近年来ImageNet1k (IN1k) 上线性探测结果的演变, 对比了全监督学习 (SL)、弱监督学习 (WSL) 和自监督学习 (SSL) 方法。尽管自监督学习出现较晚, 但其发展迅速, 现已达到近年来ImageNet准确率的平台期。另一方面, 我们证明自监督学习具备提供高质量密集特征的独特潜力。通过DINOv3, 我们在密集任务上显著超越了弱监督模型, 如当前最佳WSL模型与DINOv3的相对性能对比所示 (b)。我们还利用在自然图像 (c) 和航拍图像 (d) 上训练的DINOv3, 生成了高分辨率图像特征的PCA可视化图谱。

在组织病理学 (Vorontsov等人, 2024)、生物学 (Kim等人, 2025)、医学影像 (Pérez-García等人, 2025)、遥感 (Cong等人, 2022; Tolan等人, 2024)、天文学 (Parker等人, 2024) 或高能粒子物理学 (Dillon等人, 2022) 等领域中, 这些领域通常缺乏元数据, 且已被证明能够受益于DINOv2等基础模型。最后, 自监督学习无需人工干预, 非常适合在不断增长的网络数据中进行持续学习。

在实践中, 自监督学习 (SSL) 的承诺——即通过利用大量无约束数据来生成任意规模且强大的模型——在大规模应用时仍然面临挑战。尽管Oquab等人 (2024年) 提出的启发式方法缓解了模型不稳定和崩溃的问题, 但随着规模的进一步扩大, 更多问题逐渐浮现。首先, 如何从未标注的数据集中收集有用数据尚不明确。其次, 在常规训练实践中, 采用余弦调度意味着需要事先知道优化周期, 这在大型图像数据集上进行训练时难以实现。第三, 特征性能在早期训练后逐渐下降, 这一点通过视觉检查补丁相似度图得到了证实。这种现象出现在ViT-Large规模以上 (3亿参数) 模型的长时间训练中, 从而降低了扩展DINOv2的实用性。

针对上述问题, 我们开展了这项研究DINOv3, 推动了大尺度自监督学习的训练进程。我们证明 *single frozen SSL backbone* 能够作为通用视觉编码器, 在具有挑战性的下游任务中实现最先进的性能表现, 其效果优于依赖监督学习和元数据的预训练策略。本研究遵循以下目标: (1) 训练一个跨任务与跨领域的通用基础模型, (2) 改进现有自监督模型在密集特征提取方面的不足, (3) 发布一系列开箱即用的模型体系。下文将围绕这三个目标展开论述。




图2: DINOv3系列模型在不同基准测试中与其他自监督或弱监督模型系列的对比表现。在密集预测基准上, DINOv3显著超越了其他模型, 包括利用掩码标注先验的模型(如AM-RADIO (Heinrich等人, 2025年))。

强大且多才多艺的基础模型 DINOv3 旨在通过扩大模型规模和训练数据, 在两个维度上实现高度的多功能性。首先, 自监督学习模型的一个关键理想特性是在保持冻结状态下仍能取得优异性能, 最好能达到与专用模型相当的先进水平。在这种情况下, 单次前向传播即可在多项任务中提供尖端结果, 从而大幅节省计算资源——这对实际应用(尤其是在边缘设备上)至关重要。我们在第 6 节展示了 DINOv3 可成功应用的广泛任务范围。其次, 不依赖元数据的可扩展自监督训练流程为众多科学应用开辟了道路。通过对多样化图像(无论是网络图像还是观测数据)进行预训练, 自监督学习模型能够泛化至大量领域和任务。如图 1(d) 所示, 从高分辨率航拍图像中提取的 DINOv3 特征进行主成分分析后, 能清晰区分道路、房屋和植被, 凸显了模型特征的高质量。

通过Gram锚定实现卓越的特征图 DINOv3的另一关键特性是其密集特征图的显著改进。DINOv3的自监督学习训练策略旨在构建擅长高层语义任务的模型, 同时生成适用于深度估计或三维匹配等几何任务的优质特征图。尤其重要的是, 这些模型应能生成可直接使用或仅需少量后处理的密集特征。在使用海量图像进行训练时, 密集表征与全局表征之间的平衡优化尤为困难, 因为高层语义理解的目标可能与密集特征图的质量产生冲突。这些矛盾的目标会导致大型模型和长周期训练中出现密集特征崩溃。我们提出的Gram锚定策略有效缓解了这种崩溃现象(参见第4节)。因此, DINOv3获得了比DINOv2显著更优的密集特征图, 即使在高分辨率下仍能保持清晰度(见图3)。

DINOv3模型家族通过Gram锚定解决密集特征图退化问题, 释放了规模化训练的潜力。因此, 采用自监督学习训练更大规模的模型能带来显著的性能提升。本研究成功训练了拥有70亿参数的DINO模型。鉴于如此庞大的模型需要大量计算资源, 我们应用知识蒸馏技术将其能力压缩至更小的变体。最终我们推出了 *DINOv3 family of vision models*——一套旨在应对广泛计算机视觉挑战的完整模型体系。该模型家族通过提供可适应不同资源限制与部署场景的扩展方案, 致力于推动前沿技术发展。蒸馏过程产生了多尺度模型变体, 包括视觉Transformer (ViT) 的小型、基座和大型版本, 以及基于ConvNeXt的架构。值得注意的是, 高效且广泛采用的ViT-L模型在多项任务中实现了接近原始70亿参数教师模型的性能。总体而言, DINOv3家族在广泛基准测试中展现出强大性能: 在全局任务上达到或超越了竞争模型的精度, 而在密集预测任务中表现尤为突出(如图2所示)。



图3：高分辨率密集特征。我们可视化使用DINOv3输出特征在标记为红色十字的图块与所有其他图块之间获得的余弦相似度图。输入图像尺寸为 4096×4096 。Please zoom in, 你同意DINOv3的观点吗？

贡献概述 在本工作中，我们提出了多项贡献，以应对将自监督学习(S²L)扩展至大型前沿模型的挑战。我们基于自动数据筛选的最新进展(Vo等人, 2024)，构建了一个大规模的“背景”训练数据集，并将其与少量专业数据(ImageNet-1k)进行精心混合。这使得我们能够利用大量无约束数据来提升模型性能。这项围绕数据扩展的贡献(i)将在第3.1节中详述。

我们通过定义ViT架构的自定义变体，将主模型规模提升至70亿参数。我们引入了现代位置嵌入技术(轴向RoPE)，并开发了一种正则化方法来避免位置伪影。与DINOv2中使用的多重余弦调度不同，我们采用恒定超参数调度进行了100万次迭代训练，从而能够生成性能更强大的模型。关于模型架构与训练的这项贡献(ii)将在第3.2节详细阐述。

借助上述技术，我们能够大规模地按照DINOv2算法训练模型。然而，如前所述，规模扩大会导致密集特征的质量下降。为解决这一问题，我们提出在流程中引入一个核心改进——Gram锚定训练阶段。该方法能清除特征图中的噪声，生成令人印象深刻的相似度图，并大幅提升参数化与非参数化密集任务的性能。关于Gram训练的这项贡献(iii)将在第4节详细阐述。

遵循以往的做法，我们流程的最后步骤包括高分辨率后训练阶段，以及蒸馏成一系列不同尺寸的高性能模型。对于后者，我们开发了一种新颖且

高效的单一教师多学生蒸馏流程。这一贡献 (iv) 将我们70亿参数前沿模型的能力迁移至一系列适用于日常使用的更小型实用模型，我们将在第5.2节对此进行详细阐述。

在我们全面的基准测试中，第6节的结果表明，我们的方法在密集任务上确立了新标准，并在全局任务上表现与CLIP衍生模型相当。具体而言，通过 *with a frozen vision backbone*，我们在目标检测（COCO检测，mAP 66.1）和图像分割（ADE20k，mIoU 63.0）等长期存在的计算机视觉问题上实现了最先进的性能，超越了专门优化的流程。此外，我们在第8节中通过将DINOv3算法应用于卫星图像，证明了我们方法在不同领域的通用性，超越了所有先前的方法。

2 相关工作

自监督学习无需标注的学习需要一种人工设计的学习任务来替代训练所需的监督信号。自监督学习的艺术与挑战在于精心设计这些所谓的预训练任务，以学习对下游任务有效的表征。语言领域因其离散特性，为构建此类任务提供了直接途径，从而催生了众多成功的文本数据无监督预训练方法，例如词嵌入（Mikolov等人，2013；Bojanowski等人，2017）、句子表征（Devlin等人，2018；Liu等人，2019）以及纯语言模型（Mikolov等人，2010；Zaremba等人，2014）。相比之下，计算机视觉由于信号的连续性而面临更大挑战。早期模仿语言方法的尝试通过预测图像块相对位置（Doersch等人，2015）、图像块重排序（Noroozi和Favaro，2016；Misra和Maaten，2020）或图像修复（Pathak等人，2016）*e.g.*，从图像局部提取监督信号。其他任务包括图像重新着色（Zhang等人，2016）或预测图像变换（Gidaris等人，2018）。

在这些任务中，基于补丁的视觉Transformer架构（He等人，2021；Bao等人，2021；El-Nouby等人，2021）的灵活性使得 *inpainting-based* 方法获得了广泛关注。其目标是重建图像的损坏区域，这可以视为一种去噪自编码形式，在概念上与BERT预训练中的掩码标记预测任务相关（Devlin等人，2018）。值得注意的是，He等人（2021）证明了基于像素的掩码自编码器（MAE）可作为下游任务微调的强大初始化方法。随后，Baeovski等人（2022；2023）和Assran等人（2023）的研究表明，预测 *learned latent space* 而非像素空间能产生更强大、更高层次的特征——这一学习范式被称为JEPA：“联合嵌入预测架构”（LeCun，2022）。最近，JEPA方法也被扩展至视频训练领域（Bardes等人，2024；Assran等人，2025）。

第二条研究路线与我们的工作更为接近，它利用 *discriminative signals between images* 来学习视觉表征。这类方法可追溯至早期深度学习研究（Hadsell等人，2006），但随着实例分类技术的引入而广受欢迎（Dosovitskiy等人，2016；Bojanowski和Joulin，2017；Wu等人，2018）。后续进展引入了对比性目标和信息论准则（Hénaff等人，2019；He等人，2020；Chen和He，2020；Chen等人，2020a；Grill等人，2020；Bardes等人，2021），以及基于自聚类策略的方法（Caron等人，2018；Asano等人，2020；Caron等人，2020；2021）。近期方法如iBOT（Zhou等人，2021）将判别性损失与掩码重建目标相结合。所有这些方法都展现出学习强特征的能力，并在ImageNet等标准基准测试中取得优异性能（Russakovsky等人，2015）。然而，大多数方法在扩展到更大模型规模时仍面临挑战（Chen等人，2021）。

视觉基础模型 深度学习革命始于AlexNet的突破性成果（Krizhevsky等人，2012），这是一个深度卷积神经网络，在ImageNet挑战赛（Deng等人，2009；Russakovsky等人，2015）中超越了所有先前方法。早期研究已发现，通过大型人工标注的ImageNet数据集端到端学习到的特征，对于广泛的迁移学习任务极为有效（Oquab等人，2014）。随后的视觉{v*}研究聚焦于架构开发，包括VGG（Simonyan和Zisserman，2015）、GoogLeNet（Szegedy等人，2015）和ResNet（He等人，2016）。

鉴于 *scaling* 的有效性，后续研究探索了在大型数据集上训练更大规模的模型。Sun等人（2017）利用包含3亿张图片的专有JFT数据集扩展了监督训练数据。

标注图像，展示了令人印象深刻的结果。JFT也为Kolesnikov等人（2020）带来了显著的性能提升。与此同时，研究者们结合监督和无监督数据探索了扩展方法。例如，一个在ImageNet上监督训练的模型可用于为无监督数据生成伪标签，进而用于训练更大的网络（Yalznik等人，2019）。随后，JFT等大型监督数据集的可用性也促进了Transformer架构在计算机视觉领域的适应（Dosovitskiy等人，2020）。特别是，若无法访问JFT数据，要达到与原始视觉Transformer（ViT）相当的性能需要付出巨大努力（Touvron等人，2020；2022）。得益于ViT的学习能力，Zhai等人（2022a）进一步推进了扩展研究，最终发展出超大规模的ViT-22B编码器（Dehghani等人，2023）。

鉴于手动标注大型数据集的复杂性，*weakly-supervised training*——其中标注来源于图像关联的元数据——为监督训练提供了一种有效的替代方案。早期，Joulin等人（2016年）证明，仅通过预测图像描述中的所有单词作为目标，即可对网络进行预训练。这一初始方法随后通过利用句子结构（Li等人，2017年）、整合其他类型的元数据并进行数据筛选（Mahajan等人，2018年），以及扩大规模（Singh等人，2022年）得到了进一步改进。然而，弱监督算法直到引入对比损失和联合训练描述表征后，才充分发挥其潜力，如Align（Jia等人，2021年）和CLIP（Radford等人，2021年）所示例。

这一极为成功的方案启发了众多*open-source reproductions and scaling efforts*。OpenCLIP（Cherti等人，2023）首次通过LAION数据集（Schuhmann等人，2021）进行训练，以开源方式复现了CLIP；后续研究则通过CLIP风格的微调方式利用预训练骨干网络（Sun等人，2023；2024）。鉴于数据收集是CLIP训练成功的关键因素，MetaCLIP（Xu等人，2024）严格遵循原始CLIP流程以复现其结果，而Fang等人（2024a）则利用监督数据集来筛选预训练数据。其他研究聚焦于改进训练损失，*e.g.*例如SigLIP（Zhai等人，2023）采用sigmoid损失函数，或利用预训练图像编码器（Zhai等人，2022b）。然而最终，获得尖端基础模型最关键的要素仍是海量高质量数据与充足的计算资源。基于此，SigLIP 2（Tschannen等人，2025）和感知编码器（Bolya等人，2025）在超过400亿图文对训练后取得了令人瞩目的成果。最大的PE模型使用了860亿样本和13.1万的全局批次规模进行训练。最后，一系列更复杂且原生多模态的方法被提出，包括对比式描述生成（Yu等人，2022）、潜在空间掩码建模（Bao等人，2021；Wang等人，2022b；Fang等人，2023；Wang等人，2023a）以及自回归训练（Fini等人，2024）。

相比之下，针对*scaling unsupervised image pretraining*的研究相对较少。早期工作包括Caron等人（2019）和Goyal等人（2019）利用YFCC数据集（Thomee等人，2016）进行的研究。后续进展主要通过聚焦更大规模的数据集和模型（Goyal等人，2021；2022a），以及自监督学习数据筛选的初步尝试（Tian等人，2021）来实现。通过对训练算法的精细调优、采用更庞大的架构和更广泛的训练数据，DINOv2（Oquab等人，2024）取得了令人瞩目的成果——这是首次有自监督学习模型在一系列任务上达到或超越了开源CLIP变体的性能。这一方向近期由Fan等人（2025）通过在不进行数据筛选的情况下扩展至更大模型，以及Venkataramanan等人（2025）利用开放数据集和改进的训练方案得到了进一步推进。

密集Transformer特征广泛的现代视觉应用利用预训练Transformer的*dense features*，包括多模态模型（Liu等人，2023；Beyer等人，2024）、生成模型（Yu等人，2025；Yao等人，2025）、3D理解（Wang等人，2025）、视频理解（Lin等人，2023a；Wang等人，2024b）以及机器人技术（Driess等人，2023；Kim等人，2024）。此外，传统视觉任务如检测、分割或深度估计需要精确的局部描述符。为提升自监督学习训练的局部描述符质量，大量研究致力于开发*local SSL losses*。例如利用视频中的时空一致性，*e.g.*使用点轨迹环作为训练信号（Jabri等人，2020）、利用同一图像不同裁剪区域的空间对齐（Pinheiro等人，2020；Bardes等人，2022），或强制相邻图像块间的一致性（Yun等人，2022）。Darcet等人（2025）证明预测聚类局部图像块能提升密集表示质量。DetCon（Hénaff等人，2021）和ORL（Xie等人，2021）则对




图4：极高分辨率下的DINOv3。我们通过将特征空间上计算得到的PCA前三个分量映射到RGB来可视化DINOv3的密集特征。为使PCA聚焦于主体，我们通过背景减除对特征图进行掩码处理。随着分辨率提升，DINOv3能生成保持语义清晰度的锐利特征。更多PCA可视化结果见第6.1.1节。

区域提议但假设此类提议存在 *a priori*；这一假设在ODIN (Hénaff等人, 2022) 和SlotCon (Wen等人, 2022) 等方法中得到了放宽。在不改变训练目标的情况下，Darcet等人 (2024) 表明，在输入序列中添加寄存器标记能显著改善密集特征图，而近期研究 (Jiang等人, 2025; Chen等人, 2025) 发现这可以在不进行模型训练的情况下实现。

近期的一个趋势是基于蒸馏的“*agglomerative*”方法，这些方法结合了多个图像编码器的信息，这些编码器在全局和局部特征质量上各不相同，并采用不同级别的监督进行训练 (Ranzinger等人, 2024; Bolya等人, 2025)：AM-RADIO (Ranzinger等人, 2024) 结合了全监督SAM (Kirillov等人, 2023)、弱监督CLIP以及自监督DINOv2的优势，形成一个统一的骨干网络。感知编码器 (Bolya等人, 2025) 类似地将SAM(v2)蒸馏为一个专门的密集变体PEspatial。它们采用一个目标函数，强制学生和教师图像块之间的余弦相似度保持较高，其中教师模型使用掩码标注进行训练。类似的损失函数在风格迁移领域已被证明是有效的，通过减少特征维度间Gram矩阵的不一致性 (Gatys等人, 2016; Johnson等人, 2016; Yoo等人, 2024)。在本工作中，我们采用Gram目标函数来正则化学生和教师图像块之间的余弦相似度，促使它们尽可能接近。在我们的案例中，我们使用自监督学习模型自身的早期迭代作为教师，证明了早期阶段的自监督学习模型能有效指导全局和密集任务的自监督训练。

其他研究侧重于对SSL训练模型局部特征进行事后改进。例如，Ziegler和Asano (2022) 通过密集聚类目标对预训练模型进行微调；类似地，Salehi等人 (2023) 通过时间对齐图像块特征进行微调，这两种方法都提升了局部特征的质量。与我们的工作更接近的是，Pariza等人 (2025) 提出基于图像块排序的目标函数，促使学生模型和教师模型生成具有一致邻域排序的特征。无需微调的方法中，STEGO (Hamilton等人, 2022) 在冻结的SSL特征上学习非线性投影以形成紧凑簇并增强相关性模式。另一种方案是，Simoncini等人 (2024) 通过将不同自监督目标的梯度与冻结SSL特征拼接来实现特征增强。最近，Wysoczańska等人 (2024) 研究表明，通过图像块的加权平均可显著改善噪声特征图。

与SSL相关但并非特指SSL，近期的一些研究从ViT特征图中生成高分辨率特征图 (Fu等人, 2024年)，这些特征图常因图像分块处理而分辨率较低。与这类工作相比，我们的模型原生提供高质量密集特征图，这些特征图在不同分辨率下保持稳定和一致，如图4所示。

3 无需监督的大规模训练

DINOv3是下一代模型，旨在通过突破自监督学习的边界，生成迄今为止最强大、最灵活的视觉表示。我们从大型语言模型 (LLM) 的成功中汲取灵感，其模型规模的扩大带来了卓越的 *emerging properties*。通过利用规模大一个数量级的模型和训练数据集，我们致力于释放自监督学习的全部潜力，推动计算机视觉领域实现类似的范式转变，摆脱现有局限性的束缚。

表1: 通过下游任务性能展示训练数据对特征质量的影响。我们将*clustering* (Vo等人, 2024)和*retrieval* (Oquab等人, 2024)整理的数据集与*raw*数据及我们的数据混合方案进行比较。此消融实验采用较短的20万次迭代训练周期进行。

Dataset	IN1k k-NN	IN1k Linear	ObjectNet	iNaturalist 2021	Paris Retrieval
Raw	80.1	84.8	70.3	70.1	63.3
Clustering	79.4	85.4	72.3	81.3	85.2
Retrieval	84.0	86.7	70.7	86.0	82.7
LVD-1689M (ours)	84.6	87.2	72.8	87.0	85.9

传统监督式或任务特定方法固有的问题。特别是，自监督学习能生成丰富、高质量的视觉特征，这些特征不会偏向任何特定监督或任务，从而为广泛的下游应用提供了通用基础。虽然以往尝试扩展自监督学习模型时曾受稳定性问题阻碍，本节将阐述我们如何通过精细的数据准备、设计和优化来发挥扩展的优势。我们首先描述数据集创建流程（第3.1节），随后介绍用于DINOv3首个训练阶段的自监督学习方案（第3.2节），包括架构选择、损失函数和优化技术。第二个专注于密集特征的训练阶段将在第4节详述。

3.1 数据准备

数据规模扩展是大型基础模型成功背后的驱动因素之一（Touvron等人, 2023；Radford等人, 2021；Xu等人, 2024；Oquab等人, 2024）。然而，单纯增加训练数据量并不必然转化为更高的模型质量及下游基准测试的更好表现（Goyal等人, 2021；Oquab等人, 2024；Vo等人, 2024）：成功的数据扩展工作通常需要精心设计的数据处理流程。这些算法可能具有不同目标：或侧重于提升数据的*diversity*与*balance*，或关注数据的*usefulness*——即其与实际常见应用场景的相关性。在DINOv3的开发过程中，我们结合了两种互补的方法来同时提升模型的泛化能力和性能，从而在这两个目标之间取得了平衡。

数据收集与整理 我们通过利用Instagram公开帖子中收集的网络图像大型数据池，构建了大规模预训练数据集。这些图像已经过平台级内容审核，有助于防止有害内容，我们获得了约170亿张图像的初始数据池。基于此原始数据池，我们创建了三个数据集*parts*。第一部分采用Vo等人（2024）提出的基于分层 k -均值的自动整理方法构建。我们使用DINOv2作为图像嵌入，采用5级聚类，从最低到最高层级的聚类数量分别为2亿、800万、80万、10万和2.5万。建立聚类层次结构后，我们应用Vo等人（2024）提出的平衡采样算法，最终得到包含16.89亿张图像的整理子集（命名为LVD-1689M），该子集能保证对网络所有视觉概念的平衡覆盖。第二部分采用基于检索的整理系统，其流程类似Oquab等人（2024）提出的方法。我们从数据池中检索与选定种子数据集相似的图像，构建出覆盖下游任务相关视觉概念的数据集。第三部分使用原始公开可用的计算机视觉数据集，包括ImageNet1k（Deng等人, 2009）、ImageNet22k（Russakovsky等人, 2015）和Mapillary街景序列数据集（Warburg等人, 2020）。参照Oquab等人（2024）的方法，这最后一部分使我们能够优化模型的性能。

在预训练期间，我们使用采样器将不同的数据部分混合在一起。对于混合上述数据组件，有几种不同的选择。一种是在每次迭代中使用来自单个随机选择组件的*homogeneous*批次数据进行训练。或者，我们可以通过按特定比例选择所有组件的数据来组装*heterogeneous*批次，并在此基础上优化模型。受Charton和Kempe（2024）的启发，他们观察到由小数据集中非常高质量数据组成的同质批次是有益的，我们在每次迭代中随机采样

表2: DINOv2与DINOv3模型中使用的教师架构对比。我们保持模型深度为40个模块, 并将嵌入维度提升至4096。关键的是, 我们采用16像素的补丁尺寸, 从而改变了给定分辨率下的有效序列长度。

Teacher model	DINOv2	DINOv3
Backbone	ViT-giant	ViT-7B
#Params	1.1B	6.7B
#Blocks	40	40
Patch Size	14	16
Pos. Embeddings	Learnable	RoPE
Registers	4	4
Embed. Dim.	1536	4096
FFN Type	SwiGLU	SwiGLU
FFN Hidden Dim.	4096	8192
Attn. Heads	24	32
Attn. Heads Dim.	64	128
DINO Head MLP	4096-4096-256	8192-8192-512
DINO Prototypes	128k	256k
iBOT Head MLP	4096-4096-256	8192-8192-384
iBOT Prototypes	128k	96k

要么是仅来自ImageNet1k的均匀批次, 要么是混合了所有其他组件数据的异质批次。在我们的训练中, 来自ImageNet1k的均匀批次占训练的10%。

数据消融实验 为了评估我们数据整理技术的影响, 我们进行了一项消融研究, 将我们的数据混合方案与仅通过聚类或基于检索方法整理的数据集以及原始数据池进行比较。为此, 我们在每个数据集上训练一个模型, 并比较它们在标准下游任务上的性能。为了提高效率, 我们使用了20万次迭代的较短训练计划, 而非100万次迭代。从表1可以看出, 没有单一的整理技术在所有基准测试中都表现最佳, 而我们的完整流程使我们能够兼收并蓄, 获得最佳效果。

3.2 基于自监督的大规模训练

尽管采用自监督学习 (SSL) 训练的模型展现出了一些有趣特性 (Chen等人, 2020b; Caron等人, 2021), 但大多数SSL算法尚未扩展到更大模型规模。这既源于训练稳定性问题 (Darcet等人, 2025), 也因过于简化的解决方案难以捕捉视觉世界的完整复杂性。即使进行大规模训练 (Goyal等人, 2022a), SSL模型也未必能展现卓越性能。一个显著例外是DINOv2——这个基于精选数据训练的11亿参数模型, 其性能可与CLIP (Radford等人, 2021) 等弱监督模型相媲美。近期将DINOv2扩展至70亿参数的尝试 (Fan等人, 2025) 在全局任务上展现出潜力, 但在密集预测任务中表现欠佳。本研究旨在扩大模型规模与数据量, 从而获得更强大的视觉表征, 使其同时具备更优的全局与局部特性。

学习目标 我们采用一种判别式自监督策略训练模型, 该策略融合了多个同时包含全局与局部损失项的自监督目标。遵循DINOv2 (Oquab等人, 2024) 的方法, 我们采用图像级目标 (Caron等人, 2021) $\mathcal{L}_{\text{DINO}}$, 并通过补丁级潜在重建目标 (Zhou等人, 2021) $\mathcal{L}_{\text{iBOT}}$ 与之平衡。我们还在两个目标中将DINO的中心化操作替换为SwAV (Caron等人, 2020) 的Sinkhorn-Knopp算法。每个目标均通过骨干网络顶端的专用头输出进行计算, 使得在损失计算前特征可进行一定程度的专门化。此外, 我们对局部与全局裁剪的骨干网络输出应用了专用的层归一化。经验表明, 这一调整能稳定训练后期ImageNet kNN分类的精度 (提升+0.2准确率) 并提升密集预测性能 (ADE20k分割任务提升*e.g.* +1 mIoU, NYUv2深度估计任务降低0.02 RMSE)。同时, 我们加入Koleo正则化项 $\mathcal{L}_{\text{Koleo}}$ 以促使批次内特征在空间中均匀分布 (Sablayrolles等人, 2018)。我们采用




图5: ViT-g (b) 和ViT-7B (c) 的余弦相似度演变 (a) 以及在ImageNet1k线性分类 (IN1k) 和VOC分割任务上的准确率变化。我们观察到，当图像块标记与类别标记之间的余弦相似度较低时，分割性能达到最高。随着训练的进行，这些相似度逐渐上升，导致密集预测任务的性能下降。

Koleo的分布式实现中，损失函数以16个样本为小批量（可能跨GPU）进行计算。我们的初始训练阶段通过优化以下损失函数进行：

$$\mathcal{L}_{\text{Pre}} = \mathcal{L}_{\text{DINO}} + \mathcal{L}_{\text{iBOT}} + 0.1 * \mathcal{L}_{\text{DKoleo}}. \quad (1)$$

更新模型架构 在本工作的模型缩放方面，我们将模型规模扩大至110亿参数，并在表2中提供了与DINOv2工作中训练的11亿参数模型对应的超参数对比。我们还采用了自定义版本的RoPE：基础实现将每个图像块分配至归一化的 $[-1, 1]$ 坐标框内，随后根据两个图像块的相对位置在多头注意力操作中应用偏置。为提升模型对分辨率、尺度与宽高比的鲁棒性，我们采用RoPE-box jittering方法——将坐标框 $[-1, 1]$ 随机缩放至 $[-s, s]$ 范围，其中 $s \in [0.5, 2]$ 。这些改进共同使DINOv3能更有效地学习细致且鲁棒的视觉特征，从而提升其性能与可扩展性。

优化训练 在超大规模数据集上训练大型模型是一项复杂的实验工作流程。由于模型容量与训练数据复杂度之间的相互作用难以评估[a priori](#)，我们无法准确预测最佳优化周期。为解决这一问题，我们摒弃了所有参数调度策略，采用恒定的学习率、权重衰减和教师EMA动量进行训练。这种方法带来两大优势：首先，只要下游性能持续提升，我们就可以继续训练；其次，优化超参数数量得以减少，使其更易于合理设置。为确保训练正常启动，我们仍对学习率和教师温度采用线性预热策略。遵循常规实践，我们使用AdamW优化器（Loshchilov和Hutter, 2017），并将总批次大小设置为4096张图像，分配到256个GPU上进行处理。训练采用多裁剪策略（Caron等人, 2020），每张图像提取2个全局裁剪和8个局部裁剪。全局/局部裁剪使用边长为256/112像素的正方形图像，结合补丁尺寸的调整，使每张图像的有效序列长度与DINOv2保持一致，每批次总序列长度达到3.7M个标记。更多超参数设置可参见附录C及代码发布文件。




图6: 红色标注的补丁与所有其他补丁之间余弦相似度的演变。随着训练的进行, 模型生成的特征逐渐去局部化, 相似度图也变得更加嘈杂。

4 克锚定: 密集特征的正则化

为了充分利用大规模训练的优势, 我们计划对7B模型进行长时间训练, 甚至考虑其具备无限期训练的潜力。正如预期, 延长训练时间确实提升了模型在全局基准测试上的表现。然而, 随着训练的推进, 模型在密集任务上的性能却出现下降(图5b和5c)。这一现象源于特征表示中出现的区块级不一致性, 从而削弱了延长训练的意义。¹在本节中, 我们首先分析区块级一致性的缺失, 随后提出一种名为 *Gram anchoring* 的新目标函数来缓解此问题。最后, 我们将探讨该方法对训练稳定性和模型性能的影响。

4.1 训练过程中补丁级一致性的损失

在长时间的训练过程中, 我们观察到全局指标持续提升, 但在密集预测任务上的性能却显著下降。这种行为先前在DINOv2的训练中(程度较轻)已被观察到, 并在Fan等人(2025年)的扩展研究中进行过讨论。然而, 据我们所知, 该问题至今仍未得到解决。我们在图5b和图5c中展示了这一现象, 图中呈现了模型在图像分类和分割任务上随迭代次数的性能变化。对于分类任务, 我们使用CLS标记在ImageNet-1k上训练线性分类器, 并报告top-1准确率; 对于分割任务, 我们在从Pascal VOC提取的补丁特征上训练线性层, 并报告平均交并比(mIoU)。我们观察到, 无论是ViT-g还是ViT-7B, 分类准确率在整个训练过程中均单调提升。但两者的分割性能在大约20万次迭代后均出现下降, 其中ViT-7B的分割性能甚至低于早期训练阶段的水平。

为了更好地理解这种退化现象, 我们通过可视化图像块间的余弦相似度来分析图像块特征的质量。图6展示了主干网络输出的图像块特征与参考图像块(以红色高亮显示)之间的余弦相似度图。在20万次迭代时, 相似度图平滑且定位清晰, 表明图像块级别的表征具有一致性。然而, 到60万次迭代及之后, 相似度图显著退化, 与参考图像块具有高相似度的无关图像块数量不断增加。这种图像块级别一致性的丧失与密集任务性能的下降密切相关。

这些补丁级别的不规则性与Darcet等人(2024)中描述的高范数补丁异常值不同。具体来说, 随着寄存器标记的引入, 补丁范数在整个训练过程中保持稳定。然而, 我们注意到CLS标记与补丁输出之间的余弦相似度在训练期间逐渐增加。这虽在预期之中, 但也意味着补丁特征的局部性逐渐减弱。我们在图5a中可视化了这一现象, 该图展示了200k次和1M次迭代时的余弦相似度图。为了缓解这一问题,

¹我们还观察到了差异 - rent types of outliers appearing with continued training; we provide 附录A中的讨论。




图7: 训练迭代过程中, 块级iBOT损失、全局损失DINO (应用于全局裁剪图像) 以及新引入的Gram损失的演变趋势。我们特别标注了采用Gram目标的细化步骤迭代阶段 $\mathcal{L}_{\text{Ref}}$

在密集任务上表现下降, 我们提出了一个专门设计的新目标, 旨在规范化补丁特征并确保良好的补丁级一致性, 同时保持较高的全局性能。

4.2 语法锚定目标

在我们的实验过程中, 我们发现学习强判别性特征与保持局部一致性之间存在相对独立性, 这一点从全局性能与密集性能之间缺乏相关性可以观察到。虽然将全局DINO损失与局部iBOT损失结合已经开始解决这一问题, 但我们观察到这种平衡并不稳定, 随着训练的进行, 全局表征逐渐占据主导。基于这一洞察, 我们提出了一种新方法, 明确利用这种独立性。

我们引入了一个新的目标函数, 它通过增强块级一致性的质量来缓解块级一致性的退化, 同时不影响特征本身。这个新的损失函数作用于格拉姆矩阵: 即图像中所有块特征两两点积构成的矩阵。我们希望将学生的格拉姆矩阵推向一个早期模型的格拉姆矩阵, 该模型被称为*Gramteacher*。我们通过选取教师网络的早期迭代来选定格拉姆教师, 该迭代展现出更优的密集特性。通过作用于格拉姆矩阵而非特征本身, 只要相似性结构保持不变, 局部特征便可以自由移动。假设我们有一幅由 P 个块组成的图像, 以及一个在维度 d 上操作的神经网络。我们用 $\mathbf{X}_S$ (分别用 $\mathbf{X}_G$) 表示学生 (分别表示格拉姆教师) 的 L_2 归一化局部特征的 $P \times d$ 矩阵。我们将损失 $\mathcal{L}_{\text{Gram}}$ 定义如下:

$$\mathcal{L}_{\text{Gram}} = \|\mathbf{X}_S \cdot \mathbf{X}_S^\top - \mathbf{X}_G \cdot \mathbf{X}_G^\top\|_F^2. \quad (2)$$

我们仅在全局裁剪上计算此损失。尽管它可以在训练早期应用, 但出于效率考虑, 我们仅在100万次迭代后才开始。有趣的是, 我们观察到即使较晚应用 $\mathcal{L}_{\text{Gram}}$, 仍能成功“修复”严重退化的局部特征。为了进一步提升性能, 我们每1万次迭代更新一次Gram教师模型, 此时Gram教师模型与主EMA教师模型完全相同。我们将这一训练的第二阶段称为*refinement step*, 其优化目标为 $\mathcal{L}_{\text{Ref}}$, 其中

$$\mathcal{L}_{\text{Ref}} = w_D \mathcal{L}_{\text{DINO}} + \mathcal{L}_{\text{iBOT}} + w_{\text{DK}} \mathcal{L}_{\text{DKoleo}} + w_{\text{Gram}} \mathcal{L}_{\text{Gram}}. \quad (3)$$

我们在图7中可视化了不同损失的演变过程, 并观察到应用Gram目标函数会显著影响iBOT损失, 使其下降速度加快。这表明稳定Gram教师引入的稳定性对iBOT目标产生了积极影响。相比之下, Gram目标函数对DINO损失没有显著影响。这一观察意味着Gram与iBOT目标函数以相似的方式影响特征, 而DINO损失对特征的影响方式则有所不同。




图8: 应用我们提出的 *Gram anchoring* 方法后, 不同基准测试结果的演变。我们可视化了在原始训练基础上继续使用我们的优化步骤 (记为 ' $\mathcal{L}_{\text{Ref}}$ ') 时的结果。同时绘制了采用更高分辨率特征计算Gram目标函数 (如第4.3节所述, 记为 ' $\mathcal{L}_{\text{HRef}}$ ') 时获得的结果。我们特别标出了使用Gram目标函数的迭代阶段。


在性能方面, 我们观察到新损失函数的影响几乎是立竿见影的。如图8所示, 引入Gram锚定机制使密集任务在前10k次迭代内就取得了显著提升。在Gram教师模型更新后, ADE20k基准测试也呈现出明显进步。此外, 更长时间的训练进一步提升了ObjectNet基准的表现, 而其他全局基准测试则显示新损失函数带来的影响较为温和。

4.3 利用更高分辨率的特征

近期研究表明, 通过对图像块特征进行加权平均, 能够通过平滑异常图像块并增强块间一致性来获得更强的局部表征 (Wysoczańska等人, 2024)。另一方面, 将更高分辨率的图像输入主干网络可产生更精细、更详细的特征图。我们结合这两项观察的优势, 为Gram教师模型计算高质量特征。具体而言, 我们首先将两倍于常规分辨率的图像输入Gram教师模型, 随后通过双三次插值对生成的特征图进行 $2\times$ 倍下采样, 从而获得与学生输出尺寸匹配的平滑特征图。图9a可视化展示了分辨率256和512图像所获得的图像块特征Gram矩阵, 以及从512分辨率特征经 $2\times$ 倍下采样 (标记为“downsamp.”) 后得到的矩阵。我们观察到, 高分辨率特征中优越的块级一致性在下采样过程中得以保留, 从而产生更平滑、更连贯的块级表征。值得一提的是, 得益于采用Su等人 (2024) 提出的旋转位置编码 (RoPE), 我们的模型能够无缝处理不同分辨率的图像而无需额外适配。

我们计算下采样特征的格拉姆矩阵, 并用它替换目标函数 $\mathcal{L}_{\text{Gram}}$ 中的 $\mathbf{X}_G$ 。我们将由此得到的新优化目标记为 $\mathcal{L}_{\text{HRef}}$ 。这种方法使格拉姆目标能够有效地将平滑高分辨率特征改进的块一致性提炼到学生模型中。如图8和图9b所示, 这种提炼转化为在密集任务上获得更好的预测结果, 在 $\mathcal{L}_{\text{Ref}}$ (+2 mIoU于ADE20k)带来的增益基础上实现了额外提升。我们还在图9b中对格拉姆教师模型的选择进行了消融实验。有趣的是, 选择100k或200k次迭代的格拉姆教师对结果没有显著影响, 但使用迭代次数多得多 (100万次) 的格拉姆教师反而有害, 因为这种教师的块级一致性较差。

最后, 我们在图10中定性说明了Gram锚定对块级一致性的影响, 该图可视化展示了通过初始训练和高分辨率Gram锚定细化获得的块特征的Gram矩阵。我们观察到, 我们的高分辨率细化过程在特征相关性方面带来了显著改进。



(a) Gram matrices at different input resolutions.

Method	Teacher Iteration	Res.	IN1k Linear	ADE mIoU	NYU RMSE
Baseline	—	—	88.2	50.3	0.307
GRAM	200k	$\times 1$	88.0	53.6	0.285
GRAM	200k	$\times 2$	88.0	55.7	0.281
GRAM	100k	$\times 2$	87.9	55.7	0.284
GRAM	1M	$\times 2$	88.1	54.9	0.290

(b) Ablation of Gram teachers and resolutions.

图9: 高分辨率Gram影响的定量与定性研究。我们展示了(a)将高分辨率映射下采样为较小映射后改进的余弦映射, 以及(b)通过改变训练迭代次数和Gram教师分辨率带来的定量提升。




图10: Gram锚定的定性效果。我们展示了在使用优化目标 $\mathcal{L}_{HRef}$ 前后余弦图的可视化结果。图像的输入分辨率为 1024×1024 像素。

5 训练后

本节介绍了 *post-training* 个阶段。这包括一个高分辨率适应阶段, 使模型能在不同输入分辨率下进行有效推理 (第5.1节); 模型蒸馏阶段, 用于生成高质量且高效的小尺寸模型 (第5.2节); 以及文本对齐阶段, 为 DINOv3 添加零样本能力 (第5.3节)。

5.1 分辨率缩放

我们在256这一相对较小的分辨率下训练模型, 这在速度与效果之间取得了良好平衡。采用16的补丁尺寸时, 该设置产生的输入序列长度与DINOv2相同——后者使用224分辨率和14补丁尺寸进行训练。然而, 许多现代计算机视觉




图11：高分辨率适应的效果。分辨率缩放前后（第5.1节）在以下任务上的结果对比：(a) ImageNet上的线性分类，(b) 应用于ObjectNet的分布外检测，(c) ADE20k上的线性语义分割，以及(d) DAVIS上不同评估分辨率下的分割跟踪。

应用需要处理分辨率显著更高的图像，通常为 512×512 像素或更大，以捕捉复杂的空间信息。在实际应用中，推理图像的分辨率也并非固定，而是根据具体使用场景而变化。为了解决这一问题，我们通过一个高分辨率适应步骤（Touvron等人，2019）扩展了训练方案。为确保在一系列分辨率下都能保持高性能，我们采用 *mixed resolutions*，在每个小批量中采样不同尺寸的全局裁剪和局部裁剪对。具体来说，我们考虑的全局裁剪尺寸范围为 $\{512, 768\}$ ，局部裁剪尺寸范围为 $\{112, 168, 224, 336\}$ ，并额外训练模型10,000次迭代。

与主要训练类似，这一高分辨率适应阶段的关键组成部分是加入Gram锚定，使用7B教师模型作为Gram教师。我们发现这一组件至关重要：若缺少它，模型在密集预测任务上的性能会显著下降。Gram锚定促使模型在空间位置上保持一致且稳健的特征相关性，这在处理高分辨率输入带来的更高复杂度时尤为关键。

根据经验，我们观察到这一相对简短但有针对性的高分辨率步骤显著提升了模型的整体质量，并使其能够泛化到广泛的输入尺寸范围，如图4所示。在图11中，我们比较了适应前后的7B模型。我们发现分辨率缩放对ImageNet分类 (a) 带来小幅提升，且性能随分辨率保持相对稳定。然而，在ObjectNet分布外迁移 (b) 中，我们观察到较低分辨率下性能略有下降，而较高分辨率下则有所改善。这主要得益于高分辨率下局部特征质量的提升——ADE20k分割 (c) 和DAVIS跟踪 (d) 的正向趋势证明了这一点。适应过程使得局部特征能够 *improve with image size*，利用更大分辨率下更丰富的空间信息，从而有效实现高分辨率推理。有趣的是，适应后的模型支持的分辨率远超768的最大训练分辨率——我们通过可视化观察到在4k以上分辨率下特征图仍保持稳定 (c.f., 见图4)。

5.2 模型蒸馏

面向多种应用场景的模型家族 我们将7B模型通过知识蒸馏压缩为更小的视觉Transformer变体（ViT-S、ViT-B和ViT-L）。这些轻量化模型因其更优的可管理性和效率而备受社区推崇。蒸馏过程采用与第一阶段训练相同的目标函数，确保学习信号的一致性。与依赖模型权重指数移动平均（EMA）的方法不同，我们直接使用7B模型作为教师模型指导小型学生模型，且教师模型参数保持固定。实验中未观察到图像块级别的特征一致性问题，因此未采用格拉姆锚定技术。该策略使蒸馏模型既能继承大型教师模型丰富的表征能力，又更具部署与实验的实用性。

我们的ViT-7B模型被蒸馏成一系列不同规模的ViT模型，覆盖了广泛的计算预算范围，并允许与同期模型进行恰当比较。这些模型包括标准的ViT-S（2100万参数）、B（8600万）、L（3亿），以及定制的ViT-S+（2900万）和定制的ViT-H+（8亿）模型，以缩小与自蒸馏7B教师模型的性能差距。事实上，我们在DINOv2中观察到，较小的




图12: 多学生蒸馏过程示意图。在此流程中, 我们并行蒸馏3个学生模型: 首先在所有 T 节点间共享教师模型推理以节省计算资源, 并在所有GPU上收集输入与结果。随后, 较小规模的分组将执行学生模型训练。我们通过动态调整这些分组的规模, 使得所有学生模型 S_i 的训练步骤时长保持一致, 从而最小化同步屏障处的等待空闲时间。

学生模型通过蒸馏可以达到与教师模型相当的性能。因此, 蒸馏后的模型仅需少量推理计算即可实现前沿性能, 如表14所示。我们将模型训练100万次迭代, 随后按照余弦调度进行25万次学习率冷却迭代, 再应用上文第5.1节所述的高分辨率训练阶段(不使用Gram锚定)。

高效多学生蒸馏 由于大型教师的推理成本可能比学生高出数个数量级(见图16a), 我们设计了一种并行蒸馏流程, 允许同时训练多个学生, 并在所有参与训练的节点之间共享教师推理(示意图见图12)。设 C_T 和 C_S 分别为在单样本上运行教师推理和学生训练的成本, 在批大小为 B 的单教师/单学生蒸馏中, 每个 N GPU 处理数据的 B/N 切片, 则教师推理成本为每 GPU $B/N \times C_T$, 学生训练成本为每 GPU $B/N \times C_S$ 。在多学生蒸馏中, 我们按如下步骤进行。每个学生 S_i 被分配一组 N_{Si} GPU 进行训练, 所有 $N_T = \sum N_{Si}$ GPU 均为全局推理组的一部分。在每次迭代中, 我们首先在全局组上运行教师推理, 每 GPU 计算成本为 $B/N_T \times C_T$ 。随后执行一次 *all-gather* 集合操作, 将输入数据和推理结果共享给所有计算节点。最后, 每个学生组分别进行学生训练, 成本为 $B/N_{Si} \times C_{Si}$ 。

上述计算表明, 在蒸馏流程中增加额外学生模型将 (1) 降低每次迭代的单GPU计算量, 从而全局提升蒸馏速度; (2) 仅因新增学生的训练成本而增加总体计算量, 因为教师模型的推理总成本现已固定。该实施方案仅需谨慎设置GPU进程组, 调整数据加载器和教师推理过程, 确保通过NCCL集合通信实现跨组输入输出的同步。由于各组在每次迭代时均需同步, 为最大化速度, 我们调整每个学生模型分配的GPU数量, 使其迭代时间大致相同。通过这一流程, 我们能够无缝训练多个学生模型, 并基于旗舰7B模型生成完整的蒸馏模型家族。

5.3 将DINOv3与文本对齐

开放词汇图像-文本对齐因其实现灵活可扩展多模态理解的潜力, 已获得研究界的广泛关注与热情。大量

已有大量工作致力于提升CLIP（Radford等人，2021）的质量，该模型最初仅学习了图像与文本表征之间的全局对齐。尽管CLIP展现了出色的零样本能力，但其对全局特征的关注限制了捕捉细粒度局部对应关系的能力。近期研究（Zhai等人，2022b）表明，通过预训练的自监督视觉骨干网络可以实现有效的图文对齐。这使得在多模态场景中利用这些强大模型成为可能，不仅促进了超越全局语义、更丰富且更精确的文本-图像关联，同时由于视觉编码已预先习得，也降低了计算成本。

我们采用Jose等人（2025年）先前提出的训练策略，将文本编码器与我们的DINOv3模型对齐。该方法遵循LIT训练范式（Zhai等人，2022b），从头开始训练文本表示，通过对比目标将图像与其描述匹配，同时保持视觉编码器冻结。为了在视觉侧保留一定灵活性，我们在冻结的视觉骨干网络顶部引入了两个Transformer层。该方法的一个关键改进在于：在匹配文本嵌入之前，将平均池化的图像块嵌入与输出的CLS标记进行拼接。这使得全局和局部视觉特征都能与文本对齐，从而在不依赖额外启发式方法或技巧的情况下，提升了密集预测任务的性能。此外，我们采用与Jose等人（2025年）相同的数据筛选流程，以确保一致性和可比性。

6 结果

在本节中，我们在多种计算机视觉任务上评估我们的旗舰DINOv3 7B模型。在所有实验中，除非另有说明，我们均使用`we keep DINOv3 frozen`并仅利用其表征。我们证明，使用DINOv3无需微调即可获得强劲性能。本节结构如下：首先通过轻量级评估方案探究DINOv3的密集（第6.1节）与全局（第6.2节）图像表征质量，并与现有最强视觉编码器进行比较。我们展示DINOv3既能学习卓越的密集特征，又能提供稳健且多功能的全局图像表征。随后，我们将DINOv3作为开发更复杂计算机视觉系统的基础（第6.3节）。通过在DINOv3基础上施加极少努力，我们就能在目标检测、语义分割、3D视角估计或相对单目深度估计等多样化任务中取得与当前最优方法相当或更优的结果。

6.1 DINOv3 提供卓越的密集特征

我们首先通过一系列多样化的轻量级评估，探究DINOv3稠密表征的原始质量。在所有实验中，我们均使用最后一层的冻结补丁特征，并通过以下方式进行评估：(1) 定性可视化（第6.1.1节）、(2) 稠密线性探测（第6.1.2节：分割、深度估计）、(3) 非参数方法（第6.1.3节：3D对应估计，第6.1.4节：物体发现，第6.1.5节：跟踪），以及(4) 轻量级注意力探测（第6.1.6节：视频分类）。

基线模型 我们将DINOv3的密集特征与当前公开可用的最强图像编码器（包括弱监督和自监督方法）进行对比。我们考虑了采用CLIP风格图文对比学习的弱监督编码器：感知编码器（PE）核心（Bolya等人，2025）和SigLIP 2（Tschannen等人，2025）。同时对比了最先进的自监督方法：带寄存器机制的DINOv3前代模型DINOv2（Oquab等人，2024；Darcet等人，2024）、近期扩展的DINO变体Web-DINO（Fan等人，2025），以及开源数据SSL模型中最优的Franca（Venkataramanan等人，2025）。此外，我们还对比了聚合模型：从DINOv2蒸馏的AM-RADIOv2.5（Heinrich等人，2025）、CLIP（Radford等人，2021）、DFN（Fang等人，2024a）、Segment Anything（SAM）（Kirillov等人，2023），以及将SAM 2（Ravi等人，2025）蒸馏至PEcore的PEspatial。针对每个基线模型，我们报告了可用最强模型的性能，并在表格中注明了对应架构。

6.1.1 定性分析

我们首先对DINOv3的密集特征图进行定性分析。为此，我们使用主成分分析（PCA）将密集特征空间投影到3维，并将得到的3D空间映射到RGB色彩空间。由于PCA存在符号歧义（八种变体）以及主成分与色彩通道之间的任意映射关系，




图13: 密集特征对比。我们通过使用PCA投影其密集输出并将其映射到RGB, 比较了几种视觉骨干网络。从左到右依次为: SigLIP 2 ViT-g/16、PEspatial ViT-G/14、带寄存器的DINOv2 ViT-g/14、DINOv3 ViT-7B/16。使用 16×16 图像块的模型以 1280×960 分辨率前传, 14×14 图像块的模型以 1120×840 分辨率前传, *i.e.* 所有特征图尺寸均为 80×60 。

组件与颜色（六种变体），我们探索了所有组合并报告了视觉上最具吸引力的一种。最终的可视化结果如图13所示。与其他视觉骨干网络相比，可以看出DINOv3的特征更加锐利，包含的噪声少得多，并展现出更优的语义一致性。

6.1.2 密集线性探测

我们在密集特征之上进行线性探测，以完成两项任务：语义分割和单目深度估计。在这两种情况下，我们都在DINOv3冻结的补丁输出之上训练一个线性变换。对于语义分割，我们在ADE20k (Zhou等人, 2017)、Cityscapes (Cordts等人, 2016) 和PASCAL VOC 2012 (Everingham等人, 2012) 数据集上进行评估，并报告平均交并比。

表3: 使用冻结骨干网络在语义分割和单目深度估计上的密集线性探测结果。对于分割基准ADE20k、Cityscapes和VOC, 我们报告平均交并比 (mIoU) 指标。对于深度基准NYUv2和KITTI, 我们报告均方根误差 (RMSE) 指标。在分割任务中, 所有模型均以适配1024个图像块标记的输入分辨率进行评估 (当图像块尺寸为14时采用*i.e.* 448×448 , 当图像块尺寸为16时采用 512×512)。

Method	ViT	Segmentation			Depth	
		ADE20k	Citysc.	VOC	NYUv2 ↓	KITTI ↓
<i>Agglomerative backbones</i>						
AM-RADIOv2.5	g/14	53.0	78.4	85.4	0.340	2.918
PEspatial	G/14	49.3	73.2	82.7	0.362	3.082
<i>Weakly-supervised backbones</i>						
SigLIP 2	g/16	42.7	64.8	72.7	0.494	3.273
PEcore	G/14	38.9	61.1	69.2	0.590	4.119
<i>Self-supervised backbones</i>						
Franca	g/14	46.3	68.7	82.9	0.445	3.140
DINOv2	g/14	49.5	75.6	83.1	0.372	2.624
Web-DINO	7B/14	42.7	68.3	76.1	0.466	3.158
DINOv3	7B/16	55.9	81.1	86.6	0.309	2.346

(mIoU)指标。对于深度估计, 我们使用NYUv2 (Silberman等人, 2012年) 和KITTI (Geiger等人, 2013年) 数据集, 并报告均方根误差 (RMSE)。

结果 (表3) 分割结果证明了我们密集特征的卓越质量。在通用的ADE20k数据集上, DINOv3比自监督基线高出超过6个mIoU点, 比弱监督基线高出超过13点。此外, DINOv3超越PEspatial超过6点, 超越AM-RADIOv2.5近3点。这些结果非常显著, 因为两者都是强大的基线, 均从强监督分割模型SAM (Kirillov等人, 2023) 中蒸馏得到。在自动驾驶基准Cityscapes上也观察到类似结果, DINOv3取得了81.1的最佳mIoU, 超越AM-RADIOv2.5达2.5点, 并领先所有其他骨干网络至少5.5点。

在单目深度估计方面, DINOv3再次以显著优势超越所有其他模型: 弱监督模型PEcore和SigLIP 2仍然落后, 而DINOv2及基于SAM衍生的更先进模型是最接近的竞争者。有趣的是, 尽管PEspatial和AM-RADIO在NYU数据集上表现强劲, 但它们在KITTI数据集上的性能低于DINOv2。即便在此情况下, DINOv3仍以0.278的RMSE优势超越其前代模型DINOv2。

两组评估结果均显示了DINOv3密集特征的卓越表征能力, 并印证了图13中的可视化结果。仅通过线性预测器, DINOv3便能稳健预测物体类别与掩码, 同时完成相对深度等场景物理测量。这些结果表明, 其特征不仅视觉上清晰且定位准确, 还能以线性可分的方式表征底层观测对象的多种重要属性。最后, 在ADE20k数据集上使用线性分类器取得的绝对性能 (55.9 mIoU) 本身令人瞩目, 因其与该数据集当前最优水平 (63.0 mIoU) 差距甚微。

6.1.3 三维对应关系估计

理解三维世界一直是计算机视觉的重要目标。图像基础模型近期通过提供 *3D-aware features*, 推动了三维理解的研究。本节中, 我们遵循Probe3D (Banani等人, 2024) 定义的评估协议, 检验DINOv3的 *multi-view consistency*——即同一物体不同视角下相同关键点的图像块特征是否相似。我们区分了 *geometric* 与 *semantic* 对应关系估计: 前者指为 *same object instance* 匹配关键点, 后者指为 *same object class* 的不同实例匹配关键点。我们在NAVI数据集 (Jampani等人, 2023) 上评估几何对应关系, 并分析语义

表4: 密集表示的三维一致性评估。我们遵循Probe3D (Banani等人, 2024年) 的评估方案, 跨视图估计三维关键点对应关系。为衡量性能, 我们报告了对应召回率 $\{v^*\}$ ——即落在指定距离内的对应关系百分比。

		Geometric	Semantic
Method	ViT	NAVI	SPair
<i>Agglomerative backbones</i>			
AM-RADIOv2.5	g/14	59.4	56.8
PEspatial	G/14	53.8	49.6
<i>Weakly-supervised backbones</i>			
SigLIP 2	g/16	49.4	42.6
PEcore	G/14	39.9	23.1
<i>Self-supervised backbones</i>			
Franca	g/14	54.6	51.0
DINOv2	g/14	60.1	56.1
Web-DINO	7B/14	55.0	32.2
DINOv3	7B/16	64.4	58.7

在SPair数据集上的对应关系 (Min等人, 2019), 并在两种情况下通过对应关系召回率来衡量性能。更多实验细节请参见附录D.3。

结果 (表4) 在几何对应方面, DINOv3超越了所有其他模型, 并将召回率比第二佳模型 (DINOv2) 提升了4.3%。其他自监督学习扩展尝试 (Franca和WebSSL) 落后于DINOv2, 表明它仍然是一个强大的基线。弱监督模型 (PEcore和SigLIP 2) 在此任务上表现不佳, 显示出缺乏3D感知能力。对于采用SAM蒸馏的模型, AM-RADIO几乎达到了DINOv2的性能, 但PEspatial仍落后于它 (-11.6%召回率), 甚至不及Franca (-0.8%召回率)。这表明自监督学习是此任务取得强劲性能的关键因素。在语义对应方面, 相同结论依然成立。DINOv3表现最佳, 既优于其前代模型 (+2.6%召回率), 也优于AM-RADIO (+1.9%召回率)。总体而言, 这些在关键点匹配上的出色表现, 为DINOv3在其他重度依赖3D的应用中的下游使用提供了非常乐观的信号。

6.1.4 无监督目标发现

强大的自监督特征有助于在图像中发现物体实例, 而无需依赖 any 标注 (Vo等人, 2021; Siméoni等人, 2021; Seitzer等人, 2023; Wang等人, 2023c; Siméoni等人, 2025)。我们通过无监督物体发现任务测试不同视觉编码器的这一能力, 该任务要求对图像中的物体进行与类别无关的分割 (Russell等人, 2006; Tuytelaars等人, 2010; Cho等人, 2015; Vo等人, 2019)。具体而言, 我们采用基于图的非参数化TokenCut算法 (Wang等人, 2023c), 该算法已在多种骨干网络上展现出优异性能。我们在三个广泛使用的数据集上运行该算法: VOC 2007、VOC 2012 (Everingham等人, 2015) 和COCO-20k (Lin等人, 2014; Vo等人, 2020)。遵循Siméoni等人 (2021) 定义的评估协议, 我们报告CorLoc指标。为公平比较具有不同特征分布的骨干网络, 我们对TokenCut的主要超参数——即在构建用于分割的图块图时应用的余弦相似度阈值——进行了搜索。最初, 最佳物体发现结果是通过DINO (Caron等人, 2021) 使用最后一层注意力层的键特征获得的。但这种人工选择方案无法稳定推广到其他骨干网络。为简化流程, 我们对所有模型均统一使用输出特征。

结果 (图14) 原始DINO为此任务设定了极高的标准。有趣的是, 尽管DINOv2在像素级密集任务中表现出色, 却在物体发现任务中失败。这部分可归因于其密集特征中存在的伪影 (*c.f.* 图13)。DINOv3凭借其清晰精确的输出特征图, 超越了所有前代模型 (在VOC 2007上实现5.9的CorLoc提升) 以及其他所有骨干网络——无论是自监督、弱监督还是凝聚式方法。这项评估证实了

Method	ViT	VOC07	VOC12	COCO
<i>Agglomerative backbones</i>				
AM-RADIOv2.5	g/14	55.0	59.7	45.9
PEspatial	G/14	51.2	56.0	43.9
<i>Weakly-supervised backbones</i>				
SigLIPv2	g/16	20.5	24.7	18.6
PEcore	G/14	14.2	18.2	13.5
<i>Self-supervised backbones</i>				
DINO	S/16	61.1	66.0	48.7
DINO	B/16	60.1	64.4	50.5
DINOv2	g/14	55.6	60.4	45.4
Web-DINO	7B/14	26.1	29.7	20.9
DINOv3	7B/16	66.1	69.5	55.1



图14：无监督物体发现。我们在不同骨干网络的输出补丁特征上应用TokenCut（Wang等人，2022c），并报告CorLoc指标。同时，我们可视化通过DINOv3获得的预测掩码（在1024分辨率输入图像上的红色叠层），结果with no annotation and no post-processing。

DINOv3的密集特征既具备强大的语义表达能力，又能实现精准的局部定位。我们相信这将为更多类别无关的目标检测方法开辟道路，尤其在标注成本高昂或难以获取、且相关类别不局限于预定义子集的场景中。

6.1.5 视频分割跟踪

除了静态图像，视觉表征的一个重要特性是它们的*temporal consistency*，*i.e.*，即特征是否随时间以稳定的方式演化。为测试这一特性，我们在视频分割跟踪任务上评估DINOv3：给定视频第一帧的真实实例分割掩码，目标是将这些掩码传播到后续帧。我们使用DAVIS 2017（Pont-Tuset等人，2017）、YouTube-VOS（Xu等人，2018）和MOSE（Ding等人，2023）数据集。我们采用标准的 $\mathcal{J}$ & $\mathcal{F}$ -均值指标评估性能，该指标综合了区域相似度（ $\mathcal{J}$ ）和轮廓准确度（ $\mathcal{F}$ ）（Perazzi等人，2016）。遵循Jabri等人（2020）的方法，我们使用一种非参数化的标签传播算法，该算法考虑跨帧的补丁特征之间的相似性。我们在三种输入分辨率下进行评估，对于补丁尺寸为14/16的模型（匹配补丁标记数量），短边长度分别设为420/480（S）、840/960（M）和1260/1440（L）像素。 $\mathcal{J}$ & $\mathcal{F}$ 分数始终在视频原始分辨率下计算。更多实验设置细节见附录D.5。

结果（表5）与之前的所有结果一致，弱监督主干网络未能提供令人信服的性能。从视频模型SAMv2蒸馏得到的PEspatial在较小分辨率下表现令人满意，超越了DINOv2，但在较大分辨率上表现不足。在所有分辨率中，DINOv3均优于所有竞争对手，在DAVIS-L上取得了惊人的83.3 $\mathcal{J}$ & $\mathcal{F}$ ，比DINOv2高出6.7个百分点。此外，性能随分辨率的变化呈现健康趋势，证实了我们的模型能够利用更多输入像素来输出精确的高分辨率特征图（*c.f.*，见图3和图4）。相比之下，SigLIP 2和PEcore在较高分辨率下的性能几乎保持平稳，而PEspatial则出现下降。有趣的是，我们的图像模型未经任何视频调优，便能正确跟踪时间序列中的物体（见图15）。这使其成为视频嵌入的优秀候选方案，为构建强大的视频模型奠定了基础。

6.1.6 视频分类

先前的结果已显示DINOv3表征具备低层次的时间一致性，能够准确追踪物体在时间维度上的变化。更进一步，本节将评估其密集特征在高层视频分类任务中的适用性。类似于V-JEPA 2（Assran等人，2025年）的设置，我们在从每帧提取的补丁特征之上训练一个*attentive probe*——一个基于浅层4层Transformer的分类器。由于特征是按帧独立提取的，该设计支持模型在时间和空间维度上进行推理。

表5: 视频分割跟踪评估。我们在多个分辨率下报告了DAVIS、YouTube-VOS和MOSE数据集上的 $\mathcal{J}$ 与 $\mathcal{F}$ 均值。对于补丁尺寸为14/16的模型，小、中、大分辨率分别对应视频短边为420/480、840/960、1260/1140像素。

Method	ViT	DAVIS			YouTube-VOS			MOSE		
		S	M	L	S	M	L	S	M	L
<i>Agglomerative backbones</i>										
AM-RADIOv2.5	g/14	66.5	77.3	81.4	70.1	78.1	79.2	44.0	52.6	54.3
PEspatial	G/14	68.4	74.5	70.5	68.5	67.5	55.6	39.3	40.2	34.0
<i>Weakly-supervised backbones</i>										
SigLIP 2	g/16	56.1	62.3	62.9	52.0	57.3	55.1	28.0	30.3	29.2
PEcore	G/14	48.2	53.1	49.8	34.7	33.0	25.3	17.8	19.0	15.4
<i>Self-supervised backbones</i>										
Franca	g/14	61.8	66.9	66.5	67.3	70.5	67.9	40.3	42.6	41.9
DINOv2	g/14	63.9	73.6	76.6	65.6	73.5	74.6	40.4	47.6	48.5
Web-DINO	7B/14	57.2	65.8	69.5	43.9	49.6	50.9	24.9	29.9	31.1
DINOv3	7B/16	71.1	79.7	83.3	74.1	80.2	80.7	46.0	53.9	55.6




图15: 分割跟踪示例。给定初始帧的真实实例分割掩码，我们根据DINOv3特征空间中的补丁相似性将实例标签传播到后续帧。输入分辨率为 2048×1536 像素，对应生成 128×96 个补丁。

在评估过程中，我们为每个视频选取单个片段，或采用测试时增强（TTA）方法——通过对每个视频的3个空间裁剪和2个时间裁剪的预测结果取平均值来获得最终预测。实验细节详见附录D.6。我们在三个数据集上进行了评估：UCF101（Soomro等人，2012）、Something-Something V2（Goyal等人，2017）和Kinetics-400（Kay等人，2017），并报告了Top-1准确率。作为额外基线，我们报告了当前最先进的视频理解自监督学习模型V-JEPA v2的性能表现。

结果（表6）与先前实验的结论一致，我们发现DINOv3能够成功用于提取强大的视频特征。由于本次评估涉及训练多个自注意力层，模型之间的差异不太明显。然而，DINOv3的表现与PEcore和SigLIP 2处于同一水平，并在所有数据集中明显优于其他模型（DINOv2、AM-RADIO）。UCF101和K400侧重于外观特征，其中对物体类别层面的深刻理解贡献了主要性能。而SSv2则需要更好地理解运动——专为视频设计的模型V-JEPA v2在该数据集上表现出色。有趣的是，DINOv3与弱监督模型之间的差距在该数据集上略大。这再次证实了DINOv3适用于视频任务。

表6: 使用注意力探针的视频分类评估。我们在UCF101、Something-Something V2 (SSv2) 和Kinetics-400 (K400) 上报告了top-1准确率。对于每个模型, 我们报告了每个视频评估单个片段的表现, 或通过平均多个片段的预测概率应用测试时增强 (TTA) 的表现。

		UCF101		SSv2		K400	
Method	ViT	Single	TTA	Single	TTA	Single	TTA
<i>Agglomerative backbones</i>							
AM-RADIOv2.5	g/14	92.8	92.5	69.1	70.0	84.8	85.2
PEspatial	G/14	92.7	92.8	66.4	68.4	83.5	84.8
<i>Weakly-supervised backbones</i>							
SigLIP 2	g/16	93.6	94.2	68.8	70.2	86.9	87.7
PEcore	G/14	93.1	93.3	69.0	70.4	87.9	88.8
<i>Self-supervised backbones</i>							
DINOv2	g/14	93.5	93.8	67.4	68.4	84.4	85.6
V-JEPA 2	g/16	94.0	93.8	73.8	75.4	83.3	84.3
Web-DINO	7B/14	93.9	94.1	67.3	68.1	86.8	87.2
DINOv3	7B/16	93.5	93.5	70.1	70.8	87.8	88.2

6.2 DINOv3 拥有稳健且多功能的全局图像描述符

在本节中, 我们评估DINOv3捕捉全局图像统计信息的能力。为此, 我们考虑使用线性探针 (第6.2.1节) 的经典分类基准和实例检索基准 (第6.2.2节)。我们再次与公开可用的最强图像编码器进行比较。除了上一节的模型外, 我们还评估了两个弱监督模型: AIMv2 (Fini等人, 2024年), 该模型通过联合自回归像素与文本预测进行训练; 以及大规模的EVA-CLIP-18B (Sun等人, 2024年)。

6.2.1 基于线性探测的图像分类

我们在DINOv3输出的CLS标记上训练一个线性分类器, 以在分类基准上评估模型。我们采用ImageNet1k (Deng等人, 2009) 数据集及其变体来评估分布外鲁棒性, 并利用一组来自不同领域的数据集来理解DINOv3区分细粒度类别的能力。评估细节见附录D.7。

基于ImageNet的领域泛化 (表7) 在本实验中, 我们在ImageNet-*train*上进行训练, 使用ImageNet-*val*作为 *validation set*来选择超参数, 并将找到的最佳分类器迁移到不同的测试数据集: ImageNet-V2 (Recht等人, 2019) 和ReaL (Beyer等人, 2020) 是ImageNet的替代图像和标签集, 用于测试在ImageNet验证集上的过拟合; Rendition (Hendrycks等人, 2021a) 和Sketch (Wang等人, 2019) 展示了ImageNet类别的风格化和人工合成版本; Adversarial (Hendrycks等人, 2021b) 和ObjectNet (Barbu等人, 2019) 包含刻意选择的困难样本; Corruptions (Hendrycks和Dietterich, 2019) 衡量对常见图像损坏的鲁棒性。作为参考, 我们还列出了Dehghani等人 (2023) 在大型JFT数据集 (30亿–40亿图像) 上通过监督分类训练的ViT的线性探测结果。请注意, 这些结果遵循略有不同的评估协议, 与我们的结果不能直接比较。

DINOv3显著超越了所有先前的自监督骨干网络, 在ImageNet-R上提升+10%, 在-Sketch上提升+6%, 在ObjectNet上相比先前最强的SSL模型DINOv2提升+13%。我们注意到, 在ImageNet-A和ObjectNet等困难OOD任务上, 目前最强的弱监督模型SigLIP 2和PE已优于最强的监督模型 (ViT-22B)。DINOv3在ImageNet-R和-Sketch上取得了可比的结果, 而在困难任务ImageNet-A和ObjectNet上紧随PE之后, 同时超越了SigLIPv2。在ImageNet上, 虽然验证分数比SigLIPv2和PE低0.7–0.9分, 但在更“干净”的测试集-V2和-ReaL上表现几乎相同。值得注意的是, DINOv3实现了最佳的抗干扰鲁棒性 (ImageNet-C)。总而言之, *this is the first time that a SSL model has reached*

表7：在ImageNet1k上使用冻结骨干网络训练的线性探针分类准确率。弱监督和自监督模型评估时，图像分辨率调整为1024个图像块标记（*i.e.* 当图像块尺寸为14时采用 448×448 分辨率，图像块尺寸为16时采用 512×512 分辨率）。作为参考，我们还列出了Dehghani等人（2023年）采用不同评估方案的结果（以*标记）。

Method	ViT	ImageNet			Rendition		Hard		
		Val	V2	ReaL	R	S	A	C ↓	Obj.
<i>Supervised backbones</i>									
Zhai et al. (2022a)*	G/14	89.0	81.3	90.6	91.7	—	78.8	—	69.6
Chen et al. (2023)*	e/14	89.3	82.5	90.7	94.3	—	81.6	—	71.5
Dehghani et al. (2023)*	22B/14	89.5	83.2	90.9	94.3	—	83.8	—	74.3
<i>Agglomerative backbones</i>									
AM-RADIOv2.5	g/14	88.0	80.2	90.3	83.8	67.1	81.3	27.1	68.4
<i>Weakly-supervised backbones</i>									
PEcore	G/14	89.3	81.6	90.4	92.2	71.9	89.0	22.7	80.2
SigLIP 2	g/16	89.1	81.6	90.5	92.2	71.8	84.6	30.0	78.6
AIMv2	3B/14	87.9	79.5	89.7	82.3	67.1	74.5	29.5	69.0
EVA-CLIP	18B/14	87.9	79.3	89.5	85.2	64.0	81.6	33.0	71.9
<i>Self-supervised backbones</i>									
Web-DINO	7B/14	85.9	77.1	88.6	75.6	64.0	71.6	31.2	69.7
Franca	g/14	84.8	75.3	89.2	67.6	49.5	56.5	40.0	54.5
DINOv2	g/14	87.3	79.5	89.9	81.1	65.4	81.7	24.1	66.4
DINOv3	7B/16	88.4	81.4	90.4	91.1	71.3	86.9	19.6	79.0

表8：细粒度分类基准。Fine-S平均了12个数据集的结果，完整结果参见表22。

Method	ViT	Fine-S	Places	iNat18	iNat21
<i>Agglomerative backbones</i>					
AM-RADIOv2.5	g/14	93.9	70.2	79.0	83.7
<i>Weakly-supervised backbones</i>					
SigLIP 2	g/16	93.7	70.5	80.7	82.7
PEcore	G/14	94.5	71.3	86.6	87.0
AIMv2	3B/14	92.9	70.7	80.8	83.2
EVA CLIP	18B/14	92.9	71.1	80.7	83.5
<i>Self-supervised backbones</i>					
Franca	g/14	87.7	64.6	61.4	70.6
DINOv2	g/14	92.6	68.2	80.7	86.1
Web-DINO	7B/14	90.2	69.6	65.3	74.1
DINOv3	7B/16	93.0	70.0	85.6	89.8

表9：实例识别基准。更多指标请参见表23。

Oxford-H	Paris-H	Met (GAP)	AmsterTime
47.5	85.7	30.5	23.1
25.1	60.9	13.9	15.5
32.7	68.9	10.6	23.1
28.8	71.4	29.5	14.6
27.1	65.6	0.5	18.9
14.3	51.6	27.2	21.1
58.2	84.6	44.6	48.9
31.2	80.3	35.2	30.6
60.7	87.1	55.4	56.5

comparable results to weakly- and supervised models on image classification——这一领域曾是（弱）监督训练方法的强项。考虑到像ViT-22B、SigLIP 2和PE这样的模型都是使用海量人工标注数据集进行训练的，这一结果尤为显著。相比之下，DINOv3仅从图像中学习，这使得未来进一步扩展/改进该方法成为可能。

细粒度分类（表8）我们还在多个细粒度分类数据集上训练线性探针，以评估DINOv3的性能。具体而言，我们报告了三个大型数据集上的准确率：用于场景识别的Places205（Zhou等人，2014）、用于详细动植物物种识别的iNaturalist 2018（Van Horn等人，2018）和iNaturalist 2021（Van Horn等人，2021），以及涵盖场景、物体和纹理的12个较小数据集的平均准确率（参照Oquab等人（2024）的方法，此处称为Fine-S）。各数据集的单独结果另见表22。

我们发现，DINOv3再次超越了所有先前的自监督学习方法。与弱监督方法相比，它也展现出具有竞争力的结果，这表明其在多样化的细粒度分类任务中具有鲁棒性和泛化能力。值得注意的是，DINOv3在难度较高的iNaturalist21数据集上达到了89.8%的最高准确率，甚至超过了最佳弱监督模型PEcore的87.0%。

6.2.2 实例识别

为评估我们模型在实例级别的识别能力，我们采用了非参数检索方法。该方法通过计算查询图像与数据库图像在输出CLS token上的余弦相似度，对数据库图像进行排序。我们在多个数据集上进行了性能基准测试：用于地标识别的牛津和巴黎数据集（Radenovi 等人, 2018）、包含大都会博物馆艺术品的Met数据集（Ypsilantis等人, 2021），以及将现代街景图像与阿姆斯特丹历史档案图像匹配的AmsterTime数据集（Yildiz等人, 2022）。检索效果通过平均平均精度（牛津、巴黎和AmsterTime）和全局平均精度（Met）进行量化。更多评估细节请参见附录D.8。

结果（表9和表23）在所有评估基准中，DINOv3均以显著优势取得最强性能，*e.g.* 其在Met基准上较次优模型DINOv2提升+10.8分，在AmsterTime基准上提升+7.6分。在此基准测试中，弱监督模型普遍大幅落后于DINOv3，唯一例外是从DINOv2特征蒸馏得到的AM-RADIO。这些发现凸显了DINOv3在实例级检索任务中的鲁棒性与泛化能力，其优势覆盖传统地标数据集及艺术与历史图像检索等更具挑战性的领域。

6.3 DINOv3是复杂计算机视觉系统的基础

前两节已为DINOv3在密集任务和全局任务中的质量提供了有力信号。然而，这些结果是在“模型探测”实验协议下获得的，即使用轻量级线性适配器甚至非参数算法来评估特征质量。虽然这种简单评估能够排除复杂实验协议中的干扰因素，但尚不足以评估DINOv3作为大型计算机视觉系统基础组件的全部潜力。因此，在本节中，我们摒弃轻量级协议，转而训练更复杂的下游解码器，并考虑更强、更具任务针对性的基线。具体而言，我们将DINOv3作为基础应用于：(1) 基于Plain-DETR的目标检测（第6.3.1节），(2) 基于Mask2Former的语义分割（第6.3.2节），(3) 基于Depth Anything的单目深度估计（第6.3.3节），以及(4) 基于视觉几何接地Transformer的3D理解（第6.3.4节）。这些任务仅作为探索DINOv3潜力的示例。尽管如此，我们发现基于DINOv3构建系统能以极小代价获得具有竞争力甚至最先进的结果。

6.3.1 目标检测

作为首要任务，我们着手解决目标检测这一长期存在的计算机视觉问题。给定一张图像，目标是为所有预定义类别的物体实例提供边界框。这项任务既需要精确定位，也需要良好的识别能力，因为边界框必须与物体边界匹配，并对应正确的类别。尽管在COCO（Lin等人, 2014）等标准基准测试上的性能已趋于饱和，我们仍提出采用*frozen*骨干网络来处理此任务，仅在其上训练一个轻量级解码器。

数据集与评估指标 我们使用COCO数据集（Lin等人, 2014年）评估DINOv3的目标检测能力，并在COCO-VAL2017划分上报告结果。此外，我们在COCO-O评估数据集（Mao等人, 2023年）上评估其分布外性能。该数据集包含相同的类别，但在六种分布偏移设置下提供输入图像。对于这两个数据集，我们报告IoU阈值在[0.5 : 0.05 : 0.95]范围内的平均精度均值（mAP）。对于COCO-O，我们还额外报告了有效鲁棒性（ER）。由于COCO是一个小型数据集，仅包含11.8万张训练图像，我们按照常见做法，利用更大的Objects365数据集（Shao等人, 2019年）对解码器进行预训练。

表10：与最先进系统在目标检测上的比较。我们在`frozen` DINOv3骨干网络上训练了一个检测适配器。我们在COCO和COCO-O数据集的验证集上展示结果，并报告了跨IoU阈值的mAP以及有效鲁棒性（ER）。我们基于DINOv3的检测系统创造了新的最先进水平。由于InternImage-G检测模型尚未发布，我们无法复现其结果或计算COCO-O分数。

Model	Detector	FT	Parameters			COCO		COCO-O	
			Encoder	Decoder	Trainable	Simple	TTA	mAP	ER
EVA-02	Cascade	🐟	300M	—	300M	64.1	—	63.6	34.7
InternImage-G	DINO	🐟	6B	—	6B	65.1	65.3	—	—
EVA-02	Co-DETR	🐟	300M	—	300M	65.4	65.9	63.7	34.3
PEspatial	DETA	🐟	1.9B	50M	2B	65.3	66.0	64.0	34.7
DINOv3	Plain-DETR	🌟	7B	100M	100M	65.6	66.1	66.4	36.8

实现 我们在Plain-DETR（Lin等人，2023b）的基础上进行构建，但做了如下修改：我们并未将Transformer编码器融合到主干网络中，而是将其保留为独立模块，这与原始DETR（Carion等人，2020）的做法相似。这使得我们能够在训练和推理过程中完全冻结DINOv3主干网络。据我们所知，这使其成为 *the first competitive detection model touse a frozen backbone*。我们在Objects365数据集上以1536分辨率训练Plain-DETR检测器22个周期，随后以2048分辨率训练1个周期，再在COCO数据集上以2048分辨率训练12个周期。推理时采用2048分辨率。可选地，我们还通过多分辨率（从1536到2880）前传图像来应用测试时增强（TTA）。完整实验细节参见附录D.9。

结果（表10）我们对比了四个模型：采用级联检测器的EVA-02（Fang等人，2024b）、采用Co-DETR的EVA-02（Zong等人，2023）、采用DINO的InternImage-G（Wang等人，2023b）以及采用DETA的PEspatial（Bolya等人，2025）。我们发现，基于冻结的DINOv3骨干网络训练的轻量级检测器（1亿参数）能够达到最先进的性能。在COCO-O数据集上，性能差距尤为明显，这表明检测模型能有效利用DINOv3的鲁棒性。值得注意的是，我们的模型以远少于所有先前模型的训练参数实现了更优性能——即使参数量最小的对比模型仍使用超过3亿可训练参数。我们认为，在不专门优化骨干网络的情况下实现如此强大的性能，为多种实际应用提供了可能：单次骨干网络前向传播即可提供支持多任务的特征，从而降低计算需求。

6.3.2 语义分割

继之前的实验之后，我们现在对语义分割进行评估，这是另一个长期存在的计算机视觉问题。这项任务同样需要强大且定位准确的表征，并期望得到密集的逐像素预测。然而，与目标检测不同，模型无需区分同一物体的不同实例。与检测任务类似，我们在`frozen` DINOv3模型之上训练了一个解码器。

数据集与评估指标 我们的评估主要基于ADE20k数据集（Zhou等人，2017），该数据集包含20k张训练图像和2k张验证图像，涵盖150个语义类别。我们采用平均交并比（mIoU）来衡量性能。为训练分割模型，我们还额外使用了COCO-Stuff（Caesar等人，2018）和Hypersim（Roberts等人，2021）数据集。这两个数据集分别包含164k张图像（171个语义类别）和77k张图像（40个类别）。

实现 为了构建一个从DINOv3特征映射到语义类别的解码器，我们结合了ViT-Adapter（Chen等人，2022）和Mask2Former（Cheng等人，2022），类似于先前的工作（Wang等人，2022b；2023b；a）。然而，在我们的方案中，DINOv3骨干网络在训练期间保持冻结状态。为了避免改变骨干网络的特征，我们进一步移除了原始ViT-Adapter架构中的注入器组件。与基线方法相比，我们还将嵌入维度从1024增加到2048，以支持处理DINOv3骨干网络输出的4096维特征。我们首先对

表 11: ADE20k 语义分割任务与前沿系统的对比。我们在单尺度或多尺度设置（分别对应 Simple 和 TTA）下评估模型。遵循常规做法，我们在 896 分辨率下进行评估并报告 mIoU 分数。BEIT3、ONE-PEACE 和 DINOv3 均采用基于 ViT-Adapter 架构的 Mask2Former，解码器参数同时考虑两者。更多数据集的实验结果见表 24。

Model	FT	Parameters			mIoU	
		Encoder	Decoder	Trainable	Simple	TTA
BEIT3	🐣	1.0B	550M	1.6B	62.0	62.8
InternImage-H	🐣	1.1B	230M	1.3B	62.5	62.9
ONE-PEACE	🐣	1.5B	710M	2.2B	62.0	63.0
DINOv3	🌸	7B	927M	927M	62.6	63.0

在COCO-Stuff数据集上对分割解码器进行80k次迭代训练，随后在Hypersim数据集（Roberts等人，2021）上进行10k次迭代训练。最后，我们在ADE20k的训练集上进行了20k次迭代训练，并在验证集上报告结果。所有训练均在输入分辨率为896的条件下进行。在推理阶段，我们考虑两种设置：单尺度*i.e.*——以前向传播图像时保持训练分辨率；或多尺度*i.e.*——在原始训练分辨率的 $\times 0.9$ 至 1.1 之间取多个图像比例进行预测并取平均值。更多实验细节请参见附录D.10。

结果（表11）我们将所提模型的性能与多种先进基线方法进行比较，包括BEIT-3（Wang等人，2022b）、InternImage-H（Wang等人，2023b）和ONE-PEACE（Wang等人，2023a），并在表24中报告了额外数据集上的结果。基于冻结DINOv3主干网络的语义分割模型达到了最先进的性能，与ONE-PEACE持平（63.0 mIoU）。该模型在COCO-Stuff（Caesar等人，2018）和VOC 2012（Everingham等人，2012）数据集上也超越了所有先前模型。由于语义分割需要精确的逐像素预测，视觉Transformer主干网络存在一个根本性问题：16像素宽的输入块使得预测粒度相对粗糙——这促使了ViT-Adapter等解决方案的出现。另一方面，我们证明了即使分辨率高达4096（*c.f.*，见图3和图4），仍能获得高质量的特征图；这相当于512个令牌宽度的密集特征图。我们希望未来工作能够利用这些高分辨率特征，在不依赖ViT-Adapter与Mask2Former等重型解码器的情况下实现最先进的性能。

6.3.3 单目深度估计

我们现在考虑构建一个单目深度估计系统。为此，我们遵循近期先进方法Depth Anything V2（DAv2）（Yang等人，2024b）的设置。DAv2的核心创新在于利用大量合成生成的图像及其真实深度标注。关键在于，该方法依赖DINOv2作为特征提取器，能够弥合{v*}差距，这是SAM（Kirillov等人，2023）等其他视觉骨干网络所不具备的能力（Yang等人，2024b）。因此，我们在DAv2流程中将DINOv2替换为DINOv3，以验证是否能取得类似效果。

与DAv2类似，我们采用密集预测变换器（DPT）（Ranftl等人，2021）来预测逐像素深度场，并以DINOv3四个等间距层的特征作为输入。我们使用DAv2的合成数据集，并沿用其损失函数组合对模型进行训练，同时将训练分辨率提升至 1024×768 ，以充分发挥DINOv3的高分辨率特性。与DAv2不同的是，我们 *keep the backbone frozen* 而非对其进行微调，以此测试DINOv3的開箱即用能力。我们还发现扩大DPT头部规模有助于充分释放DINOv3 7B更大特征向量的潜力。详见附录D.11。

数据集与评估指标 我们在5个真实世界数据集（NYUv2（Silberman等人，2012）、KITTI（Geiger等人，2013）、ETH3D（Schöps等人，2017）、ScanNet（来自Ke等人（2025））和DIODE（Vasiljevic等人，2019））上评估我们的模型，采用与Ranftl等人（2020）和Ke等人（2025）类似的零样本尺度不变深度估计设置。

表12: 与相对单目深度估计的先进系统对比。通过将DINOv3与Depth Anything V2 (Yang等人, 2024b) 结合, 我们获得了相对深度估计的SotA模型。

Method	FT	NYUv2		KITTI		ETH3D		ScanNet		DIODE	
		ARel ↓	δ_1 ↑	ARel ↓	δ_1 ↑	ARel ↓	δ_1 ↑	ARel ↓	δ_1 ↑	ARel ↓	δ_1 ↑
MiDaS	🐟	11.1	88.5	23.6	63.0	18.4	75.2	12.1	84.6	33.2	71.5
LeReS	🐟	9.0	91.6	14.9	78.4	17.1	77.7	9.1	91.7	27.1	76.6
Omnidata	🐟	7.4	94.5	14.9	83.5	16.6	77.8	7.5	93.6	33.9	74.2
DPT	🐟	9.8	90.3	10.0	90.1	7.8	94.6	8.2	93.4	18.2	75.8
Marigold	🐟	5.5	96.4	9.9	91.6	6.5	96.0	6.4	95.1	30.8	77.3
DAv2 (ViT-g)	🐟	4.4	97.9	7.5	94.7	13.1	86.5	—	—	—	—
DINOv3	🌟	4.3	98.0	7.3	96.7	5.4	97.5	4.4	98.1	25.6	82.2

Yang等人 (2024b)。我们报告了标准指标绝对相对误差 (ARel) (越低越好) 和 δ_1 (越高越好)。关于这些指标的详细说明, 请参考Yang等人 (2024a)。

结果 (表12) 我们与相对深度估计的最新方法进行了比较: MiDaS (Ranftl等人, 2020)、LeReS (Yin等人, 2021)、Omnidata (Eftekhar等人, 2021)、DPT (Ranftl等人, 2021)、集成版本的Marigold (Ke等人, 2025) 以及DAv2。我们的深度估计模型在所有数据集上都达到了新的最优水平, 仅在DIODE数据集的ARel指标上略逊于DPT。值得注意的是, 这是通过使用 *frozen backbone* 实现的, 而所有其他基线方法都需要针对深度估计任务对主干网络进行微调。此外, 这验证了DINOv3继承了DINOv2的 *strong sim-to-real capabilities* 特性, 这一理想特性为下游任务使用合成生成的训练数据开辟了可能性。

6.3.4 基于DINOv3的视觉几何基础Transformer

最后, 我们利用最新的视觉几何基础Transformer (VGGT) (Wang等人, 2025年) 探讨三维理解。通过在大量三维标注数据上进行训练, VGGT学会了在单次前向传播中估计场景的所有重要三维属性, 例如相机内参和外参、点云图或深度图。它采用简单统一的流程, 在许多三维任务上达到了最先进的结果, 同时比专用方法更高效——这构成了三维理解领域的一项重大进展。

VGGT的实现采用DINOv2预训练主干网络获取场景多视角表征, 再通过transformer进行融合。此处我们直接将DINOv2主干网络替换为DINOv3, 采用ViT-L变体 (参见第7节) 以匹配原工作中DINOv2 ViT-L/14的配置。我们沿用VGGT的训练流程, 包括图像主干网络的微调。为适配DINOv3的16×16图像块尺寸并保持结果与VGGT可比, 将图像分辨率从518×518调整为592×592。另采用附录D.12详述的少量超参数调整。

数据集与评估指标 遵循Wang等人 (2025) 的方法, 我们在Re10K (Zhou等人, 2018) 和CO3Dv2 (Reizenstein等人, 2021) 数据集上评估相机姿态估计, 在DTU (Jensen等人, 2014) 上评估密集多视角估计, 在ScanNet-1500 (Dai等人, 2017) 上评估双视角匹配。对于相机姿态估计和双视角匹配, 我们报告标准的曲线下面积 (AUC) 指标。对于多视角估计, 我们将预测到真实值的最小L2距离报告为“准确度”, 将真实值到预测的最小L2距离报告为“完整度”, 二者的平均值报告为“综合指标”。具体方法与评估细节请参考Wang等人 (2025) 的研究。

结果 (表13) 我们发现, 配备DINOv3 *further improves over the previous state-of-the-art* 的VGGT在所有三项考量任务中均带来明确且一致的性能提升——使用DINOv3产生了显著增益。考虑到我们仅对DINOv3进行了最小限度的调优, 这一结果令人鼓舞。这些任务涵盖了不同层次的视觉理解: 场景内容的高层抽象 (相机姿态估计)、密集几何预测 (多视角深度估计) 以及细粒度像素级对应 (视图匹配)。至

表13: 使用视觉几何基础Transformer (VGGT) 进行三维理解 (Wang等人, 2025年)。仅需在VGGT流程中将DINOv2替换为DINOv3 ViT-L作为图像特征提取器, 我们就能在各种三维几何任务上取得最先进的结果。我们复现了Wang等人 (2025年) 的基线结果, 同时报告了使用真实相机信息的方法 (标记为*)。相机姿态估计结果以AUC@30指标呈现。

(a) 相机姿态估计。			(b) 在DTU上的多视角估计。				(在ScanNet-1500数据集上进行c)视图匹配。		
Method	Re10K	CO3Dv2	Method	Acc.↓	Comp.↓	Overall↓	Method	AUC@5	AUC@10
DUSt3R	67.7	76.7	Gipuma*	0.283	0.873	0.578	SuperGlue	16.2	33.8
MASt3R	76.4	81.8	CIDER*	0.417	0.437	0.427	LoFTR	22.1	40.8
VG GSfM v2	78.9	83.4	MASt3R*	0.403	0.344	0.374	DKM	29.4	50.7
CUT3R	75.3	82.8	GeoMVSNet*	0.331	0.259	0.295	CasMTR	27.1	47.0
FLARE	78.8	83.3	DUSt3R	2.677	0.805	1.741	Roma	31.8	53.4
VGGT	85.3	88.2	VGGT	0.389	0.374	0.382	VGGT	33.9	55.2
DINOv3	86.3	89.6	DINOv3	0.375	0.361	0.368	DINOv3	35.2	56.1

结合先前关于对应关系估计 (第6.1.3节) 和深度估计 (第6.3.3节) 的研究结果, 我们将此视为进一步的经验证据, 表明DINOv3{v*}作为三维任务基础具有极强的适用性。此外, 我们预期使用更大的DINOv3 7B模型将带来进一步的性能提升。

7 评估DINOv3完整模型家族

在本节中, 我们对从7B参数模型 (参见第5.2节) 蒸馏得到的模型系列进行定量评估。该系列包括基于视觉变换器 (ViT) 和ConvNeXt (CNX) 架构的变体。我们在图16a中提供了所有模型的详细参数数量和推理浮点运算量。这些模型覆盖了广泛的计算预算范围, 以适应不同用户和部署场景的需求。我们对所有ViT (第7.1节) 和ConvNeXt变体进行了全面评估, 以衡量它们在各项任务中的性能表现。

图2提供了DINOv3系列与其他模型集合的概览对比。在密集预测任务上, DINOv3系列显著优于所有其他模型, 这包括从AM-RADIO和PEspatial等有监督骨干网络蒸馏得到的专用模型。同时, 我们的模型在分类任务上取得了相似的结果, 使其成为不同计算预算下的最优选择。

在7.1节中, 我们详细介绍了我们的ViT模型, 并将其与其他开源替代方案进行了比较。接着, 在7.2节中, 我们讨论了ConvNeXt模型。最后, 遵循5.3节的方法, 我们训练了一个与ViT-L模型输出对齐的文本编码器。我们在7.3节中展示了该模型的多模态对齐结果。


7.1 适用于各种使用场景的视觉Transformer

我们的ViT系列涵盖从紧凑型ViT-S到拥有8.4亿参数的更大规模ViT-H+模型等多种架构。前者专为在笔记本电脑等资源受限设备上高效运行而设计, 后者则为要求更高的应用提供最先进的性能表现。我们将ViT模型与同尺寸的最佳开源图像编码器进行比较, 包括DINOv2 (Oquab等人, 2024)、SigLIP 2 (Tschannen等人, 2025) 和感知编码器 (Bolya等人, 2025)。为确保公平比较, 我们统一了各模型的输入序列长度: 当模型使用16×16图像块大小时, 输入图像尺寸为512××512; 当使用14×14图像块时, 输入尺寸则为448××448。

我们的实证研究清楚地表明, DINOv3模型在密集预测任务上始终优于同类模型。最值得注意的是, 在ADE20k基准测试中, DINOv3 ViT-L模型相比最佳竞争对手DINOv2实现了超过6个mIoU点的提升。ViT-B变体相较于次优竞争对手也获得了约3个mIoU点的增益。这些显著改进凸显了DINOv3局部特征在捕捉细粒度空间细节方面的有效性。此外, 在深度估计任务上的评估也显示, 相比竞争方法, DINOv3取得了持续的性能提升。

Model	#Params	Inference GFLOPs	
		Res. 256	Res. 512
CNX-Tiny	29M	5	20
CNX-Small	50M	11	46
CNX-Base	89M	20	81
CNX-Large	198M	38	152
ViT-S	21M	12	63
ViT-S+	29M	16	79
ViT-B	86M	47	216
ViT-L	300M	163	721
ViT-H+	840M	450	1903
ViT-7B	6716M	3550	14515

(a) DINOv3 family of models.



(b) ViT-H+ v.s. ViT-7B.

图 16: (a) 蒸馏模型特性展示。CNX 代表 ConvNeXT。我们列出了每个模型的参数量以及在 256×256 和 512×512 尺寸图像上估算的 GFLOPs。(b) 我们将 DINOv3 ViT-H+ 与其 70 亿参数的教师模型进行对比；尽管 ViT-H+ 的参数量减少了近 $10\times$ 倍，其性能仍接近 DINOv3 7B。

表14: 我们模型系列与规模相当的开源替代方案的比较。我们在具有代表性的全局和密集基准测试集上展示了我们的ViT-{S, S+, B, L, H+}模型：分类（IN-ReAL、IN-R、ObjectNet）、检索（Oxford-H）、分割（ADE20k）、深度估计（NYU）、跟踪（960px下的DAVIS）以及关键点匹配（NAVI、SPair）。为公平比较不同补丁尺寸的模型，我们统一了补丁标记的数量。

Size	Model	Global Tasks				Dense Tasks				
		IN-ReaL	IN-R	Obj.	Ox.-H	ADE20k	NYU↓	DAVIS	NAVI	SPair
S	DINOv2	87.3	54.0	47.8	39.5	45.5	0.446	73.6	53.4	51.6
S	DINOv3	87.0	60.4	50.9	49.5	47.0	0.403	72.7	56.3	50.4
S+	DINOv3	88.0	68.8	54.6	50.0	48.8	0.399	75.5	57.1	55.2
B	PEcore	87.5	68.4	57.9	20.2	37.4	0.641	44.5	41.8	13.7
B	SigLIP 2	89.3	80.6	66.9	20.2	41.6	0.512	63.2	45.4	32.8
B	DINOv2	89.0	68.4	57.3	51.0	48.4	0.416	72.9	56.9	57.1
B	DINOv3	89.3	76.7	64.1	58.5	51.8	0.373	77.2	58.8	57.2
L	PEcore	90.1	87.7	74.9	25.6	39.7	0.650	48.2	42.1	19.2
L	SigLIP 2	90.1	89.2	75.0	21.4	43.6	0.484	66.3	47.8	41.9
L	DINOv2	89.7	79.1	64.7	55.7	48.8	0.394	73.4	59.9	57.0
L	DINOv3	90.2	88.1	74.8	63.1	54.9	0.352	79.9	62.3	61.2
SO400m	SigLIP 2	90.3	90.4	76.2	23.0	44.0	0.402	64.8	48.8	38.7
H+	DINOv3	90.3	90.0	78.6	64.5	54.8	0.352	79.3	63.3	56.3

这凸显了DINOv3系列在不同密集视觉问题上的多功能性。重要的是，我们的模型在ObjectNet和ImageNet-1k等全局识别基准上取得了具有竞争力的结果。这表明增强的密集任务性能并未以牺牲全局任务准确性为代价。这种平衡证实了DINOv3模型提供了稳健而全面的解决方案，在密集和全局视觉任务上均表现出色，且无需妥协。

另一方面，我们也想验证我们蒸馏出的最大模型是否捕捉了教师模型的所有信息。为此，我们将最大的ViT-H+与70亿参数的教师模型进行了比较。如图16b所示，最大的学生模型取得了与规模大8倍的ViT-7B模型相当的性能。




图 17: DINOv3 ViT 系列模型在多分辨率下的特征稳定性。从上至下: ViT-S、S+、B、L、H+。我们对同一图像进行多分辨率推理, 随后对在 1792×1024 图像 (112×64 图像块) 上计算得到的特征进行主成分分析。接着将所有分辨率下的特征投影到第 5-7 主成分上, 并将其映射至 RGB 空间进行可视化。虽然模型在所有分辨率下均能运行, 但我们观察到特征在发生漂移前能在较宽的分分辨率范围内保持一致性: 例如 ViT-S+ 的特征在 896×512 至 3584×2048 的输入范围内保持稳定, 而 ViT-L 仅在最大分辨率 7168×4096 上开始出现轻微漂移。ViT-H+ 在整个测试分辨率范围内均保持稳定。

这一结果不仅验证了我们蒸馏过程的有效性, 还表明在高质量教师的指导下, 较小模型也能学会提供相当水平的性能。这一发现强化了我们的信念: *training very large models benefits the broader community*。大型模型的能力可以成功蒸馏到更高效的小型模型中, 且几乎不会损失质量。

7.2 面向资源受限环境的高效ConvNeXts

在本节中, 我们评估了从7B教师模型蒸馏得到的ConvNeXt (CNX) 模型的质量。ConvNeXt模型在FLOPs方面非常高效, 非常适合在针对卷积计算优化的设备上部署。此外, Transformer模型通常不易进行量化 (Bondarenko等人, 2021年), 而卷积网络的量化则是一个经过充分研究的课题。我们蒸馏了T、S、B和L尺寸的CNX架构 (见图16a), 并将它们与原始的ConvNeXt模型 (Liu等人, 2022年) 进行比较。这些基线模型在ImageNet-1k上实现了高性能, 因为它们使用ImageNet-22k标签以监督方式进行训练, 因此代表了强大的竞争对手。在本实验中, 我们提供了输入分辨率为256和512的全局任务结果、分辨率为512的ADE20k结果, 以及分辨率为640的NYU结果。

表15: 我们蒸馏的DINOv3 ConvNeXt模型评估。我们将模型与在ImageNet-22k上监督训练的开箱即用ConvNeXt模型（Liu等人，2022）进行比较。针对全局任务，我们提供了输入分辨率256和512下的结果，因为我们发现监督模型在512分辨率下性能显著下降。

Size	Model	Global Tasks						Dense Tasks	
		IN-ReAL		IN-R		Obj.		ADE20k	NYU↓
		256	512	256	512	256	512		
T	Sup.	87.3	83.0	45.0	33.0	44.5	27.1	24.8	0.666
T	DINOv3	86.6	87.7	73.7	74.1	52.6	58.7	42.7	0.448
S	Sup.	88.9	86.8	52.8	39.1	50.8	40.0	22.6	0.630
S	DINOv3	87.9	88.7	73.7	74.1	52.6	58.7	44.8	0.432
B	Sup.	89.3	87.8	57.3	46.2	53.6	46.5	26.5	0.596
B	DINOv3	88.5	89.2	77.2	78.2	56.2	61.3	46.3	0.420
L	Sup.	89.6	88.1	58.4	46.6	55.0	47.7	33.3	0.567
L	DINOv3	88.9	89.4	81.3	82.4	59.3	65.2	47.8	0.403

结果（表15）我们发现，在分布内图像分类任务中，256分辨率下我们的模型略逊于监督模型（CNX-T的IN-ReAL指标为*e.g.*−0.7）。然而在512分辨率下趋势发生逆转：监督版ConvNeXt性能显著下降，而我们的模型能随输入分辨率提升持续扩展。在分布外分类任务（IN-R、ObjectNet）中，两种模型系列在所有规模上均存在显著差距——这印证了DINOv3 CNX模型的强健性。此外，DINOv3模型在密集预测任务上展现出巨大提升：CNX-T版本实现+17.9 mIoU增幅（42.7对比24.8），CNX-L版本获得+14.5 mIoU提升（47.8对比33.3）。高性能与计算效率的结合，使蒸馏后的ConvNeXt模型在资源受限的实际应用场景中尤为前景广阔。值得注意的是，将ViT-7B模型蒸馏至更小的ConvNeXt架构尤其令人振奋——它弥合了两种根本不同的架构范式：ViT-7B基于带CLS标记的Transformer模块，而ConvNeXt依赖无CLS标记的卷积操作，这使得知识迁移过程非比寻常。这一成果彰显了我们蒸馏流程的多功能性与卓越效能。

7.3 基于DINOv3的dino.txt零样本推理

如第5.3节所述，我们按照dino.txt Jose等人（2025）的方法训练了一个文本编码器，将蒸馏后的DINOv3 ViT-L模型的CLS标记和输出图像块与文本对齐。我们在标准基准测试中从全局和图像块两个层面评估对齐质量。我们采用CLIP协议（Radford等人，2021）在ImageNet-1k、ImageNet-Adversarial、ImageNet-Rendition和ObjectNet基准上报告零样本分类准确率。对于图文检索任务，我们在COCO2017数据集（Tsung-Yi等人，2017）上评估，并报告图像到文本（I → T）和文本到图像（T → I）任务的Recall@1指标。为探究图像块级对齐质量，我们在开放词汇分割任务上使用ADE20k和Cityscapes常用基准评估模型，并报告mIoU指标。

结果（表16）我们在同等规模类别中将文本对齐的DINOv3 ViT-L与竞品进行比较。相较于Jose等人（2025）将DINOv2与文本对齐的工作，DINOv3在所有基准测试中均带来显著性能提升。在全局对齐任务上，我们较原始CLIP（Radford等人，2021）及EVA-02-CLIP（Sun等人，2023）等强基线具有优势，但略逊于SigLIP2（Tschannen等人，2025）和感知编码器（Bolya等人，2025）。在密集对齐任务中，得益于DINOv3纯净的特征图谱，我们的文本对齐模型在ADE20K和Cityscapes两个挑战性基准上展现出卓越性能。

表16: 将我们的文本对齐DINOv3 ViT-L与最先进模型进行比较。我们的模型在保持全局对齐任务竞争力的同时, 实现了优异的密集对齐性能。所有对比模型均为ViT-L尺寸, 并在相同的576序列长度上运行。

Method	Classification				Retrieval		Segmentation	
	IN1k	A	R	Obj.	I $\rightarrow$ T	T $\rightarrow$ I	ADE20k	Cityscapes
CLIP	76.6	77.5	89.0	72.3	57.9	37.1	6.0	11.5
EVA-02-CLIP	80.4	82.9	93.2	78.5	64.1	47.9	10.9	14.1
dino.txt	81.6	83.2	88.8	74.5	62.5	45.0	19.2	27.4
SigLIP 2	83.1	84.3	95.7	84.4	71.4	55.3	10.8	16.3
PE	83.5	89.0	95.2	84.7	75.9	57.1	17.6	21.4
DINOv3 dino.txt	82.3	85.4	93.0	80.5	63.7	45.6	24.7	36.9

8 DINOv3 在地理空间数据上的应用

我们的自监督学习方案是通用的, 可应用于任何图像领域。在本节中, 我们通过为卫星图像构建DINOv3 7B模型来展示这种普适性。卫星图像具有与DINOv3最初开发时所基于的网络图像截然不同的特征 (*e.g.* 物体纹理、传感器噪声和焦点视角)。

8.1 预训练数据与基准测试

我们的卫星DINOv3 7B模型在SAT-493M数据集上进行了预训练, 该数据集包含4.93亿张 512×512 图像, 这些图像是从0.6米分辨率的Maxar RGB正射校正影像中随机采样的。我们使用了与网络版DINOv3 7B模型完全相同的超参数集, 仅针对卫星图像调整了RGB均值和标准差归一化参数, 并调整了训练时长。与网络模型类似, 我们卫星模型的训练流程包括: 使用全局裁剪 (256×256) 进行10万次初始预训练迭代, 随后进行1万次采用Gram正则化的迭代, 最后以512分辨率进行8千步高分辨率微调。同样与网络模型类似, 我们将7B卫星模型蒸馏为更易管理的ViT-Large模型, 以便在低资源环境下使用。

我们在多个地球观测任务上评估了DINOv3卫星和网络模型。针对全球冠层高度制图任务, 我们使用了附录D.13中描述的Satlidar数据集, 该数据集包含一百万张 512×512 像素的图像, 并配有激光雷达地面实况数据, 按8:1:1的比例划分为训练集、验证集和测试集。这些划分包含了Tolan等人 (2024) 使用的Neon和圣保罗数据集。对于国家尺度的冠层高度制图, 我们在Open-Canopy数据集 (Fogel等人, 2025) 上进行评估, 该数据集结合了SPOT 6-7卫星影像和覆盖法国87,000平方公里的航空激光雷达数据。由于该数据集中的图像包含4个通道 (含额外的红外通道), 我们通过取补丁嵌入模块权重中三个通道的平均值, 并将其作为第四通道添加到权重中, 以此调整我们的骨干网络。我们在 512×512 像素的图像裁剪块上训练了DPT解码器, 这些图像被调整为1667像素以匹配Maxar的地面采样分辨率。

语义地理空间任务通过GEO-Bench (Lacoste等人, 2023) 进行评估, 该基准包含六项分类和六项分割任务, 涵盖不同空间分辨率和光学波段。GEO-Bench任务类型多样, 包括屋顶光伏系统检测、局地气候区分类、森林砍伐驱动因素测量以及树冠检测。针对高分辨率语义任务, 我们采用土地覆盖分割数据集LoveDA (Wang等人, 2022a)、对象分割数据集ISAID (Zamir等人, 2019) 以及水平检测数据集DIOR (Li等人, 2020)。

8.2 冠层高度估算

从卫星图像估算冠层高度是一项具有挑战性的度量任务, 需要在坡度、观测几何、太阳角度、大气散射和量化伪影的随机变化中准确恢复连续空间结构。该任务对于全球碳监测以及森林和农业管理至关重要 (Harris等人, 2021年)。遵循Tolan等人 (2024年) 的研究——首个利用自监督学习 (SSL) 的工作——

表17：不同骨干网络在高分辨率冠层高度预测中的评估。所有模型均使用DPT解码器进行训练。结果展示分为两种情况：一是解码器在SatLidar数据集上训练，并在同分布样本（SatLidar验证集）及外分布测试集（SatLidar测试集、Neon和圣保罗数据集）上评估；二是解码器在Open-Canopy数据集上训练和评估。我们列出了平均绝对误差（MAE）及Tolan等人（2024）提出的区块 R^2 指标。为完整起见，我们还额外评估了Tolan等人（2024）在Neon数据集上训练的原版解码器（标记为*）。

Method	Arch.	SatLidar								Open Canopy
		SatLidar Val		SatLidar Test		Neon Test		São Paulo		
		MAE↓	R^2 ↑	MAE↓	R^2 ↑	MAE↓	R^2 ↑	MAE↓	R^2 ↑	MAE↓
Tolan et al. (2024)*	ViT-L	2.8	0.86	4.0	0.61	2.7	0.73	5.4	0.42	—
Tolan et al. (2024)	ViT-L	2.4	0.90	3.4	0.81	2.9	0.69	5.4	0.48	2.42
DINOv3 Web	ViT-7B	2.4	0.90	3.6	0.74	2.7	0.75	5.9	0.34	2.17
DINOv3 Sat	ViT-L	2.2	0.91	3.2	0.81	2.4	0.81	5.8	0.42	2.07
DINOv3 Sat	ViT-7B	2.2	0.92	3.2	0.82	2.6	0.74	5.5	0.51	2.02

针对这一任务，我们基于卫星图像训练了骨干网络，在SatLidar1M训练集上对冻结的DINOv3模型顶层添加DPT头进行训练，随后在SatLidar1M验证集的独立同分布样本以及包括SatLidar1M测试集、Neon和Sao Paulo在内的分布外测试集上进行评估。我们还在Open-Canopy数据集上进行了补充训练与评估。

结果（表17）我们比较了不同的SSL骨干网络，其中“DINOv3 Sat”表示在SAT-493M数据集上训练的模型，“DINOv3 Web”表示在LVD-1689M上训练的模型（参见第3.1节）。可以看出，DINOv3卫星模型在大多数基准测试中取得了最先进的性能。我们的7B卫星模型在SatLidar1M验证集、SatLidar1M测试集和Open-Canopy上创造了新的最优结果，将MAE分别从2.4降至2.2、从3.4降至3.2、从2.42降至2.02。这些结果表明DINOv3的训练方案具有通用性，能够直接有效地应用于其他领域。有趣的是，我们蒸馏后的ViT-L卫星模型与其7B版本表现相当，在SatLidar1M和Open-Canopy上取得相近结果，而在Neon测试集上表现更优，达到了2.4的最低MAE，优于7B模型的2.6和Tolan等人（2024）的2.9。我们的DINOv3 7B网络模型在基准测试中表现良好，在SatLidar1M验证集、Neon和Open-Canopy上超越了Tolan等人（2024）的结果，但仍落后于卫星模型。这凸显了针对冠层高度估计这类物理基础任务时，领域特异性预训练的优势——传感器特定先验和辐射一致性在此类任务中至关重要。

8.3 与地球观测领域先进技术的比较

我们在表18和表19中比较了不同方法在地球观测任务上的性能。冻结的DINOv3卫星和网络模型在15项分类、分割和水平目标检测任务中的12项上取得了新的最先进结果。我们的Geo-Bench结果超越了包括Prithvi-v2（Szwarcman等人，2024）和DOFA（Xiong等人，2024）在内的先前模型，这些模型在Sentinel-2和Landsat任务中使用了6+波段，并进行了任务特定的微调（表18）。尽管使用仅RGB输入的冻结骨干网络，DINOv3卫星模型在三个非饱和分类任务以及六项分割任务中的五项上优于先前方法。有趣的是，DINOv3 7B网络模型在这些基准测试中表现出极强的竞争力。它在许多GEO-Bench任务以及大规模、高分辨率遥感分割和检测基准测试中取得了相当或更优的性能。如表18和表19所示，冻结的DINOv3网络模型在Geo-Bench任务以及LoweDA和DIOR数据集上的分割与检测任务中均确立了新的领先结果。

这些发现对地理空间基础模型的设计具有更广泛的意义。近期研究多侧重于启发式技术，如多时相聚合、多传感器融合或融入卫星专用元数据（Brown等人，2025；Feng等人，2025）。我们的结果表明，对于依赖精确物体边界（分割任务）的应用，通用自监督学习方法的表现可与卫星专用方法相媲美甚至更优。

表18: 我们的DINOv3模型与强基线DOFA (Xiong等人, 2024)、Prithvi-v2 (Szwarcman等人, 2024) 以及Tolan等人 (2024) 在Geo-Bench任务中的对比。尽管Prithvi-v2和DOFA利用了所有可用的光学波段, 我们的模型仅使用RGB输入就实现了显著更优的性能。

(a) 分类任务。

Method	Arch.	FT	Bands	m-BEnet	m-brick-kiln	m-eurosat	m-forestnet	m-pv4ger	m-so2sat	Mean
DOFA	ViT-L	✗	all	68.7	98.4	96.6	55.7	98.2	61.6	79.9
Best of Prithvi-v2	ViT-L/H	✗	all	71.2	98.8	96.4	54.1	98.1	59.1	79.6
Tolan et al. (2024)	ViT-L	✗	RGB	66.0	97.1	95.2	56.3	94.3	58.1	77.8
DINOv3 Sat	ViT-L	✗	RGB	73.0	96.5	94.1	60.6	96.0	57.4	79.6
DINOv3 Sat	7B	✗	RGB	74.0	97.2	94.8	62.3	96.1	62.1	81.1
DINOv3 Web	7B	✗	RGB	74.6	97.7	97.0	57.9	98.3	63.8	81.6

(b) 分割任务。方法架构。FT 波段 m-cashew* m-chesapeake m-NeonTree m-nz-cattle m-pv4ger-seg m-SA-crop 平均值 DOFA ViT-L ✗ 全部 81.2 61.6 58.5 77.4 95.1 35.7 68.3 Prithvi-v2 ViT-L/H ✗ 最佳 全部 90.2 69.4 59.1 81.0 95.3 41.9 72.8 Tolan 等人 (2024) ViT-L ✗ RGB 92.8 73.7 58.1 83.1 94.7 35.1 72.9 DINOv3 Sat ViT-L ✗ RGB 94.2 75.6 61.8 83.7 95.2 36.8 74.5 DINOv3 Sat 7B ✗ RGB 94.1 76.6 62.6 83.4 95.5 37.6 75.0 DINOv3 Web 7B ✗ RGB 96.0 76.5 66.4 83.7 95.9 36.8 75.9

* Conversion to 6 classes following Szwarcman et al. (2024).




图18: 由单一DINOv3模型实现的遥感多样化应用示意图。DINOv3特征的PCA分析显示出比DINOv2更精细的细节。分割图仅使用GEO-Bench切萨皮克标签计算得出。冠层高度模型解码器在Open-Canopy数据集上使用4个通道 (RGB + 红外) 进行训练, 而推理过程仅使用RGB通道执行。

mentation或物体检测)。这支持了新兴的证据发现, 即领域无关的预训练即使在专业的下游领域也能提供强大的泛化能力 (Lahrichi等人, 2025)。

总的来说, 我们的研究表明, 领域特定的预训练具有任务依赖性优势。DINOv3卫星模型在深度估计等度量任务中表现出色, 这得益于其利用的卫星特定先验知识。相比之下, DINOv3网络模型通过多样化的通用表征, 在语义地理空间任务上取得了最先进的结果。两种模型的互补优势说明了DINOv3自监督学习范式具有广泛的适用性和有效性。

9 环境影响

为了估算我们预训练的碳排放量, 我们遵循了先前自然语言处理 (Strubell 等人, 2019; Touvron 等人, 2023) 和自监督学习 (Oquab 等人, 2024) 工作中使用的方法。我们将所有外生变量 {v*} 的值固定, 即电力使用效率 (PUE) 和电网的碳强度因子, 设定为与 Touvron 等人 (2023) 使用的相同值 {v*}。我们假设 PUE 为 1.1, 碳强度因子采用美国平均值 0.385 千克 CO{v*}eq/千瓦时。对于 GPU 的功耗, 我们采用

表19: 我们将DINOv3与最先进模型Privthi-v2 (Szwarcman等人, 2024)、BillionFM (Cha等人, 2024) 和SkySense V2 (Zhang等人, 2025) 在高分辨率语义地理空间任务上的性能进行比较。我们在分割数据集LoveDA (1024×) 和iSAID (896×) 上报告mIoU, 在检测数据集DIOR (800×) 上报告mAP。

Method	Arch.	FT	LoveDA	iSAID	DIOR
Prev. SotA			BillionFM, ViT-G 54.4	SkySense V2, Swin-G* 71.9	SkySense V2, Swin-G* 79.5
Decoder Arch.			UPerNet	UPerNet	Faster-RCNN
Privthi-v2	ViT-H		52.2	62.8	—
DINOv3 Sat	ViT-L		54.4	62.9	72.7
DINOv3 Sat	ViT-7B		55.3	64.8	76.6
DINOv3 Web	ViT-7B		56.2	71.4	80.5

* Uses modified DINOv2 SSL with supervised pretraining alignment on OpenStreetMap, reporting +0.8 mIoU on iSAID.




图19: DINOv3 7B卫星模型与Tolan等人 (2024) 在Open Canopy数据集上的定性对比。两个模型的解码器均在448×448输入图像上训练。可以看出, DINOv3生成了更精确的地图, 例如对田间树木高度的准确描绘。

其热设计功耗: A100 GPU为400W, H100 GPU为700W。我们在表20中报告了ViT-7B预训练的计算细节。作为参考, 我们提供了DINOv2和MetaCLIP的类似数据。另一点比较是, 训练一个DINOv3模型所需的能量 (4.7兆瓦时) 大致相当于一辆普通电动汽车行驶24万公里所需的能量。

整个项目的碳足迹 为了计算整个项目的碳足迹, 我们粗略估计总共需要50万GPU小时。使用上述相同的电网参数, 我们估计总碳足迹约为2600吨二氧化碳当量。作为对比, 一架波音777客机在巴黎和纽约之间的往返航班大约对应560吨二氧化碳当量。假设每天有12个这样的航班, 我们项目的环境影响相当于这两个城市之间一天所有航班排放量的一半。该估算仅考虑了为GPU供电的电力消耗, 忽略了其他排放源, 例如冷却、制造和处置过程。

表20: 模型训练的碳足迹。我们报告了完整模型预训练的潜在碳排放量, 计算时使用的PUE为1.1, 碳强度系数为0.385kg CO₂eq/KWh。

Model	Arch.	GPU type	Power (W)	Steps	GPU hours	PUE	Total power (MWh)	Emission (tCO ₂ eq)
MetaCLIP	ViT-G	A100-40GB	400W	390k	368,640	1.1	160	62
DINOv2	ViT-g	A100-40GB	400W	625k	22,016	1.1	9.7	3.7
DINOv3	ViT-7B	H100-SXM5	700W	1,000k	61,440	1.1	47	18

10 结论

DINOv3代表了自监督学习领域的一项重大进展，展现了革新各领域视觉表征学习方式的潜力。通过精细的数据准备、设计和优化来扩展数据集与模型规模，DINOv3彰显了自监督学习摆脱人工标注依赖的强大能力。Gram锚定方法的引入有效缓解了密集特征图在长期训练中的退化问题，确保了稳健可靠的性能表现。

结合实施事后优化策略，如高分辨率后训练和蒸馏技术，我们在不对图像编码器进行微调的情况下，在广泛的视觉任务中实现了最先进的性能。DINOv3视觉模型套件不仅设立了新的基准，还为各种资源限制、部署场景和应用用例提供了通用解决方案。DINOv3取得的进展证明了自监督学习在推动计算机视觉及其他领域技术前沿发展方面的巨大潜力。

参考文献 Yongqi An, Xu Zhao, Tao Yu, Ming Tang, and Jinqiao Wang. 大语言模型中的系统性离群值。 *ICLR*, 2025. Yuki Markus Asano, Christian Rupprecht, and Andrea Vedaldi. 通过同步聚类与表征学习进行自标注。 In *ICLR*, 2020. Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. 基于图像的联合嵌入预测架构的自监督学习。 *arXiv preprint arXiv:2301.08243*, 2023. Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Matthew Muckley, Ammar Rizvi, Claire Roberts, Koustuv Sinha, Artem Zhohus, et al. V-JEPA 2: 自监督视频模型实现理解、预测与规划。 *arXiv preprint arXiv:2506.09985*, 2025. Alexei Baevski, Wei-Ning Hsu, Qiantong Xu, Arun Babu, Jiatao Gu, and Michael Auli. Data2vec: 语音、视觉与语言自监督学习的通用框架。 *arXiv preprint arXiv:2202.03555*, 2022. Alexei Baevski, Arun Babu, Wei-Ning Hsu, and Michael Auli. 面向视觉、语音和语言的上下文文化目标表征高效自监督学习。 In *ICML*, 2023. Mohamed El Banani, Amit Raj, Kevis-Kokitsi Maninis, Abhishek Kar, Yuanzhen Li, Michael Rubinstein, Deqing Sun, Leonidas Guibas, Justin Johnson, and Varun Jampani. 探究视觉基础模型的三维感知能力。 In *CVPR*, 2024. Hangbo Bao, Li Dong, and Furu Wei. BEiT: 图像变换器的BERT预训练。 *arXiv preprint arXiv:2106.08254*, 2021. Andrei Barbu, David Mayo, Julian Alverio, William Luo, Christopher Wang, Dan Gutfreund, Josh Tenenbaum, and Boris Katz. ObjectNet: 一个用于推动物体识别模型极限的大规模偏置控制数据集。 In *NeurIPS*, 2019. Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: 自监督学习的方差-不变性-协方差正则化。 *arXiv preprint arXiv:2105.04906*, 2021. Adrien Bardes, Jean Ponce, and Yann LeCun. VICRegL: 局部视觉特征的自监督学习。 *arXiv preprint arXiv:2210.01571*, 2022. Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mahmoud Assran, and Nicolas Ballas. 重访特征预测以从视频中学习视觉表征。 *arXiv preprint arXiv:2404.08471*, 2024. Lucas Beyer, Olivier J. Hénaff, Alexander Kolesnikov, Xiaohua Zhai, and Aaron van den Oord. 我们完成ImageNet了吗? *CoRR*, abs/2006.07159, 2020. Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschannen, Emanuele Bugliarello, Thomas Unterthiner, Daniel Keysers, Skanda Koppula, Fangyu Liu, Adam Grycner, Alexey Gritsenko, Neil Houlsby, Manoj Kumar, Keran Rong, Julian Eisenschlos, Rishabh Kabra, Matthias Bauer, Matko Bošnjak, Xi Chen, Matthias Minderer, Paul Voigtlaender, Ioana Bica, Ivana Balazevic, Joan Puigcerver, Pinelopi Papalampidi, Olivier Henaff, Xi Xiong, Radu Soricut, Jeremiah Harmsen, and Xiaohua Zhai. PaliGemma: 一个适用于迁移的通用3B VLM。 *arXiv preprint arXiv:2407.07726*, 2024. Navaneeth Bodla, Bharat Singh, Rama Chellappa, and Larry S. Davis. Soft-NMS——用一行代码改进目标检测。 In *ICCV*, Oct 2017. Piotr Bojanowski and Armand Joulin. 通过预测噪声进行无监督学习。 In *ICML*, 2017.

Piotr Bojanowski、Edouard Grave、Armand Joulin 和 Tomas Mikolov。利用子词信息丰富词向量。*Transactions of the association for computational linguistics*, 第5卷: 135–146, 2017年。Daniel Bolya、Pao-Yao Huang、Peize Sun、Jang Hyun Cho、Andrea Madotto、Chen Wei、Tengyu Ma、Jiale Zhi、Jathushan Rajasegaran、Hanoona Rasheed 等。感知编码器：最佳视觉嵌入不在网络输出端。*arXiv preprint arXiv:2504.13181*, 2025年。Yelysei Bondarenko、Markus Nagel 和 Tijmen Blankevoort。理解并克服高效Transformer量化的挑战。收录于 *Conference on Empirical Methods in Natural Language Processing*, 2021年。Lukas Bossard、Matthieu Guillaumin 和 Luc Van Gool。Food-101——利用随机森林挖掘判别性成分。收录于 *ECCV*, 2014年。Christopher F. Brown、Michal R. Kazmierski、Valerie J. Pasquarella、William J. Rucklidge、Masha Samsikova、Chenhui Zhang、Evan Shelhamer、Estefania Lahera、Olivia Wiles、Simon Ilyushchenko、Noel Gorelick、Lihui Lydia Zhang、Sophia Alj、Emily Schechter、Sean Askay、Oliver Guinan、Rebecca Moore、Alexis Boukouvalas 和 Pushmeet Kohli。Alphaearth基础模型：一种基于稀疏标签数据实现精确高效全球制图的嵌入场模型，2025年。Holger Caesar、Jasper Uijlings 和 Vittorio Ferrari。Coco-stuff：上下文中的物体与材质类别。收录于 *CVPR*, 2018年。Zhi Cai、Songtao Liu、Guodong Wang、Zheng Ge、Xiangyu Zhang 和 Di Huang。Align-detr：通过对齐损失增强端到端目标检测，2024年。Nicolas Carion、Francisco Massa、Gabriel Synnaeve、Nicolas Usunier、Alexander Kirillov 和 Sergey Zagoruyko。基于Transformer的端到端目标检测。收录于 *European conference on computer vision*, 第213–229页。Springer, 2020年。Mathilde Caron、Piotr Bojanowski、Armand Joulin 和 Matthijs Douze。基于深度聚类的视觉特征无监督学习。收录于 *ECCV*, 2018年。Mathilde Caron、Piotr Bojanowski、Julien Mairal 和 Armand Joulin。非精选数据上的图像特征无监督预训练。收录于 *ICCV*, 2019年。Mathilde Caron、Ishan Misra、Julien Mairal、Priya Goyal、Piotr Bojanowski 和 Armand Joulin。通过对比聚类分配实现视觉特征的无监督学习。收录于 *NeurIPS*, 2020年。Mathilde Caron、Hugo Touvron、Ishan Misra、Hervé Jégou、Julien Mairal、Piotr Bojanowski 和 Armand Joulin。自监督视觉Transformer的新兴特性。收录于 *ICCV*, 2021年。Keumgang Cha、Junghoon Seo 和 Taekyung Lee。面向遥感图像的十亿级基础模型。*IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 第1–17页, 2024年。ISSN 2151-1535。doi: 10.1109/jstars.2024.3401772。François Charton 和 Julia Kempe。重复样本涌现的特性，2024年。Richard J Chen、Tong Ding、Ming Y Lu、Drew FK Williamson、Guillaume Jaume、Bowen Chen、Andrew Zhang、Daniel Shao、Andrew H Song、Muhammad Shaban 等。迈向通用计算病理学基础模型。*Nature Medicine*, 2024年。Ting Chen、Simon Kornblith、Mohammad Norouzi 和 Geoffrey Hinton。视觉表征对比学习的简单框架。*preprint arXiv:2002.05709*, 2020a。Ting Chen、Simon Kornblith、Kevin Swersky、Mohammad Norouzi 和 Geoffrey E Hinton。大型自监督模型是强大的半监督学习器。*Advances in neural information processing systems*, 第33卷: 22243–22255, 2020b。

陈曦、王晓、Soravit Changpinyo、AJ Piergiovanni、Piotr Padlewski、Daniel Salz、Sebastian Goodman、Adam Grycner、Basil Mustafa、Lucas Beyer、Alexander Kolesnikov、Joan Puigcerver、丁楠、Keran Rong、Hassan Akbari、Gaurav Mishra、薛林亭、Ashish V Thapliyal、James Bradbury、郭伟成、Mojtaba Seyedhosseini、贾超、Burcu Karagol Ayan、Carlos Riquelme Ruiz、Andreas Peter Steiner、Anelia Angelova、翟晓华、Neil Houlsby、Radu Soricut。PaLI：一种联合扩展的多语言语言-图像模型。发表于*ICLR*，2023年。陈鑫雷、何恺明。探索简单的孪生表示学习。*preprint arXiv:2011.10566*，2020年。陈鑫雷、谢赛宁、何恺明。自监督视觉Transformer训练实证研究。*arXiv preprint arXiv:2104.02057*，2021年。陈胤杰、严子鹏、周冲、戴波Andrew F Luo。具有自蒸馏寄存器的视觉Transformer。*arXiv preprint arXiv:2505.21501*，2025年。陈喆、段宇辰、王文海、何俊俊、卢同、戴继峰、乔宇。用于密集预测的视觉Transformer适配器。*arXiv preprint arXiv:2205.08534*，2022年。程博文Ishan Misra、Alexander G. Schwing、Alexander Kirillov、Rohit Girdhar。用于通用图像分割的掩码注意力掩码Transformer。发表于*CVPR*，2022年。Mehdi Cherti、Romain Beaumont、Ross Wightman、Mitchell Wortsman、Gabriel Ilharco、Cade Gordon、Christoph Schuhmann、Ludwig Schmidt、Jenia Jitsev。对比式语言-图像学习的可复现缩放定律。发表于*CVPR*，2023年。Minsu Cho、Suha Kwak、Cordelia Schmid、Jean Ponce。野外无监督物体发现与定位：基于部件匹配与自底向上区域提议。发表于*CVPR*，2015年。M. Cimpoi、S. Maji、I. Kokkinos、S. Mohamed、A. Vedaldi。描述野外纹理。发表于*CVPR*，2014年。丛晔臻Samar Khanna、陈林萌、Patrick Liu、Erik Rozi、何宇彤、Marshall Burke、David Lobell、Stefano Ermon。Satmae：面向时序与多光谱卫星图像的Transformer预训练。*NeurIPS*，2022年。Marius Cordts、Mohamed Omran、Sebastian Ramos、Timo Rehfeld、Markus Enzweiler、Rodrigo Benenson、Uwe Franke、Stefan Roth、Bernt Schiele。用于语义城市场景理解的城市景观观数据集。发表于*Proceedings of the IEEE conference on computer vision and pattern recognition*，第3213–3223页，2016年。Angela Dai、Angel X. Chang、Manolis Savva、Maciej Halber、Thomas Funkhouser、Matthias Nießner。ScanNet：室内场景的丰富标注3D重建。发表于*CVPR*，2017年。Timothée Darcet、Maxime Oquab、Julien Mairal、Piotr Bojanowski。视觉Transformer需要寄存器。发表于*ICLR*，2024年。Timothée Darcet、Federico Baldassarre、Maxime Oquab、Julien Mairal、Piotr Bojanowski。聚类与预测潜在图像块以改进掩码图像建模。*TMLR*，2025年。Mostafa Dehghani、Josip Djolonga、Basil Mustafa、Piotr Padlewski、Jonathan Heek、Justin Gilmer、Andreas Steiner、Mathilde Caron、Robert Geirhos、Ibrahim M. Alabdulmohsin、Rodolphe Jenatton、Lucas Beyer、Michael Tschannen、Anurag Arnab、王晓、Carlos Riquelme、Matthias Minderer、Joan Puigcerver、Utku Evci、Manoj Kumar、Sjoerd van Steenkiste、Gamaleldin F. Elsayed、Aravindh Mahendran、Fisher Yu、Avital Oliver、Fantine Huot、Jasmijn Bastings、Mark Collier、Alexey A. Gritsenko、Vighnesh Birodkar、Christina Nader Vasconcelos、Yi Tay、Thomas Mensink、Alexander Kolesnikov、Filip Pavetić、Dustin Tran、Thomas Kipf、Mario Luvcić、翟晓华、Daniel Keysers、Jeremiah Harmsen、Neil Houlsby。将视觉Transformer扩展至220亿参数。发表于*ICML*，2023年。

贾登、魏东、Richard Socher、李立佳、李凯和李飞飞。ImageNet：一个大规模分层图像数据库。于 *CVPR*, 2009年。

Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。BERT：用于语言理解的深度双向 Transformer 预训练。 *preprint arXiv:1810.04805*, 2018年。

巴里·M狄龙、格雷戈尔·卡西茨卡、汉斯·奥利施拉格、蒂尔曼·普莱恩、彼得·索伦森与洛伦茨·福格尔。对称性、安全性与自监督学习。 *SciPost Physics*, 12(6):188, 2022。

丁恒辉、刘畅、何书婷、蒋旭东、Philip HS Torr、白松。Mose：复杂场景中视频对象分割的新数据集。发表于 *CVPR*, 2023年。

Carl Doersch、Abhinav Gupta 和 Alexei A Efros。通过上下文预测进行无监督视觉表示学习。发表于 *ICCV*, 2015年。

Alexey Dosovitskiy、Philipp Fischer、Jost Tobias Springenberg、Martin Riedmiller 和 Thomas Brox。基于范例卷积神经网络的判别式无监督特征学习。 *IEEE TPAMI*, 2016年。

Alexey Dosovitskiy、Lucas Beyer、Alexander Kolesnikov、Dirk Weissenborn、翟晓华、Thomas Unterthiner、Mostafa Dehghani、Matthias Minderer、Georg Heigold、Sylvain Gelly 等。一幅图像价值 16x16 个词汇：大规模图像识别中的 Transformer 模型。 *preprint arXiv:2010.11929*, 2020。

Danny Driess、Fei Xia、Mehdi S. M. Sajjadi、Corey Lynch、Aakanksha Chowdhery、Brian Ichter、Ayzaan Wahid、Jonathan Tompson、Quan Vuong、Tianhe Yu、Wenlong Huang、Yevgen Chebotar、Pierre Sermanet、Daniel Duckworth、Sergey Levine、Vincent Vanhoucke、Karol Hausman、Marc Toussaint、Klaus Greff、Andy Zeng、Igor Mordatch 和 Pete Florence。PaLM-E：一个具身多模态语言模型。发表于 *ICML*, 2023年。

Ainaz Eftekhari、Alexander Sax、Jitendra Malik 和 Amir Zamir。Omnidata：一个从 3D 扫描构建多任务中层视觉数据集的可扩展流程。发表于 *ICCV*, 2021 年。

Alaaeldin El-Nouby、Gautier Izacard、Hugo Touvron、Ivan Laptev、Hervé Jegou 和 Edouard Grave。大规模数据集对于自监督预训练是否必要？ *arXiv preprint arXiv:2112.10740*, 2021。

Mark Everingham、Luc Van Gool、Christopher KI Williams、John Winn 和 Andrew Zisserman。PASCAL 视觉对象分类挑战赛 2007 (VOC2007) 结果, 2007。

Mark Everingham、Luc Van Gool、Christopher K. I. Williams、John Winn 和 Andrew Zisserman。PASCAL 视觉对象分类挑战赛 2012 (VOC2012) 结果, 2012。

Mark Everingham、SM Ali Eslami、Luc Van Gool、Christopher KI Williams、John Winn 和 Andrew Zisserman。PASCAL 视觉对象分类挑战：回顾。 *IJCV*, 111(1):98–136, 2015。

David Fan, Shengbang Tong, Jiachen Zhu, Koustuv Sinha, Zhuang Liu, Xinlei Chen, Michael Rabbat, Nicolas Ballas, Yann LeCun, Amir Bar, 等。扩展无语言视觉表示学习。 *arXiv preprint arXiv:2504.01017*, 2025。

Alex Fang、Albin Madappally Jose、Amit Jain、Ludwig Schmidt、Alexander T Toshev 与 Vaishaal Shankar。数据过滤网络。收录于 *ICLR*, 2024a。

方玉欣、王文、谢斌辉、孙全、吴乐德、王兴刚、黄铁军、王新龙、曹越。EVA：探索大规模掩码视觉表征学习的极限。发表于 *CVPR*, 2023年。

方玉欣、孙全、王兴刚、黄铁军、王新龙、曹跃。Eva-02：新世纪视觉表征。 *Image and Vision Computing*, 149: 105171, 2024b。

李飞飞、Rob Fergus 与 Pietro Perona。从少量训练样本中学习生成式视觉模型：一种在 101 个物体类别上测试的增量贝叶斯方法。载于 *2004 conference on computer vision and pattern recognition workshop*, 第 178–178 页。IEEE, 2004 年。

郑鹏峰、克莱门特·阿茨伯格、萨迪克·贾弗尔、约瓦娜·克内泽维奇、西尔娅·索尔穆宁、罗宾·杨、玛德琳·C·利赛厄斯、马库斯·伊米策、大卫·A·库姆斯、阿尼尔·马达瓦佩迪、安德鲁·布莱克与斯里尼瓦桑·凯沙夫。TES SERA: 用于地球表征与分析的地表光谱时间嵌入, 2025。

恩里科·菲尼、穆斯塔法·舒科尔、修俊·李、菲利普·杜夫特、米哈尔·克莱因、大卫·哈尔迪曼、赛·艾塔拉朱、维克多·吉尔赫姆·图里西·达科斯塔、路易·贝图恩、甘哲、亚历山大·T托舍夫、马尔钦·艾希纳、莫因·纳比、杨寅飞、约书亚·M·萨斯金德和阿拉埃尔·丁·埃尔努比。大型视觉编码器的多模态自回归预训练。
arXiv preprint arXiv:2411.14402, 2024年。

Fajwel Fogel, Yohann Perron, Nikola Besic, Laurent Saint-André, Agnès Pellissier-Tanon, Martin Schwartz, Thomas Boudras, Ibrahim Fayad, Alexandre d'Aspremont, Loic Landrieu 等人。Open-canopy: 迈向超高分辨率森林监测。收录于 *CVPR*, 2025年。

Stephanie Fu, Mark Hamilton, Laura E Brandt, Axel Feldmann, Zhoutong Zhang 与 William T Freeman。Feat up: 一种与模型无关的任意分辨率特征提取框架。发表于 *ICLR*, 2024年。

Leon A Gatys, Alexander S Ecker 和 Matthias Bethge。使用卷积神经网络进行图像风格迁移。载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 第 2414–2423 页, 2016 年。

Andreas Geiger, Philip Lenz, Christoph Stiller 和 Raquel Urtasun。视觉与机器人学的交汇: KITTI 数据集。*The International Journal of Robotics Research*, 32(11):1231–1237, 2013。

Spyros Gidaris, Praveer Singh 与 Nikos Komodakis。通过预测图像旋转进行无监督表示学习, 2018。

Priya Goyal, Dhruv Mahajan, Abhinav Gupta 和 Ishan Misra。自监督视觉表征学习的规模化与基准测试。载于 *ICCV*, 2019年。

Priya Goyal, Mathilde Caron, Benjamin Lefaudeaux, Min Xu, Pengchao Wang, Vivek Pai, Mannat Singh, Vitaliy Liptchinsky, Ishan Misra, Armand Joulin 等。在真实场景中视觉特征的自监督预训练。*preprint arXiv:2103.01988*, 2021。

Priya Goyal, Quentin Duval, Isaac Seessel, Mathilde Caron, Mannat Singh, Ishan Misra, Levent Sagun, Arm and Joulin 和 Piotr Bojanowski。视觉模型在未经筛选的无监督图像上进行预训练时更具鲁棒性和公平性。*arXiv preprint arXiv:2202.08360*, 2022a。

Priya Goyal, Adriana Romero Soriano, Caner Hazirbas, Levent Sagun 与 Nicolas Usunier。视觉特征提取器系统评估中的公平性指标。收录于 *2022 ACM Conference on Fairness, Accountability, and Transparency*, 第 70–88 页, 2022b 年。

Raghav Goyal, Samira Ebrahimi Kahou, Vincent Michalski, Joanna Materzynska, Susanne Westphal, Heuna Kim, Valentin Haenel, Ingo Fruend, Peter Yianilos, Moritz Mueller-Freitag 等人。"Something Something" 视频数据库: 用于学习和评估视觉常识。收录于 *ICCV*, 2017年。

Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko。引导你的潜在层: 一种自监督学习的新方法。发表于 *NeurIPS*, 2020年。

Raia Hadsell, Sumit Chopra 和 Yann LeCun。通过学习不变映射进行降维。发表于 *CVPR*, 2006年。

Mark Hamilton, Zhoutong Zhang, Bharath Hariharan, Noah Snavely 与 William T Freeman。通过蒸馏特征对应实现无监督语义分割。发表于 *ICLR*, 2022年。

南希·哈里斯、大卫·吉布斯、A. 巴奇尼、理查德·伯德西、赛茨·德布鲁因、玛丽·法里纳、洛拉·法托因博、马修·汉森、马丁·赫罗尔德、理查德·霍顿、彼得·波塔波夫、丹妮拉·雷克纳·苏亚雷斯、罗莎·玛丽亚·罗曼·库埃斯塔、萨桑·萨奇、克里斯蒂·斯莱、斯韦特兰娜·图鲁巴诺娃和亚历山德拉·秋卡维娜。二十一世纪森林碳通量的全球地图。*Nature Climate Change*, 11: 1–7, 2021年3月。doi: 10.1038/s41558-020-00976-6。

何恺明、张翔宇、任少卿、孙剑。深度残差学习用于图像识别。于 *CVPR*, 2016。

何恺明、范浩强、吴育昕、谢赛宁和Ross Girshick。无监督视觉表征学习的动量对比方法。发表于 *CVPR*, 2020年。

何恺明、陈鑫磊、谢赛宁、李阳昊、Piotr Dollár 与 Ross Girshick。掩码自编码器是可扩展的视觉学习器。*arXiv preprint arXiv:2111.06377*, 2021年。

Greg Heinrich、Mike Ranzinger、Hongxu Yin、Yao Lu、Jan Kautz、Andrew Tao、Bryan Catanzaro 和 Pavlo Molchanov。RADIOv2.5: 改进的聚合视觉基础模型基线。*arXiv preprint arXiv:2412.07679*, 2025年。

Olivier J Hénaff, Aravind Srinivas, Jeffrey De Fauw, Ali Razavi, Carl Doersch, SM Eslami 和 Aaron van den Oord。基于对比预测编码的数据高效图像识别。*preprint arXiv:1905.09272*, 2019。

Olivier J Hénaff、Skanda Koppula、Jean-Baptiste Alayrac、Aaron van den Oord、Oriol Vinyals 和 João Carreira。基于对比检测的高效视觉预训练。*arXiv preprint arXiv:2103.10957*, 2021年。

Olivier J Hénaff、Skanda Koppula、Evan Shelhamer、Daniel Zoran、Andrew Jaegle、Andrew Zisserman、João Carreira 和 Relja Arandjelović。物体发现与表征网络。发表于 *ECCV*, 2022年。

丹·亨德里克斯和托马斯·迪特里希。基准测试神经网络对常见损坏和扰动的鲁棒性。*ICLR*, 2019年。

Dan Hendrycks、Steven Basart、Norman Mu、Saurav Kadavath、Frank Wang、Evan Dorundo、Rahul Desai、Tyler Zhu、Samyak Parajuli、Mike Guo 等。稳健性的多面性：对分布外泛化的批判性分析。载于 *ICCV*, 第8340–8349页, 2021a。

Dan Hendrycks、Kevin Zhao、Steven Basart、Jacob Steinhardt 和 Dawn Song。自然对抗样本。收录于 *CVPR*, 第15262–15271页, 2021b。

Byeongho Heo、Song Park、Dongyoon Han 和 Sangdoo Yun。视觉 Transformer 的旋转位置嵌入。收录于 *European Conference on Computer Vision*, 第289–305页。Springer, 2024。

Allan Jabri、Andrew Owens 和 Alexei A. Efros。时空对应关系作为对比随机游走。收录于 *NeurIPS*, 2020年。

Varun Jampani、Kevis-Kokitsi Maninis、Andreas Engelhardt、Arjun Karpur、Karen Truong、Kyle Sargent、Stefan Popov、Andre Araujo、Ricardo Martin-Brualla、Kaushal Patel、Daniel Vlasic、Vittorio Ferrari、Ameesh Makadia、Ce Liu、Yuanzhen Li 和 Howard Zhou。Navi: 具有高质量三维形状与姿态标注的类别无关图像集。收录于 *NeurIPS*, 2023年。

Rasmus Jensen、Anders Dahl、George Vogiatzis、Engin Tola 与 Henrik Aanaes。大规模多视角立体视觉评估。收录于 *CVPR*, 2014年6月。

Chao Jia, Yinfei Yang, Ye Xia, Yi-Ting Chen, Zarana Parekh, Hieu Pham, Quoc Le, Yun-Hsuan Sung, Zhen Li, and Tom Duerig。利用噪声文本监督扩展视觉与视觉-语言表征学习。收录于 *International Conference on Machine Learning*, 第4904–4916页。PMLR, 2021。

Nick Jiang、Amil Dravid、Alexei Efros 和 Yossi Gandelsman。视觉变换器无需训练寄存器。*arXiv preprint arXiv:2506.08010*, 2025年。

Justin Johnson、Alexandre Alahi 和李飞飞。用于实时风格迁移和超分辨率的感知损失。载于 *ECCV*, 2016年。

Cijo Jose, Théo Moutakanni, Dahyun Kang, Federico Baldassarre, Timothée Darcet, Hu Xu, Daniel Li, Marc Szafraniec, Michaël Ramamonjisoa, Maxime Oquab 等人。DINOv2 遇见文本：一个统一的图像级与像素级视觉-语言对齐框架。发表于 *CVPR*, 2025。

Armand Joulin、Laurens Van Der Maaten、Allan Jabri 和 Nicolas Vasilache。从大规模弱监督数据中学习视觉特征。于 *ECCV*, 2016年。Will Kay、Joao Carreira、Karen Simonyan、Brian Zhang、Chloe Hillier、Sudheendra Vijayanarasimhan、Fabio Viola、Tim Green、Trevor Back、Paul Natsev 等。Kinetics 人体动作视频数据集。 *arXiv preprint arXiv:1705.06950*, 2017年。Bingxin Ke、Kevin Qu、Tianfu Wang、Nando Metzger、Shengyu Huang、Bo Li、Anton Obukhov 和 Konrad Schindler。Marigold: 面向图像分析的基于扩散的图像生成器的经济适配。 *arXiv preprint arXiv:2505.09358*, 2025年。Moo Jin Kim、Karl Pertsch、Siddharth Karamcheti、Ted Xiao、Ashwin Balakrishna、Suraj Nair、Rafael Rafailov、Ethan Foster、Grace Lam、Pannag Sanketi、Quan Vuong、Thomas Kollar、Benjamin Burchfiel、Russ Tedrake、Dorsa Sadigh、Sergey Levine、Percy Liang 和 Chelsea Finn。OpenVLA: 一个开源的视觉-语言-动作模型。 *arXiv preprint arXiv:2406.09246*, 2024年。Vladislav Kim、Nikolaos Adaloglou、Marc Osterland、Flavio M Morelli、Marah Halawa、Tim König、David Gnutt 和 Paula A Marin Zapata。自监督通过解锁强大的图像表征推进形态学分析。 *Scientific Reports*, 15(1):4876, 2025年。Alexander Kirillov、Eric Mintun、Nikhila Ravi、Hanzi Mao、Chloe Rolland、Laura Gustafson、Tete Xiao、Spencer Whitehead、Alexander C Berg、Wan-Yen Lo 等。Segment Anything。于 *CVPR*, 2023年。Alexander Kolesnikov、Lucas Beyer、Xiaohua Zhai、Joan Puigcerver、Jessica Yung、Sylvain Gelly 和 Neil Houlsby。大迁移 (BiT): 通用视觉表征学习。于 *ECCV*, 第491–507页。Springer, 2020年。Jonathan Krause、Michael Stark、Jia Deng 和 Li Fei-Fei。用于细粒度分类的3D物体表征。于 *4th International IEEE Workshop on 3D Representation and Recognition (3dRR-13)*, 澳大利亚悉尼, 2013年。Alex Krizhevsky、Geoffrey Hinton 等。从微小图像中学习多层特征。2009年。Alex Krizhevsky、Ilya Sutskever 和 Geoffrey E Hinton。使用深度卷积神经网络进行 ImageNet 分类。 *NeurIPS*, 2012年。Alexandre Lacoste、Nils Lehmann、Pau Rodriguez、Evan Sherwin、Hannah Kerner、Björn Lütjens、Jeremy Irvin、David Dao、Hamed Alemohammad、Alexandre Drouin 等。Geo-bench: 迈向地球监测的基础模型。 *NeurIPS*, 2023年。Saad Lahrichi、Zion Sheng、Shufan Xia、Kyle Bradbury 和 Jordan Malof。卫星图像上的自监督预训练比 ImageNet 更好吗? 一项基于 Sentinel-2 的系统性研究, 2025年。Yann LeCun。通往自主机器智能之路。 *openreview*, 2022年。Ang Li、Allan Jabri、Armand Joulin 和 Laurens Van Der Maaten。从网络数据中学习视觉 N-gram。于 *ICCV*, 2017年。Ke Li、Gang Wan、Gong Cheng、Liqu Meng 和 Junwei Han。光学遥感图像中的目标检测: 综述与新基准。 *ISPRS journal of photogrammetry and remote sensing*, 159: 296–307, 2020年。Bin Lin、Bin Zhu、Yang Ye、Munan Ning、Peng Jin 和 Li Yuan。Video-LLaVA: 通过投影前对齐学习统一的视觉表征。于 *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 2023a。Tsung-Yi Lin、Michael Maire、Serge Belongie、James Hays、Pietro Perona、Deva Ramanan、Piotr Dollár 和 Lawrence Zitnick。Microsoft COCO: 上下文中的常见物体。于 *ECCV*, 2014年。

Tsung-Yi Lin、Priya Goyal、Ross Girshick、何恺明和Piotr Dollár。用于密集目标检测的Focal Loss，2018。

林宇桐、袁彧辉、张政、李晨、郑南宁、胡翰。DETR无需多尺度或局部设计。于ICCV，2023b。

Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. 视觉指令调优。在 *NeurIPS*, 2023。

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: 一种稳健优化的BERT预训练方法。 *arXiv preprint arXiv:1907.11692*, 2019。

庄刘、韩子毛、吴超元、克里斯托夫·费希滕霍夫、特雷弗·达雷尔和谢赛宁。面向2020年代的卷积网络。发表于 *CVPR*, 2022年。

Ilya Loshchilov 与 Frank Hutter。解耦权重衰减正则化。发表于 *ICLR*, 2017年。

Dhruv Mahajan、Ross Girshick、Vignesh Ramanathan、何恺明、Manohar Paluri、李轶轩、Ashwin Bharambe 和 Laurens van der Maaten。探索弱监督预训练的极限。发表于 *ECCV*, 2018年。

S. Maji, J. Kannala, E. Rahtu, M. Blaschko 和 A. Vedaldi。飞机的细粒度视觉分类。 *arXiv preprint arXiv:1306.5151*, 2013。

肖峰毛、岳峰陈、姚朱、达陈、杭苏、荣张、和薛辉。COCO-O: 自然分布偏移下的目标检测器基准。于 *ICCV*, 2023。

Tomáš Mikolov, Martin Karafiát, Lukáš Burget, Jan Šernocký 和 Sanjeev Khudanpur。基于循环神经网络的语言模型。收录于 *Interspeech*, 2010年。

Tomas Mikolov、Ilya Sutskever、Kai Chen、Greg S Corrado 和 Jeff Dean。词与短语的分布式表示及其组合性。发表于 *NeurIPS*, 2013年。

Juhong Min、Jongmin Lee、Jean Ponce 和 Minsu Cho。SPair-71k: 用于语义对应的大规模基准，2019。

Ishan Misra 与 Laurens van der Maaten。基于借口不变表征的自监督学习。发表于 *CVPR*, 2020年。

Maria-Elena Nilsback 与 Andrew Zisserman。基于大量类别的自动化花卉分类。载于 *Indian Conference on Computer Vision, Graphics and Image Processing*, 2008年12月。

Mehdi Noroozi 和 Paolo Favaro。通过解决拼图游戏进行视觉表征的无监督学习。载于 Bastian Leibe、Jiri Matas、Nicu Sebe 和 Max Welling 编辑的 *Computer Vision – ECCV 2016*, 第 69–84 页, Cham, 2016 年。Springer International Publishing。ISBN 978-3-319-46466-4。

马克西姆·奥卡布、莱昂·博图、伊万·拉普捷夫和约瑟夫·西维奇。使用卷积神经网络学习和迁移中层图像表示。载于 *CVPR*, 2014年。

马克西姆·奥卡布、蒂莫西·达塞、泰奥·穆塔坎尼、胡伊·沃、马克·萨弗兰涅克、瓦西尔·哈利多夫、皮埃尔·费尔南德斯、丹尼尔·哈齐扎、弗朗西斯科·马萨、阿拉埃尔丁·埃尔努比等人。DINOv2: 无需监督学习鲁棒的视觉特征。 *TMLR*, 2024年。

瓦伦蒂诺斯·帕里扎、穆罕默德雷扎·萨利希、格特扬·J·伯格豪茨、弗朗切斯科·洛卡特洛和结城麻野。远近之间: 补丁排序增强视觉基础模型的场景理解能力。收录于 *ICLR*, 2025年。

利亚姆·帕克、弗朗索瓦·拉努斯、西亚瓦什·戈尔卡、莱奥波尔多·萨拉、迈尔斯·克兰默、阿尔贝托·比耶蒂、迈克尔·艾肯伯格、热罗·克拉维齐克、迈克尔·麦凯布、鲁迪·莫雷尔等。AstroCLIP: 一个用于星系的跨模态基础模型。 *Monthly Notices of the Royal Astronomical Society*, 531(4):4990–5011, 2024。

Omkar M. Parkhi, Andrea Vedaldi, Andrew Zisserman 和 C. V. Jawahar。猫与狗。载于 *IEEE Conference on Computer Vision and Pattern Recognition*, 2012年。

Deepak Pathak, Philipp Krähenbühl, Jeff Donahue, Trevor Darrell 和 Alexei Efros。上下文编码器：通过修复进行特征学习。发表于 *CVPR*, 2016年。

Federico Perazzi, Jordi Pont-Tuset, Brian McWilliams, Luc Van Gool, Markus Gross 和 Alexander Sorkine-Hornung。视频对象分割的基准数据集与评估方法。载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 第724–732页, 2016年。

费尔南多·佩雷斯-加西亚、哈希塔·夏尔马、萨姆·邦德-泰勒、肯扎·布齐德、瓦伦蒂娜·萨尔瓦泰利、马克西米利安·伊尔泽、什鲁蒂·班努尔、丹尼尔·C·卡斯特罗、安东·施瓦伊霍费尔、马修·P·隆格伦等。探索超越文本监督的可扩展医学图像编码器。 *Nature Machine Intelligence*, 第1–12页, 2025年。

Pedro O Pinheiro, Amjad Almahairi, Ryan Y Benmaleck, Florian Golemo 与 Aaron Courville。密集视觉表征的无监督学习。发表于 *NeurIPS*, 2020年。

Jordi Pont-Tuset, Federico Perazzi, Sergi Caelles, Pablo Arbeláez, Alex Sorkine-Hornung 和 Luc Van Gool。2017年DAVIS视频对象分割挑战赛。 *preprint arXiv:1704.00675*, 2017年。

Filip Radenovi, Ahmet Iscen, Giorgos Tolias, Yannis Avrithis 和 Ondrej Chum。重访牛津与巴黎：大规模图像检索基准测试。于 *CVPR*, 2018。

亚历克·拉德福德、金钟旭、克里斯·哈拉西、阿迪蒂亚·拉梅什、加布里埃尔·戈、桑迪尼·阿加瓦尔、吉里什·萨斯特里、阿曼达·阿斯科尔、帕梅拉·米什金、杰克·克拉克等。从自然语言监督中学习可迁移的视觉模型。发表于 *International Conference on Machine Learning*, 第8748–8763页。PMLR, 2021年。

Jathushan Rajasegaran, Ilija Radosavovic, Rahul Ravishankar, Yossi Gandelsman, Christoph Feichtenhofer 和 Jitendra Malik。关于视频自回归预训练的实证研究。 *arXiv preprint arXiv:2501.05453*, 2025年。

René Ranftl, Katrin Lasinger, David Hafner, Konrad Schindler 和 Vladlen Koltun。面向稳健的单目深度估计：混合数据集以实现零样本跨数据集迁移。 *IEEE TPAMI*, 44(3):1623–1637, 2020。

René Ranftl, Alexey Bochkovskiy 和 Vladlen Koltun。用于密集预测的视觉变换器。收录于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 第12179–12188页, 2021年。

Mike Ranzinger, Greg Heinrich, Jan Kautz 与 Pavlo Molchanov。AM-Radio：将各领域聚合为一的凝聚视觉基础模型。发表于 *CVPR*, 2024年。

Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollar, 以及 Christoph Feichtenhofer。SAM 2：对图像和视频进行任意分割。收录于 *ICLR*, 2025年。

Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt 和 Vaishal Shankar。ImageNet 分类器能否推广到 ImageNet? 载于 *ICML*, 第5389–5400页, 2019年。

Jeremy Reizenstein, Roman Shapovalov, Philipp Henzler, Luca Sbordone, Patrick Labatut 与 David Novotny。三维常见物体：真实场景三维类别重建的大规模学习与评估。发表于 *ICCV*, 2021年。

Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun。Faster r-cnn: 基于区域提议网络实现实时目标检测。In *Advances in Neural Information Processing Systems (NeurIPS)*, 2015。

Hamid Rezatofighi, Nathan Tsoi, JunYoung Gwak, Amir Sadeghian, Ian Reid 和 Silvio Savarese。广义交并比：一种用于边界框回归的度量与损失函数, 2019。

迈克·罗伯茨、贾森·拉马普拉姆、阿努拉格·兰詹、阿图利特·库马尔、米格尔·安赫尔·包蒂斯塔、内森·帕克赞、拉斯·韦伯和约书亚·M·萨斯金德。Hypersim：用于整体室内场景理解的照片级真实感合成数据集。收录于 *ICCV*, 2021年。

Olga Russakovsky、Jia Deng、Hao Su、Jonathan Krause、Sanjeev Satheesh、Sean Ma、Zhiheng Huang、Andre j Karpathy、Aditya Khosla、Michael Bernstein、Alexander C Berg 和李飞飞。ImageNet 大规模视觉识别挑战赛。 *IJCV*, 2015年。

Bryan Russell, William Freeman, Alexei Efros, Josef Sivic 和 Andrew Zisserman。利用多重分割在图像集合中发现物体及其范围。载于 *CVPR*, 2006年。

Alexandre Sablayrolles, Matthijs Douze, Cordelia Schmid 和 Hervé Jégou。用于相似性搜索的扩散向量。 *arXiv preprint arXiv:1806.03198*, 2018。

Mohammadreza Salehi、Efstratios Gavves、Cees G. M. Snoek 与 Yuki M. Asano。时间自有其言：密集图像表征的自监督时间调优。发表于 *《ICCV》*, 2023年。

托马斯·舍普斯、约翰内斯·L·舍恩伯格、西尔瓦诺·加利安尼、托尔斯滕·萨特勒、康拉德·辛德勒、马克·波尔费斯与安德烈亚斯·盖格。《包含高分辨率图像与多相机视频的多视图立体视觉基准测试》。载于 *CVPR*, 2017年。

克里斯托夫·舒曼、理查德·文丘、罗曼·博蒙特、罗伯特·卡兹马尔奇克、克莱顿·穆利斯、阿鲁什·卡塔、西奥·库姆斯、詹妮亚·吉采夫与荒井小松崎。Laion-400m：包含4亿个经CLIP筛选的图文对开源数据集。 *arXiv preprint arXiv:2111.02114*, 2021年。

马克西米利安·塞策、马克斯·霍恩、安德里·扎达扬丘克、多米尼克·齐特洛、肖天骏、卡尔·约翰·西蒙·加布里埃尔、何彤、张正、伯恩哈德·舍尔科普夫、托马斯·布罗克斯与弗朗切斯科·洛卡特洛。弥合现实世界以物体为中心学习的差距。发表于 *ICLR*, 2023年。

帅少、李泽明、张天元、彭超、余刚、张翔宇、李静和孙剑。Objects365：一个用于目标检测的大规模高质量数据集。于 *Proceedings of the IEEE/CVF International conference on computer vision*, 第8430–8439页, 2019年。

Nathan Silberman、Derek Hoiem、Pushmeet Kohli 和 Rob Fergus。基于 RGBD 图像的室内分割与支撑关系推断。收录于 *European conference on computer vision*, 第746–760页。Springer 出版社, 2012年。

Oriane Siméoni, Gilles Puy, Huy V Vo, Simon Roburin, Spyros Gidaris, Andrei Bursuc, Patrick Pérez, Renaud Marlet 和 Jean Ponce。使用自监督Transformer和无标签进行目标定位。 *arXiv preprint arXiv:2109.14279*, 2021。

Oriane Siméoni, Éloi Zablocki, Spyros Gidaris, Gilles Puy 和 Patrick Pérez。自监督视觉Transformer时代的无监督目标定位：综述。 *IJCV*, 133(2):781–808, 2025。

Walter Simoncini、Andrei Bursuc、Spyridon Gidaris 与 Yuki Asano。《无需训练，全面获益：自监督梯度提升深度冻结表示》。 *NeurIPS*, 2024年。

Karen Simonyan 与 Andrew Zisserman。用于大规模图像识别的极深卷积网络。发表于 *ICLR*, 2015年。

Mannat Singh、Laura Gustafson、Aaron Adcock、Vinicius de Freitas Reis、Bugra Gedik、Raj Prateek Kosaraju、Dhruv Mahajan、Ross Girshick、Piotr Dollár 和 Laurens van der Maaten。重新审视视觉感知模型的弱监督训练。发表于 *CVPR*, 2022年。

Khurram Soomro、Amir Roshan Zamir 和 Mubarak Shah。Ucf101：一个包含 101 类野外视频中人类动作的数据集。 *arXiv preprint arXiv:1212.0402*, 2012。

Emma Strubell、Ananya Ganesh 和 Andrew McCallum。自然语言处理中深度学习的能耗与政策考量。 *arXiv preprint arXiv:1906.02243*, 2019年。

苏剑林, 艾哈迈德·穆尔塔扎, 卢宇, 潘盛丰, 薄文, 刘云峰。Roformer: 采用旋转位置嵌入增强的Transformer模型。 *Neurocomputing*, 568: 127063, 2024年。

陈孙、阿比纳夫·施里瓦斯塔瓦、索拉布·辛格和阿比纳夫·古普塔。重探深度学习时代数据的不合理有效性。载于 *ICCV*, 2017年。

全孙、方宇欣、吴乐德、王新龙、曹越。Eva-CLIP: 大规模CLIP训练的改进技术。 *arXiv preprint arXiv:2303.15389*, 2023。

全孙、王金生、余启颖、崔宇峰、张帆、张晓松和王新龙。EVA-CLIP-18B: 将CLIP扩展至180亿参数。 *arXiv preprint arXiv:2402.04252*, 2024年。

Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke 和 Andrew Rabinovich。通过卷积网络走向更深层次。发表于 *CVPR*, 2015年。

Daniela Szwarzman, Sujit Roy, Paolo Fraccaro, Thorsteinn Elí Gíslason, Benedikt Blumenstiel, Rinki Ghosal, Pedro Henrique de Oliveira, Joao Lucas de Sousa Almeida, Rocco Sedona, Yanghui Kang 等。Prithvi-eo-2.0: 一个用于地球观测应用的多功能多时相基础模型。 *arXiv preprint arXiv:2412.02732*, 2024年。

Mingxing Tan与Quoc V Le。EfficientNet: 重新思考卷积神经网络的模型缩放。 *preprint arXiv:1905.11946*, 2019年。

Bart Thomee, David A. Shamma, Gerald Friedland, Benjamin Elizalde, Karl Ni, Douglas Poland, Damian Borth 与李飞飞。Yfcc100m: 多媒体研究中的新数据。 *Communications of the ACM*, 59 (2): 64–73, 2016。

Yonglong Tian, Olivier J Henaff 与 Aäron van den Oord。分而治之: 从未经筛选数据中进行自监督学习。发表于 *ICCV*, 2021年。

Jamie Tolan, Hung-I Yang, Benjamin Nosarzewski, Guillaume Couairon, Huy V Vo, John Brandt, Justine Spore, Sayantan Majumdar, Daniel Haziza, Janaki Vamaraju 等人。利用基于航空激光雷达训练的自监督视觉变换器与卷积解码器, 从RGB图像生成超高分辨率冠层高度图。 *Remote Sensing of Environment*, 300:113888, 2024。

Hugo Touvron, Andrea Vedaldi, Matthijs Douze 和 Hervé Jégou。修正训练与测试分辨率差异。收录于 *NeurIPS*, 2019年。

Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles 和 Hervé Jégou。通过注意力机制训练数据高效的图像变换器与蒸馏。 *preprint arXiv:2012.12877*, 2020年。

Hugo Touvron, Matthieu Cord 与 Hervé Jégou。DeiT iii: 视觉Transformer的复仇。 *arXiv preprint arXiv:2204.07118*, 2022年。

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave 和 Guillaume Lample。Llama: 开放且高效的基础语言模型。 *arXiv preprint arXiv:2302.13971*, 2023年。

Michael Tschannen, Alexey Gritsenko, Xiao Wang, Muhammad Ferjad Naeem, Ibrahim Alabdulmohsin, Nikhil Parthasarathy, Talfan Evans, Lucas Beyer, Ye Xia, Basil Mustafa, Olivier Hénaff, Jeremiah Harmsen, Andreas Steiner 和 Xiaohua Zhai。SigLIP 2: 具有改进语义理解、定位和密集特征的多语言视觉-语言编码器。 *arXiv preprint arXiv:2502.14786*, 2025年。

Tsung-Yi, Genevieve Patterson, Matteo R. Ronchi, Yin Cui, Michael Maire, Serge Belongie, Lubomir Bourdev, Ross Girshick, James Hays Georgia, Pietro Perona, Deva Ramanan, Larry Zitnick 和 Piotr Dollár。COCO 2017: 上下文中的常见物体, 2017。

Tinne Tuytelaars、Christoph Lampert、Matthew Blaschko 和 Wray Buntine。无监督物体发现：一项比较。*IJCV*, 2010年。

Grant Van Horn、Oisin Mac Aodha、Yang Song、Yin Cui、Chen Sun、Alex Shepard、Hartwig Adam、Pietro Perona 和 Serge Belongie。iNaturalist 物种分类与检测数据集。发表于 *CVPR*, 2018年。

Grant Van Horn、Elijah Cole、Sara Beery、Kimberly Wilber、Serge Belongie 和 Oisin Mac Aodha。自然世界图像集合的表征学习基准测试。收录于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 第 12884–12893 页, 2021 年。

伊戈尔·瓦西列维奇、尼克·科尔金、张善怡、罗若天、王浩晨、戴子凡、安德烈亚·F·丹尼尔、穆罕默德雷扎·莫斯塔贾比、史蒂文·巴萨特、马修·R·沃尔特和格雷戈里·沙赫纳罗维奇。DIODE：一个密集的室内外深度数据集。*ArXiv 1908.00463*, 2019年。

阿希什·瓦斯瓦尼、诺姆·沙泽尔、尼基·帕尔马、雅各布·乌兹科雷特、利昂·琼斯、艾丹·N·戈麦斯、卢卡什·凯泽和伊利亚·波洛苏欣。注意力就是你所需要的一切。发表于 *NeurIPS*, 2017年。

Shashanka Venkataramanan, Valentinos Pariza, Mohammadreza Salehi, Lukas Knobel, Spyros Gidaris, Elias Ramzi, Andrei Bursuc, 以及 Yuki M. Asano。Franca：用于可扩展视觉表示学习的嵌套套娃聚类。*arXiv preprint arXiv:2507.14137*, 2025。

Huy V. Vo, Francis Bach, Minsu Cho, Kai Han, Yann LeCun, Patrick Pérez 和 Jean Ponce。作为优化的无监督图像匹配与物体发现。发表于 *CVPR*, 2019。

Huy V. Vo、Patrick Pérez 与 Jean Ponce。面向大规模图像集合的无监督多目标发现。收录于 *Proceedings of the European Conference on Computer Vision (ECCV)*, 2020年。

Huy V. Vo、Elena Sizikova、Cordelia Schmid、Patrick Pérez 和 Jean Ponce。大规模无监督物体发现。发表于 *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 2021年。

Huy V. Vo, Vasil Khalidov, Timothée Darcet, Théo Moutakanni, Nikita Smetanin, Marc Szafraniec, Hugo Touvron, Camille Couprie, Maxime Oquab, Armand Joulin, Hervé Jégou, Patrick Labatut, 以及 Piotr Bojanowski。面向自监督学习的自动数据管理：一种基于聚类的方法。*TMLR*, 2024。

尤金·沃龙佐夫、阿利坎·博兹库尔特、亚当·卡森、乔治·沙伊科夫斯基、米哈尔·泽莱霍夫斯基、克里斯滕·塞弗森、埃里克·齐默尔曼、詹姆斯·霍尔、尼尔·特南霍尔茨、尼科洛·富西等。面向临床级计算病理学与罕见癌症检测的基础模型。*Nature medicine*, 30(10):2924–2935, 2024。

王迪、张静、徐敏强、刘林、王东升、高而重、韩承曦、郭浩南、杜博、陶大程和张良培。MTP：通过多任务预训练推进遥感基础模型, 2024a。

Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny。Vggt：视觉几何基础Transformer。于 *CVPR*, 2025。

王俊珏、郑卓、马爱龙、卢晓燕、钟燕飞。Loveda：一个用于领域自适应语义分割的遥感土地覆盖数据集, 2022a。

彭王、施杰王、俊阳林、帅白、晓欢周、景仁周、兴刚王和昌周。One-PEACE：探索面向无限模态的统一通用表示模型。*arXiv preprint arXiv:2305.11172*, 2023a。

温海旺、戴继峰、陈喆、黄振航、李志祺、朱熙洲、胡晓伟、卢同、卢乐炜、李弘生等。Internimage：利用可变形卷积探索大规模视觉基础模型。发表于 *《CVPR》*, 2023b。

王慧文、鲍航波、李东、Johan Bjorck、彭志良、刘强、Kriti Aggarwal、Owais Khan Mohammed、Saksham Singhal、Subhojit Som 等。图像作为外语：面向所有视觉与视觉-语言任务的Beit预训练模型。*arXiv preprint arXiv:2208.10442*, 2022b。

Xiaolong Wang, Allan Jabri, and Alexei A Efros. Learning correspondence from the cycle-consistency of time. In {v*}, 2019.

杨涛王, 席沈, Shell Xu Hu, 袁元, James L Crowley, 以及 Dominique Vaufreydaz。使用归一化割进行无监督物体发现的自监督变换器。载于 *CVPR*, 第14543–14553页, 2022c。

杨涛王、席申、袁源、杜宇明、李毛毛、Shell Xu Hu、James L Crowley 和 Dominique Vaufreydaz。TokenCut: 利用自监督 Transformer 和归一化割在图像和视频中分割对象。 *IEEE TPAMI*, 45(12):15790–15801, 2023c。

王毅, 李昆昌, 李新浩, 于佳硕, 何一楠, 王晨婷, 陈果, 裴宝琪, 郑荣坤, 徐继兰, 王尊等. Internvideo2: 扩展视频基础模型以实现多模态视频理解. 收录于 *ECCV*, 2024b.

弗雷德里克·瓦伯格、索伦·豪贝格、曼努埃尔·洛佩斯-安特克拉、保·加加洛、邝宇斌和哈维尔·西韦拉。Mapillary 街景序列: 一个用于终身地点识别的数据集。发表于 *Computer Vision and Pattern Recognition (CVPR)*, 2020年。

P. Welinder、S. Branson、T. Mita、C. Wah、F. Schroff、S. Belongie 与 P. Perona。《Caltech-UCSD Birds 200》。技术报告 CNS-TR-2010-001, 加州理工学院, 2010年。

辛文, 赵秉宸, 郑安林, 张向宇, 齐晓娟。基于语义分组的自监督视觉表示学习。发表于 *NeurIPS*, 2022年。

吴志荣, 熊元君, Stella X. Yu, 林达华。通过非参数实例判别进行无监督特征学习。发表于 *CVPR*, 2018年。

Monika Wysoczańska, Oriane Siméoni, Michaël Ramamonjisoa, Andrei Bursuc, Tomasz Trzcíński 与 Patrick Pérez。Clip-dinoiser: 向 CLIP 传授一些 DINO 技巧。 *ECCV*, 2024。

J. Xiao, J. Hays, K. A. Ehinger, A. Oliva, and A. Torralba. SUN数据库: 从修道院到动物园的大规模场景识别。发表于 *2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 第3485–3492页, 2010年6月。doi: 10.1109/CVPR.2010.5539970。

Tete Xiao, Yingcheng Liu, Bolei Zhou, Yuning Jiang, and Jian Sun. 面向场景理解的统一感知解析, 2018。

谢佳浩, 詹晓航, 刘子纬, Ong Yew Soon, 以及罗诚昌。从场景图像中进行无监督物体级表征学习。发表于 *NeurIPS*, 2021年。

谢赛宁、Ross Girshick、Piotr Dollár、屠卓文、何恺明。深度神经网络的聚合残差变换。载于 *CVPR*, 2017年。

熊志通、王毅、张法鸿、Adam J Stewart、Joëlle Hanna、Damian Borth、Ioannis Papoutsis、Bertrand Le Saux、Gustau Camps-Valls 与 朱晓香。面向跨模态地球观测的神经可塑性启发基础模型。 *arXiv preprint arXiv:2403.15356*, 2024。

胡旭、谢赛宁、谭晓青、黄柏尧、Russell Howes、Vasu Sharma、李尚文、Gargi Ghosh、Luke Zettlemoyer 与 Christoph Feichtenhofer。《CLIP 数据揭秘》。收录于 *ICLR*, 2024。

徐宁、杨林杰、范宇晨、杨建超、岳鼎成、梁宇晨、Brian Price、Scott Cohen和Thomas Huang。YouTube-V OS: 序列到序列的视频对象分割。收录于 *Proceedings of the European conference on computer vision (ECCV)*, 第585–601页, 2018年。

I Zeki Yalniz, Hervé Jégou, Kan Chen, Manohar Paluri 和 Dhruv Mahajan。用于图像分类的十亿级半监督学习。 *arXiv preprint arXiv:1905.00546*, 2019年。

李贺阳, 康秉艺, 黄子龙, 徐晓刚, 冯佳时, 赵恒爽。深度万物: 释放大规模无标签数据的力量。于 *CVPR*, 2024a。

李贺阳, 康秉毅, 黄子龙, 赵振, 徐晓刚, 冯家时, 赵恒爽. Depth Anything v2. *NeurIPS*, 2024b。

姚景峰、杨斌和王兴刚。重建与生成：驯服潜在扩散模型中的优化困境。于 *CVPR*, 2025。

Burak Yildiz, Seyran Khademi, Ronald Maria Siebes 和 Jan van Gemert. Amstertime: 一个面向严重领域偏移的视觉位置识别基准数据集。 *arXiv preprint arXiv:2203.16291*, 2022年。

魏寅、张建明、Oliver Wang、Simon Niklaus、龙迈、Simon Chen和沈春华。学习从单张图像恢复三维场景形状。发表于 *CVPR*, 2021年。

Yongseon Yoo, Seonggyu Kim, and Jong-Min Lee. Sagagan: 基于StarGAN v2使用Gram矩阵归因的风格应用。收录于 *BMVC*, 2024。

Nikolaos-Antonios Ypsilantis, Noa Garcia, Guangxing Han, Sarah Ibrahimi, Nanne Van Noord, and Giorgos Tolias. The met dataset: Instance-level recognition for artworks. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*, 2021.

Jiahui Yu、Zirui Wang、Vijay Vasudevan、Legg Yeung、Mojtaba Seyedhosseini与Yonghui Wu。CoCa: 对比式描述生成模型作为图文基础模型。 *arXiv preprint arXiv:2205.01917*, 2022年。

Sihyun Yu, Sangkyung Kwak, Huiwon Jang, Jongheon Jeong, Jonathan Huang, Jinwoo Shin 和 Saining Xie。面向生成的表示对齐：扩散Transformer的训练比想象中更容易。发表于 *ICLR*, 2025年。

Sukmin Yun、Hankook Lee、Jaehyung Kim和Jinwoo Shin。面向自监督视觉变换器的补丁级表征学习。发表于 *CVPR*, 2022年。

赛义德·瓦卡斯·扎米尔、阿迪亚·阿罗拉、阿克希塔·古普塔、萨尔曼·汗、郭磊·孙、法哈德·沙赫巴兹·汗、朱凡、邵岭、夏桂松与白翔。isaid: 一个用于航空图像实例分割的大规模数据集, 2019。

Wojciech Zaremba、Ilya Sutskever 和 Oriol Vinyals。循环神经网络正则化。 *arXiv preprint arXiv:1409.2329*, 2014年。

Xiaohua Zhai, Alexander Kolesnikov, Neil Houlsby, and Lucas Beyer. Scaling vision transformers. In *CVPR*, 2022a .

翟晓华、王晓、巴兹尔·穆斯塔法、安德烈亚斯·施泰纳、丹尼尔·凯泽斯、亚历山大·科列斯尼科夫与卢卡斯·拜尔。《Lit: 通过锁定图像文本调优实现零样本迁移》。载于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 第18123–18133页, 2022b年。

翟晓华、Basil Mustafa、Alexander Kolesnikov 和 Lucas Beyer。语言图像预训练的 Sigmoid 损失。载于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 第 11975–11986 页, 2023 年。

Richard Zhang, Phillip Isola 和 Alexei A Efros。彩色图像上色。于 *ECCV*, 2016。

张莹莹, 茹立祥, 吴康, 余磊, 梁磊, 李延生, 陈京东。SkySense V2: 面向多模态遥感的统一基础模型。 *arXiv preprint arXiv:2507.13812*, 2025。

Bolei Zhou, Agata Lapedriza, Jianxiong Xiao, Antonio Torralba, and Aude Oliva. 利用Places数据库学习场景识别的深度特征。发表于 *NeurIPS*, 2014。

周博磊, 赵航, Xavier Puig, Sanja Fidler, Adela Barriuso, Antonio Torralba。通过ADE20K数据集进行场景解析。载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 第633–641页, 2017年。

周靖皓、陈伟、王慧宇、沈伟、谢慈航、艾伦·尤伊尔和陶坤。ibot: 基于在线分词器的图像bert预训练。 *arXiv preprint arXiv:2111.07832*, 2021年。

Tinghui Zhou, Richard Tucker, John Flynn, Graham Fyffe, and Noah Snavely. 立体放大：使用多平面图像学习视图合成。发表于 *SIGGRAPH*, 2018.

Adrian Ziegler 与 Yuki M Asano. 面向语义分割的物体部件自监督学习。发表于 *CVPR*, 2022年。

宗若凡、宋光鲁和刘宇。采用协作混合分配训练的DETR模型。载于 *Proceedings of the IEEE/CVF international conference on computer vision*, 第6748–6758页, 2023年。

Barret Zoph、Golnaz Ghiasi、Tsung-Yi Lin、Yin Cui、Hanxiao Liu、Ekin D Cubuk 和 Quoc V Le. 重新思考预训练与自训练。 *preprint arXiv:2006.06882*, 2020年。

附录

大规模训练中的伪影与异常值

本节讨论了近期在大型模型训练中观察到的伪影和异常值的出现，无论是在LLM领域（An等人，2025年）还是视觉领域（Darcet等人，2024年）。借鉴An等人（2025年）的定义，异常值通常被描述为网络激活值，其数值显著偏离其分布的平均值。在DINOv3的训练过程中，我们在不同层面识别出了此类异常值：有些发生在补丁层面，另一些则出现在特征维度层面。下文我们将讨论观察到的不同类型的异常值、它们对训练和结果的影响，同时也会介绍我们为解决问题所做的不同尝试以及初步结论。

A.1 高范数补丁异常值

Darcet等人（2024年）发现，在DINOv2中，补丁异常值会对性能产生负面影响。这些异常值主要表现为高范数标记，通常位于图像的低信息背景区域。研究发现，这些标记在补丁与CLS标记的内部通信中起着关键作用。此外，这一现象也影响其他模型，无论是否经过监督训练，例如CLIP（Radford等人，2021年）。当扩展到70亿参数模型时，我们观察到此类高范数补丁的出现，主要集中在背景区域。在本节中，我们展示了经过15万次迭代训练的70亿参数模型的结果，虽然有限，但为我们提供了指导决策的初步信号。我们在图20a的“ $\emptyset$ ”列中绘制了输出补丁范数（层归一化之前），其中高范数补丁以黄色显示，出现在天空和其他低信息区域。

令牌寄存器 为了缓解此类令牌异常值的出现(Darcet et al., 2024) 提出了一种简单而有效的解决方案：在ViT的输入序列中引入额外的令牌，称为寄存器。它们的作用是接管图像块与CLS之间的内部通信。根据研究结论，我们使用4个寄存器，且由于实验成本较高，未进行进一步的消融实验。图20a展示了该策略的实际应用示例，我们观察到高范数异常值得以消除，这一点在对应的范数分布直方图中得到了进一步证实。此外，我们在图20b中定量地观察到，在ImageNet-1k（IN1k）基准测试中加入额外寄存器令牌带来的益处。


在注意力机制中整合偏差 An等人（2025）的最新研究探讨了不同模型和架构中大语言模型领域异常值的出现。作者分析了多种类型的异常值，发现这些异常值与注意力机制存在内在关联。他们提出了多种缓解方案，我们从中选取了两种有前景且对注意力机制改动较小的方案：显式固定偏差（我们称为“值门控”）和注意力偏差策略。值门控策略的核心是在注意力输出中添加可学习的值偏差 $\{\mathbf{v}^*\}$ ，具体通过重新定义注意力机制实现：

$$\text{Attn}(Q, K, V; \mathbf{k}', \mathbf{v}') = \text{softmax}\left(\frac{Q[K^T]}{\sqrt{d}}\right)V + \mathbf{v}', \quad (4)$$

以 $Q, K, V \in \mathbb{R}^{T \times d}$ 为查询、键和值矩阵， d 为隐藏空间的维度。或者，如公式5所定义的注意力偏置，是在键和值矩阵中分别整合两个可学习的偏置项 $\mathbf{k}'$ 和 $\mathbf{v}' \in \mathbb{R}^d$ 。其定义如下：

$$\text{Attn}(Q, K, V; \mathbf{k}', \mathbf{v}') = \text{softmax}\left(\frac{Q[K^T \mathbf{k}']}{\sqrt{d}}\right) \begin{bmatrix} V \\ \mathbf{v}' \end{bmatrix}. \quad (5)$$

我们在图20a中观察到，值门控策略显著改变了补丁范数的分布，导致整体范数值普遍升高，并消除了明显的异常值。虽然注意力机制缓解了高范数标记的存在，但并未完全解决这一问题——如顶行图像所示，与使用寄存器标记的结果相比，某些高范数补丁仍然存在。值得注意的是，结合寄存器标记能获得最佳性能，因此我们在论文报告的所有实验中均采用此策略。



(a) 按离群值策略绘制的补丁范数可视化。底部两行每行共享一个从深蓝（低）到黄色（高）的色标。

图20: 不同策略对缓解高范数补丁异常值存在的影响, 分别从 (a) 定性和 (b) 定量两方面进行评估。我们使用一个7B模型生成结果, 该模型采用我们的训练方法进行了150k次迭代训练, 分别对应以下情况: 未采用任何高范数处理策略的“ $\emptyset$ ”、使用四个寄存器标记 (Darcet等人, 2024年), 以及采用注意力偏置与值门控策略 (An等人, 2025年)。在 (a, 首行) 中, 我们绘制了三张图像计算得到的输出补丁范数分布 (按升序排列)。同时, 我们逐图像可视化输出补丁范数 (底部两行), 采用统一的色彩映射——每张图像的最小值与最大值均基于不同异常值策略跨图像计算得出。

A.2 特征维度异常值

在模型架构中引入额外的寄存器有效解决了高范数补丁异常值的问题。然而, 在训练7B模型的过程中, 我们观察到一种不同类型的异常值, 它并非出现在补丁之间, 而是出现在学习表征的特征 (通道) 维度内。具体而言, 通过对变压器层间和训练迭代中的补丁激活进行分析, 我们发现一小部分特征维度会达到异常大的幅值, 尽管补丁间的范数保持稳定。有趣的是, 这些特征维度异常值在不同补丁和图像中均表现出持续的高值, 这一行为与 (An等人, 2025) 中报告观察结果形成对比。此外, 这些异常维度在给定模型的全层中持续存在, 其幅值随深度增加而增大, 并在输出层达到最大值。它们还会在训练过程中持续增大其幅值。

我们尝试在训练和推理过程中对这些维度进行中性化处理。实验结果表明, 这些维度在训练阶段起着重要作用, 因为应用L2正则化抑制它们会导致性能下降。然而, 在推理阶段移除这些维度并不会引起显著的性能变化, 这表明它们主要携带的是无关紧要或非信息性的信号。此外, 我们观察到最终层归一化被训练用于大幅缩小这些异常维度的数值。因此, 我们建议在下游应用中对最终层特征施加最终层归一化。或者, 应用批量归一化也可以抑制这些特征维度的异常值, 因为它们的高数值在图像块和图像之间具有一致性。

在使用早期层特征时需谨慎。如上所述, 这些早期层同样受到特征维度异常值的影响, 可能导致特征条件不良。虽然最终层归一化非常适合用于标准化最终特征的分布, 但其学习到的参数若应用于早期层特征可能并非最优选择。实际上, 我们观察到在某些任务中这样做会导致性能下降。在这些情况下, 我们发现标准特征缩放技术 (使用批量归一化或主成分分析进行 $\{v^*\}$ 归一化) 能有效处理特征维度异常值。

表21: 图1所用数字的发表年份、性能及参考文献详情。对于所有论文, 我们报告该算法在ImageNet上使用最大模型的top-1准确率。对于弱监督和自监督模型, 我们提供线性探测性能。关于日期, 我们采用首次在arXiv上出现的年份。

Year	Supervised		Weakly-Supervised		Self-Supervised	
	Top-1	Reference	Top-1	Reference	Top-1	Reference
2012	59.3	Krizhevsky et al. (2012)				
2013						
2014						
2015	78.6	He et al. (2016)	34.9	Joulin et al. (2016)		
2016						
2017	80.9	Xie et al. (2017)				
2018			83.6	Mahajan et al. (2018)	38.2	Caron et al. (2018)
2019	84.3	Tan and Le (2019)			68.6	He et al. (2020)
2020	87.5	Kolesnikov et al. (2020)			75.3	Caron et al. (2020)
2021	88.6	Dosovitskiy et al. (2020)	88.4	Radford et al. (2021)	82.3	Zhou et al. (2021)
2022						
2023	89.5	Dehghani et al. (2023)			86.5	Oquab et al. (2024)
2024						
2025			89.3	Bolya et al. (2025)	88.4	This work

例如, 在我们的语义分割 (第6.3.2节) 和深度估计实验 (第6.3.3节) 中, 当使用中间层的特征时, 我们应用了批量归一化。

B 附加结果

B.1 历年演变

在图1中, 我们提供了历年最先进性能的大致演变情况。此处, 我们提供图中标注的精确参考文献和性能数据。详情请参见表21。

B.2 逐层分析

在本节中, 我们评估了DINOv3 7B模型各层特征的质量。具体而言, 我们展示了五项代表性任务的结果: 分类 (IN-1k验证集、ImageNet-ReAL和ObjectNet)、分割 (ADE20k)、深度估计 (NYU)、跟踪 (DAVIS) 以及三维对应关系估计 (NAVI)。对于前三项基准测试, 我们参照第6.1.2节和第6.2.1节的方法, 在每个骨干网络层的输出上训练线性层以评估特征性能。对于跟踪和对应关系估计任务, 我们采用第6.1.3节和第6.1.5节中的非参数化方法。

结果如图21所示。我们发现对于分类和密集预测任务, 性能随层数平滑提升。深度估计、目标跟踪和3D对应关系估计在约第32层达到峰值, 这表明对于几何特征起关键作用的任务, 通过考虑更早的中间层可以提升DINOv3的下游性能。另一方面, 中间层性能相比最后一层仅略有改善, 这使得最后一层成为良好的默认选择。

B.3 主要结果章节的补充结果

我们在第6节主要结果的基础上补充了额外的实验结果。在表22中, 我们展示了基于线性探测的小型数据集细粒度分类结果 (Fine-S, 详见第6.2.1节)。在表23中, 我们提供了实例识别评估 (第6.2.2节) 的完整结果, 并补充了更多评价指标。




图21: 使用DINOv3 7B中间层特征在五个基准测试上的结果。评估 (a-c) 采用线性层方法 (参见第6.1.2和6.2.1节), 而 (d, e) 采用非参数化方法 (参见第6.1.3和6.1.5节)。

表22: 在小型数据集上使用线性探测进行细粒度分类的逐数据集结果 (Fine-S, 见第6.2.1节), 方法遵循Oquab等人 (2024) 的研究。

Method	ViT	Food	C10	C100	SUN	Cars	Aircr.	VOC	DTD	Pets	Cal101	Flowers	CUB	Avg
<i>Agglomerative backbones</i>														
AM-RADIOv2.5	g/14	96.5	99.5	95.0	82.8	95.4	91.7	90.3	88.6	96.7	98.8	99.7	91.5	93.9
<i>Weakly-supervised backbones</i>														
SigLIP	g/16	97.7	99.3	92.7	85.1	96.5	88.7	91.0	87.7	98.7	90.3	99.7	90.3	93.7
PE-core	G/14	97.8	99.5	95.3	85.2	96.5	92.0	90.5	88.2	98.7	93.3	99.5	93.3	94.5
AIMv2	3B/14	96.6	99.3	93.3	83.4	95.6	84.2	90.5	87.4	96.8	90.7	99.7	90.7	92.9
EVA CLIP	18B/14	96.9	99.5	95.4	85.0	95.4	81.6	90.2	87.1	98.4	90.6	99.6	90.6	92.9
<i>Self-supervised backbones</i>														
Franca	g/14	89.2	98.6	90.4	73.7	89.7	74.1	89.4	80.6	93.2	97.6	97.8	78.4	87.7
DINOv2	g/14	95.6	99.5	94.5	78.9	94.6	88.5	88.4	86.8	96.8	95.9	99.7	91.6	92.6
Web-DINO	7B/14	96.1	99.5	93.4	77.5	95.0	88.8	87.0	79.9	92.9	93.1	99.6	78.9	90.2
DINOv3	7B/16	96.9	99.6	96.0	81.1	95.0	88.2	88.2	87.2	97.0	94.8	99.7	92.4	93.0

最后, 在表24中, 我们展示了我们最先进的语义分割模型 (第6.3.2节) 在COCO-Stuff (Caesar等人, 2018)、PASCAL VOC 2012 (Everingham等人, 2012) 和Cityscapes (Geiger等人, 2013) 数据集上的补充结果。

B.4 在OCR密集型数据集上的分类

在本实验中, 我们评估了DINOv3在需要某种字符识别形式的分类任务上的表现。这些任务包括街道路牌、商标和产品分类。我们将我们的模型与最佳自监督模型 (DINOv2 g) 和最佳弱监督模型 (PE-core G) 进行了比较。我们以512分辨率图像运行我们的模型评估, 并调整其他模型的补丁大小以匹配序列长度。我们在表25中报告了该实验的结果。

表23：实例识别的完整结果，为第6.2.2节提供了更多指标。

Method	ViT	Oxford		Paris		Met			AmsterTime
		M	H	M	H	GAP	GAP-	ACC	mAP
<i>Agglomerative backbones</i>									
AM-RADIOv2.5	g/16	72.8	50.7	93.3	85.3	30.5	65.9	69.0	46.7
<i>Weakly-supervised backbones</i>									
SigLIPv2	g/16	49.3	25.1	79.3	60.9	0.0	0.0	0.2	15.5
PE-core	G/14	57.4	32.7	83.6	68.9	10.6	34.8	44.9	23.1
AIMv2	3B/14	55.0	28.8	85.6	71.4	29.5	67.3	69.9	23.1
EvaCLIP	18B/14	55.2	27.1	81.8	65.6	0.5	4.3	11.0	18.9
<i>Self-supervised backbones</i>									
Franca	g/14	44.6	14.3	73.8	51.6	27.2	54.3	57.7	21.1
DINOv2	g/14	78.2	58.2	92.7	84.6	44.6	73.0	75.2	48.9
Web-DINO	7B/14	64.1	31.2	89.8	80.3	35.2	67.3	71.3	30.6
DINOv3	7B/16	81.1	60.7	93.3	87.1	55.4	77.7	80.7	56.5

我们发现，我们的新模型DINOv3大幅超越了其前身DINOv2。然而，与弱监督模型之间的差距仍然很大。由于我们的模型在训练过程中未利用成对的图像-文本数据，它在学习字形关联方面面临更大的困难。Fan等人（2025年）的最新研究暗示了训练数据对此类任务性能的影响。由于我们工作的主要重点是改进密集特征，我们将缩小这一差距的任务留给未来的工作。

B.5 公平性分析

我们依据Goyal等人（2022b）的评估框架，对DINOv3 7B模型在不同收入层级和地区的地理公平性与多样性进行了评估。作为参照，我们同时列出了DINOv2和SEERv2的相应结果。结果显示，DINOv3在各收入类别间表现出一定的一致性，但低收入层级的性能相比最高收入层级显著下降了23%。中高收入层级的性能表现则较为接近。从地区维度看，DINOv3在各区域均取得了相对良好的评分，但欧洲与非洲之间仍存在超过14%的相对差距——这相比DINOv2超过17%的相对差距已有所改善。

C 实现细节

我们采用多裁剪策略（Caron等人，2020年），使用2个全局裁剪（256×256像素）和8个局部裁剪（112×112像素）供学生模型处理，总序列长度达到3.7M个标记。教师模型采用指数移动平均（EMA）

表24：在其他数据集上的语义分割与先进系统的比较，作为表11中ADE20k结果的补充。我们报告了模型在单尺度或多尺度（TTA）设置下评估时的mIoU分数，并与各数据集先前发表的最佳结果进行比较：COCO-Stuff 164k使用Fang等人（2023）的方法，Cityscapes使用Wang等人（2023b）的方法，VOC 2012使用Zoph等人（2020）的方法。我们采用的输入分辨率分别为：COCO-Stuff 1280、VOC 2012 1024、Cityscapes 1280。所有基线方法都需要对主干网络进行微调，而我们保持DINOv3主干网络冻结。

Method	FT	COCO-Stuff 164k		Cityscapes		VOC 2012	
		Single	TTA	Single	TTA	Single	TTA
Previous Best	🐼	53.7	53.7	86.3	87.0	—	90.0
DINOv3	🌟	53.8	54.0	86.1	86.7	90.1	90.4

表25: DINOv3在OCR密集型数据集上的分类性能对比。这些数据集对自监督学习而言是公认的难题。我们将DINOv3与最佳DINOv2模型（g）以及最佳弱监督PE-core模型（G）进行比较。

Model		GTSRB	Logo-2K+	FlickrLogos-32	RP2K	Products-10K	SOPProducts
DINOv2	ViT-g	78.2	52.9	83.6	91.4	70.8	57.6
PE-core	ViT-G	94.8	93.2	99.0	93.1	80.6	80.7
DINOv3-7B	ViT-7B	87.5	86.0	86.3	94.7	74.5	65.2

表26: 按收入区间和地区划分的地理公平性与多样性分析，遵循Goyal等人（2022b）的研究方案。

Method	Arch.	Income Buckets			Regions			
		low	medium	high	Africa	Asia	Americas	Europe
SEERv2	RG-10B	59.7	78.5	86.6	65.9	76.3	81.1	85.6
DINOv2	ViT-g/14	67.4	83.3	90.5	74.0	81.6	86.2	89.7
DINOv3	ViT-7B	69.6	85.7	90.9	76.7	83.0	88.0	90.7

学生模型的移动平均仅处理全局裁剪图像。我们在所有学生局部裁剪图像和两个教师全局裁剪图像类别标记上应用 $\mathcal{L}_{\text{DINO}}$ 损失，并在两个模型的不同全局裁剪图像对之间应用该损失。学生看到的全局裁剪图像块标记中，随机比例在[0.1, 0.5]范围内的标记以50%概率被掩码，我们在这些掩码标记与教师EMA模型可见标记之间应用 $\mathcal{L}_{\text{iBOT}}$ 损失。我们对学生看到的第一个全局裁剪图像的16个类别标记小批量应用 $\mathcal{L}_{\text{DKoleo}}$ 损失。我们使用PyTorch中的完全分片数据并行设置进行100万次迭代训练，采用bfloat16精度和8位浮点矩阵乘法。我们使用恒定学习率0.0004，预热10万次迭代，权重衰减为0.04，每层学习率衰减因子为0.98，随机深度（层丢弃）值为0.4，教师模型的EMA因子为0.999。其余超参数可在代码发布版的配置文件中找到。

在Gram锚定步骤中，我们使用损失权重为 $w_{\text{Gram}} = 2$ ，并每10k步更新一次Gram教师模型，最多更新三次。对于高分辨率适配（第5.1节），我们按以下概率从以下全局/局部/Gram教师裁剪分辨率对中采样：(512, 112, 768) 对应概率 $p = 0.3$ ，(768, 112, 1152) 对应概率 $p = 0.3$ ，(768, 168, 1152) 对应概率 $p = 0.3$ ，(768, 224, 1152) 对应概率 $p = 0.05$ ，以及 (768, 336, 1152) 对应概率 $p = 0.05$ 。这些数值是通过经验获得的。

D 实验详情

在本节中，我们将详细描述本文所有基准测试中使用的数据集和评估指标。

D.1 语义分割：线性探测

数据集与评估指标 我们通过线性探测在三个基准数据集上评估DINOv3的语义分割性能：ADE20k（Zhou等人，2017）、VOC12（Everingham等人，2012）和Cityscapes（Cordts等人，2016）。报告的评估指标为标准平均交并比（mIoU）。

评估协议 为了评估密集特征的质量，我们在每个基准的训练集上训练一个线性分类器。该线性层应用于冻结主干网络经过层归一化后的补丁输出特征之上，并进一步使用训练过的批量归一化层对特征进行归一化处理。对于所有主干网络，我们使用AdamW优化器进行超参数扫描，学习率在 $\{1 \times 10^{-4}, 3 \times 10^{-4}, 1 \times 10^{-3}\}$ 范围内调整，权重衰减在 $\{1 \times 10^{-4}, 1 \times 10^{-3}\}$ 范围内调整。

D.2 深度估计：线性探测

数据集与评估指标 我们在深度估计基准数据集Uv2 (Silberman等人, 2012) 和KITTI (Geiger等人, 2013) 上评估DINOv3特征在几何任务中的质量, 并使用均方根误差 (RMSE) 指标报告结果。

评估协议 为评估密集特征的质量, 我们在每个基准的训练集上训练一个线性分类器。该线性层应用于冻结主干网络经层归一化后的补丁输出特征之上, 并进一步通过一个训练过的批量归一化层对特征进行归一化处理。对于所有主干网络, 我们使用AdamW优化器进行超参数扫描, 学习率在 $[1 \times 10^{-4}, 3 \times 10^{-4}, 1 \times 10^{-3}]$ 范围内调整, 权重衰减在 $[1 \times 10^{-4}, 1 \times 10^{-3}]$ 范围内调整。

D.3 三维关键点匹配

数据集与评估指标 几何对应性在NAVI数据集 (Jampani等人, 2023) 上评估, 语义对应性在SPair数据集 (Min等人, 2019) 上评估。对于NAVI数据集, 我们将图像调整至边长为448/512像素 (对应补丁尺寸为14/16的模型)。对于SPair数据集, 则将图像调整至边长为896/1024像素 (对应补丁尺寸为14/16的模型)。为衡量性能, 我们采用对应召回率*i.e.*, 即落在指定距离内的对应点百分比。

对于NAVI, 我们遵循Probe3D (Banani等人, 2024) 中定义的评估协议。具体而言, 我们子采样1/4的物体视角, 并为每个源视角选择另一个目标视角 (最大旋转角度为120度) 以创建图像对 (源, 目标) 进行块匹配。对于每个图像对, 源图像 (物体内部) 的每个块都会与目标图像中的一个块进行匹配。保留余弦相似度最高的前1000个匹配用于评估, 并根据已知的相机姿态和两幅图像的深度图为每个匹配计算3D距离误差。这允许计算不同阈值下的召回误差, 我们使用的阈值为1厘米、2厘米和5厘米。随后, 我们计算跨阈值的平均召回率作为对应召回率。

对于每个评估的主干网络, 我们使用最终层的特征, 并在应用和不应用最终层归一化的情况下进行评估。这是因为我们注意到某些模型在应用最终层归一化时表现不佳。我们报告两种结果中的最大值。

D.4 无监督目标发现

数据集与评估指标 本任务的目标是为每张图像生成一个边界框, 以突出显示场景中描绘的任何物体。我们遵循Siméoni等人 (2021) 的无监督物体发现协议, 并在检测基准VOC07 (Everingham等人, 2007)、VOC12 (Everingham等人, 2012) 和COCO20K (Lin等人, 2014; Vo等人, 2020) 上评估所有骨干网络。COCO20K是COCO2014训练验证数据集 (Lin等人, 2014) 的一个子集, 包含19,817张随机选择的图像, 由Vo等人 (2020) 提出并在此任务中广泛使用。每张图像生成一个边界框。评估时, 我们采用*Correct Localization* (CorLoc) 指标, 该指标计算正确定位框的百分比。若预测框与任意真实边界框的*intersection over union* (IoU) 超过0.5, 则视为正确。

评估协议 为评估图像编码器的质量, 我们采用TokenCut策略 (Wang等人, 2023c)。该方法将图像块组织成完全连接图, 其中边表示块对之间的相似度分数, 这些分数通过Transformer学习的主干特征计算。通过应用归一化割算法识别显著目标块, 该算法解决了图割问题。随后将边界框拟合到生成的显著目标掩码上。所有图像均以原始分辨率输入编码器, 并使用所有图像编码器的块输出特征。为考虑模型间特征分布的差异, 我们对TokenCut的唯一超参数——图构建中使用的相似度阈值——进行扫描。具体而言, 我们将阈值在0至0.4之间以0.05为步长进行调整。

D.5 视频分割跟踪

数据集与评估指标 针对此任务，我们采用DAVIS 2017 (Pont-Tuset等人, 2017)、YouTube-VOS (Xu等人, 2018) 和MOSE (Ding等人, 2023) 数据集。DAVIS定义了包含60个视频的训练集和30个视频的验证集，其中所有帧均标注了真实实例分割掩码。YouTube-VOS仅提供已标注的公开训练集，其验证集需通过评估服务器访问。为模拟DAVIS的设置，我们随机选取2758个已标注视频 (80%) 作为训练集，其余690个视频 (20%) 作为验证集。类似地，我们将MOSE数据集划分为1206个视频用于验证，301个视频用于测试。对于所有数据集，我们采用标准的 $\mathcal{J}$ & $\mathcal{F}$ -mean指标 (Perazzi等人, 2016) 评估性能，该指标综合了区域相似度 ($\mathcal{J}$) 和轮廓精度 ($\mathcal{F}$) 得分。仅对首帧标注的目标进行跟踪与评估，视频后续出现的目标即使具有真实掩码标注也会被忽略。

评估协议 与Rajasegaran 等人 (2025) 类似，我们采用了一种基于图像块相似度的非参数化标签传播协议，该相似度通过冻结的 DINOv3 骨干网络提取的特征之间的余弦相似度计算。我们假设视频的第一帧已标注实例分割掩码，并将其表示为每个图像块的一热向量。对于每一帧，我们计算其所有图像块特征与第一帧所有图像块以及少量过去帧所有图像块之间的余弦相似度。针对当前帧中的单个图像块，我们考虑其空间邻域内最相似的 k 个图像块，并对它们的标签进行加权平均，从而得到当前图像块的预测结果。处理完一帧后，我们移至下一帧，并将先前的预测视为软实例分割标签。在通过骨干网络逐帧前传时，我们会调整图像尺寸，使短边匹配特定长度，并保持宽高比至图像块尺寸的最近整数倍。² 图像块相似度与标签传播在所得特征的分辨率下计算，随后将掩码概率通过双线性插值调整至原始分辨率，以计算 $\mathcal{J}$ 和 $\mathcal{F}$ 。我们考虑了多种超参数组合，*e.g.* 包括用作上下文的历史帧数量、邻居数量 k 以及空间邻域大小，详见表 27。我们在 DAVIS 的训练集上进行超参数选择，然后将最佳组合应用于所有数据集的测试集。

D.6 视频分类

数据集与指标 我们使用CF101 (Soomro等人, 2012)、Something-Something V2 (Goyal等人, 2017) 和Kinetics-400 (Kay等人, 2017) 数据集，在视频分类任务上评估DINOv3。整体流程如下：从每个视频中提取固定数量的帧，通过冻结的主干网络进行编码，将所有图像块特征整合为扁平序列，随后输入一个基于浅层Transformer的分类器——该分类器通过常规监督方式在一组已标注视频上进行训练。在先前的研究*e.g.* (Assran等人, 2025) 中，此流程被称为*attentive probe*，这一命名暗示了其于图像分类中使用的*linear probes*的关联。接下来我们将详细描述该流程的具体实现。

在训练阶段，我们从每个视频中随机选取16个时间位置对应的帧，并记录对应的时间戳。同时，我们采样一个空间裁剪参数，该裁剪覆盖视频画面面积的40%到100%——这些参数将在视频的所有帧之间共享，以避免画面抖动。随后，我们将每一帧作为独立的256×256图像输入DINOv3进行处理，提取16×16的块特征并丢弃CLS标记。对于每个图像块，我们记录其在 $[0, 1]^2$ 归一化坐标系下的空间位置。所有帧的块特征经过线性投影映射到1024维，拼接成长度为 $16 \times 16 \times 16 = 4096$ 的扁平序列，随后输入四个自注意力模块以建模块之间的时空关系。为确保模型能获取位置信息，我们在模块处理前为每个块注入时间戳和空间坐标信息：一方面采用正弦-余弦加性嵌入 (Vaswani et al., 2017)，另一方面在每次注意力计算中使用带随机空间旋转的3D分解式RoPE进行编码。

²For example, DAVIS videos are natively 480×854 and we want to process them at resolution 960. For a model with patch size 16, we resize the frames to 960×1712 with a slight horizontal stretch, resulting in a 60×107 feature map. Instead, for a model with patch size 14, we resize the frames to 966×1708 with a slight vertical stretch, resulting in a 69×122 feature map.

表27: 在DAVIS 2017训练集 (Pont-Tuset等人, 2017) 上评估视频分割跟踪的超参数列表。已高亮标出的最佳超参数将应用于所有数据集。

Max context length	Neighborhood mask size	Neighborhood mask shape	Top-K	Temperature
7	12	Square	5	0.2
7	12	Circle	5	0.2
7	5	Square	5	0.2
7	24	Square	5	0.2
7	∞	—	5	0.2
7	12	Square	5	0.01
7	12	Square	5	0.1
7	12	Square	5	0.7
4	12	Square	5	0.2
10	12	Square	5	0.2
15	12	Square	5	0.2
7	12	Square	3	0.2
7	12	Square	10	0.2
7	12	Square	15	0.2
15	12	Circle	10	0.1
15	24	Circle	10	0.1
15	36	Circle	10	0.1
15	∞	—	10	0.1

头部 (Heo等人, 2024年)。在四个模块之后, 我们应用一个带有单个无位置可学习查询的交叉注意力模块, 将所有图像块的信息聚合到单个向量中, 随后通过线性投影得到最终的分类型逻辑值。自注意力模块堆栈、交叉注意力模块、位置嵌入以及最终投影层共同构成了视频分类器, 我们使用批量大小为64的标准交叉熵损失训练了20个周期。实际训练中, 我们并行训练了一组分类器, 每个分类器对应学习率 $\{1 \cdot 10^{-4}, 2 \cdot 10^{-4}, 5 \cdot 10^{-4}, 1 \cdot 10^{-3}, 2 \cdot 10^{-3}, 5 \cdot 10^{-3}\}$ 与权重衰减 $\{10^{-3}, 10^{-2}, 10^{-1}\}$ 的一种组合。针对每个数据集, 我们使用90%的训练集更新模型参数, 10%的训练集选择最佳学习率与权重衰减组合, 最终在验证集上报告所选模型的性能。

在推理阶段, 我们采用确定性策略从每个视频中采样单个片段: 选取首帧、尾帧以及中间均匀间隔的帧, 总计16帧。对每一帧, 我们裁剪出最大的中心正方形区域, 并将其调整为 256×256 像素, 这可能会损失矩形视频两侧的信息。随后将这些帧输入DINOv3和分类器, 以获取视频的预测结果。另一种方法是遵循Assran等人 (2025) 的做法, 通过选择多个帧序列和多个空间裁剪区域进行测试时增强 (TTA), 独立处理这些数据后对类别概率进行平均, 从而得到最终预测。片段采样的具体示例如图22所示。

对于选定的基线模型, 我们采用相同的评估协议*i.e.*、特征提取方法、分类器架构、训练流程和推理协议, 仅存在少数差异。使用16补丁尺寸的模型输入分辨率为 256×256 像素, 14补丁尺寸的模型则为 224×224 像素。通过这种方式, 所有骨干网络生成相同数量的标记, 从而在分类器中实现等量的计算。由于这些模型基于图像训练, 所有模型均逐帧独立处理视频。唯一的例外是V-JEPA 2模型, 我们向其输入完整视频片段以提取时间感知特征。由于V-JEPA 2将时间轴压缩为原长的二分之一*e.g.* (在输入16帧时产生8个时间步), 我们通过复制每个补丁标记来匹配其他模型的序列长度。




图22：用于视频分类的采样片段。选择用于训练或推理的片段意味着确定空间裁剪的坐标以及要采样的帧/时间戳。在训练时，我们通过从整个视频中随机选择帧，并应用覆盖 $\geq 40\%$ 区域的空间裁剪来随机采样片段。在推理时，我们以确定性的方式选择片段。在空间上，我们取左对齐、居中对齐和右对齐的三个最大正方形裁剪区域。在时间上，我们取两组重叠的帧，使其尽可能覆盖视频的大部分内容，并且它们的时间戳交错排列。

D.7 基于线性探测的图像分类

数据集与评估指标 我们采用广泛使用的线性探测评估方法来衡量DINOv3模型的整体质量。我们在ImageNet-1k (Deng等人, 2009) 的训练集上训练线性变换，并在验证集上评估结果。通过评估模型在分类测试集上的迁移能力来检验其泛化质量：ImageNet-V2 (Recht等人, 2019) 和ReaL (Beyer等人, 2020) 为ImageNet提供了替代性的图像和标签集，旨在测试模型对原始ImageNet验证集的过拟合情况。此外，我们还考虑了Renderition (Hendrycks等人, 2021a) 和Sketch (Wang等人, 2019) 数据集，它们呈现了ImageNet类别的风格化和人工合成版本；Adversarial (Hendrycks等人, 2021b) 和ObjectNet (Barbu等人, 2019) 数据集包含刻意设计的挑战性样本；以及Corruptions (Hendrycks和Dietterich, 2019) 数据集，用于衡量模型对常见图像损坏的鲁棒性。除ImageNet-C外，我们对所有数据集报告top-1分类准确率作为评估指标；对于ImageNet-C，我们报告平均损坏误差 (mCE, 参见 (Hendrycks和Dietterich, 2019))。

对于细粒度数据集，我们采用与Oquab等人 (2024) 相同的12个数据集集合，在此称为Fine-S: Food-101 (Bossard等人, 2014)、CIFAR-10 (Krizhevsky等人, 2009)、CIFAR-100 (Krizhevsky等人, 2009)、SUN397 (Xiao等人, 2010)、StanfordCars (Krause等人, 2013)、FGVC-

飞机 (Maji等人, 2013)、VOC 2007 (Everingham等人, 2007)、DTD (Cimpoi等人, 2014)、牛津宠物 (Parkhi等人, 2012)、Caltech101 (Fei-Fei等人, 2004)、花卉 (Nilsback和Zisserman, 2008) 和CUB200 (Welinder等人, 2010), 以及更大的数据集Places205 (Zhou等人, 2014)、iNaturalist 2018 (Van Horn等人, 2018) 和iNaturalist 2021 (Van Horn等人, 2021)。

评估协议 对于较大规模的数据集 (ImageNet、Places205、iNaturalist 2018 和 iNaturalist 2021), 我们采用以下流程: 针对每个基线模型, 我们在 ImageNet-1k 训练集 (Deng 等人, 2009) 上基于 CLS 令牌 (令牌) 的最终特征 (经过层归一化后) 训练一个线性层。具体而言, 我们使用动量为 0.9 的随机梯度下降 (SGD), 以 1024 的批次大小训练 10 个周期。我们扫描学习率 $\{1 \times 10^{-4}, 2 \times 10^{-4}, 5 \times 10^{-4}, 1 \times 10^{-3}, 2 \times 10^{-3}, 5 \times 10^{-3}, 1 \times 10^{-2}, 2 \times 10^{-2}, 5 \times 10^{-2}, 1 \times 10^{-1}, 2 \times 10^{-1}, 5 \times 10^{-1}, 1 \times 10^0, 2 \times 10^0, 5 \times 10^0\}$ 以及权重衰减值 $\{0, 1e-5\}$, 并利用 ImageNet-1k 的验证集选择最佳组合。训练过程中, 我们采用随机缩放裁剪增强方法, 并应用标准的 Inception-crop 参数。对于 Fine-S 中的数据集, 遵循 Oquab 等人 (2024) 的做法, 我们采用更轻量级的评估方式, 使用 scikit-learn 的 LogisticRegression 实现并搭配 L-BFGS 求解器。

在这两种情况下, 我们评估模型的分辨率均产生 1024 个图像块标记, 即: 当图像块尺寸为 14 时, 采用 448×448 分辨率; 当图像块尺寸为 16 时, 采用 512×512 分辨率。图像会调整大小使其短边匹配选定边长, 然后取中心正方形区域进行裁剪。

D.8 实例识别

数据集与指标 我们使用牛津和巴黎数据集进行地标识别 (Radenovi 等人, 2018 年), 包含大都会博物馆艺术品的 Met 数据集 (Ypsilantis 等人, 2021 年), 以及由现代街景图像与阿姆斯特丹历史档案图像匹配组成的 AmsterTime 数据集 (Yildiz 等人, 2022 年)。在表 9 中, 我们报告了 Oxford-Hard、Paris-Hard 和 AmsterTime 的平均精度均值 (mAP), 以及 Met 的全局平均精度 (GAP)。在表 23 中, 我们额外提供了 Oxford-Medium 和 Paris-Medium 的 mAP, 以及补充指标 GAP 和准确率 (参见 Ypsilantis 等人, 2021 年)。对于牛津和巴黎数据集, 我们将所有图像调整大小, 使较长边为 224 像素, 保持宽高比, 然后进行完整中心裁剪, 得到分辨率为 224×224 的图像。对于 AmsterTime, 我们将所有图像调整大小, 使较短边为 256 像素, 保持宽高比, 然后进行 224×224 的中心裁剪。对于 Met 数据集, 我们在接近原始分辨率下评估所有图像, 将两边调整至最接近的补丁尺寸倍数 (对于补丁尺寸 14/16, 长边分别为 508/512)。

评估协议 图像相似度通过计算查询图像与目标图像 CLS 令牌之间的余弦距离来衡量。我们遵循以下评估协议: 针对 Oxford 和 Paris 数据集采用 (Radenovi 等人, 2018) 的方法; 针对 AmsterTime 数据集采用 (Yildiz 等人, 2022) 的方法; 针对 Met 数据集采用 Ypsilantis 等人 (2021) 的方法。对于 Met 数据集, 这包括通过网格搜索调整超参数 k 和 $\{v^*\}$, 在 Met 验证集上优化 GAP (平均准确率均值), 并使用基于 Met 训练集估计的 PCA 对特征进行白化处理。

D.9 目标检测

数据集与评估指标 我们在 COCO (Lin 等人, 2014 年) 和 COCO-O (Mao 等人, 2023 年) 数据集上评估 DINO v3 的目标检测性能。COCO 是目标检测的标准基准, 涵盖 80 个物体类别, 包含 11.8 万张训练图像和 5000 张验证图像。COCO-O 是仅用于评估的数据集, 其类别与 COCO 相同, 但视觉条件更具挑战性, 例如存在严重遮挡、背景杂乱和光照变化显著的场景。为训练目标检测模型, 我们还利用了 Objects365 (Shao 等人, 2019 年) 数据集, 该数据集包含 250 万张图像, 涵盖 365 个物体类别, 其中部分类别可直接映射到 COCO 类别。对于 COCO 和 COCO-O, 我们均报告在 IoU 阈值为 $[0.5 : 0.05 : 0.95]$ 时计算的平均精度均值 (mAP)。

架构 我们的方法基于 Plain-DETR (Lin 等人, 2023b) 实现, 并进行了若干修改。我们并未将 Transformer 编码器融合到 backbone 中, 而是将其保留为独立模块, 这与原始 DETR (Carion 等人, 2020) 的设计相似。这使得我们能够在训练和推理过程中完全冻结 DINO v3 主干网络, 使其成为首个实现此特性的具有竞争力的检测模型。从 DINO v3 ViT-7B/16 主干网络中, 我们提取了四个中间层的特征, 即 $[10, 20, 30, 40]$ 。对于

在每个补丁中，我们沿通道维度拼接中间特征，得到特征维度为 $4 \cdot 4096 = 16384$ ，并通过下文描述的窗口化策略进一步增加。骨干特征输入到`encoder`中，这是一个由6个自注意力块组成的堆叠结构，嵌入维度为768。`decoder`则是一个由6个交叉注意力块组成的堆叠结构，具有相同的嵌入维度，其中1500个“一对一”查询和1500个“一对多”查询关注编码器的补丁标记，以预测边界框和类别标签。

图像预处理训练分为三个阶段进行，具体如下：一个阶段的基础图像分辨率为1536像素，另外两个阶段的基础分辨率为2048像素。遵循DETR的方法，我们首先应用随机水平翻转（ $p = 0.5$ ），随后采用以下两种方式之一：(i) 随机调整尺寸，将最短边在920像素（对应1228像素）与当前阶段基础分辨率（1536或2048）之间均匀采样；(ii) 随机裁剪保留原始图像面积的60–100%，随后按方式(i)调整尺寸。在评估阶段，图像将调整尺寸使最短边为2048像素，不进行额外增强，且图像两边长度均向上取整至最近的分块尺寸倍数。

窗口化策略 随后，我们采用一种窗口化策略，将图像的全局视角与较小视角相结合，以使骨干网络能够处理所有尺度的目标。窗口数量固定为 3×3 ，其尺寸根据输入分辨率而变化。例如，对于尺寸为 1536×2304 的图像：

1. 图像被划分为 3×3 个大小为 512×768 的非重叠窗口。每个窗口通过主干网络前向传播，生成 32×48 个维度为16384的补丁标记。所有窗口的特征在空间上重新组装为 $(3 \cdot 32) \times (3 \cdot 48)$ 的特征图。
2. 将整张图像调整为 512×768 大小，通过主干网络前向传播，得到 32×48 个维度为16384的补丁标记特征图。随后将这些特征双线性上采样至 96×144 ，以匹配窗口化特征图的尺寸。
3. 最后，将步骤1和步骤2的特征图在通道维度上进行拼接，得到 96×144 、维度为 $2 \cdot 16384 = 32768$ 的特征图。该特征图随后被展平为 $96 \cdot 144$ 个标记的序列，并输入编码器。

训练 我们遵循一个三阶段的训练课程，使用Objects365数据集（Shao等人，2019）和COCO数据集（Lin等人，2014），并逐步提高分辨率。在整个训练过程中，我们使用AdamW优化器（Loshchilov和Hutter，2017），权重衰减为0.05。遵循DETR，我们使用Focal Loss（Lin等人，2018）作为分类损失，权重为2；L1损失作为边界框损失，权重为1；并辅以GIoU损失（Rezatofighi等人，2019），权重为2。各阶段如下：

1. 我们首先在Objects365数据集上以1536像素的基础分辨率开始训练。我们使用32的全局批次大小训练22个周期，并在32个GPU上分配训练任务。经过1000步的初始预热后，学习率设置为 $5 \cdot 10^{-5}$ ，并在第20个周期后除以10。
2. 随后，我们在Objects365数据集上以2048像素的基础分辨率继续训练。我们以 $2.5 \cdot 10^{-5}$ 的学习率训练4个周期。
3. 我们通过在COCO数据集上以2048的基础分辨率进行12个周期的训练来完成训练。经过2000次迭代的线性预热后，学习率遵循余弦衰减计划，从 $2.5 \cdot 10^{-5}$ 开始，在第8个周期时降至 $2.5 \cdot 10^{-6}$ 。在这一部分中，我们使用IA-BCE分类损失（Cai等人，2024年）替代了DETR中的简单焦点损失。我们观察到这种损失在迁移时能提升模型性能，但在预训练时则不然。由于该损失融合了类别和边界框信息，若边界框预测已得到良好初始化，其潜力便能充分发挥。此阶段将GIoU损失权重设为4，以促进更好的边界框对齐。

测试时增强 在测试阶段，我们遵循上述推理流程，将图像短边调整为36或2048像素。在此分辨率下，CO CO mAP分别达到65.4和65.6。此外，我们可采用Bolya等人（2025年）提出的测试时增强策略，通过图像翻转与多分辨率缩放处理，并利用SoftNMS（Bodla等人，2017年）融合预测结果。具体而言，每张图像将在[1536, 1728, 1920, 2112, 2304, 2496, 2688, 2880]分辨率序列中进行处理，最终获得66.1的mAP。

D.10 语义分割

数据集与评估指标 我们在ADE20k (Zhou等人, 2017)、Cityscapes (Cordts等人, 2016)、COCO-Stuff (Caezar等人, 2018) 和VOC 2012 (Everingham等人, 2012) 数据集上评估DINOv3的语义分割性能。ADE20k是广泛使用的语义分割基准数据集, 包含150个语义类别, 涵盖从户外场景到室内人物与物体的各类图像。此外, COCO-Stuff和Hypersim (Roberts等人, 2021) 数据集被用于模型预训练。COCO-Stuff比ADE20k规模更大 (11.8万张训练图像), 包含80个物体类别和91个材质类别; 而Hypersim是呈现室内场景的光照真实合成数据集, 包含40个语义类别, 其标注更清晰精确。超过半数的Hypersim图像包含21个或更多物体, 这使其成为帮助模型学习场景丰富信息的理想选择。所有数据集均采用mIoU作为评估指标。

架构 我们采用了其他基线方法所使用的ViT-Adapter与Mask2former配置 (Wang等人, 2023a), 但存在若干差异。首先, 为确保主干网络保持冻结状态且其激活值不被改变, 我们移除了ViT-Adapter中的注入器组件。这使得主干网络输出的特征可直接用于提取器模块。其次, 为适应我们主干网络4096维的输出维度, 我们将Mask2former解码器中的嵌入维度调整为2048而非默认的1024, 而其他基线方法的主干网络通常输出维度为1024或1536。作为解码器的输入, 我们从DINOv3 7B/16主干网络的四个中间层 (即第[10, 20, 30, 40]层) 提取特征。我们对所有层级的特征应用最终层归一化, 并添加可学习的批量归一化。

训练协议 为在COCO-Stuff数据集上生成结果, 我们采用余弦调度器训练模型, 设置6k次线性预热, 最大学习率为 $1.5e-5$ 。模型在1280像素分辨率下训练80k次迭代。对于其他数据集ADE20k、Cityscapes和VOC 2012的训练, 我们首先在COCO-Stuff上对解码器进行80k次迭代的预训练, 采用6k线性预热和 $1.5e-5$ 的学习率, 并遵循余弦调度器。这有助于模型在比ADE20k更大的数据集上学习多样化的语义类别 (共171类)。随后, 模型在Hypersim数据集上以 $2.5e-5$ 的学习率训练10k次迭代, 采用带1.5k线性预热的余弦调度器。此步骤约相当于2个训练周期, 凭借Hypersim照片级真实的合成特性, 有助于模型学习高质量的图像-掩码对应关系。最后, 我们在ADE20k数据集上以 $3e-5$ 的学习率训练模型20k次迭代, 同样采用1.5k线性预热和余弦调度。最终结果基于验证集报告。对于Cityscapes和VOC 2012数据集, 分别使用 $1.5e-5$ 和 $1e-5$ 的学习率。所有训练均采用批次大小为16的AdamW优化器。

在单尺度评估中, 采用滑动推理来评估模型——图像首先会调整至训练分辨率 (例如, 对于ADE20k数据集, 一张 400×500 的图像会被缩放至 896×1120 像素, 因为模型是在896分辨率下训练的)。随后, 使用滑动窗口方法配合固定步长 (例如, ADE20k的步长为596像素) 在方形裁剪区域 (例如 896×896 像素) 上滑动遍历图像, 为每个裁剪区域生成预测结果。这些结果随后被聚合并重新缩放到原始图像尺寸, 以生成最终预测。在测试时增强方面, ADE20k和VOC 2012数据集的图像均被按评估分辨率的[0.9, 0.95, 1.0, 1.05, 1.1]比例进行缩放, 同时每张图像还进行了水平翻转, 从而为每个样本生成总计10组预测。在对每张图像完成滑动推理后, 结果被重新缩放至原始图像尺寸并取平均值。COCO-Stuff 164K数据集的TTA mIoU是通过每个样本额外使用水平翻转图像获得的; 而对于Cityscapes数据集, 则采用了评估分辨率的[1.0, 1.5, 2.0]比例进行缩放。

D.11 单目深度估计

实现细节 我们的方法Depth Anything v2 (DAv2) (Yang等人, 2024b) 的主要区别在于图像分辨率配置 (设置为 768×1024 pixels) 和网络架构。主干网络在整个训练过程中保持冻结, 同时在DPT头部 (Ranftl等人, 2021) 末端应用0.05的丢弃率。作为解码器的输入, 我们从四个中间层提取特征。

DINOv3 7B/16 骨干网络的若干层，即第 [10, 20, 30, 40] 层。我们对所有层的特征应用最终层归一化，并添加一个可学习的批量归一化。深度估计输出被离散化为 256 个均匀分布的区间，覆盖从 0.001 米到 100 米的范围。训练采用 $1e-3$ 的基础学习率，使用 PolyLR 调度器（幂次为 3.5）并包含持续 12k 次迭代的初始线性预热阶段。为增强鲁棒性和泛化能力，我们应用了一系列数据增强：高斯模糊、高斯噪声、自动对比度、自动均衡、色彩抖动、旋转以及左右翻转。

数据集与评估指标 我们在DAv2数据集上训练模型，该数据集包含来自IRS、TartanAir、BlendedMVS、Hypersim和VKITTI2数据集的合成生成图像。我们在五个数据集上进行评估：NYUv2（Silberman等人，2012）、KITTI（Geiger等人，2013）、ETH3D（Schöps等人，2017）、来自（Ke等人，2025）的ScanNet以及DIODE（Vasiljevic等人，2019）。我们采用零样本尺度不变深度设置，并报告标准指标绝对相对误差和 δ_1 （参见（Yang等人，2024a））。

D.12 基于DINOv3的视觉几何感知Transformer

实现细节 与原始GGT（Wang等人，2025年）相比，我们采用了以下调整：（1）将图像尺寸从518改为592，以匹配DINOv2生成的图像块标记数量；（2）采用更小的学习率，具体从0.0002降至0.0001；（3）将DINOv3 ViT-L的四个中间层输出进行拼接，而非仅使用最后一层作为下游模块的输入。有趣的是，我们发现使用四个中间层能为DINOv3带来性能提升，而对DINOv2采用相同操作则未产生额外增益。我们还尝试了更接近原始VGGT设置的版本（图像尺寸512、相同学习率、仅使用最终层），发现即使这一未调优版本在所有测试基准上也已超越了原始VGGT的性能。

D.13 地理空间

评估细节 在所有评估中，我们保持主干网络冻结，仅训练针对任务设计的轻量级分类器或解码器。对于GeoBench分类任务，我们使用批量大小为32训练线性分类器2400次迭代，采用SGD优化器与余弦学习率退火策略，并在 $1e-5$ 至1之间选择最佳学习率。除非另有说明，分割评估均使用DPT解码器（Ranftl et al., 2021），其学习率通过在验证集上对 $[3e-5, 1e-4, 3e-4, 1e-3]$ 范围内的四个值进行网格搜索，根据性能表现选定。

在LoveDA和iSAID数据集上，我们训练了一个UPerNet解码器（Xiao等人，2018），共进行80k次迭代，批大小为8，并按照（Wang等人，2024a）的方法进行了1500次迭代的线性预热。所有其他超参数（如裁剪尺寸和权重衰减）均与（Wang等人，2024a）保持一致。遵循先前工作（Tolan等人，2024；Wang等人，2022a）的做法，我们使用DPT头进行冠层高度预测评估，并训练了一个Faster RCNN（Ren等人，2015）检测器用于目标检测任务，共训练12个周期。

Satlidar数据集包含一百万张 512×512 的Maxar图像以及相应的密集激光雷达测量数据，这些数据采集自不同地点，详见表Tab. 28。图像是从更大的图块中提取的，每个子数据集对应的图块数量已在表中注明。

表28: Satlidar数据集的描述。

Subdataset	Path	Amount of tiles	Purpose
Kalimantan	https://daac.ornl.gov/cgi-bin/dsvviewer.pl?ds_id=1540	86	train/val/test
OpenDC	https://opendata.dc.gov/datasets/2020-lidar-classified-las/about	68	train/val/test
Brazil	https://daac.ornl.gov/cgi-bin/dsvviewer.pl?ds_id=1644	37	train/val/test
Mozambique	https://daac.ornl.gov/cgi-bin/dsvviewer.pl?ds_id=1521	144	train/val/test
Neon	https://data.neonscience.org/data-products/DP3.30015.001	5366	train/val/test
CA20Graup	https://portal.opentopography.org/datasetMetadata?otCollectionID=OT.092021.6339.1	99	train/val/test
CA17Duvall	https://portal.opentopography.org/datasetMetadata?otCollectionID=OT.042020.6339.2	56	train/val/test
Netherlands	https://geotiles.citg.tudelft.nl/	13	train/val/test
Sao Paulo	https://daac.ornl.gov/CMS/guides/LiDAR_Forest_Inventory_Brazil.html	4	test
CA brande	https://doi.org/10.5069/G9C53J18	1	test