

ImageNet Large Scale Visual Recognition Challenge

Olga Russakovsky* · Jia Deng* · Hao Su · Jonathan Krause ·
Sanjeev Satheesh · Sean Ma · Zhiheng Huang · Andrej Karpathy ·
Aditya Khosla · Michael Bernstein · Alexander C. Berg · Li Fei-Fei

收到日期 / 接受日期

Abstract ImageNet大规模视觉识别挑战赛是一个在数百个物体类别和数百万张图像上进行物体分类与检测的基准测试。该挑战自2010年起每年举办，至今已吸引了超过五十家机构的参与。

本文介绍了该基准数据集的创建过程，以及由此推动的物体识别技术进展。我们探讨了挑

在收集大规模地面真实标注方面面临的挑战，突出分类物体识别的关键突破，详细分析当前大规模图像分类和物体检测领域的现状，并比较最先进的计算机视觉精度与人类精度。我们总结了挑战赛五年来的经验教训，并提出了未来的方向和改进建议。

Keywords 数据集 · 大规模 · 基准测试 · 物体识别 · 物体检测

O. Russakovsky*
Stanford University, Stanford, CA, USA
E-mail: olga@cs.stanford.edu

J. Deng*
University of Michigan, Ann Arbor, MI, USA
(* = authors contributed equally)

H. Su
Stanford University, Stanford, CA, USA

J. Krause
Stanford University, Stanford, CA, USA

S. Satheesh
Stanford University, Stanford, CA, USA

S. Ma
Stanford University, Stanford, CA, USA

Z. Huang
Stanford University, Stanford, CA, USA

A. Karpathy
Stanford University, Stanford, CA, USA

A. Khosla
Massachusetts Institute of Technology, Cambridge, MA, USA

M. Bernstein
Stanford University, Stanford, CA, USA

A. C. Berg
UNC Chapel Hill, Chapel Hill, NC, USA

L. Fei-Fei
Stanford University, Stanford, CA, USA

1 Introduction

Overview. ImageNet大规模视觉识别挑战赛 (ILSVRC) 已连续举办五年 (自2010年起)，成为大规模物体识别的标准基准。¹ ILSVRC沿袭了2005年设立的PASCAL VOC挑战赛 (Everingham等人, 2012) 的传统，后者以年度竞赛的形式为识别算法的标准化评估开创了先例。与PASCAL VOC类似，ILSVRC包含两个部分：(1) 公开可用的 *dataset*；(2) 年度 *competition* 及相应研讨会。该数据集支持分类物体识别算法的开发与比较，而竞赛和研讨会则为追踪年度进展、探讨每年最成功与最具创新性的参赛方案所获经验提供了平台。

¹ In this paper, we will be using the term *object recognition* broadly to encompass both *image classification* (a task requiring an algorithm to determine what object classes are present in the image) as well as *object detection* (a task requiring an algorithm to localize all objects present in the image).

公开发布的数据集包含一组手动标注的*training*图像。同时，还发布了一组*test*图像，但未提供其手动标注。²参与者使用训练图像训练其算法，然后自动标注测试图像。这些预测标注将提交至*evaluation server*。评估结果将在竞赛期结束时公布，并邀请作者在交替举办的国际计算机视觉大会（ICCV）或欧洲计算机视觉大会（ECCV）研讨会上分享见解。

ILSVRC的标注分为两类：(1)

image-level annotation 图像中是否存在某物体类别的二元标签，例如，“这张图中有汽车”但“没有老虎”；(2) *object-level annotation* 图像中物体实例的紧密边界框及类别标签，例如，“有一个螺丝刀，中心位于位置(20,25)，宽度为50像素，高度为30像素”。

Large-scale challenges and innovations. 在构建数据集的过程中，需要解决若干挑战。从PASCAL VOC 2010的19,737张图像扩展到ILSVRC 2010的1,461,406张图像，以及从20个物体类别增加到1000个物体类别，带来了诸多难题。像其他数据集那样由少数标注者完成标注工作已不再可行（Fei-Fei et al., 2004; Criminisi, 2004; Everingham et al., 2012; Xiao et al., 2010）。为此，我们转而设计新颖的众包方法以收集大规模标注数据（Sutcliffe et al., 2012; Deng et al., 2009, 2014）。

在1000个物体类别中，部分类别可能不如PASCAL VOC的20个类别那样易于标注：例如成串出现的香蕉，其轮廓标注难度可能高于飞机、汽车等基础类别。超过百万张的图像规模使得标注所有物体的位置变得不可行（更不用说PASCAL VOC子集中包含的物体分割、人体部位等精细标注）。需要制定新的评估标准，以考虑到在此规模下获得完美人工标注可能无法实现的客观情况。

一旦挑战数据集被收集完成，其规模为物体识别算法的评估和新技术的开发提供了前所未有的机遇。随着大规模训练数据的可用性，新颖的算法创新不断涌现。广泛的物体类别范围促使人们需要能够区分视觉上非常相似的类别的算法。我们重点介绍最

本文中这些算法的成功，并将其性能与人类水平的准确度进行比较。

最后，ILSVRC中大量的物体类别使我们能够分析物体的统计特性及其对识别算法的影响。这类分析有助于更深入地理解物体识别，并为设计下一代通用物体识别算法提供依据。

Goals. 本文有三个关键目标：

1. 探讨创建这一大规模物体识别基准数据集所面临的挑战，
2. 强调由此努力带来的物体分类与检测领域的发展，
3. 并深入审视当前类别物体识别领域的研究现状。

这篇论文可能会引起致力于创建大规模数据集的研究人员的兴趣，同时也适合任何希望更深入了解大规模物体识别的历史与现状的人士。

收集的数据集以及关于ILSVRC的更多信息可以在以下位置找到：

<http://image-net.org/challenges/LSVRC/>

1.1 相关工作

我们简要讨论一些在构建基准图像数据集方面的先前工作。

Image classification datasets. Caltech 101（Fei-Fei等人，2004年）是最早用于多类别图像分类的标准化数据集之一，包含101个物体类别，通常每个类别有15-30张训练图像。Caltech 256（Griffin等人，2007年）将物体类别数量增加到256个，并添加了更具尺度变化和背景多样性的图像。TinyImages数据集（Torralba等人，2008年）包含8000万张从互联网收集的32x32低分辨率图像，使用WordNet（Miller，1995年）中的同义词集作为查询词。然而，由于这些数据未经人工验证，存在大量错误，因此不太适合用于算法评估。诸如15 Scenes（Oliva和Torralba，2001年；Fei-Fei和Perona，2005年；Lazebnik等人，2006年）或近年提出的Places（Zhou等人，2014年）等数据集则提供单一场景类别标签（与物体类别标签相对应）。

ImageNet数据集（Deng等人，2009年）是ILSVRC的支柱。ImageNet是一个依据WordNet层次结构（Miller，1995年）组织的图像数据集。WordNet中的每个概念（可能由多个单词或词组描述）被称为一个“同义词集”

² In 2010, the test annotations were later released publicly; since then the test annotation have been kept hidden.

“集合”或“同义词集”。ImageNet 为 WordNet 的 21,841 个同义词集填充了平均 650 张经过人工验证的全分辨率图像。因此，ImageNet 包含了 14,197,122 张带标注的图像，这些图像按照 WordNet 的语义层次结构进行组织（截至 2014 年 8 月）。ImageNet 在规模和多样性上都大于其他图像分类数据集。ILSVRC 使用 ImageNet 图像的一个子集来训练算法，并采用 ImageNet 的部分图像收集协议来标注额外的图像，用于测试算法。

Image parsing datasets. 许多数据集旨在提供比图像类别标签更丰富的图像标注。LabelMe (Russell 等人, 2007) 包含每张图像有多个物体的普通照片，它提供了物体周围的边界多边形标注，但物体名称未标准化：标注者可自由选择标注哪些物体以及为每个物体命名。SUN 2012 (Xiao 等人, 2010) 数据集包含 16,873 张经过人工清理和完整标注的图像，更适合标准的物体检测训练和评估。SIFT Flow (Liu 等人, 2011) 包含 2,688 张使用 LabelMe 系统标注的图像。LotusHill 数据集 (Yao 等人, 2007) 对 636,748 张图像和视频帧中的物体提供了非常详细的标注，但该数据集并非免费提供。若干数据集提供了像素级分割标注：例如包含 591 张图像和 23 个物体类别的 MSRC 数据集 (Criminisi, 2004)、包含 715 张图像和 8 个类别的斯坦福背景数据集 (Gould 等人, 2009)，以及包含 500 张标注了物体边界的图像的伯克利分割数据集 (Arbelaez 等人, 2011)。OpenSurfaces 从消费级照片中分割表面，并用表面属性（包括材质、纹理和上下文信息）进行标注 (Bell 等人, 2013)。

与 ILSVRC 最接近的是 PASCAL VOC 数据集 (Everingham 等人, 2010 年, 2014 年)，它为物体检测、图像分类、物体分割、人物布局和动作分类提供了一个标准化的测试平台。ILSVRC 中的许多设计选择都受到了 PASCAL VOC 的启发，并且本文详细讨论了这两个数据集之间的相似之处和差异。ILSVRC 在物体类别和图像数量上，将 PASCAL VOC 标准化训练和评估识别算法的目标扩展了一个数量级以上：PASCAL VOC 2012 包含 20 个物体类别和 21,738 张图像，而 ILSVRC 2012 则包含 100 个物体类别和 1,431,167 张标注图像。

最近发布的 COCO 数据集 (Lin 等人, 2014b) 包含超过 328,000 张图像，其中 250 万个物体实例经过人工分割。它的数量较少

与 ILSVRC 相比，COCO 的物体类别更少 (COCO 为 91 类，而 ILSVRC 物体检测为 200 类)，但每个类别的实例更多 (平均 27K，而 ILSVRC 物体检测约为 1K)。此外，它包含了 ILSVRC 目前尚未提供的物体分割标注。COCO 有望成为另一个重要的大规模基准数据集。

Large-scale annotation. ILSVRC 广泛使用亚马逊土耳其机器人 (Amazon Mechanical Turk) 来获取精确标注 (Soroikin 和 Forsyth, 2008 年)。诸如 (Welinder 等人, 2010 年; Sheng 等人, 2008 年; Vittayakorn 和 Hays, 2011 年) 等研究描述了该平台的质量控制机制。(Vondrick 等人, 2012 年) 对众包视频标注进行了详细综述。另一相关研究方向是通过精心设计的游戏获取标注，例如 (von Ahn 和 Dabbish, 2005 年)。我们在第 3.1.3 节、3.2.1 节和 3.3.3 节中提出了众包精确图像标注的新方法。

Standardized challenges. 存在多个与 ILSVRC 类似、具备标准化在线评估的数据集：前文提及的 PASCAL VOC (Everingham 等人, 2012)、用于无约束人脸识别的 Labeled Faces in the Wild (Huang 等人, 2007)、面向三维重建的 Reconstruction meets Recognition (Urtasun 等人, 2014)，以及用于自动驾驶计算机视觉的 KITTI (Geiger 等人, 2013)。这些数据集与 ILSVRC 共同为计算机视觉不同领域的进展提供了基准参照。诸如 (Torralba 和 Efros, 2011) 的研究工作，则强调了审视任何标准化数据集固有偏差的重要性。

1.2 论文结构

我们从第 2 节对 ILSVRC 挑战赛任务的简要概述开始。第 3 节详细描述了数据集的收集与标注过程。第 4 节讨论了大规模识别场景下算法的评估标准。第 5 节概述了 ILSVRC 参赛者所开发的方法。

第 6 节对 ILSVRC 结果进行了深入分析：6.1 节记录了大尺度识别技术多年来的进展，6.2 节得出 ILSVRC 结果具有统计显著性的结论，6.3 节全面分析了当前物体识别领域的发展现状，6.4 节将最先进的计算机视觉准确率与人类准确率进行了对比。我们在第 7 节进行总结，并讨论从 ILSVRC 中获得的经验教训。

2 Challenge tasks

ILSVRC的目标是评估照片内容，以实现检索和自动标注。测试图像在无初始标注的情况下呈现，算法需生成标签以指明图像中存在哪些物体。专门为此竞赛收集并标注了新的测试图像，这些图像不属于先前发布的ImageNet数据集（Deng et al., 2009）。

ILSVRC 多年来包含以下一项或多项任务（年份在括号内）：³

1. **Image classification** (2010-2014)：算法生成图像中存在的物体类别列表。 2.

Single-object localization (2011-2014)：算法生成图像中存在的物体类别列表，并提供一个轴对齐的边界框，用于指示*one*每个物体类别实例的位置和尺度。

3. **Object detection** (2013-2014)：算法生成图像中存在的物体类别列表，并提供一个轴对齐的边界框，用于指示每个物体类别*every*实例的位置和尺度。

本节概述了三个任务各自的历史与概况。表1展示了汇总统计数据。

2.1 图像分类任务

图像分类任务的数据包括从Flickr⁴和其他搜索引擎收集的照片，这些照片经过人工标注，包含1000个对象类别中的一种。每张图像都有一个真实标签。

对于每张图像，算法会生成一个存在于图像中的物体类别列表。标注质量基于与图像真实标签最匹配的标注进行评估（参见第4.1节）。

构建ImageNet是为了扩展图像分类数据集，使其覆盖英语中的大多数名词，使用了数千万张经过人工验证的照片（Deng等人，2009年）。ILSVRC的图像分类任务正是这一努力的直接延伸。从中选取并固定了一部分类别和图像，以提供一个标准化的基准，而ImageNet的其余部分则持续增长。

³ In addition, ILSVRC in 2012 also included a taster fine-grained classification task, where algorithms would classify dog photographs into one of 120 dog breeds (Khosla et al., 2011). Fine-grained classification has evolved into its own Fine-Grained classification challenge in 2013 (Berg et al., 2013), which is outside the scope of this paper.

⁴ www.flickr.com

2.2 单目标定位任务

单目标定位任务于2011年被提出，它建立在图像分类任务的基础上，旨在评估算法学习目标对象本身外观而非其图像上下文的能力。

单目标定位任务的数据集与图像分类任务所收集的照片相同，这些照片已手工标注了1000个物体类别中某一类的存在。每张图像包含一个真实标签。此外，该类别的每个实例都用一个轴对齐的边界框进行了标注。

对于每张图像，算法会生成一个存在于图像中的物体类别列表，以及一个指示每个物体类别一个实例位置和尺度的边界框。标注质量基于与真实标签最匹配的物体类别标签进行评估，同时要求预测实例的位置也必须准确（参见第4.2节）。

2.3 目标检测任务

物体检测任务在单物体定位的基础上更进一步，致力于解决图像中多类别物体的定位问题。多年来，该任务一直是PASCAL VOC挑战赛的核心内容，其规模维持在20个物体类别和数万张图像。然而，若要将物体类别和图像数量提升一个数量级，从数据集收集与标注的角度来看极具挑战性（详见第3.3节）。

检测任务的数据包括通过场景级查询从Flickr收集的新照片。这些图像用轴对齐的边界框进行标注，指示每个目标对象类别每个实例的位置和尺度。训练集还额外补充了：(a) 来自单对象定位任务的数据，其中仅包含一个对象类别所有实例的标注，以及(b) 已知不包含某些对象类别任何实例的负样本图像。

对于每张图像，算法会生成边界框，标示出所有目标对象类别实例的位置和尺度。标注质量通过*recall*（即检测到的目标对象实例数量）和*precision*（即算法产生的误检数量）进行评估（详见第4.3节）。

Task		Image classification	Single-object localization	Object detection
Manual labeling on training set	Number of object classes annotated per image	1	1	1 or more
	Locations of annotated classes	—	all instances on some images	all instances on all images
Manual labeling on validation and test sets	Number of object classes annotated per image	1	1	all target classes
	Locations of annotated classes	—	all instances on all images	all instances on all images

Table 1 ILSVRC各项任务所提供标注的概述。

3 Dataset construction at large scale

我们构建大规模物体识别图像数据集的过程包含三个关键步骤。

第一步是定义目标物体类别的集合。为此，我们从现有的ImageNet（Deng等人，2009年）类别中进行筛选。通过以WordNet为骨干（Miller，1995年），ImageNet已经负责消除词语歧义并将同义词合并到同一物体类别中。由于物体类别的选择在每个挑战任务中只需进行一次，我们结合自动启发式方法和人工后处理，为每个任务创建合适的目标类别列表。例如，对于图像分类，我们可能包含更广泛的场景类别，如某种海滩类型；但对于单物体定位和物体检测，我们希望仅关注那些能在图像中明确{v*}定位的物体类别（第3.1.1节和第3.3.1节）。

第二步是收集一组多样化的候选图像来代表所选类别。我们利用多种搜索引擎，结合自动与手动策略进行图像采集。针对不同的ILSVRC任务，这一流程会相应调整。例如，在物体检测任务中，我们重点通过“非洲野生动物园”等通用查询来收集场景类图像，以获取可能包含多个动物同框的画面（详见第3.3.2节）。

第三步（也是最富挑战性的一步）是对收集的数百万张图像进行标注，以获取一个干净的数据集。我们针对每个ILSVRC任务精心设计了众包策略。例如，用于定位和检测任务的边界框标注系统包含三个独立部分，以实现自动化的众包质量控制（第3.2.1节）。若要在合理预算内为物体检测任务完整标注所有目标物体类别，则需要额外的分层图像标注系统（第3.3.3节）。

我们依次描述ILSVRC各项任务的数据收集和标注流程：图像

分类（第3.1节）、单目标定位（第3.2节）和目标检测（第3.3节），重点阐述每个数据集的三个关键步骤。

3.1 图像分类数据集构建

图像分类任务测试算法对图像中存在的物体进行命名的能力，无需精确定位它们。

我们阐述了构建ILSVRC图像分类数据集时所做的选择：从ImageNet中选定目标对象类别（第3.1.1节），通过使用多个搜索引擎和多种语言的扩展查询集来收集多样化的候选图像（第3.1.2节），最后借助ImageNet精心设计的众包策略（Deng et al., 2009）对数百万张收集到的图像进行筛选（第3.1.3节）。

3.1.1 Defining object categories for the image classification dataset

用于图像分类任务的1000个类别选自ImageNet（Deng等人，2009年）的类别。这1000个同义词集的选择确保了同义词集之间没有重叠：对于任意同义词集 i 和 j ，在ImageNet层次结构中 i 不是 j 的祖先。这些同义词集是更大层次结构的一部分，在ImageNet中可能拥有子类别；然而，对于ILSVRC，我们不考虑它们的子类别。ILSVRC的同义词集层次结构可以视为完整ImageNet层次结构的“修剪”版本。图1展示了ILSVRC2012对象类别的多样性。

用于图像分类和单目标定位任务的1000个精确同义词集（synsets）在过去几年中发生了变化。迄今为止，在所有五次ILSVRC挑战中，有639个同义词集被持续使用。在挑战赛的第一年，同义词集是从当时可用的ImageNet同义词集中随机选取的，随后经过人工筛选，以确保目标类别不会过于冷门。随着




Fig. 1 ILSVRC图像分类与单目标定位任务中数据的多样性。针对八个维度中的每一个，我们沿该属性范围展示示例对象类别。每个对象类别的物体尺度、实例数量和图像杂乱度均使用第3.2.2节及附录B定义的度量标准进行计算。其余属性通过邀请受试者对1000个对象类别进行标注得出（Russakovsky等人，2013年）。

2011年的物体定位挑战中，有321个同义词集发生了变化：诸如“新西兰海滩”这类本质上难以定位的类别被移除，同时新增了来自ImageNet的、包含物体定位标注的部分新类别。在ILSVRC2012中，90个同义词集被替换为对应犬种细分类别的标签，以便评估更精细的物体分类能力，如图2所示。自2012年起，同义词集始终保持一致。附录A提供了ILSVRC2012-2014使用的完整物体类别列表。

3.1.2 Collecting candidate images for the image classification dataset

ILSVRC分类任务的图像收集采用了与构建ImageNet（Deng等人，2009年）相同的策略。训练图像直接取自ImageNet。使用该策略为ILSVRC收集的额外图像被随机划分为验证集和测试集。

我们简要概述这一过程；更多细节可参见(Deng et al., 2009)。候选图像通过向多个图像搜索引擎发起查询从互联网收集。对于每个同义词集，查询词为WordNet同义词集合。搜索引擎通常限制可检索图像数量（约数百至上千张）。为获取尽可能多的图像，我们通过将查询词与父同义词集中的词汇组合来扩展查询集——若该词汇同时出现在目标同义词集的词表中。例如查询“whippet”（根据WordNet释义为“在英国培育的一种灰猎犬型细长小型犬”）时，我们同时使用“whippet dog”和“whippet greyhound”。为进一步扩大并丰富候选图像池，我们将查询词翻译为其他语言，包括中文、西班牙语、荷兰语和意大利语，并借助对应语言的WordNet确保翻译准确性。

3.1.3 Image classification dataset annotation

为图像标注对应的物体类别遵循了ImageNet（Deng等人，2009年）采用的策略。我们在此简要概述。

为了收集高精度的数据集，我们依靠人工来验证前一步为给定同义词集收集的每个候选图像。这是通过使用亚马逊机械土耳其人（AMT）实现的，这是一个在线平台，用户可以在上面发布任务以获取金钱报酬。凭借全球用户基础，AMT特别适合大规模标注。在我们的每一个

在标注任务中，我们向用户展示一组候选图像以及目标同义词集的定义（包含维基百科链接）。随后请用户验证每张图像是否包含该同义词集所指代的物体。我们鼓励用户选择图像时无需考虑遮挡情况、物体数量或场景杂乱程度，以确保数据多样性。

尽管用户被要求做出准确判断，我们仍需建立质量控制体系以确保这种准确性。这涉及两个需要考虑的问题。首先，人类用户会犯错，且并非所有用户都遵循指示。其次，用户之间并不总能达成一致，尤其是对于更微妙或易混淆的同义词集，通常位于树状结构的更深层级。解决这些问题的方法是让多位用户独立标注同一张图像。只有当图像获得令人信服的多数票时，才被视为正例。然而我们观察到，不同类别需要用户之间不同水平的共识。例如，虽然缅甸猫图像可能需要五位用户才能达成良好共识，但普通猫图像所需的用户数量则少得多。我们开发了一种简单算法，用于动态确定不同图像类别所需的赞同票数。对于每个同义词集，我们首先随机抽样一个初始图像子集。每张图像至少由10位用户进行投票。随后我们得到一个置信度评分表，该表显示了在用户投票共识下图像属于优质图像的概率。对于该同义词集中剩余的候选图像，我们会持续进行AMT用户标注，直至达到预设的置信度评分阈值。

Empirical evaluation. 对大规模众包图像标注系统准确性的评估是在整个ImageNet数据集上进行的（Deng等人，2009年）。在哺乳动物和车辆子树的每个树深度上，随机抽取了共计80个同义词集。一个独立的受试者小组验证了每张图像的正确性。在所有同义词集上，平均达到了99.7%的精确度。由于图像标注流程保持不变，我们预期在ILSVRC图像分类数据集上会有相似的准确性。为验证这一点，我们手动检查了1500张ILSVRC2012-2014图像分类测试集图像（该测试集在这三年中保持不变）。我们发现了5个标注错误，对应的精确度如预期为99.7%。

3.1.4 Image classification dataset statistics

利用前几节描述的图像收集和标注流程，我们收集了一个用于ILSVRC分类任务的大规模数据集。



Fig. 2 与标准的PASCAL VOC基准相比，ILSVRC数据集包含了更多细粒度类别；例如，在ILSVRC2012-2014分类和单目标定位任务中，取代PASCAL的“狗”类别的是120种不同的犬种。

包含1000个对象类别，约120万张训练图像、5万张验证图像和10万张测试图像。表2（顶部）记录了挑战赛历年数据集的规模。

3.2 单目标定位数据集构建

单目标定位任务评估算法对某一物体类别单个实例的定位能力。该任务于2011年ILSVRC中作为体验性任务首次亮相，并于2012年成为ILSVRC的正式竞赛项目。

关键挑战在于开发一种可扩展的众包方法用于物体边界框标注。我们三步自验证流程在3.2.1节中详述。完成数据集收集后，我们在3.2.2节进行详细分析，以确保数据集具有充分的多样性，适用于物体定位算法的评估。

Object classes and candidate images. 单目标定位任务的对象类别与上文第3.1节描述的图像分类任务对象类别相同。定位任务的训练图像是图像分类任务所用训练图像的一个子集，而验证图像和测试图像在两项任务中保持一致。

Bounding box annotation. 回想一下，在图像分类任务中，每张图像都被标注了一个

物体类别标签，对应图像中存在的一个物体。对于单物体定位任务，每个验证和测试图像以及部分训练图像都标注了该物体每个实例的轴对齐边界框。

每个边界框都要求尽可能小，同时包含物体实例的所有可见部分。另一种标注方法可能是标注物体的 *full (estimated) extent*：例如，如果一个人的腿部被遮挡，只有躯干可见，边界框可以绘制为包含腿部可能的位置。然而，这种替代方法本质上具有模糊性和不明确性，会导致标注者和研究人员之间的分歧（这个物体的真实“最可能”范围是什么？）。我们遵循仅标注可见物体部分的标准协议（Russell等人，2007年；Everingham等人，2010年）。⁵

3.2.1 Bounding box object annotation system

我们总结了（Su等人，2012）中详细描述众包边界框标注系统。目标是构建一个完全自动化的系统，

⁵ Some datasets such as PASCAL VOC (Everingham et al., 2010) and LabelMe (Russell et al., 2007) are able to provide more detailed annotations: for example, marking individual object instances as being *truncated*. We chose not to provide this level of detail in favor of annotating more images and more object instances.

Image classification annotations (1000 object classes)

Year	Train images (per class)	Val images (per class)	Test images (per class)
ILSVRC2010	1,261,406 (668-3047)	50,000 (50)	150,000 (150)
ILSVRC2011	1,229,413 (384-1300)	50,000 (50)	100,000 (100)
ILSVRC2012-14	1,281,167 (732-1300)	50,000 (50)	100,000 (100)

Additional annotations for single-object localization (1000 object classes)

Year	Train images with bbox annotations (per class)	Train bboxes annotated (per class)	Val images with bbox annotations (per class)	Val bboxes annotated (per class)	Test images with bbox annotations
ILSVRC2011	315,525 (104-1256)	344,233 (114-1502)	50,000 (50)	55,388 (50-118)	100,000
ILSVRC2012-14	523,966 (91-1268)	593,173 (92-1418)	50,000 (50)	64,058 (50-189)	100,000

Table 2 ILSVRC图像分类任务（上）与单目标定位任务（下）的规模。括号中的数字对应（每类最少数量 - 每类最多数量）。1000个类别每年有所变动，但在同一年份中图像分类与单目标定位任务的类别保持一致。图像分类任务中的所有图像均可用于单目标定位任务。

高精度且成本效益显著。给定一组已验证存在感兴趣对象的图像，系统会为每张图像中该对象的每个实例收集一个紧密的边界框。

有两个要求：

- **Quality** 每个边界框都需要是紧凑的，即包含对象所有可见部分的最小边界框。这有助于物体检测学习算法，通过提供每个物体实例的精确位置；
- **Coverage** 每个物体实例都需要有一个边界框。这对于训练定位算法很重要，因为它明确告知学习算法哪些部分不属于该物体。

构建此类系统的核心挑战在于以最低成本有效控制数据质量。我们的关键观察是：绘制边界框远比回答多项选择题更为困难且耗时。因此，通过附加验证任务进行质量控制，比基于共识的算法更具成本效益。这催生了以下采用简单基础子任务的工作流程：

1. Drawing 一名工作人员在给定图像中为一个物体实例绘制一个边界框。**2. Quality verification** 第二名工作人员检查边界框是否正确绘制。**3.**

Coverage verification 第三名工作人员检查是否所有物体实例都已标注边界框。

子任务的设计遵循两个原则。首先，任务尽可能简化。例如，我们不要求工人在同一张图像上绘制所有边界框，而只要求绘制一个。这降低了任务的复杂度。其次，每个任务都有固定且可预估的工作量。例如，假设输入图像是

当清洁（物体存在性被正确验证）且覆盖验证任务给出正确结果时，绘图任务的工作量始终是提供恰好一个边界框。

任务2和3的质量控制通过嵌入已知正确答案的“黄金标准”图像来实现。这些子任务的工作人员培训详情见(Su et al., 2012)。

Empirical evaluation. 该系统在ImageNet (Deng等人, 2009)的10个类别上进行评估：气球、熊、床、长椅、海滩、鸟、书架、篮球框、瓶子和人物。每个类别随机抽取200张图像。在图像层面，我们的评估显示97.9%的图像被边界框完全覆盖。对于剩余的2.1%，部分边界框存在缺失。然而，这些均为困难案例：尺寸过小、边界模糊或存在强烈阴影。

在边界框层面，99.2%的边界框是精确的（边界框明显紧凑）。剩下的0.8%略有偏差。未发现任何边界框与真实标注的交并比重叠低于50%。

关于总体成本的额外评估以及质量控制的分析可在(Su et al., 2012)中查阅。

3.2.2 Single-object localization dataset statistics

利用上述标注流程，我们为ILSVRC单物体分类任务收集了大量边界框标注数据。验证集中的全部5万张图像及测试集中的10万张图像均已标注，所有真实物体类别的实例均被边界框标出（每张图像仅含一个物体类别）。此外，ILSVRC2011中25%的训练图像也完成了边界框标注。

以相同的方式标注边界框，产生了超过31万张标注图像，包含超过34万个标注对象实例。在ILSVRC2012中，40%的训练图像被标注，产生了超过52万张标注图像，包含超过59万个标注对象实例。表2（底部）记录了该数据集的规模。

除了数据集的大小，我们还分析了这些图像中物体定位的难度水平，并与PASCAL VOC基准进行了比较。我们计算了ILSVRC2012单物体定位验证集图像与PASCAL VOC 2012验证图像的统计信息。

现实场景中可能包含多个同类物体的实例，而相邻的物体实例尤其难以精确分割。在ILSVRC数据集中，平均每个正样本图像包含1.61个目标物体实例，每个实例平均有0.47个相邻实例（即同一物体类别中相邻的实例）。这一数据与PASCAL数据集中平均每个正样本图像包含1.69个实例、每个实例平均有0.52个相邻实例的情况相当。

如（Hoiem等人，2012年）所述，较小的物体往往明显更难定位。在PASCAL数据集的平均物体类别中，物体占据图像面积的24.1%，而在ILSVRC中这一比例为35.8%。然而，PASCAL仅包含20个物体类别，而ILSVRC有1000个。ILSVRC中平均物体尺寸最小的537个类别，其物体占图像面积的比例与PASCAL相同：24.1%。因此，尽管ILSVRC图像中的物体实例平均尺寸更大，但其物体类别数量是PASCAL VOC的25倍以上，且这些类别具有相同的平均物体尺度。

附录B和（Russakovsky等人，2013年）提供了更多比较。

3.3 目标检测数据集构建

ILSVRC的目标检测任务评估算法对图像中存在的*all*个目标对象的*all*个实例进行命名和定位的能力。这比目标定位更具挑战性，因为某些对象实例可能较小/被遮挡/难以准确定位，而算法需要定位所有实例，而不仅仅是它认为最容易找到的那一个。

收集目标检测数据集面临三个关键挑战。第一个挑战是选择那些在杂乱照片中常见且适合用于目标检测性能基准测试的物体类别。我们的方法依赖于目标定位数据集的统计数据以及PASCAL VOC挑战赛的传统做法（第3.3.1节）。

Class name in PASCAL VOC (20 classes)	Closest class in ILSVRC-DET (200 classes)	Avg object scale (%)	
		PASCAL VOC	ILSVRC-DET
aeroplane	airplane	29.7	22.4
bicycle	bicycle	29.3	14.3
bird	bird	15.9	20.1
boat	watercraft	15.2	16.5
bottle	wine bottle	7.3	10.4
bus	bus	29.9	22.1
car	car	14.0	13.4
cat	domestic cat	46.8	29.8
chair	chair	12.8	10.1
cow	cattle	19.3	13.5
dining table	table	29.1	30.3
dog	dog	37.0	28.9
horse	horse	29.5	18.5
motorbike	motorcycle	32.0	20.7
person	person	17.5	19.3
potted plant	flower pot	12.3	8.1
sheep	sheep	12.2	17.3
sofa	sofa	41.7	44.4
train	train	35.4	35.1
tv/monitor	tv or monitor	14.6	11.2

Table 3 PASCAL VOC（Everingham等人，2010）与ILSVRC检测任务中物体类别的对应关系。物体尺度指物体实例所占图像面积的比例（以百分比报告）。该数据基于PASCAL VOC 2012和ILSVRC-DET的验证集计算得出。在20个PASCAL VOC类别中，平均物体尺度为24.1%；在20个对应的ILSVRC-DET类别中，平均物体尺度为20.3%。第3.3.4节将报告更多数据集统计信息。

第二个挑战是获取比用于图像分类和单目标定位数据集的场景图像更为多样化的图像集。第3.3.2节描述了如何尽可能利用单目标定位数据集中的数据，并通过使用数百个手动设计的高级查询从Flickr获取的图像进行补充的过程。

第三个也是最大的挑战是完整标注数据集中所有对象。这项工作分为两部分：3.3.3节描述了第一部分——我们通过分层策略获取每张图像中所有目标对象的列表。由于在此规模下，为每个（图像，对象类别）组合单独创建标注任务已不可行，这一步骤显得尤为必要。附录E阐述了第二部分：利用3.2.1节中的单对象定位边界框标注流程，并辅以额外验证来确保每个对象的*every*实例都严格对应*one*个边界框，从而完成对这些对象的边界框标注。

3.3.1 Defining object categories for the object detection dataset

为检测任务手工选取了200个物体类别，每个类别对应ImageNet中的一个同义词集。这些类别大多选择为基础层级的物体分类，便于人们识别和标注。其设计理念在于：若需要更精细的划分，可在此任务开发的物体检测系统基础上，结合细粒度分类模型对物体进行进一步归类。⁶ 与1000个分类类别类似，同义词集的选取遵循非重叠原则：对于任意同义词集 i 和 j ，在ImageNet层级结构中 i 不是 j 的祖先节点。

2013年选定的200个目标检测类别是基于ILSVRC 2012分类与定位数据集确定的。我们从1000个目标类别及其边界框标注出发，首先剔除了所有在图像中通常显得过于“庞大”的类别（即目标平均面积超过图像面积的50%），例如T恤衫、蜘蛛网或井盖等类别。随后，我们人工排除了所有我们认为不适合用于检测的类别，例如干草、理发店或披风。经过筛选后剩余494个目标类别，这些类别被合并为基础层级类别：例如，不同种类的鸟类被统一归为“鸟类”。ILSVRC2014中沿用了相同的类别设置。附录D完整列出了ILSVRC2013-2014使用的目标类别清单（其层级结构遵循第3.3.3节所述的分类体系）。

在铭记PASCAL VOC数据集传统的同时，我们也尽力确保这200个类别尽可能涵盖20个PASCAL VOC类别。表3展示了对应关系。所做的调整是为了保证更精确、更一致的众包标注。对应关系最弱的物体类别是PASCAL VOC中的“盆栽植物”，对应ILSVRC中的“花盆”。“盆栽植物”原是PASCAL VOC所有类别中最难保持标注一致性的对象之一，为通过众包获得精确标注，我们不得不将定义限制为更具体的物体。

3.3.2 Collecting images for the object detection dataset

检测任务中的许多图像采集方式与ImageNet中的图像不同，且分类任务中的图像采集方式也有所差异。

⁶ Some of the training objects are actually annotated with more detailed classes: for example, one of the 200 object classes is the category “dog,” and some training instances are annotated with the specific dog breed.




Fig. 3 为检测任务收集的图像总结。绿色（粗体）框中的图像已完整标注了所有200个检测对象类别的全部实例。表4列出了完整的统计数据。

检测和单目标定位任务。图3总结了所收集图像的类型。理想情况下，所有这些图像都应是完全标注了所有目标类别的场景图像。然而，考虑到预算限制，我们的目标是提供尽可能多的合适检测数据，即使这些图像来自少数不同的来源和分布。

验证和测试检测集的图像来自两个来源（每个来源的图像百分比在括号中）。第一个来源（77%）是来自ILSVRC2012单目标定位验证集和测试集的图像，对应200个检测类别（或它们在ImageNet层级结构中的子类）。目标对象占据图像面积超过50%的图像被剔除，因为它们不太可能包含其他感兴趣的对象。第二个来源（23%）是专门为检测任务从Flickr收集的图像。我们使用大量手动定义的查询（如“小厨房”或“澳大利亚动物园”）在Flickr上检索可能包含多个感兴趣对象的场景图像。附录C包含完整列表。我们还添加了成对查询，或包含两个目标对象名称的查询（如“老虎狮子”），这类查询也经常返回杂乱场景的图像。

图4展示了两类验证图像的随机集合。图像被随机分割，其中33%进入验证集，67%进入测试集。 $\{v^*\}$

检测任务的训练集来自三个图像来源（每个来源的图像百分比在括号中）。第一个来源（63%）是ILSVRC2012单目标定位任务中所有与200个检测类别（或它们在ImageNet层级中的子类别）对应的训练图像。我们没有按物体大小进行筛选，以便让团队能够充分利用—

⁷ The validation/test split is consistent with ILSVRC2012: validation images of ILSVRC2012 remained in the validation set of ILSVRC2013, and ILSVRC2012 test images remained in ILSVRC2013 test set.




Fig. 4 ILSVRC检测验证集中随机选取的图像。前4行的图像来自ILSVRC2012单目标定位验证集，后4行的图像是通过场景级查询从Flickr收集的。

所有可用正例的标签。第二个来源（24%）是负面图像，这些图像原本是ImageNet收集过程的一部分，但被投票判定为负面：例如，部分图像是从Flickr和搜索引擎中为ImageNet同义词集“动物”收集的，但在人工验证步骤中未获得足够票数被认定为包含“动物”。这些图像为检测任务进行了人工重新验证，以确保它们实际上不包含目标物体。第三个来源（13%）

这些图像是从Flickr专门为检测任务收集的。这些图像按照与验证集和测试集中第二类图像相同的协议，被添加至ILSVRC2014。此举旨在使训练和测试的数据分布更为接近。




Fig. 5 考虑二元多标签标注问题。对于每个输入（如图像）和每个标签（如物体），目标是确定标签的存在或缺失（+ 或 -）（例如判断图像中是否存在该物体）。当考虑到数据的真实世界结构时——标签间的相关性、概念的层次化组织以及标签的稀疏性——多标签标注的效率将大幅提升。

3.3.3 Complete image-object annotation for the object detection dataset

为物体检测任务标注图像的关键挑战在于，所有图像中的所有物体都需要被标记。假设有 N 个输入（图像）需要标注 K 个标签（物体）的存在与否。一种天真的方法会为每个输入和标签的组合向人类提问，需要进行 NK 次查询。然而， N 和 K 可能非常大，这种穷举方法的成本很快就会变得难以承受。例如，为检测任务标注60,000张验证和测试图像中200个物体类别的存在与否，其工作量将比分类任务中标注150,000张验证和测试图像（每张图像仅含1个物体）多出80倍——这甚至还未计入为每个物体实例收集边界框标注的额外成本。这种方法很快就会变得不可行。

在（Deng等人，2014）中，我们研究了可扩展的多标签标注策略，即如何高效地从人类标注者处为项目集合获取多个标签。我们利用了现实应用场景中标签的三个关键观察（如图5所示）：

1. Correlation. 标签子集通常高度相关。例如计算机键盘、鼠标和显示器等物体在图像中频繁同时出现。类似地，某些标签往往同时全部缺失。例如所有需要电力的物体在户外拍摄的照片中通常都不存在。这表明我们可以通过将多个标签分组为单一人工查询项，来推测多个标签的取值。与其逐一检查照片中是否存在狗、猫、兔子等，我们只需确认

关于“动物”组，如果答案为否，则意味着该组中所有类别的答案均为否。

2. Hierarchy. 上述将狗、猫、兔子等归类为动物的例子隐含了一个前提：标签可以被分组，且人类能够高效地回答关于整个组别的查询。这引出了我们的第二个关键发现：人类将语义概念组织成层次结构，并能够在更高的语义层次上进行高效分类（Thorpe等人，1996），例如，人类判断图像中是否存在动物的速度，与判断每种具体动物个体的速度同样快。这能带来显著的成本节约。

3. Sparsity. 每张图像的标签值往往具有稀疏性，即一张图像不太可能包含超过十几种物体类型，这仅占数百种物体类别中的一小部分。这种特性使得我们能够通过快速填充“否”来迅速排除大量物体。在高度稀疏的情况下，高效算法的成本可以随物体数量呈对数增长，而非线性增长。

我们提出了利用上述直觉的算法策略。关键在于为人类选择一系列查询，使得我们仅需朴素方法成本的一小部分就能达到相同的标注效果。主要挑战包括如何衡量查询的成本与效用、如何构建有效的查询，以及如何动态排序。关于通用算法的详细描述，连同理论分析和实证评估，已在（Deng et al., 2014）中给出。

Application of the generic multi-class labeling algorithm to our setting. 通用算法基于从训练集中学习到的物体标签统计信息，自动选择最具信息量的查询进行提问。在我们涉及200个物体类别的情况下，由于获取训练集本身具有挑战性，我们选择手动设计查询问题。我们创建了一个层次化的查询体系，问题类型为“图像中是否有……？”。例如，一个高层级的问题是“图像中是否有动物？”。我们针对每张待标注图像向众包工作者提出这个问题。“动物”问题的子问题则对应具体的动物类别：例如“图像中是否有哺乳动物？”或“图像中是否有无腿动物？”。为高效标注图像，这类问题仅在对已确定包含动物的图像进行提问。200个字节节点问题对应200个目标物体，例如“图像中是否有猫？”。图6展示了该算法的几次示例迭代过程。

算法1是用于标注图像中每个目标对象存在与否的正式算法




Fig. 6 我们的算法动态选择下一个查询，以高效确定每个图像中每个对象的存在与否。绿色表示肯定标注，红色表示否定标注。这个简化示例展示了算法在针对一组图像中某个标签（猫）的典型执行过程。

类别。考虑到这一算法，问题的层级结构遵循以下原则构建：误判只会增加额外成本，而漏判则会显著影响标注质量。因此，始终应选择更通用、歧义更少的问题，例如“图像中有哺乳动物吗？”，而非提出过于具体但可能产生歧义的问题，例如“图像中有能爬树的动物吗？”。构建这一层级结构的过程出乎意料地耗时，需要多次迭代以确保标注的高准确性并避免问题歧义。附录D展示了构建的层级结构。

Bounding box annotation. 在所有图像都被标记了所有对象类别的存在与否后，我们使用第3.2.1节中描述的边界框系统，并结合附录E中的一些额外修改，来标注每个存在的对象类别中每个实例的位置。

3.3.4 Object detection dataset statistics

使用上述流程，我们为ILSVRC目标检测任务收集了一个大规模数据集。该数据集包含200个对象类别，约45万张训练图像、2万张验证图像和4万张测试图像。表4记录了历年挑战赛中数据集的规模变化。ILSVRC2013与ILSVRC2014之间的主要差异在于新增了60,658张完整标注的训练图像。

在ILSVRC之前，目标检测的基准是PASCAL VOC挑战赛（Everingham等人，2010年）。ILSVRC的目标类别数量是PASCAL VOC的10倍（200 vs 20），完全标注的训练图像数量是10.6倍（60,658 vs 5,717），训练目标数量是35.2倍（478,807 vs 13,609），验证图像数量是3.5倍（20,121 vs 5823），验证目标数量是3.5倍（55,501 vs 15,787）。在验证集上，ILSVRC每张图像有2.8个标注目标，而PASCAL VOC为2.7个。ILSVRC中的平均目标占据图像面积的17.0%，而PASCAL VOC中为20.7%；表3包含

Input 图像 i ，查询 Q ，有向图 G 覆盖 Q **Output**: 标签 $L: Q \rightarrow \{ \text{“是”}, \text{“否”} \}$ 初始化标签
 $L(q) = \emptyset \forall q \in Q$; 初始化候选 $C = \{q: q \in \text{Root}(G)\}$
while C not empty **do** 获取查询 $q^* \in C$ 的答案 A
if $L(q^*) \leftarrow A$; **then** $C \setminus \{q^*\}$;
 $\text{Chldr} = \{q \in \text{Children}(q^*, G): L(q) = \emptyset\}$;
else $C \cup \text{Chldr}$;
 $\text{Des} = \{q \in \text{Descendants}(q^*, G): L(q) = \emptyset\}$;
 $L(q) = \text{“no”} \forall q \in \text{Des}$; $C = C \setminus \text{Des}$; **end**
end

Algorithm 1: 完整多类别标注算法。这是(Deng et al., 2014)中所述算法的一个特例。我们手动构建了一个问题层次结构 G 。所有根问题都会在每个图像上提问。若图像 i 对查询 q^* 的回答为“否”，则假定所有满足“ q 是层次结构中 q^* 的后代节点”条件的查询 q 答案均为“否”。我们将持续提问直至所有查询获得回答。对于来自单物体定位任务的图像，我们使用已知物体标签来初始化 L 。

每类比较。此外，ILSVRC包含了各种各样的物体，包括微小物体，如太阳镜（平均占图像面积的1.3%）、乒乓球（平均占图像面积的1.5%）和篮球（平均占图像面积的2.0%）。

4 Evaluation at large scale

数据集收集完成后，我们需要为算法定义标准化的评估流程。部分衡量标准已由现有数据集确立，例如用于图像分类的Caltech 101（Fei-Fei等，2004）以及同时涵盖图像分类与目标检测的PASCAL VOC（Everingham等，2012）。为将这些评估流程适配于大规模场景，我们必须解决三个关键挑战：首先，在图像分类与单目标定位任务中，由于数据集规模限制，每张图像仅能标注一个物体类别，这可能导致评估过程中的歧义（解决方案见第4.1节）；其次，对包含密集物体群的图像进行实例定位评估存在固有困难（解决方案见第4.2节）；最后，评估图像中仅占少量像素的物体实例定位极具挑战性（解决方案见第4.3节）。

在本节中，我们描述了针对ILSVRC三项任务中每一项的标准化评估标准。

Object detection annotations (200 object classes)

Year	Train images (per class)	Train bboxes annotated (per class)	Val images (per class)	Val bboxes annotated (per class)	Test images
ILSVRC2013	395909 (417-561-66911 pos, 185-4130-10073 neg)	345854 (438-660-73799)	21121 (23-58-5791 pos, rest neg)	55501 (31-111-12824)	40152
ILSVRC2014	456567 (461-823-67513 pos, 42945-64614-70626 neg)	478807 (502-1008-74517)	21121 (23-58-5791 pos, rest neg)	55501 (31-111-12824)	40152

Table 4 ILSVRC目标检测任务的规模。括号中的数字对应（每类最小数量 - 每类中位数数量）
c类 - 每类最大数量）。

我们进一步详细阐述了这些以及其他在大规模评估中较为次要的挑战。附录F描述了提交协议以及举办竞赛本身的其他细节。

4.1 图像分类

ILSVRC分类任务的规模（1000个类别及超过百万张图像）使得为每张图像中的每个物体实例进行标注成本极高。因此，在该数据集中，每张图像仅标注一个物体类别。这给评估带来了模糊性。例如，一张图像可能被标注为“草莓”，但其中同时包含草莓和苹果。此时算法将无法确定应识别两个物体中的哪一个。针对图像分类任务，我们允许算法识别图像中的多个物体（最多5个），只要其中一个物体与真实标签相符就不会受到惩罚。图7（顶部行）展示了一些示例。

具体来说，每张图像 i 都有一个单独的类别标签 C_i 。算法可以返回 5 个标签 $c_{i1}, \dots, c_{i5}$ ，若存在某个 j 使得 $c_{ij} = C_i$ 成立，则视为正确。

让预测的误差 $d_{ij} = d(c_{ij}, C_i)$ 在 $c_{ij} \neq C_i$ 时为 1，否则为 0。算法的误差是算法在测试图像上犯错的比率：

$$\text{error} = \frac{1}{N} \sum_{i=1}^N \min_j d_{ij} \quad (1)$$

我们使用了两种额外的误差度量方法。首先，我们评估了top-1误差。在这种情况下，如果算法最高置信度的输出标签 c_{i1} 与真实类别 C_i 不匹配，则算法会受到惩罚。其次，我们评估了层次误差。其直观思想是：混淆两个相近的类别（例如两种不同品种的狗）不如将狗误认为集装箱船那样有害。对于层次标准，一次错误分类的代价 $d(c_{ij}, C_i)$ 被定义为最低共同祖先的高度。

c_{ij} 和 C_i 在ImageNet层次结构中的最近公共祖先。节点的高度是到叶节点的最长路径长度（叶节点的高度为零）。

然而，在实践中我们发现，所有三种误差度量（top-5、top-1和分层误差）得出的结果排序完全一致。因此，自ILSVRC2012起，我们便统一采用最简单且最适配该数据集的top-5评估指标。

4.2 单目标定位

单目标定位的评估与物体分类类似，同样采用前5名的标准，允许算法返回未标注的物体类别而不受惩罚。然而，现在算法只有在同时正确识别目标类别 C_i 并准确定位其一个实例时，才被视为正确。图7（中间行）展示了一些示例。

具体而言，一幅图像与物体类别 C_i 相关联，该物体类别的所有实例均用边界框 B_{ik} 进行标注。算法返回类别标签 c_{ij} 的 $\{(c_{ij}, b_{ij})\}_{j=1}^5$ 及其对应位置 b_{ij} 。预测 j 的误差为：

$$d_{ij} = \max(d(c_{ij}, C_i), \min_k d(b_{ij}, B_{ik})) \quad (2)$$

这里 $d(b_{ij}, B_{ik})$ 是定位误差，定义为：若边界框 b_{ij} 与 B_{ik} 的交集面积除以其并集面积大于 0.5，则为 0，否则为 1。（Everingham 等人，2010）算法的误差按公式 1 计算。

在某些图像中评估定位本身就很困难。以一堆香蕉或一箱苹果的照片为例。将这些图像分类为包含香蕉或苹果很容易，甚至可能定位到每种水果的几个实例。然而，为了评估的准确性，每个香蕉或苹果的实例都需要被标注，而这可能无法实现。为了处理那些定位单个物体实例本身存在歧义的图像，自ILSVRC2012以来，我们手动剔除了3%至5%的图像。图8展示了一些被剔除图像的示例。




Fig. 7 ILSVRC中的任务。第一列展示了示例图像上的真实标注，接下来的三列则显示了三个样本输出及其对应的评估分数。



Fig. 8 在ILSVRC2012单目标定位验证集中标记为“困难”的图像。详情请参阅第4.2节。

4.3 目标检测

物体检测的标准采用了PASCAL VOC（Everingham等人，2010年）的方法。该标准旨在对算法因遗漏物体实例、对同一实例进行重复检测以及产生误报检测而进行惩罚。图7（底行）展示了相关示例。

对于每个物体类别和每张图像 I_i ，算法会返回预测检测结果 (b_{ij}, s_{ij}) ，包含预测位置 b_{ij} 和置信度分数 s_{ij} 。这些检测结果通过算法2与真实标注框 $\{B_{ik}\}$ 进行贪心匹配。对于图像 i 上的每个检测结果 j ，若检测成立，算法将返回 $z_{ij} = 1$ 。

根据阈值标准与真实边界框匹配时，该值为1，否则为0。对于给定的物体类别，设 N 为所有图像中真实实例的总数。给定阈值 t ，定义 $recall$ 为算法检测出的 N 个物体所占比例， $precision$ 为算法返回的总检测结果中正确检测所占的比例。具体而言，

$$Recall(t) = \frac{\sum_{ij} 1[s_{ij} \geq t] z_{ij}}{N} \quad (3)$$

$$Precision(t) = \frac{\sum_{ij} 1[s_{ij} \geq t] z_{ij}}{\sum_{ij} 1[s_{ij} \geq t]} \quad (4)$$

Input 对于给定物体类别，图像 I 上带有置信度分数 $\{(b_j, s_j)\}_{j=1}^M$ 的边界框预测与真实框 B 。 **Output**: 预测 j 是否为真正检测的二元结果 $\{z_j\}_{j=1}^M$ 。令 $\mathcal{U} = \mathcal{B}$ 为未匹配物体的集合；将 $\{(b_j, s_j)\}_{j=1}^M$ 按 s_j 降序排列；
for $j=1 \dots M$ **do** 令 $\mathcal{C} = \{B_k \in \mathcal{U} : \text{IOU}(B_k, b_j) \geq \text{阈值}(B_k)\}$; **if** $\mathcal{C} \neq \emptyset$ **then** 令 $k^* = \arg \max_{\{k : B_k \in \mathcal{C}\}} \text{IOU}(B_k)$; **else** 设置 $\mathcal{U} = \mathcal{U} \setminus B_{k^*}$; 因是真正检测，设置 $z_j = 1$;
 因是假正检测，设置 $z_j = 0$; **end**

Algorithm 2: 贪婪匹配物体检测输出与真实标签的算法。标准阈值 $(B_k) = 0.5$ (Everingham等人, 2010年)。ILSVRC使用公式5计算阈值 (B_k) ，以更好地处理低分辨率物体。

评估算法在给定对象类别上的最终指标是通过改变阈值 t 在不同召回率水平上获得的 *average precision*。每个对象类别的获胜者是平均精度最高的团队，而挑战赛的获胜者则是在最多对象类别上获胜的团队。⁸

Difference with PASCAL VOC. 评估图像中占据极少像素的物体实例的定位是一项挑战。PASCAL VOC 的方法是将此类实例标记为“困难”并在评估时忽略它们。然而，由于 ILSVRC 包含了更多样化的物体类别，例如“指甲”和“乒乓球”等存在许多极小实例的类别，因此在评估中纳入即使是非常小的物体实例也至关重要。

在算法2中，若 $\text{IOU}(b, B) \geq \text{thr}(B)$ ，则预测边界框 b 被认为被真实边界框 B 正确定位。PASCAL VOC 指标采用阈值 $\text{thr}(B) = 0.5$ 。然而对于小物体，即使几个像素的偏差根据此阈值也显得不可接受。例如，考虑一个尺寸为 10×10 像素的物体 B ，若检测窗口为 20×20 像素且完全包含该物体。此时每个维度的误差约为5像素，这接近人类标注的平均误差水平。但此情况下的交并比(IOU)仅为 $100/400 = 0.25$ ，远低于0.5的阈值。因此

对于较小的物体，我们在ILSVRC中放宽了阈值，允许标注在物体周围每个方向上平均延伸最多5个像素。具体来说，如果真实边界框 B 的尺寸为 $w \times h$ ，那么

$$\text{thr}(B) = \min \left(0.5, \frac{wh}{(w+10)(h+10)} \right) \quad (5)$$

实际上，这仅改变了尺寸小于约 $25 \times$ 像素的物体的阈值，并影响了检测验证集中5.5%的物体。

Practical consideration. ILSVRC检测评估中一个额外的实际考虑是微妙且直接源于ILSVRC的规模。在PASCAL中，算法通常会在测试集上为每个类别返回许多检测结果，包括那些置信度较低的检测。这使得算法至少在极低精确度的范围内能够达到高召回率。而在ILSVRC检测测试集上，如果算法为每张图像的每个物体返回10个边界框，这将导致 $10 \times 200 \times 40 \times 80$ M次检测。每次检测包含图像索引、类别索引、4个边界框坐标和置信度分数，因此每次检测大约需要28字节。完整的检测结果集将需要 2×24 Gb来存储并提交给评估服务器，这是不切实际的。这意味着算法被隐含要求将其预测限制在仅最有信心的位置。

5 Methods

ILSVRC数据集及其竞赛在大规模图像识别与检索领域推动了显著的算法进步。

5.1 挑战条目

本节按时间顺序组织，重点介绍每年参与ILSVRC竞赛中尤为创新且成效显著的方法。表5、表6和表7列出了所有参赛团队。我们看到2012年随着大规模卷积神经网络的发展出现了一个转折点。

ILSVRC2010. 挑战赛的第一年只包含分类任务。NEC团队的获胜方案(Lin等人, 2011)采用了SIFT(Lowe, 2004)和LBP(Ahonen等人, 2006)特征，并结合了两种非线性编码表示方法(Zhou等人, 2010; Wang

⁸ In this paper we focus on the mean average precision across all categories as the measure of a team's performance. This is done for simplicity and is justified since the ordering of teams by mean average precision was always the same as the ordering by object categories won.

等人, 2010) 以及一个随机支持向量机。荣誉提名XRCE团队 (Perronnin等人, 2010) 采用了改进的Fisher向量表示 (Perronnin和Dance, 2007), 并结合了PCA降维和数据压缩, 随后使用线性支持向量机。基于Fisher向量的方法在该挑战赛的五年间不断发展, 并在2010年至2014年的每一届ILSVRC中持续表现强劲。

ILSVRC2011. 2011年的获胜分类参赛作品是2010年的亚军团队XRCE, 他们应用了高维图像签名 (Perronnin等人, 2010年), 并通过产品量化进行压缩 (Sanchez和Perronnin, 2011年), 以及一对多线性支持向量机。单目标定位竞赛首次举办, 有两支勇敢的团队参赛。获胜者是UvA团队, 他们采用选择性搜索方法生成类别无关的目标假设区域 (van de Sande等人, 2011b), 随后对多种颜色SIFT特征进行密集采样和向量量化 (van de Sande等人, 2010年), 通过空间金字塔匹配进行池化 (Lazebnik等人, 2006年), 并使用在GPU上训练的直方图交集核支持向量机进行分类 (Maji和Malik, 2009年; van de Sande等人, 2011a)。

ILSVRC2012. 这是大规模物体识别的一个转折点, 当时大规模深度神经网络开始崭露头角。2012年分类与定位任务无可争议的赢家是SuperVision团队。他们基于RGB值训练了一个大型深度卷积神经网络, 该网络包含6000万个参数, 采用了高效的GPU实现和一种新颖的隐藏单元丢弃技巧 (Krizhevsky等人, 2012; Hinton等人, 2012)。图像分类的第二名由ISI团队获得, 他们使用了费舍尔向量 (Sanchez和Perronnin, 2011) 和精简版的高斯图向量 (Harada与Kuniyoshi, 2012), 并搭配采用被动-主动 (PA) 算法的线性分类器 (Crammer等人, 2006)。单物体定位的第二名则归属VGG团队, 其图像分类系统包含密集SIFT特征与颜色统计 (Lowe, 2004)、费舍尔向量表示 (Sanchez和Perronnin, 2011) 以及线性SVM分类器, 并融合了 (Arandjelovic与Zisserman, 2012; Sanchez等人, 2012) 的额外洞见。ISI和VGG均采用 (Felzenszwalb等人, 2010) 的方法进行物体定位; 而SuperVision使用了训练来预测边界框位置的回归模型。尽管检测模型相对较弱, SuperVision仍以显著优势赢得了物体定位任务。关于SuperVision与VGG在单物体定位任务上提交方案的详细分析与比较, 可参阅 (Russakovsky等人, 2013)。

SuperVision模型成功的影响在ILSVRC2013和ILSVRC2014中清晰可见。

ILSVRC2013. ILSVRC2013竞赛共有24支队伍参与, 而前三年仅有21支 *combined*。继2012年基于深度学习的方法取得成功后, 2013年绝大多数参赛作品都在提交中使用了深度卷积神经网络。分类任务的获胜者是Clarifai, 其方案采用了多个大型深度卷积神经网络进行集成平均。网络架构的选择借鉴了 (Zeiler和Fergus, 2013) 的可视化技术, 并遵循 (Zeiler等人, 2011) 在GPU上使用dropout技术 (Krizhevsky等人, 2012) 进行训练。

获胜的单目标定位OverFeat方案基于一个集成框架, 该框架采用多尺度滑动窗口方法 (Sermanet等人, 2013年), 利用卷积网络进行分类、定位和检测。他们是唯一一个同时应对所有三项任务的团队。

目标检测任务的获胜者是UvA团队, 他们采用了一种新颖的高效编码方法 (van de Sande等人, 2014年), 在选择性搜索框架 (Uijlings等人, 2013年) 中, 通过多级空间金字塔对密集采样的颜色描述符 (van de Sande等人, 2010年) 进行池化处理。检测结果通过全图像卷积网络分类器进行了重新评分。

ILSVRC2014. 2014年吸引了最多的参赛作品, 共有36支团队提交了123项参赛作品, 而2013年仅有24支团队——参与度增长了1.5倍。⁹ 与2013年类似, 几乎所有团队都使用卷积神经网络作为其参赛作品的基础。仅一年时间就取得了显著进展: 图像分类错误率较ILSVRC2013几乎减半, 而目标检测的平均精度均值相比ILSVRC2013几乎翻倍。详情请参阅第6.1节。

2014年, 竞赛允许团队使用外部数据训练模型, 因此设立了六个赛道: 图像分类、单目标定位和目标检测任务各设提供数据与外部数据两个赛道。

使用提供数据获胜的图像分类团队是GoogLeNet, 该团队探索了一种改进的卷积神经网络架构, 将多尺度理念与从赫布原理获得的直觉相结合。额外的降维层使他们能够同时增加网络的深度和宽度。

⁹ Table 7 omits 4 teams which submitted results but chose not to officially participate in the challenge.

Codename	CLS	LOC	Institutions	Contributors and references
Hminmax	54.4		Massachusetts Institute of Technology	Jim Mutch, Sharat Chikkerur, Hristo Paskov, Ruslan Sala
IBM	70.1		IBM research [†] , Georgia Tech [‡]	Lexing Xie [†] , Hua Ouyang [‡] , Apostol Natsev [†]
ISIL	44.6		Intelligent Systems and Informatics Lab., The University of Tokyo	Tatsuya Harada, Hideki Nakayama, Yoshitaka Ushiku, Yuya
ITNLP	78.7		Harbin Institute of Technology	Deyuan Zhang, Wenteng Xuan, Xiaolong Wang, Bingquan
LIG	60.7		Laboratoire d'Informatique de Grenoble	Georges Quénot
NEC	28.2		NEC Labs America [†] , University of Illinois at Urbana-Champaign [‡] , Rutgers [±]	Yuangqing Lin [†] , Pengjun Lv [†] , Shenghuo Zhu [†] , Ming Yan, Zhen Li [‡] , Min-Hsuan Tsai [‡] , Xi Zhou [†] , Thomas Huang [‡] , (Lin et al., 2011)
NII	74.2		National Institute of Informatics, Tokyo, Japan [†] , Hefei Normal Univ. Hefei, China [‡]	Cai-Zhi Zhu [†] , Xiao Zhou [‡] , Shinichi Satoh [†]
NTU	58.3		CeMNet, SCE, NTU, Singapore	Zhengxiang Wang, Liang-Tien Chia
Regularities	75.1		SRI International	Omid Madani, Brian Burns
UCI	46.6		University of California Irvine	Hamed Pirsiavash, Deva Ramanan, Charles Fowlkes
XRCE	33.6		Xerox Research Centre Europe	Jorge Sanchez, Florent Perronnin, Thomas Mensink (Perronnin et al., 2010)

ILSVRC 2011

Codename	CLS	LOC	Institutions	Contributors and references
ISI	36.0	-	Intelligent Systems and Informatics lab, University of Tokyo	Tatsuya Harada, Asako Kanazaki, Yoshitaka Ushiku, Yuya Kuniyoshi
NII	50.5	-	National Institute of Informatics, Japan	Duy-Dinh Le, Shinichi Satoh
UvA	31.0	42.5	University of Amsterdam [†] , University of Trento [‡]	Koen E. A. van de Sande [†] , Jasper R. R. Uijlings [‡] , Arnold Cees Snoek [†] (van de Sande et al., 2011b)
XRCE	25.8	56.5	Xerox Research Centre Europe [†] , CHU [‡]	Florent Perronnin [†] , Jorge Sanchez [†] [‡] (Sanchez and Perronnin, 2011)

ILSVRC 2012

Codename	CLS	LOC	Institutions	Contributors and references
ISI	26.2	53.6	University of Tokyo [†] , JST PRESTO [‡]	Naoyuki Gunji [†] , Takeyuki Higuchi [†] , Koki Yasunoto [†] , Harada [‡] , Yasuo Kuniyoshi [†] (Harada and Kuniyoshi, 2012)
LEAR	34.5	-	LEAR INRIA Grenoble [†] , TVPA Xerox Research Centre Europe [‡]	Thomas Mensink [†] , Jakob Verbeek [†] , Florent Perronnin [‡] , (Mensink et al., 2012)
VGG	27.0	50.0	University of Oxford	Karen Simonyan, Yusanf Ayar, Andrea Vedaldi, Andrew Zisserman, 2012; Sanchez et al., 2012)
SuperVision	16.4	34.2	University of Toronto	Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton
UvA	29.6	-	University of Amsterdam	Koen E. A. van de Sande, Amir Habibi, Cees G. M. Snoek (Sanchez and Perronnin, 2011; Scheirer et al., 2012)
XRCE	27.1	-	Xerox Research Centre Europe [†] , LEAR INRIA [‡]	Florent Perronnin [†] , Zeynep Akata [†] , Zaid Harchaout [‡] , Co (Perronnin et al., 2012)

Table 5 参与ILSVRC2010-2012的团队按字母顺序排列。每种方法均以文本中使用的代号标识。我们以百分比形式报告平面top-5分类和于提交多个参赛结果的团队，我们报告其最佳成绩。2012年，SuperVision团队还提交了使用ImageNet 2011年秋季发布版额外数据训练的参5%的定位错误率。在可能的情况下提供了关键参考文献。获胜参赛方案的更多细节详见第5.1节。

ILSVRC 2013

Codename	CLS	LOC	DET	Institutions	Contributors and references
Adobe	15.2	-	-	Adobe [†] , University of Illinois at Urbana-Champaign [‡]	Hailin Jin [†] , Zhe Lin [†] , Jianchao Yang [†] , (Krizhevsky et al., 2012)
AHoward	13.6	-	-	Andrew Howard Consulting	Andrew Howard
BUP [†]	25.2	-	-	Beijing University of Posts and Telecommunications [†] , Orange Labs International Center Beijing [‡]	Chong Huang [†] , Yanlong Bian [†] , Honglata
Clarifai	11.7	-	-	Clarifai	Matthew Zeiler
CogVision	16.1	-	-	Microsoft Research [†] , Harbin Institute of Technology [‡]	(Zeiler and Fergus, 2013; Zeiler et al., 2010)
decaf	19.2	-	-	University of California Berkeley	Kuiyuan Yang [†] , Yalong Bai [†] , Yong Rui;
Deep Pmx	20.9	-	-	Saint Petersburg State University	Yangqing Jia, Jeff Donahue, Trevor Dar
Delta	-	-	6.1	National Tsing Hua University	(Donahue et al., 2013)
IBM	20.7	-	-	University of Illinois at Urbana-Champaign [†] , IBM Watson Research Center [‡] , IBM Haifa Research Center [†]	Yangqing Jia, Jeff Donahue, Trevor Dar
MIL	24.4	-	-	University of Tokyo	Evgeny Sminov, Denis Timoshenko, Ale
Minerva	21.7			Peking University [†] , Microsoft Research [‡] , Shanghai Jiao Tong University [†] , Xidian University [§] , Harbin Institute of Technology ⁵	(Krizhevsky et al., 2012; Wan et al., 201
NEC	-	-	19.6	NEC Labs America [†] , University of Missouri [‡]	Che-Rung Lee, Hwann-Tzong Chen, Hao
NUS	13.0			National University of Singapore	Che Kao
Orange	25.2			Orange Labs International Center Beijing [†] , Beijing University of Posts and Telecommunications [‡]	Zhicheng Yan [†] , Liangliang Cao [†] , John F
OverFeat	14.2	30.0	(19.4)	New York University	Pankanti [‡] , Sharon Alpert [†] , Yochay Tz
Quantum	82.0	-	-	Self-employed [†] , Student in Troy High School, Pullerton, CA [†]	Masatoshi Hidaka, Chie Kamada, Yusuk
SYSU	-	-	10.5	Sun Yat-Sen University, China.	Tianjun Xiao [†] , Minjie Wang [†] , Jianp
Toronto	-	-	11.5	University of Toronto	Yang [†] , Chuntee Hong [‡] , Zheng Zhang [†]
Thimps	26.2	-	-	The Third Research Institute of the Ministry of Public Security, P.R. China	(Wang et al., 2014)
UCLA	-	-	9.8	University of California Los Angeles	XiaoYu Wang [†] , Miao Sun [†] , Tianbao Yan
UUC	-	-	1.0	University of Illinois at Urbana-Champaign	(Wang et al., 2013)
UVA	14.3	-	22.6	University of Amsterdam, Euvision Technologies	Min Lin*, Qiang Chen*, Jian Dong, ju
VGG	15.2	46.4	-	Visual Geometry Group, University of Oxford	(Krizhevsky et al., 2012)
ZF	13.5	-	-	New York University	Hongliang Bai [†] , Lezi Wang [†] , Shusheng

Table 6 参与ILSVRC2013的团队按字母顺序排列。每种方法在文中以代号标识。对于分类和单目标定位任务，我们报告的是扁平化前5任务，我们报告的是平均精度均值（百分比，越高越好）。尽管挑战赛的优胜者由获胜的目标类别数量决定，但这与mAP高度相关。括号内正式竞赛。部分参赛团队也提交了使用外部数据训练的模型：Clarifai的分类错误率为11.2%，NEC的检测mAP为20.9%。关键参考文献已见节。

ILSVRC 2014									
Codename	CLS	CLSo	LOC	LOCo	DET	DETo	Institutions		
Adobe	-	11.6	-	30.1	-	-	Adobe [†] , UTIC [‡]		
AHoward	8.1	-	0	-	-	-	Howard Vision Technologies		
BDC	11.3	-	0	-	-	-	Institute for Infocomm Research [†] , Universit� Pierre et Marie Curie [‡]		
Berkeley	-	-	-	-	-	34.5	UC Berkeley		
BREIL	16.0	-	0	-	-	-	KAIST department of EE		
Brio	17.6	-	52.0	-	-	-	Brno University of Technology		
CASIA-2	-	-	-	-	28.6	-	Chinese Academy of Science [†] , Southeast University [‡]		
CASIAWS	-	11.4	-	0	-	-	CRTPAC, CASIA		
Cidi	13.9	-	46.9	-	-	-	KAIST [†] , Cidi Inc. [‡]		
CUHK	-	-	-	-	-	40.7	The Chinese University of Hong Kong		
DeepCNet	17.5	-	0	-	-	-	University of Warwick		
DeepInsight	-	-	-	-	-	40.5	NLPRI [†] , HKUST [‡]		
FengjunLv	17.4	-	0	-	-	-	Fengjun Lv Consulting		
GoogleNet	6.7	-	26.4	-	-	43.9	Google		
HKUST	-	-	-	-	28.9	-	Hong Kong U. of Science and Tech [†] , Chinese U. of H. K. [‡] , Stanford U. [‡]		
libccv	16.0	-	0	-	-	-	libccv.org		
MIL	18.3	-	33.7	-	-	30.4	The University of Tokyo [†] , HIT Guwahati [‡]		
MPG-UT	-	-	-	-	-	26.4	The University of Tokyo		
MSRA	8.1	-	35.5	-	35.1	-	Microsoft Research [†] , Xi'an Jiaotong U. [‡] , U. of Science and Tech. of China [‡]		
NUS	-	-	-	-	37.2	-	National University of Singapore [†] , IBM Research Australia [‡]		
NUS-BST	9.8	-	0	-	-	-	National Univ. of Singapore [†] , Beijing Samsung Telecom R&D Center [‡]		
Orange	15.2	14.8	42.8	42.7	-	27.7	Orange Labs Beijing [†] , BUPT China [‡]		
PassBy	16.7	-	0	-	-	-	LENOVO [†] , HKUST [‡] , U. of Macao [‡]		
SCUT	18.8	-	0	-	-	-	South China Univ. of Technology		
Southeast	-	-	-	-	30.5	-	Southeast U. [†] , Chinese A. of Sciences [‡]		
SYSU	14.4	-	31.9	-	-	-	Sun Yat-Sen University		
Trimps	-	11.5	-	42.2	-	33.7	The Third Research Institute of the Ministry of Public Security		
TTIC	10.2	-	48.3	-	-	-	Toyota Technological Institute at Chicago [†] , Ecole Centrale Paris [‡]		
UI	99.5	-	0	-	-	-	University of Isfahan		
UvA	12.1	-	0	-	32.0	35.4	U. of Amsterdam and Eindhoven Tech.		
VGG	7.3	-	25.3	-	-	-	University of Oxford		
XYZ	11.2	-	0	-	-	-	The University of Queensland		

Table 7 参与ILSVRC2014的团队按字母顺序排列。每种方法在文中以代号标识。对于分类和单目标定位任务，我们报告的是扁平化前）。对于检测任务，我们报告的是平均精度均值，以百分比表示（数值越高越好）。CLSo、LOCo、DETo对应使用外部训练数据的参赛方定位错误率超过60%（每项分类提交都必须附带定位结果）。尽可能提供了关键参考文献。获胜方案的更多细节详见第5.1节。

在不显著增加计算开销的情况下，显著提升了网络的性能。在借助外部数据的图像分类任务中，CASIAWS团队通过仅利用分类标签进行弱监督目标定位，从而提升了图像分类效果。该方法采用基于PASCAL VOC 2012数据预训练的MCG区域建议算法（Arbeláez等人，2014）提取候选区域，使用卷积网络表征区域特征，并采用多示例学习策略训练弱监督目标检测器以表征图像。

在提供数据轨迹的单目标定位任务中，获胜团队VG G探索了卷积神经网络深度对其准确性的影响。他们基于Caffe框架（Jia, 2013）实现了三种不同架构，最多采用19个带有线性整流单元非线性的权重层。对于定位任务，他们采用了类似OverFeat（Sermanet等人，2013）的逐类边界框回归方法。在允许使用外部数据的单目标定位任务中，Adobe团队额外使用了2000个ImageNet类别，在统一的卷积神经网络框架中同时训练分类和定位模型，并采用边界框回归技术。测试阶段，他们使用k均值算法寻找边界框聚类，并根据分类得分对聚类进行排序。

在提供数据的目标检测赛道中，获胜团队NUS采用了RCNN框架（Girshick等人，2013年），结合了网络中的网络方法（Lin等人，2014a）以及（Howard，2014年）的改进。全局上下文信息则借鉴了（Chen等人，2014年）的方法进行整合。在使用外部数据的目标检测赛道中，获胜团队是GoogLeNet（该团队同时在提供数据的图像分类赛道中获胜）。值得注意的是，同一团队能同时在图像分类和目标检测中获胜，这表明他们的方法不仅能基于场景信息对图像进行分类，还能准确定位多个目标实例。与此赛道的大多数参赛团队类似，GoogLeNet将图像分类数据集作为额外训练数据使用。

5.2 大规模算法创新

过去五年中，ILSVRC为计算机视觉领域的多项突破铺平了道路。

类别物体识别领域在大规模场景下经历了显著的发展。第5.1节记录了从编码SIFT特征开始，到大规模卷积神经网络在图像分类、单物体定位和物体检测这三项任务中占据主导地位的演进历程。随着海量训练数据的可获得性（以及

随着高效的算法实现和GPU计算资源的应用，现在可以直接从图像数据中学习神经网络，而无需构建多阶段、手动调整的特征提取和判别分类器流程。这一领域的重大突破发生在2012年，SuperVision团队在图像分类和单目标定位任务中获胜（Krizhevsky等人，2012年），到2014年，所有顶尖参赛者都已高度依赖卷积神经网络。

此外，过去几年计算机视觉领域对大规模识别给予了大量关注。2013年顶级视觉会议的最佳论文奖均授予了大规模识别方法：CVPR 2013的获奖论文是《单机快速准确检测10万个物体类别》（Dean等人，2013），ICCV 2013的获奖论文是《从大规模图像分类到入门级类别》（Ordonez等人，2013）。同时，还涌现出多个具有影响力的研究方向，例如（Kuetel等人，2012）提出的大规模弱监督定位工作曾获ECCV 2012最佳论文奖，以及（Frome等人，2013）等研究者开展的大规模零样本学习。

6 Results and analysis

6.1 多年来的改进

从ILSVRC2010到ILSVRC2014，最先进的准确率显著提升，展示了过去五年在大规模物体识别领域取得的巨大进展。每年各项任务的获胜ILSVRC参赛作品性能如图9所示，逐年进步清晰可见。本节我们将对这一进步进行量化分析。

6.1.1 Image classification and single-object localization improvement over the years

自挑战开始以来，图像分类错误率降低了4.2倍（从28.2%降至6.7%），单目标定位错误率降低了1.7倍（从42.5%降至25.3%）。为保持一致性，此处仅考虑使用官方提供训练数据的团队。尽管具体目标类别有所调整（第3.1.1节），但数据集的大规模特性始终保持不变（表2），这使得历年结果具有可比性。自2012年以来数据集未作变动，其间图像分类错误率下降2.4倍（从16.4%降至6.7%），单目标定位错误率下降1.3倍




Fig. 9 ILSVRC2010-2014竞赛中各项任务获胜参赛作品的性能表现（参赛作品详情与数值结果见第5.1节）。在物体分类与单物体定位任务中，误差率逐年稳步下降；物体检测任务的均值平均精度则提升了1.9倍。进行此类比较时需注意两点：（1）ISLVR C使用的物体类别在2010-2011年及2011-2012年间有所变动，但由于数据规模始终保持一致（1000个物体类别、120万训练图像），结果仍具可比性。图中展示的分类与单物体定位参赛作品仅使用官方提供的训练数据。（2）物体检测训练数据量在2013-2014年间显著增加（第3.3节）。第6.1节将讨论训练数据增长与算法改进的相对影响。

单目标定位误差（从33.5%降至25.3%）在过去三年中。

6.1.2 Object detection improvement over the years

以平均精度均值（mAP）衡量的目标检测准确率自该任务提出以来已提升1.9倍，从ILSVRC2013的22.6% mAP上升至ILSVRC2014的43.9% mAP。然而，这些结果因以下两个原因无法直接比较：首先，目标检测训练数据的规模在2013至2014年间显著增加（第3.3节）；其次，43.9% mAP的结果是在加入图像分类与单目标定位训练数据后取得的。本文旨在解析训练集规模扩大与算法改进的相对影响。所有模型均在相同的ILSVRC2013-2014目标检测测试集上进行评估。

首先，我们通过比较同一模型在ILSVRC2013检测数据与ILSVRC2014检测数据上的训练效果，量化了两次挑战间增加检测训练数据的影响。UvA团队2013年的框架使用ILSVRC2013数据时达到22.6%（表6），而使用ILSVRC2014数据且未作其他修改时达到26.3%¹⁰，mAP绝对值提升3.7%。RCNN模型使用ILSVRC2013检测数据加图像分类数据时获得31.4% mAP（Girshick等，2013），使用ILSVRC2014检测数据加图像分类数据时获得34.5% mAP（表7中伯克利团队结果）。

将ILSVRC2013检测数据扩展至ILSVRC2014带来的mAP提升为3.1%。

其次，我们量化了添加外部数据对训练目标检测模型的影响。2013年的NEC模型仅使用ILSVRC2013检测数据训练时达到19.6% mAP，而使用ILSVRC2013检测加分类数据训练时达到20.9% mAP（表6）。mAP的绝对提升为1.3%。2014年UvA团队的最佳参赛模型使用ILSVRC2014检测数据训练时达到32.0% mAP，使用ILSVRC2014检测加分类数据训练时达到35.4% mAP。mAP的绝对提升为3.4%。

因此，根据目前的证据，我们得出结论：将ILSVRC2013检测集扩展至ILSVRC2014集，以及从分类任务中增加额外的训练数据，共同为模型带来了约1–4%的绝对mAP提升。作为对比，我们也可以尝试量化算法创新的影响。如上所述，UvA团队2013年的框架在ILSVRC2014数据上取得了26.3%的mAP，而他们2014年的改进方法则达到了32.0%的mAP（表7）。这意味着仅通过算法创新，一年内就实现了5.8%的绝对mAP增长。

总而言之，我们得出结论，ILSVRC2013获胜作品（22.6% mAP）与ILSVRC2014获胜作品（43.9% mAP）之间mAP绝对值21.3%的提升，是卓越算法创新的成果，而不仅仅是训练数据增加的结果。然而，进一步扩大ILSVRC2014目标检测训练数据集可能会为现有算法带来检测准确率的额外提升。

6.2 统计显著性

一个重要的问题是，ILSVRC不同提交结果之间是否存在统计学上的显著差异。鉴于其规模之大，即使准确率上的微小差异也具有统计显著性并不令人意外；我们需要精确量化多大的差异才算足够。

遵循PASCAL VOC（Everingham等人，2014年）采用的策略，对于每种方法，我们通过自助采样获得其得分的置信区间。在每一轮自助采样中，我们从所有可用的 N 张测试图像中有放回地抽取 N 张图像，并在这些抽样图像上评估算法的性能。通过预先计算每张图像的准确率，这一过程可以高效完成。根据所有自助采样轮次的结果，我们剔除最低和最高的 α 比例部分。剩余结果的范围代表了 $1-2\alpha$ 置信

¹⁰ Personal communication with members of the UvA team.

Image classification			
Year	Codename	Error (percent)	99.9% Conf Int
2014	GoogLeNet	6.66	6.40 - 6.92
2014	VGG	7.32	7.05 - 7.60
2014	MSRA	8.06	7.78 - 8.34
2014	AHoward	8.11	7.83 - 8.39
2014	DeeperVision	9.51	9.21 - 9.82
2013	Clarifai [†]	11.20	10.87 - 11.53
2014	CASIAWS [†]	11.36	11.03 - 11.69
2014	Trimps [†]	11.46	11.13 - 11.80
2014	Adobe [†]	11.58	11.25 - 11.91
2013	Clarifai	11.74	11.41 - 12.08
2013	NUS	12.95	12.60 - 13.30
2013	ZF	13.51	13.14 - 13.87
2013	AHoward	13.55	13.20 - 13.91
2013	OverFeat	14.18	13.83 - 14.54
2014	Orange [†]	14.80	14.43 - 15.17
2012	SuperVision [†]	15.32	14.94 - 15.69
2012	SuperVision	16.42	16.04 - 16.80
2012	ISI	26.17	25.71 - 26.65
2012	VGG	26.98	26.53 - 27.43
2012	XRCE	27.06	26.60 - 27.52
2012	UvA	29.58	29.09 - 30.04
Single-object localization			
Year	Codename	Error (percent)	99.9% Conf Int
2014	VGG	25.32	24.87 - 25.78
2014	GoogLeNet	26.44	25.98 - 26.92
2013	OverFeat	29.88	29.38 - 30.35
2014	Adobe [†]	30.10	29.61 - 30.58
2014	SYSU	31.90	31.40 - 32.40
2012	SuperVision [†]	33.55	33.05 - 34.04
2014	MIL	33.74	33.24 - 34.25
2012	SuperVision	34.19	33.67 - 34.69
2014	MSRA	35.48	34.97 - 35.99
2014	Trimps [†]	42.22	41.69 - 42.75
2014	Orange [†]	42.70	42.18 - 43.24
2013	VGG	46.42	45.90 - 46.95
2012	VGG	50.03	49.50 - 50.57
2012	ISI	53.65	53.10 - 54.17
2014	CASIAWS [†]	61.96	61.44 - 62.48
Object detection			
Year	Codename	AP (percent)	99.9% Conf Int
2014	GoogLeNet [†]	43.93	42.92 - 45.65
2014	CUHK [†]	40.67	39.68 - 42.30
2014	DeepInsight [†]	40.45	39.49 - 42.06
2014	NUS	37.21	36.29 - 38.80
2014	UvA [†]	35.42	34.63 - 36.92
2014	MSRA	35.11	34.36 - 36.70
2014	Berkeley [†]	34.52	33.67 - 36.12
2014	UvA	32.03	31.28 - 33.49
2014	Southeast	30.48	29.70 - 31.93
2014	HKUST	28.87	28.03 - 30.20
2013	UvA	22.58	22.00 - 23.82
2013	NEC [†]	20.90	20.40 - 22.15
2013	NEC	19.62	19.14 - 20.85
2013	OverFeat [†]	19.40	18.82 - 20.61
2013	Toronto	11.46	10.98 - 12.34
2013	SYSU	10.45	10.04 - 11.32
2013	UCLA	9.83	9.48 - 10.77

Table 8 我们采用自助法 (bootstrapping) 为2012-2014年间每项ILSVRC任务中最多前5名的提交结果构建了99.9%的置信区间。[†]表示该参赛作品使用了外部训练数据。每年每赛道中使用规定数据的获胜者已用粗体标出。每年获胜方法与亚军之间的差异即使在99.9%的置信水平上仍具有显著性。




Fig. 10 对于每个物体类别，我们考虑了提交至ILSVRC2012-2014竞赛的所有参赛方案（包括使用额外训练数据的方案）中的最佳性能。这些图表展示了这些“乐观”的每类结果分布。性能通过图像分类准确率（左图）、单物体定位准确率（中图）以及物体检测平均精度（右图）进行衡量。尽管图像分类的结果非常令人鼓舞，但ILSVRC数据集远未达到饱和状态：许多物体类别对当前算法而言仍具挑战性。

置信区间。我们进行了大量自助抽样轮次（从20,000次直至收敛）。表8展示了ILSVRC2012-2014各任务中顶尖参赛方法的结果。即使在99.9%的置信水平下，优胜方法与其他方法仍存在统计学上的显著差异。

6.3 类别物体识别的当前状态

除了观察数百个物体类别和数万张图像的平均准确率外，我们还可以深入探究错误发生的位置，以及研究人员应集中精力以加速进展的方向。

为此，在本节中，我们将分析一种对当前最先进识别性能的“乐观”评估，而非聚焦于单个算法的差异。针对每项任务和每个对象类别，我们计算了提交至ILSVRC2012-2014的*any*参赛方案中的最佳性能，包括使用额外训练数据的方法。由于测试集保持不变，我们可以直接比较过去三年的所有参赛方案，从而获得对每个类别上最先进准确率的“乐观”评估。

为了与目标检测指标（越高越好）保持一致，在本节中我们将使用图像分类和单目标定位*accuracy*而非误差，其中 $accuracy = 1 - error$ 。

6.3.1 Range of accuracy across object classes

图10展示了“乐观”模型在各个物体类别上达到的准确率分布。图像分类模型平均达到94.6%的准确率（或5.4%的误差），但最

以及准确率最低的物体类别。单物体定位模型的平均准确率达到81.5%（即18.5%的误差），不同物体类别间的准确率差异范围为77.0%。物体检测模型的平均精度为44.7%，各类别间的精度差异范围达84.7%。显然ILSVRC数据集远未达到饱和：尽管模型整体表现强劲，但许多类别的性能仍然较差。

6.3.2 Qualitative examples of easy and hard classes

图11和图12展示了每个任务中最简单和最困难的类别，即使用“乐观”模型获得最佳和最差结果的类别。

在图像分类任务中，根据乐观估计，1000个物体类别中有121个达到了100%的图像分类准确率。图11（顶部）展示了随机选取的其中10个类别。这些类别多种多样，包括哺乳动物如“红狐”，以及具有独特结构的动物如“黄貂鱼”。图像分类任务中最难的类别准确率低至59.0%，包括金属和透明的人造物体，如“挂钩”和“水瓶”，材质类别“天鹅绒”，以及高度多样化的场景类别“餐厅”。

在单目标定位任务中，10个最容易的类别（准确率达99.0–100%）均为哺乳动物和鸟类。最具挑战性的类别包括金属人造物（如“开信刀”和“长柄勺”）、细长结构物（如“杆子”和“空格键”）以及形态多变的类别（如“翅膀”）。其中最困难的“空格键”类别定位准确率仅为23.0%。

目标检测结果如图12所示。最容易识别的类别包括生物体如“狗”和“老虎”，以及具有独特形状和颜色的“篮球”和“排球”，还有略显意外的“扫雪机”。最简单的类别“蝴蝶”虽未达到完美检测，但已非常接近，AP值为92.7%。最困难的类别如预期所示，是细小的物体如“长笛”和“钉子”，以及形态高度多变的“灯具”和“背包”类别，其AP值低至8.0%。

6.3.3 Per-class accuracy as a function of image properties

我们现在更仔细地观察图像属性，试图理解为什么当前算法在某些物体类别上表现良好，而在其他类别上则不然。一种假设是，准确率的差异源于某些类别的实例在图像中往往比其他类别的实例小得多，而较小的物体可能对计算机来说更难识别。在本节中，我们认为虽然准确率与

图像中的物体尺度，并非所有准确度的变化都能仅由尺度来解释。

对于每个物体类别，我们计算其*average scale*，即在ILSVRC2012-2014验证集上该物体类别单个实例所占图像面积的平均比例。由于图像分类任务和单物体定位任务中的图像及物体类别相同，我们对两项任务均使用单物体定位数据集的边界框标注。在该数据集中，物体类别的尺度范围从“游泳裤”的1.5%到“蜘蛛网”的85.6%。在物体检测验证数据集中，物体类别的尺度范围则从“太阳镜”的1.3%到“沙发”的44.4%。

图13展示了“乐观”方法的性能随图像中物体平均尺度的变化情况。每个点对应一个物体类别。我们观察到物体尺度与图像分类准确率之间存在极弱的正相关性： $\rho = 0.14$ 。对于单物体定位和物体检测任务，相关性更强，分别为 $\rho = 0.40$ 和 $\rho = 0.41$ 。显然，准确率的变化不能仅由尺度因素完全解释。尽管如此，在下一节中我们将对物体尺度进行归一化处理，以确保该因素不会影响我们的结论。

6.3.4 Per-class accuracy as a function of object properties.

除了考虑图像层面的属性，我们还可以观察准确率如何随内在物体属性的变化而变化。我们定义了三种受人类视觉启发的属性：物体的真实世界尺寸、它是否在实例内可变形，以及其纹理丰富程度。针对每种属性，物体类别被分配到几个分组之一（如下所列）。这些属性在图1中进行了说明。

人类受试者使用这些属性对ILSVRC2012-2014中的1000个图像分类和单目标定位对象类别逐一进行了标注（Rusakovsky等人，2013年）。根据设计（见第3.3.1节），200个目标检测类别中的每一个要么是1000个对象类别之一，要么是ImageNet层次结构中一个或多个类别的祖先。为计算每个目标检测类别的属性值，我们直接对后代类别的标注值进行平均处理。

在本节中，我们针对这些物体属性，就最先进的识别精度得出以下结论：

- **Real-world size:** *XS* for extra small (e.g. nail), small (e.g. fox), medium (e.g. bookcase), large (e.g. car) or *XL* for extra large (e.g. church)

Image classification

Easiest classes



Hardest classes



Single-object localization

Easiest classes



Hardest classes



Fig. 11 对于每个物体类别，我们选取ILSVRC2012-2014竞赛中提交的任何参赛方案（包括使用额外训练数据的方案）的最佳性能。基于这些“乐观”结果，我们展示了每项任务中最简单和较难的类别。括号中的数字表示分类和定位准确率。在图像分类任务中，10个最简单类别是从准确率达到100%的121个物体类别中随机选取的。物体检测结果如图12所示。




Fig. 12 对于每个物体类别，我们选取ILSVRC2012-2014期间提交的任何参赛方案（包括使用额外训练数据的方案）中的最佳性能。基于这些“乐观”结果，我们展示了物体检测任务中最简单和最困难的类别，即结果最佳和最差的类别。括号中的数字表示平均精度。图像分类和单物体定位结果如图11所示。




Fig. 13 “乐观”方法在各项任务中作为图像内物体尺度函数的性能表现。每个点对应一个物体类别。平均尺度（x轴）的计算方式为：该物体类别在ILSVRC2014验证集上单个实例所占图像面积的平均比例。“乐观”性能（y轴）对应ILSVRC2012-2014期间提交的任何参赛方案（含使用额外训练数据的方案）在测试集上的最佳性能。该测试集在这三年间保持不变。我们可以观察到，当图像中物体尺寸增大时，准确率往往随之提升。然而显然可见，仅凭尺度因素远不能解释这些类别在准确率上的全部差异。

图像分类和单目标定位的“乐观”模型在大型和超大型现实世界物体上的表现优于较小物体。令人惊讶的是，“乐观”目标检测模型在超小物体上的表现优于中小型物体。

– **Deformability within instance:** *Rigid (e.g., mug) or deformable (e.g., water snake)* 在这三项任务中，“乐观”模型在可变形物体上的表现均具有统计学意义上的显著优势。

与刚性物体相比的物体。然而，当将自然物体与人造物体分开分析时，这种效应就消失了。

– **Amount of texture:** *none (e.g. punching bag), low (e.g. horse), medium (e.g. sheep) or high (e.g. honeycomb)* 在三个任务中，针对至少具有低纹理水平的物体，“乐观”模型的表现显著优于无纹理物体。

这些及其他发现将在下文中得到详细论证和讨论。

Experimental setup. 我们在6.3.3节中观察到，图像中占据面积较大的物体往往更容易被识别。为确保物体尺度的差异不影响本节结果，我们按物体尺度对每个分组进行归一化处理。我们会根据需要舍弃每个分组中尺度最大的物体类别，直到各组中物体类别在某一属性上的平均物体尺度相同（或尽可能接近）。以真实世界尺寸属性为例，经过处理后，图像分类和单物体定位任务中五个分组的平均物体尺度分别为31.6%–31.7%，而物体检测任务中则为12.9%–13.4%。¹¹

图14展示了“乐观”模型在每个属性对应的各个区间内物体类别的平均性能。我们将在下文中详细分析这些结果。除非另有说明，以下报告的准确率均为经过尺度归一化处理后的结果。

为了评估统计显著性，我们使用自助法计算准确率的95%置信区间：我们在箱内对物体类别进行重复抽样（有放回），根据需要舍弃部分样本以按尺度归一化，并计算“乐观”模型在剩余类别上的平均准确率。我们在括号中报告95%置信区间（CI）。

¹¹ For rigid versus deformable objects, the average scale in each bin is 34.1% – 34.2% for classification and localization, and 13.5%–13.7% for detection. For texture, the average scale in each of the four bins is 31.1% – 31.3% for classification and localization, and 12.7% – 12.8% for detection.

Real-world size. 在图14（上，左）中我们观察到，在图像分类任务中，“乐观”模型在现实世界中体积较大的物体上往往表现显著更优。对于XS、S和M尺寸的物体，分类准确率为93.6% – 93.9%，而L尺寸物体达到97.0%，XL尺寸物体则为96.4%。由于数据已进行尺度归一化处理，无法通过物体在图像中的尺寸解释这一现象，因此我们得出结论：要么（1）现实世界中较大的物体更容易被模型识别，要么（2）较大的现实世界物体通常出现在具有非常独特背景的图像中。

为了区分这两种情况，我们查看图14（上，中）。我们发现，在单目标定位任务中，L类物体易于定位，定位准确率达到82.4%。然而，XL类物体往往最难定位，定位准确率仅为73.4%。我们得出结论：模型必然更容易学习L类物体的外观特征，而XL类物体往往出现在独特的背景中。图像背景使得这些XL类别对图像级分类器而言更易识别，但单个实例却难以精确定位。L类物体的例子包括“虎鲸”、“纵帆船”和“狮子”，而XL类物体的例子则有“船库”、“清真寺”、“玩具店”和“钢拱桥”。

在图14（顶部，右侧）对应的物体检测任务中，真实世界物体尺寸的影响并不明显。一个关键原因在于，在构建检测数据集时（第3.3.1节），图像分类和单物体定位数据集中许多XL和L类别的物体类别被移除了，因为它们并非适合检测的基本类别。数据集中仅保留了3个XL物体类别（“火车”、“飞机”和“巴士”），且在尺度归一化后已不存在XL类别。我们将其排除在分析之外。XS、S、M物体的平均精度（分别为44.5%、39.0%和38.5% mAP）与L物体的平均精度在统计上无显著差异：L物体的95%置信区间为37.5% – 59.5%。这可能是因为尺度归一化后仅剩6个L物体类别；而其他真实世界尺寸分箱中至少包含18个物体类别。

最后，有趣的是，在XS物体上44.5%的mAP（置信区间40.5% – 47.6%）表现，在统计上显著优于S或M物体上分别为39.0% mAP和38.5% mAP的表现。XS物体的一些例子包括“草莓”、“领结”和“橄榄球”。

Deformability within instance. 在图14（第二行）中，可以明显看出“乐观”模型在刚性物体上的表现统计显著差于可变形物体。图像分类准确率为93.2%




Fig. 14 “乐观”计算机视觉模型性能随物体属性变化的函数关系。x轴对应人工标注者为每个物体类别标注的属性（Russakovsky等人，2013年），如图1所示。y轴表示“乐观”模型的平均准确率。请注意，为使趋势更明显，每个任务的y轴范围各不相同。黑色圆点表示模型在落入每个分箱的所有物体类别上的平均准确率。我们通过对每个分箱内的物体尺度进行归一化来控制物体尺度的影响（详见第6.3.4节）。彩色条形表示模型在剩余类别上的平均准确率。误差条显示通过自助法获得的95%置信区间。部分分箱缺少彩色条形，是因为尺度归一化后该分箱中剩余的物体类别少于5个。例如，XL现实世界物体检测类别的条形缺失，是因为该分箱仅包含3个物体类别（飞机、公交车、火车），经过尺度归一化后已无剩余类别。

在刚性物体上（置信区间 92.6% – 93.8%），远低于可变形物体上的 95.7%。单物体定位准确率在刚性物体上为 76.2%（置信区间 74.9% – 77.4%），远低于可变形物体上的 84.7%。物体检测 mAP 在刚性物体上为 40.1%（置信区间 37.2% – 42.9%），远低于可变形物体上的 44.8%。

我们可以根据ImageNet层次结构将物体类别分为“自然”和“人造”两类，进一步分析形变能力的影响。形变能力与物体属于自然类还是人造类高度相关：图像分类和单物体定位类别的相关系数为0.72，物体检测类别的相关系数为0.61。图14（第三行）分别展示了形变能力对模型处理人造物体和自然物体时性能的影响。

人造类别的识别难度显著高于自然类别：分类准确率人造类为92.8%（置信区间92.3% – 93.3%），自然类为97.0%；定位准确率人造类为75.5%（置信区间74.3% – 76.5%），自然类为88.5%；检测mAP人造类为38.7%（置信区间35.6 – 41.3%），自然类为50.9%。然而在此细分维度下，类别属于刚性或可变形物体在多数情况下不再具有显著影响。例如，人造刚性物体的图像分类准确率为92.3%（置信区间91.4% – 93.1%），人造可变形物体为91.8%——两者在统计学上无显著差异。

在两种情况下，性能差异{v*}具有统计学显著性。首先，在单目标定位任务中，自然可变形物体比自然刚性物体更容易定位：自然可变形物体的定位准确率为87{v*}9%（置信区间85{v*}9% {v*} 90{v*}1%），高于自然刚性物体的85{v*}8%——该数值略超出95%置信区间。这种性能差异很可能是因为可变的自然动物通常比刚性的自然水果更容易定位。

其次，在物体检测方面，人造刚性物体比人造可变形物体更容易检测：人造刚性物体的38.5% mAP（置信区间35.2% – 41.7%）高于人造可变形物体的33.0% mAP。这是因为人造刚性物体包含“交通信号灯”或“汽车”等类别，而人造可变形物体则包含“塑料袋”、“泳裤”或“听诊器”等具有挑战性的类别。

Amount of texture. 最后，我们分析了物体纹理对“乐观”模型精度的影响。图14（第四行）表明，随着物体表面纹理的增加，模型表现更好。最显著的差异出现在无纹理物体与低纹理物体的性能之间。图像分类—

在无纹理物体上的分类准确率为90.5%（置信区间89.3%至91.6%），低于低纹理物体的94.6%。单物体定位准确率在无纹理物体上为71.4%（置信区间69.1%至73.3%），低于低纹理物体的80.2%。无纹理物体的目标检测mAP为33.2%（置信区间29.5%至35.9%），低于低纹理物体的42.9%。

纹理与物体是自然还是人造相关，在图像分类和单物体定位中相关性为0.35，在物体检测中相关性为0.46。为判断这是否是一个影响因素，我们在图14（底行）中将物体类别分为自然和人造，并展示了无纹理物体与低纹理物体的准确率。我们观察到，无论是在人造还是自然物体类别中，模型在低纹理物体类别上的表现仍然在统计上显著优于无纹理物体类别。¹²

6.4 人类在大规模图像分类上的准确率

ILSVRC数据集上最先进精度的最新进展，与人类水平精度相比较时，更容易被客观看待。本节将领先的大规模图像分类方法在此任务上的表现与人类的表现进行对比。

为了支持这一比较，我们开发了一个界面，允许人工标注者为图像标注最多五个ILSVRC目标类别。我们将人类标注错误与ILSRC2014图像分类比赛的获胜模型GoogLeNet（第5.1节）的错误进行了对比。在此分析中，我们随机抽取了1500张ILSVRC2012-2014图像分类测试集的图片作为样本。

Annotation interface. 我们的基于网络的标注界面由一张测试集图像和侧边栏上的1000个ILSVRC类别列表组成。每个类别通过其标题进行描述，例如“牛仔靴”。这些类别按照ImageNet层次结构的拓扑顺序排序，使得语义上相似的概念在列表中相邻排列。例如，所有与机动车辆相关的类别在列表中连续排列。每个类别还附带一行来自训练集的13张示例图像，以便进行更快速的视觉扫描。界面用户通过点击所需项目从列表中选择5个类别。

¹² Natural object detection classes are removed from this analysis because there are only 3 and 13 natural untextured and low-textured classes respectively, and none remain after scale normalization. All other bins contain at least 9 object classes after scale normalization.

由于我们的界面是基于网页的，它允许自然滚动浏览列表，并且也支持通过文本进行搜索。

Annotation protocol. 我们发现，对于未经训练的标注者来说，为图像标注1000个类别中的一项是极具挑战性的任务。未经训练的标注者最容易犯的错误是未能将相关类别视为可能的标签，因为他们不知道其存在。

因此，在评估人类准确度时，我们主要依赖学习了如何识别1000个ILSVRC类别中大部分类别的专家标注员。在训练期间，标注员先标注了几百张验证图像进行练习，随后转向测试集图像。

6.4.1 Quantitative comparison of human and computer accuracy on large-scale image classification

我们报告了基于两位专家标注员实验的结果。第一位标注员（A1）在500张图像上进行了训练，并标注了1500张测试图像。第二位标注员（A2）在100张图像上训练后，标注了258张测试图像。平均标注速度约为每分钟1张图像，但分布呈现明显的双峰特征：部分图像可快速识别，而另一些图像（例如细分类别的狗、鸟类或猴子图像）可能需要数分钟的集中精力才能完成标注。

结果报告于表9中。

Annotator 1. 标注员A1共评估了1500张测试集图像。在此样本上，GoogLeNet的分类错误率估计为6.8%（回顾表7所示，在包含100,000张图像的完整测试集上错误率为6.7%）。人工错误率估计为5.1%。因此，标注员A1的表现优于GoogLeNet，幅度约为1.7%。我们可以在“两者来自同一分布”的零假设下分析这一结果的统计显著性。具体而言，通过z检验比较两个比例，得到单侧 p 值为 $p = 0.022$ 。因此，我们可以在95%的置信水平上判定该结果具有统计显著性。

Annotator 2. 我们的第二位标注员（A2）仅用100张图像的小样本进行训练，随后标注了258张测试集图像。如表9所示，其最终分类误差显著更高，Top-5错误率约为12.0%。这些错误中大部分（48.8%）可归因于标注员未能发现并考虑将真实标签作为备选选项。

Relative Confusion	A1	A2
Human succeeds, GoogLeNet succeeds	1352	219
Human succeeds, GoogLeNet fails	72	8
Human fails, GoogLeNet succeeds	46	24
Human fails, GoogLeNet fails	30	7
Total number of images	1500	258
Estimated GoogLeNet classification error	6.8%	5.8%
Estimated human classification error	5.1%	12.0%

Table 9 ILSVRC2012-2014分类测试集上的人类分类结果，针对两位专家标注者A1和A2。我们报告了前五名的分类错误率。

因此，我们得出结论，人类需要在ILSVRC上投入大量的训练时间才能达到有竞争力的表现。然而，通过充分的训练，人类标注者仍能超越GoogLeNet的结果（ $p = 0.022$ ）约1.7%。

Annotator comparison. 我们还比较了两位标注者的预测准确性。在A1和A2共同标注的204张图像中，174张（85%）被A1和A2同时正确标注，19张（9%）被A1正确标注但未被A2正确标注，6张（3%）被A2正确标注但未被A1正确标注，5张（2%）被两者均错误标注。其中包括2张我们认为在真实标注中也被错误标记的图像。

具体而言，我们的结果表明人类标注者的预测结果重叠度不高。我们可以通过假设只要A1或A2中至少有一方正确标注图像，即判定该图像正确，来估算“乐观”人类分类器的性能。在此204张图像的样本中，我们估算“乐观”人类标注者的错误率为2.4%，而GoogLeNet的错误率为4.9%。

6.4.2 Analysis of human and computer errors on large-scale image classification

我们手动检查了人类和GoogLeNet的错误，以了解常见错误类型及其对比情况。在本节中，我们仅讨论基于标注者A1标记的1500张较大样本图像的结果。代表性错误示例如图15所示。以下分析和见解专门源自GoogLeNet的预测，但我们怀疑许多相同的错误可能也存在于其他方法中。

Types of errors in both computer and human annotations:

1. Multiple objects. GoogLeNet和人类都在处理包含多个ILSVRC的图像时遇到困难



Fig. 15 突出常见错误来源的代表性验证图像。对于每张图像，我们以蓝色显示真实标注，随后展示GoogLeNet的前5个预测结果（红色=为错误预测，绿色=为正确预测）。验证集图像的GoogLeNet预测结果由GoogLeNet团队成员慷慨提供。从左至右分别为：包含多个物体的图像、极端特写与非典型视角图像、使用滤镜处理的图像、需借助文本识别能力才能准确判断的图像、包含微小纤细物体的图像、具有抽象表现的图像，以及GoogLeNet能正确识别但人类难以判别的细粒度图像示例。

类别（通常远多于五个），且几乎没有指示图像中哪个物体是焦点。这种错误仅出现在分类设置中，因为每张图像都被限制为恰好有一个正确标签。总体而言，我们将GoogLeNet错误中的24个（24%）以及人类错误中的12个（16%）归因于此类。值得注意的是，人类在这种错误类型上可能略有优势，因为有时识别图像中最显著的物体可能较为容易。

2. Incorrect annotations. 我们发现，在约1500张图像中，大约有5张（0.3%）在基准真值中被错误标注。这为人类和GoogLeNet引入了大致相等数量的错误。

Types of errors that the computer is more susceptible to than the human:

1. Object small or thin. GoogLeNet在识别图像中非常小或细长的物体时存在困难，即使该物体是图像中唯一的对象。例如，一张戴太阳镜站立的人像、手持羽毛笔的人，或是花朵茎干上的一只小蚂蚁。我们估计，大约有22个（21%）的GoogLeNet错误属于此类，而人类错误中则没有一例。换言之，在我们的图像样本中，没有一张图像因人类无法识别极小或细长物体而被错误标注。这种差异可归因于人类能够非常有效地利用上下文信息和可供性，来准确推断小物体的身份（例如，人手附近几乎不可见的几根羽毛，很可能属于一支大部分被遮挡的羽毛笔）。

2. Image filters. 许多人使用滤镜来增强照片效果，这些滤镜会扭曲图像的对比度和颜色分布。我们发现，在GoogLeNet错误分类的图像中，有13张（13%）使用了滤镜。因此，我们认为GoogLeNet对这些扭曲的鲁棒性不强。相比之下，在人类分类错误的图像中只有一张使用了滤镜，但我们并不认为该错误源于滤镜。

3. Abstract representations. GoogLeNet在处理以抽象形式描绘感兴趣对象的图像时表现不佳，例如3D渲染图像、绘画、素描、毛绒玩具或雕像。一个例子是夜间摄影中用光源绘制的蝴蝶结抽象形状、3D渲染的机器蝎子，或是秋千上孩子在地面的影子。我们将GoogLeNet约6%（6%）的错误归因于此类错误，并认为人类在此方面明显更为稳健，在我们的样本中未观察到此类错误。

4. Miscellaneous sources. 相对较少出现的其他误差来源包括：物体的局部极端特写、非常规视角（如图像旋转）、需依赖文字识别才能准确解读的图像（例如仅标注“散粉”的无特征容器）、严重遮挡的物体，以及呈现多图拼贴效果的图像。总体而言，我们发现人类对这些类型的误差具有更强的适应能力。

Types of errors that the human is more susceptible to than the computer:

1. Fine-grained recognition. 我们发现人类在细粒度识别（例如狗、猴子、蛇、鸟类）方面的表现明显较差，即使他们

清晰可见。要理解其中的困难，需考虑到数据集中有超过120种犬类。我们估计，人类错误中有28个（37%）属于此类，而GoogLeNet的错误中仅有7个（7%）属于此类。

2. Class unawareness. 标注者有时可能未意识到某个标签选项中存在真实类别。当被指出这是ILSVRC类别时，通常能明显看出该标签适用于图像。随着标注者对ILSVRC类别越来越熟悉，这类错误会逐渐减少。大约有18例（24%）的人工标注错误属于此类。

3. Insufficient training data. 回想一下，标注员在每个类别名称下仅看到该类的13个示例。然而，13张图像并不总能充分传达允许的类别变体。例如，如果“凯尔皮犬”的所有示例都是黑色毛发的狗，那么一只棕色的狗可能会被错误地排除为“凯尔皮犬”。然而，如果列出超过13张图像，就会清楚表明“凯尔皮犬”可能有棕色毛发。大约有4例（5%）的人工错误属于此类。

6.4.3 Conclusions from human image classification experiments

我们对1500张ILSVRC测试集图像样本进行了训练有素的人工标注者性能研究。结果表明，经过训练的人工标注者能够超越最佳模型（GoogLeNet）约1.7%（ $p = 0.022$ ）。

我们预计，部分误差来源可能相对容易消除（例如对滤镜、旋转、拼贴的鲁棒性，以及有效跨多尺度推理），而另一些可能更难解决（例如识别物体的抽象表征）。另一方面，绝大多数人类错误源于细粒度类别和类别认知不足。我们认为前者可通过细粒度专家标注显著减少，而后者可通过更多练习和更熟悉ILSVRC类别来降低。我们的结果还暗示，人类错误之间关联性不强，且人类集成方法可能进一步降低人类错误率。

显然，人类很快将仅凭大量努力、专业知识和时间就能超越最先进的ILSVRC图像分类模型。一个值得未来研究的有趣后续问题是，在更复杂的图像理解任务上，计算机级别的准确度与人类级别的准确度相比如何。

7 Conclusions

本文阐述了ILSVRC的大规模数据收集过程，总结了该数据集上最成功的算法，并分析了这些算法的成功与失败模式。本节将讨论我们在多年ILSVRC实践中获得的关键经验，着力回应针对该数据集的主要批评意见及我们多年来遇到的挑战，最后展望未来发展方向。

7.1 经验教训

收集数据集并运行挑战赛五年的关键教训是：

All human intelligence tasks need to be exceptionally well-designed. 这一教训既体现在使用亚马逊 Mechanical Turk 工作者标注数据集时（第3节），也体现在尝试通过专业标注者评估人类水平的图像分类准确度时（第6.4节）。标注界面的首次迭代总是存在缺陷——通常意味着 *completely unusable*。如果所提问题存在任何固有的模糊性（而这几乎总是存在），工作者便会发现它，导致准确度下降。若能为未来研究提供一条建议，那就是：必须极其谨慎地设计、持续监控并广泛进行合理性检验所有众包任务。

另一个教训，对于大规模研究者来说已经众所周知的是：**Scaling up the dataset always reveals unexpected challenges.** 从设计复杂的多步骤标注策略（第3.2.1节）到不得不修改评估流程（第4节），我们必须不断适应大规模研究的设定。当然，从积极的一面看，物体识别准确率的重大突破（第5节）以及根据物体类别属性分析当前算法的优势与不足（第6.3节），在小规模研究中是绝不可能实现的。

7.2 批评

在过去的五年中，我们遇到了对ILSVRC数据集及其相应挑战的三大主要批评：(1) ILSVRC数据集挑战性不足，(2) ILSVRC数据集包含标注错误，以及(3) ILSVRC竞赛规则限制过多。我们将依次讨论这些问题。

第一个批评是数据集中物体往往较大且位于图像中心，这使得数据集挑战性不足。在第3.2.2节

在3.3.4节中，我们试图通过分析ILSVRC数据集的统计数据来消除这些顾虑，并得出结论：该数据集与长期使用的PASCAL VOC基准（Everingham等人，2010年）具有可比性，且在多数情况下更具挑战性。

第二点涉及地面实况标注中的错误。我们对通过众包获得的标注进行了多轮内部后处理，并纠正了许多常见错误来源（例如附录E）。剩余的主要标注错误源于细粒度物体类别，例如标注者未能区分不同种类的鸟类。这是必须做出的权衡：为了在合理预算内实现如此大规模的数据标注，我们不得不依赖非专业的众包标注员。但总体而言，该数据集令人鼓舞地保持了高洁净度。据我们估计，图像分类数据集（章节3.1.3和6.4）达到了99.7%的精确度，而经过边界框标注系统的图像中有97.9%为目标物体类别的所有实例都标注了边界框（章节3.2.1）。

我们遇到的第三个批评是关于竞赛使用外部训练数据的规则。在ILSVRC2010-2013期间，算法只能使用提供的训练集和验证集图像及其标注来训练模型。然而，随着大规模无监督特征学习领域的发展，关于何为“外部”数据的问题开始浮现：例如，是否允许使用通过无监督方式在大量“外部”图像上训练得到的图像特征参赛？经过多次讨论，我们在ILSVRC2014中迈出了解决这一问题的第一步。我们遵循PASCAL VOC的策略，在竞赛中设立了两个赛道：仅使用“提供”数据的参赛作品，以及使用“外部”数据的参赛作品，即使用未作为ILSVRC训练集或验证集部分提供的任何图像或标注。然而，随着计算机视觉领域的发展，这一策略未来很可能需要进一步修订。例如，竞赛可以考虑允许使用任何公开可用的图像特征，即使这些特征是从外部数据源学习得到的。

7.3 未来

鉴于过去五年算法上的巨大突破，我们非常期待看到未来五年会发生什么。对于ILSVRC和其他大规模图像数据集来说，存在着许多潜在的改进和发展方向。

首先，延续向更丰富图像理解发展的趋势（从图像分类到单一

从物体定位到物体检测，下一个挑战将是解决像素级的物体分割。最近发布的大规模COCO数据集（Lin等人，2014b）已朝着这个方向迈出了一步。

其次，随着数据集的规模进一步扩大，可能无法完全通过人工方式进行标注。ILSVRC的规模已经对可行的人工标注设定了限制：例如，我们不得不限制图像分类和单目标定位数据集中每张图像标注的对象数量。未来，面对数十亿张图像，甚至为每张图像获取一个准确的标签都将变得不可能。像雅虎的Flickr Creative Commons 100M¹³这样仅带有弱人工标签、缺乏集中标注的数据集，将会变得更加普遍。

未标记或仅部分标记的大规模数据集的增长意味着两件事。首先，算法将不得不更多地依赖弱监督训练数据。其次，甚至评估可能必须在算法做出预测之后进行，而不是之前。这意味着，我们将更多地关注*precision*：在算法做出的预测中，有多少被人类认为是正确的，而不是评估*accuracy*（算法正确识别了多少测试图像或物体）或*recall*（算法成功找到了多少所需图像或物体），这两者都需要一个完全标注的测试集。

我们热切期待物体识别数据集和算法的未来发展，并感谢ILSVRC作为这条道路上的垫脚石。

Acknowledgements 我们感谢斯坦福大学、北卡罗来纳大学教堂山分校、谷歌和Facebook对挑战赛的赞助，以及NVIDIA为ILSVRC2014的参与者提供的计算资源。我们感谢多年来的导师们：Lubomir Bourdev、Alexei Efros、Derek Hoiem、Jitendra Malik、Chuck Rosenberg和Andrew Zisserman。我们感谢PASCAL VOC的组织者与我们合作举办ILSVRC2010-2012。我们感谢斯坦福视觉实验室的所有成员对挑战赛的支持以及在此过程中对我们的包容。最后，也是最重要的，我们感谢所有研究人员，他们通过参与挑战赛并利用数据集推动计算机视觉的发展，使ILSVRC的努力取得了成功。

Appendix A ILSVRC2012-2014 image classification and single-object localization object categories

算盘，阿拉伯长袍，学位袍，手风琴，椰子，橡实南瓜，原声吉他，海军上将，猴面犬，阿富汗猎犬，非洲变色龙，非洲鳄鱼。

¹³ <http://webscope.sandbox.yahoo.com/catalog.php?datatype=i&did=67>

非洲象, 非洲灰鹦鹉, 非洲野犬, 鬣蜥, 伞菌, 航空母舰, 艾尔谷犬, 客机, 飞艇, 信天翁, 鳄鱼, 高山, 祭坛, 救护车, 美洲短吻鳄, 美洲黑熊, 美洲变色龙, 美洲白背顶, 美洲白鹭, 美洲龙虾, 美国斯塔福德梗, 两栖动物, 模拟时钟, 海藻鱼, 安哥拉兔, 蚂蚁, 养蜂场, 阿彭策尔犬, 围裙, 阿拉伯骆驼, 北极狐, 狄翁, 洋刺, 垃圾桶, 突击步枪, 澳洲梗, 美国纯口獭, 佛佛, 青包, 獾, 百吉饼, 面包包, 平衡木, 白头海雕, 气球, 棒球运动员, 圆珠笔, 香蕉, 创可贴, 带纹壁虎, 班卓琴, 楼梯扶手, 杠铃, 理发椅, 理发店, 谷仓, 谷仓蜘蛛, 气压计, 南乳鱼, 桶, 手推车, 棒球, 巴仙吉犬, 篮球, 巴吉度犬, 摇篮, 巴松管, 浴巾, 泳帽, 浴缸, 旅行车, 灯塔, 比格犬, 烧杯, 熊皮, 河狸, 贝灵顿梗, 蜜蜂, 蜂虎, 啤酒瓶, 啤酒杯, 钟楼, 甜椒, 伯恩山犬, 围嘴, 双人自行车, 大角羊, 比基尼, 活页夹, 双筒望远镜, 鸟屋, 野牛, 麻鸭, 黑黄圆珠, 黑琴鸟, 黑熊, 黑天鹅, 黑寡妇蜘蛛, 黑褐猎浣熊犬, 黑足猫, 布伦海姆西班牙猎犬, 寻血猎犬, 蓝斑猎犬, 蟒蛇, 船库, 雪橇, 牛肝菌, 波洛领带, 女帽, 书皮, 书架, 书店, 边境牧羊犬, 边境梗, 俄罗斯猎狼犬, 波士顿梗犬, 瓶装, 法兰德斯牧羊犬, 弓, 领结, 箱龟, 拳师犬, 布鲁塞尔格里芬犬, 脑珊瑚, 燕雀, 黄铜器, 胸罩, 防波堤, 胸甲, 布里牧犬, 布列塔尼猎犬, 西兰花, 扫帚, 棕熊, 气泡, 水桶, 七叶树果实, 扣环, 鸭, 斗牛犬, 子弹头列车, 防弹背心, 牛蛙, 墨西哥卷饼, 鸭, 肉铺, 冬瓜瓜, 出租车, 菜粉蝶, 石象, 大锅, 开罐器, 蜡烛, 大炮, 独木舟, 卷尾猴, 汽车后视镜, 汽车车轮, 培根蛋卷意大利面, 卡迪根犬, 开衫, 刺包菜蓟, 旋转木马, 木工工具箱, 纸箱, 取款机, 磁带, 磁带播放器, 城堡, 双体船, 花椰菜, CD播放器, 大提琴, 手机, 蜈蚣, 链条, 锁子甲, 链锯, 链环栅栏, 鹦鹉螺, 芝士汉堡, 猎豹, 切萨皮克湾寻回犬, 胸部, 山雀, 五斗柜, 吉娃娃, 编织, 黑猩猩, 瓷器柜, 石凳, 巧克力酱, 松狮犬, 圣诞袜, 花椰菜, 电影院, 切肉刀, 悬崖, 厨房, 斗篷, 木底鞋, 克伦伯猎犬, 公鸡, 可卡犬, 蜂蝎, 鸡尾酒调制器, 咖啡杯, 咖啡壶, 银链, 线圈, 柯利犬, 疣猴, 密码锁, 漫画书, 普通蜥蜴, 普通螺蛳, 电脑键盘, 海螺, 糖果店, 清汤, 集装箱船, 敞篷车, 珊瑚礁, 珊瑚礁, 开瓶器, 玉米, 短号, 鸚鵡, 美洲狮, 牛仔靴, 牛仔帽, 郊狼, 摇篮, 鹤, 起重机, 防撞头盖, 板条箱, 小龙虾, 婴儿床, 蟋蟀, 慢跑机, 髓球, 填字游戏, 拐杖, 黄瓜, 胸甲, 杯子, 卷毛寻回犬, 番荔枝, 雏菊, 斑点狗, 水坝, 豆娘, 丹迪丁蒙梗, 书桌, 台式电脑, 针, 拨盘电话, 菱背响尾蛇, 尿布, 数字钟, 电子表, 澳洲野犬, 餐桌, 抹布, 洗碗机, 盘式制动器, 杜宾犬, 码头, 狗拉雪橇, 圆顶, 门垫, 面团, 半蹼鹬, 蜻蜓, 公鸭, 钻井平台, 鼓, 鼓槌, 儒艮, 哑铃, 蜥蜴, 珍宝蟹, 荷兰烤猪, 耳朵, 地星, 针鼹, 鳗鱼, 水蛭, 蛋酒, 埃及猫, 电风扇, 电吉他, 电力机车, 电脑, 英国猎狐犬, 英国塞特犬, 英国史宾格犬, 娱乐中心, 恩斯特赫山地区, 信封, 爱斯基摩犬, 意式浓缩咖啡, 意式咖啡机, 欧洲火蜥蜴, 欧洲水鸡, 散粉, 羽毛围巾, 招潮蟹, 无花果, 文件, 消防车, 防火屏, 消防船, 旗杆, 火烈鸟, 平毛寻回犬, 扇形伞, 长笛, 苍鹭, 折叠椅, 橄榄球头盔, 叉车, 喷泵, 铜像, 四柱床, 狐松鼠, 货车车厢, 法国斗牛犬, 法国号, 法式长棍面包, 皱褶蜥, 煎锅, 皮大衣, 雀巢, 垃圾车, 园蛛, 束带蛇, 加油站, 防毒面具, 瞪羚, 德国牧羊犬, 德国短毛指示犬, 国歌泉, 大熊猫, 巨型雪纳瑞, 长臂猿, 毒蛇, 卡丁车, 高脚杯, 金毛寻回犬, 金翅雀, 金鱼, 高尔夫球, 高尔夫球车, 多拉拉, 锣, 鹅, 文登塞特犬, 大猩猩, 礼服, 三角钢琴, 青苹果, 蜻蜓, 大丹犬, 马林鸭, 大白熊犬, 大白鲨, 大瑞士山地犬, 绿蜥蜴, 绿曼巴蛇, 绿蛇, 温室, 灰狐, 灰熊, 格棚, 杂货店, 比利时特伏丹犬, 新郎, 步甲, 鸚鵡属, 长尾猴, 断头台, 豚鼠, 鹿花菌, 发夹, 发胶, 半履带车, 锤子, 双髻鲨, 洗衣篮, 仓鼠, 手摇吹风机, 掌上电脑, 手帕, 硬盘, 野兔, 口琴, 竖琴, 魔铃, 收割机, 盲蛛, 短柄小斧, 干草, 卷心菜, 母鸡, 灰树花, 寄居蟹, 臀部, 河马, 猪, 猪鼻蛇, 手枪皮套, 家庭影院, 蜂巢, 钩子, 裙撑, 单杠, 犀鸟, 角蛙, 马车, 火锅, 热狗, 沙漏, 家朱雀, 吼猴, 蜂鸟, 鬣狗, 北山羊, 伊比沙猎犬, 北极熊, 冰淇淋, 冰棒, 黑斑羚, 印度眼镜蛇, 印度象, 靛蓝彩鸦, 大狐猴, iPod, 爱尔兰塞特犬, 爱尔兰水猎犬, 爱尔兰猎狼犬, 鬃牛, 等足目动物, 意大利灵猫, 鸛属, 杰克灯, 菠萝蜜, 美洲豹, 日本种, 松鸦, 牛仔猴, 吉普车, 水母, 运动衫, 拼图, 人力车, 操纵杆, 灯罩, 荷兰毛狮犬, 凯尔皮犬, 凯利蓝梗, 虎鲸, 和服, 帝王蟹, 帝企鹅, 王蛇, 小狐, 风琴, 护膝, 绳结, 考拉, 科莫多巨蜥, 可蒙犬, 库瓦兹犬, 实验服, 拉布拉多寻回犬, 草蛉, 长柄勺, 瓢虫, 湖畔梗, 湖边, 灯罩, 叶猴, 笔记本电脑, 割草机, 叶甲, 叶蝉, 棱皮龟, 柠檬, 镜头盖, 莱昂伯格犬, 豹, 小熊猫, 拆信刀, 拉萨犬, 图书馆, 救生艇, 打火机, 豪华轿车, 秧鸭, 邮轮, 狮子, 狮子鱼, 口红, 小蓝鹭, 羊驼, 乐福鞋, 红海龟, 天平, 吸蜜鹦鹉, 乳液, 扬声器, 放大镜, 锯木厂, 灰蝶, 猓猴, 猕猴桃, 金剛鸚鵡, 马达加斯加猫, 磁罗盘, 喜鹊, 邮袋, 邮箱, 连体泳衣, 连体衣, 阿拉斯加雪橇犬, 马利诺斯犬, 马尔济斯犬, 并盖, 螳螂, 沙球, 马林巴琴, 猴猴, 土拨鼠, 土豆泥, 面具, 火柴, 五月柱, 迷宮, 量杯, 肉糕, 医药箱, 猫鼬, 巨石, 菜单, 墨西哥无毛犬, 麦克风, 微波炉, 军装, 牛奶罐, 迷你杜宾犬, 迷你贵宾犬, 迷你雪纳瑞, 小型巴士, 迷你裙, 小型货车, 水貂, 导弹, 手指手套, 搅拌碗, 活动房屋, T型车, 调制解调器, 黑脉金斑蝶, 修道院, 猫鼬, 显示器, 轻便摩托车, 迫击炮, mortarboard, 清真寺, 蚊帐, 踏板车, 山地自行车, 山地帐篷, 老鼠, 捕鼠器, 搬家货车, 泥龟, 蘑菇, 口套, 钉子, 颈托, 项链, 线虫, 纽芬兰犬, 夜蛇, 乳头, 诺福克梗, 挪威猎鹿犬, 诺里奇梗, 笔记本, 方尖碑, 双簧管, 陶笛, 里程表, 机油滤清器, 古代英国牧羊犬, 橙子, 猩猩, 管风琴, 示波器, 鸵鸟, 水獭, 水獭猎犬, 罩裙, 牛, 牛车, 氧气面罩, 蜥蜴, 小包, 明轮, 挂镜, 画笔, 睡衣, 宫殿, 排箫, 纸巾, 蝴蝶伞, 降落伞, 双杠, 公园长椅, 停车计时器, 鹈鹕, 客车, 赤猴, 露台, 付费电话, 孔雀, 基座, 北京犬, 鸛属, 彭布罗克威尔士柯基犬, 铅笔盒, 卷笔刀, 香水, 波斯猫, 培养皿, 复印机, 锅, 尖顶盔, 尖桩篱栅, 皮卡车, 码头, 存钱罐, 药瓶, 枕头, 菠萝, 乒乓球, 纸风车, 海盜, 水罐, 披萨, 飞机, 天文望远镜, 塑料袋, 盘子, 盘架, 鸭嘴兽, 犁, 皮鞭子, 宝丽来相机, 杆, 犀象, 警车, 石榴, 博美犬, 披风, 台球桌, 汽水瓶, 豪猪, 锅, potpie, 陶轮, 电钻, 草原松鸦, 祈祷毯, 椒盐卷饼, 打印机, 监狱, 长鼻猴, 抛射体, 投影仪, 海角, 雷鸟, 冰球, 河豚, 巴哥犬, 沙袋, 钱包, 鹈鹕, 羽茎, 被子, 赛车, 球拍, 散热器, 收音机, 射电望远镜, 雨水桶, 公羊, 油菜籽, 房车, 赤狐, 红葡萄酒, 红狼, 红背滨鹬, 红胸秋沙鸭, 红骨猎浣熊犬, 红脚鹬, 卷轴, 反光照相机, 冰箱, 遥控器, 餐厅, 左轮手枪, 犀龟, 罗德西亚脊背犬, 步枪, 小环, 环颈蛇, 知更鸟, 岩 beauty, 岩蜥, 岩蟒, 摇椅, 旋转烤肉架, 罗威纳犬, 橡皮擦, 翻石鹬, 披肩榛鸡, 橄榄球, 尺子, 跑鞋, 保险箱, 安全别针, 圣伯纳犬, 盐瓶, 萨路基猎犬, 萨摩耶犬, 凉鞋, 沙洲, 沙龙, 萨克斯管, 剑鞘, 秤, 比利时史基伯犬, 校车, 纵帆船, 记分牌, 蝎子, 苏格兰梗, 苏格兰猫头犬, 屏幕, 螺丝, 螺丝刀, 潜水员, 海藻, 海参, 海狮, 海蛞蝓, 海蛇, 海胆, 西里汉梗, 海滨, 安全带, 缝纫

机器, 设得兰牧羊犬, 盾牌, 西施犬, 鞋店, 障子, 购物篮, 购物车, 铲子, 浴帽, 浴巾, 合趾鞋, 暹罗猫, 西伯利亚哈士奇, 响尾蛇, 丝毛梗, 滑雪板, 滑雪面罩, 臭鼬, 睡袋, 计算尺, 推拉门, 插槽, 懒熊, 蛞蝓, 蜗牛, 呼吸器, 雪豹, 雪地摩托, 扫雪机, 皂液器, 足球, 袜子, 软毛麦色梗, 太阳能碟, 墨西哥宽边帽, 栗色马, 汤碗, 空格键, 取暖器, 航天飞机, 意大利面南瓜, 抹布, 快艇, 蜘蛛猴, 蜘蛛网, 纺锤, 刺龙虾, 琵琶, 跑车, 聚光灯, 斑点蛛蝎, 松鼠猴, 斯塔福德斗牛梗, 舞台, 标准贵宾犬, 标准雪纳瑞, 海星, 蒸汽机车, 钢拱桥, 钢鼓, 听诊器, 黄貂鱼, 鬼笔菌, 披肩, 石墙, 砂表, 炉子, 遮网, 草莓, 路牌, 有轨电车, 担架, 沙发床, 佛塔, 鲟鱼, 潜艇, 西装, 硫磺蝶, 葵花凤头鹦鹉, 日晷, 太阳镜, 太阳镜, 防晒霜, 悬索桥, 苏塞克斯猎犬, 棉签, 运动衫, 游泳裤, 秋千, 开关, 注射器, 虎斑猫, 台灯, 尾蛙, 坦克, 磁带播放器, 狼蛛, 茶壶, 秦帝熊, 电视, 丁鲷, 网球, 水龟, 茅草, 剧院幕布, 顶针, 三趾树懒, 长尾鲨, 王座, 雷蛇, 藏獒, 西藏梗, 蟬虫, 老虎, 虎甲虫, 虎猫, 虎鲨, 瓦屋顶, 森林狼, 伶猴, 烤面包机, 烟草店, 马桶座圈, 卫生纸, 火炬, 图腾柱, 巨嘴鸟, 拖车, 玩具贵宾犬, 玩具梗, 玩具店, 拖拉机, 交通灯, 拖挂卡车, 托盘, 树蛙, 风衣, 三角龙, 三轮车, 松糕, 三叶虫, 三体船, 三脚架, 凯旋门, 无轨电车, 长号, 浴缸, 旋转栅门, 长牙象, 打字机键盘, 雨伞, 独轮车, 立式钢琴, 吸尘器, 山谷, 花瓶, 拱顶, 天鹅绒, 自动售货机, 法衣, 高架桥, 藤蛇, 小提琴, 维兹拉犬, 火山, 排球, 秃鹰, 华夫饼煎斗, 步行猎犬, 手杖, 挂件, 小袋鼠, 钱包, 衣柜, 军用飞机, 疣猪, 洗脸盆, 洗衣机, 水瓶, 水牛, 水罐, 河马, 水蛇, 水塔, 黄鼠狼, 网站, 魏玛犬, 威尔士史宾格犬, 西部高地白梗, 惠比特犬, 鞭尾蜥, 威士忌酒壶, 哨子, 白鹇, 白狼, 假发, 野猪, 纱窗, 百叶窗, 温莎领带, 酒瓶, 翅膀, 刚毛猎狐梗, 炒锅, 狼蛛, 袋熊, 林兔, 木勺, 羊毛, 虫茧, 残骸, 小帆船, 黄杓兰, 约克夏梗, 蒙古包, 斑马, 西葫芦

Appendix B Additional single-object localization dataset statistics

我们考虑了物体定位难度的两个额外指标：定位的随机表现和杂波水平。我们使用这些指标来比较ILSVRC 2012-2014单物体定位数据集与PASCAL VOC 2012物体检测基准。定位难度的度量是在两个数据集的验证集上计算的。根据这两种难度度量，ILSVRC中存在一个子集，其挑战性与PASCAL相当，但规模要大一个数量级以上。图16展示了两数据集中不同类别间各种属性（物体尺度、定位的随机表现和杂波水平）的分布情况。

Chance performance of localization (CPL). 在数据集上的随机表现是一个常见的考量指标。我们将CPL度量为检测器的期望准确率，该检测器首先随机采样该类的一个物体实例，然后直接将其边界框用作所有其他图像上的定位窗口（在将图像调整到相同大小之后）。具体来说，令 $\{v^*\}$ 为某个类别内所有物体实例的边界框，则

$$\text{CPL} = \frac{\sum_i \sum_{j \neq i} \text{IOU}(B_i, B_j) \geq 0.5}{N(N-1)} \quad (6)$$

根据该指标，ILSVRC中最难定位的类别包括篮球、泳裤、乒乓球和橡皮擦，它们的CPL均低于0.2%。这一指标与物体的平均尺度（物体在图像中所占比例）高度相关（ $\rho = 0.9$ ）。整体平均CPL为

1000个ILSVRC类别的准确率是20.8%。20个PASCAL类别的平均CPL为8.7%，这与ILSVRC中562个最困难类别的CPL相同。

Clutter. 直观上，即使是很小的物体在纯色背景上也容易被定位。为了量化背景杂乱程度，我们采用了（Alex e等人，2012年）提出的物体性度量方法——这是一种类别无关的物体检测器，用于评估图像中某个窗口包含连贯物体（任意类别）而非背景（天空、水、草地）的可能性。对于每张包含目标物体实例的图像 m ，其目标实例位于位置 $B_1^m, B_2^m, \dots$ ，我们使用公开可用的物体性软件按窗口包含任意通用物体的概率降序采样1000个窗口 $W_1^m, W_2^m, \dots, W_{1000}^m$ 。设 $\text{OBJ}(m)$ 为在定位到目标类别实例前采样的类物体窗口数量，即 $\text{OBJ}(m) = \min\{k : \max_i \text{IOU}(W_k^m, B_i^m) \geq 0.5\}$ 。对于一个包含 M 张图像类别，我们计算每张图像中此类窗口的平均数量，并定义为

$$\text{CLUTTER} = \log_2\left(\frac{1}{M} \sum_m \text{OBJ}(m)\right) \quad (7)$$

一个类别的杂乱程度越高，根据通用线索定位物体的难度就越大。如果某个物体无法在前1000个窗口中被定位（在ILSVRC中平均每类别有1%的图像属于这种情况，在PASCAL中则为5%），我们设定 $\text{OBJ}(m) = 1001$ 。超过95%的物体能通过这些窗口实现定位，这一事实表明物体性线索已相当强，因此那些平均需要大量窗口的物体将极难检测：例如ILSVRC中的乒乓球（杂乱度9.57，平均需758个窗口）、篮球（杂乱度9.21）、冰球（杂乱度9.17）。PASCAL数据集中最困难的物体是瓶子，其杂乱度得分为8.47。ILSVRC的平均杂乱度得分为3.59。ILSVRC中最困难的250个物体类别子集，其类别数量多一个数量级，且平均杂乱度（5.90）与PASCAL数据集相同。

Appendix C Manually curated queries for obtaining object detection scene images

在3.3.2节中，我们讨论了用于收集目标检测图像的三种查询类型：(1) 单一目标类别名称或其同义词；(2) 一对目标类别名称；(3) 手动查询，通常针对一个或多个数据不足的目标类别。此处我们提供129条人工整理查询的列表：

下午茶, 蚂蚁搭桥, 狢猻赛跑, 狢猻庭院, 艺术家工作室, 听诊, 婴儿房, 班卓琴乐团, 班卓琴排练, 班卓琴表演, 卡利丰耳机与媒体播放器套装, 骆驼甜点, 骆驼游客, 木匠钻孔, 木工, 野生蜈蚣, 咖啡店, 大陆早餐烤面包机, 大陆早餐华夫饼, 扭扭行走, 沙漠蝎子, 小餐馆, 餐厅, 餐桌, 晚餐, 友善蜻蜓, 蜻蜓孩童, 蜻蜓池塘, 野生蜻蜓, 吹干头发, 哑铃弯举, 风扇吹风, 快餐, 快餐店, 劈柴, 流感疫苗, 金鱼水族馆, 金鱼缸, 高尔夫球场上的高尔夫球车, 健身房哑铃, 仓鼠喝水, 口琴乐团, 口琴排练, 口琴表演, 竖琴合奏, 竖琴乐团, 竖琴排练, 竖琴表演, 可爱刺猬, 刺猬地板, 隐藏刺猬, 河马鸟, 友善河马, 家装DIY电钻, 骑马, 酒店咖啡机, 酒店咖啡壶, 酒店华夫饼机, 水母潜水, 水母浮潜, 厨房, 厨房台面咖啡机, 厨房台面烤面包机, 小厨房, 喂食考拉, 考拉树, 瓢虫花, 瓢虫庭院, 自助洗衣店, 狮子斑马友善, 午餐, 邮递员, 做早餐, 做华夫饼, 墨西哥食物, 摩托车比赛, 办公室, 办公室风扇, 负鼠在树枝上, 管弦乐团, 熊猫玩耍, 熊猫树, 比萨店, 石榴树, 豪猪爬树, 电钻木匠, 钱包店, 小熊猫树, 骑马比赛, 骑摩托滑板车, 学校用品, 潜水海星, 海狮海滩, 海獭, 海胆栖息地, 购买学校用品, 坐在风扇前, 臭鼬和猫, 臭鼬公园, 野生臭鼬, 臭鼬庭院, 蜗牛花, 浮潜海星, 扫雪车清理, 扫雪车雪堆, 扫雪车冬季, 足球比赛, 南美动物园, 海星海洋世界, 开始购物, 燕洋鲷, 听诊器医生, 滤网意面, 滤网茶, 注射器医生, 摆满食物的桌子, 磁带播放器, 老虎马戏团, 宠物老虎, 使用开罐器, 使用电钻, 华夫饼机早餐, 野生狮子草原, 野生动物保护区动物, 擦盘子, 袋熊动物园, 斑马草原, 动物园喂食, 澳大利亚动物园

Appendix D Hierarchy of questions for full image annotation

以下是为众包对图像进行完整标注而手动构建的问题层级结构，这些图像涉及ILSVRC2013和ILSVRC2014中200个物体检测类别的存在与否。所有问题均采用“图像中是否有……？”的形式。标有{v*}的问题

● 每张图像都会被问到这些问题。如果某个问题的答案被确定为“否”，那么其所有后续问题的答案也被假定为“否”。200个带编号的叶节点对应着200个物体检测类别。


层次结构构建的目标是节省成本（通过对每张图像尽可能少地提问），同时避免问题中的任何歧义，以免在标注过程中导致假阴性。该层次结构并非树状结构；部分问题具有多个父节点。

Hierarchy of questions:

● 急救/医疗物品 ○ (1) 听诊器 ○ (2) 注射器 ○ (3) 颈托 ○ (4) 拐杖 ○ (5) 担架 ○ (6) 创可贴：用于覆盖小伤口或水疱的粘性绷带

● 乐器 ○ (7) 手风琴（一种便携式盒状自由簧乐器；通过演奏者控制风箱的气流使簧片振动） ○ (8) 钢琴 ○ 打击乐器：编钟、沙锤、鼓等 ○ (9) 编钟：一种由一组调音钟组成的打击乐器，用槌敲击演奏；常用作管弦乐器 ○ (10) 沙锤 ○ (11) 鼓 ○ 弦乐器 ○ (12) 班卓琴，琴身为圆形。请注意勿与吉他混淆 ○ (13) 大提琴：一种大型弦乐器；演奏者采用坐姿将其直立放置演奏 ○ (14) 小提琴：用琴弓演奏的四弦弓弦乐器，具有空心琴身和五品指板。请注意勿与演奏时需直立放置的大提琴混淆 ○ (15) 竖琴 ○ (16) 吉他，请注意勿与班卓琴混淆。班卓琴的琴身为圆形 ○ 管乐器：通过呼吸驱动封闭空气柱发声的乐器（如小号、圆号、口琴、长笛等） ○ (17) 小号：一种铜管乐器，具有细管和喇叭口，通过活塞按键演奏。顶部通常设有三个按键 ○ (18) 圆号：一种铜管乐器，由锥形管卷成螺旋状，末端带有喇叭口 ○ (19) 长号：一种铜管乐器，由长管构成，通过U形滑管改变管长 ○ (20) 口琴

**1000 classes of ILSVRC2012-2014 single-object localization (dark green)
versus 20 classes of PASCAL 2012 (light blue)**



**200 hardest classes of ILSVRC2012-2014 single-object localization (dark green)
versus 20 classes of PASCAL 2012 (light blue)**




Fig. 16 ILSVRC2012-2014单目标定位（深绿色）与PASCAL VOC 2012（浅蓝色）验证集上各类定位难度指标的分布情况。物体尺度指单个物体实例平均所占图像面积比例。定位的随机性能与背景杂乱程度的定义详见附录B。上方图表包含含1000个类别的完整ILSVRC验证集；下方图表包含ILSVRC中定位随机性能最低的200个类别。所有图表均包含PASCAL VOC的全部20个类别。

○ (21) 长笛：一种高音乐器，外形呈直管状，通常横向吹奏（请勿与双簧管混淆，双簧管具有独特的稻草状吹嘴和略微外扩的管口）○ (22) 双簧管：一种细长的乐器，长约65厘米，带有金属按键，具有独特的稻草状吹嘴，管口常略微外扩（请勿与长笛混淆）○ (23) 萨克斯管：一种由黄铜锥形管构成的乐器，末端常带有U形弯管

○ (52) 笔记本电脑，便携式电脑 ○ (53) 打印机（请勿将打字机视为打印机）○ (54) 计算机键盘 ○ (55) 灯具 ○ 电炊具（一种产生热量以烹饪食物或烧水的器具）○ (56) 微波炉 ○ (57) 烤面包机 ○ (58) 华夫饼机 ○ (59) 咖啡机：一种用于自动冲泡咖啡的厨房电器 ○ (60) 吸尘器 ○ (61) 洗碗机 ○ (62) 洗衣机：一种用于洗涤衣物的电器 ○ (63) 交通信号灯 ○ (64) 电视或显示器：一种以视觉形式呈现信息的电子设备 ○ (65) 数字时钟：一种以数字形式显示时间的时钟

● 食物：可供食用或饮用的物品（包括种植的水果、蔬菜和蘑菇，但不包括活体动物）○ 带面包或外皮的食物：椒盐卷饼、百吉饼、披萨、热狗、汉堡等 ○ (24) 椒盐卷饼 ○ (25) 百吉饼 ○ (26) 披萨 ○ (27) 热狗 ○ (28) 汉堡 ○ (29) 鳄梨酱 ○ (30) 墨西哥卷饼 ○ (31) 冰棒（插在小木棍上的冰淇淋或雪糕）○ 水果 ○ (32) 无花果 ○ (33) 菠萝 ○ (34) 香蕉 ○ (35) 石榴 ○ (36) 苹果 ○ (37) 草莓 ○ (38) 橙子 ○ (39) 柠檬 ○ 蔬菜 ○ (40) 黄瓜 ○ (41) 洋葱 ○ (42) 甜椒 ○ (43) 卷心菜 ○ (44) 蘑菇

● 厨房用品：通常在厨房中发现的工具、器皿和电器 ○ 电烹饪器具（一种产生热量以烹饪食物或烧水的器具）○ (56) 微波炉 ○ (57) 烤面包机 ○ (58) 华夫饼机 ○ (59) 咖啡机：一种用于自动冲泡咖啡的厨房电器 ○ (61) 洗碗机 ○ (66) 炉灶 ○ 用于打开罐头/瓶子的物品：开罐器或开瓶器 ○ (67) 开罐器 ○ (68) 开瓶器 ○ (69) 鸡尾酒摇酒器 ○ 厨房中常见的非电器物品：锅、平底锅、餐具、碗等 ○ (70) 滤网 ○ (71) 煎锅 ○ (72) 碗：一种用于盛放食物的圆形、顶部开口且无把手的器皿（请勿与杯子混淆，杯子通常有把手，用于盛放饮料）○ (73) 盐或胡椒粉：一种顶部有孔用于撒盐或胡椒粉的瓶子 ○ (74) 盘架 ○ (75) 锅铲：一种带有窄而灵活刀片的翻面工具 ○ (76) 长柄勺：一种长柄勺形容器；常用于将液体从一个容器转移到另一个容器 ○ (77) 冰箱

● 使用电力的物品（插电或使用电池）：包括时钟、麦克风、交通信号灯、计算机等 ○ (45) 遥控器，遥控 ○ 吹风的电子产品 ○ (46) 吹风机，电吹风 ○ (47) 电风扇：通过一个或多个表面的运动产生气流的设备（请勿考虑吹风机）○ 可以播放音乐或放大声音的电子产品 ○ (48) 磁带播放器 ○ (49) iPod ○ (50) 麦克风，话筒 ○ 计算机及计算机外围设备：鼠标、笔记本电脑、打印机、键盘等 ○ (51) 电脑鼠标

● 家具（包括长凳）

- (78) 书架：用于存放书籍的架子 ◦ (79) 婴儿床：供婴儿使用的小床，四周有围栏防止婴儿跌落 ◦ (80) 文件柜：用于有序存放文件的办公家具 ◦ (81) 长凳（供多人使用的长型座位，通常由木材或石头制成） ◦ (82) 椅子：供单人使用的有座面的家具；请注意不要与供多人使用的长凳或沙发混淆 ◦ (83) 沙发：供多人使用的软垫座椅；请注意不要与（由木材或石头制成的）长凳或（仅供单人使用的）椅子混淆 ◦ (84) 桌子

- 衣物，服装：设计用于穿戴在人体上的覆盖物 ◦ (85) 尿布：由折叠布料制成，穿过双腿并在腰部固定的服装；婴儿穿着以承接排泄物 ◦ 泳装：用于游泳或沐浴的衣物（泳衣、泳裤、泳帽） ◦ (86) 泳裤：男性游泳时穿着的泳装 ◦ (87) 泳帽：游泳或淋浴时佩戴以保持头发干燥的帽子 ◦ (88) 连体泳衣：女性的一件式泳装 ◦ 领带：男性穿着的正式颈部服饰（包括领结） ◦ (89) 领结：系成蝴蝶结形状的男性领饰 ◦ (90) 领带：用于装饰目的的长条布料，佩戴于颈部或肩部，置于衬衫领下并在喉部打结（非指领结） ◦ 头饰，头具：头部穿戴物（帽子、头盔、泳帽等） ◦ (87) 泳帽：游泳或淋浴时佩戴以保持头发干燥的帽子 ◦ (91) 宽檐帽 ◦ (92) 头盔：由硬质材料制成的防护头具，用于抵御击打 ◦ (93) 迷你裙：极短的裙子 ◦ (94) 胸罩：女性穿着的内衣，用于支撑胸部 ◦ (95) 太阳镜

- 生物（除人类外）：狗、蛇、鱼、昆虫、海胆、海星等。◦ 能飞的生物 ◦ (96) 蜜蜂 ◦ (97) 蜻蜓 ◦ (98) 瓢虫 ◦ (99) 蝴蝶 ◦ (100) 鸟 ◦ 不能飞的生物（请勿包含人类） ◦ 有2条或4条腿的生物（请勿包含人类）：◦ 哺乳动物（但请勿包含人类） ◦ 猫科动物（猫形动物）：猫、虎或狮 ◦ (101) 家猫 ◦ (102) 虎 ◦ (103) 狮 ◦ 犬科动物（狗形动物）：狗、鬣狗、狐狸或狼 ◦ (104) 狗、家犬、犬属熟悉种 ◦ (105) 狐狸：野生食肉哺乳动物，口鼻尖、耳尖，尾毛浓密（请勿与狗混淆） ◦ 有蹄动物：骆驼、大象、河马、猪、羊等 ◦ (106) 大象 ◦ (107) 河马 ◦ (108) 骆驼 ◦ (109) 猪类：猪或野猪 ◦ (110) 绵羊：毛茸茸的动物，雄性有大型螺旋角（请勿与腿长的羚羊混淆） ◦ (111) 牛类：奶牛或公牛（家养牛科动物） ◦ (112) 斑马 ◦ (113) 马 ◦ (114) 羚羊：姿态优雅的动物，腿长，角向上后方弯曲 ◦ (115) 松鼠 ◦ (116) 仓鼠：短尾穴居啮齿动物，有大型颊囊 ◦ (117) 水獭 ◦ (118) 猴子 ◦ (119) 树袋熊 ◦ (120) 熊（除熊猫外） ◦ (121) 臭鼬（以其能喷射强烈气味液体而闻名的哺乳动物；其背部及尾部可能有一条粗条纹、两条细条纹或一系列白斑与断续条纹） ◦ (122) 兔子 ◦ (123) 大熊猫：以独特黑白斑纹为特征的动物 ◦ (124) 小熊猫：红褐色、类似浣熊的旧大陆食肉动物 ◦ (125) 蛙、蟾蜍 ◦ (126) 蜥蜴：请勿与蛇混淆（蜥蜴有腿） ◦ (127) 龟 ◦ (128) 玳瑁 ◦ (129) 豪猪、刺猬 ◦ 有6条或更多腿的生物：龙虾、蝎子、昆虫等 ◦ (130) 龙虾：大型海洋甲壳动物，身体长，尾部肌肉发达；五对腿中有三对带钳 ◦ (131) 蝎子 ◦ (132) 蜈蚣：节肢动物，身体扁平，有15至173个体节，每节有一对腿，最前一对特化为捕食肢 ◦ (133) 蝉虫（一种有4对腿的小型生物，以哺乳动物和鸟类的血液为食） ◦ (134) 等足目动物：小型甲壳动物，有七对适于爬行的腿 ◦ (135) 蚂蚁 ◦ 无腿生物：鱼、蛇、海豹等（请勿包含植物） ◦ 生活在水中的生物：海豹、鲸、鱼、海参等 ◦ (136) 水母 ◦ (137) 海星 ◦ (138) 海豹 ◦ (139) 鲸 ◦ (140) 鳐鱼：海洋动物，身体水平扁平，胸鳍扩大如翼，鳃位于身体下方 ◦ (141) 金鱼：金色或橙红色的小型鱼类 ◦ 在陆地上滑行的生物：蠕虫、蜗牛、蛇 ◦ (142) 蜗牛 ◦ (143) 蛇：请勿与蜥蜴混淆（蛇没有腿）

- 车辆：用于将人或物体从一地移动到另一地的任何物体 ◦ 带轮子的车辆 ◦ (144) 高尔夫球车 ◦ (145) 扫雪机：用于清除道路积雪的车辆 ◦ (146) 摩托车（或助力车） ◦ (147) 汽车（非高尔夫球车或巴士） ◦ (148) 巴士：运载多名乘客的车辆；用于公共交通 ◦ (149) 火车 ◦ (150) 畜力车：通常有两个轮子、由动物牵引的敞篷重型货车 ◦ (151) 自行车：通过脚踏板驱动的两轮车辆 ◦ (152) 独轮车 ◦ 无轮车辆（雪地摩托、雪橇） ◦ (153) 雪地摩托：用于雪地行驶的履带式车辆 ◦ (154) 水上交通工具（如轮船或小船）：设计用于水上运输的载具 ◦ (155) 飞机：由螺旋桨或喷气发动机驱动的航空器

- 化妆品：用于美化身体的盥洗用品 ◦ (156) 粉饼 ◦ (157) 香水、香精（通常比发胶瓶更小） ◦ (158) 发胶 ◦ (159) 乳霜、药膏、乳液 ◦ (160) 口红、唇彩

- 木工用品：木工中使用的物品，包括钉子、锤子、斧头、螺丝刀、钻头、链锯等 ◦ (161) 链锯 ◦ (162) 钉子：一端有头、另一端呈尖状的针形物 ◦ (163) 斧头：常用于砍伐树木/木材的锋利工具 ◦ (164) 锤子：用于敲入钉子或砸碎物体的钝头手工具（请注意勿与锋利的斧头混淆） ◦ (165) 螺丝刀 ◦ (166) 电钻：用于在硬质材料上钻孔的电动工具

- 文具用品：尺子、橡皮、卷笔刀、铅笔盒、活页夹 ◦ (167) 尺子，规则：由一条木制、金属或塑料直边条组成的测量工具，用于画直线和测量长度 ◦ (168) 橡皮擦，橡胶，铅笔擦 ◦ (169) 卷笔刀 ◦ (170) 铅笔盒，笔袋 ◦ (171) 活页夹，环扣文件夹

- 体育用品：用于体育运动或健身的物品（如滑雪板、球拍、体操杠、弓、沙袋、球） ◦ (172) 弓：射箭武器，由弹性木材弯曲制成，配以绷紧的弦以推动箭矢 ◦ (173) 冰球：硫化橡胶制成的圆盘，直径3英寸，在冰球运动中替代球使用 ◦ (174) 滑雪板 ◦ (175) 球拍 ◦ 体操器械：双杠、平衡木等 ◦ (176) 平衡木：体操用的水平横杆，离地架起且宽度足以行走 ◦ (177) 单杠：体操器械；运动员用手抓握（请勿与可行走的平衡木混淆） ◦ 球 ◦ (178) 高尔夫球 ◦ (179) 棒球 ◦ (180) 篮球 ◦ (181) 网球 ◦ (182) 足球 ◦ (183) 乒乓球 ◦ (184) 橄榄球 ◦ (185) 排球 ◦ (186) 网球 ◦ (187) 沙袋 ◦ (188) 哑铃：锻炼用重物；由短杆连接两个球体作为手柄

- 液体容器：通常盛装液体的器皿，如瓶子、罐子等。◦ (189) 水罐：带手柄和倒水口的容器 ◦ (190) 烧杯：由玻璃或塑料制成的平底广口杯；用于化学实验 ◦ (191) 牛奶罐 ◦ (192) 皂液器 ◦ (193) 酒瓶 ◦ (194) 水瓶 ◦ (195) 杯子或马克杯（通常带手柄且多为圆柱形）

- 包 ◦ (196) 背包：用背带背在背上或肩上的包 ◦ (197) 钱包：装钱用的小包 ◦ (198) 塑料袋

- (199) 人
- (200) 花盆：用于栽培植物的容器

Appendix E Modification to bounding box system for object detection

第3.2.1节中描述的边界框标注系统，既用于单目标定位数据集也用于目标检测数据集的图像标注。然而，在目标检测场景中，为确保准确性还需要进行两项额外的人工后处理：

Ambiguous objects. 第一个常见的错误来源是工人在标注过程中无法准确区分某些物体类别。一些常见的混淆标签包括海豹和海獭、背包和钱包、班卓琴和吉他、小提琴和大提琴、铜管乐器（小号、长号、圆号及其他铜管乐器）、长笛和双簧管、长柄勺和锅铲。尽管我们尽了最大努力（在标注任务中提供正反例图片，添加文字说明以提醒用户注意这些类别之间的区别），这些错误仍然持续存在。

在单目标定位设置中，这个问题并不那么突出，原因有二。首先，数据收集方式对图像中存在的物体类别施加了强先验。其次，由于每张图像只需标注一个物体类别，存在歧义的图像可直接被剔除：例如，如果标注人员无法就图像中是否确实存在小号达成一致，这张图像便可直接移除。相比之下，在目标检测设置中，必须对所有图像中的所有目标类别达成标注共识。

为了解决这个问题，一旦收集到边界框标注，我们便手动检查了所有两个不同物体类别的边界框存在显著重叠的情况（约占收集框的3%）。其中约四分之一的框被发现对应错误的物体，因此被移除。虽然可以通过众包完成这一后处理步骤（需设定极其严格的准确度要求），但由于此类情况较少，内部处理反而更快捷（且更准确）。

Duplicate annotations. 第二个常见的错误来源是在同一物体实例上绘制了重复的边界框。尽管已明确指示不要在同一物体实例周围绘制多个边界框，且标注界面强制要求不同边界框之间至少存在5像素的差异，这类错误仍然存在。原因之一是初始边界框有时不够精确，后续标注者会绘制一个略微优化的替代框。

这类错误在单目标定位场景中同样存在，但并非主要关注点。重复的边界框是轻微扰动但仍正确的正例，而单目标定位仅关注正确定位单个目标实例。对于检测任务，算法需评估其定位 *every* 个目标实例的能力，并对重复检测进行惩罚，因此必须修正这些标注错误（即使它们仅出现在约0.6%的情况下）。

大约1%的边界框被发现与另一个边界框存在超过50%的显著重叠。

同一物体类别的其他边界框。我们再次在内部手动核验了所有这些情况。大约40%的情况下，两个边界框正确对应了人群中不同的个体、堆叠的盘子，或是管弦乐队中相邻的乐器。在其余60%的情况下，其中一个边界框被随机移除。

这些验证步骤完成了检测任务中验证集、测试集及部分训练集图像内每个对象类别的每个实例周围边界框的标注流程。

Training set annotation. 利用第3.3.3节的优化算法，我们完成了验证集和测试集的完整标注。然而，为 *all* 张训练图像标注所有目标物体类别仍存在预算限制。从单物体定位数据集中提取的正样本训练图像已包含每张图像中单个物体类别的所有实例边界框标注。我们通过两项调整将现有标注扩展至检测数据集：首先，修正因合并细粒度类别导致的边界框遗漏——例如，若某图像属于“达尔马提亚犬”类别，且单物体定位任务中已标注所有“达尔马提亚犬”实例的边界框，我们会确保为物体检测任务补标所有剩余的“狗”类实例。其次，针对“人物”类别收集了更多训练数据，因为现有标注集的多样性不足以形成代表性样本（单物体定位任务中仅包含潜水员、新郎和球员三类人物）。为此，我们额外对现有训练集图像中的大量人物实例进行了标注。

Appendix F Competition protocol

Competition format. 每年竞赛期开始时，我们会发布新的训练/验证/测试图像、训练/验证标注以及当年的竞赛规范。随后我们会设定提交截止日期，通常在数据发布后约4个月左右。参赛团队需在此截止日期前将测试图像的预测标注文本文件上传至指定服务器。我们将评估所有提交结果并公布成绩。

对于每个任务，我们都发布了代码，该代码接收一个自动生成的图像标注文本文件，并将其与真实标注进行比较，以返回算法准确性的量化指标。团队可以使用此代码在验证数据上评估他们的表现。

如(Everingham等人, 2014年)所述, 衡量测试数据性能有三种选择: (i) 发布测试图像和标注, 允许参与者自行评估性能; (ii) 发布测试图像但不发布测试标注——参与者提交结果, 组织者评估性能; (iii) 既不发布测试图像也不发布标注——参与者提交软件, 组织者在新数据上运行并评估性能。遵循PASCAL VOC的选择, 我们采用了选项(ii)。选项(i)在过拟合测试数据方面给予过多自由; 选项(iii)不可行, 特别是考虑到我们测试集的规模(4万至10万张图像)。

我们发布了ILSVRC2010图像分类任务的测试标注, 但所有其他测试标注仍处于隐藏状态, 以防止在测试数据上进行微调优化结果。

Evaluation protocol after the challenge. 在挑战期结束后, 我们建立了一个自动评估服务器, 研究人员全年都可以使用该服务器, 继续根据真实测试标注来评估他们的算法。我们限制每个团队每周只能提交2次, 以防止在测试数据上进行参数调优, 实际上我们从未遇到过研究人员滥用系统的问题。

*参考文献

- Ahonen, T., Hadid, A., and Pietikinen, M. (2006). 基于局部二值模式的人脸描述: 应用于人脸识别。 *PAMI*, 28.
- Alexe, B., Deselaers, T., and Ferrari, V. (2012). 测量图像窗口的物体性。收录于 *PAMI*。 Arandjelovic, R. and Zisserman, A. (2012). 提升物体检索效果需知的三个要点。收录于 *CVPR*。 Arbelaez, P., Maire, M., Fowlkes, C., and Malik, J. (2011). 轮廓检测与分层图像分割。 *IEEE TPAMI*, 33. Arbeláez, P., Pont-Tuset, J., Barron, J., Marques, F., and Malik, J. (2014). 多尺度组合分组。收录于 *Computer Vision and Pattern Recognition*。 Batra, D., Agrawal, H., Banik, P., Chavali, N., Mathialagan, C. S., and Alfadda, A. (2013). Cloudcv: 作为云服务的大规模分布式计算机视觉。 Bell, S., Upchurch, P., Snavely, N., and Bala, K. (2013). OpenSurfaces: 一个包含丰富标注的表面外观目录。收录于 *ACM Transactions on Graphics (SIGGRAPH)*。 Berg, A., Farrell, R., Khosla, A., Krause, J., Fei-Fei, L., Li, J., and Maji, S. (2013). 细粒度竞赛。 <https://sites.google.com/site/fgcomp2013/>。
- Chatfield, K., Simonyan, K., Vedaldi, A., and Zisserman, A. (2014). 重返细节中的魔鬼: 深入探究卷积网络。 *CoRR*, abs/1405.3531。
- Chen, Q., Song, Z., Huang, Z., Hua, Y., and Yan, S. (2014). 目标检测与分类的情境化。卷 PP。 Crammer, K., Dekel, O., Keshet, J., Shalev-Shwartz, S., and Singer, Y. (2006). 在线被动-主动算法。 *Journal of Machine Learning Research*, 7:551–585。 Criminisi, A. (2004). 微软剑桥研究院(MSRC)目标识别图像数据库(版本2.0)。 <http://research.microsoft.com/vision/cambridge/recognition>。
- Dean, T., Ruzon, M., Segal, M., Shlens, J., Vijayanarasimhan, S., and Yagnik, J. (2013). 单机上快速、准确地检测 100,000 个目标类别。于 *CVPR*。 Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. (2009). ImageNet: 一个大规模分层图像数据库。于 *CVPR*。 Deng, J., Russakovsky, O., Krause, J., Bernstein, M., Berg, A. C., and Fei-Fei, L. (2014). 可扩展的多标签标注。于 *CHI*。 Donahue, J., Jia, Y., Vinyals, O., Hoffman, J., Zhang, N., Tzeng, E., and Darrell, T. (2013). Decaf: 用于通用视觉识别的深度卷积激活特征。 *CoRR*, abs/1310.1531。
- Dubout, C. and Fleuret, F. (2012). 线性目标检测器的精确加速。于 *Proceedings of the European Conference on Computer Vision (ECCV)*。 Everingham, M., Eslami, S. M. A., Van Gool, L., Williams, C. K. I., Winn, J., and Zisserman, A. (2014). Pascal 视觉目标类别(VOC)挑战赛 - 回顾。 *IJCV*。 Everingham, M., Gool, L. V., Williams, C., Winn, J., and Zisserman, A. (2005-2012). PASCAL 视觉目标类别挑战赛(VOC)。 <http://www.pascal-network.org/challenges/VOC/voc2012/workshop/index.html>。
- Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., and Zisserman, A. (2010). The Pascal Visual Object Classes (VOC) 挑战赛。 *IJCV*, 88(2):303–338. Fei-Fei, L., Fergus, R., and Perona, P. (2004). 从少量样本学习生成式视觉模型: 一种在101个物体类别上测试的增量贝叶斯方法。于 *CVPR*。 Fei-Fei, L. and Perona, P. (2005). 一种用于学习自然场景类别的贝叶斯分层模型。于 *CVPR*。 Felzenszwalb, P., Girshick, R., McAllester, D., and Ramanan, D. (2010). 基于判别式的物体检测。

- 基于部件的模型经过相对训练。PAMI, 32。Frome, A., Corrado, G., Shlens, J., Bengio, S., Dean, J., Ranzato, M., 和 Mikolov, T. (2013)。Devise: 一种深度视觉语义嵌入模型。发表于 *Advances In Neural Information Processing Systems, NIPS*。Geiger, A., Lenz, P., Stiller, C., 和 Urtasun, R. (2013)。视觉与机器人学的相遇: KITTI数据集。 *International Journal of Robotics Research (IJRR)*。Girshick, R., Donahue, J., Darrell, T., 和 Malik, J. (2014)。用于精确目标检测和语义分割的丰富特征层次结构。发表于 *CVPR*。Girshick, R. B., Donahue, J., Darrell, T., 和 Malik, J. (2013)。用于精确目标检测和语义分割的丰富特征层次结构 (v4)。 *CoRR*。Gould, S., Fulton, R., 和 Koller, D. (2009)。将场景分解为几何和语义一致的区域。发表于 *ICCV*。Graham, B. (2013)。用于在线字符识别的稀疏签名数组。 *CoRR*。Griffin, G., Holub, A., 和 Perona, P. (2007)。Caltech-256 目标类别数据集。技术报告 7694, 加州理工学院。Harada, T. 和 Kuniyoshi, Y. (2012)。用于图像分类的图形高斯向量。发表于 *NIPS*。Harel, J., Koch, C., 和 Perona, P. (2007)。基于图的视觉显著性。发表于 *NIPS*。He, K., Zhang, X., Ren, S., 和 Su, J. (2014)。深度卷积网络中用于视觉识别的空间金字塔池化。发表于 *ECCV*。Hinton, G. E., Srivastava, N., Krizhevsky, A., Sutskever, I., 和 Salakhutdinov, R. (2012)。通过防止特征检测器的共适应来改进神经网络。 *CoRR*, abs/1207.0580。Hoiem, D., Chodpathumwan, Y., 和 Dai, Q. (2012)。诊断目标检测器中的错误。发表于 *ECCV*。Howard, A. (2014)。基于深度卷积神经网络的图像分类的一些改进。 *ICLR*。Huang, G. B., Ramesh, M., Berg, T., 和 Learned-Miller, E. (2007)。野外标记人脸: 用于研究无约束环境中人脸识别的数据库。技术报告 07-49, 马萨诸塞大学阿默斯特分校。Iandola, F. N., Moskewicz, M. W., Karayev, S., Girshick, R. B., Darrell, T., 和 Keutzer, K. (2014)。Densenet: 实现高效的卷积网络描述符金字塔。 *CoRR*。Jia, Y. (2013)。Caffe: 一种用于快速特征嵌入的开源卷积架构。 <http://caffe.berkeleyvision.org/>。Jojic, N., Frey, B. J., 和 Kannan, A. (2003)。外观和形状的 epitomic 分析。发表于 *ICCV*。Kanezaki, A., Inaba, S., Ushiku, Y., Yamashita, Y., Murao, H., Kuniyoshi, Y., 和 Harada, T. (2014)。用于多目标检测的困难负类。于 *ICRA*。Khosla, A., Jayadevaprakash, N., Yao, B., 和 Fei-Fei, L. (2011)。用于细粒度图像分类的新数据集。于 *First Workshop on Fine-Grained Visual Categorization, CVPR*。Krizhevsky, A., Sutskever, I., 和 Hinton, G. (2012)。使用深度卷积神经网络进行ImageNet分类。于 *NIPS*。Kuetzel, D., Guillaumin, M., 和 Ferrari, V. (2012)。ImageNet中的分割传播。于 *eccv*。Lazebnik, S., Schmid, C., 和 Ponce, J. (2006)。超越词袋特征: 用于识别自然场景类别的空间金字塔匹配。于 *CVPR*。Lin, M., Chen, Q., 和 Yan, S. (2014a)。网络中的网络。 *ICLR*。Lin, T.-Y., Maire, M., Belongie, S., Hay, S., Perona, P., Ramanan, D., Dollr, P., 和 Zitnick, C. L. (2014b)。Microsoft COCO: 上下文中的常见物体。于 *ECCV*。Lin, Y., Lv, F., Cao, L., Zhu, S., Yang, M., Cour, T., Yu, K., 和 Huang, T. (2011)。大规模图像分类: 快速特征提取与SVM训练。于 *CVPR*。Liu, C., Yuen, J., 和 Torralba, A. (2011)。通过标签传递进行非参数场景解析。 *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(12)。Lowe, D. G. (2004)。来自尺度不变关键点的独特图像特征。 *IJCV*, 60(2):91–110。Maji, S. 和 Malik, J. (2009)。使用最大间隔霍夫变换进行目标检测。于 *CVPR*。Manen, S., Guillaumin, M., 和 Van Gool, L. (2013)。使用随机Prim算法生成主要物体提议。于 *ICCV*。Mensink, T., Verbeek, J., Perronnin, F., 和 Csurka, G. (2012)。大规模图像分类的度量学习: 以接近零成本泛化到新类别。于 *ECCV*。Mikolov, T., Chen, K., Corrado, G., 和 Dean, J. (2013)。向量空间中词表示的高效估计。 *ICLR*。Miller, G. A. (1995)。WordNet: 英语词汇数据库。 *Commun. ACM*, 38(11)。Oliva, A. 和 Torralba, A. (2001)。场景形状建模: 空间包络的整体表示。 *IJCV*。Ordonez, V., Deng, J., Choi, Y., Berg, A. C., 和 Berg, T. L. (2013)。从大规模图像分类到入门级类别。于 *IEEE International Conference on Computer Vision (ICCV)*。

欧阳、罗、曾、邱、田、李、杨、王、熊、钱、朱、王、罗伊、王、唐 (2014)。DeepID-net: 用于目标检测的多阶段可变形深度卷积神经网络。CoRR, abs/1409.3505。欧阳与王 (2013)。行人检测的联合深度学习。收录于ICCV。Papandreou (2014)。深度缩影卷积神经网络。CoRR。Papandreou、陈、Yuille (2014)。使用微型缩影通用字典建模图像块。Perronnin、Akata、Harchaoui、Schmid (2012)。面向大规模图像分类的良好实践。收录于CVPR。Perronnin与Dance (2007)。视觉词汇上的Fisher核用于图像分类。收录于CVPR。Perronnin、Sánchez、Mensink (2010)。改进Fisher核以用于大规模图像分类。收录于ECCV (4)。Russakovsky、邓、黄、Berg、Fei-Fei (2013)。从牛油果到西葫芦的检测: 我们做了什么, 又将走向何方? 收录于ICCV。Russell、Torralba、Murphy、Freeman (2007)。LabelMe: 图像标注数据库与基于Web的工具。IJCV。Sánchez与Perronnin (2011)。面向大规模图像分类的高维特征压缩。收录于CVPR。Sánchez、Perronnin、de Campos (2012)。超越空间金字塔的图像空间布局建模。收录于PRL。Scheirer、Kumar、Belhumeur、Boulton (2012)。多属性空间: 属性融合与相似性搜索的校准。收录于CVPR。Schmidhuber (2012)。用于图像分类的多列深度神经网络。收录于CVPR。Sermanet、Eigen、张、Mathieu、Fergus、LeCun (2013)。OverFeat: 使用卷积网络实现集成识别、定位与检测。CoRR, abs/1312.6229。Sheng、Provost、Ipeirotis (2008)。获取更多标注? 利用多重噪声标注者提升数据质量与数据挖掘。收录于SIGKDD。Simonyan、Vedaldi、Zisserman (2013)。用于大规模图像分类的深度Fisher网络。收录于NIPS。Simonyan与Zisserman (2014)。用于大规模图像识别的极深度卷积网络。CoRR, abs/1409.1556。

索罗金, A. 和福赛斯, D. (2008)。使用亚马逊 Mechanical Turk 进行效用数据标注。于 InterNet08。苏, H., 邓, J., 和李飞飞 (2012)。众包视觉对象检测标注。于 AAAI Human Computation Workshop。塞格迪, C., 刘, W., 贾, Y., 塞尔马内, P., 里德, S., 安圭洛夫, D., 埃尔汉, D., 和拉比诺维奇, A. (2014)。通过卷积网络深入探索。技术报告。唐Y. (2013)。使用支持向量机进行深度学习。CoRR, abs/1306.0239。索普S., 菲兹, D., 马洛, C., 等 (1996)。人类视觉系统的处理速度。nature, 381(6582):520–522。托拉尔巴A. 和埃夫罗斯, A. A. (2011)。对数据集偏差的无偏见审视。于 CVPR'11。托拉尔巴A., 弗格斯, R., 和弗里曼, W. (2008)。8000 万张微小图像: 用于非参数对象和场景识别的大规模数据集。于 PAMI。尤林斯J., 范德桑德, K., 格弗斯, T., 和斯梅尔德斯, A. (2013)。用于对象识别的选择性搜索。International Journal of Computer Vision。乌尔塔松, R., 弗格斯, R., 霍伊姆, D., 托拉尔巴, A., 盖格, A., 伦茨, P., 西尔伯曼, N., 肖, J., 和菲德勒, S. (2013-2014)。重建与识别挑战赛。<http://ttic.uchicago.edu/~rurtasun/rmrc/>。范德桑德, K. E. A., 格弗斯, T., 和斯诺克, C. G. M. (2010)。评估用于对象和场景识别的颜色描述符。IEEE Transactions on Pattern Analysis and Machine Intelligence, 32(9):1582–1596。范德桑德K. E. A., 格弗斯, T., 和斯诺克, C. G. M. (2011a)。利用 GPU 增强视觉分类能力。IEEE Transactions on Multimedia, 13(1):60–70。范德桑德, K. E. A., 斯诺克, C. G. M., 和斯梅尔德斯, A. W. M. (2014)。具有 Flair 的 Fisher 和 VLAD。于 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition。范德桑德K. E. A., 尤林斯, J. R. R., 格弗斯, T., 和斯梅尔德斯, A. W. M. (2011b)。分割作为对象识别的选择性搜索。于 ICCV。维塔亚科恩S. 和海斯, J. (2011)。众包对象标注的质量评估。于 BMVC。凌, L. 和达比什, L. (2005)。ESP: 通过计算机游戏标注图像。于 AAAI Spring Symposium: Knowledge Collection from Volunteer Contributors。冯德里克C., 帕特森, D., 和拉马南, D. (2012)。高效扩展众包视频标注。International Journal of Computer Vision。万L., 蔡勒, M., 张, S., 勒昆, Y., 和弗格斯, R. (2013)。使用 DropConnect 正则化神经网络。于 Proc. International Conference on Machine learning (ICML'13)。

王建、杨建、余凯、吕帆、黄通和龚宇（2010）。用于图像分类的局部约束线性编码。于 *CVPR*。王明、肖涛、李健、洪晨、张健和张志（2014）。Minerva：一个可扩展且高效的大规模深度学习训练平台。于 *APSys*。王旭、杨明、朱松纯和林胤（2013）。用于通用目标检测的Regionlets方法。于 *ICCV*。韦林德、布兰森、贝隆吉和佩罗纳（2010）。群体的多维智慧。于 *NIPS*。肖剑、海斯、埃辛格、奥利瓦和托拉尔巴（2010）。SUN数据库：从修道院到动物园的大规模场景识别。于 *CVPR*。杨建、余凯、龚宇和黄通（2009）。基于稀疏编码的线性空间金字塔匹配用于图像分类。于 *CVPR*。姚斌、杨旭和朱松纯（2007）。大规模通用真实标注数据集介绍：方法、标注工具与基准测试。泽勒和弗格斯（2013）。卷积网络的可视化与理解。 *CoRR*, abs/1311.2901。泽勒、泰勒和弗格斯（2011）。用于中高层特征学习的自适应反卷积网络。于 *ICCV*。周博、拉佩德里扎、肖剑、托拉尔巴和奥利瓦（2014）。基于Places数据库学习场景识别的深度特征。 *NIPS*。周曦、余凯、张潼和黄通（2010）。使用局部图像描述子超向量编码的图像分类方法。于 *ECCV*。