

RT-DETRv4：基于视觉基础模型轻松推进实时目标检测

廖子隽^{1†} 赵一安^{1†} 单欣¹ 严宇¹ 刘畅² 卢磊¹ 季向阳^{2✉} 陈杰^{1✉}

¹School of Electronic and Computer Engineering, Peking University, Shenzhen, China

²Department of Automation and BNRist, Tsinghua University, Beijing, China

zjliao25@stu.pku.edu.cn zhaoyan@stu.pku.edu.cn

摘要

Real-time object detection has achieved substantial progress through meticulously designed architectures and optimization strategies. However, the pursuit of high-speed inference via lightweight network designs often leads to degraded feature representation, which hinders further performance improvements and practical on-device deployment. In this paper, we propose a cost-effective and highly adaptable distillation framework that harnesses the rapidly evolving capabilities of Vision Foundation Models (VFM) to enhance lightweight object detectors. Given the significant architectural and learning objective disparities between VFMs and resource-constrained detectors, achieving stable and task-aligned semantic transfer is challenging. To address this, on one hand, we introduce a **Deep Semantic Injector (DSI)** module that facilitates the integration of high-level representations from VFMs into the deep layers of the detector. On the other hand, we devise a **Gradient-guided Adaptive Modulation (GAM)** strategy, which dynamically adjusts the intensity of semantic transfer based on gradient norm ratios. Without increasing deployment and inference overhead, our approach painlessly delivers striking and consistent performance gains across diverse DETR-based models, underscoring its practical utility for real-time detection. Our new model family, RT-DETRv4, achieves state-of-the-art results on COCO, attaining AP scores of 49.7/53.5/55.4/57.0 at corresponding speeds of 273/169/124/78 FPS.

1. 引言

实时目标检测是计算机视觉中的一项基础任务，它支撑着众多需要即时感知与决策的交互式和安全关键型应用，例如自动驾驶[5]、具身智能[21]以及人机交互—




图1. 与COCO数据集[20]上现有先进实时目标检测器相比，我们的RT-DETRv4模型实现了最先进的性能。

tion [16]。过去十年中，网络架构的日益高效和端到端学习框架推动了显著进展。特别是YOLO [30]和DETR [3]这两个代表性系列，深刻影响了目标检测范式的演进。YOLO系列强调快速单阶段检测，实现了高推理速度和实际部署效率；而DETR系列则通过对目标查询的统一建模和基于集合的预测，重塑了检测范式。在其变体中，RT-DETR [38]作为首个实时DETR模型具有里程碑意义，它以速度和精度均超越YOLO模型的表现，将DETR系列引入了实时检测领域。

尽管取得了显著进展，一个长期存在的挑战依然存在：设计轻量级模型以实现高推理速度与采用复杂架构以提升特征表示能力之间的固有权衡。

[†]Equal contribution. ✉Corresponding author. Code and models will be open source very soon.

为了满足实时性约束，检测器通常采用轻量级骨干网络和精心设计的计算模块，这不可避免地降低了其捕获高层语义的能力，并导致语义瓶颈。这一限制不仅阻碍了性能的进一步提升，也增加了实际设备端部署的难度。

本文受视觉基础模型（VFM）[13, 31]快速发展的启发，提出了一种成本效益高、适应性强的蒸馏框架，利用VFM强大的表征能力来增强轻量级目标检测器。通过在训练阶段将VFM丰富的语义信息迁移到实时检测器中，同时在推理阶段保持检测器架构不变，我们的方法能够在不引入任何额外推理或部署成本的情况下实现显著性能提升。这一优势对于实际实时检测应用尤为重要。

然而，由于视觉基础模型与资源受限检测器之间在架构和学习目标上存在巨大差异，实现稳定且与任务对齐的语义迁移具有挑战性。为解决这一问题，我们首先引入了深度语义注入器模块，该模块能够将视觉基础模型的高层表征整合到检测器的深层网络中。为确保稳定高效的优化，我们进一步设计了梯度引导自适应调制策略，该策略基于梯度范数比动态调整语义注入的强度，从而协调语义迁移与检测目标的学习过程。

大量实验表明，所提出的框架在不增加推理或部署开销的情况下，相比先进的基于DETR的检测器实现了持续且显著的性能提升，凸显了其有效性。总而言之，我们的主要贡献如下：

- 我们提出了一种成本效益高且高度自适应的蒸馏框架，该框架利用视觉基础模型不断演进的能力，轻松增强实时检测器，为将基础级语义迁移至轻量级架构提供了可扩展的路径。
- 我们提出了深度语义注入器（DSI）和梯度引导自适应调制（GAM），它们能够在架构和学习目标显著不同的视觉基础模型（VFM）与检测器之间实现稳定且任务对齐的语义迁移。
- 我们建立了一个新的模型系列RT-DETRv4-S/M/L/X，在COCO数据集上以273/169/124/78 FPS的速度实现了49.7/53.5/55.4/57.0 AP的得分，为COCO数据集设立了新的SOTA。

2. 相关工作

2.1. 实时目标检测

实时目标检测的发展长期以来一直由YOLO（You Only Look Once）系列[30]推动，该系列通过高效统一的检测流程普及了单阶段检测范式。过去几年间，该系列经历了快速迭代，在骨干网络设计、标签分配和优化策略等方面持续改进[2, 9, 10, 18, 28, 29, 34, 35]。最新版本进一步拓展了设计空间：YOLOv10[33]摒弃了YOLO系列长期依赖的非极大值抑制，YOLO11[11]优化了架构层次与颈部连接，YOLOv12[32]引入注意力机制以增强上下文推理能力，YOLOv13[17]则探索超图表示来捕获高阶特征依赖。这些进展推动了卷积与混合架构在性能与效率边界上的突破，逐步缩小了实时检测器与高精度检测器之间的差距。

与此同时，另一条研究路线围绕DEtection TRansformer（DETR）[3]展开，它将目标检测重新定义为集合预测问题，并消除了锚点设计和非极大值抑制等手工设计组件。这种基于Transformer的范式催生了众多变体，包括Deformable DETR [39]、Conditional DETR [24]和ID AB-DETR [22]，这些方法专注于提升收敛速度与定位精度。后续研究如DN-DETR [19]、DINO [37]和Group-DETR [6]则引入了去噪目标和分组监督机制，进一步增强了训练稳定性和表征质量。

在此基础上，RT-DETR [38] 构建了首个实时端到端Transformer检测器，其性能与同期YOLO模型持平，并在某些情况下实现了超越。后续研究持续提升了其训练效率和表征学习能力，且未增加推理开销。例如，RT-DETRv2 [23] 和 RT-DETRv3 [36] 通过辅助监督增强梯度流，D-FINE [26] 采用自蒸馏技术优化语义表征，而DEIM [15] 则引入密集匹配以实现更精确的特征对齐。这些进展共同揭示了一个明显趋势：当架构效率趋于饱和时，训练监督与语义表征成为推动性能提升的主要杠杆。本研究基于这一洞见，通过深度语义迁移强化核心表征，在不增加部署或推理成本的前提下实现了更高的精度。

2.2. 视觉基础模型

视觉基础模型（VFM）已成为从大规模图像语料库中以最少或无需监督的方式学习通用视觉表示的主导范式。




图2. RT-DETRv4概览。我们利用视觉基础模型（VFM）提取高质量的语义表示，这些表示通过深度语义注入器（DSI）中的特征投影器与AIFI模块的最深层特征图（ F_5 ）对齐。为确保更快且更稳定的收敛，梯度引导自适应调制（GAM）在训练过程中动态调整DSI损失。所提出的框架仅在实时检测器的训练阶段（由虚线箭头和蓝色块突出显示）运行，并在推理和部署期间保持原始架构不变，在提升精度的同时不引入额外开销。

人类监督。早期的进展源于自监督和弱监督学习方法，这些方法使模型能够从未标记或松散标记的数据中捕获高级语义。代表性方法包括对比学习框架，如SimCLR [7]和MoCo [12]，它们通过增强同一图像的不同视图之间的一致性，同时与其他图像形成对比，来学习判别性特征。CLIP [27]进一步将这一思想扩展到大规模的图像-文本对比训练中，对齐视觉和语言嵌入，并在多样化的任务中展现出强大的零样本迁移能力。

受自然语言处理中掩码语言建模的启发，掩码图像建模方法被引入以重建被遮蔽的图像区域，从而学习上下文感知和整体性表征。其中值得注意的方法包括MAE [13]和BEiT [1]。在这些进展的基础上，DINO系列方法[4, 25, 31]融合了对比学习、基于重建的目标以及自蒸馏目标，以产生高度语义化且可迁移的特征。特别是DINOv3 [31]证明了大规模自监督学习的可扩展性和有效性，无需人工标注即可获得丰富且鲁棒的表征。

3. 方法

3.1. 概述

在这项工作中，我们专注于将我们的框架应用于基于DETR的实时目标检测器，*i.e.*，即RT-DETR模型[38]。我们方法的整体框架如图2所示，其中所提出的模块以蓝色高亮显示。

预备知识。我们的模型基于RT-DETR架构，特别是其高效的混合编码器，如整体框架所示。编码器处理从CNN骨干网络提取的多尺度特征图（ S_3 、 S_4 、 S_5 ）。它包含两个主要组成部分：

- 基于注意力的尺度内特征交互（AIFI）：为保持计算效率，自注意力机制仅应用于最高层级的特征图 $S_5 \in \mathbb{R}^{H/32 \times W/32 \times C_5}$ 。AIFI能够捕获全局上下文和长程依赖关系，生成一个增强的表示，记为 F_5 。
- 基于CNN的跨尺度特征融合（CCFF）：语义增强的 F_5 进一步与低层特征图 S_3 和 S_4 融合，将高层语义传播至浅层特征，最终生成解码器所需的多尺度输出 P_3, P_4, P_5 。

动机。混合编码器的设计使得特征图 F_5 的质量尤为关键。作为唯一经过自注意力机制处理的特征， F_5 是整个模型获取高层次、全局语义信息的主要来源。其质量直接影响后续CCFF模块中的跨尺度融合、初始查询选择，并最终决定解码器的性能。这种依赖性导致了我們所谓的 F_5 *Semantic Bottle-neck* 问题。然而，生成 F_5 的AIFI模块仅通过间接监督进行训练，因为最终检测损失的梯度需经过解码器和CCFF模块反向传播才能到达 F_5 。这种间接监督可能不足以充分优化 F_5 。

为了解决这一问题，我们提出了深度语义注入器（DSI），这是一个轻量级的仅训练模块，旨在




图3. 不同深度语义注入器 (DSI) 策略示意图。(a) 多尺度骨干特征直接对齐 (S_3, S_4, S_5)。 (b) 骨干特征与AIFI输出特征的混合对齐 (F_5)。 (c) 我们提出的方法: 仅针对具有最高层级语义的AIFI输出特征进行定向对齐 (F_5)。该设计允许梯度反向传播, 从而同时增强AIFI模块与骨干网络。

explicitly aligns the deep feature F_5 with semantically rich representations from a vision foundation model. This targeted supervision enhances the semantic expressiveness of F_5 and allows its gradient to flow back through AIFI and the backbone, improving both modules synergistically.

在融入DSI后, 总训练目标被定义为:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{det}} + \lambda \mathcal{L}_{\text{DSI}}, \quad (1)$$

其中 $\mathcal{L}_{\text{det}}$ 表示标准检测损失 (如分类和边界框回归), $\mathcal{L}_{\text{DSI}}$ 代表提出的语义对齐损失。然而, 由于视觉基础模型与资源受限检测器之间巨大的架构和学习目标差异, 实现稳定且任务对齐的语义传递具有挑战性。 λ 的选择不当可能导致早期阶段语义监督不足, 或在后期阶段过度主导检测目标, 最终阻碍收敛并降低性能。为适应训练过程中不断变化的优化动态, 我们提出梯度自适应调制机制, 该机制基于梯度统计动态调整 λ , 确保检测目标与语义监督之间的平衡优化。

3.2. 深度语义注入器

为了解决 F_5 *Semantic Bottleneck*, 我们引入了深度语义注入器 (DSI), 这是一个仅用于训练的模块, 旨在为特征图 F_5 提供显式且强大的监督。DSI的目标是通过将 F_5 与来自高性能语义教师 (表示为 $\mathcal{T}$) 的表征对齐, 来丰富 F_5 的语义质量。给定输入图像, $\mathcal{T}$ 会生成高质量的特征表示 $F_{\mathcal{T}} \in \mathbb{R}^{H' \times W' \times C_{\mathcal{T}}}$ 。

特征投影器。为了将检测器的特征图 $F_5 \in \mathbb{R}^{H_5 \times W_5 \times C_5}$ 与教师的表征 $F_{\mathcal{T}}$ 对齐,

空间分辨率和通道维度上的差异必须得到调和。教师模型 (通常为ViT [8]) 输出一系列图像块标记 $T_p \in \mathbb{R}^{N_p \times C_{\mathcal{T}}}$ 。为实现空间对比, T_p 被重塑为二维网格表示 $F_{\mathcal{T}}^{\text{sp}} \in \mathbb{R}^{H_{\mathcal{T}} \times W_{\mathcal{T}} \times C_{\mathcal{T}}}$, 其中 $N_p = H_{\mathcal{T}} \times W_{\mathcal{T}}$ 。

接着, 我们引入了一个轻量级特征投影器 $\mathcal{P}$ 来实现双重对齐。首先, $F_{\mathcal{T}}^{\text{sp}}$ 通过插值调整以匹配 F_5 的空间分辨率。同时, $\mathcal{P}$ 调整 F_5 的通道维度, 使其与教师的语义空间对齐。完整的投影过程总结如下:

$$F_{\mathcal{T}}^{\text{sp}} = \text{Reshape}(T_p), \quad F_{\mathcal{T}}^{\text{sp}} \in \mathbb{R}^{H_{\mathcal{T}} \times W_{\mathcal{T}} \times C_{\mathcal{T}}}, \quad (2)$$

$$F'_{\mathcal{T}} = \text{Interpolate}(F_{\mathcal{T}}^{\text{sp}}), \quad F'_{\mathcal{T}} \in \mathbb{R}^{H_5 \times W_5 \times C_{\mathcal{T}}}, \quad (3)$$

$$F'_5 = \mathcal{P}(F_5), \quad F'_5 \in \mathbb{R}^{H_5 \times W_5 \times C_{\mathcal{T}}} \quad (4)$$

语义注入。如图3所示, 我们设计了三种逐步增强的语义注入配置。在配置 (a) 和 (b) 中, DSI模块通过特征投影器在不同层级深度执行特征对齐, 将来自冻结VFM的语义知识注入检测器的特征层次结构。在配置 (c) 中, 考虑到AIFI模块在混合编码器中的关键作用, 对齐操作在其输出 F_5 上进行, 该输出包含最丰富的语义信息。在保持梯度连接的情况下, DSI损失得以反向传播, 从而更新轻量级骨干网络。因此, 前向传播利用增强后的 F_5 来指导CCFF模块中的跨尺度融合, 而反向路径则强制语义一致性并增强骨干网络的表征能力。这种双向监督实现了检测器语义增强的统一。

对齐损失。为了鼓励检测器捕捉教师表示的丰富语义, 我们采用了一种

余弦相似度损失。我们最大化检测器投影特征 F'_5 与教师模型投影特征 F'_7 之间的逐块余弦相似度，其公式化为最小化所有空间位置 (i, j) 上的负余弦相似度平均值：

$$\mathcal{L}_{DSI}(F'_5, F'_7) = -\frac{1}{H_5 W_5} \sum_{i,j} \frac{F'_5(i, j) \cdot F'_7(i, j)}{\|F'_5(i, j)\| \|F'_7(i, j)\|}. \quad (5)$$

3.3. 梯度引导的自适应调制

为确保稳定且自适应的语义监督，我们提出了一种动态梯度引导自适应调制（GAM）机制，该机制根据AIFI模块的*gradient norm ratio*而非原始损失大小来调节其相对贡献。这种基于梯度的调节能够自适应地将AIFI的有效贡献维持在期望范围内，从而实现模型组件间的均衡优化。

具体来说，对于每个训练周期 e 内的训练步骤 t ，我们计算每个主要组件（包括骨干网络、AIFI、CCFF和解码器）的梯度 L_1 范数：

$$\mathcal{C} = \{\text{Backbone, AIFI, CCFF, Decoder}\}, \quad (6)$$

$$G_t^{(C)} = \|\nabla_{\theta_C} \mathcal{L}_{total}\|_1. \quad (7)$$

总梯度幅值由下式给出：

$$G_t^{(total)} = \sum_C G_t^{(C)}, \quad (8)$$

而AIFI在步骤 t 处的相对梯度贡献定义为：

$$r_t = \frac{G_t^{(\text{AIFI})}}{G_t^{(total)}}. \quad (9)$$

随后，我们在第 e 个周期内对所有训练步骤的梯度比进行平均，得到：

$$\bar{r}_e = \frac{1}{T_e} \sum_{t=1}^{T_e} r_t, \quad (10)$$

其中 T_e 表示在时期 e 中的步数。

两个超参数控制调制过程：

- 目标比率（ ρ ）：AIFI的理想平均梯度比率，代表其对优化的理想相对贡献。
- 公差区间（ δ ）：一个定义目标比例周围可接受偏差范围 $[\rho - \delta, \rho + \delta]$ 的裕度。

在每个epoch结束时，GAM会检查 $\bar{r}_e$ 是否处于目标区间内。如果 $\bar{r}_e \in [\rho - \delta, \rho + \delta]$ ，则 $\mathcal{L}_{DSI}$ 的权重 λ_e 保持不变。否则，将调整 λ_e ，使得下一个epoch的AIFI梯度比被导向目标区间。

further boundary 目标范围而非其中点的梯度，因为只有部分AIFI的梯度来源于 $\mathcal{L}_{DSI}$ ，基于边界的调整在平衡点附近能带来更稳定的收敛。

$$\lambda_{e+1} = \begin{cases} \lambda_e \cdot \frac{\rho - \delta}{\bar{r}_e}, & \text{if } \bar{r}_e > \rho + \delta, \\ \lambda_e \cdot \frac{\rho + \delta}{\bar{r}_e}, & \text{if } \bar{r}_e < \rho - \delta, \\ \lambda_e, & \text{otherwise.} \end{cases} \quad (11)$$

此更新规则驱动AIFI的有效梯度贡献在期望的操作范围内收敛，同时防止振荡。超参数 ρ 和 δ 为训练动态提供了显式控制： ρ 定义了期望的监督强度，而 δ 则调节响应性与稳定性之间的权衡。较小的 δ 能实现更快的适应但可能带来不稳定风险，而较大的 δ 则会产生更平稳但更慢的收敛。在实践中，GAM能提供稳定的收敛，并在无需额外调优开销的情况下持续提升语义对齐效果。

4. 实验

4.1. 设置

数据集与评估指标。所有实验均在COCO 2017 [20]数据集上进行，使用train2017划分进行训练，val2017划分进行评估。我们报告标准的COCO评估指标，包括AP（在0.50至0.95范围内以0.05为步长均匀采样的IoU阈值上的平均值）、AP₅₀、AP₇₅，以及不同尺度下的AP：AP_S、AP_M、AP_L。

实现细节。我们的实验基于RT-DETR架构[38]，并融合了RT-DETRv2[23]、D-FINE[26]和DEIM[15]的架构与训练优化。为公平比较，核心超参数与对应基线保持一致。DSI采用预训练且冻结的DINOv3-ViT-B模型作为语义教师。所有评估均使用COCO AP指标，推理延迟（毫秒级）在单张NVIDIA T4 GPU上基于TensorRT FP16精度测得。

4.2. 与SOTA的对比

我们将提出的RT-DETRv4与近期先进的实时检测器进行比较，包括最新的YOLO系列（YOLOv10 [33]、YOLOv11 [11]、YOLOv12 [32]和YOLOv13 [17]）以及基于DETR的检测器（RT-DETR [38]、RT-DETRv2 [23]、RT-DETRv3 [36]、D-FINE [26]、DEIM [15]和DEIMv2 [14]）。结果如图1所示，详细统计数据见表1。实验表明，RT-DETRv4在所有模型规模下均能持续取得最佳性能。

表1. 在COCO [20] val2017数据集上与其他实时目标检测器的对比。结果来源于官方出版物。未明确报告但通过公开权重经标准评估得出的数值以*标记。R18、R34、R50和R101分别指代ResNet-18、ResNet-34、ResNet-50和ResNet-101。

Model	#Epochs	#Params.	GFLOPs	Latency (ms)	AP ^{val}	AP ^{val} ₅₀	AP ^{val} ₇₅	AP ^{val} _S	AP ^{val} _M	AP ^{val} _L
YOLOv10-S [33]	500	7	22	2.52	46.3	63.0	50.4	26.8	51.0	63.8
YOLO11-S [11]	500	9	22	2.60	47.0	63.4*	50.5*	-	-	-
YOLOv12-S [32]	600	9	21	2.78	48.0	65.0	51.8	29.8	<u>53.2</u>	65.6
YOLOv13-S [17]	600	9	21	2.98	48.0	65.2	52.0	-	-	-
RT-DETR-R18 [38]	120	20	60	4.61	46.5	63.8	50.4	28.4	49.8	63.0
RT-DETRv2-S [23]	120	20	60	4.61	48.1	65.1	52.1*	30.2*	51.2*	64.2*
RT-DETRv3-R18 [36]	120	20	60	4.61	48.1	65.6	52.0*	30.2*	51.5*	63.9*
D-FINE-S [26]	120	10	25	3.66	48.5	65.6	52.6	29.1	52.2	65.4
DEIM-S [15]	120	10	25	3.66	<u>49.0</u>	<u>65.9</u>	<u>53.1</u>	30.4	52.6	65.7
RT-DETRv4-S (ours)	120	10	25	3.66	49.7	66.8	54.1	<u>30.2</u>	53.6	66.9
YOLOv10-M [33]	500	15	59	4.74	51.1	68.1	55.8	33.8	56.5	67.0
YOLO11-M [11]	500	20	68	4.85	51.5	68.1*	55.8*	-	-	-
YOLOv12-M [32]	600	20	68	4.96	52.5	69.6	57.1	35.7	58.2	68.8
RT-DETR-R34 [38]	120	31	92	6.91	48.9	66.8	52.9	30.6	52.4	66.3
RT-DETRv2-M [23]	120	31	92	6.91	49.9	67.5	54.1*	32.0*	53.2*	66.5*
RT-DETRv3-R34 [36]	120	31	92	6.91	49.9	67.7	53.9*	31.7*	54.0*	66.2*
D-FINE-M [26]	120	19	57	5.91	52.3	69.8	56.4	33.2	56.5	<u>70.2</u>
DEIM-M [15]	90	19	57	5.91	<u>52.7</u>	<u>70.0</u>	<u>57.3</u>	<u>35.3</u>	56.7	69.5
RT-DETRv4-M (ours)	90	19	57	5.91	53.5	71.1	58.1	34.9	<u>57.7</u>	72.1
YOLOv10-L [33]	500	24	120	7.38	53.2	70.1	58.1	35.8	58.5	69.4
YOLO11-L [11]	500	25	87	6.33	53.4	69.7*	58.3*	-	-	-
YOLOv12-L [32]	600	27	89	6.85	53.7	70.7	58.5	<u>36.9</u>	59.5	69.9
YOLOv13-L [17]	600	88	28	8.63	53.4	70.9	58.1	-	-	-
RT-DETR-R50 [38]	72	42	136	9.29	53.1	71.3	57.7	34.8	58.0	70.0
RT-DETRv2-L [23]	72	42	136	9.29	53.4	71.6	57.4*	36.1*	57.9*	70.8*
RT-DETRv3-R50 [36]	120	42	136	9.29	53.4	71.7	57.3*	35.4*	57.4*	69.8*
D-FINE-L [26]	72	31	91	8.07	54.0	71.6	58.4	36.5	58.0	71.9
DEIM-L [15]	50	31	91	8.07	<u>54.7</u>	<u>72.4</u>	<u>59.4</u>	<u>36.9</u>	<u>59.6</u>	71.8
RT-DETRv4-L (ours)	50	31	91	8.07	55.4	73.0	60.3	37.1	60.1	72.9
YOLOv10-X [33]	500	30	160	10.45	54.4	71.3	59.3	37.0	59.8	70.9
YOLO11-X [11]	500	57	195	11.50	54.7	71.3*	59.7*	-	-	-
YOLOv12-X [32]	600	59	199	11.80	55.2	72.0	60.2	39.6	60.7	70.9
YOLOv13-X [17]	600	64	199	14.67	54.8	72.0	59.8	-	-	-
RT-DETR-R101 [38]	72	76	259	13.88	54.3	72.7	58.6	36.0	58.8	72.1
RT-DETRv2-X [23]	72	76	259	13.88	54.3	72.8	58.8*	35.8*	58.8*	72.1*
RT-DETRv3-R101 [36]	120	76	259	13.88	54.6	73.1	-	-	-	-
D-FINE-X [26]	72	62	202	12.90	55.8	73.7	60.2	37.3	60.5	73.4
DEIM-X [15]	50	62	202	12.90	<u>56.5</u>	<u>74.0</u>	<u>61.5</u>	38.8	<u>61.4</u>	<u>74.2</u>
RT-DETRv4-X (ours)	50	62	202	12.90	57.0	74.6	62.1	<u>39.5</u>	61.9	74.8

(S、M、L 和 X)，无需引入任何额外的推理和部署开销。

具体而言，我们的RT-DETRv4-L在COCO数据集上以124 FPS的速度实现了55.4 AP，在计算量相当甚至更低的条件下，超越了YOLOv13-L (53.4 AP) 和DEIM-L (54.7 AP)。最大规模的变体RT-DETRv4-X达到了57.0 AP，在未引入任何推理开销的情况下超越了DEIM-X (56.5 AP)。在较小规模上，RT-DETRv4-S和RT-DETRv4-M分别取得了49.7和53.5 AP，均明显优于同规模的DEIM对应模型。

部分 (49.0 和 52.7 AP)。

为确保在相似的延迟范围内进行公平比较，我们仅在图表1中报告DEIMv2 [14]的结果，并将其排除在表格1之外，因为它们的模型通常表现出更高的推理延迟。在可比较的推理速度下，我们的RT-DETRv4-M大幅超越DEIMv2-S (169 FPS对比173 FPS时，AP值为53.5对比50.9)，而RT-DETRv4-L进一步优于DEIMv2-M (124 FPS对比113 FPS时，AP值为55.4对比53.0)。这些结果充分证明了其有效性和巨大潜力。

表2. 在多种检测器上对DSI和GAM的消融实验结果。我们的方法以零额外推理成本带来了持续且显著的性能提升。

Method	AP	AP ₅₀	AP ₇₅
RT-DETRv2-L	52.1	70.2	56.7
w/ DSI	52.3 (+0.2)	70.4 (+0.2)	56.4 (-0.3)
w/ DSI+GAM	52.6 (+0.5)	70.7 (+0.5)	56.8 (+0.1)
D-FINE-L	53.1	70.8	57.4
w/ DSI	53.2 (+0.1)	70.8 (+0)	57.7 (+0.3)
w/ DSI+GAM	53.4 (+0.3)	71.1 (+0.3)	58.0 (+0.6)
DEIM-L	53.8	71.4	58.5
w/ DSI	53.9 (+0.1)	71.3 (-0.1)	58.8 (+0.3)
w/ DSI+GAM	54.3 (+0.5)	71.8 (+0.4)	59.0 (+0.5)

所提方法的潜力。尽管DEIMv2-X实现了更强的性能，但其延迟也高于RT-DETRv4-X。此外，直接采用DINO v3作为骨干网络以获取语义丰富性，从根本上受到模型规模和部署成本的限制，只能局限于DINOv3的Tiny或Small变体，难以扩展到更强大的大规模模型。相比之下，我们的框架对视觉基础模型（VFM）的类型和规模均保持不可知性，不引入任何推理或部署开销，提供了一个更灵活且更利于部署的解决方案。

4.3. 消融研究

我们进行了一系列消融实验以验证所提出模块的有效性。除非另有说明，所有消融实验均训练36个周期。未明确指定的超参数或配置遵循相应实验设置中的最佳设定。

关于DSI和GAM的消融实验。我们首先评估了DSI和GAM的有效性。如表2所示，应用DSI能带来轻微的性能提升，而进一步应用GAM则能显著提高性能增益（0.5 AP），这充分证明了两者的有效性。为验证我们方法的普适性，我们还在RT-DETRv2和D-FINE上进行了实验，结果表明我们的方法能为不同检测器带来持续的性能提升。

语义注入位置的消融实验。为了验证注入位置的选择，我们比较了图3所示的策略。表3的结果表明，直接将语义监督应用于骨干特征（ S_3 、 S_4 或 S_5 ）单独或联合使用均未带来改进。同样，对齐骨干特征与 F_5 特征的混合方法（策略(b)）也未带来增益（53.8 AP）。

相比之下，我们的设计（策略(c)）仅对齐AIFI输出 F_5 ，实现了明显的0.5 AP提升（54.3 AP）。这表明在 F_5 中保持更丰富的语义对于提升检测性能至关重要，因为它在传播高层语义信息中起着关键作用。

表3. 语义注入位置消融实验结果。我们比较了在不同位置应用DSI的效果，对应图3中的策略。仅对齐AIFI输出($\{v^*\}$)可获得最佳性能。

Position	S_3	S_4	S_5	F_5	AP	AP ₅₀	AP ₇₅
Baseline	-	-	-	-	53.8	71.4	58.5
Backbone	✓	-	-	-	53.7	71.2	58.4
	-	✓	-	-	53.7	71.3	58.4
	-	-	✓	-	53.8	71.3	58.5
	✓	✓	✓	-	53.7	71.3	58.5
Hybrid	✓	✓	✓	✓	53.8	71.4	58.4
AIFI	-	-	-	✓	54.3	71.8	59.0

表4. 特征投影器消融实验结果。

Projector Arch.	AP	AP ₅₀	AP ₇₅
Baseline	53.8	71.4	58.5
w/ 1x1 Conv	53.8	71.5	58.5
w/ MLP	54.2	71.7	59.0
w/ Linear	54.3 (+0.5)	71.8 (+0.4)	59.0 (+0.5)

表5. 对齐损失消融实验结果。余弦相似度损失展现出更优性能。实验以DEIM-M作为基线模型，所有报告结果均遵循DEIM训练协议，采用90轮训练周期及12轮指数移动平均策略获得。

Loss Function	AP	AP ₅₀	AP ₇₅
Baseline	52.5	69.9	57.2
w/ MSE Loss	52.7	70.0	57.4
w/ Cosine Similarity	53.5 (+1.0)	71.1 (+1.2)	58.1 (+0.9)

信息传递至后续的特征层次。此外，混合方法的有效性表明，同时对齐基于CNN的主干网络和基于Transformer的AIFI的特征可能会引入优化冲突或语义不对齐。我们选择的策略不仅更有效，而且更高效。它避免了多个中间投影和插值的复杂性，并且来自单一 $\{v^*\}$ 对齐损失的梯度自然回流，协同更新AIFI和主干网络，通过单一、有针对性的目标实现一致的增强。

特征投影器的设计。特征投影器是连接学生和教师特征空间的关键组件。我们探索了多种架构选择，详见表4。基于线性的投影器取得了最佳效果，在表达能力和参数效率之间实现了最优平衡。

损失函数的选择。我们进一步研究了DSI的对齐损失。我们在表5中比较了均方误差（MSE）损失和余弦相似度损失，后者




图4. 密集特征对比。我们通过PCA将密集输出投影至RGB空间，对比了DEIM-L（上）与RT-DETRv4-L（下）的特征图质量。可视化结果表明，我们的DSI模块显著增强了AIFI特征的语义表示，进而提升了后续CCFF特征的性能。从左至右分别为：输入图像、AIFI特征图 F_5 以及多尺度CCFF特征 P_3 、 P_4 、 P_5 。

表6. 损失加权策略的消融研究。GAM持续超越最佳调优的静态权重。采用DEIM-L作为基线。所有报告结果均来自按照[15]方法训练50个周期并采用8周期指数移动平均的模型。

λ	0.1	0.2	0.4	1	2	4
AP^{val}	54.7	54.7	54.8	54.9	<u>55.0</u>	<u>55.0</u>
λ	10	20	30	50	100	GAM
AP^{val}	<u>55.0</u>	55.1	<u>55.0</u>	54.9	54.6	55.4




图5. 训练期间COCO数据集上的验证AP变化。我们将动态GAM与基线模型及DSI损失的多个静态 λ 值进行比较。GAM策略始终优于所有静态配置，展现了其在训练全程提供稳定有效监督的能力。

优于前者，验证了我们的假设，即对齐特征方向更为关键。

GAM与静态权重的比较。最后，我们通过静态权重验证所提出的GAM。该

GAM在引导训练动态方面的优越性在图5中得到了进一步说明，该图绘制了验证AP随训练轮次的变化曲线。如图所示，GAM的曲线始终保持在基线及所有静态权重配置之上，在整个训练过程中展现出清晰而稳定的性能优势。

表6详细列出了静态权重和GAM的结果。对于静态加权，性能在 $\lambda = 20$ 时达到峰值，获得55.1 AP，但数值过小或过大时性能均会下降。然而通过观察图5中的训练曲线，我们发现即使这种最优静态权重（ $\lambda = 20$ ）也会导致训练中前期收敛速度较慢，这凸显了固定超参数的内在局限性。我们的实验表明，GAM实现了最佳性能（55.4 AP）。

特征可视化。图4直观比较了DEIM-L与我们的RT-DETRv4-L的特征图。值得注意的是，我们的模型丰富了AIFI特征 F_5 的语义内容，使得后续多尺度特征 P_3 、 P_4 和 P_5 中的物体轮廓与背景更为精确且可区分。特别是 P_5 对物体区域表现出显著更强且更集中的响应。

5. 讨论

为了进一步凸显我们的框架相较于现有方法[14, 26]的优势，我们从三个角度进行讨论：部署效率、可扩展性和训练效率。

部署效率。我们的方法对检测器架构进行了零修改，且不改变推理流程，确保不会产生额外的计算成本或延迟。这一部署友好的特性对于工业应用至关重要，因为实时检测器通常紧密集成于现有系统及硬件受限的环境中。

可扩展性。该框架具有高度通用性，可无缝应用于多种架构的检测器，包括基于CNN和基于Transformer的检测器。它使各类实时检测器都能快速受益于视觉基础模型（VFM）的快速发展。此外，该框架不受限于任何特定类型或规模的VFM，能够灵活整合不同的基础模型，例如DINOv3 [31]、MAE [13]或CLIP [27]，甚至可利用任意大规模模型将语义知识蒸馏到实时检测器中。这种灵活性也为多VFM语义融合开辟了前景广阔的研究方向，进一步体现了该框架的通用性与可扩展性。

训练效率。我们的方法轻量且易于实现。由于检测器结构或优化流程均未因融入VFMs而改变，因此额外的训练成本保持在最低水平。这种高效性凸显了我们方法在大规模应用和实时工业部署中的实用性。

6. 结论

在本工作中，我们提出了一种成本效益高且适应性强的语义蒸馏框架，该框架在不增加推理或部署开销的情况下，增强了基于实时DETR的目标检测器。通过提出的深度语义注入器（DSI）和梯度引导自适应调制（GAM），我们的方法以稳定且任务对齐的方式，有效地将视觉基础模型中的高级语义迁移到轻量级检测器中。在COCO数据集上的大量实验表明，该方法在多个模型尺度上均实现了持续且显著的性能提升，最终形成了最先进的RT-DETRv4系列。这些结果突显了显式语义监督在弥合大规模基础模型与资源高效检测架构之间差距方面的有效性。总体而言，我们的工作为释放基础模型在高效视觉感知方面的潜力提供了一条实用途径。

参考文献

- [1] Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. BEiT: 基于图像Transformer的BERT预训练。发表于 *International Conference on Learning Representations*. 3[2] Alexey Bochkovskiy, Chien-Yao Wang, and Hong-Yuan Mark Liao. YOLOv4: 目标检测的最佳速度与精度。 *arXiv preprint arXiv:2004.10934*, 2020. 2[3] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. 基于Transformer的端到端目标检测。发表于 *ECCV*, 2020. 1, 2[4] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. 自监督视觉Transformer的新兴特性。发表于 *Proceedings of the IEEE/CVF international conference on computer vision*, 页码 9650–9660, 2021. 3
- [5] 李晨、彭浩、Kashyap Chitta, Bernhard Jaeger, Andreas Geiger、李洪阳。端到端自动驾驶：挑战与前沿。 *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024年。1[6] 陈强、陈晓康、王健、张山、姚坤、冯浩成、韩俊宇、丁二锐、曾刚、王京东。Group DETR: 通过分组一对多分配实现快速DETR训练。于 *ICCV*, 2023年。2[7] 陈霆、Simon Kornblith, Mohammad Norouzi, Geoffrey Hinton. 视觉表示对比学习的简单框架。于 *International conference on machine learning*, 第1597–1607页。PmLr, 2020年。3[8] Alexey Dosovitskiy. 一幅图像值16x16个词：用于大规模图像识别的Transformer。 *arXiv preprint arXiv:2010.11929*, 2020年。4[9] Jocher Glenn. YOLOv5 发布 v7.0。 <https://github.com/ultralytics/yolov5/tree/v7.0>, 2022年。2[10] Jocher Glenn. YOLOv8。 <https://docs.ultralytics.com/models/yolov8/>, 2023年。2[11] Jocher Glenn. YOLO11。 <https://docs.ultralytics.com/models/yolo11/>, 2024年。2, 5, 6[12] 何恺明、范浩祺、吴育昕、谢赛宁、Ross Girshick. 用于无监督视觉表示学习的动量对比。于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 第9729–9738页, 2020年。3[13] 何恺明、陈新雷、谢赛宁、李阳浩、Piotr Dollár、Ross Girshick. 掩码自编码器是可扩展的视觉学习器。于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 第16000–16009页, 2022年。2, 3, 9[14] 黄世华、侯永杰、刘龙飞、余轩龙、沈曦。实时目标检测遇见DINOv3。 *arXiv preprint arXiv:2509.20787*, 2025年。5, 6, 8[15] 黄世华、卢志超、孙晓东、余永俊、周晓、沈曦。DEIM: 具有改进匹配策略以实现快速收敛的DETR。于 *CVPR*, 2025年。2, 5, 6, 8[16] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead、Alexander C Berg、Wan-Yen Lo等。分割一切。于 *Proceedings of the IEEE/CVF international conference on computer vision*, 第4015–4026页, 2023年。1[17] 雷梦琪、李思琪、吴一弘、胡涵、周游、郑新虎、丁贵广、杜少毅、吴宗泽、高跃。YOLOv13: 具有超图增强自适应视觉感知的实时目标检测。 *arXiv preprint arXiv:2506.17733*, 2025年。2, 5, 6[18] 李楚怡、李露露、蒋洪亮、翁凯恒、耿逸飞、李亮、柯再丹、李青原、程梦、聂伟强等。YOLOv6: 面向工业应用的单阶段目标检测框架。 *arXiv*, 2022年。2[19] 李峰、张浩、刘世龙、郭健、倪凌峰、张磊。DN-DETR: 通过引入查询去噪加速DETR训练。于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第13619–13627页, 2022年。2

- [20] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft COCO: 上下文中的常见物体。收录于 *European Conference on Computer Vision*, 第740–755页。Springer, 2014年。1, 2, 5, 6[21] 刘华平, 刘新竹, 黄康尧, 郭迪。具身智能。收录于 *Embodied Multi-Agent Systems: Perception, Action, and Learning*, 第3–48页。Springer, 2025年。1[22] 刘世龙, 李峰, 张浩, 杨晓, 齐先彪, 苏航, 朱军, 张磊。DAB-DETR: 动态锚框是DETR更好的查询。收录于 *ICLR*, 2022年。2[23] 吕文宇, 赵一安, 常钦尧, 黄奎, 王冠中, 刘毅。RT-DETRv2: 为实时检测Transformer改进的基线及免费技巧包。arXiv, 2024年。2, 5, 6[24] 孟德普, 陈晓康, 范泽佳, 曾钢, 李厚强, 袁钰辉, 孙磊, 王井东。Conditional DETR: 用于快速训练收敛。收录于 *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 第3651–3660页, 2021年。2[25] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, 等。Dinov2: 无需监督学习鲁棒的视觉特征。arXiv preprint arXiv:2304.07193, 2023年。3[26] 彭岩松, 李贺北, 吴培玺, 张悦怡, 孙晓艳, 吴枫。D-Fine: 将DETR中的回归任务重新定义为细粒度分布优化。收录于 *ICLR*, 2024年。2, 5, 6, 8[27] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, 等。从自然语言监督中学习可迁移的视觉模型。收录于 *International conference on machine learning*, 第8748–8763页。PmLr, 2021年。3, 9[28] Joseph Redmon, Ali Farhadi。YOLOv3: 更好、更快、更强。收录于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第7263–7271页, 2017年。2[29] Joseph Redmon, Ali Farhadi。YOLOv3: 一种渐进式改进。arXiv preprint arXiv:1804.02767, 2018年。2[30] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi。你只看一次: 统一的实时物体检测。收录于 *CVPR*, 2016年。1, 2[31] Oriane Siméoni, Huy V Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, 等。Dinov3。arXiv, 2025年。2, 3, 9[32] 田云杰, 叶启祥, David Doermann。YOLOv12: 以注意力为中心的实时物体检测器。收录于 *NeurIPS*, 2025年。2, 5, 6[33] 王傲, 陈辉, 刘立豪, 陈恺, 林子佳, 韩军功, 丁贵广。YOLOv10: 实时端到端物体检测。收录于 *NeurIPS*, 2024年。2, 5, 6[34] Chien-Yao Wang, Alexey Bochkovskiy, Hong-Yuan Mark Liao。YOLOv7: 可训练的免费技巧包为实时物体检测器设定了新的技术水平。收录于 *the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第7464–7475页, 2023年。2 [35] Chien-Yao Wang, I-Hau Yeh, 和 Hong-Yuan Mark Liao。YOLOv9: 使用可编程梯度信息学习你想学习的内容。arXiv, 2024年。2 [36] Shuo Wang, Chunlong Xia, Feng Lv, 和 Yifeng Shi。RT-DETRv3: 具有分层密集正监督的实时端到端目标检测。收录于 *2025 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 第1628–1636页。IEEE, 2025年。2, 5, 6 [37] Hao Zhang, Feng Li, Shilong Liu, Lei Zhang, Hang Su, Jun Zhu, Lionel Ni, 和 Heung-Yeung Shum。DINO: 具有改进去噪锚框的DETR, 用于端到端目标检测。收录于 *International Conference on Learning Representations*, 2022年。2 [38] Yian Zhao, Wenyu Lv, Shangliang Xu, Jinman Wei, Guanzhong Wang, Qingqing Dang, Yi Liu, 和 Jie Chen。在实时目标检测上, DETRs击败了YOLOs。收录于 *CVPR*, 2024年。1, 2, 3, 5, 6 [39] Xizhou Zhu, Weiye Su, Lewei Lu, Bin Li, Xiaogan Wang, 和 Jifeng Dai。可变形DETR: 用于端到端目标检测的可变形Transformer。收录于 *International Conference on Learning Representations*, 2020年。2