

FCOS: 全卷积单阶段目标检测

智天 春华 沈* 陈浩 何童 澳大利亚阿德莱德大学

摘要

We propose a fully convolutional one-stage object detector (FCOS) to solve object detection in a per-pixel prediction fashion, analogue to semantic segmentation. Almost all state-of-the-art object detectors such as RetinaNet, SSD, YOLOv3, and Faster R-CNN rely on pre-defined anchor boxes. In contrast, our proposed detector FCOS is anchor box free, as well as proposal free. By eliminating the pre-defined set of anchor boxes, FCOS completely avoids the complicated computation related to anchor boxes such as calculating overlapping during training. More importantly, we also avoid all hyper-parameters related to anchor boxes, which are often very sensitive to the final detection performance. With the only post-processing non-maximum suppression (NMS), FCOS with ResNeXt-64x4d-101 achieves 44.7% in AP with single-model and single-scale testing, surpassing previous one-stage detectors with the advantage of being much simpler. For the first time, we demonstrate a much simpler and flexible detection framework achieving improved detection accuracy. We hope that the proposed FCOS framework can serve as a simple and strong alternative for many other instance-level tasks. Code is available at:

[tinyurl.com/FCOSv1](https://github.com/whuang0322/FCOS)

1. 引言

目标检测是计算机视觉中一项基础且具有挑战性的任务，它要求算法为图像中每个感兴趣的实例预测一个带有类别标签的边界框。当前所有主流检测器，如Faster R-CNN [24]、SSD [18] 和 YOLOv2、v3 [23]，都依赖于一组预定义的锚框和it has long been believed that the use of anchor boxes is the key to detectors' success。尽管它们取得了巨大成功，但值得注意的是，基于锚框的检测器存在一些缺点：1) 如[15, 24]所示，检测性能对锚框的尺寸、宽高比和数量非常敏感。例如，在RetinaNet [15]中，调整这些超参数会使COCO基准上的AP性能变化高达4%。




图1 – 如左图所示，FCOS的工作原理是在每个前景像素点预测一个4D向量 ($\{v^*\}$)，该向量编码了边界框的位置（训练时通过真实边界框信息进行监督）。右图表明，当某个位置位于多个边界框内时，该位置应回归到哪个边界框可能会产生歧义。

标记[16]。因此，在基于锚点的检测器中，这些超参数需要仔细调整。2) 即使经过精心设计，由于锚框的尺度和长宽比是固定的，检测器在处理形状变化较大的候选物体时仍会遇到困难，特别是对于小物体。预定义的锚框还限制了检测器的泛化能力，因为需要在具有不同物体尺寸或长宽比的新检测任务上重新设计它们。3) 为了实现高召回率，基于锚点的检测器需要在输入图像上密集放置锚框 (e.g., 对于短边为800的图像，特征金字塔网络 (FPN) [14]中超过18万个锚框)。在训练过程中，这些锚框大多被标记为负样本。过多的负样本加剧了训练中正负样本之间的不平衡。4) 锚框还涉及复杂的计算，例如计算与真实边界框的交并比 (IoU) 分数。

最近，全卷积网络 (FCNs) [20]在密集预测任务中取得了巨大成功，例如语义分割[20, 28, 9, 19]、深度估计

*Corresponding author, email: chunhua.shen@adelaide.edu.au

[17, 31]、关键点检测[3]和计数[2]。作为高级视觉任务之一，目标检测可能是唯一偏离了简洁的全卷积逐像素预测框架的任务，这主要归因于锚框的使用。很自然地会提出一个问题：*Can we solve object detection in the neat per-pixel prediction fashion, analogue to FCN for semantic segmentation, for example?* 因此，这些基础的视觉任务可以（几乎）统一在单一的框架中。我们证明答案是肯定的。此外，我们首次证明，基于FCN的更简单的检测器甚至能取得比基于锚框的检测器更好的性能。

在文献中，一些研究尝试利用基于全卷积网络（FCN）的框架进行目标检测，例如DenseBox [12]。具体而言，这些基于FCN的框架直接在特征图某一层级的每个空间位置上预测一个4维向量及一个类别标签。如图1（左）所示，该4维向量描述了边界框四条边相对于该位置的偏移量。这些框架与用于语义分割的FCN相似，区别在于每个位置需要回归一个4维连续向量。然而，为处理不同尺寸的边界框，DenseBox [12]需将训练图像裁剪并缩放到固定尺度。因此DenseBox必须在图像金字塔上进行检测，这违背了FCN一次性计算所有卷积的核心理念。此外更重要的是，这些方法主要应用于特定领域的检测任务，如场景文本检测[33, 10]或人脸检测[32, 12]，因为普遍认为当应用于具有高度重叠边界框的通用目标检测时，这些方法效果不佳。如图1（右）所示，高度重叠的边界框会导致难以处理的歧义：对于重叠区域内的像素，无法明确应针对哪个边界框进行回归。

在后续部分，我们将更深入地探讨这一问题，并证明通过FPN可以很大程度上消除这种模糊性。因此，我们的方法已经能够获得与传统基于锚点的检测器相当的检测精度。此外，我们观察到，在远离目标物体中心的位置，我们的方法可能会产生一些低质量的预测边界框。为了抑制这些低质量的检测结果，我们引入了一个新颖的“中心度”分支（仅包含一层），用于预测像素点与其对应边界框中心的偏差，如公式(3)所定义。该得分随后被用于降低低质量检测边界框的权重，并在非极大值抑制（NMS）中合并检测结果。这个简单而有效的中心度分支使得基于FCN的检测器在完全相同的训练和测试设置下，能够超越基于锚点的检测器。

这一新的检测框架具有以下优势。

- 检测现在与许多其他FCN可解决的任务（如语义分割）统一起来，使得从这些任务中复用想法变得更加容易。
- 检测变得无需提议和锚点，这显著减少了设计参数的数量。设计参数通常需要启发式调整，并且涉及许多技巧才能实现良好性能。因此，我们的新检测框架使检测器（尤其是其训练过程）*considerably*更加简单。
- 通过消除锚框，我们的新检测器完全避免了与锚框相关的复杂计算，例如训练期间锚框与真实框之间的IOU计算和匹配，从而比基于锚框的对应方法训练和测试速度更快，训练内存占用也更少。
- 在不添加任何花哨功能的情况下，我们在单阶段检测器中取得了最先进的结果。我们还表明，所提出的FCOS可以用作两阶段检测器中的区域提议网络（RPNs），并且能够比基于锚点的RPN对应物实现显著更好的性能。考虑到更简单的无锚点检测器 *we encourage the community to rethink the necessity of anchor boxes in object detection*（目前被视为检测领域的*de facto*标准）具有更优越的性能。
- 所提出的检测器可以立即扩展到解决其他视觉任务，只需最小修改，包括实例分割和关键点检测。我们相信这种新方法可以成为许多实例级预测问题的新基准。

2. 相关工作

基于锚点的检测器。基于锚点的检测器继承了传统滑动窗口和基于提议的检测器（如Fast R-CNN [6]）的思想。在这些检测器中，锚框可视为预定义的滑动窗口或提议区域，它们被分类为正样本或负样本，并通过额外的偏移量回归来细化边界框位置的预测。因此，这些检测器中的锚框可视为*training samples*。与Fast R-CNN等早期检测器需为每个滑动窗口/提议重复计算图像特征不同，锚框利用CNN的特征图，避免了重复的特征计算，从而显著加速了检测过程。锚框的设计由Faster R-CNN在其RPN[24]、SSD[18]和YOLOv2[22]中推广，已成为现代检测器的常规方法。

然而，如上所述，锚框会导致超参数过多，而这些参数通常需要




图2 – FCOS的网络架构，其中C3、C4和C5表示骨干网络的特征图，P3至P7是用于最终预测的特征层级。 $H \times W$ 是特征图的高度和宽度。 $\cdot/s$ ($s = 8, 16, \dots, 128$) 是该层级特征图相对于输入图像的下采样比例。举例而言，所有数值均基于 800×1024 的输入计算得出。

需要仔细调整以获得良好的性能。除了上述描述锚框形状的超参数外，基于锚框的检测器还需要其他超参数来将每个锚框标记为正样本、忽略样本或负样本。在以往的研究中，通常利用锚框与真实框的交并比 (IOU) 来确定锚框的标签 (*e.g.*, 若其IOU处于 $[0.5, 1]$ 区间内则为正样本锚框)。这些超参数对最终精度有显著影响，且需要启发式调优。同时，这些超参数专属于检测任务，使得检测任务偏离了其他密集预测任务（如语义分割）所使用的简洁全卷积网络架构。

无锚点检测器。最流行的无锚点检测器可能是YOLOv1 [21]。YOLOv1不使用锚框，而是在物体中心附近的位置预测边界框。仅使用中心附近的点是因为它们被认为能够产生更高质量的检测。然而，由于只有中心附近的点被用于预测边界框，正如YOLOv2 [22]所述，YOLOv1存在召回率低的问题。因此，YOLOv2 [22]也采用了锚框。与YOLOv1相比，FCOS利用真实边界框内的所有点来预测边界框，并通过提出的“中心度”分支抑制低质量检测边界框。因此，如我们的实验所示，FCOS能够提供与基于锚点的检测器相当的召回率。

CornerNet [13] 是近期提出的一种单阶段无锚框

自由检测器，它检测边界框的一对角点并将它们分组以形成最终检测到的边界框。CornerNet需要更复杂的后处理来将属于同一实例的角点对分组。为此目的，学习了一个额外的距离度量。

另一类无锚检测器，如[32]，基于DenseBox[12]。这类检测器曾被认为不适用于通用目标检测，因为难以处理重叠边界框且召回率相对较低。在本研究中，我们证明通过多级FPN预测可以大幅缓解这两个问题。此外，结合我们提出的中心度分支，这种更简单的检测器甚至能比基于锚点的同类方法实现更好的检测性能。

3. 我们的方法

在本节中，我们首先以逐像素预测的方式重新定义目标检测。接着，我们展示了如何利用多层级预测来提高召回率，并解决由重叠边界框引起的歧义问题。最后，我们提出了所设计的“中心度”分支，该分支有助于抑制低质量的检测边界框，并大幅提升整体性能。

3.1. 全卷积单阶段目标检测器

设 $F_i \in \mathbb{R}^{H \times W \times C}$ 为骨干CNN第 i 层的特征图， s 为该层之前的总步长。输入图像的真实边界框为

定义为 $\{B_i\}$, 其中 $B_i = (x_0^{(i)}, y_0^{(i)}, x_1^{(i)}, y_1^{(i)}, c^{(i)}) \in \mathbb{R}^4 \times \{1, 2 \dots C\}$ 。这里 $(x_0^{(i)}, y_0^{(i)})$ 和 $(x_1^{(i)}, y_1^{(i)})$ 表示边界框左上角和右下角的坐标。 $c^{(i)}$ 是边界框内物体所属的类别。 C 是类别数量, 在MS-COCO数据集中为80。

对于特征图 F_i 上的每个位置 (x, y) , 我们可以将其映射回输入图像上的 $(\lfloor \frac{s}{2} \rfloor + xs, \lfloor \frac{s}{2} \rfloor + ys)$, 该点位于该位置 (x, y) 感受野的中心附近。不同于基于锚框的检测器——它们将输入图像上的位置视为(多个)锚框的中心, 并以这些锚框为参考回归目标边界框——我们直接在位置上回归目标边界框。换句话说, 我们的检测器直接将位置视为*training samples*, 而非基于锚框检测器中的锚框, 这与用于语义分割的FCNs做法一致[20]。

具体来说, 如果位置 (x, y) 落入任意真实标注框内, 且该位置的类别标签 c^* 与真实标注框的类别标签一致, 则将其视为正样本。否则, 它将被视为负样本, 且 $c^* = 0$ (背景类别)。除了分类标签外, 我们还有一个4维实向量 $\mathbf{t}^* = (l^*, t^*, r^*, b^*)$ 作为该位置的回归目标。其中 l^* 、 t^* 、 r^* 和 b^* 分别表示该位置到边界框四条边的距离, 如图1 (左) 所示。如果一个位置落入多个边界框内, 则将其视为*ambiguoussample*。我们直接选择面积最小的边界框作为其回归目标。在下一节中, 我们将展示通过多级预测, 模糊样本的数量可以显著减少, 因此它们几乎不会影响检测性能。形式上, 如果位置 (x, y) 与边界框 B_i 相关联, 则该位置的训练回归目标可表示为:

$$\begin{aligned} l^* &= x - x_0^{(i)}, \quad t^* = y - y_0^{(i)}, \\ r^* &= x_1^{(i)} - x, \quad b^* = y_1^{(i)} - y. \end{aligned} \quad (1)$$

It is worth noting that FCOS can leverage as many foreground samples as possible to train the regressor. 与基于锚点的检测器不同, 后者仅将与真实边界框具有足够高IOU的锚框视为正样本。我们认为, 这可能是FCOS 优于其基于锚点的对应方法的原因之一。

网络输出。与训练目标相对应, 我们网络的最后一层预测一个80维的分类标签向量 $\mathbf{p}$ 和一个4维的边界框坐标向量 $\mathbf{t} = (l, t, r, b)$ 。遵循[15]的方法, 我们训练 C 个二元分类器, 而非训练一个多类分类器。与[15]类似, 我们在骨干网络的特征图后分别添加四个卷积层用于分类——

分类和回归分支。此外, 由于回归目标始终为正, 我们在回归分支的顶部采用 $\exp(x)$ 将任意实数映射到 $(0, \infty)$ 区间。*It is worth noting that FCOS has 9 $\times$ fewer network output variables than the popular anchor-based detectors [15, 24] with 9 anchor boxes per location.*

损失函数。我们将训练损失函数定义如下:

$$\begin{aligned} L(\{\mathbf{p}_{x,y}\}, \{\mathbf{t}_{x,y}\}) &= \frac{1}{N_{\text{pos}}} \sum_{x,y} L_{\text{cls}}(\mathbf{p}_{x,y}, c_{x,y}^*) \\ &+ \frac{\lambda}{N_{\text{pos}}} \sum_{x,y} \mathbb{1}_{\{c_{x,y}^* > 0\}} L_{\text{reg}}(\mathbf{t}_{x,y}, \mathbf{t}_{x,y}^*), \end{aligned} \quad (2)$$

其中 L_{cls} 是如文献[15]所述的焦点损失, L_{reg} 是UnitBox [32] 中的IOU损失。 N_{pos} 表示正样本的数量, 本文中 λ 设为1, 作为 L_{reg} 的平衡权重。求和计算在特征图 F_i 的所有位置上进行。 $\mathbb{1}_{\{c_i^* > 0\}}$ 是指示函数, 当 $c_i^* > 0$ 时为1, 否则为0。

推理。FCOS的推理过程是直接的。给定输入图像, 我们通过网络前向传播, 获取特征图 F_i 上每个位置的分类得分 $\mathbf{p}_{x,y}$ 和回归预测 $\mathbf{t}_{x,y}$ 。遵循[15]的方法, 我们选择 $p_{x,y} > 0.05$ 的位置作为正样本, 并通过反解公式(1)得到预测边界框。

3.2. 基于FPN的FCOS多级预测

在此我们展示了如何通过使用FPN[14]的多层预测来解决所提出的FCOS可能存在的两个问题。1) CNN中最终特征图的大步长(e.g., $16\times$)可能导致相对较低的*best possible recall (BPR)*¹。对于基于锚点的检测器, 大步长导致的低召回率可以通过降低正锚框所需的IOU分数在一定程度上得到补偿。对于FCOS, 乍看之下人们可能会认为其BPR可能远低于基于锚点的检测器, 但是由于大步长, 最终特征图上没有位置编码的对象是无法被召回的。然而, 我们通过实验证明, 即使在大步长的情况下, 基于FCN的FCOS仍能产生良好的BPR, 甚至在官方实现Detectron[7]中, 其BPR可以优于基于锚点的检测器RetinaNet[15] (参见表1)。因此, BPR实际上并非FCOS的问题。此外, 通过多层FPN预测[14], BPR可以进一步提升以达到匹配效果。

¹Upper bound of the recall rate that a detector can achieve.

基于锚点的RetinaNet所能达到的最佳BPR。2) 真实标注框之间的重叠会导致难以处理的歧义问题, *i.e.*, 即重叠区域内的位置应该回归到哪个边界框? 这种歧义导致基于FCN的检测器性能下降。在本研究中, 我们证明通过多层级预测可以极大程度地解决这种歧义, 并且基于FCN的检测器能够取得*on par*, 有时甚至优于基于锚点的检测器的性能。

遵循FPN[14]的方法, 我们在不同层级的特征图上检测不同尺寸的目标。具体而言, 我们利用五个层级的特征图, 定义为 $\{P_3, P_4, P_5, P_6, P_7\}$ 。 P_3 、 P_4 和 P_5 由骨干CNN的特征图 C_3 、 C_4 和 C_5 通过[14]中所述的自顶向下连接并接一个 1×1 卷积层生成, 如图2所示。 P_6 和 P_7 则分别通过对 P_5 和 P_6 应用步长为2的卷积层得到。最终, 特征层级 P_3 、 P_4 、 P_5 、 P_6 和 P_7 的步长分别为8、16、32、64和128。

与基于锚点的检测器将不同尺寸的锚框分配给不同特征层不同, 我们直接限制每个层级的边界框回归范围。具体而言, 我们首先为所有特征层上的每个位置计算回归目标 l^* 、 t^* 、 r^* 和 b^* 。接着, 若某位置满足 $\max(l^*, t^*, r^*, b^*) > m_i$ 或 $\max(l^*, t^*, r^*, b^*) < m_{i-1}$, 则将其设为负样本, 不再需要进行边界框回归。此处 m_i 是特征层 i 所需回归的最大距离。本研究中, m_2 、 m_3 、 m_4 、 m_5 、 m_6 和 m_7 分别设置为0、64、128、256、512和 ∞ 。由于不同尺寸的目标被分配到不同特征层, 且重叠主要发生在尺寸差异显著的目标之间。若某位置即使采用多层级预测仍被分配给多个真实框, 我们直接选择面积最小的真实框作为其目标。实验表明, 多层级预测能显著缓解前述歧义, 并将基于全卷积网络的检测器提升至与基于锚点的检测器相当的水平。

最后, 遵循[14, 15]的做法, 我们在不同特征层级间共享检测头, 这不仅使检测器参数高效, 还提升了检测性能。然而, 我们观察到不同特征层级需要回归不同尺寸范围 (*e.g.*, P_3 的尺寸范围为[0,64], P_4 的尺寸范围为[64,128]), 因此为不同特征层级使用相同的检测头并不合理。于是, 我们不再使用标准的 $\exp(x)$, 而是采用 $\exp(s_i x)$ 并引入可训练标量 s_i , 以自动为特征层级 P_i 调整指数函数的底数, 这略微提升了检测性能。

3.3. FCOS的中心度

在使用FCOS进行多级预测后, FCOS与基于锚点的检测器之间仍存在性能差距。我们观察到, 这是由于距离物体中心较远的位置产生了大量低质量的预测边界框。

我们提出了一种简单而有效的策略来抑制这些低质量的检测边界框, 且无需引入任何超参数。具体而言, 我们在分类分支之外并行添加了*a single-layer branch*, 以预测位置²的“中心度”。如图7所示, 中心度描述了该位置到其负责的目标中心的归一化距离。给定位置对应的回归目标 l^* 、 t^* 、 r^* 和 b^* , 中心度目标定义为:

$$\text{centerness}^* = \sqrt{\frac{\min(l^*, r^*)}{\max(l^*, r^*)} \times \frac{\min(t^*, b^*)}{\max(t^*, b^*)}}. \quad (3)$$

我们在此采用平方根运算以减缓中心度的衰减。中心度的取值范围为0到1, 因此使用二元交叉熵 (BCE) 损失进行训练。该损失被加入损失函数公式 (2) 中。在测试时, 最终得分 (用于对检测到的边界框进行排序) 通过将预测的中心度与相应的分类得分相乘来计算。因此, 中心度可以降低远离物体中心的边界框的得分权重。这样一来, 这些低质量的边界框有很大概率会在最终的非极大值抑制 (NMS) 过程中被过滤掉, 从而提升检测性能*remarkably*。

中心度的一种替代方法是仅使用真实边界框的中心部分作为正样本, 代价是增加一个额外的超参数, 如文献[12, 33]所示。在我们提交后, 文献[1]表明两种方法的结合可以实现更好的性能。实验结果见表3。

4. 实验

我们的实验在大规模检测基准COCO[16]上进行。遵循通用实践[15, 14, 24], 我们使用COCO trainval35k划分 (11.5万张图像) 进行训练, 并采用minival划分 (5千张图像) 作为验证集以开展消融研究。我们将检测结果提交至评估服务器, 在test_dev划分 (2万张图像) 上报告了主要实验结果。

²After the initial submission, it has been shown that the AP on MS-COCO can be improved if the center-ness is parallel with the regression branch instead of the classification branch. However, unless specified, we still use the configuration in Fig. 2.




图3 – 中心度。红色、蓝色及其他颜色分别表示1、0及介于两者之间的数值。中心度通过公式(3)计算，并随着位置偏离物体中心从1衰减至0。测试时，网络预测的中心度会与分类得分相乘，从而降低远离物体中心的位置所预测的低质量边界框的权重。

训练细节。除非特别说明，我们使用ResNet-50 [8]作为骨干网络，并采用与RetinaNet [15]相同的超参数。具体而言，我们的网络使用随机梯度下降（SGD）进行训练，共90K次迭代，初始学习率为0.01，小批量大小为16张图像。学习率在迭代60K和80K时分别降低10倍。权重衰减和动量分别设置为0.0001和0.9。我们使用在ImageNet [4]上预训练的权重初始化骨干网络。对于新增的层，我们按照[15]的方法进行初始化。除非特别说明，输入图像的短边调整为800像素，长边小于或等于1333像素。

推理细节。我们首先将输入图像通过网络前向传播，获得带有预测类别的边界框预测。除非另有说明，以下后处理步骤与RetinaNet[15]完全相同，我们直接沿用RetinaNet相同的后处理超参数。我们使用与训练时相同尺寸的输入图像。我们推测，若仔细调整超参数，检测器的性能可能得到进一步提升。

4.1. 消融研究

4.1.1 基于FPN的多级预测

如前所述，基于FCN的检测器主要关注的是由真实边界框重叠引起的*low recall*率和*ambiguous samples*问题。在本节中，我们将展示这两个问题在很大程度上可以得到解决。

Method	w/ FPN	Low-quality matches	BPR (%)
RetinaNet	✓	None	86.82
RetinaNet	✓	≥ 0.4	90.92
RetinaNet	✓	All	99.23
FCOS		-	95.55
FCOS	✓	-	98.40

表1 – 基于锚点的RetinaNet在不同匹配规则下的BPR，以及基于FCN的FCOS的BPR。基于FCN的FCOS的召回率与最佳的基于锚点的方法非常接近，且远高于Detectron官方实现[7]中的召回率——后者仅考虑IOU ≥ 0.4 的低质量匹配。

w/ FPN	Amb. samples (%)	Amb. samples (diff.) (%)
	23.16	17.84
✓	7.14	3.75

表2 – Amb. samples 表示模糊样本占有所有正样本的比例。Amb. samples (diff.) 与之类似，但排除了重叠区域中属于同一类别的模糊样本，因为在推断时这类模糊性并不重要。可以看出，在使用FPN的情况下，这类模糊样本的占比比较小（3.75%）。

采用多级预测。

最佳可能召回率。关于基于FCN的检测器的首要担忧是，它可能无法提供良好的最佳可能召回率（BPR）。在本节中，我们表明这种担忧是不必要的。这里BPR定义为检测器最多能召回的真实标注框数量除以所有真实标注框的比率。如果一个真实标注框在训练期间被分配给至少一个样本（*i.e.*，例如FCOS中的某个位置或基于锚框检测器中的锚框），则认为该框被召回。如表1所示，仅使用步长为16的特征层级 P_4 （*i.e.*，即不使用FPN），FCOS已经可以获得95.55%的BPR。这一BPR远高于官方实现Detectron中基于锚框的检测器RetinaNet的90.92% BPR，后者仅使用了IOU ≥ 0.4 的低质量匹配。借助FPN，FCOS可以实现98.40%的BPR，非常接近基于锚框的检测器通过使用所有低质量匹配所能达到的最佳BPR。由于当前检测器的最佳召回率远低于90%，FCOS与基于锚框检测器之间的小幅BPR差距（小于1%）实际上不会影响检测器的性能。表3也证实了这一点，在相同的训练和测试设置下，FCOS甚至实现了比基于锚框的对应方法更好的平均召回率（AR）。因此，对低BPR的担忧可能是不必要的。

模糊样本。关于基于FCN的检测器的另一个担忧是，它可能包含大量*ambigu-*

Method	C_5/P_5	w/ GN	nms thr.	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L	AR ₁	AR ₁₀	AR ₁₀₀
RetinaNet	C_5		.50	35.9	56.0	38.2	20.0	39.8	47.4	31.0	49.4	52.5
FCOS	C_5		.50	36.3	54.8	38.7	20.5	39.8	47.8	31.5	50.6	53.5
FCOS	P_5		.50	36.4	54.9	38.8	19.7	39.7	48.8	31.4	50.6	53.4
FCOS	P_5		.60	36.5	54.5	39.2	19.8	40.0	48.9	31.3	51.2	54.5
FCOS	P_5	✓	.60	37.1	55.9	39.8	21.3	41.0	47.8	31.4	51.4	54.9
Improvements												
+ ctr. on reg.	P_5	✓	.60	37.4	56.1	40.3	21.8	41.2	48.8	31.5	51.7	55.2
+ ctr. sampling [1]	P_5	✓	.60	38.1	56.7	41.4	22.6	41.6	50.4	32.1	52.8	56.3
+ GIoU [1]	P_5	✓	.60	38.3	57.1	41.0	21.9	42.4	49.5	32.0	52.9	56.5
+ Normalization	P_5	✓	.60	38.6	57.4	41.4	22.3	42.5	49.8	32.3	53.4	57.1

表3 – 以 ResNet-50-FPN 为骨干网络时，FCOS 与 RetinaNet 在 minival 数据集上的对比。直接采用 RetinaNet 的训练和测试设置，我们无锚框的 FCOS 在 AP 和 AR 上均取得了优于基于锚框的 RetinaNet 的性能。在检测头中使用组归一化（GN）且 NMS 阈值为 0.6 时，FCOS 的 AP 可达 37.1。在我们提交结果后，FCOS 进行了一些几乎无需额外成本的改进，性能得到大幅提升，如“改进项”下方各行所示。“ctr. on reg.”：将中心度分支移至回归分支。“ctr. sampling”：仅将真实框的中心区域采样为正样本。“GIoU”：在 IoU 损失中对外接矩形面积与并集面积的比值进行惩罚。“Normalization”：使用 FPN 层级的步长对公式（1）中的回归目标进行归一化。详见代码实现。

ous samples 由于真实边界框的重叠，如图1（右）所示。在表2中，我们展示了在minival划分上模糊样本占所有正样本的比例。如表所示，如果不使用FPN而仅使用特征层级 P_4 ，确实存在大量模糊样本（23.16%）。然而，使用FPN后，该比例可显著降低至仅7.14%，因为大多数重叠物体被分配到了不同的特征层级。此外，我们认为由同一类别物体间重叠导致的模糊样本并不重要。例如，若物体A和B属于同一类别且存在重叠，则无论重叠区域内的位置预测哪个物体，预测结果都是正确的，因为它始终与同一类别匹配。未被预测到的物体可通过仅属于其自身的位置进行预测。因此，我们仅统计不同类别边界框重叠产生的模糊样本。如表2所示，多层级预测将模糊样本的比例从17.84%降低至3.75%。为进一步证明真实边界框的重叠并非我们基于FCN的FCOS的问题，我们统计了推断时有多少检测到的边界框来源于模糊位置。我们发现仅2.3%的检测边界框由模糊位置产生。若进一步仅考虑不同类别间的重叠，该比例降至1.5%。需注意，这并不意味着存在1.5%的位置是FCOS无法处理的。如前所述，这些位置与面积最小的真实边界框相关联。因此，这些位置仅承担遗漏某些较大物体的风险。如下述实验所示，它们并未使我们的FCOS逊色于基于锚框的检测器。

	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
None	33.5	52.6	35.2	20.8	38.5	42.6
center-ness [†]	33.5	52.4	35.1	20.8	37.8	42.8
center-ness	37.1	55.9	39.8	21.3	41.0	47.8

表4 – 在minival划分上对所提出的中心度分支进行的消融研究。“无”表示未使用任何中心度。“中心度[†]”表示使用从预测回归向量计算出的中心度。“中心度”表示使用从所提出的中心度分支预测的中心度。该中心度分支在所有指标下均提升了检测性能。

4.1.2 带或不带中心度

如前所述，我们提出“中心度”来抑制那些远离物体中心位置所产生的低质量检测边界框。如表4所示，中心度分支能将AP从33.5%提升至37.1%，使得无锚框的FCOS超越基于锚框的RetinaNet（35.9%）。需要注意的是，基于锚框的RetinaNet采用两个IoU阈值将锚框标记为正/负样本，这同样有助于抑制低质量预测。我们提出的中心度方法可以消除这两个超参数。然而，在我们初次提交后，研究表明同时使用中心度和阈值能获得更好的性能，如表3中“+ ctr. sampling”行所示。有人可能注意到，中心度也可以通过预测的回归向量计算，无需引入额外的中心度分支。但如表4所示，基于回归向量计算的中心度无法提升性能，因此独立的中心度分支是必要的。

4.1.3 FCOS与基于锚框的检测器对比

上述FCOS与标准RetinaNet有两个细微差别。1) 我们使用组归一化

Method	Backbone	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
Two-stage methods:							
Faster R-CNN w/ FPN [14]	ResNet-101-FPN	36.2	59.1	39.0	18.2	39.0	48.2
Faster R-CNN by G-RMI [11]	Inception-ResNet-v2 [27]	34.7	55.5	36.7	13.5	38.1	52.0
Faster R-CNN w/ TDM [25]	Inception-ResNet-v2-TDM	36.8	57.7	39.2	16.2	39.8	52.1
One-stage methods:							
YOLOv2 [22]	DarkNet-19 [22]	21.6	44.0	19.2	5.0	22.4	35.5
SSD513 [18]	ResNet-101-SSD	31.2	50.4	33.3	10.2	34.5	49.8
DSSD513 [5]	ResNet-101-DSSD	33.2	53.3	35.2	13.0	35.4	51.1
RetinaNet [15]	ResNet-101-FPN	39.1	59.1	42.3	21.8	42.7	50.2
CornerNet [13]	Hourglass-104	40.5	56.5	43.1	19.4	42.7	53.9
FSAF [34]	ResNeXt-64x4d-101-FPN	42.9	63.8	46.3	26.6	46.2	52.7
FCOS	ResNet-101-FPN	41.5	60.7	45.0	24.4	44.8	51.6
FCOS	HRNet-W32-51 [26]	42.0	60.4	45.3	25.4	45.0	51.0
FCOS	ResNeXt-32x8d-101-FPN	42.7	62.2	46.1	26.0	45.6	52.6
FCOS	ResNeXt-64x4d-101-FPN	43.2	62.8	46.6	26.5	46.2	53.3
FCOS w/ improvements	ResNeXt-64x4d-101-FPN	44.7	64.1	48.4	27.6	47.5	55.6

表5 – FCOS与其他先进的两阶段或一阶段检测器对比 (*single-model and single-scale results*)。在相同骨干网络下, FCOS的AP比基于锚点的对应方法RetinaNet高出2.4%。FCOS也优于近期无需锚点的单阶段检测器CornerNet, 且设计复杂度显著降低。具体“改进”细节请参见表3。

Method	# samples	AR ¹⁰⁰	AR ^{1k}
RPN w/ FPN & GN (ReImpl.)	~200K	44.7	56.9
FCOS w/ GN w/o center-ness	~66K	48.0	59.3
FCOS w/ GN	~66K	52.8	60.3

表6 – FCOS作为区域提议网络与使用FPN的RPN对比。主干网络采用ResNet-50。FCOS将AR¹⁰⁰和AR^{1k}分别提升了8.1%和3.4%。GN: 组归一化。

(GN) [29] 在新增加的卷积层中 (除了最后的预测层), 这使得我们的训练更加稳定。2) 我们使用 P_5 来生成 P_6 和 P_7 , 而不是标准 RetinaNet 中的 C_5 。我们观察到使用 P_5 可以略微提升性能。

为了证明我们的FCOS可以作为基于锚点检测器的一个简单而强大的替代方案, 并且为了公平比较, 我们移除了GN (梯度被裁剪以防止爆炸) 并在检测器中使用了 C_5 。如表3所示, 在完全相同的设置下, 我们的FCOS仍然优于基于锚点的检测器 (36.3% vs 35.9%)。此外, 值得注意的是, 我们直接使用了RetinaNet的所有超参数 (*e.g.*、学习率、NMS阈值等), 这些参数已针对基于锚点的检测器进行了优化。我们认为, 如果为FCOS调整超参数, 其性能还可以进一步提升。

值得注意的是, 通过一些几乎零成本的改进 (如表3所示), 我们的无锚点检测器性能可获得大幅提升。鉴于无锚点检测器的卓越性能及其优势 ($\{v^*\}$, 比基于锚点的检测器更简洁且超参数更少), 我们建议学界重新思考目标检测中锚框的必要性。

4.2. 与最先进检测器的比较

我们在MS-COCO基准测试的test – dev分割上, 将FCOS与其他最先进的物体检测器进行比较。在这些实验中, 我们在训练期间将图像的短边随机缩放至640到800的范围内, 并将迭代次数加倍至180K (学习率变化点按比例调整)。其他设置与表3中AP为37.1%的模型完全相同。如表5所示, 使用ResNet-101-FPN作为骨干网络时, 我们的FCOS在AP上比使用相同骨干网络ResNet-101-FPN的RetinaNet高出2.4%。据我们所知, 这是首次有无锚框检测器在没有任何额外修饰的情况下, 以较大优势超越基于锚框的检测器。FCOS同样以较大优势超越了其他经典的基于锚框的两阶段检测器, 如Faster R-CNN。使用ResNeXt-64x4d-101-FPN[30]作为骨干网络时, FCOS实现了43.2%的AP。它以较大优势超越了近期最先进的无锚框检测器CornerNet[13], 同时结构更为简洁。值得注意的是, CornerNet需要通过嵌入向量对角点进行分组, 这需要为检测器进行特殊设计。因此, 我们认为FCOS更有可能成为当前主流基于锚框检测器的强大而简洁的替代方案。此外, 结合表3中的改进, FCOS在单模型和单尺度测试下实现了44.7%的AP, 以较大优势超越了先前的检测器。

5. 区域提议网络的扩展

到目前为止, 我们已经证明, 在单阶段检测器中, 我们的FCOS可以实现比基于锚点的同类方法更好的性能。直观上, FCOS应该也能够

在两级检测器Faster R-CNN中，用FPN [14] 替换区域提议网络（RPNs）中的锚框。我们通过实验对此进行了验证。

与采用FPN的RPN[14]相比，我们使用FCOS中的方法替换了锚框。此外，我们在FPN头部各层中加入了GN，这能使训练更加稳定。其余所有设置均与官方代码[7]中采用FPN的RPN完全相同。如表6所示，即使未使用提出的中心度分支，我们的FCOS也已显著提升了 AR^{100} 和 AR^{1k} 。加入提出的中心度分支后，FCOS进一步将 AR^{100} 和 AR^{1k} 分别提升至52.8%和60.3%，相较于采用FPN的RPN， AR^{100} 实现了18%的相对提升， AR^{1k} 则获得3.4%的绝对提升。

6. 结论

我们提出了一种无锚框且无需候选区域的单阶段检测器FCOS。实验表明，FCOS与当前流行的基于锚框的单阶段检测器（包括RetinaNet、YOLO和SSD）相比具有优势，同时设计复杂度显著降低。FCOS完全避免了与锚框相关的所有计算和超参数，并以逐像素预测的方式解决目标检测问题，其形式类似于语义分割等其他密集预测任务。FCOS在单阶段检测器中实现了最先进的性能。我们还证明FCOS可作为两阶段检测器Faster R-CNN中的区域提议网络（RPN），并以显著优势超越其原有RPN。鉴于其高效性与有效性，我们希望FCOS能成为当前主流基于锚框检测器的有力且简洁的替代方案。我们亦相信FCOS可扩展应用于解决其他实例级识别任务。

附录

7. 类别无关的精确率-召回率曲线

Method	AP	AP ₅₀	AP ₇₅	AP ₉₀
Original RetinaNet [15]	39.5	63.6	41.8	10.6
RetinaNet w/ GN [29]	40.0	64.5	42.2	10.4
FCOS	40.5	64.7	42.6	13.1
		+0.2	+0.4	+2.7

表7 – RetinaNet和FCOS的类别无关检测性能。FCOS的性能优于RetinaNet。此外，随着IOU阈值更严格，FCOS相对于RetinaNet的提升幅度更大。这些结果采用我们主论文表4中的相同模型获得。

在图4、图5和图6中，我们展示了在IOU阈值为 $\{v^*\}$ 时，针对分割minival的类别无关精确率-召回率曲线。




图4 – 在IOU $\{v^*\}$ 0.50下的类别无关精确率-召回率曲线。

分别为0.50、0.75和0.90。表7展示了这三条曲线对应的AP值。

如表7所示，我们的FCOS相比其基于锚点的对应方法RetinaNet取得了更优的性能。值得注意的是，在更严格的IOU阈值下，FCOS相对于RetinaNet的提升幅度更大，这表明FCOS拥有更优的边界框回归器，能够更精确地检测目标。原因之一应是FCOS能够如主论文所述，利用更多前景样本来训练回归器。

最后，如所有精确率-召回率曲线所示，这些检测器在曲线中的最佳召回率远低于90%。这进一步表明，FCOS与RetinaNet之间*best possible recall (BPR)*的微小差距（98.40%对比99.23%）几乎不会损害最终检测性能。

8. 中心度可视化

如我们在主论文中所述，通过抑制低质量检测边界框，所提出的中心度分支大幅提升了检测性能。本节将对此进行验证。

我们期望中心度能够降低低质量边界框的得分，使得这些边界框在后续的后处理（如非极大值抑制）中被过滤掉。如果一个检测到的边界框与其对应的真实边界框的交并比得分较低，那么它就被认为是低质量的。一个交并比低但置信度得分高的边界框很可能成为误报，从而损害精确度。

在图7中，我们将检测到的边界框视为一个二维




图5 – 在IOU = 0.75下的类别无关精确率-召回率曲线。




图6 – 在IOU = 0.90下的类别无关精确率-召回率曲线。

点 (x, y) ，其中 x 为其得分， y 为其与对应真实框的交并比。如图7（左）所示，在应用中心度之前，存在大量低质量边界框却具有高置信度得分（即位于直线 $y = x$ 下方的点）。由于得分较高，这些低质量边界框无法在后处理中被消除，导致检测器的精度下降。将分类得分与中心度得分相乘后，这些点被推至图的左侧（即其得分降低），如图7（右）所示。因此，这些低质量边界框在后处理中被过滤掉的可能性大大增加，最终检测性能得以提升。

9. 定性结果

一些定性结果如图8所示。如图所示，我们提出的FCOS能够检测包括拥挤、遮挡、高度重叠、极小和极大物体在内的广泛目标。

10. 更多讨论

中心度 vs. IoUNet:

Jiang等人的“Acquisition of Localization Confidence for Accurate Object Detection”中的Center-ness和IoUNet具有相似的目的（*i.e.*，即抑制低质量预测），但方法不同。IoUNet训练一个独立的网络来预测预测边界框与真实边界框之间的IoU分数。而Center-ness作为我们检测器的一部分，仅包含单层结构并与检测器联合训练，因此更为简洁。此外，“center-ness”并不以预测边界框作为输入，而是直接评估位置预测高质量边界框的能力。

第4.1节中的BPR与歧义分析:

我们并不旨在比较“特定IoU下的召回率”与“框内像素召回率”。表1的主要目的是展示FCOS的召回率上限与基于锚点的RetinaNet的召回率上限非常接近（98.4%对比99.23%）。其他IoU阈值下的BPR也被列出，因为这些阈值在RetinaNet官方代码中被使用。此外，*no evidence shows that the regression targets of FCOS are difficult to learn because they are more spread-out*. FCOS实际上能产生更准确的边界框。

在训练过程中，我们通过选择面积最小的真实框来处理同一FPN层级上的歧义。测试时，若两个同类物体A和B存在重叠区域，则无论重叠区域内的位置点预测哪一个物体，该预测均被视为正确，而未被预测到的物体仍可通过其专属位置点进行预测。当A和B属于不同类别时，重叠区域内的位置点可能出现预测为A类别却回归到B边界框的错误情况。因此我们仅统计跨类别的歧义现象。此外，如表8所示，这种歧义并未导致FCOS在AP指标上逊色于RetinaNet。

额外的消融研究:

如表8所示，基础版FCOS与RetinaNet表现相当，其设计更简洁且网络输出减少 $\sim 9\times$ 。此外，FCOS在单锚点设置下明显优于RetinaNet。关于test-dev上2%的性能提升，除表8中各组件带来的增益外，我们推测不同的训练细节（*e.g.*、学习率调整策略）可能导致性能的细微差异。

带中心度的RetinaNet:




图7 – 无（左）或有（右）所提出的中心度。图中的点表示检测到的边界框。虚线为直线 $y = x$ 。如图所示（右），将分类分数与中心度分数相乘后，低质量框（直线 $y = x$ 下方）被推至图的左侧。这表明这些框的分数被显著降低。

Method	C_5/P_5	GN	Scalar	IoU	AP
RetinaNet (#A=1)	C_5				32.5
RetinaNet (#A=9)	C_5				35.7
FCOS (pure)	C_5				35.7
FCOS	P_5				35.8
FCOS	P_5	✓			36.3
FCOS	P_5	✓	✓		36.4
FCOS	P_5	✓	✓	✓	36.6

表8 – 在MS-COCO数据集上的消融研究 *minival*。“#A”表示RetinaNet中每个位置的锚框数量。“IOU”指IOU损失函数。“Scalar”表示是否在指数运算中使用标量。所有实验均在相同设置下进行。

中心度无法直接用于每个位置有多个锚框的RetinaNet中，因为特征图上的一个位置只有一个 *only one* 中心度分数，但同一位置的不同锚框需要不同的“中心度”（请注意，中心度也用作正负样本的“软”阈值）。

对于基于锚点的RetinaNet，锚框与真实框之间的IoU分数可以作为“中心度”的一种替代指标。

正样本与RetinaNet重叠：

我们想强调的是，中心度在测试时发挥作用 *only*。在训练时，所有位于真实框内的位置都被标记为正样本。因此，FCOS可以利用更多的前景位置来训练回归器，从而产生更准确的边界框。

致谢。我们要感谢[1]的作者提出的中心采样和GIoU技巧。我们同样

感谢邓超瑞基于HRNet的FCOS以及他将中心度分支与边界框回归结合的建议。

参考文献

- [1] https://github.com/yqyao/FCOS_PLUS, 2019. [2] Lokesh Bominathan, Srinivas SS Kruthiventi, 和 R Venkatesh Babu. Crowdnet: 用于密集人群计数的深度卷积网络。载于 *Proc. ACM Int. Conf. Multimedia*, 第640–644页。ACM, 2016. [3] 陈宇, 沈春华, 魏秀参, 刘凌巧, 和杨健. Adversarial PoseNet: 一种用于人体姿态估计的结构感知卷积网络。载于 *Proc. IEEE Int. Conf. Comp. Vis.*, 2017. [4] 邓嘉, 董炜, Richard Socher, 李立佳, 李凯, 和李飞飞. ImageNet: 一个大规模分层图像数据库。载于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第248–255页。IEEE, 2009. [5] 傅成阳, 刘伟, Ananth Ranga, Ambrish Tyagi, 和 Alexander Berg. DSSD: 反卷积单次检测器。 *arXiv preprint arXiv:1701.06659*, 2017. [6] Ross Girshick. Fast R-CNN。载于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第1440–1448页, 2015. [7] Ross Girshick, Ilija Radosavovic, Georgia Gkioxari, Piotr Dollár, 和何恺明. Detectron. <https://github.com/facebookresearch/detectron>, 2018. [8] 何恺明, 张祥雨, 任少卿, 和孙剑. 用于图像识别的深度残差学习。载于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第770–778页, 2016. [9] 何通, 沈春华, 田值, 龚东, 孙长明, 和颜友良. 知识自适应应用于高效语义分割。载于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2019年6月。



图 8 – 在 *minival* 分割集上的部分检测结果。采用 ResNet-50 作为骨干网络。如图所示，FCOS 在包括密集、遮挡、高度重叠、极小和极大物体在内的多种目标上均表现良好。

[10] 何桐、田植、黄伟林、沈春华、乔宇、孙长明。一种具有显式对齐与注意力的端到端文本定位器。发表于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第5020–5029页, 2018年。[11] Jonathan Huang、Vivek Rathod、Chen Sun、Menglong Zhu、Anoop Korattikara、Alireza Fathi、Ian Fischer、Zbigniew Wojna、Yang Song、Sergio Guadarrama等。现代卷积目标检测器的速度/精度权衡。发表于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第7310–7311页, 2017年。[12] 黄立超、杨毅、邓亚峰、于毅男。DenseBox：将地标定位与端到端目标检测相统一。arXiv preprint arXiv:1509.04874, 2015年。[13] 何辉、邓佳。CornerNet：将目标检测为成对关键点。发表于 *Proc. Eur. Conf. Comp. Vis.*, 第734–750页, 2018年。[14] 林腾毅、Piotr Dollár、Ross Girshick、何恺明、

Bharath Hariharan 和 Serge Belongie。用于目标检测的特征金字塔网络。载于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第2117–2125页, 2017年。[15] Tsung-Yi Lin、Priya Goyal、Ross Girshick、何恺明和 Piotr Dollár。密集目标检测的焦点损失。载于 *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第2980–2988页, 2017年。[16] Tsung-Yi Lin、Michael Maire、Serge Belongie、James Hays、Pietro Perona、Deva Ramanan、Piotr Dollár 和 Lawrence Zitnick。Microsoft COCO：上下文中的常见物体。载于 *Proc. Eur. Conf. Comp. Vis.*, 第740–755页。Springer, 2014年。[17] 刘发尧、沈春华、林国盛和 Ian Reid。使用深度卷积神经网络从单目图像学习深度。*IEEE Trans. Pattern Anal. Mach. Intell.*, 2016年。[18] 刘伟、Dragomir Anguelov、Dumitru Erhan、Christian Szegedy、Scott Reed、傅成阳和 Alexander C

Berg. SSD: 单发多框检测器。于*Proc. Eur. Conf. Comp. Vis.*, 第21–37页。Springer, 2016年。[19] 刘一凡、陈可、刘克、秦增昌、罗振波、王京东。面向语义分割的结构化知识蒸馏。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2019年6月。[20] Jonathan Long、Evan Shelhamer、Trevor Darrell。全卷积网络用于语义分割。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第3431–3440页, 2015年。[21] Joseph Redmon、Santosh Divvala、Ross Girshick、Ali Farhadi。你只看一次: 统一、实时的目标检测。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第779–788页, 2016年。[22] Joseph Redmon、Ali Farhadi。YOLO9000: 更好、更快、更强。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第7263–7271页, 2017年。[23] Joseph Redmon、Ali Farhadi。Yolov3: 一种渐进式改进。*arXiv preprint arXiv:1804.02767*, 2018年。[24] 任少卿、何恺明、Ross Girshick、孙剑。Faster R-CNN: 通过区域提议网络实现实时目标检测。于*Proc. Adv. Neural Inf. Process. Syst.*, 第91–99页, 2015年。[25] Abhinav Shrivastava、Rahul Sukthankar、Jitendra Malik、Abhinav Gupta。超越跳跃连接: 用于目标检测的自顶向下调制。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2017年。[26] 孙珂、肖斌、刘东、王京东。用于人体姿态估计的深度高分辨率表示学习。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2019年。[27] Christian Szegedy、Sergey Ioffe、Vincent Vanhoucke、Alexander A Alemi。Inception-v4、Inception-ResNet以及残差连接对学习的影响。于*Proc. National Conf. Artificial Intell.*, 2017年。[28] 田植、何彤、沈春华、严有良。解码器对语义分割至关重要: 数据依赖的解码实现灵活的特征聚合。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第3126–3135页, 2019年。[29] 吴育昕、何恺明。组归一化。于*Proc. Eur. Conf. Comp. Vis.*, 第3–19页, 2018年。[30] 谢赛宁、Ross Girshick、Piotr Dollár、涂卓文、何恺明。深度神经网络的聚合残差变换。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第1492–1500页, 2017年。[31] 尹威、刘一凡、沈春华、严有良。通过虚拟法向量的几何约束强化深度预测。于*Proc. IEEE Int. Conf. Comp. Vis.*, 2019年。[32] 于嘉慧、蒋宇宁、王张洋、曹志敏、黄煦。Unitbox: 一种先进的目标检测网络。于*Proc. ACM Int. Conf. Multimedia*, 第516–520页。ACM, 2016年。[33] 周新宇、姚聪、温鹤、王玉志、周树昌、何蔚然、梁佳俊。EAST: 一种高效准确的场景文本检测器。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 第5551–5560页, 2017年。[34] 朱晨晨、何一辉、Marios Savvides。用于单发目标检测的特征选择无锚模块。于*Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2019年6月。