

RepPoints: 用于目标检测的点集表示方法

泽杨^{1†*} 刘少辉^{2,3†*} 胡翰³ 王立威¹ 林史蒂芬³ ¹北京大学 ²清华大学 ³微软亚洲研究院

yangze@pku.edu.cn, blueber2y@gmail.com, wanglw@cis.pku.edu.cn

{hanhu, stevelin}@microsoft.com

摘要

Modern object detectors rely heavily on rectangular bounding boxes, such as anchors, proposals and the final predictions, to represent objects at various recognition stages. The bounding box is convenient to use but provides only a coarse localization of objects and leads to a correspondingly coarse extraction of object features. In this paper, we present **RepPoints** (representative points), a new finer representation of objects as a set of sample points useful for both localization and recognition. Given ground truth localization and recognition targets for training, RepPoints learn to automatically arrange themselves in a manner that bounds the spatial extent of an object and indicates semantically significant local areas. They furthermore do not require the use of anchors to sample a space of bounding boxes. We show that an anchor-free object detector based on RepPoints can be as effective as the state-of-the-art anchor-based detection methods, with 46.5 AP and 67.4 AP₅₀ on the COCO test-dev detection benchmark, using ResNet-101 model. Code is available at <https://github.com/microsoft/RepPoints>.

1. 引言

目标检测旨在定位图像中的物体并提供其类别标签。作为计算机视觉中最基础的任务之一，它是许多视觉应用的关键组成部分，包括实例分割[30]、人体姿态分析[37]和视觉推理[41]。目标检测问题的重要性与深度神经网络的快速发展相结合，近年来取得了显著进展[7, 11, 10, 33, 14, 3]。

在目标检测流程中，包围盒作为处理的基本单元，它们框定图像中的矩形区域，用以描述目标位置。




图1. RepPoints 是一种用于目标检测的新表征方式，它由一组指示物体空间范围及语义显著局部区域的点构成。该表征通过矩形标注框提供的弱定位监督与隐式识别反馈进行学习。基于这种更丰富的RepPoints表征，我们开发了一种无需锚框的目标检测器，相比使用边界框的方法取得了更优的性能。

在物体检测器的各个阶段，从锚框和候选框到最终预测，边界框始终贯穿其中。基于这些边界框，特征被提取并用于物体分类和位置细化等目的。边界框表示法的盛行，部分归因于物体检测性能的常用评估指标，这些指标考虑了物体估计边界框与真实边界框之间的重叠程度。另一个原因在于其便于深度网络中的特征提取，因为其规则形状以及将矩形窗口轻松细分为池化单元矩阵的特性。

尽管边界框便于计算，但它们仅提供物体的粗略定位，无法贴合物体的形状和姿态。因此，从边界框的规则单元格中提取的特征可能会受到背景内容或缺乏语义信息的无意义前景区域的严重影响。这可能导致特征质量下降，从而降低物体检测中的分类性能。

在本文中，我们提出了一种新的表示方法，称为

*Equal contribution. †The work is done when Ze Yang and Shaohui Liu are interns at Microsoft Research Asia.

*RepPoints*它提供了更精细的定位并有助于分类。如图1所示, *RepPoints*是一组点, 它们学习以自适应方式在物体上定位自身, 从而勾勒出物体的空间范围并指示语义上重要的局部区域。 *RepPoints*的训练由目标定位和识别任务共同驱动, 使得*RepPoints*被紧密约束在真实标注边界框内, 并引导检测器实现正确的物体分类。这种自适应且可微的表示能够连贯地应用于现代物体检测器的不同阶段, 且无需使用锚框来对边界框空间进行采样。

*RepPoints*与现有的非矩形物体检测表示方法不同, 后者均采用自下而上的方式构建[38, 21, 48]。这些自下而上的表示方法先识别独立点(如边界框角点或物体极值点), 再依赖手工设计的聚类将其组合成物体模型。此外, 它们的表示要么仍像边界框一样与坐标轴对齐[38, 21], 要么需要真实物体掩码作为额外监督[48]。相比之下, *RepPoints*通过自上而下的方式从输入图像/物体特征中学习, 支持端到端训练, 并能在无需额外监督的情况下实现精细定位。

通过将两阶段目标检测器中所有传统的边界框表示(包括锚点、提议和最终定位目标)替换为*RepPoints*, 我们开发了一个简洁高效的*anchor-free*目标检测器。在COCO基准测试[26]中, 该检测器无需多尺度训练和测试即可达到42.8 AP和65.0 AP_{50} ; 使用ResNet-101模型进行多尺度训练和测试时, 性能进一步提升至46.5 AP和67.4 AP_{50} 。所提出的目标检测器不仅超越了所有现有的无锚检测器, 其性能也与当前最先进的基于锚点的基线模型相当。

2. 相关工作

目标检测问题中的边界框。边界框长期以来一直是目标检测领域中占主导地位的目标表示形式。其普遍存在的一个原因是, 边界框标注方便且歧义性小, 同时能为后续识别过程提供足够精确的定位。这或许解释了为什么主要基准测试都采用基于边界框的标注和评估方式[8, 26, 20]。反过来, 这些基准测试也促使目标检测方法将边界框作为其基本表示形式, 以便与评估标准保持一致。

边界框占据主导地位的另一个原因是, 几乎所有图像特征提取器——无论是深度学习时代之前[39, 5]还是期间[19, 34, 36, 15]——都基于具有规则网格形式的输入图像块。因此它天

使用边界框表示法便于特征提取[11, 10, 33]。

尽管提出的*RepPoints*具有不规则形态, 我们证明其仍能适配便捷的特征提取。我们的系统将*RepPoints*与可变形卷积[4]结合使用, 这种组合天然契合*RepPoints*的特性——后者通过多个采样点聚合输入特征信息。此外, 矩形框*pseudo box*可直接从*RepPoints*生成(参见第3.2节), 这使得新表征能够兼容现有目标检测基准框架。

现代物体检测器中的边界框。迄今为止性能最佳的物体检测器通常遵循多阶段识别范式[24, 4, 13, 23, 2, 35, 27], 而边界框表示几乎出现在所有阶段: 1) 作为预定义[33, 25]或学习得到[40, 45, 47]的锚框, 在边界框空间中充当假设; 2) 作为连接连续识别阶段的优化物体提议[33, 2]; 3) 作为最终的定位目标。

*RepPoints*可用于替换模型目标检测器所有阶段中的边界框表示, 从而形成一个更有效的新目标检测器。具体来说, 锚点被中心点所取代, 这是*RepPoints*的一种特殊配置。边界框提议和最终定位目标被替换为*RepPoints*提议和最终目标。请注意, 由于使用中心点进行初始目标表示, 所得目标检测器是无锚点的。因此, 它比基于边界框的方法使用起来更加方便。

目标检测的其他表示方法。为了解决矩形边界框的局限性, 已有一些尝试开发更灵活的目标表示方法。这些方法包括用于行人检测的椭圆表示法[22]和能更好处理旋转变化的旋转边界框[16, 49]。

其他研究旨在以自下而上的方式表示物体。早期的自下而上表示方法包括DPM [9]和Poselet [1]。近年来, 基于深度网络的自下而上物体检测方法得到了探索[21, 48]。CornerNet [21]首先预测左上角和右下角, 然后采用专门的分组方法[28]来获取物体的边界框。然而, 这两个相对的角点本质上仍是对矩形边界框的建模。ExtremeNet [48]被提出用于定位物体在x和y方向上的极值点[29], 并通过真实掩码标注进行监督。总体而言, 自下而上的检测器受益于更小的假设空间(例如, CornerNet和ExtremeNet都检测二维点而非直接检测四维边界框)以及潜在更精细的定位能力。然而, 它们也存在局限性, 例如依赖手工设计的聚类或后处理步骤来组合完整的物体。

从检测到的点中提取物体。

与这些自下而上的工作类似, *RepPoints* 同样是一种灵活的对象表示方法。然而, 该表示是以自上而下的方式构建的, 无需手工设计的聚类步骤。*RepPoints* 能够自动学习极值点和关键语义点, 仅需真实标注框作为监督, 无需额外标注信息——这与需要额外掩码监督的 *ExtremeNet*[48] 不同。

物体识别中的形变建模。视觉识别最根本的挑战之一是如何识别具有各种几何变化的物体。为有效建模此类变化, 一种可能的解决方案是利用低级组件的自底向上组合。沿此方向的代表性检测器包括 *DPM*[9] 和 *Posenet*[1]。另一种方法是以自顶向下的方式隐式建模变换, 即在输入特征上应用轻量级神经网络模块, 这种方式既可全局应用[18]也可局部应用[4]。

RepPoints 受到这些工作的启发, 尤其是自上而下的变形建模方法[4]。主要区别在于, 除了语义特征提取外, 我们还致力于开发一种灵活的对象表示以实现精确的 *geometric localization*。相比之下, 可变形卷积和可变形 *RoI* 池化方法都仅旨在改进特征提取。第4节和附录中探讨了可变形 *RoI* 池化在学习精确几何定位方面的不足。从这个意义上说, 我们将先前几何建模方法[18, 4]中自适应采样点的应用扩展到包含更精细的对象定位。

3. *RepPoints* 表示法

我们首先回顾边界框表示及其在多阶段目标检测器中的应用, 随后介绍 *RepPoints* 及其与边界框的区别。

3.1. 边界框表示

边界框是一种4维表示, 用于编码物体的空间位置, $\mathcal{B} = (x, y, w, h)$, 其中 x, y 表示中心点, w, h 表示宽度和高度。由于其简单性和使用便利性, 现代物体检测器在检测流程的各个阶段都严重依赖边界框来表示物体。

多阶段目标检测器综述 性能最佳的目标检测器通常遵循多阶段识别范式, 其中目标定位通过逐阶段优化逐步精细化。目标表征在

该流程的步骤如下:

$$\begin{array}{lll} \text{bbox anchors} & \xrightarrow{\text{bbox reg.}} & \text{bbox proposals (S1)} \\ & \xrightarrow{\text{bbox reg.}} & \text{bbox proposals (S2)} \\ & \dots & \\ & \xrightarrow{\text{bbox reg.}} & \text{bbox object targets} \end{array} \quad (1)$$

起初, 假设多个锚框以覆盖不同尺度和长宽比的边界框范围。通常, 通过在庞大的4维假设空间中使用密集锚框, 可以获得高覆盖率。例如, *RetinaNet* [25] 中每个位置使用了45个锚框。

对于锚点, 我们采用其中心点的图像特征作为物体特征, 随后该特征被用于生成一个置信度分数, 以判断该锚点是否为物体, 并通过边界框回归过程生成精细化的边界框。精细化后的边界框被标记为“边界框提议 (S1)”。

在第二阶段, 从精炼的边界框提议中提取出精炼的对象特征, 通常通过 *RoI* 池化[10]或 *RoI* 对齐[13]实现。对于两阶段框架[33], 精炼特征将通过边界框回归生成最终的边界框目标。对于多阶段方法[2], 精炼特征则用于生成中间的精炼边界框提议 (S2), 同样通过边界框回归完成。该步骤可在生成最终边界框目标前多次迭代进行。

在此框架中, 边界框回归在逐步优化目标定位与目标特征方面起着核心作用。我们将在下文阐述边界框回归的过程。

边界框回归传统上, 预测一个4维回归向量 ($\{v^*\}$) 以将当前边界框提议 $\{v^*\}$ 映射到一个精炼的边界框 $\{v^*\}$, 其中

$$\mathcal{B}_r = (x_p + w_p \Delta x_p, y_p + h_p \Delta y_p, w_p e^{\Delta w_p}, h_p e^{\Delta h_p}). \quad (2)$$

给定物体的真实边界框 $\mathcal{B}_t = (x_t, y_t, w_t, h_t)$, 边界框回归的目标是使 $\mathcal{B}_r$ 和 $\mathcal{B}_t$ 尽可能接近。具体而言, 在目标检测器的训练中, 我们使用预测的4维回归向量与期望的4维回归向量 $\hat{\mathcal{F}}(\mathcal{B}_p, \mathcal{B}_t)$ 之间的距离作为学习目标, 并采用平滑的 l_1 损失函数:

$$\hat{\mathcal{F}}(\mathcal{B}_p, \mathcal{B}_t) = \left(\frac{x_t - x_p}{w_p}, \frac{y_t - y_p}{h_p}, \log \frac{w_t}{w_p}, \log \frac{h_t}{h_p} \right). \quad (3)$$

该边界框回归过程在现有目标检测方法中被广泛使用。当所需修正较小时, 它在实践中表现良好, 但当初始表示与目标之间存在较大距离时, 其性能往往较差。另一个问题在于

$\Delta x, \Delta y$ 和 $\Delta w, \Delta h$ 之间的尺度差异，这需要调整它们的损失权重以获得最佳性能。

3.2. 代表点

如前所述，4维边界框是物体位置的粗略表示。边界框表示仅考虑物体的矩形空间范围，未考虑形状、姿态以及语义重要局部区域的位置，而这些信息可用于更精细的定位和更好的物体特征提取。

为了克服上述限制，*RepPoints*转而建模一组自适应采样点：

$$\mathcal{R} = \{(x_k, y_k)\}_{k=1}^n, \quad (4)$$

其中 n 是表示中使用的样本点总数。在我们的工作中， n 默认为 9。

RepPoints 的逐步优化 逐步优化边界框定位和特征提取对于多阶段目标检测方法的成功至关重要。对于 *RepPoints* 而言，这种优化可以简单表示为

$$\mathcal{R}_r = \{(x_k + \Delta x_k, y_k + \Delta y_k)\}_{k=1}^n, \quad (5)$$

其中 $\{(\Delta x_k, \Delta y_k)\}_{k=1}^n$ 是新样本点相对于旧样本点的预测偏移量。我们注意到，这种优化不会面临边界框回归参数间尺度差异的问题，因为在 *RepPoints* 的优化过程中，偏移量处于同一尺度。

将RepPoints转换为边界框 为了在 *RepPoints* 的训练中利用边界框标注，并评估基于 *RepPoints* 的目标检测器，需要一种将 *RepPoints* 转换为边界框的方法。我们使用预定义的转换函数 $\mathcal{T}: \mathcal{R}_P \rightarrow \mathcal{B}_P$ 来执行此转换，其中 $\mathcal{R}_P$ 表示目标 P 的 *RepPoints*， $\mathcal{T}(\mathcal{R}_P)$ 代表一个 *pseudo box*。

为此目的，考虑了三种转换函数：

- $\mathcal{T} = \mathcal{T}_1$: 最小-最大函数。在 *RepPoints* 上沿双轴执行最小-最大运算以确定 $\mathcal{B}_p$ ，这等价于样本点上的边界框。
- $\mathcal{T} = \mathcal{T}_2$: 部分最小-最大函数。在样本点子集上执行最小-最大操作，覆盖两个坐标轴以获得矩形框 $\mathcal{B}_{p\circ}$ 。
- $\mathcal{T} = \mathcal{T}_3$: 基于矩的函数。利用 *RepPoints* 的均值与标准差计算矩形框的中心点与尺度 $\mathcal{B}_p$ ，其中尺度会乘以全局共享的可学习乘数 λ_x 和 $\lambda_{y\circ}$ 。

这些函数都是可微分的，当它们被插入到目标检测系统中时，能够实现端到端的学习。在我们的实验中，我们发现它们表现相当出色。

学习 *RepPoints* 由目标定位损失和目标识别损失共同驱动。为计算目标定位损失，我们首先使用先前讨论的转换函数 $\mathcal{T}$ 将 *RepPoints* 转换为 *pseudo box*，随后计算转换后的 *pseudo box* 与真实边界框之间的差异。本系统采用左上角与右下角点之间的平滑 l_1 距离来表示定位损失，这种平滑 l_1 距离无需像计算边界框回归向量距离时（即针对 $\Delta x, \Delta y$ 和 $\Delta w, \Delta h$ ）那样调整不同损失的权重。图4表明，当训练由目标定位与目标识别损失共同驱动时，物体的极端点和语义关键点会被自动学习（在将 *RepPoints* 转换为伪框时使用了 $\mathcal{T}_1$ ）。

4. RPDet：一种无锚框检测器

我们设计了一种无锚框目标检测器，它使用 *RepPoints* 代替边界框作为基本表示。在多阶段流程中，目标表示按如下方式演进：

$$\begin{array}{ccc} \text{object centers} & \xrightarrow{\text{RP refine}} & \text{RepPoints proposals (S1)} \\ & \xrightarrow{\text{RP refine}} & \text{RepPoints proposals (S2)} \\ & \dots & \\ & \xrightarrow{\text{RP refine}} & \text{RepPoints object targets} \end{array} \quad (6)$$

我们的 *RepPoints* 检测器 (RPDet) 基于可变形卷积构建，包含两个识别阶段，如图2所示。可变形卷积与 *RepPoints* 能很好地配合，因为其卷积计算在一组不规则分布的采样点上进行，反之其识别反馈也能指导这些点的定位训练。本节将介绍 RPDet 的设计，并讨论其与现有物体检测器的关联及差异。

基于中心点的初始物体表示。在物体检测的初始阶段，预定义锚点主导着物体的表示，我们遵循 YOLO [31] 和 DenseBox [17] 的方法，采用中心点作为物体的初始表示，从而构建了一种无锚框的物体检测器。

中心点表示的一个重要优势在于，与基于锚点的方法相比，其假设空间更为紧凑。基于锚点的方法通常依赖大量多比例、多尺度的锚点来确保对四维边界框空间的密集覆盖。




图2. 所提出的RPDet (RepPoints检测器) 概述。虽然采用特征金字塔网络 (FPN) [24] 作为骨干网络, 但为清晰说明, 我们仅绘制了单尺度FPN特征图的后继流程。请注意, 所有尺度的FPN特征图共享相同的后继网络架构和模型权重。

在框假设空间中，基于中心点的方法能更轻松覆盖其二维空间。事实上，所有物体的中心点都将位于图像内部。

然而，基于中心点的方法也面临着识别目标模糊的问题，这是由于两个不同物体在特征图中位于同一位置所导致的，这限制了其在现代物体检测器中的普及。在先前方法[31]中，主要通过在每个位置生成多个目标来解决这一问题，但这又带来了归属模糊的问题。在RPDet中，我们展示了通过使用FPN结构[24]可以极大地缓解这一问题，原因如下：首先，不同尺度的物体会被分配到不同的图像特征层级，这解决了不同尺度物体具有相同中心点位置的问题；其次，FPN为小物体提供了高分辨率的特征图，这也降低了两物体中心位于同一特征位置的可能性。事实上，我们观察到，在使用FPN时，COCO数据集[26]中仅有1.1%的物体存在中心点位于同一位置的问题。

值得注意的是，中心点表示可视为一种特殊的RepPoints配置，其中仅使用单个固定采样点，从而在整个检测框架中保持连贯的表示形式。

RepPoints的利用。如图2所示，RepPoints作为我们检测系统中的基本对象表示。从中心点出发，第一组 $\{v^*\}$ 通过回归中心点上的偏移量获得。这些 $\{v^*\}$ 的学习由两个目标驱动：1) 诱导出的 $\{v^*\}$ 与真实边界框之间左上和右下点的距离损失；2) 后续阶段的对象识别损失。如图4所示，极端




图3. RPDet的头部架构。

并且关键点被自动学习。第二组 $RepPoints$ 代表最终的对象定位,它通过方程(5)从第一组 $RepPoints$ 中细化而来。仅由点距离损失驱动,这第二组 $RepPoints$ 旨在学习更精细的对象定位。

与可变形RoI池化[4]的关系。如第2节所述,可变形RoI池化在目标检测中扮演的角色与提出的 $RepPoints$ 不同。本质上, $RepPoints$ 是目标的几何表征,反映了更精确的语义定位,而可变形RoI池化则旨在学习目标更强的外观特征。实际上,可变形RoI池化无法学习到表示目标精确定位的采样点(证明详见附录)。

我们还注意到，可变形RoI池化可以作为RepPoints的补充，如表6所示。

骨干网络与头部架构 我们的FPN骨干网络遵循[25]的设计, 从第3阶段(下采样率为8)到第7阶段(下采样率为128)共生成5个特征金字塔层级。

头部架构如图3所示。包含两个 $non-shared$ 子网络, 分别用于定位(RepPoints生成)和分类。定位子网络首先应用三个 256 维 3×3 卷积层, 后接一一

¹If the center points of multiple ground truth objects are located at a same feature map position, only one randomly chosen ground truth object is assigned to be the target of this position.

随后是两个连续的小型网络，用于计算两组RepPoints的偏移量。分类子网络同样应用三个256维3×3卷积层，接着是一个256维3×3可变形卷积层，其输入偏移场与定位子网络中第一个可变形卷积层的偏移场共享。在两个子网络中，前三个256维3×3卷积层之后均应用了组归一化层。

请注意，尽管我们的方法采用了两个阶段的定位，但它甚至比单阶段的RetinaNet [25] 检测器更高效（使用ResNet-50时分别为210.9 vs. 234.5 GFLOPS）。由于层共享，额外的定位阶段引入的开销很小。无锚框设计减轻了最终分类层的负担，从而略微减少了计算量。

定位/分类目标分配。存在两个定位阶段：首先生成第一组RepPoints，通过从物体中心点假设（特征图单元）进行细化；然后生成第二组RepPoints，通过从第一组RepPoints进行细化。在这两个阶段中，训练时仅对 *positive* 物体假设分配定位（RepPoints）目标。对于第一定位阶段，一个特征图单元被 *positive* 的条件是：1) 该特征图单元的金字塔层级等于真实物体 $s(B) = \lfloor \log_2(\sqrt{w_B h_B}/4) \rfloor$ 的对数尺度；2) 该真实物体中心点的投影位于此特征图单元内。对于第二定位阶段，第一组RepPoints被 *positive* 的条件是：其诱导出的伪框与某个真实物体有足够重叠，即它们的交并比大于0.5。

分类仅在第一组RepPoints上进行。分类分配标准遵循[25]，即诱导出的伪框与真实边界框之间的IoU大于0.5表示 *positive*，小于0.4表示背景，其余情况则忽略。分类训练采用焦点损失[25]。

5. 实验

5.1. 实验设置

我们在MS-COCO [26]检测基准上展示了所提出的RPDet框架的实验结果，该基准包含118k张训练图像、5k张验证图像（minival）和20k张测试图像（test-dev）。除非另有说明，所有消融研究均使用ResNet-50 [15] 在minival上进行。表7中报告了在test-dev上的最先进性能对比。

我们的检测器使用同步随机梯度下降（SGD）在4个GPU上进行训练，每个小批次共包含8张图像（每个GPU处理2张图像）。初始化时采用了ImageNet [6]的预训练模型。我们的学习率调度遵循“1x”设置 [12]。随机水平

Representation	Backbone	AP	AP_{50}	AP_{75}
Bounding box	ResNet-50	36.2	57.3	39.8
RepPoints (ours)	ResNet-50	38.3	60.0	41.1
Bounding box	ResNet-101	38.4	59.9	42.4
RepPoints (ours)	ResNet-101	40.4	62.0	43.6

表1. 目标检测中RepPoints与边界框表示方法的比较。除处理给定目标表示方式外，网络结构保持相同。

Representation	Supervision		AP	AP_{50}	AP_{75}
	loc.	rec.			
bounding box	✓		36.2	57.3	39.8
	✓	✓	36.2	57.5	39.8
RepPoints		✓	33.8	54.3	35.8
	✓		37.6	59.4	40.4
	✓	✓	38.3	60.0	41.1

表2. 基于边界框和RepPoints的目标检测中监督来源的消融实验。“loc.”表示目标定位损失。“rec.”表示来自下一检测阶段的目标识别损失。

other repr.	init repr.	AP	AP_{50}	AP_{75}
bounding box	single anchor	36.2	57.3	39.8
	center point	37.3	58.0	40.0
RepPoints	single anchor	36.9	58.2	39.7
	center point	38.3	60.0	41.1

表3. 使用单个锚点与中心点作为初始对象表示（“初始表示”）的对比。“其他表示”指代对象提议和最终目标的表示方法。

method	backbone	# anchors per scale	AP
RetinaNet [25]	ResNet-50	3×3	35.7
FPN-RoIAlign [24]	ResNet-50	3×1	36.7
YOLO-like	ResNet-50	-	33.9
RPDet (ours)	ResNet-50	-	38.3
RetinaNet [25]	ResNet-101	3×3	37.8
FPN-RoIAlign [24]	ResNet-101	3×1	39.4
YOLO-like	ResNet-101	-	36.3
RPDet (ours)	ResNet-101	-	40.4

表4. 所提方法（RPDet）与基于锚框的方法（RetinaNet、FPN-RoIAlign）以及无锚框方法（类YOLO方法）的对比。类YOLO方法基于YOLOv1方法[31]改进，额外引入了FPN[24]、GN[42]和焦点损失[25]以提升精度。

在训练中采用了水平图像翻转。在推理过程中，按照[25]的方法，使用NMS（{v*}0.5）对结果进行后处理。



图4. 在COCO [26] 小型验证集的若干示例上，学习到的RepPoints及由其导出的边界框可视化（使用伪框转换函数 $\mathcal{T}_1$ ）。总体而言，学习到的RepPoints通常位于物体的极值点或语义关键点上。

pseudo box converting function	AP	AP_{50}	AP_{75}
$\mathcal{T} = \mathcal{T}_1$: min-max	38.2	59.7	40.7
$\mathcal{T} = \mathcal{T}_2$: partial min-max	38.1	59.6	40.5
$\mathcal{T} = \mathcal{T}_3$: moment-based	38.3	60.0	41.1

表5. 从RepPoints到伪框的不同转换函数比较， $\mathcal{T}$ 。

representation method	w. dpool	AP	AP_{50}	AP_{75}
bounding box		36.2	57.3	39.8
	✓	36.9	58.0	41.0
RepPoints		38.3	60.0	41.1
	✓	39.1	60.6	42.4

表6. 在首阶段提议上应用可变形RoI池化层[4]的效果（参见公式(1)与公式(6)）。可变形RoI池化层能分别提升使用边界框和RepPoints两种方法的性能。

5.2. 消融研究

RepPoints与边界框对比。为了展示所提出的RepPoints的有效性，我们将提出的RPDet与一个基线检测器进行比较，其中RepPoints全部被常规的边界框表示所取代。

Baseline detector based on bounding box representations. 初始目标表示采用一个尺度为4、宽高比为1:1的单一锚点，若其与真实目标的交并比大于0.5，则锚框为positive。两组RepPoints被替换为边界框表示，其中几何细化通过标准边界框回归方法实现，特征提取则采用RoIAlign[13]方法，使用 3×3 网格点²。其余所有设置均与所提出的RPDet方法保持一致。

表1展示了两种检测器的对比。基于边界框的方法达到了36.2 mAP，表明其作为基线检测器的强大性能，而将物体表示从边界框改为RepPoints后，在使用ResNet-50 [15] 时带来了+2.1 mAP的提升，在使用ResNet-101 [15] 骨干网络时带来了+2.0 mAP的提升，这证明了在物体检测任务中RepPoints表示相较于边界框的优势。

RepPoints学习的监督来源。RPDet利用目标定位损失和目标识别损失（来自后续识别的梯度）共同驱动学习过程。

²It can be also implemented by a deformable convolution operator with an unlearnable input offset field induced by the 3×3 grid points.

第一组RepPoints，代表了第一阶段的物体提议。表2消融了这两种监督来源在物体表示学习中的使用。如前所述，描述物体的几何定位是表示方法的重要职责。没有物体定位损失，表示方法很难完成这一职责，因为这会导致物体检测器的性能显著下降。对于RepPoints，我们观察到移除物体定位监督后mAP大幅下降了4.5，这表明描述几何定位对于物体表示方法的重要性。

表2同样展示了在学习RepPoints时加入物体识别损失的好处（ $\{v^*\}$ 0.7 mAP）。使用物体识别损失能够驱动RepPoints定位到物体上具有语义意义的位置，从而实现细粒度的定位，并提升后续识别阶段的物体特征提取效果。值得注意的是，物体识别反馈无法使采用边界框表示的目标检测方法受益（见表2第一栏），这进一步证明了RepPoints在灵活物体表示方面的优势。

无锚框与基于锚框的方法。我们首先在表3中比较了基于中心点的方法（一种特殊的RepPoints配置）和主流的基于锚框的方法在表示初始目标假设方面的表现。对于两种检测器使

	Backbone	Anchor-Free	AP	AP_{50}	AP_{75}	AP_S	AP_M	AP_L
Faster R-CNN w. FPN [24]	ResNet-101		36.2	59.1	39.0	18.2	39.0	48.2
RefineDet [46]	ResNet-101		36.4	57.5	39.5	16.6	39.9	51.4
RetinaNet [25]	ResNet-101		39.1	59.1	42.3	21.8	42.7	50.2
Deep Regionlets [44]	ResNet-101		39.3	59.8	-	21.7	43.7	50.9
Mask R-CNN [13]	ResNeXt-101		39.8	62.3	43.4	22.1	43.2	51.2
FSAF [50]	ResNet-101		40.9	61.5	44.0	24.0	44.2	51.3
Cascade R-CNN [2]	ResNet-101		42.8	62.1	46.3	23.7	45.5	55.2
CornerNet [21]	Hourglass-104	✓	40.5	56.5	43.1	19.4	42.7	53.9
ExtremeNet [48]	Hourglass-104	✓	40.1	55.3	43.2	20.3	43.2	53.1
RPDet	ResNet-101	✓	41.0	62.9	44.3	23.6	44.1	51.7
RPDet	ResNet-101-DCN	✓	42.8	65.0	46.3	24.9	46.2	54.7
RPDet (ms train)	ResNet-101-DCN	✓	45.0	66.1	49.0	26.6	48.6	57.5
RPDet (ms train & ms test)	ResNet-101-DCN	✓	46.5	67.4	50.9	30.3	49.7	57.1

表7. 提出的RPDet与先前最先进检测器在COCO [26] test-dev数据集上的对比。提出的RPDet可实现46.5 AP，显著超越所有其他检测器。同时请注意RPDet的 AP_{50} 值相对较高，该指标在许多应用中被认为是更优的评估标准[32]。“ms”表示多尺度测试。

在边界框和RepPoints方面，基于中心点的方法分别超越了基于锚点的方法+1.1 mAP和+1.4 mAP，这很可能是因为它能更好地覆盖真实目标物体。

我们还将提出的基于RepPoints的无锚点检测器与RetinaNet[25]（一种流行的单阶段基于锚点的方法）、采用RoIAlign的FPN[24]（一种流行的两阶段基于锚点方法）[13]，以及从YOLOv1[31]的无锚点方法改进而来的类YOLO检测器进行比较，结果如表4所示。所提出的方法在性能上超越了RetinaNet[25]和FPN[24]方法，这两种方法均使用了每尺度多个锚点和复杂的锚点配置（FPN）。同时，所提出的方法也显著优于另一种无锚点方法（类YOLO检测器），分别以+4.4 mAP和+4.1 mAP的优势领先，这很可能归功于RepPoints表示的灵活性及其有效的优化机制。

将RepPoints转换为伪边界框。表5显示，第3.2节中提出的变换函数 $\{v^*\}$ 的不同实例化效果相当。

RepPoints与可变形RoI池化[4]起到互补作用。表6展示了将可变形RoI池化层[4]同时应用于边界框提议和RepPoints提议的效果。虽然对边界框提议应用可变形RoI池化层带来了+0.7 mAP的提升，但将其应用于RepPoints提议同样带来了+0.8 mAP的提升，这表明可变形RoI池化与所提出的RepPoints具有互补性。

5.3. RepPoints 可视化

在图4中，我们可视化了从COCO [26] minival数据集中选取的几个示例上学习到的RepPoints及其对应的检测结果。可以观察到，Rep-Points倾向于位于物体的极值点或关键语义点上。这些分布在物体上的点是自动学习得到的，无需显式监督。可视化结果也表明，本文提出的RPDet（此处采用最小-最大变换函数实现）能够有效检测微小物体。

5.4. 最先进技术对比

我们在测试开发集上将RPDet与最先进的检测器进行比较。表7展示了结果。在没有任何额外技巧的情况下，RPDet在COCO基准测试[26]上取得了42.8 AP，这与基于四阶段锚框的Cascade R-CNN[2]表现相当，并超越了所有现有的无锚框方法。通过采用多尺度训练和测试（详见附录），RPDet可以达到46.5 AP，显著超越所有其他检测器。同时值得注意的是，RPDet的 $\{v^*\}$ 相对较高，这被认为在许多应用中是更优的评估指标[32]。

6. 结论

本文提出了一种用于目标检测的表示方法RepPoints，该方法能够建模细粒度的定位信息，并识别对目标分类至关重要的局部区域。基于RepPoints，我们开发了一种名为RPDet的目标检测器，无需锚框即可实现具有竞争力的检测性能。学习如RepPoints般更丰富、更自然的目标表示，是目标检测领域极具前景的发展方向。

参考文献

[1] Lubomir Bourdev, Subhransu Maji, Thomas Brox, Jitendra Malik. 利用相互一致的姿态激活进行人体检测。发表于 *ECCV*, 第168–181页。Springer, 2010年。2, 3[2] 蔡兆伟, Nuno Vasconcelos. Cascade R-CNN: 深入高质量目标检测。发表于 *CVPR*, 第6154–6162页, 2018年。2, 3, 8[3] 戴继峰, 李毅, 何恺明, 孙剑。R-FCN: 基于区域的全卷积网络目标检测。发表于 *NIPS*, 第379–387页, 2016年。1[4] 戴继峰, 齐浩志, 熊宇雯, 李毅, 张国栋, 胡涵, 魏亦忱。可变形卷积网络。发表于 *ICCV*, 第764–773页, 2017年。2, 3, 5, 7, 8, 11, 12[5] Navneet Dalal, Bill Triggs. 用于人体检测的方向梯度直方图。发表于 *CVPR*, 第1卷, 第886–893页。IEEE计算机学会, 2005年。2[6] 邓嘉, 董伟, Richard Socher, 李立佳, 李凯, 李飞飞。ImageNet: 一个大规模分层图像数据库。2009年。6[7] Dumitru Erhan, Christian Szegedy, Alexander Toshev, Dragomir Anguelov. 使用深度神经网络的可扩展目标检测。发表于 *CVPR*, 第2147–2154页, 2014年。1[8] Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn, Andrew Zisserman. PASCAL视觉对象类别 (VOC) 挑战赛。 *IJCV*, 88(2):303–338, 2010年。2[9] Pedro F Felzenszwalb, Ross B Girshick, David McAllester, Deva Ramanan. 使用判别性训练的基于部件的模型进行目标检测。 *PAMI*, 32(9):1627–1645, 2010年。2, 3[10] Ross Girshick. Fast R-CNN. 发表于 *ICCV*, 第1440–1448页, 2015年。1, 2, 3[11] Ross Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik. 用于精确目标检测和语义分割的丰富特征层次结构。发表于 *CVPR*, 第580–587页, 2014年。1, 2, 11[12] Ross Girshick, Ilija Radosavovic, Georgia Gkioxari, Piotr Dollár, 何恺明。Detectron. <https://github.com/facebookresearch/detectron>, 2018年。6, 12[13] 何恺明, Georgia Gkioxari, Piotr Dollár, Ross Girshick. Mask R-CNN. 发表于 *ICCV*, 第2961–2969页, 2017年。2, 3, 7, 8, 11[14] 何恺明, 张祥雨, 任少卿, 孙剑。深度卷积网络中用于视觉识别的空间金字塔池化。 *PAMI*, 37(9):1904–1916, 2015年。1[15] 何恺明, 张祥雨, 任少卿, 孙剑。用于图像识别的深度残差学习。发表于 *CVPR*, 第770–778页, 2016年。2, 6, 7, 12[16] 黄畅, 艾海舟, 李源, 劳世宏。高性能旋转不变多视角人脸检测。 *PAMI*, 29(4):671–686, 2007年。2[17] 黄立超, 杨毅, 邓亚峰, 于亦楠。DenseBox: 将地标定位与端到端目标检测相统一。 *arXiv preprint arXiv:1509.04874*, 2015年。4

[18] Max Jaderberg, Karen Simonyan, Andrew Zisserman 等。空间变换网络。发表于 *NIPS*, 第 2017–2025 页, 2015 年。3[19] Alex Krizhevsky, Ilya Sutskever, Geoffrey E Hinton. 使用深度卷积神经网络进行 ImageNet 分类。发表于 *NIPS*, 第 1097–1105 页, 2012 年。2[20] Alina Kuznetsova, Hassan Rom, Neil Aldrin, Jasper Uijlings, Ivan Krasin, Jordi Pont-Tuset, Shahab Kamali, Stefan Popov, Matteo Mallocci, Tom Duerig 等。Open Images 数据集 V4: 统一的大规模图像分类、目标检测与视觉关系检测。 *arXiv preprint arXiv:1811.00982*, 2018 年。2[21] Hei Law, Jia Deng. CornerNet: 将目标检测为成对关键点。发表于 *ECCV*, 第 734–750 页, 2018 年。2, 8[22] Bastian Leibe, Edgar Seemann, Bernt Schiele. 拥挤场景中的行人检测。发表于 *CVPR*, 第 1 卷, 第 878–885 页。IEEE, 2005 年。2[23] Zeming Li, Chao Peng, Gang Yu, Xiangyu Zhang, Yangdong Deng, Jian Sun. Light-Head R-CNN: 为两阶段目标检测器辩护。 *arXiv preprint arXiv:1711.07264*, 2017 年。2[24] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, Serge Belongie. 用于目标检测的特征金字塔网络。发表于 *ICCV*, 第 2117–2125 页, 2017 年。2, 5, 6, 8, 12[25] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, Piotr Dollár. 用于密集目标检测的 Focal Loss. 发表于 *ICCV*, 第 2980–2988 页, 2017 年。2, 3, 5, 6, 8[26] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, C Lawrence Zitnick. Microsoft COCO: 上下文中的常见目标。发表于 *ECCV*, 第 740–755 页。Springer, 2014 年。2, 5, 6, 7, 8, 12[27] Shu Liu, Lu Qi, Haifang Qin, Jianping Shi, Jiaya Jia. 用于实例分割的路径聚合网络。发表于 *CVPR*, 第 8759–8768 页, 2018 年。2[28] Alejandro Newell, Zhiao Huang, Jia Deng. 关联嵌入: 用于联合检测与分组的端到端学习。发表于 *NIPS*, 第 2277–2287 页, 2017 年。2[29] Dim P Papadopoulos, Jasper RR Uijlings, Frank Keller, Vittorio Ferrari. 用于高效目标标注的极限点击。发表于 *ICCV*, 第 4930–4939 页, 2017 年。2[30] Pedro O Pinheiro, Ronan Collobert, Piotr Dollár. 学习分割候选目标。发表于 *NIPS*, 第 1990–1998 页, 2015 年。1[31] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi. 你只看一次: 统一的实时目标检测。发表于 *CVPR*, 第 779–788 页, 2016 年。4, 5, 6, 8[32] Joseph Redmon, Ali Farhadi. YOLOv3: 一种渐进式改进。 *arXiv preprint arXiv:1804.02767*, 2018 年。8[33] Shaoqing Ren, Kaiming He, Ross Girshick, Jian Sun. Faster R-CNN: 利用区域提议网络实现实时目标检测。发表于 *NIPS*, 第 91–99 页, 2015 年。1, 2, 3, 11[34] Karen Simonyan, Andrew Zisserman. 用于大规模图像识别的极深卷积网络。发表于 *ICLR*, 2015 年。2[35] Bharat Singh, Larry S Davis. 目标检测 SNIP 中尺度不变性的分析。发表于 *CVPR*, 第 3578–3587 页, 2018 年。

[36] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke 和 Andrew Rabinovich. 通过卷积网络走向更深层次。收录于*CVPR*, 第1–9页, 2015年。2[37] Alexander Toshev 和 Christian Szegedy. Deeppose: 通过深度神经网络进行人体姿态估计。收录于*CVPR*, 第1653–1660页, 2014年。1[38] Lachlan Tychsen-Smith 和 Lars Petersson. Denet: 通过定向稀疏采样实现可扩展的实时目标检测。收录于*ICCV*, 第428–436页, 2017年。2[39] Paul Viola, Michael Jones 等人。使用简单特征的增强级联进行快速目标检测。*CVPR*, 第1卷, 第511–518页, 2001年。2[40] Jiaqi Wang, Kai Chen, Shuo Yang, Chen Change Loy 和 Dahua Lin. 通过引导锚定进行区域提议。收录于*CVPR*, 2019年。2[41] Jiajun Wu, Erika Lu, Pushmeet Kohli, Bill Freeman 和 Josh Tenenbaum. 通过视觉解动画学习观察物理现象。收录于*NIPS*, 第153–164页, 2017年。1[42] Yuxin Wu 和 Kaiming He. 组归一化。收录于*ECCV*, 第3–19页, 2018年。6[43] Saining Xie, Ross Girshick, Piotr Dollár, Zhuowen Tu 和 Kaiming He. 用于深度神经网络的聚合残差变换。收录于*CVPR*, 第1492–1500页, 2017年。12[44] Hongyu Xu, Xutao Lv, Xiaoyu Wang, Zhou Ren, Navaneeth Bodla 和 Rama Chellappa. 用于目标检测的深度区域候选网络。收录于*ECCV*, 第798–814页, 2018年。8[45] Tong Yang, Xiangyu Zhang, Zeming Li, Wenqiang Zhang 和 Jian Sun. Metaanchor: 学习使用定制锚框检测目标。收录于*NeurIPS*, 第318–328页, 2018年。2[46] Shifeng Zhang, Longyin Wen, Xiao Bian, Zhen Lei 和 Stan Z Li. 用于目标检测的单次优化神经网络。收录于*CVPR*, 第4203–4212页, 2018年。8[47] Yuanyi Zhong, Jianfeng Wang, Jian Peng 和 Lei Zhang. 目标检测的锚框优化。*arXiv preprint arXiv:1812.00469*, 2018年。2[48] Xingyi Zhou, Jiacheng Zhuo 和 Philipp Krähenbühl. 通过分组极值点和中心点进行自底向上的目标检测。收录于*CVPR*, 2019年。2, 3, 8[49] Yanzhao Zhou, Qixiang Ye, Qiang Qiu 和 Jianbin Jiao. 定向响应网络。收录于*CVPR*, 第519–528页, 2017年。2[50] Chenchen Zhu, Yihui He 和 Marios Savvides. 用于单次目标检测的特征选择性无锚模块。收录于*CVPR*, 2019年。8

附录

A1. RepPoints与可变形RoI池化之间的关系

在本节中，我们将更详细地阐述我们的方法与可变形RoI池化[4]之间的差异。首先，我们描述目标检测流程中回归步骤对平移的敏感性。接着，我们讨论可变形RoI池化[4]的工作原理，并解释为何它无法像我们提出的RepPoints表示法那样提供物体的几何表征。

翻译敏感性 我们在边界框的背景下解释回归步骤的翻译敏感性。将回归前的矩形边界框提议表示为 $\mathcal{B}_P$ ，将真实边界框表示为 $\mathcal{B}_{GT}$ 。那么，边界框回归的目标可以表示为

$$T_P = \mathcal{F}(\mathcal{B}_P, \mathcal{B}_{GT}), \quad (7)$$

其中 $\mathcal{F}$ 是将 $\mathcal{B}_P$ 转换为 $\mathcal{B}_{GT}$ 的函数。这种转换通常被学习为一个回归函数 $\mathcal{R}_B$ ：

$$\mathcal{R}_B(\mathcal{P}_B(I, \mathcal{B}_P)) = T_P = \mathcal{F}(\mathcal{B}_P, \mathcal{B}_{GT}), \quad (8)$$

其中 I 是输入图像， $\mathcal{P}_B$ 是在矩形建议区域上定义的池化函数，例如直接裁剪图像 [11]、RoIPooling [33] 或 RoIAlign [13]。该公式旨在基于 $\mathcal{B}_P$ 区域内的特征预测相对于真实边界框的位移。 $\mathcal{B}_P$ 的变化应相应地改变目标：

$$\mathcal{R}_B(\mathcal{P}_B(I, \mathcal{B}_P + \Delta\mathcal{B})) = \mathcal{F}(\mathcal{B}_P + \Delta\mathcal{B}, \mathcal{B}_{GT}). \quad (9)$$

因此，池化特征 $\mathcal{P}_B(I, \mathcal{B}_P)$ 应对候选框 $\mathcal{B}_P$ 保持敏感。具体而言，对于任意一对候选框 $\mathcal{B}_1 \neq \mathcal{B}_2$ ，我们应满足 $\mathcal{P}_B(I, \mathcal{B}_1) \neq \mathcal{P}_B(I, \mathcal{B}_2)$ 。大多数现有特征提取器 $\mathcal{P}_B$ 均符合这一特性。值得注意的是，RoIAlign [13] 相较于 RoIPooling [33] 的改进，部分原因正在于这种有保证的平移敏感性。

可变形RoI池化分析。 对于可变形RoI池化[4]，系统通过在规则网格[13]上生成逐点形变，为每个候选区域生成一组采样点 S_P 。其公式可表述为

$$S_P = \mathcal{D}(I, \mathcal{B}_P), \quad (10)$$

其中 $\mathcal{D}$ 是生成采样点的函数。随后，边界框回归旨在学习一个回归函数 $\mathcal{R}_S$ ，该函数通过 S_P 利用采样特征来预测目标 T_P ，具体如下：

$$\mathcal{R}_S(\mathcal{P}_S(I, S_P)) = T_P = \mathcal{F}(\mathcal{B}_P, \mathcal{B}_{GT}) \quad (11)$$




图5. 如主论文第4节所述，可变形RoI池化[4]无法作为几何物体表征的示意图。我们考虑基于不同候选框的两种边界框回归。假设可变形RoI池化[4]能够学习到相似的几何物体表征，使得两组采样点位于目标物体的相似位置。要实现这一点，采样特征必须相似，从而导致两个候选框无法被区分。然而，可变形RoI池化[4]实际上能够区分相邻的物体候选框，由此产生矛盾。因此可得出结论：可变形RoI池化[4]无法学习物体的几何表征。




图6. 3×3 可变形RoI池化[4]学习到的采样点可视化。结果表明，采样点的尺度随提案框的尺度变化而改变，这表明采样点未能自适应地形成几何object表示。

其中 $\mathcal{P}_S$ 是关于样本点 S_P 的池化函数。

根据翻译敏感性特性，我们有 $\mathcal{P}_S(I, \mathcal{D}(I, \mathcal{B}_1)) \neq \mathcal{P}_S(I, \mathcal{D}(I, \mathcal{B}_2)), \forall \mathcal{B}_1 \neq \mathcal{B}_2$ 。由于池化特征 $\mathcal{P}_S(I, \mathcal{D}(I, \mathcal{B}))$ 由采样点 $\mathcal{D}(I, \mathcal{B})$ 的位置决定，因此我们得到 $\mathcal{D}(I, \mathcal{B}_1) \neq \mathcal{D}(I, \mathcal{B}_2), \forall \mathcal{B}_1 \neq \mathcal{B}_2$ 。这意味着对于同一物体的两个不同提议 $\mathcal{B}_1$ 和 $\mathcal{B}_2$ ，可变形RoI池化为这两个提议生成的采样点应当不同。因此，不同提议的采样点无法对应同一物体的几何结构。它们代表的是提议本身的属性，而非物体的几何特征。

图5展示了如果可变形RoI池化是物体几何形状的代表，将会产生的矛盾。

method	backbone	ms train	ms test	AP
RPDet	R-50			38.6
	R-50	✓		40.8
	R-50	✓	✓	42.2
	R-101			40.3
	R-101	✓		42.3
	R-101	✓	✓	44.1
	R-101-DCN			43.0
	R-101-DCN	✓		44.8
	R-101-DCN	✓	✓	46.4
	X-101-DCN			44.5
	X-101-DCN	✓		45.6
	X-101-DCN	✓	✓	46.8

表8. RPDet在MS-COCO [26]验证集（minival）上的基准测试结果。此处所有模型均采用FPN [24]在‘2x’设置[12]下训练。主干网络标注中，‘R-50’和‘R-101’分别表示ResNet-50和ResNet-101[15]。‘R-101-DCN’表示将所有卷积层替换为可变形卷积层[4]的ResNet-101。‘X’表示ResNeXt-101[43]主干网络。“ms”代表多尺度测试。

此外，图6表明，通过可变形RoI池化学习到的同一物体两个提议的采样点，这些采样点代表的是提议的属性，而非物体的几何结构。

RepPoints 与可变形RoI池化不同，后者池化后的特征代表原始边界框提议，而RepPoints提取的特征直接定位物体。由于不受平移敏感性要求的限制，当提供对应伪框的定位监督时（参见主论文图4），RepPoints能够学习到 $\{v^*\}$ 的几何表示。虽然物体定位监督未应用于可变形RoI池化的采样点，但我们在主论文表2中证明，这种监督对RepPoints至关重要。

值得注意的是，可变形RoI池化[4]被证明与RepPoints表示具有互补性（参见主论文表6），进一步表明它们具有不同的功能。

A2. RPDet的更多基准测试结果

我们在表8中展示了我们提出的检测器RPDet的更多基准测试结果。我们的PyTorch实现可在<https://github.com/microsoft/RepPoints>获取。所有模型均在MS-COCO [26]验证集（minival）上进行了测试。

Multi-scale training and test settings. 在多尺度训练中，每个小批次的图像短边会从[480, 960]范围内随机选取。在多尺度测试中——

首先，我们将每张图像的短边调整为{400, 600, 800, 1000, 1200, 1400}。接着，合并所有尺度下的检测结果（在非极大值抑制之前），最后通过一个非极大值抑制步骤生成最终的检测结果。