

尺度不变关键点中的独特图像特征

David G. Lowe 计算机
科学系 不列颠哥伦比亚大学
温哥华, B.C., 加拿大lowe
@cs.ubc.ca

2004年1月5日

摘要

本文提出了一种从图像中提取独特不变特征的方法, 该特征可用于在不同视角的对象或场景之间进行可靠匹配。这些特征对图像尺度和旋转具有不变性, 并能在较大范围的仿射畸变、三维视角变化、噪声干扰以及光照变化下实现稳健匹配。这些特征具有高度独特性, 单个特征能够以高概率正确匹配来自大量图像的特征数据库。本文还描述了利用这些特征进行物体识别的方法。识别过程首先通过快速最近邻算法将单个特征与已知物体的特征数据库进行匹配, 随后采用霍夫变换识别属于同一物体的特征簇, 最后通过最小二乘解算一致姿态参数进行验证。该识别方法能够在杂乱和遮挡环境中稳健地识别物体, 并实现近实时性能。

1 引言

图像匹配是计算机视觉中许多问题的基本方面，包括物体或场景识别、从多幅图像求解三维结构、立体对应以及运动跟踪。本文描述的图像特征具有多种特性，使其适用于匹配同一物体或场景的不同图像。这些特征对图像缩放和旋转具有不变性，对照明变化和三维摄像机视角变化具有部分不变性。它们在空间域和频域中都能被精确定位，降低了因遮挡、杂乱或噪声干扰的可能性。通过高效算法可从典型图像中提取大量特征。此外，这些特征具有高度独特性，使得单个特征能够以高概率正确匹配大型特征数据库，从而为物体和场景识别提供基础。

提取这些特征的成本通过采用级联过滤方法得以最小化，该方法中更昂贵的操作仅应用于通过初始测试的位置。以下是用于生成图像特征集的主要计算阶段：

1. 尺度空间极值检测：计算的第一阶段在所有尺度和图像位置进行搜索。通过使用高斯差分函数高效实现，以识别对尺度和方向不变的特征点。
2. 关键点定位：在每个候选位置，拟合一个详细模型以确定位置和尺度。关键点的选择基于其稳定性的度量。
3. 方向分配：基于局部图像梯度方向，为每个关键点位置分配一个或多个方向。所有后续操作均在相对于每个特征所分配的方向、尺度和位置进行变换后的图像数据上执行，从而确保对这些变换的不变性。
4. 关键点描述符：在选定尺度下，测量每个关键点周围区域的局部图像梯度。这些梯度被转换为一种能够显著容忍局部形状畸变和光照变化的表示形式。

该方法被命名为尺度不变特征变换（SIFT），因为它将图像数据转换为相对于局部特征的尺度不变坐标。

这种方法的一个重要方面是它能生成大量特征，这些特征在图像的所有尺度和位置上密集覆盖。一张典型的500x500像素图像会产生约2000个稳定特征（尽管具体数量取决于图像内容及各项参数的选择）。特征数量对于物体识别尤为重要——在杂乱背景中检测小物体时，每个物体至少需要正确匹配3个特征才能实现可靠识别。

对于图像匹配与识别，首先从一组参考图像中提取SIFT特征并存储于数据库中。新图像的匹配通过将其每个特征与此前数据库逐一对比，并基于特征向量的欧几里得距离寻找候选匹配特征来实现。本文将探讨能够针对大型数据库快速执行此计算的最近邻算法。

关键点描述符具有高度独特性，这使得单个特征能够在大型特征数据库中，以较高的概率找到其正确匹配。然而，在杂乱环境中

图像中，背景的许多特征在数据库中将没有任何正确匹配，除了正确的匹配外还会产生许多错误匹配。通过识别在新图像中关于物体及其位置、尺度和方向一致的关键点子集，可以从完整匹配集中筛选出正确匹配。多个特征在这些参数上偶然一致的概率远低于任何单个特征匹配出错的概率。通过使用广义霍夫变换的高效哈希表实现，可以快速确定这些一致的聚类。

对于每个包含3个或以上特征、且在物体及其姿态上达成一致的簇，会进行进一步的详细验证。首先，通过最小二乘法估算物体姿态的仿射近似值。接着，识别出与此姿态一致的其他图像特征，并剔除异常值。最后，根据拟合精度和可能误匹配的数量，详细计算特定特征集指示物体存在的概率。通过所有这些测试的物体匹配结果，可以高置信度地判定为正确。

2 相关研究

利用一组局部兴趣点进行图像匹配的发展可以追溯到Moravec（1981）使用角点检测器进行立体匹配的工作。Harris和Stephens（1988）改进了Moravec检测器，使其在微小图像变化和边缘附近更具可重复性。Harris还展示了其在高效运动跟踪和运动恢复三维结构中的价值（Harris, 1992），此后哈里斯角点检测器被广泛用于许多其他图像匹配任务。虽然这些特征检测器通常被称为角点检测器，但它们选择的不仅仅是角点，而是在预定尺度上所有方向都具有大梯度的任何图像位置。

最初的应用是针对立体视觉和短距离运动追踪，但该方法后来被扩展到更复杂的问题上。Zhang *et al.* (1995) 证明，通过在每个角点周围使用相关窗口来选择可能的匹配，可以在大范围的图像中匹配哈里斯角点。然后，通过求解描述刚性场景两个视图之间几何约束的基本矩阵，并移除与多数解不一致的匹配点，从而剔除异常值。与此同时，Torr（1995）为长距离运动匹配开发了类似的方法，其中利用几何约束来移除图像内刚性物体运动产生的异常值。

Schmid和Mohr（1997）的开创性工作表明，不变局部特征匹配可以扩展到一般图像识别问题中，即在一个大型图像数据库中匹配特征。他们同样采用Harris角点来选取兴趣点，但并未使用相关窗口进行匹配，而是采用了局部图像区域的旋转不变描述符。这使得特征能够在两幅图像之间发生任意方向变化时仍可匹配。此外，他们证明通过识别匹配特征的一致性聚类，多重特征匹配能够在遮挡和杂波干扰下实现通用识别。

Harris角点检测器对图像尺度的变化非常敏感，因此无法为匹配不同尺寸的图像提供良好基础。作者早期的工作（Lowe, 1999）扩展了局部特征方法以实现尺度不变性。该研究还描述了一种新的局部描述符，能在保持较低 $\{v^*\}$ 的同时提供更具区分性的特征。

对局部图像失真（如3D视角变化）敏感。本文在先前研究基础上进行了更深入的拓展与分析，同时提出了多项在稳定性和特征不变性方面的改进。

关于识别在尺度变化下保持稳定的表示方法，已有大量先前研究。该领域的早期工作之一是Crowley和Parker（1984）提出的，他们开发了一种能识别尺度空间中的峰值与脊线、并将其连接成树状结构的表示方法。这种树结构可在任意尺度变化的图像间进行匹配。Shokoufandeh、Marsic和Dickinson（1999）近期基于图匹配的研究，利用小波系数提供了更具区分度的特征描述符。Lindeberg（1993, 1994）则深入研究了为特征检测确定合适且一致尺度的问题，他将此称为尺度选择问题，下文我们将运用其研究成果。

近年来，在将局部特征扩展至完全仿射变换不变性方面涌现了大量令人瞩目的研究成果（Baumberg, 2000; Tuytelaars and Van Gool, 2000; Mikolajczyk and Schmid, 2002; Schaffalitzky and Zisserman, 2002; Brown and Lowe, 2002）。这类方法通过局部仿射框架对图像进行重采样，在多数情况下能够实现平面表面特征在正交三维投影变化下的不变匹配。然而，由于完整探索仿射空间的计算成本过高，这些方法均以非仿射不变的方式选择初始特征尺度与位置，因而尚未实现完全的仿射不变性。相较于尺度不变特征，仿射框架对噪声更为敏感，因此实践中除非平面倾斜角度超过约40度（Mikolajczyk, 2002），否则仿射特征的重复性往往低于尺度不变特征。对于许多应用场景而言，更广泛的仿射不变性可能并非必需——为捕捉三维物体的非平面形变与遮挡效应，最佳训练视角通常需至少每隔30度采集一次（这意味着识别视角与最近训练视角的偏差需控制在15度以内）。

尽管本文提出的方法并非完全仿射不变，但我们采用了一种不同的策略，使得局部描述子允许特征相对位置在描述子仅发生微小变化时产生显著偏移。这种方法不仅能让描述子在较大范围的仿射畸变下实现可靠匹配，还能使特征对非平面表面的三维视角变化更具鲁棒性。其他优势包括更高效的特征提取能力以及识别更多特征的可能性。另一方面，仿射不变性对于在极大视角变化下匹配平面表面具有重要价值，未来研究应进一步探索如何以高效稳定的方式，将这种特性与非平面的三维视角不变性相结合。

许多其他特征类型已被提议用于识别，其中一些可以结合本文所述的特征使用，以在不同情况下提供更多匹配。一类特征是利用图像轮廓或区域边界的特征，这应使它们不太可能被物体边界附近杂乱的背景干扰。Matas *et al.*, (2002) 已证明，他们的最大稳定极值区域能够产生大量具有良好稳定性的匹配特征。Mikolajczyk *et al.*, (2003) 开发了一种新的描述符，该描述符利用局部边缘同时忽略无关的邻近边缘，从而即使在叠加于杂乱背景上的狭窄形状边界附近也能找到稳定特征。Nelson 和 Selinger（1998）展示了基于图像轮廓分组的局部特征的良好效果。类似地，

Pope和Lowe（2000）采用了基于图像轮廓层次化分组的特征，这些特征对于缺乏细节纹理的物体尤为有用。

视觉识别研究的历史包含了多种其他图像属性的研究工作，这些属性可作为特征度量使用。Carneiro和Jepson（2002）描述了基于相位的局部特征，这类特征表示局部空间频率的相位而非幅度，可能提供更好的光照不变性。Schiele和Crowley（2000）提出了使用多维直方图来概括图像区域内测量值的分布。此类特征可能对识别具有可变形形状的纹理物体特别有用。Basri和Jacobs（1997）论证了提取局部区域边界对识别的价值。其他值得整合的有用属性包括颜色、运动、图-底区分、区域形状描述符以及立体深度线索。局部特征方法能轻松整合新型特征类型，因为当额外特征提供正确匹配时会增强鲁棒性，即使匹配失败，除了计算成本外几乎不会造成负面影响。因此，未来的系统很可能将融合多种特征类型。

3 尺度空间极值检测

如引言所述，我们将采用级联过滤方法检测关键点，该方法通过高效算法识别候选位置，随后进行更详细的检测。关键点检测的第一阶段是确定在不同视角下能够被稳定重复定位的位置与尺度。要检测对图像尺度变化具有不变性的位置，可通过尺度空间（Witkin, 1983）这一连续尺度函数，在所有可能的尺度中搜索稳定的特征来实现。

Koenderink（1984）和Lindeberg（1994）的研究表明，在多种合理的假设下，唯一可能的尺度空间核是高斯函数。因此，图像的尺度空间被定义为一个函数 $L(x, y, \sigma)$ ，它是由可变尺度的高斯函数 $G(x, y, \sigma)$ 与输入图像 $I(x, y)$ 进行卷积产生的：

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y),$$

其中 $*$ 是 x 和 y 中的卷积运算，且

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}.$$

为了在尺度空间中高效检测稳定的关键点位置，我们曾提出（Lowe, 1999）利用图像与高斯差分函数卷积后的尺度空间极值 $D(x, y, \sigma)$ ，该函数可通过两个相邻尺度（其间以恒定乘积因子 k 分隔）的差值计算得出：

$$\begin{aligned} D(x, y, \sigma) &= (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y) \\ &= L(x, y, k\sigma) - L(x, y, \sigma). \end{aligned} \quad (1)$$

选择此函数的原因有很多。首先，它是一个计算效率特别高的函数，因为平滑图像 L ，无论如何都需要为尺度空间特征描述而计算，因此 D 可以通过简单的图像相减来计算。




图1：对于尺度空间的每个八度，初始图像与高斯函数反复卷积，生成左侧所示的尺度空间图像集。相邻的高斯图像相减后，生成右侧的高斯差分图像。每个八度结束后，高斯图像会进行2倍降采样，并重复此过程。

此外，差分高斯函数为尺度归一化的拉普拉斯高斯函数 $\{v^*\}$ 提供了紧密的近似，正如Lindeberg（1994）所研究的那样。Lindeberg证明，拉普拉斯算子需通过因子 $\{v^*\}$ 进行归一化才能实现真正的尺度不变性。在详细的实验比较中，Mikolajczyk（2002）发现，相较于梯度、海森矩阵或哈里斯角点函数等一系列其他可能的图像函数， $\{v^*\}$ 的极大值和极小值能产生最稳定的图像特征。

D 与 $\sigma^2 \nabla^2 G$ 之间的关系可通过热扩散方程（以 σ 而非更常见的 $t = \sigma^2$ 为参数）来理解：

$$\frac{\partial G}{\partial \sigma} = \sigma \nabla^2 G.$$

由此，我们看到 $\nabla^2 G$ 可以通过对 $\partial G / \partial \sigma$ 的有限差分近似来计算，利用 $k\sigma$ 和 σ 处邻近尺度的差值：

$$\sigma \nabla^2 G = \frac{\partial G}{\partial \sigma} \approx \frac{G(x, y, k\sigma) - G(x, y, \sigma)}{k\sigma - \sigma}$$

因此，

$$G(x, y, k\sigma) - G(x, y, \sigma) \approx (k - 1)\sigma^2 \nabla^2 G.$$

这表明，当高斯差分函数的尺度相差一个常数因子时，它已经包含了尺度不变性所需的 σ^2 尺度归一化。




图2：高斯差分图像的最大值和最小值是通过将像素（标记为X）与其在当前尺度及相邻尺度下3x3区域中的26个邻域像素（标记为圆圈）进行比较来检测的。

拉普拉斯算子。方程中的因子 $(k - 1)$ 在所有尺度上都是常数，因此不影响极值位置。当 k 趋近于1时，近似误差将趋于零，但实际上我们发现即使尺度差异显著（例如 $k = \sqrt{2}$ ），这种近似对极值检测或定位的稳定性也几乎没有影响。

一种构建 $D(x, y, \sigma)$ 的高效方法如图1所示。初始图像与高斯函数进行增量卷积，以在尺度空间中生成间隔为恒定因子 k 的图像，如左列堆叠所示。我们选择将尺度空间的每个八度（即 σ 的翻倍）划分为整数个 s 区间，因此 $k = 2^{1/s}$ 。我们必须为每个八度生成 $s + 3$ 幅模糊图像堆栈，以确保最终的极值检测覆盖完整的八度。相邻尺度的图像相减后，得到右侧所示的高斯差分图像。当一个完整八度处理完毕后，我们对高斯图像进行重采样——该图像的 σ （初始值将加倍（即位于堆栈顶部向下第2幅图像））——方法是在每行和每列中隔一个像素取样。相对于 σ 的采样精度与前一八度起始时相同，而计算量则大幅减少。

3.1 局部极值检测

为了检测 $D(x, y, \sigma)$ 的局部极大值和极小值，每个采样点需与当前图像中的八个相邻点以及上下相邻尺度中的九个相邻点进行比较（见图2）。仅当该点大于所有这些相邻点或小于所有相邻点时，才会被选中。由于大多数采样点会在最初几次比较后被淘汰，这一检测过程的计算成本相对较低。

一个重要的问题是确定在图像和尺度域中采样的频率，以便可靠地检测极值点。不幸的是，事实证明，不存在能够检测所有极值点的最小采样间隔，因为极值点可以任意接近。这可以通过考虑黑色背景上的白色圆形来理解：当高斯差分函数的圆形正中心区域与圆的大小和位置匹配时，尺度空间中将存在一个最大值。对于一个非常细长的椭圆，其两端附近将出现两个最大值。由于最大值的位置是图像的连续函数，对于某些中等细长程度的椭圆，将会出现从一个最大值到两个最大值的过渡，且这两个最大值可以任意接近。




图3：第一张图表的顶线显示了在变换图像中，在相同位置和尺度上可重复检测到的关键点百分比，作为每八度音阶采样尺度数量的函数。底线显示了那些描述符能够与大型数据库正确匹配的关键点百分比。第二张图表展示了典型图像中检测到的关键点总数，作为尺度采样数量的函数。

在转变附近彼此接近。

因此，我们必须接受一种在效率与完整性之间权衡的解决方案。事实上，正如预期且经实验验证的那样，彼此接近的极值点对图像的微小扰动非常不稳定。我们可以通过研究一系列采样频率，并在匹配任务的实际模拟中使用那些能提供最可靠结果的频率，从而通过实验确定最佳选择。

3.2 尺度中的采样频率

最大化极值稳定性的采样频率实验测定结果如图3和图4所示。这些图表（及本文大多数其他仿真实验）基于一项匹配任务，该任务使用了32幅真实图像组成的多样化集合，涵盖户外场景、人脸、航拍图像和工业图像（研究发现图像域对结果几乎不产生影响）。每幅图像随后经过一系列变换处理，包括旋转、缩放、仿射拉伸、亮度与对比度调整以及图像噪声添加。由于这些变化是合成生成的，我们能够精确预测原始图像中每个特征在变换后图像中的应现位置，从而实现对每个特征正确重复率与位置精度的量化测量。

图3展示了这些模拟结果，用于研究在极值检测前对图像函数进行采样时，每八度音阶尺度数量变化的影响。在此情况下，每张图像先经过随机角度旋转和随机比例缩放（缩放比例在原始尺寸的0.2至0.9倍之间），随后进行重采样。将降分辨率图像中的关键点与原始图像中的关键点进行匹配，以确保所有关键点的尺度都能在匹配图像中体现。此外，还添加了1%的图像噪声，这意味着每个像素值在[0,1]范围内（相当于为图像像素提供略低于6位的精度）的基础上，叠加了来自均匀区间[-0.01,0.01]的随机数。




图4：图中顶线显示了在变换图像中可重复检测到的关键点位置百分比，作为每个八度第一层先验图像平滑度的函数。底线显示了与大型数据库正确匹配的描述符百分比。

图3第一张图中的顶线显示了在变换图像中，在匹配位置和尺度上检测到的关键点百分比。对于本文中的所有示例，我们将匹配尺度定义为在正确尺度的 $\sqrt{2}$ 倍以内，匹配位置定义为在 σ 像素以内，其中 σ 是关键点的尺度（根据公式(1)定义为高斯差分函数中使用的最小高斯的标准差）。该图中的底线显示了使用第6节将描述的最近邻匹配程序，与包含40,000个关键点的数据库正确匹配的关键点数量（这表明一旦关键点可重复定位，它很可能对识别和匹配任务有用）。如图所示，当每个八度采样3个尺度时，可获得最高的重复性，这也是本文所有其他实验所使用的尺度采样数量。

随着采样尺度的增加，可重复性并未持续提升，这或许令人惊讶。原因在于，这会导致检测到更多的局部极值点，但这些极值点的平均稳定性较低，因此在变换后的图像中被检测到的可能性较小。图3中的第二张图表展示了这一点，该图显示了每张图像中检测到并正确匹配的关键点的平均数量。随着尺度采样的增加，关键点数量上升，正确匹配的总数也随之增加。由于物体识别的成功往往更依赖于正确匹配关键点的数量，而非其正确匹配的百分比，因此在许多应用中，使用更多尺度采样样本将是最优选择。然而，计算成本也会随此数量增加，因此本文实验中，我们选择每八度仅使用3个尺度采样样本。

总而言之，这些实验表明，尺度空间的高斯差分函数 $\{v^*\}$ 存在大量极值点，检测所有极值点的计算成本极高。幸运的是，即使对尺度进行粗采样，我们也能检测到其中最稳定且最有用的子集。

3.3 空间域采样频率

正如我们确定了尺度空间每八度的采样频率一样，我们也必须确定图像域中相对于平滑尺度的采样频率。鉴于极值点可以任意接近，采样频率与检测率之间将存在类似的权衡。图4展示了在构建八度尺度空间表示之前，对每个图像层级应用的先验平滑量 σ 的实验测定结果。同样，顶线表示关键点检测的重复性，结果显示重复性随 σ 的增加而持续提升。然而，使用较大的 σ 会带来效率上的代价，因此我们选择使用 $\sigma = 1.6$ ，这提供了接近最优的重复性。该值在本文中全程使用，并已应用于图3的结果。

当然，如果在极值检测前对图像进行预平滑处理，我们实际上就丢弃了最高的空间频率。因此，为了充分利用输入信息，可以通过扩展图像来生成比原始图像更多的采样点。我们在构建金字塔第一层之前，使用线性插值将输入图像的尺寸扩大一倍。虽然通过在原始图像上使用亚像素偏移滤波器组也能实现等效操作，但图像加倍能带来更高效的实现。我们假设原始图像至少具有 $\sigma = 0.5$ 的模糊度（这是避免明显混叠所需的最小值），因此加倍后的图像相对于其新像素间距具有 $\sigma = 1.0$ 的模糊度。这意味着在创建尺度空间的第一阶八度前，几乎不需要额外的平滑处理。图像加倍使稳定关键点的数量增加近4倍，但采用更大的扩展系数并未带来显著改善。

4 精确关键点定位

一旦通过比较像素与其邻域找到关键点候选，下一步便是对附近数据进行详细拟合，以确定位置、尺度以及主曲率之比。这些信息可用于剔除低对比度（因而对噪声敏感）或边缘定位不佳的点。

该方法的最初实现（Lowe, 1999）仅将关键点定位在中心采样点的位置和尺度上。然而，Brown最近开发了一种方法（Brown and Lowe, 2002），通过对局部采样点拟合三维二次函数来确定最大值的插值位置，其实验表明这显著提升了匹配性能和稳定性。他的方法利用了尺度空间函数 $\{v^*\}$ 的泰勒展开（至二次项），并将原点平移至采样点：

$$D(\mathbf{x}) = D + \frac{\partial D}{\partial \mathbf{x}}^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T \frac{\partial^2 D}{\partial \mathbf{x}^2} \mathbf{x} \quad (2)$$

其中 D 及其导数在采样点处取值， $\mathbf{x} = (x, y, \sigma)^T$ 是该点的偏移量。极值点 $\hat{\mathbf{x}}$ 的位置通过对该函数关于 $\mathbf{x}$ 求导并令其为零来确定，从而得到

$$\hat{\mathbf{x}} = - \frac{\partial^2 D}{\partial \mathbf{x}^2}^{-1} \frac{\partial D}{\partial \mathbf{x}} \quad (3)$$




图5: 此图展示了关键点选择的各个阶段。(a) 233x189像素的原始图像。(b) 高斯差分函数极值处的832个初始关键点位置, 关键点以表示尺度、方向和位置的矢量形式显示。(c) 应用最小对比度阈值后, 剩余729个关键点。(d) 经过主曲率比值附加阈值处理后, 最终保留的536个关键点。

正如Brown所建议, 通过使用相邻采样点之间的差异来近似 D 的Hessian矩阵和导数。由此产生的 3×3 线性系统可以以最小成本求解。如果偏移量 $\hat{\mathbf{x}}$ 在任何维度上大于0.5, 则意味着极值点更接近另一个采样点。在这种情况下, 将更改采样点, 并围绕该点执行插值计算。最终偏移量 $\hat{\mathbf{x}}$ 会加到其采样点的位置上, 从而得到极值点位置的插值估计。

极值处的函数值 $\{v^*\}$ 可用于排除低对比度的不稳定极值。这可以通过将方程 (3) 代入 (2) 得到, 即

$$D(\hat{\mathbf{x}}) = D + \frac{1}{2} \frac{\partial D^T}{\partial \mathbf{x}} \hat{\mathbf{x}}.$$

在本文的实验中, 所有值小于0.03的极值点均被舍弃 (如前所述, 我们假设图像像素值范围在 $[0,1]$ 之间)。

图5展示了关键点选择对自然图像的影响。为避免画面过于杂乱, 此处采用低分辨率 (233×189像素) 图像, 并将关键点以矢量形式呈现, 每个矢量标明了关键点的位置、尺度和方向 (方向分配方法将在下文说明)。图5(a)为原始图像, 在后续子图中将以降低对比度的形式作为背景显示。图5(b)展示了所有检测到的极值点共832个关键点。

而高斯差分函数的极小值，同时(c)部分展示了在移除那些值小于0.03的 $|D(\mathbf{x})|$ 后保留的729个关键点。第(d)部分将在下一节中解释。

4.1 消除边缘响应

为了稳定性，仅拒绝低对比度的关键是远远不够的。高斯差分函数在边缘处会产生强烈响应，即使边缘上的位置难以精确定位，因而对少量噪声也不稳定。

高斯差分函数中定义不佳的峰值在边缘方向上会有较大的主曲率，而在垂直方向上则较小。主曲率可通过在关键点位置和尺度上计算的2x2 Hessian矩阵 $\mathbf{H}$ 得出：

$$\mathbf{H} = \begin{bmatrix} D_{xx} & D_{xy} \\ D_{xy} & D_{yy} \end{bmatrix} \quad (4)$$

导数通过取相邻样本点的差值来估计。

$\mathbf{H}$ 的特征值与 D 的主曲率成正比。借鉴Harris和Stephens（1988）使用的方法，我们可以避免显式计算特征值，因为我们只关心它们的比例。令 α 为幅值最大的特征值， β 为较小的特征值。那么，我们可以通过 $\mathbf{H}$ 的迹计算特征值之和，并通过其行列式计算特征值之积：

$$\begin{aligned} \text{Tr}(\mathbf{H}) &= D_{xx} + D_{yy} = \alpha + \beta, \\ \text{Det}(\mathbf{H}) &= D_{xx}D_{yy} - (D_{xy})^2 = \alpha\beta. \end{aligned}$$

如果行列式为负（这种情况不太可能发生），则曲率符号不同，因此该点被舍弃，不作为极值点。设 r 为最大特征值的绝对值与较小特征值的绝对值之比，使得 $\alpha = r\beta$ 。那么，

$$\frac{\text{Tr}(\mathbf{H})^2}{\text{Det}(\mathbf{H})} = \frac{(\alpha + \beta)^2}{\alpha\beta} = \frac{(r\beta + \beta)^2}{r\beta^2} = \frac{(r + 1)^2}{r},$$

它仅依赖于特征值的比例，而非各自的数值。当两个特征值相等时，量 $(r + 1)^2/r$ 达到最小值，并随 r 增大而增加。因此，要验证主曲率之比是否低于某个阈值 r ，我们只需检查

$$\frac{\text{Tr}(\mathbf{H})^2}{\text{Det}(\mathbf{H})} < \frac{(r + 1)^2}{r}.$$

计算这一步骤非常高效，测试每个关键点所需的浮点运算次数少于20次。本文实验采用 $r = 10$ 作为阈值，该设定会剔除主曲率比值大于10的关键点。从图5(c)到(d)的转换过程展示了此操作的效果。

5 方向分配

通过基于局部图像属性为每个关键点分配一致的方向，关键点描述符可以相对于此方向表示，从而实现图像旋转的不变性。这种方法与Schmid和Mohr（1997）的方向不变描述符形成对比，后者中每个图像属性都基于旋转不变的度量。该方法的缺点在于，它限制了可使用的描述符类型，并且由于不要求所有度量基于一致的旋转，从而丢弃了图像信息。

在尝试了多种分配局部方向的方法后，发现以下方法能产生最稳定的结果。关键点的尺度被用于选择高斯平滑图像 L ，该图像具有最接近的尺度，从而所有计算都以尺度不变的方式进行。对于该尺度下的每个图像样本 $L(x, y)$ ，使用像素差分预先计算梯度幅值 $m(x, y)$ 和方向 $\theta(x, y)$ ：

$$m(x, y) = \sqrt{(L(x+1, y) - L(x-1, y))^2 + (L(x, y+1) - L(x, y-1))^2}$$

$$\theta(x, y) = \tan^{-1}((L(x, y+1) - L(x, y-1)) / (L(x+1, y) - L(x-1, y)))$$

方向直方图由关键点周围区域内样本点的梯度方向构成。该方向直方图包含36个柱，覆盖360度的方向范围。添加到直方图中的每个样本都按其梯度幅值以及一个高斯加权圆形窗口进行加权，该窗口的 σ 是关键点尺度的1.5倍。

方向直方图中的峰值对应局部梯度的主导方向。检测直方图中的最高峰，然后使用任何其他位于最高峰80%范围内的局部峰值，以该方向创建另一个关键点。因此，对于具有多个相似幅值峰值的位置，将在相同位置和尺度但不同方向上创建多个关键点。大约只有15%的点被分配了多个方向，但这些点对匹配的稳定性有显著贡献。最后，对每个峰值最接近的3个直方图值拟合抛物线，以插值峰值位置，从而提高精度。

图6展示了在不同程度的图像噪声下，位置、尺度和方向分配的实验稳定性。与之前一样，图像被随机旋转和缩放。顶线显示了关键点位置和尺度分配的稳定性。第二线显示了当方向分配也要求在15度以内时的匹配稳定性。如顶两条线之间的间隙所示，即使在添加了 $\pm 10\%$ 像素噪声（相当于相机提供少于3位精度）后，方向分配仍保持95%的准确率。正确匹配的方向测量方差约为2.5度，在10%噪声下升至3.9度。图6的底线显示了将关键点描述符正确匹配到包含40,000个关键点的数据库的最终准确率（将在下文讨论）。如图所示，SIFT特征即使在大幅像素噪声下也表现出较强的鲁棒性，而误差的主要来源是初始位置和尺度检测。




图6: 图中顶线显示了关键点位置和尺度可重复检测的百分比与像素噪声的函数关系。第二条线显示了在同时要求方向一致后的可重复性。底线显示了最终正确匹配到大型数据库的描述符百分比。

6 局部图像描述符

之前的操作已经为每个关键点分配了图像位置、尺度和方向。这些参数建立了一个可重复的局部二维坐标系，用于描述局部图像区域，从而提供了对这些参数的不变性。下一步是计算局部图像区域的描述符，该描述符需具有高度区分性，同时尽可能对剩余的变化（如光照变化或三维视角变化）保持不变。

一种显而易见的方法是，在适当的尺度上对关键点周围的局部图像强度进行采样，并使用归一化相关度量进行匹配。然而，简单的图像块相关对于导致样本错配的变化（如仿射或三维视角变化或非刚性变形）极为敏感。Edelman、Intrator和Poggio（1997）展示了一种更好的方法。他们提出的表示基于生物视觉模型，特别是初级视觉皮层中的复杂神经元。这些复杂神经元对特定方向和空间频率的梯度作出响应，但梯度在视网膜上的位置允许在一个小的感受野内移动，而不是精确定位。Edelman *et al.* 假设这些复杂神经元的功能是允许从不同视角匹配和识别三维物体。他们使用物体和动物形状的三维计算机模型进行了详细实验，结果表明，在允许梯度位置移动的情况下进行匹配，能在三维旋转下实现更好的分类。例如，对于深度旋转20度的三维物体，识别准确率从梯度相关的35%提升到使用复杂细胞模型后的94%。我们下文描述的实现方法受此启发，但通过不同的计算机制允许位置移动。




图7：关键点描述符的生成首先通过在关键点位置周围的区域内计算每个图像采样点的梯度幅值和方向，如左图所示。这些值通过一个高斯窗口进行加权，如叠加的圆所示。随后，这些采样点被累积到方向直方图中，汇总了4x4子区域内的内容，如右图所示，每个箭头的长度对应于该区域内该方向附近梯度幅值的总和。此图展示了一个由8x8采样集计算得到的2x2描述符阵列，而本文实验使用的是由16x16采样阵列计算得到的4x4描述符。

6.1 描述符表示

图7展示了关键点描述符的计算过程。首先，在关键点位置周围采样图像梯度幅值和方向，并利用关键点的尺度选择图像的高斯模糊级别。为实现方向不变性，描述符的坐标和梯度方向会相对于关键点方向进行旋转。为提高效率，如第5节所述，梯度已在金字塔的所有层级上预先计算完成。这些梯度在图7左侧的每个采样点上用小箭头示意表示。

采用一个高斯加权函数，其 σ 等于描述符窗口宽度的一半，用于为每个采样点的幅值分配权重。图7左侧的圆形窗口展示了这一过程，尽管权重实际上是平滑衰减的。该高斯窗口的目的是避免描述符因窗口位置的微小变化而发生突变，并降低远离描述符中心的梯度权重，因为这些梯度最容易受到配准误差的影响。

关键点描述符如图7右侧所示。它通过在4x4采样区域上创建方向直方图，允许梯度位置发生显著偏移。图中每个方向直方图显示八个方向，箭头的长度对应直方图条目的幅值。左侧的梯度样本最多可偏移4个采样位置，同时仍对右侧同一直方图作出贡献，从而实现允许更大局部位置偏移的目标。

避免所有边界效应至关重要，即当样本从一个直方图平滑过渡到另一个，或从一个方向平滑过渡到另一个方向时，描述符不应发生突变。因此，采用三线性插值将每个梯度样本的值分配到相邻的直方图区间中。换言之，每个区间条目的计入值会乘以一个权重 $1 - d$ （针对每个维度），其中 d 表示样本与该区间中心值之间的距离，以直方图区间间距为单位度量。

描述符由一个包含所有方向直方图条目标值的向量构成，这些值对应图7右侧箭头的长度。图中展示的是 2×2 的方向直方图阵列，而我们后续实验表明，最佳结果是通过 4×4 的直方图阵列（每个直方图包含8个方向区间）实现的。因此，本文实验为每个关键点使用 $4 \times 4 \times 8 = 128$ 维特征向量。

最后，对特征向量进行修改以减少光照变化的影响。首先，将向量归一化为单位长度。图像对比度的变化（即每个像素值乘以一个常数）会使梯度乘以相同的常数，因此这种对比度变化将通过向量归一化被抵消。亮度变化（即在每个图像像素上添加一个常数）不会影响梯度值，因为梯度值是通过像素差异计算得出的。因此，该描述符对光照的仿射变化具有不变性。然而，非线性光照变化也可能发生，这可能是由于相机饱和，或是由于光照变化对不同方向的3D表面产生不同程度的影响。这些效应可能导致某些梯度的相对幅度发生较大变化，但不太可能影响梯度的方向。因此，我们通过将单位特征向量中的值阈值化（每个值不超过0.2），然后重新归一化为单位长度，来减小大幅值梯度的影响。这意味着大幅值梯度的匹配不再那么重要，而方向的分布则被赋予更大的权重。0.2这个值是通过包含相同3D物体在不同光照下的图像进行实验确定的。

6.2 描述符测试

描述符的复杂度可以通过两个参数进行调整：直方图中的方向数量 r ，以及方向直方图 $n \times n$ 数组的宽度 n 。生成的描述符向量大小为 rn^2 。随着描述符复杂度的增加，它能在大型数据库中实现更精准的区分，但同时也会对形状扭曲和遮挡更为敏感。

图8展示了改变方向数量和描述符大小的实验结果。该图表针对视角变换生成，其中平面表面相对于观察者倾斜50度，并添加了4%的图像噪声。这接近可靠匹配的极限，因为正是在这些更困难的情况下，描述符的性能最为关键。结果显示的是在包含40,000个关键点的数据库中，找到与最近邻正确匹配的关键点百分比。图表表明，单一方向直方图（ $n = 1$ ）的区分能力非常差，但结果持续改善直至使用8个方向的 4×4 直方图阵列。此后，增加更多方向或使用更大的描述符实际上可能损害匹配效果，因为描述符对失真更加敏感。这些结果在其他程度的视角变化和噪声条件下大致相似，尽管在某些较简单的情况下，使用 5×5 及更大尺寸的描述符（在已经较高的水平上）区分能力持续提升。在本文中，我们使用具有8个方向的 4×4 描述符，从而生成128维的特征向量。虽然描述符的维度可能显得较高，但我们发现，在一系列匹配任务中，其性能始终优于低维描述符，并且在使用下文所述的近似最近邻方法时，匹配的计算成本仍然很低。




图8: 该图表展示了关键点与包含40,000个关键点的数据库正确匹配的百分比, 该百分比随 $n \times n$ 关键点描述符的宽度以及每个直方图中方向数量的变化而变化。此图表基于图像在50度仿射视角变化并添加4%噪声的条件下计算得出。

6.3 对仿射变换的敏感性

描述符对仿射变化的敏感性在图9中进行了检验。该图显示了关键点位置与尺度选择、方向分配以及与数据库的最近邻匹配的可靠性, 这些均随平面相对于观察者的深度旋转而变化。可以看出, 随着仿射变形的增加, 计算的每个阶段的可重复性都有所降低, 但即使在视角变化达到50度时, 最终匹配的准确率仍保持在50%以上。

为了在更广的视角范围内实现可靠的匹配, 可以采用一种仿射不变性检测器来选择和重采样图像区域, 如第2节所述。如前文所提, 这些方法均非真正的仿射不变方法, 因为它们都始于以非仿射不变方式确定的初始特征位置。在目前最具仿射不变性的方法中, Mikolajczyk (2002) 提出并利用Harris-仿射检测器进行了详细实验。他发现, 在视角角度约50度以内时, 其关键点重复性低于本文方法, 但在视角达到70度时仍能保持接近40%的重复性, 这为极端仿射变换提供了更好的性能。其缺点在于计算成本显著更高、关键点数量减少, 以及因噪声下难以分配一致的仿射框架而导致对小范围仿射变化的稳定性较差。实际上, 三维物体允许的旋转范围远小于平面表面, 因此仿射不变性通常不是跨视角匹配能力的主要限制因素。若需要广泛的仿射不变性 (例如已知表面为平面的情况), 可采用Pritchard和Heidrich (2003) 的简易方案: 通过生成训练图像的4个仿射变换版本 (对应60度视角变化) 来创建额外的SIFT特征。这样在识别待处理图像时, 可使用标准SIFT特征且无需额外成本, 但会导致特征数据库的规模扩大至原来的3倍。




图9: 该图展示了关键点位置、方向以及与数据库最终匹配的检测稳定性随仿射失真变化的情况。仿射失真程度通过平面表面在深度方向上的等效视角旋转来表示。

6.4 与大型数据库匹配

衡量特征独特性时，一个重要的遗留问题是匹配可靠性如何随数据库中待匹配特征数量的变化而变化。本文大多数示例基于包含32张图像、约4万个关键点的数据库生成。图10展示了匹配可靠性如何随数据库规模变化。该图表通过扩展数据库（112张图像）生成，除常规随机图像旋转与尺度变化外，还包含30度视角深度旋转及2%的图像噪声。

虚线显示了图像特征中最近邻匹配正确的部分，其随数据库大小的变化以对数尺度呈现。最左侧的点表示仅与单张图像的特征进行匹配，而最右侧的点表示从包含112张图像全部特征的数据库中选取匹配。可以看出，匹配可靠性确实会随着干扰项数量的增加而下降，但所有迹象表明，即使数据库规模极大，仍能持续找到大量正确匹配。

实线表示在变换后的图像中，在正确匹配位置和方向上被识别的关键点百分比，因此只有这些点才有可能在数据库中找到匹配的描述符。这条线之所以平坦，是因为测试针对每个值都在完整数据库上运行，而仅改变用于干扰项的数据库部分。值得注意的是，两条线之间的差距很小，这表明匹配失败更多是由于初始特征定位和方向分配的问题，而非特征独特性不足所致，即使在大规模数据库中也如此。




图10：虚线显示了关键点与数据库正确匹配的百分比随数据库大小（使用对数刻度）的变化关系。实线则显示了被分配正确位置、尺度和方向的关键点百分比。图像在匹配前添加了随机尺度和旋转变换、30度的仿射变换以及2%的图像噪声。

7 应用于物体识别

本文的主要议题是推导如上所述的独特不变关键点。为展示其应用，我们将简要描述其在存在杂乱和遮挡情况下用于物体识别的方法。关于这些特征在识别中应用的更多细节，可参阅其他论文（Lowe, 1999; Lowe, 2001; Se, Lowe and Little, 2002）。

物体识别首先通过将每个关键点独立地与从训练图像中提取的关键点数据库进行匹配来完成。由于模糊特征或背景杂波产生的特征，许多初始匹配将是错误的。因此，首先识别出至少3个特征组成的簇，这些簇在物体及其姿态上达成一致，因为这些簇比单个特征匹配具有更高的正确概率。接着，通过执行与模型的详细几何拟合来检查每个簇，并根据结果接受或拒绝该解释。

7.1 关键点匹配

每个 keypoints 的最佳候选匹配是通过在训练图像的关键点数据库中识别其最近邻来找到的。最近邻被定义为具有最小欧几里得距离的不变描述符向量所对应的关键点，如第6节所述。

然而，图像中的许多特征在训练数据库中不会有任何正确匹配，因为它们来自背景杂波或在训练图像中未被检测到。因此，需要一种方法来丢弃那些在数据库中没有良好匹配的特征。对最近邻特征距离设置全局阈值效果不佳，因为某些描述符比其他描述符更具区分性。一种更有效的度量方法是通过比较最近邻的距离与 $\{v^*\}$ 的距离来获得。




图11：匹配正确的概率可以通过计算最近邻距离与次近邻距离的比值来确定。使用包含40,000个关键点的数据集时，实线表示正确匹配的比值概率密度函数，而虚线表示错误匹配的情况。

第二近邻。如果同一物体有多个训练图像，那么我们将第二近邻定义为已知与第一近邻来自不同物体的最近邻，例如仅使用已知包含不同物体的图像。这种度量方法表现良好，因为正确匹配需要其最近邻明显比最近的不正确匹配更接近，才能实现可靠匹配。对于错误匹配，由于特征空间的高维度，很可能在相似距离内存在许多其他错误匹配。我们可以将第二近邻匹配视为对此部分特征空间内错误匹配密度的估计，同时识别特征模糊的具体实例。

图11展示了该度量在真实图像数据上的取值。正确匹配与错误匹配的概率密度函数以每个关键点最近邻与次近邻的比值表示。最近邻为正确匹配的对应点，其概率密度函数集中在比错误匹配低得多的比值处。在我们的物体识别实现中，我们拒绝所有距离比值大于0.8的匹配，此举可消除90%的错误匹配，同时仅舍弃不足5%的正确匹配。本图通过将图像在随机尺度与方向变化、30度深度旋转及添加2%图像噪声后，与包含40,000个关键点的数据集进行匹配而生成。

7.2 高效最近邻索引

目前尚无已知算法能够以比穷举搜索更高效的方式识别高维空间中点的确切最近邻。我们的关键点描述符具有128维特征向量，而最佳算法（如k-d树（Friedman *et al.*, 1977））在超过约10维的空间中无法提供比穷举搜索更快的速度。因此，我们采用了一种近似算法，称为最佳优先分箱（BBF）算法（Beis和Lowe, 1997）。该算法的近似性在于它返回的是最接近的

高概率的邻居。

BBF算法对k-d树算法采用了改进的搜索顺序，使得特征空间中的区间按照与查询位置的最小距离顺序进行搜索。这种优先级搜索顺序最早由Arya和Mount（1993年）提出，并在（Arya *et al.*, 1998年）中对其计算特性进行了进一步研究。该搜索顺序需要使用基于堆的优先级队列来高效确定搜索顺序。通过限制在探索特定数量的最近区间后停止进一步搜索，可以以较低成本返回近似答案。在我们的实现中，我们在检查前200个最近邻候选点后停止搜索。对于包含10万个关键点的数据集，这比精确最近邻搜索提高了约两个数量级的速度，同时正确匹配数量损失不到5%。BBF算法在此问题上表现优异的一个原因是，我们仅考虑最近邻距离小于次近邻距离0.8倍的匹配（如前一节所述），因此无需精确求解那些多个邻域距离极其接近的最困难情况。

7.3 使用霍夫变换进行聚类

为了最大化小型或高度遮挡物体的识别性能，我们希望以尽可能少的特征匹配数量来识别物体。我们发现，仅需3个特征即可实现可靠的识别。典型图像包含2000个或更多特征，这些特征可能来自许多不同物体以及背景杂波。虽然第7.1节中描述的距离比测试可以让我们丢弃许多由背景杂波产生的错误匹配，但这无法消除来自其他有效物体的匹配，我们通常仍需要从99%离群点中识别出包含不足1%内点的正确匹配子集。当内点比例远低于50%时，许多著名的鲁棒拟合方法（如RANSAC或最小中值平方法）表现不佳。幸运的是，通过使用霍夫变换在姿态空间中对特征进行聚类（Hough, 1962; Ballard, 1981; Grimson 1990），可以获得更好的性能。

霍夫变换通过让每个特征对所有与其一致的对象姿态进行投票，来识别具有一致解释的特征簇。当发现特征簇对同一对象姿态投票时，该解释正确的概率远高于任何单一特征。我们的每个关键点指定了4个参数：二维位置、尺度和方向，而数据库中每个匹配的关键点都记录了该关键点相对于其所在训练图像的参数。因此，我们可以根据匹配假设创建一个霍夫变换条目，预测模型的位置、方向和尺度。由于这4个参数隐含的相似变换仅是三维物体完整6自由度姿态空间的近似，且未考虑任何非刚性形变，该预测具有较大的误差范围。因此，我们使用30度的宽方向区间、2倍的尺度因子，以及0.25倍的最大投影训练图像尺寸（使用预测尺度）作为位置区间。为避免区间分配中的边界效应问题，每个关键点匹配在每个维度上为最近的2个区间投票，从而每个假设产生16个条目，进一步拓宽了姿态范围。

在大多数霍夫变换的实现中，会使用多维数组来表示区间。然而，许多潜在的区间将保持为空，并且由于它们之间的相互依赖关系（例如，

位置离散化对所选尺度的依赖性)。通过使用箱值的伪随机哈希函数将投票插入一维哈希表,可以避免这些问题,在该表中碰撞很容易被检测到。

7.4 仿射参数求解

霍夫变换用于识别每个区间内至少包含3个条目的所有聚类。随后,每个此类聚类需经过几何验证流程,通过最小二乘法求解最佳仿射投影参数,以建立训练图像与新图像之间的映射关系。

仿射变换能够正确解释正交投影下平面表面的三维旋转,但对于非平面物体的三维旋转,其近似效果可能较差。更通用的解决方案是求解基本矩阵(Luong和Faugeras, 1996; Hartley和Zisserman, 2000)。然而,基本矩阵求解至少需要7个匹配点,而仿射解仅需3个,且在实际中需要更多匹配点以保证良好稳定性。我们希望仅用3个特征匹配点就能进行识别,因此仿射解提供了更好的起点,并且可以通过允许较大的残差来补偿仿射近似中的误差。假设围绕物体放置一个球体,那么球体旋转30度时,球内任意点的移动距离不会超过球体投影直径的0.25倍。对于本文使用的典型三维物体示例,在允许残差达到物体最大投影尺寸0.25倍的情况下,仿射解能够取得良好效果。(Brown和Lowe, 2002)提出了更通用的方法:初始解基于相似变换,当匹配点数量充足时,该方法会进一步求解基本矩阵。

模型点 $[x \ y]^T$ 到图像点 $[u \ v]^T$ 的仿射变换可表示为
作为

$$\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} m_1 & m_2 \\ m_3 & m_4 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix}$$

其中模型变换为 $[t_x \ t_y]^T$, 仿射旋转、缩放和拉伸由 m_i 参数表示。

我们希望求解变换参数,因此上述方程可以改写,将未知数收集到列向量中:

$$\begin{bmatrix} x & y & 0 & 0 & 1 & 0 \\ 0 & 0 & x & y & 0 & 1 \\ & & \cdots & & & \\ & & \cdots & & & \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ m_3 \\ m_4 \\ t_x \\ t_y \end{bmatrix} = \begin{bmatrix} u \\ v \\ \vdots \end{bmatrix}$$

该方程展示了一个单一匹配,但可以添加任意数量的进一步匹配,每个匹配都会为第一个和最后一个矩阵增加两行。至少需要3个匹配才能提供一个解。

我们可以将这个线性系统写作

$$\mathbf{Ax} = \mathbf{b}$$



图12：左侧展示了两个物体的训练图像。这些物体可在中间所示、存在大量遮挡的杂乱图像中被识别。识别结果如右侧所示。每个被识别物体周围绘制了一个平行四边形，显示了在识别过程中求解出的仿射变换下原始训练图像的边界。较小的方块表示用于识别的关键点。

参数 $\mathbf{x}$ 的最小二乘解可以通过求解相应的正规方程来确定，

$$\mathbf{x} = [\mathbf{A}^T \mathbf{A}]^{-1} \mathbf{A}^T \mathbf{b},$$

它最小化了从投影模型位置到对应图像位置距离的平方和。这种最小二乘法可以轻松扩展到求解铰接和柔性物体的三维姿态及内部参数（Lowe, 1991）。

现在可以通过检查每个图像特征与模型之间的一致性来剔除异常值。由于获得了更精确的最小二乘解，我们现在要求每个匹配的误差范围不超过霍夫变换箱中参数所用误差范围的一半。如果剔除异常值后剩余点数少于3个，则拒绝该匹配。在剔除异常值的同时，会使用剩余点重新求解最小二乘解，并迭代此过程。此外，采用自上而下的匹配阶段来添加与投影模型位置一致的其他匹配。这些匹配可能由于相似变换近似或其他误差而在霍夫变换箱中被遗漏。

接受或拒绝模型假设的最终决定基于先前论文（Lowe, 2001）中给出的详细概率模型。该方法首先根据模型的投影尺寸、区域内特征数量以及拟合精度，计算与模型姿态匹配的预期误匹配数量。随后，通过贝叶斯分析，根据实际找到的匹配特征数量得出目标存在的概率。若正确解释的最终概率大于0.98，我们便接受该模型。对于投影到图像小区域的物体，仅需3个特征即可实现可靠识别；而对于覆盖大部分高纹理图像的大型物体，预期误匹配数量较高，可能需要多达10个特征匹配才能确保准确性。

8 识别示例

图12展示了一个包含3D物体的杂乱且被遮挡图像的物体识别示例。左侧展示了玩具火车和青蛙的训练图像。




图13：此示例展示了复杂场景中的位置识别。训练位置图像显示在左上角，而从不同视角拍摄的640x315像素测试图像位于右上角。识别出的区域显示在下方的图像中，关键点以正方形标示，外部平行四边形显示了用于识别的仿射变换下训练图像的边界。

中间图像（尺寸为600x480像素）包含了这些物体的实例，它们被其他物体遮挡，并且背景杂乱无章，因此即使对于人类视觉来说，检测这些物体也可能不是立即就能完成的。右侧的图像显示了最终的正确识别结果，叠加在降低对比度的图像版本上。用于识别的关键点显示为带有额外线条指示方向的正方形。正方形的大小对应于用于构建描述符的图像区域。每个识别实例周围还绘制了一个外接平行四边形，其边对应于训练图像在识别过程中确定的最终仿射变换下投影的边界。

该方法的另一个潜在应用是地点识别，移动设备或车辆可通过识别熟悉的地点来确定自身位置。图13展示了此类应用的示例，其中训练图像采集自多个地点。如左上角所示，这些图像甚至可以拍摄看似无显著特征的物体，例如木墙或带有垃圾桶的树木。右上角的测试图像（尺寸为640x315像素）拍摄视角相对于原始位置绕场景旋转了约30度，但训练图像中的地点仍能被轻松识别。

识别过程的所有步骤都可以高效实现，因此在2GHz奔腾4处理器上，识别图12或图13中所有物体的总时间不到0.3秒。我们已在配备摄像头的笔记本电脑上实现了这些算法，并在各种条件下进行了广泛测试。总体而言，在任意方向深度旋转不超过50度、且光照条件能提供充足光线且不产生过度眩光的情况下，纹理平面表面可以被可靠识别。对于三维物体，可靠识别的深度旋转范围在任意方向仅约30度，且光照变化的影响更为显著。因此，三维物体识别最好通过整合多视角特征来实现，例如采用局部特征视图聚类方法（Lowe, 2001）。

这些关键点也被应用于机器人定位与地图构建问题，该问题已在其他论文中详细阐述（Se, Lowe and Little, 2001）。在此应用中，采用三目立体视觉系统来确定关键点位置的三维估计值。仅当关键点出现在所有三幅图像中且视差一致时才会被使用，从而极大减少了异常值。随着机器人移动，它通过特征匹配与现有三维地图进行自身定位，随后利用卡尔曼滤波器更新三维位置，逐步向地图中添加特征。这为机器人在未知环境中的定位问题提供了稳健而精确的解决方案。此项研究还解决了地点识别问题，即机器人可在任意位置启动并识别其在大规模地图中的方位（Se, Lowe and Little, 2002），这实质上等同于物体识别的三维实现。

9 结论

本文描述的SIFT关键点因其独特性而尤为有用，这种特性使得能够从包含大量其他关键点的数据库中准确选出匹配项。这种独特性是通过构建一个高维向量来实现的，该向量代表了图像局部区域内的梯度信息。这些关键点已被证明对图像旋转和缩放具有不变性，并且能在较大范围的仿射畸变、噪声添加以及光照变化下保持鲁棒性。从典型图像中可以提取出大量关键点，这增强了在杂乱背景中提取小目标物体的鲁棒性。关键点在完整尺度范围内被检测的特性，意味着可用于匹配小型且高度遮挡物体的局部细微特征，而大型关键点则在处理受噪声和模糊影响的图像时表现优异。其计算效率高，在标准PC硬件上能以近实时性能从典型图像中提取数千个关键点。

本文还介绍了利用关键点进行物体识别的方法。我们描述的方法采用近似最近邻查找、用于识别物体姿态一致簇的霍夫变换、最小二乘姿态确定以及最终验证。其他潜在应用包括用于三维重建的视图匹配、运动跟踪与分割、机器人定位、图像全景拼接、极线校准，以及任何需要在图像间识别匹配位置的应用。

在推导不变且独特的图像特征方面，还有许多进一步研究的方向。需要在具有完整三维视角和光照变化的数据集上进行系统测试。本文描述的特征仅使用单色强度图像，因此通过纳入光照不变的颜色描述符，可以进一步提升特征的独特性。

(Funt and Finlayson, 1995; Brown and Lowe, 2002)。类似地，局部纹理度量似乎在人类视觉中扮演着重要角色，并且可以以比当前描述符所使用的单一空间频率更一般的形式融入特征描述符中。基于不变局部特征的匹配方法的一个吸引人之处在于，无需仅选择一种特征类型，而通过使用多种不同的特征——所有这些特征都能提供有效的匹配并提升整体鲁棒性——很可能获得最佳结果。

未来研究的另一个方向将是单独学习适合识别特定物体类别的特征。这对于必须涵盖广泛可能外观的通用物体类别尤为重要。Weber、Welling和Perona（2000年）以及Fergus、Perona和Zisserman（2003年）的研究通过训练适用于识别通用物体类别的小型局部特征集，展示了这种方法的潜力。从长远来看，特征集可能同时包含先验特征和习得特征，这些特征将根据针对不同物体类别可用的训练数据量来使用。

致谢

我特别要感谢Matthew Brown，他对本文的内容和呈现方式提出了许多改进建议，并且他在特征定位和不变性方面的研究对这一方法有所贡献。此外，我还要感谢许多其他人提供的宝贵建议，包括Stephen Se、Jim Little、Krystian Mikolajczyk、Cordelia Schmid、Tony Lindeberg和Andrew Zisserman。这项研究得到了加拿大自然科学与工程研究委员会（NSERC）以及卓越中心网络机器人学与智能系统研究所（IRIS）的支持。

参考文献

Arya, S., 和 Mount, D.M. 1993. 固定维度中的近似最近邻查询。载于第四届ACM-SIAM离散算法年会（SODA'93），第271-280页。 Arya, S., Mount, D.M., Netanyahu, N.S., Silverman, R., 和 Wu, A.Y. 1998. 近似最近邻搜索的最优算法。ACM期刊，45:891-923。 Ballard, D.H. 1981. 推广霍夫变换以检测任意模式。模式识别，13(2):111-122。 Basri, R., 和 Jacobs, D.W. 1997. 使用区域对应的识别。国际计算机视觉期刊，25(2):145-166。 Baumberg, A. 2000. 在广泛分离的视图间进行可靠的特征匹配。载于计算机视觉与模式识别会议，南卡罗来纳州希尔顿黑德岛，第774-781页。 Beis, J. 和 Lowe, D.G. 1997. 在高维空间中使用近似最近邻搜索进行形状索引。载于计算机视觉与模式识别会议，波多黎各，第1000-1006页。 Brown, M. 和 Lowe, D.G. 2002. 来自兴趣点群的不变特征。载于英国机器视觉会议，威尔士卡迪夫，第656-665页。 Carneiro, G., 和 Jepson, A.D. 2002. 基于相位的局部特征。载于欧洲计算机视觉会议（ECCV），丹麦哥本哈根，第282-296页。 Crowley, J. L. 和 Parker, A.C. 1984. 一种基于低通变换差分中的峰与脊的形状表示。IEEE模式分析与机器智能汇刊，6(2):156-170。

Edelman, S., Intrator, N. and Poggio, T. 1997. 复杂细胞与物体识别。未发表手稿: http://kybele.psych.cornell.edu/{v*}edelman/archive.html

Fergus, R., Perona, P., and Zisserman, A. 2003. 通过无监督尺度不变学习进行物体类别识别。载于IEEE计算机视觉与模式识别会议, 麦迪逊, 威斯康星州, 第264-271页。

Friedman, J.H., Bentley, J.L. and Finkel, R.A. 1977. 一种在对数期望时间内寻找最佳匹配的算法。ACM数学软件汇刊, 3(3):209-226。

Funt, B.V. and Finlayson, G.D. 1995. 颜色恒常的颜色索引。IEEE模式分析与机器智能汇刊, 17(5):522-529。

Grimson, E. 1990. 计算机物体识别: 几何约束的作用, 麻省理工学院出版社: 剑桥, 马萨诸塞州。

Harris, C. 1992. 来自视觉运动的几何。载于主动视觉, A. Blake 和 A. Yuille (编), 麻省理工学院出版社, 第263-284页。

Harris, C. and Stephens, M. 1988. 一种组合的角点与边缘检测器。载于第四届阿尔维视觉会议, 曼彻斯特, 英国, 第147-151页。

Hartley, R. and Zisserman, A. 2000. 计算机视觉中的多视图几何, 剑桥大学出版社: 剑桥, 英国。

Hough, P.V.C. 1962. 识别复杂模式的方法与装置。美国专利 3069654。

Koenderink, J.J. 1984. 图像的结构。生物控制论, 50:363-396。

Lindeberg, T. 1993. 用尺度空间原始草图检测显著的类斑点图像结构及其尺度: 一种注意力聚焦方法。国际计算机视觉杂志, 11(3):283-318。

Lindeberg, T. 1994. 尺度空间理论: 分析不同尺度结构的基本工具。应用统计学杂志, 21(2):224-270。

Lowe, D.G. 1991. 将参数化三维模型拟合到图像。IEEE模式分析与机器智能汇刊, 13(5):441-450。

Lowe, D.G. 1999. 基于局部尺度不变特征的物体识别。载于国际计算机视觉会议, 科孚岛, 希腊, 第1150-1157页。

Lowe, D.G. 2001. 用于三维物体识别的局部特征视图聚类。IEEE计算机视觉与模式识别会议, 考艾岛, 夏威夷, 第682-688页。

Luong, Q.T., and Faugeras, O.D. 1996. 基础矩阵: 理论、算法与稳定性分析。国际计算机视觉杂志, 17(1):43-76。

Matas, J., Chum, O., Urban, M., and Pajdla, T. 2002. 基于最大稳定极值区域的鲁棒宽基线立体视觉。载于英国机器视觉会议, 加的夫, 威尔士, 第384-393页。

Mikolajczyk, K. 2002. 仿射变换不变的局部特征检测, 博士论文, 法国格勒诺布尔国立理工学院。

Mikolajczyk, K., and Schmid, C. 2002. 一种仿射不变的兴趣点检测器。载于欧洲计算机视觉会议(ECCV), 哥本哈根, 丹麦, 第128-142页。

Mikolajczyk, K., Zisserman, A., and Schmid, C. 2003. 基于边缘特征的形状识别。载于英国机器视觉会议论文集, 诺里奇, 英国。

Moravec, H. 1981. 漫游车视觉避障。载于国际人工智能联合会议, 温哥华, 加拿大, 第785-790页。

Nelson, R.C., and Selinger, A. 1998. 基于关键外观的三维物体识别系统的大规模测试。视觉研究, 38(15):2469-88。

Pope, A.R., and Lowe, D.G. 2000. 用于三维物体识别的外观概率模型。国际计算机视觉杂志, 40(2):149-167。

Pritchard, D., 与 Heidrich, W. 2003. 布料运动捕捉。ComputerGraphicsForum (欧洲图形学 2003), 22(3):263-271。

Schaffalitzky, F., 与 Zisserman, A. 2002. 无序图像集的多视图匹配, 或“如何整理我的假日快照?” 载于欧洲计算机视觉会议, 哥本哈根, 丹麦, 第414-431页。

Schiele, B., 与 Crowley, J.L. 2000. 使用多维感受野直方图的无对应关系识别。InternationalJournalofComputerVision, 36(1):31-50。

Schmid, C., 与 Mohr, R. 1997. 用于图像检索的局部灰度值不变量。IEEETrans.onPattern AnalysisandMachineIntelligence, 19(5):530-534。

Se, S., Lowe, D.G., 与 Little, J. 2001. 基于视觉的移动机器人定位与建图: 使用尺度不变特征。载于国际机器人与自动化会议, 首尔, 韩国, 第2051-58页。

Se, S., Lowe, D.G., 与 Little, J. 2002. 使用显著视觉特征的全局定位。载于国际智能机器人与系统会议, IROS 2002, 洛桑, 瑞士, 第226-231页。

Shokoufandeh, A., Marsic, I., 与 Dickinson, S.J. 1999. 使用显著图进行基于视图的物体识别。ImageandVisionComputing, 17:445-460。

Torr, P. 1995. 运动分割与异常值检测, 博士论文, 工程科学系, 牛津大学, 英国。

Tuytelaars, T., 与 Van Gool, L. 2000. 基于局部仿射不变区域的宽基线立体视觉。载于英国机器视觉会议, 布里斯托尔, 英国, 第412-422页。

Weber, M., Welling, M. 与 Perona, P. 2000. 识别模型的非监督学习。载于欧洲计算机视觉会议, 都柏林, 爱尔兰, 第18-32页。

Witkin, A.P. 1983. 尺度空间滤波。载于国际人工智能联合会议, 卡尔斯鲁厄, 德国, 第1019-1022页。

Zhang, Z., Deriche, R., Faugeras, O., 与 Luong, Q.T. 1995. 一种通过恢复未知极线几何来匹配两幅未标定图像的鲁棒技术。ArtificialIntelligence, 78:87-119。