

使用简单特征的增强级联进行快速目标检测

保罗·维奥拉

viola@merl.com

三菱电机研究实验室

百老汇大街201号8楼

马萨诸塞州剑桥市 02139

迈克尔·琼斯

mjones@crl.dec.com

康柏CRL

剑桥中心一号

马萨诸塞州剑桥市 02142

摘要

This paper describes a machine learning approach for visual object detection which is capable of processing images extremely rapidly and achieving high detection rates. This work is distinguished by three key contributions. The first is the introduction of a new image representation called the “Integral Image” which allows the features used by our detector to be computed very quickly. The second is a learning algorithm, based on AdaBoost, which selects a small number of critical visual features from a larger set and yields extremely efficient classifiers[6]. The third contribution is a method for combining increasingly more complex classifiers in a “cascade” which allows background regions of the image to be quickly discarded while spending more computation on promising object-like regions. The cascade can be viewed as an object specific focus-of-attention mechanism which unlike previous approaches provides statistical guarantees that discarded regions are unlikely to contain the object of interest. In the domain of face detection the system yields detection rates comparable to the best previous systems. Used in real-time applications, the detector runs at 15 frames per second without resorting to image differencing or skin color detection.

1. 引言

本文汇集了新的算法与洞见，构建了一个鲁棒且极速的目标检测框架。该框架以人脸检测任务为演示对象，并部分受其启发而构建。为此，我们开发了一个正面人脸检测系统，其检测率和误报率均与已发表的最佳成果相当[16, 12, 15, 11, 1]。该人脸检测系统最显著的特点在于其极快的检测速度：在384×288像素的图像上，人脸检测仅需——

在传统的700 MHz英特尔奔腾III处理器上，该系统以每秒15帧的速度进行检测。在其他面部检测系统中，通常需要借助辅助信息——例如视频序列中的图像差异，或彩色图像中的像素颜色——来实现高帧率。而我们的系统仅利用单张灰度图像中的信息，就能实现高帧率。若将这些其他信息源与我们的系统结合，还可实现更高的帧率。

我们的目标检测框架主要有三点贡献。下面我们将简要介绍这些想法，并在后续章节中详细阐述。

本文的第一个贡献是提出了一种称为integral image的新图像表示方法，该方法能够实现极快的特征评估。部分受到Papageorgiou等人研究的启发，我们的检测系统并不直接处理图像强度[10]。与这些研究者类似，我们采用了一组让人联想到哈尔基函数的特征集（同时我们也会使用比哈尔滤波器更复杂的相关滤波器）。为了在多尺度下快速计算这些特征，我们引入了图像的积分图表示法。积分图可通过每个像素的少量运算从图像中计算得出。一旦计算完成，任一此类类哈尔特征都可在constant时间内以任意尺度或位置进行计算。

本文的第二项贡献是提出了一种通过使用AdaBoost[6]选择少量重要特征来构建分类器的方法。在任何图像子窗口中，类Haar特征的总数非常庞大，远超像素数量。为了确保快速分类，学习过程必须排除大部分可用特征，并集中关注一小部分关键特征。受Tieu和Viola研究的启发，我们通过对AdaBoost流程进行简单修改来实现特征选择：弱学习器被约束为每个返回的弱分类器仅能依赖于一个

单一特征[2]。因此，提升过程的每个阶段（即选择新弱分类器的过程）可视为一种特征选择过程。AdaBoost 提供了一种高效的学习算法，并在泛化性能上给出了强有力的理论保证[13, 9, 10]。

本文的第三个主要贡献是提出了一种在级联结构中组合逐渐复杂分类器的方法，该方法通过将注意力集中在图像中有前景的区域，显著提高了检测器的速度。注意力聚焦方法背后的理念是，通常能够快速确定物体可能出现在图像中的位置[17, 8, 1]。更复杂的处理仅保留给这些有前景的区域。这种方法的关键衡量标准是注意力过程的“漏检率”。必须确保所有或几乎所有的物体实例都被注意力过滤器选中。

我们将描述一种训练极其简单高效分类器的过程，该分类器可用作“有监督”的注意力聚焦算子。所谓“有监督”，是指该注意力算子经过训练能够检测特定类别的样本。在人脸检测领域，使用由两个类哈尔特征构建的分类器，可以实现低于1%的漏检率和40%的误检率。该滤波器的作用是将最终检测器需要评估的位置数量减少一半以上。

那些未被初始分类器拒绝的子窗口会由一系列分类器处理，每个分类器都比前一个略微复杂。如果任何分类器拒绝了子窗口，则不再进行后续处理。这种级联检测过程的结构本质上是一个退化决策树，因此与Geman及其同事的研究[1, 4]相关。

一个极其快速的人脸检测器将拥有广泛的实际应用。这些应用包括用户界面、图像数据库和视频会议。在不需要高帧率的应用中，我们的系统将允许进行大量额外的后处理和分析。此外，我们的系统可以在各种小型低功耗设备上实现，包括手持设备和嵌入式处理器。在我们的实验室中，我们已经在康柏iPaq手持设备上实现了这个人脸检测器，并达到了每秒两帧的检测速度（该设备配备了一个低功耗的200 MIPS Strong Arm处理器，且缺乏浮点运算硬件）。

本文的其余部分描述了我们的贡献和一系列实验结果，包括对我们实验方法的详细说明。对密切相关工作的讨论将在每节末尾进行。

2. 特性

我们的目标检测程序基于简单特征值对图像进行分类。其动机有很多




图1：相对于封闭检测窗口显示的示例矩形特征。灰色矩形内像素之和减去白色矩形内像素之和。(A)和(B)展示的是双矩形特征，(C)展示的是三矩形特征，(D)展示的是四矩形特征。

使用特征而非直接使用像素的最常见原因是，特征能够编码特定领域的先验知识，这些知识难以通过有限数量的训练数据来学习。对于该系统而言，采用特征还有第二个关键动机：基于特征的系统运行速度远快于基于像素的系统。

所使用的简单特征让人联想到Papageorgiou等人[10]曾使用的哈尔基函数。更具体地说，我们使用了三种特征。*two-rectangle feature*的值是两个矩形区域内像素总和的差值。这些区域具有相同的大小和形状，并且水平或垂直相邻（见图1）。*three-rectangle feature*计算中心矩形内像素总和减去两个外部矩形内像素总和的结果。最后，*four-rectangle feature*计算对角线矩形对之间的差值。

鉴于检测器的基础分辨率为24x24，矩形特征的穷举集相当庞大，超过18万个。请注意，与哈尔基不同，矩形特征集是过完备的¹。

2.1. 积分图像

矩形特征可以使用一种称为积分图像的中间表示来非常快速地计算。²位置 x_1, y_1 处的积分图像包含 x_1, y_1 上方和左侧（包括 x_1, y_1 本身）的像素之和：

$$I(x_1, y_1) = \sum_{x_2 \leq x_1, y_2 \leq y_1} I(x_2, y_2)$$

一个完整的基在基元素之间没有线性依赖，并且与图像空间具有相同数量的元素，在本例中为576。完整的18万个特征集是多次过完备的。

²这与图形学中使用的“积分面积表”[3]有密切关系。我们在此选择不同的名称，是为了强调其在图像分析中的应用，而非纹理映射。




图2: 矩形内的像素和可通过四次数组引用计算得出。积分图像在位置1处的值为矩形A的像素和。位置2处的值为A+B, 位置3处的值为A+B+C, 位置4处的值为A+B+C+D。区域D内的像素和可通过 $s(4) - (s(3) + s(2) - s(1))$ 计算得出。

其中 $s(x, y)$ 是积分图像, $I(x, y)$ 是原始图像。使用以下递推对:

$$s(x, y) = s(x, y-1) + I(x, y) \quad (1)$$

$$s(x, y) = s(x-1, y) + s(x, y-1) - s(x-1, y-1) + I(x, y) \quad (2)$$

(其中 $s(x, 0)$ 是累积行和, $s(0, y) = 0$ 和 $s(-1, y) = 0$) 积分图像可在原始图像上单次遍历计算得出。

使用积分图像, 任何矩形和都可以通过四次数组引用计算得出(见图2)。显然, 两个矩形和之间的差异可以通过八次引用来计算。由于上述定义的双矩形特征涉及相邻的矩形和, 它们可以通过六次数组引用计算得出, 三矩形特征需要八次, 而四矩形特征则需要九次。

2.2. 特征讨论

矩形特征相较于可操纵滤波器[5,7]等替代方案而言较为原始。可操纵滤波器及其衍生方法在边界细节分析、图像压缩和纹理分析方面表现优异。相比之下, 矩形特征虽然对边缘、条形结构及其他简单图像结构的存在较为敏感, 但其表征能力相对粗糙。与可操纵滤波器不同, 矩形特征仅支持垂直、水平和对角线方向。然而, 矩形特征集合确实能提供丰富的图像表征, 足以支撑有效的学习过程。结合积分图像技术, 矩形特征集的高效性充分弥补了其灵活性不足的缺陷。

3. 学习分类函数

给定一个特征集和一个包含正负图像样本的训练集, 可以采用多种机器学习方法

可用于学习分类函数。在我们的系统中, 采用了一种AdaBoost的变体both来选择一小部分特征并训练分类器[6]。最初形式的AdaBoost学习算法旨在提升简单(有时称为弱)学习算法的分类性能。AdaBoost学习过程提供了若干形式化保证。Freund和Schapire证明了强分类器的训练误差随着迭代轮数呈指数级趋近于零。更重要的是, 后续研究证明了关于泛化性能的若干结果[14]。其关键见解在于, 泛化性能与样本间隔相关, 而AdaBoost能够快速实现较大的间隔。

回想一下, 每个图像子窗口关联着超过18万个矩形特征, 这个数字远大于像素数量。尽管每个特征的计算效率很高, 但计算完整特征集的成本却高得令人望而却步。我们的假设(已通过实验验证)是, 只需极少量这类特征组合便能构成一个有效的分类器。主要挑战在于如何找出这些特征。

为支持这一目标, 弱学习算法被设计用于选择最能区分正负样本的单个矩形特征(这与[2]在图像数据库检索领域采用的方法类似)。对于每个特征, 弱学习器会确定最优阈值分类函数, 以使误分类的样本数量最小化。因此, 一个弱分类器 $f_i(x)$ 由特征 μ_i , 阈值 θ_i 以及指示不等式方向的奇偶性 b_i 组成:

$$f_i(x) = \begin{cases} 1 & \text{if } b_i \mu_i(x) < b_i \theta_i \\ 0 & \text{otherwise} \end{cases}$$

这里 $\mathcal{I}$ 是图像的一个24x24像素子窗口。关于提升过程的总结, 请参见表1。

在实践中, 没有单一特征能以低误差完成分类任务。在提升过程的早期轮次中被选中的特征, 其错误率介于0.1至0.3之间。随着任务难度增加, 在后续轮次中被选中的特征则会产生0.4至0.5的错误率。

3.1. 学习讨论

许多通用的特征选择方法已被提出(综述见[18]第8章)。我们的最终应用需要一种极为激进的方法, 以舍弃绝大多数特征。针对类似的识别问题, Papageorgiou等人提出了一种基于特征方差的特征选择方案[10]。他们展示了从总计1734个特征中仅选择37个特征仍能取得良好效果。

Roth等人提出了一种基于Winnow指数感知器学习规则的特征选择过程[11]。Winnow学习过程收敛于一个解, 其中许多权重为零。然而, 一个非常庞大的

- Given n example images $(x^1, y^1), \dots, (x^N, y^N)$ where $y^i \in \{-1, 1\}$ for negative and positive examples respectively. Initialize weights $w_i = 1/N$ for $i = 1, \dots, N$ respectively, where N and n are the number of negatives and positives respectively.
- For $t = 1, 2, \dots$:
 1. Normalize the weights,

$$w_i^t \leftarrow \frac{w_i^{t-1}}{\sum_{j=1}^N w_j^{t-1}}$$
 so that w_i^t is a probability distribution.
 2. For each feature, f , train a classifier h_f^t which is restricted to using a single feature. The error is evaluated with respect to w_i^t ,

$$\epsilon_f^t = \sum_{i=1}^N w_i^t \mathbb{1}_{h_f^t(x^i) \neq y^i}$$
 3. Choose the classifier, $h_{f^*}^t$, with the lowest error $\epsilon_{f^*}^t$.
 4. Update the weights:

$$w_i^{t+1} = w_i^t \exp(-\epsilon_f^t y^i)$$
 where $\epsilon_f^t = \epsilon_{f^*}^t$ if example i is classified correctly, otherwise, $\epsilon_f^t = \epsilon_{f^*}^t + 1$.
- The final strong classifier is:

$$H(x) = \begin{cases} 1 & \sum_{t=1}^T \alpha_t H_{f_t}(x) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t \\ 0 & \text{otherwise} \end{cases}$$
 where $\alpha_t = \log \frac{1}{\epsilon_{f^*}^t}$

表1: AdaBoost分类器学习算法。每一轮提升从180,000个潜在特征中选择一个特征。

保留的特征数量（可能为几百或几千个）。

3.2. 学习结果

尽管最终系统的训练和性能细节将在第5节中介绍，但几项简单结果值得探讨。初步实验表明，由200个特征构建的正面人脸分类器可实现95%的检测率，每14084次检测中出现1次误报。这些结果令人瞩目，但对于许多实际任务仍显不足。在计算效率方面，该分类器可能比任何已公开的系统更快速，扫描一张384×288像素的图像仅需0.7秒。然而，提升检测性能最直接的方法——为分类器增加特征——会直接导致计算时间增加。

在人脸检测任务中，AdaBoost算法选取的初始矩形特征具有明确意义且易于解读。首个被选中的特征似乎聚焦于眼睛区域通常比脸颊区域更暗的特性。

图3: AdaBoost选择的第一和第二个特征。这两个特征在顶行显示，然后在底行叠加在一个典型的训练人脸图像上。第一个特征测量眼睛区域与上脸颊区域之间的强度差异。该特征利用了眼睛区域通常比脸颊更暗的观察结果。第二个特征比较眼睛区域的强度与鼻梁区域的强度。

鼻子和脸颊（见图3）。这一特征相对于检测子窗口来说比较大，并且应该对脸部的大小和位置有一定的鲁棒性。第二个选择的特征利用了眼睛比鼻梁更暗的特性。

4. 注意力级联

本节描述了一种构建级联分类器的算法，该算法在显著减少计算时间的同时提升了检测性能。其核心思路是：可以构建更小、因而更高效的增强分类器，在检测到几乎所有正例样本（即通过调整增强分类器的阈值使漏检率接近零）的同时，能够拒绝大量负子窗口。该算法先使用较简单的分类器排除大部分子窗口，再调用更复杂的分类器来实现较低误报率。

检测过程的整体形式是一种退化的决策树，我们称之为“级联”（见图4）。第一个分类器的肯定结果会触发第二个分类器的评估，该分类器同样经过调整以实现极高的检测率。第二个分类器的肯定结果会触发第三个分类器，依此类推。在任何阶段出现否定结果都会导致子窗口被立即拒绝。

级联检测的各个阶段通过使用AdaBoost训练分类器构建，随后调整阈值以最小化漏检率。需要注意的是，默认的AdaBoost阈值旨在使训练数据上的错误率保持较低水平。一般而言，较低的阈值会带来更高的检测——




图4：检测级联的示意图。一系列分类器被应用于每个子窗口。初始分类器以极少的处理量消除了大量负样本。后续层级消除了更多负样本但需要额外计算。经过若干处理阶段后，子窗口数量已急剧减少。后续处理可采用任何形式，例如级联的附加阶段（如我们的检测系统所示）或替代检测系统。

检出率较低且假阳性率较高。

例如，一个优秀的第一级分类器可以通过降低阈值来最小化假阴性，从而由双特征强分类器构建。在验证训练集上测量时，可以调整阈值以检测100%的人脸，同时假阳性率为40%。有关此分类器中使用的两个特征的描述，请参见图3。

两个特征分类器的计算量大约相当于60条微处理器指令。很难想象还有更简单的滤波器能达到更高的拒绝率。相比之下，扫描一个简单的图像模板或单层感知器，每个子窗口至少需要20倍以上的操作量。

级联结构反映了这样一个事实：在任意单张图像中，绝大多数子窗口都是负样本。因此，级联系统试图在最早阶段尽可能多地排除负样本。虽然正样本会触发级联中每个分类器的评估，但这种情况极为罕见。

与决策树类似，后续分类器使用那些通过所有先前阶段的样本进行训练。因此，第二个分类器面临的任务比第一个更困难。通过第一阶段的样本比典型样本“更难”。更深层分类器所面临的更困难样本将整个接收者操作特征（ROC）曲线向下推移。在给定的检测率下，更深层的分类器相应地具有更高的误报率。

4.1. 训练级联分类器

级联训练过程涉及两种权衡。在大多数情况下，具有更多特征的分类器会获得更高的检测率和更低的误报率。同时，具有更多特征的分类器需要更多的计算时间。原则上，可以定义一个优化框架，其中：i) 分类器阶段的数量，ii) 每个阶段的特征数量，以及 iii) 每个阶段的阈值，被用来权衡以最小化预期评估特征的数量。不幸的是，找到这个最优解是一个极其困难的问题。

在实践中，采用一个非常简单的框架来生成高效且效果显著的分类器。级联中的每个阶段都会降低误报率并减少检测率。选择目标时，需追求误报率的最小化降低和检测率的最大化减少。每个阶段通过不断添加特征进行训练，直至达到目标检测率和误报率（这些比率通过在验证集上测试检测器来确定）。持续添加阶段，直至满足整体误报率和检测率的目标。

4.2. 检测器级联讨论

完整的人脸检测级联包含38个阶段，超过6000个特征。尽管如此，级联结构仍能实现快速的检测平均时间。在一个包含507张人脸和7500万个子窗口的困难数据集上，每个子窗口平均仅需10次特征评估即可检测出人脸。相比之下，该系统比Rowley等人³[12]构建的检测系统实现快约15倍。

一种类似于级联的概念出现在Rowley等人描述的人脸检测系统中，该系统使用了两个检测网络[12]。Rowley等人使用了一个更快但准确性较低的网络对图像进行预筛选，以便为更慢、更准确的网络找到候选区域。尽管难以精确确定，但Rowley等人的双网络人脸系统似乎是现有最快的人脸检测器。{v*}

级联检测过程的结构本质上是一个退化决策树，因此与Amit和Geman的研究[1]相关。与使用固定检测器的技术不同，Amit和Geman提出了一种替代视角，即利用简单图像特征的异常共现来触发更复杂检测过程的评估。通过这种方式，无需在大量潜在图像位置和尺度上评估完整的检测过程。虽然这一基本见解

³Henry Rowley very graciously supplied us with implementations of his detection system for direct comparison. Reported results are against his fastest system. It is difficult to determine from the published literature, but the Rowley-Baluja-Kanade detector is widely considered the fastest detection system and has been heavily tested on real-world problems.

⁴Other published detectors have either neglected to discuss performance in detail, or have never published detection and false positive rates on a large and difficult training set.

非常有价值，在实施过程中，首先需要在每个位置评估某种特征检测器。然后对这些特征进行分组，以发现不寻常的共现现象。实际上，由于我们的检测器形式及其使用的特征极其高效，在 *every scale and location* 处评估检测器的均摊成本远低于在整个图像中寻找并分组边缘。

在最近的研究中，Fleuret和Geman提出了一种人脸检测技术，该技术依赖于一系列测试的“链”来指示特定尺度和位置是否存在人脸[4]。Fleuret和Geman所测量的图像属性——精细尺度边缘的析取——与矩形特征截然不同，后者简单、存在于所有尺度，且具有一定可解释性。这两种方法在学习理念上也存在根本差异。Fleuret和Geman学习过程的动机是密度估计和密度判别，而我们的检测器纯粹是判别式的。最后，Fleuret和Geman方法的误报率似乎高于以往的方法，如Rowley等人的方法以及本方法。遗憾的是，该论文未报告此类定量结果。所包含的示例图像每张都有2到10个误报。

5 结果

一个38层的级联分类器被训练用于检测正面直立的人脸。为了训练这个检测器，使用了一组人脸和非人脸的训练图像。人脸训练集包含4916张手动标记的人脸图像，这些图像被缩放并对齐到24×24像素的基础分辨率。这些人脸图像是从随机爬取互联网时下载的图片中提取的。图5展示了一些典型的人脸示例。用于训练检测器的非人脸子窗口来自9544张经过人工检查确认不包含任何人脸的图像。这些非人脸图像中大约有3.5亿个子窗口。

检测器前五层的特征数量分别为1、10、25、25和50个特征。其余各层具有越来越多的特征。所有层中的特征总数为6061个。

级联中的每个分类器均使用Adaboost训练流程，基于4916张训练人脸（加上其垂直镜像图像，总计9832张训练人脸）和10000个非人脸子窗口（同样为24×24像素大小）进行训练。对于初始的单特征分类器，非人脸训练样本通过从一组不含人脸的9544张图像中随机选取子窗口来收集。用于训练后续层的非人脸样本，则是通过将部分级联分类器在非人脸图像上进行扫描并收集误报结果而获得。每层最多收集10000个此类非人脸子窗口。

最终检测器的速度



图5：用于训练的正面直立人脸图像示例。

级联检测器的速度直接与每个扫描子窗口评估的特征数量相关。在MIT+CMU测试集[12]上的评估显示，每个子窗口平均评估6061个特征中的10个。这是可能的，因为绝大多数子窗口在级联的第一层或第二层就被拒绝了。在700 MHz的Pentium III处理器上，人脸检测器处理一张384×288像素的图像大约需要0.067秒（使用起始尺度为1.25、步长为1.5的参数设置，详见下文）。这比Rowley-Baluja-Kanade检测器[12]快了约15倍，比Schneiderman-Kanade检测器[15]快了约600倍。

图像处理

所有用于训练的示例子窗口都经过方差归一化处理，以最小化不同光照条件的影响。因此，在检测过程中同样需要进行归一化。图像子窗口的方差可以借助一对积分图像快速计算。回顾公式 $\sigma_q^2 = w_q^2 - \frac{1}{A} \sum x_q^2$ ，其中 σ_q 为标准差， w_q 为均值， x_q 为子窗口内的像素值。子窗口的均值可通过积分图像计算，而像素平方和则通过图像平方的积分图像（即在扫描过程中使用两个积分图像）计算。在扫描过程中，图像归一化的效果可以通过后乘特征值而非预乘像素值来实现。

扫描探测器

最终的检测器在多个尺度和位置上对图像进行扫描。缩放是通过缩放检测器本身实现的，而非缩放图像。这一过程是合理的，因为特征可以在任意

Detector	False detections						
	10	31	50	65	78	95	167
Viola-Jones	76.1%	88.4%	91.4%	92.0%	92.1%	92.9%	93.9%
Viola-Jones (voting)	81.1%	89.7%	92.1%	93.1%	93.1%	93.2%	93.7%
Rowley-Baluja-Kanade	83.2%	86.0%	-	-	-	89.2%	90.1%
Schneiderman-Kanade	-	-	-	94.4%	-	-	-
Roth-Yang-Ahuja	-	-	-	-	(94.8%)	-	-

表2：在包含130张图像和50个的MIT+CMU测试集上，不同误报数量对应的检测率

7

以相同的成本进行缩放。使用一组间隔1.25倍的缩放比例获得了良好的结果。

检测器也会在位置上进行扫描。后续位置通过将窗口移动若干像素来获得。这一移动过程受检测器尺度的影响：若当前尺度为 s ，则窗口移动步长为 $\lceil \frac{s}{4} \rceil$ ，其中 $\lceil \cdot \rceil$ 表示取整运算。

的选择会影响检测器的速度和准确性。我们展示的结果是针对 $s = 1$ 的。通过设置 $s = 1.25$ ，我们可以在精度仅有轻微下降的情况下实现显著的速度提升。

多检测集成

由于最终检测器对平移和尺度的小变化不敏感，因此在扫描图像中，每张人脸周围通常会出现多个检测结果。对于某些类型的误报，情况也往往如此。实际上，通常更合理的做法是每张人脸返回一个最终检测结果。为此，对检测到的子窗口进行后处理是有益的，以便将重叠的检测合并为单一检测。

在这些实验中，检测结果以非常简单的方式合并。首先将检测集合划分为互不相交的子集。若两个检测的边界区域重叠，则它们属于同一子集。每个子集生成一个最终检测结果，最终边界区域的角点取该子集中所有检测角点的平均值。

真实世界测试集上的实验

我们在MIT+CMU正面人脸测试集[12]上评估了我们的系统。该测试集包含130张图像，共标注了507个正面人脸。图6展示了我们的检测器在此测试集上的ROC性能曲线。为生成ROC曲线，我们将最终层分类器的阈值从 $-\infty$ 调整至 $+\infty$ 。将阈值设为 $-\infty$ 时，检测率与误报率均为0.0；而将阈值调整至 $+\infty$ 则会使检测率和误报率同时上升，但仅能提升至特定上限——两者均无法超过检测级联中去除最终层后的基准水平。实际上，将阈值设为 $-\infty$ 等效于移除该层级。若要进一步提升检测率与误报率，则需降低级联中下一级分类器的阈值。

因此，为了构建完整的ROC曲线，分类器层被移除。

我们使用假阳性的 $number$ 而非假阳性的 $rate$ 作为ROC曲线的x轴，以便与其他系统进行比较。计算假阳性率时，只需将其除以扫描的子窗口总数。在我们的实验中，扫描的子窗口数量为75,081,800个。

遗憾的是，以往发表的人脸检测结果大多只包含单一操作区间（即ROC曲线上的单个点）。为便于与我们的检测器进行比较，我们列出了其他系统所报告的误报率对应的检测率。表2列出了我们的系统以及其它已发表系统在不同误检数量下的检测率。对于Rowley-Baluja-Kanade的研究成果[12]，其检测器的多个不同版本经过测试产生了若干差异结果，这些数据均列于同一标题下。至于Roth-Yang-Ahuja检测器[11]，其报告结果基于MIT+CMU测试集（该数据集已移除5幅含线条绘制人脸的图像）。

图7展示了我们的人脸检测器在MIT+CMU测试集部分测试图像上的输出结果。

一种简单的投票方案，以进一步提升结果

在表2中，我们还展示了运行三个检测器（上文描述的38层检测器以及两个经过类似训练的检测器）并输出三者多数投票的结果。这不仅提高了检测率，还减少了更多误报。如果这些检测器更具独立性，改进效果会更显著。由于它们的误差存在相关性，当前仅比最佳单检测器取得了有限的改进。

6 结论

我们提出了一种目标检测方法，该方法在实现高检测精度的同时最大限度地减少了计算时间。该方法被用于构建一个人脸检测系统，其速度比以往任何方法快约15倍。

本文汇集了新的算法、表示方法和见解，这些内容具有相当的通用性，很可能




图7：我们的面部检测器在MIT+CMU测试集若干测试图像上的输出结果。




图6：我们的人脸检测器在MIT+CMU测试集上的ROC曲线。检测器运行时采用1.0的步长和1.0的起始尺度（共扫描75,081,800个子窗口）。

在计算机视觉和图像处理领域有更广泛的应用。

最后，本文在一个已被广泛研究的困难人脸检测数据集上进行了一系列详细实验。该数据集涵盖了极广泛条件下的人脸图像，包括：光照、尺度、姿态及相机差异。在此类庞大而复杂的数据集上进行实验既困难又耗时。然而，能在这些条件下运行的系统不太可能脆弱或仅局限于单一条件集。更重要的是，基于该数据集得出的结论不太可能是实验假象。

参考文献

- [1] Y. Amit, D. Geman, 和 K. Wilder. 形状特征与树分类器的联合归纳, 1997.
 [2] 匿名. 匿名. 于 *Anonymous*, 2000年。

- [3] F. Crow. 用于纹理映射的求和面积表。载于 *Proceedings of SIGGRAPH*, 第18卷第3期, 第207–212页, 1984年。
 [4] F. Fleuret 与 D. Geman. 从粗到精的人脸检测。 *Int. J. Computer Vision*, 2001年。
 [5] William T. Freeman 与 Edward H. Adelson. 可操纵滤波器的设计与使用。 *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 第13卷第9期, 第891–906页, 1991年。
 [6] Yoav Freund 与 Robert E. Schapire. 在线学习的决策理论推广及其在提升方法中的应用。载于 *Computational Learning Theory: Eurocolt '95*, 第23–37页。Springer-Verlag, 1995年。
 [7] H. Greenspan, S. Belongie, R. Goodman, P. Perona, S. Rakshit, 与 C. Anderson. 过完备可操纵金字塔滤波器与旋转不变性。载于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 1994年。
 [8] L. Itti, C. Koch, 与 E. Niebur. 一种基于显著性的视觉注意力模型，用于快速场景分析。 *IEEE Patt. Anal. Mach. Intell.*, 第20卷第11期, 第1254–1259页, 1998年11月。
 [9] Edgar Osuna, Robert Freund, 与 Federico Girosi. 训练支持向量机：在人脸检测中的应用。载于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 1997年。
 [10] C. Papageorgiou, M. Orten, 与 T. Poggio. 一个通用的目标检测框架。载于 *International Conference on Computer Vision*, 1998年。
 [11] D. Roth, M. Yang, 与 N. Ahuja. 一种基于雪的人脸检测器。载于 *Neural Information Processing 12*, 2000年。
 [12] H. Rowley, S. Baluja, 与 T. Kanade. 基于神经网络的人脸检测。载于 *IEEE Patt. Anal. Mach. Intell.*, 第20卷, 第22–38页, 1998年。
 [13] R. E. Schapire, Y. Freund, P. Bartlett, 与 W. S. Lee. 提升边界：对投票方法有效性的新解释。 *Ann. Stat.*, 第26卷第5期, 第1651–1686页, 1998年。
 [14] Robert E. Schapire, Yoav Freund, Peter Bartlett, 与 Wee Sun Lee. 提升边界：对投票方法有效性的新解释。载于 *Proceedings of the Fourteenth International Conference on Machine Learning*, 1997年。
 [15] H. Schneiderman 与 T. Kanade. 一种用于人脸和汽车检测的3D目标统计方法。载于 *International Conference on Computer Vision*, 2000年。

[16] K. Sung 和 T. Poggio。基于示例的视角人脸检测学习。
发表于 *IEEE Patt. Anal. Mach. Intell.*, 第20卷, 第39–51页, 1
998年。[17] J.K. Tsotsos, S.M. Culhane, W.Y.K. Wai, Y.H. Lai,
N. Davis, 和 F. Nuflo。通过选择性调谐建模视觉注意。
Artificial Intelligence Journal, 第78卷, 第1-2期, 第507–545
页, 1995年10月。[18] Andrew Webb。
Statistical Pattern Recognition。牛津大学出版社, 纽约, 1999
年。