RF-DETR目标检测与YOLOv12对比研究：基于Transformer与CNN架构在标签模糊条件下复杂果园环境中单类及多类青果检测的性能分析

拉詹·萨普科塔[a,*]，拉胡尔·哈沙·切帕利[b]，阿贾伊·沙尔达[b]，马诺吉·卡尔基[a,*]

[a]*Biological & Environmental Engineering, Cornell University, Ithaca, 14850, NY, USA*
[b]*Department of Biological and Agricultural Engineering, Kansas State University, Manhattan, 66502, KS, USA*

摘要

本研究针对标签模糊、遮挡及背景伪装等复杂果园环境下的青果识别，全面对比了RF-DETR与YOLOv12目标检测模型的性能。通过构建包含单类别（青果）与多类别（遮挡/非遮挡青果）标注的自定义数据集，评估模型在真实场景中的表现。采用DINOv2骨架与可变形注意力机制的RF-DETR模型在全局上下文建模方面表现卓越，尤其擅长识别部分遮挡或视觉模糊的青果；而基于CNN注意力机制的YOLOv12模型则通过增强局部特征提取能力，在计算效率与边缘部署适用性上更具优势。 单类别检测中，RF-DETR以0.9464的mAP@50最高值展现了其在杂乱场景中精确定位青果的强劲能力。尽管YOLOv12N在mAP@50:95指标上以0.7620领先，但RF-DETR在处理复杂空间场景时始终更胜一筹。多类别检测中，RF-DETR再次以0.8298的mAP@50领跑，验证其区分遮挡/非遮挡果实的有效性；而YOLOv12L则以0.6622的mAP@50:95值，表明其在细节遮挡条件下的分类优势。 模型训练动态分析显示，RF-DETR在单类别场景中仅需不足10个epoch即可收敛，凸显了基于Transformer架构对动态视觉数据的高效适应能力。这些结果证实RF-DETR适用于精度优先的农业任务，而YOLOv12仍是速度敏感型部署的理想选择。

关键词：目标检测，RF-DETR目标检测模型（Roboflow Detection Transformer），YOLOv12目标检测模型，You Only Look Once，Transformers，卷积神经网络，绿果检测，深度学习，机器视觉

1. 引言

如图1所示，过去十年间，在深度学习突破的推动下，目标检测领域已从基础模式识别发展为能够实现复杂图像理解的精密系统。目标检测方法可划分为六大主要技术路线（如图1所示），每种方法在技术与自动化的不同应用领域均具有独特优势。这一演进对于克服自动驾驶[1, 2]、医疗健康[3]、安防监控[4]等需要高精度与适应性的领域中的常见视觉识别挑战至关重要，尤其在农业领域[5, 6]——精准高效的目标检测技术支撑着农田自动化监测[7]与机器人采收[8]等进步。

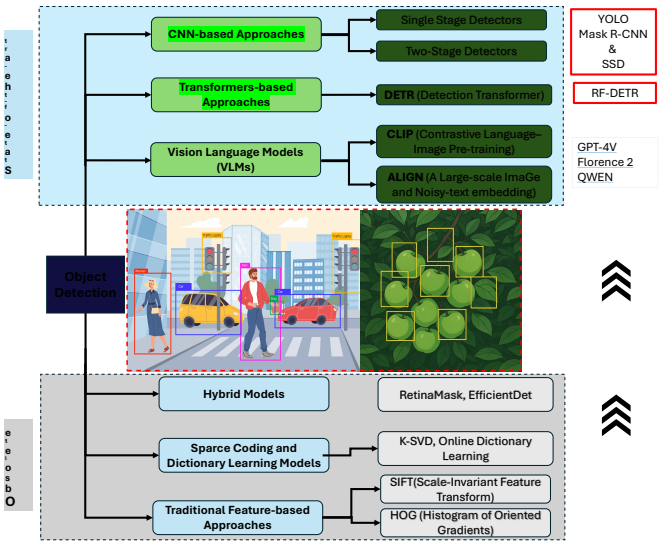

图1：目标检测方法分类：顶部展示了当前最先进的基于CNN和Transformer的方法，这些方法被广泛采用；视觉语言模型正在兴起。同时还包括混合方法、稀疏编码以及基于传统特征的方法。

*Corresponding Authors: Manoj Karkee and Ranjan Sapkota
Email address: mk2684@cornell.edu, rs2672@cornell.edu (Manoj Karkee)

图1所示的六种方法包括卷积神经网络（CNNs）[9]、基于Transformer的模型[10,11]、视觉语言模型方法[12,13]、混合模型（如RetinaMask和EfficientDet）[14,15]、稀疏编码与字典学习模型以及传统基于特征的方法。其中，CNN系列（如YOLO（You Only Look Once）[16,17]和R-CNN家族（如Mask R-CNN[18]）凭借其出色的空间层次处理能力，已成为实际部署的主流选择。基于Transformer的模型（如动态DETR[19]和可变形DETR[20]）利用自注意力机制将图像视为补丁序列，有助于整合全局上下文并省去非极大值抑制（NMS）[21]，从而简化后处理流程[22]。视觉语言模型（如对比语言-图像预训练模型CLIP）代表了融合文本与视觉数据的新兴领域，旨在通过多模态学习提升鲁棒性，尽管其在机器人学和自动化等现实场景的应用仍处于发展阶段。另一方面，RetinaMask等混合模型、在线字典学习等稀疏编码模型，以及方向梯度直方图（HOG）等传统特征方法正逐渐被视为过时技术[23,24]。这些方法已被更先进的系统所取代，后者不仅能提供更高精度，还具备实时处理能力——这对现代农业等延迟敏感场景至关重要。随着目标检测技术的持续演进，高精度与高效处理相结合的技术仍是关注焦点，使得CNN和Transformer模型成为当前领域的最先进解决方案。

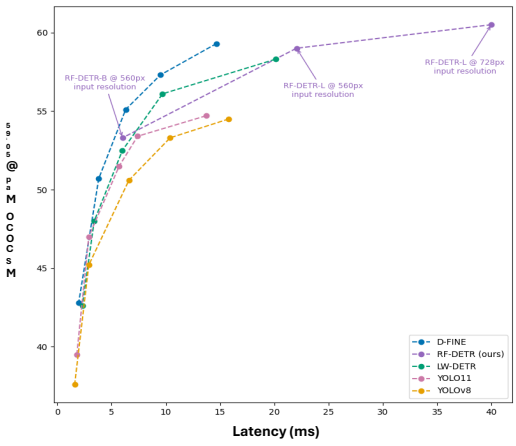

(a)

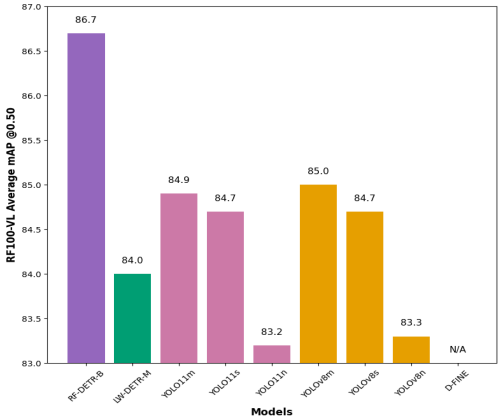

(b)

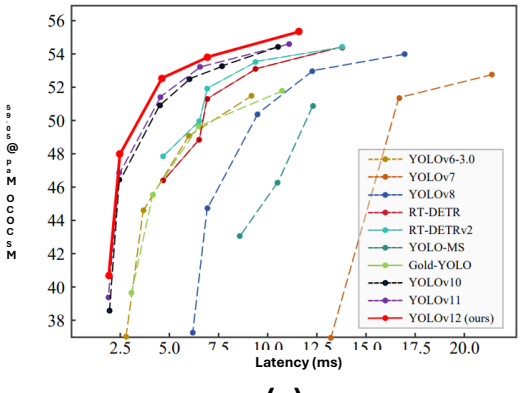

(c)

图2：基于CNN与Transformer的模型性能对比，聚焦于YOLOv12（基于CNN）和RF-DETR（基于Transformer）架构：(a) RF-DETR目标检测模型与YOLO11、YOLOv8及其他基于DETR的目标检测模型的基准评估；(b) RF-DETR在RF100-VL数据集上的评估，突出其领域适应性和边缘部署潜力；(c) 近期基于CNN模型的性能概览，包括YOLOv6至YOLOv12、Gold-YOLO、RT-DETR、RT-DETRv2及YOLO-MS。b) RF-DETR在MS COCO数据集上的基准测试结果，mAP突破60%

在图1展示的六种主要目标检测方法中，基于CNN和基于Transformer的模型已成为过去五年间最广泛采用且积极发展的技术。这两种范式凭借其可扩展性、准确性和适应性，如今主导着研究领域与实际应用。这种持续的统治地位激发了两大方法间的竞争性演进，尤其是随着Roboflow开发的RF-DETR等强大Transformer模型的发布。RF-DETR融合了可变形DETR与LW-DETR的架构创新，并采用DINOv2骨干网络，提供卓越的全局上下文建模与领域适应能力。该模型摒弃了锚框和非极大值抑制（NMS）的依赖，支持端到端训练与实时推理。通过Base（29M）和Large（128M）两个变体，RF-DETR实现了从边缘部署到高性能场景的可扩展性。实验表明，其性能超越YOLOv11，并成为迄今唯一在COCO数据集上mAP突破60%的模型。图2a与2b直观呈现了该模型在COCO和RF100-VL基准测试中的表现。然而尽管前景广阔，RF-DETR尚未与YOLO家族最新旗舰模型YOLOv12进行官方基准对比。鉴于YOLOv12在原有优势基础上的全面升级，开展比较性评估尤为必要。

YOLOv11、YOLOv10和Gold-YOLO RT-DETR的性能对比，如图2c所示。

1.1. CNN-based Object Detection Approaches

自2012年AlexNet推动该领域发展以来[25]，卷积神经网络(CNN)在目标检测领域的进步中发挥了关键作用。这些网络通过卷积层、池化层和非线性激活函数的层级结构，高效学习图像特征表示[26]。与依赖注意力机制处理全局关系的Transformer不同，CNN凭借其固有的归纳偏置（如平移等变性和空间层级结构的建立）[27]，在提取局部特征方面表现卓越。这种根本性的架构差异使CNN特别适合需要实时处理和边缘计算部署的场景，尽管其在全面建模全局上下文信息方面存在明显局限[28, 29]。

CNN在目标检测架构上的进展，以以下几项重大创新为标志：

- R-CNN系列：该系列始于2014年的R-CNN[30]，它利用选择性搜索生成候选区域，随后通过CNN提取特征，在PASCAL VOC数据集上实现了53.3%的mAP，但计算成本较高。后续迭代版本Fast R-CNN和Faster R-CNN分别引入了ROI池化与区域提议网络(RPN)，显著提升了模型的效率和速度。

- Mask R-CNN：Faster R-CNN的扩展版本，它在每个感兴趣区域（ROI）上增加了一个预测分割掩码的分支，从而以高精度水平有效处理实例分割任务[18, 31]。

- YOLO系列：从YOLOv1[16]开始，它将目标检测重新定义为从图像像素到边界框坐标及类别概率的单一回归问题，直至YOLOv12[32]，后者引入了无锚点检测和动态标签分配等改进，以提升精度与效率[33, 34, 35, 31]。

- SSD：该模型将多尺度特征图与默认边界框相结合进行检测，无需单独的区域提议即可直接从特征图完成分类与定位[36]。

- RetinaNet：以采用焦点损失函数解决类别不平衡问题而闻名，该函数通过降低分配给易分类样本的损失权重，帮助模型集中关注难以分类的样本[37]。

- EfficientDet：该模型采用了一种系统性调整网络深度、宽度和分辨率的缩放方法，并结合BiFPN实现跨尺度特征融合，从而在保证高效率的同时达到了高精度[15]。

1.2. Transformers-based Object Detection Approaches

DETR通过整合传统上用于自然语言的Transformer架构，彻底革新了目标检测领域。处理，转化为视觉识别任务[22]。由Facebook AI于2020年提出的DETR，通过将目标检测视为一个直接的集合预测问题，提出了一种新颖的方法，消除了对传统组件（如锚框）和复杂后处理步骤（如非极大值抑制NMS）的需求[22]。DETR的核心在于使用标准的CNN主干网络（通常是ResNet-50）进行初始特征提取。随后是一个由编码器和解码器组成的Transformer结构：编码器处理图像的空间特征，解码器则利用学习到的对象查询{v*}，并行预测物体的存在及其类别与边界框。

DETR的关键架构变体已解决了其初始缺陷，如收敛速度慢和计算需求高的问题：

- 可变形DETR：为解决标准Transformer注意力机制效率低下的问题而提出，它采用可变形注意力机制，该机制仅聚焦于每个参考点周围的一小组关键采样点，显著降低了计算负担并提升了小物体检测性能[20]。该变体通过迭代式边界框优化和多尺度特征融合来提升精度并加速训练过程。

- RT-DETR：专为实时应用设计，此百度推出的变体采用混合编码器架构，巧妙融合CNN与Transformer特征，优化了尺度内交互与跨尺度融合，在标准硬件上实现了卓越的运行速度。其创新性引入IoU感知查询选择机制，能根据预测的目标性分数动态调整解码流程[38, 39]。

- Co-DETR：通过实施一种结合传统一对多（如Faster R-CNN）和一对一（如DETR）标签匹配的双重监督策略[40]，显著提升了训练稳定性与性能。该方法在层次化注意力机制的支持下，大幅优化了特征表示能力，尤其在遮挡等挑战性场景中表现突出[41]。

- YOLOS：其独特之处在于直接采用视觉变换器（ViTs）进行目标检测，无需任何卷积神经网络（CNNs）[42]。该方法通过将图像分块（标记）序列与一组可学习的检测标记相结合，证明了变换器能够有效编码检测任务中固有的空间关系[43]。

- OWL-ViT：通过整合视觉与语言，利用Transformer解码器将图像特征与文本查询对齐，扩展了Transformer在开放词汇检测中的适用性[44]。该模型支持零样本检测，即系统能够识别训练期间从未见过的物体，仅通过文本描述即可实现[45, 46]。

- DINO（带改进去噪锚框的DETR）：通过一种新颖的训练策略专注于提升小物体检测能力，该策略涉及向{v*}添加噪声

真实标注框并学习预测校正偏移量，从而提高精度和鲁棒性[47]。

- RF-DETR：由Roboflow发布的RF-DETR是一款基于Transformer的实时目标检测模型，在NVIDIA T4 GPU上以25 FPS的速度实现了60.5 mAP，在COCO和RF100-VL等基准测试中超越了YOLOv11和LW-DETR等模型[48]。其架构专为高速边缘部署和领域适应性设计，提供两种变体：RF-DETR-Base（2900万参数）和RF-DETR-Large（1.28亿参数）。

1.3. Objectives

尽管目标检测领域取得了显著进展，但在复杂、标签模糊的农业环境中，最先进模型的性能仍未得到充分探索。Roboflow最新发布的RF-DETR——基于Transformer的实时目标检测模型，在MS COCO数据集上实现了超过60%的mAP，创下了迄今为止所有基于Transformer的检测器中的最高记录，展现出卓越性能。然而，RF-DETR的基准测试仅针对早期版本的YOLO（包括YOLOv11）以及LW-DETR等少数模型进行，与YOLO家族最新、最先进的基于CNN的检测器YOLOv12的对比评估存在明显空白。这种直接比较的缺失，使得在现实条件下（尤其是存在遮挡、伪装和模糊标签时）RF-DETR与YOLOv12哪个模型具备更优检测能力的问题仍存不确定性。

本研究通过详细评估RF-DETR和YOLOv12在商业苹果园绿果检测任务中的表现，填补了这一空白。未成熟的绿色小苹果对早期产量预估和疏果至关重要，但由于其体积小、与背景颜色相近、常被枝叶或其他果实遮挡，检测难度极大。这种视觉复杂性导致标签模糊，难以判断小果是完全可见、部分可见还是完全被遮挡的状态，这对人工标注和自动检测都构成了挑战。

为了评估这两种架构的鲁棒性，我们开发了一个定制数据集，并采用相同的训练协议和超参数对两个模型进行了评估。性能评估涵盖单类别和多类别检测任务，关键指标包括：精确率（Precision）、召回率（Recall）、F1分数（F1-Score）、mAP@50以及mAP@50:95。此外，我们还测量了推理速度和处理效率，旨在为精准农业中基于CNN与基于Transformer的目标检测方法提供清晰、数据驱动的对比分析。

2. 方法

本实验分四个步骤进行，如图3a所示。首先，在复杂条件下从商业果园采集了实地图像，其特征是未成熟的绿色果实与绿色树冠形成伪装，由于遮挡问题，这对机器视觉提出了重大挑战。随后，这些图像通过机器人平台和机器视觉相机采集，并进行了预处理和准备工作。第三步中，使用相同的数据集、超参数和训练周期数，实现了两种深度学习模型——RF-DETR与YOLOv12。最后，评估了这些模型在具有挑战性的果园环境下检测单类别与多类别绿色果实目标的性能表现。

2.1. Study Site and Data Acquisition

本研究的数据采集工作在美国华盛顿州普罗斯瑟市的一处商业果园中进行，如图3b所示。该果园密集种植着俗称爵士苹果的‘Scifresh’苹果树。选择这一特定果园的原因在于其复杂的环境条件——未成熟小果的绿色与树冠背景的绿色相互交融（如图3c所示）。这种颜色相似性造成了显著的遮挡和视觉混淆，为精准图像检测带来了挑战，这也是复杂果园场景中的典型情况。

图像采集采用了一款集成Intel RGB-D相机的精密机器人平台完成，该相机安装在UR5e机械臂上，如图3d所示。这一配置实现了对未成熟‘Scifresh’苹果幼果RGB图像的精准捕捉。影像采集于2024年5月进行，恰好在幼果疏除作业开始之前。采集时机的选择基于对果园发育阶段的持续监测（疏果前，正值疏果周期间），并与当地种植者和果园工作人员协商确定，以确保研究数据的最佳相关性。

该果园始建于2008年，采用系统化布局，行距3米，株距1米。本研究期间，共使用英特尔实感D435i相机采集了857张图像（如图3d所示）。所选相机搭载基于主动红外立体视觉的深度感知系统，并配有惯性测量单元（IMU）。该相机的深度传感器采用结构光技术，通过图案投影器在两台红外相机拍摄的立体图像间制造视差。

该相机的3D传感器拥有1280 × 720像素的分辨率，能够捕捉最远10米距离的深度信息。它支持高达每秒90帧（fps）的帧率，并具备69.4°的水平视场角（HFOV）和42.5°的垂直视场角（VFOV）。此外，集成的6轴IMU提供了关键的姿态数据，显著提升了深度数据与实际场景的对齐度，从而增强了对捕获图像的整体理解和分析能力。这种细致且系统化的数据采集方法，对于应对果园环境带来的视觉复杂性起到了基础性作用。

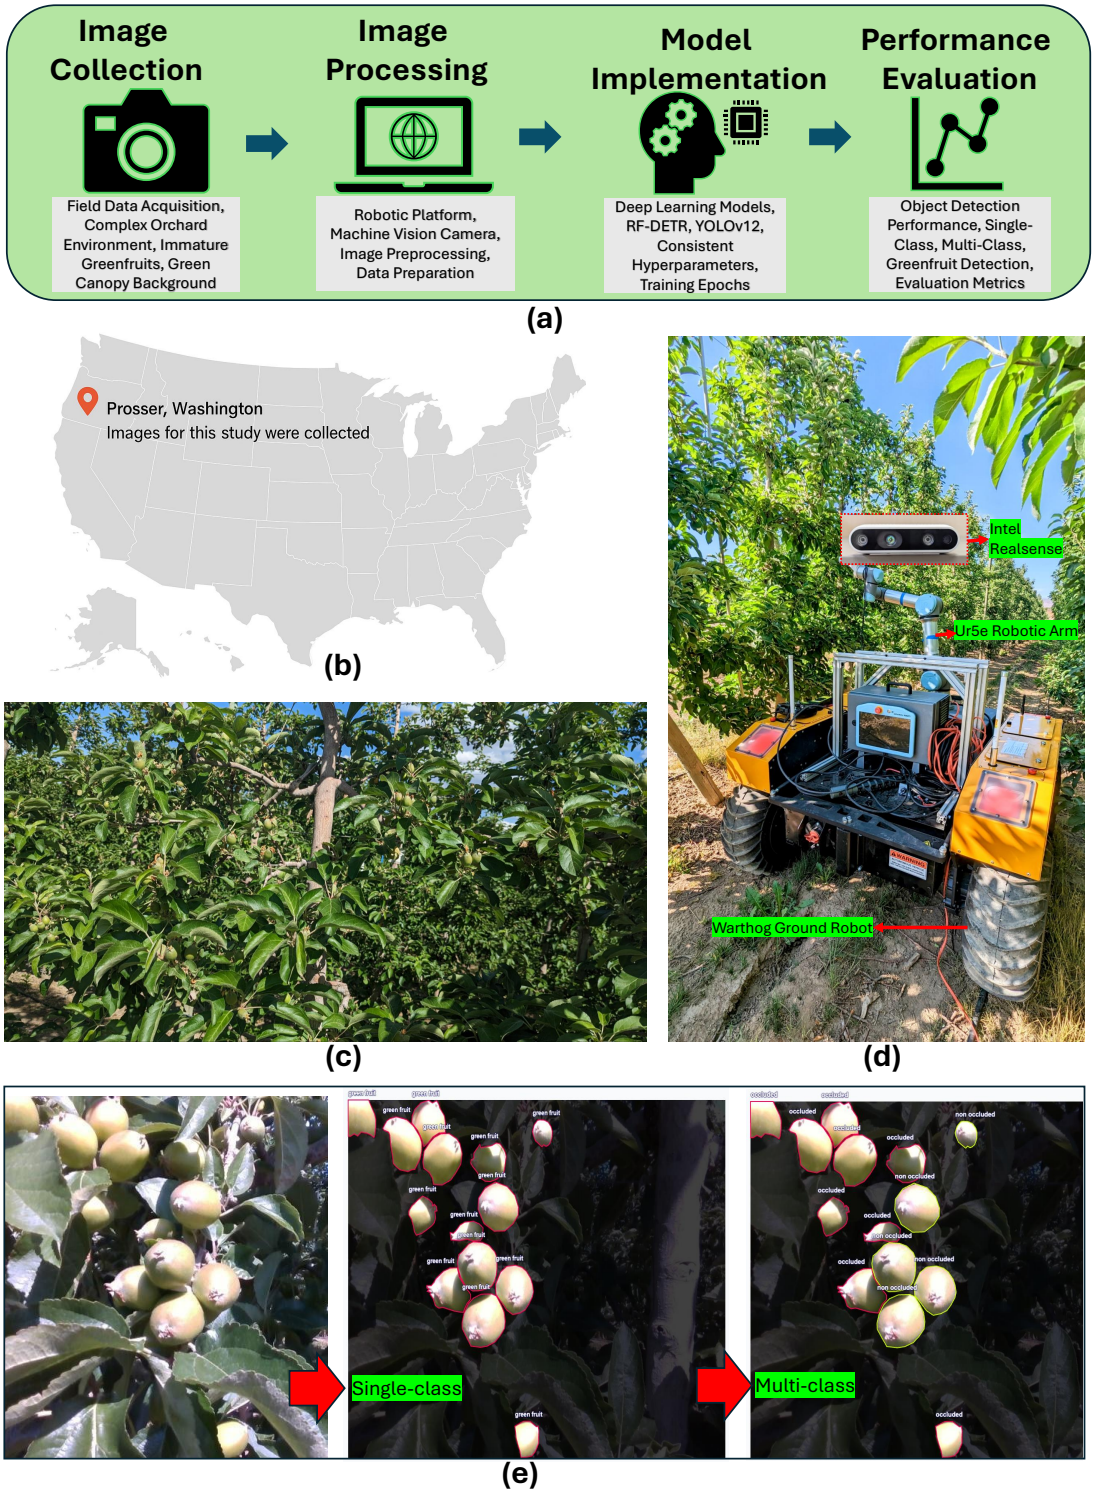

图3：数据收集设置与环境概览：a) 展示RF-DETR与YOLOv12对比方法的流程图；b) 标注美国华盛顿州普罗瑟研究地点的地图；c) 被称为爵士苹果的‘Scifresh’苹果树；d) 用于图像采集的机器人平台，配备安装在UR5e机械臂上的英特尔RGB-D相机，在复杂果园环境中捕捉未成熟绿色果实的图像。

2.2. Data Preprocessing and Preparation

在数据收集之后，所获取的RGB图像经过系统的预处理和标注流程，为深度学习模型的训练与评估做好准备。年龄标注是使用Roboflow平台（Roboflow，爱荷华州得梅因）手动完成的，该平台是计算机视觉工作流中广泛使用的自定义数据集生成工具。数据集构建涉及两种标注方案：(i) 一种

单类别数据集和（ii）多类别数据集，两者均旨在捕捉现实果园条件下绿果检测的固有复杂性。

在第一种方案中，所有可见的未成熟苹果均被统一标注为"greenfruit"类别，无论其可见程度或遮挡情况如何。为此，我们共上传并处理了857张高分辨率果园图像至Roboflow平台。如图3e中间图像所示，该数据集涵盖了绿色果实的多种外观形态，最终生成4,125个独立对象标签。这种统一标注方案适用于建立基准检测性能，但未能捕捉部分遮挡或背景融合等视觉挑战的动态特征。 为更深入探究这些复杂性，我们开发了第二种标注方案以创建多类别数据集。该方案将每个绿色果实划分为两类：被遮挡绿色果实（occluded greenfruit）和未遮挡绿色果实（non-occluded greenfruit）。分类标准基于可见程度：表面区域至少90%清晰可见、未被枝叶或其他果实遮挡的绿色果实标注为未遮挡；而任何被重叠苹果、交叉叶片或枝条部分遮挡的果实则标注为被遮挡。这种动态标注方法如图3e最右侧图像所示。

然而，标注过程因标签模糊性而变得复杂，这是计算机视觉任务尤其是自然环境中面临的关键问题。标签模糊性指的是由于视觉边界不清晰、物体重叠或可见性不一致导致的标注不确定性或主观性。本研究中出现了几种标签模糊性的实际案例。首先，当多个绿色果实紧密聚集时，往往难以判断是一个果实部分遮挡了另一个，还是它们并排生长。其次，某些果实因光照和阴影看似被遮挡，而非实际物理阻碍，导致不同图像间的标注不一致。第三，枝叶有时会模仿未成熟果实的纹理和颜色，使得难以区分目标对象与背景。第四，图像边缘的部分遮挡常让标注者犹豫应将其归类为被遮挡还是单纯因视野范围被截断。这些例子凸显了为何真实果园环境中的绿色果实检测特别容易出现标注不一致。尽管分类指南被严格执行，但物体几何形状、环境纹理与可见性之间复杂的相互作用，使得完全客观的标注难以实现。因此，标签模糊性这一术语被用来描述数据集固有的主观性及其在模型训练与评估过程中可能引入的变异性。

2.3. Training Object Detection Models

2.3.1. Training RF-DETR Object Detection Model

RF-DETR是一种基于Transformer的实时目标检测架构，针对准确性和效率[1] [2]进行了优化。如图4a所示，RF-DETR构建于Deformable DETR与LW-DETR的基础框架，集成了预训练的DINOv2视觉变换器作为其主干网络。该主干通过自监督学习增强了跨领域泛化能力，使模型能高度适应农业环境中诸如青果检测等特定领域的挑战。

RF-DETR的一项关键创新在于其能够摒弃传统目标检测组件，如锚框和非极大值抑制（NMS）。取而代之的是，它采用基于Transformer的编码器-解码器架构，结合可变形交叉注意力机制，选择性地聚焦于空间相关特征，从而提升在遮挡、杂乱和伪装场景下的检测性能。与传统DETR变体不同，RF-DETR采用单尺度特征提取策略以降低计算开销，由此在不牺牲精度的情况下实现更快的推理速度。

该模型有两种变体可供选择：RF-DETR-Base（2900万参数）和RF-DETR-Large（1.28亿参数）。本研究选择了**RF-DETR-Base**模型，因其在计算效率与高检测精度之间取得了平衡，适合野外机器人技术的实时处理。RF-DETR-Base模型在COCO基准测试中实现了53.3的mAP，在RF100-VL数据集上达到86.7的mAP@50，使其成为少数能在实时设置下mAP@50:95超过60%的模型之一。

训练遵循了Roboflow官方实现方案。模型采用DINOv2预训练权重进行初始化，使用AdamW优化器以1e-4的学习率和8的批量大小训练300个周期。训练过程融合了受RT-DETR启发的混合编码器优化技术以及可变形注意力机制。损失函数包含分类任务的交叉熵，以及边界框回归中L1损失与GIoU损失的组合。

此外，该研究采用了对比去噪训练以增强对部分可见及小尺寸目标的检测鲁棒性。RF-DETR还通过协作式标签分配策略应对标注模糊场景下的稳定性问题，并支持多分辨率输入（640–1280像素），无需重新训练即可实现延迟与精度的灵活权衡。这一配置使RF-DETR-Base成为在复杂果园环境中检测遮挡与伪装状态未成熟绿色果实的强效高效模型。

2.3.2. Training YOLOv12 Object Detection Model

YOLOv12代表了基于CNN的目标检测领域的一次变革性飞跃，它将传统卷积架构的高效性与受注意力启发的机制相融合，以应对现代计算机视觉的需求[32]。不同于以往YOLO版本，该模型采用R-ELAN（残差高效层聚合网络）作为核心骨干结构（如图4b所示），通过结合残差连接与多尺度特征融合，既解决了梯度瓶颈问题，又提升了网络深度间的特征复用效率。创新的7×7可分离卷积层取代了标准3×3卷积核，在比传统大核卷积减少60%参数量的同时保留了空间上下文信息，并隐式编码了位置关系，从而有效规避了显式位置嵌入的需求。

[1] https://blog.roboflow.com/rf-detr/
[2] https://github.com/roboflow/rf-detr

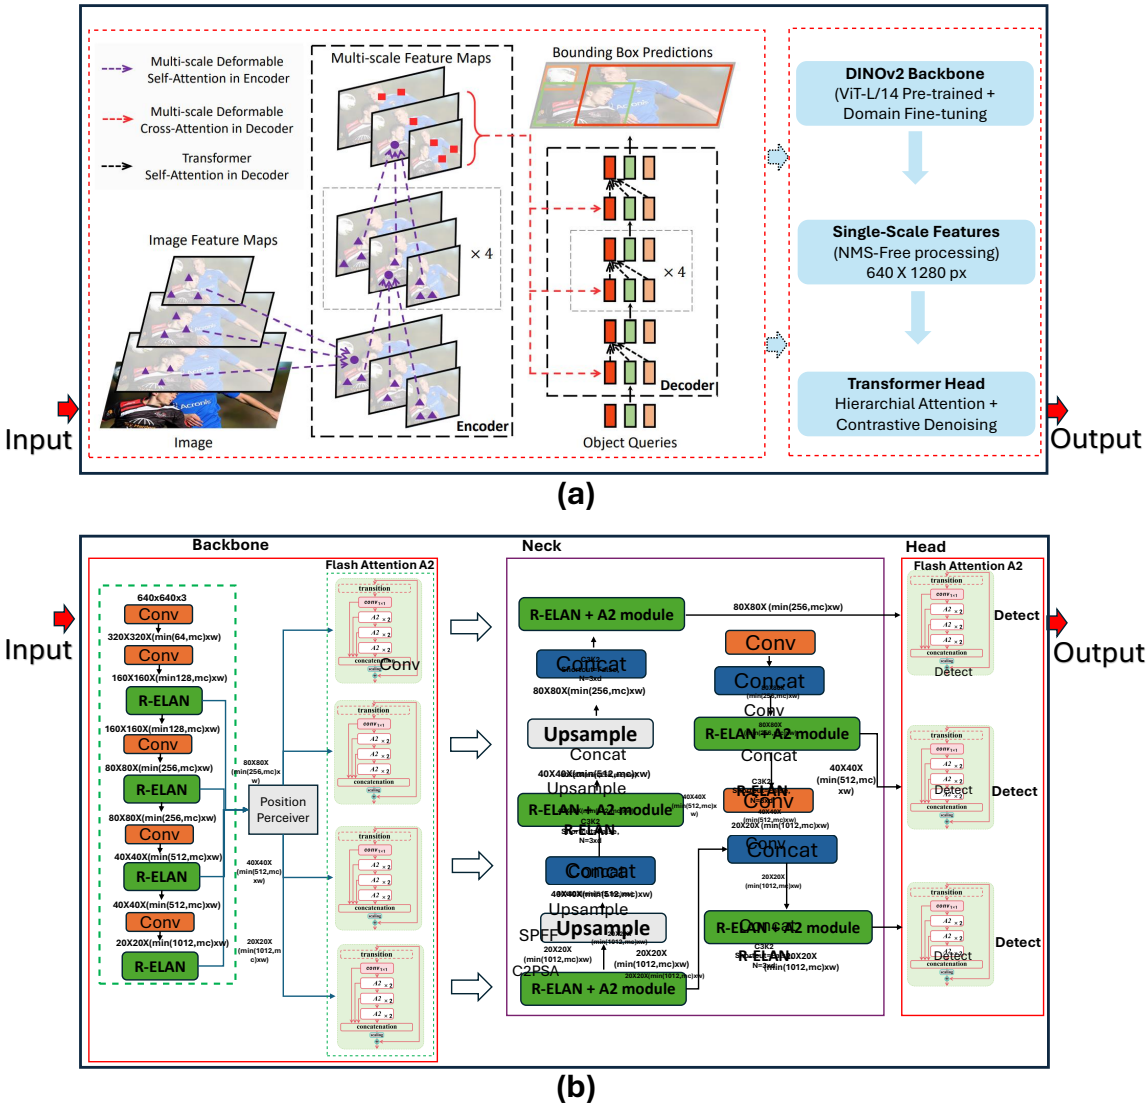

图4：(a) RF-DETR架构　　命物体检测的架构示意图；(b) YOLOv12架构图　　用于目标检测的m

基于Transformer的检测器。该颈部架构集成了经FlashAttention优化的区域注意力机制，将特征图划分为四个水平/垂直区域进行局部处理，同时不牺牲全局上下文，相比标准自注意力实现减少了40%的内存开销。这些创新在保持实时性能的同时实现了最先进的精度，其中YOLOv12-S变体在速度（快1.2×）和精度（62.1 vs 59.3 COCO mAP）上均优于RT-DETR-R18。该架构通过统一预测路径进一步支持多任务学习，可同时进行目标检测、定向边界框（OBB）估计和通过专用头实现的实例分割——这是YOLO系列的首创。硬件感知优化确保在边缘设备上实现低于10ms的推理延迟，其中12n变体（210万参数）在任务专用头中采用轻量级MLP比例（1.2-2.0 vs 传统4.0）保持对50像素以下物体的鲁棒检测，同时实现9.8ms延迟。

YOLOv12的架构优化针对现代硬件改进了卷积运算，同时通过创新的注意力混合机制引入了类Transformer的能力。其区域注意力机制借助FlashAttention的内存高效算法独立处理特征图片段，实现了精准的区域聚焦，而无需承担完整自注意力的计算负担。这一设计理念延伸至模型的可扩展性，提供四种配置（12n/12s/12m/12x），参数量从210万到4200万不等，可适配从边缘设备（Jetson Nano）到云端集群（A100 GPU）的部署需求。不同于以往仅支持轴对齐检测的YOLO版本，YOLOv12新增了具备角度预测功能的OBB检测头，这对航拍图像和文档分析至关重要。通过R-ELAN中的块级残差缩放技术增强了训练稳定性，在防止深度网络特征退化的同时，保持了YOLO系列标志性的单次推理效率。基准测试显示其mAP较YOLOv11提升4-8%。

在所有变体中，12倍模型在COCO数据集上实现了68.9 mAP，在小物体检测任务中超越了类似规模的Transformer混合架构（如DINO-DETR）。该架构将特征提取（主干网络）与注意力驱动优化（颈部网络）分离，实现了针对性优化，使得12s变体能在NVIDIA T4 GPU上以45 FPS处理4K视频流。通过融合CNN的参数效率与注意力机制的上下文感知能力，YOLOv12为实时视觉系统树立了新标杆，尤其适用于需要同时进行检测、分割和几何预测且对延迟有严格要求的工业应用场景。

2.4. Training Methodology

深度学习模型RF-DETR与YOLOv12的训练流程均在完全一致的实验环境下进行，以确保对比的公平性与严谨性。所有训练任务均搭载英特尔酷睿i9-10900K处理器（3.70 GHz主频，10核20线程）、Ubuntu 24.04.1操作系统及配备24GB显存的NVIDIA RTX A5000显卡的工作站完成。该高性能硬件配置为大规模目标检测模型的训练提供了充足算力支撑。其中RF-DETR目标检测模型（Base版本）在单类绿果数据集上训练50个周期，在多类数据集上训练100个周期。

值得注意的是，RF-DETR在单类别设置中展现出快速收敛特性，性能在20个训练周期内即趋于稳定，凸显了该模型高效的学习动态及其对低周期训练机制的良好适应性。YOLOv12系列模型（包括YOLOv12X、YOLOv12L和YOLOv12N）在单类别与多类别数据集上均训练了100个周期，以确保充分收敛和最优泛化能力。RF-DETR基于PyTorch框架通过Roboflow的`rf-detr`工具实现，该方案将可变形DETR架构与预训练的DINOv2骨干网络相结合，增强了全局上下文建模与跨域适应能力。YOLOv12模型则采用官方Ultralytics PyTorch框架进行训练，该框架专为快速检测与高效边缘部署优化。所有模型的输入图像分辨率均统一为640×640像素——这一分辨率在果园目标检测任务中被广泛采用。

模型训练采用FP32精度进行，每批次约16张图像。软件环境包含CUDA 11.7+和cuDNN 8.4+，确保与GPU加速及深度学习库的完全兼容。这一标准化配置使得我们能够对基于Transformer和CNN架构的模型在准确性、收敛行为及训练效率方面进行可靠的对比评估。

2.5. Performance Evaluation

为严格评估RF-DETR与YOLOv12在复杂果园环境中识别绿色果实的性能，我们采用{v*}进行了全面测试标准化指标。两种模型在相同数据集、训练周期数、学习率、优化器和批量大小的统一条件下进行了训练和测试，以确保基于CNN的YOLOv12与基于Transformer的RF-DETR架构之间公平的比较。

检测评估指标

采用的评估指标包括精确率（Precision）、召回率（Recall）、F1分数（F1-Score）、平均精度均值（mAP@50与mAP@50:95）以及平均交并比（mIoU）。这些指标通过预测边界框与真实标注框之间的交互关系量化模型性能：

- 真正例（TP）：预测边界框正确识别出一个真实水果，且其交并比（IoU）≥超过设定的阈值（通常为0.50）。
- 假阳性（FP）：预测的边界框与任何真实标注框的重叠不足（IoU {v*} ⩽ 0.50），或错误标记了不存在的物体。
- 假阴性（FN）：真实的水果未被检测模型识别，且没有足够重叠的预测框与之对应。

指标计算方式如下：

$$\text{Precision} = \frac{TP}{TP + FP} \tag{1}$$

$$\text{Recall} = \frac{TP}{TP + FN} \tag{2}$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{3}$$

精确度评估检测到的绿色水果的准确性，召回率衡量检测的完整性，而F1-Score则平衡这两个方面，提供一个衡量模型效能的单一指标。

交并比（IoU）与平均交并比（mIoU）

$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}} = \frac{TP}{TP + FP + FN} \tag{4}$$

IoU量化了预测边界框与实际边界框之间重叠的精确程度，在果实密集且相互重叠的场景中至关重要。mIoU通过计算所有检测结果的IoU平均值，提供了空间准确性的整体衡量指标。

mAP@50 和 mAP@50:95

$$\text{mAP@50} = \frac{1}{N} \sum_{i=1}^{N} \text{AP}_i(\text{IoU} \geq 0.50) \tag{5}$$

$$\text{mAP@50:95} = \frac{1}{10} \sum_{t=0.50}^{0.95} \text{mAP}_t \tag{6}$$

mAP@50衡量的是在IoU阈值为0.50时的平均精度均值，常用于评估检测效果的有效性。mAP@50:95则在0.50至0.95（以0.05为步长）的十个IoU阈值上取AP的平均值，通过对从宽松到严格重叠的一系列标准进行综合考量，提供了对模型精度的严格评估，反映了模型在精确和近似检测场景下的鲁棒性。

应用于我们的数据集

在单类别检测任务中，所有绿色果实被统一考量；而多类别任务还需评估将果实正确分类为被遮挡或非遮挡状态的准确率。遮挡状态的误判被视为假阳性，而未检测到的果实——尤其是因遮挡而难以辨识的——则计入假阴性。

3. 结果

为评估RF-DETR与YOLOv12在复杂果园环境中检测青苹果的性能，本文展示了单类别与多类别青果检测的结果。图5呈现了三个单类别检测场景的示例，凸显各模型在枝叶茂密、部分遮挡等挑战性条件下的检测效能。图6则通过三个多类别检测实例，重点展示模型有效处理标签模糊性的能力。

每个示例均包含果园中采集的原始RGB图像（左）、RF-DETR的检测输出（中）以及YOLOv12的检测输出（右）。关键关注区域用黄色虚线圆圈标出，聚焦于果实簇集、伪装或严重遮挡的区域。在图5a中，三个未成熟的青苹果密集簇拥在茂密树冠内，因叶片重叠造成显著部分遮挡。左侧原始图像因果实与背景对比度低、枝叶结构复杂，呈现了极具挑战性的场景。如图5a中间图像所示，RF-DETR成功检测到全部三个青苹果实例，即使果实部分可见仍正确框定每个目标。相比之下，右侧的YOLOv12仅检测到三个苹果中的两个，未能识别遮挡最严重的第三个果实。这一结果凸显了RF-DETR在处理复杂空间关系及遮挡方面的卓越能力。图5b展示了另一种挑战性场景：黄色虚线圆圈内单个青苹果因与周围树冠视觉相似而伪装。尽管果实与背景对比度极低，RF-DETR仍准确识别出该青苹果（中间图所示）；而YOLOv12未能检测到此果实，表明其在同质背景中辨识伪装目标的局限性。

在图5c中，研究了一个不同的场景：由于叶片严重遮挡及环境光线不足，果实花萼仅有小部分（约10%）可见。原始RGB图像（左）显示可见部分极少果实的表面积。值得注意的是，RF-DETR仍成功检测到中间图像中部分暴露的果实，而YOLOv12再次未能在其检测输出中识别该目标。这些实例一致表明，与基于CNN的YOLOv12模型相比，RF-DETR在单类青果检测中具有更高的敏感性和鲁棒性，特别是在遮挡、伪装和低可见度条件下。

图6展示了RF-DETR与YOLOv12在多类青果检测中的定性对比，其中幼果被分类为遮挡或非遮挡状态。该评估重点突出了模型在处理标签模糊性——即因簇集、遮挡或边缘截断导致可见性不明确的情况——时的性能表现。

同样地，在图6a中，图像边缘附近出现了一簇密集的青果，形成了高度模糊的场景。如最右侧图像所示，YOLOv12在该区域检测到了7个青果实例。然而，真实标注确认实际仅存在5个青果。YOLOv12将背景纹理或重叠的树冠特征误分类为非遮挡苹果，导致了误报。相比之下，中间图像展示的RF-DETR正确检测到了5个真实青果，但在高置信度下未能将其分类为遮挡/非遮挡类别。此例中，YOLOv12在视觉上显得更为活跃但准确性较低，而RF-DETR则以更低的误分类率提供了精确检测。

此外，在图6b中，原始图像（左）的黄色圆圈标出了真实的绿色果实。RF-DETR检测到12个苹果，包括画面底部一个被遮挡的苹果，该苹果被正确标记为遮挡状态（中）。YOLOv12检测到11个苹果，但错误地将底部被遮挡的苹果标记为非遮挡状态（右），这表明RF-DETR目标检测模型在区分遮挡类别方面表现更优，这很可能得益于其全局注意力建模机制。

同样地，图6c展示了一个极具挑战性的低可见度案例，其中仅有10%的青果在叶片覆盖下可见（由蓝色箭头标示）。RF-DETR成功检测并将其分类为被遮挡状态（中图），而YOLOv12则完全未能检测到该果实（右图）。这一结果进一步印证了RF-DETR在应对极端遮挡情况时的优势。

3.1. Evaluation of Precision, Recall and F1-Score

在评估的所有模型中，YOLOv12N在单类青果检测的召回率（0.8901）和F1分数（0.8784）方面表现最佳，这表明其在检测几乎所有青果实例的同时保持了精确度的平衡能力。然而，就精确度而言，YOLOv12L超越了YOLOv12的所有其他配置以及RF-DETR目标检测模型，在单类检测中达到了0.8892的最高值，这证明了YOLOv12L在减少误报和做出准确预测方面的卓越能力。表1详细列出了所有模型和检测类型的精确度、召回率及F1指标。

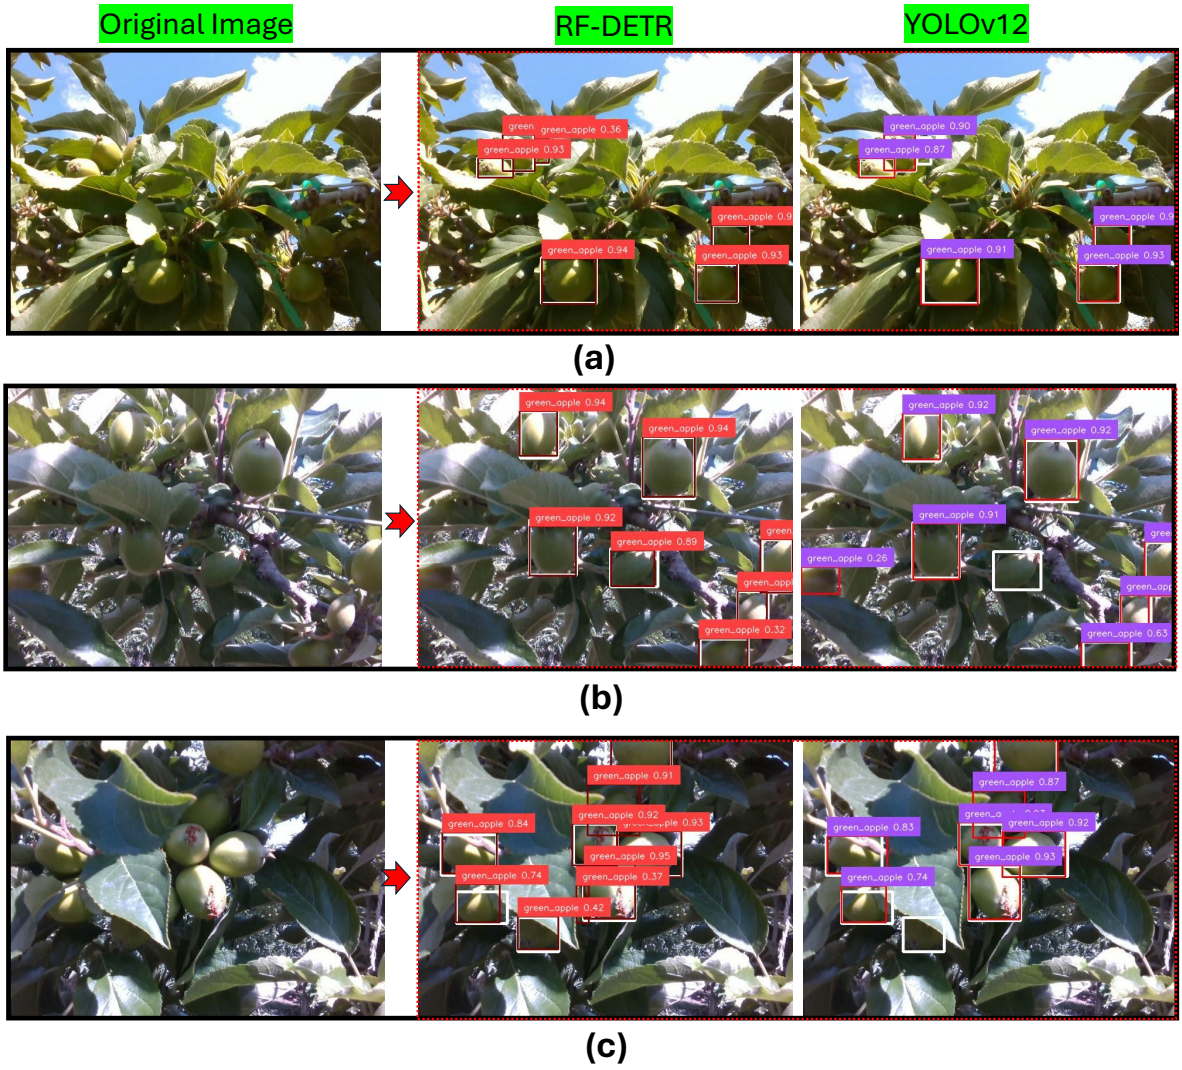

图5：复杂果园场景下RF-DETR与YOLOv12单类青果检测的视觉对比。a) 三枚簇拥的青果被茂密树冠部分遮挡；RF-DETR全部检出，YOLOv12漏检一枚。b) 一枚与树冠颜色融为一体的伪装青果；RF-DETR正确识别，YOLOv12检测失败。c) 低光照条件下仅花萼可见的严重遮挡青果；RF-DETR成功定位，YOLOv12未能检出。

表1：基于RF-DETR（Transformer架构）与YOLOv12（CNN架构）目标检测算法在单类别与多类别青果检测中的精确率、召回率及F1分数对比分析。该表展示了不同YOLOv12配置（X、L、N）下的模型性能，并突出其在果园环境中应对不同复杂度与类别条件时检测青果的有效性。

Models	Single-Class			Multi-Class		
	Precision	Recall	F1 Score	Precision	Recall	F1 Score
RF-DETR	0.8663	0.8828	0.8744	0.7652	0.8109	0.7874
YOLOv12X	0.8797	0.8595	0.8694	0.6986	0.8261	0.7570
YOLOv12L	0.8892	0.8631	0.8759	0.7692	0.7827	0.7759
YOLOv12N	0.8671	0.8901	0.8784	0.7569	0.7406	0.7487

3.2. Analysis of Mean Average Precision (mAP)

在单类青果检测任务中，RF-DETR以0.9464的最高mAP@50值超越了所有其他模型，这表明其在实现充分重叠条件下精准检测与定位青果方面具有卓越能力。此外，RF-DETR还取得了0.7433的mAP@50:95值，位列所有模型中的第二高位。

测试的模型中。尽管YOLOv12N取得了稍高的mAP@50:95值0.7620，但RF-DETR持续更高的mAP@50表明在实际果园检测场景中性能更为可靠，尤其是在50%阈值下的边界框精度至关重要时。在多类别检测场景下，绿色果实被标记为被遮挡或

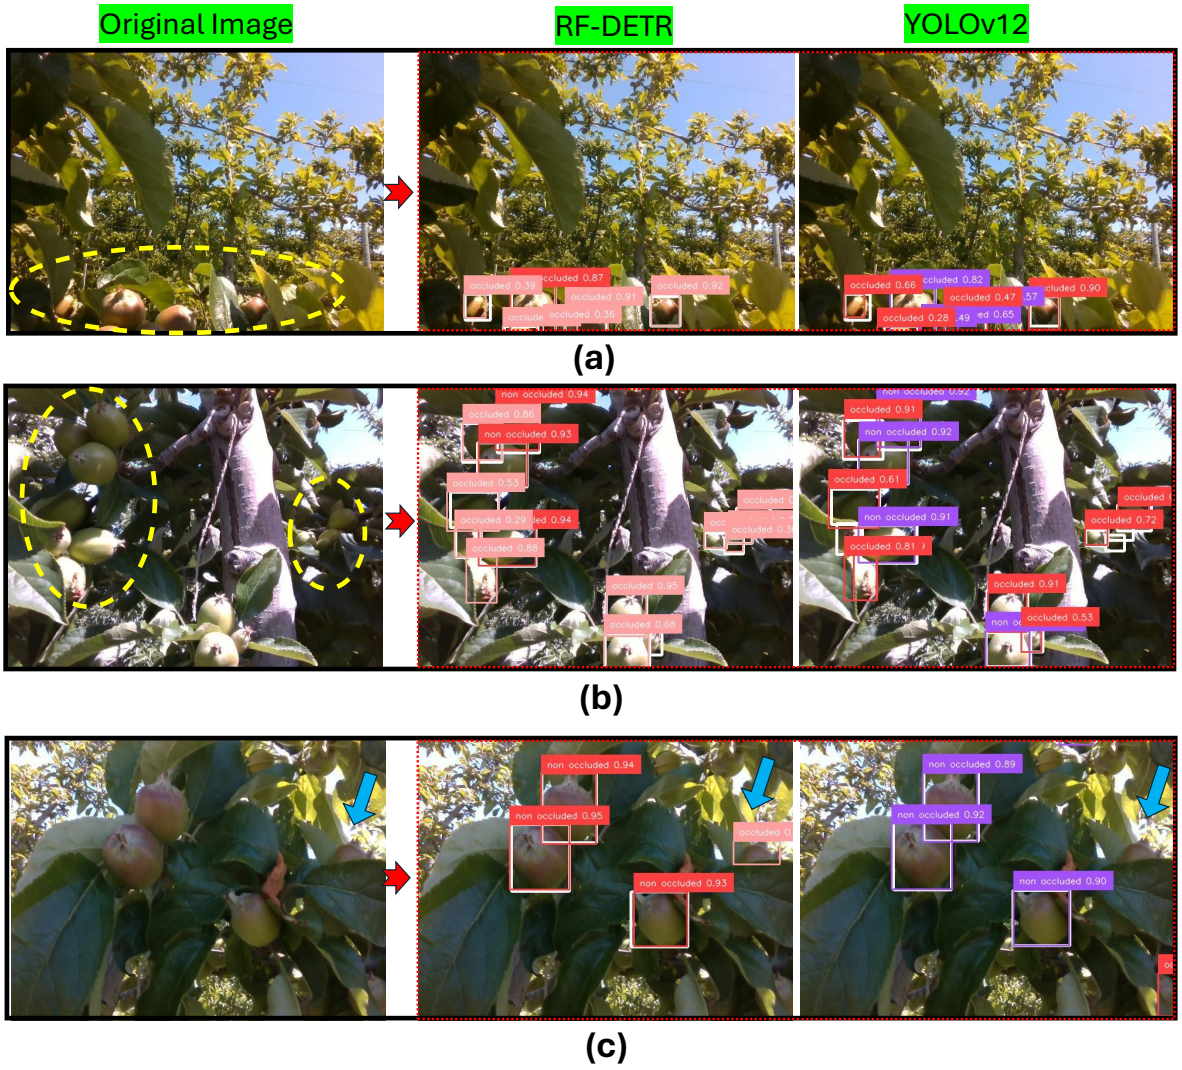

图6：RF-DETR与YOLOv12在标签模糊场景下的多类青果检测视觉对比。(a) 图像边缘处的密集果实簇；YOLOv12出现误检产生假阳性，而RF-DETR正确检测出5个真实青果。(b) 底部被遮挡的苹果；RF-DETR正确标记为遮挡状态，YOLOv12则错误分类为未遮挡。(c) 可见度仅约10%的高度遮挡果实；RF-DETR成功检测为遮挡目标，YOLOv12则完全漏检。

在非遮挡情况下，YOLOv12L以0.6622的mAP@50:95最高值略胜一筹，小幅超越YOLOv12X（0.6609）和RF-DETR目标检测模型（0.6530）。这表明在标签模糊条件下，YOLOv12L能更稳定地保持不同重叠程度下的检测一致性。然而在多类别场景中，RF-DETR模型以0.8298的mAP@50值占据优势，印证了其在空间对齐度达50%以上的目标检测任务中的强项。这些发现说明：RF-DETR擅长空间精度要求高的检测任务（尤其针对清晰可见的水果目标），而YOLOv12L在涉及遮挡的复杂分类场景中表现更优。完整指标可视化结果如图7所示，其中图7a展示单类别检测的mAP@50，图7b则呈现多类别检测的mAP@50与mAP@50:95指标。

3.3. Training Dynamics and Model Convergence Analysis

图8详细展示了RF-DETR与YOLOv12X模型在训练周期数下的平均精度均值(mAP@50)变化，揭示了二者在训练阶段的学习效率与稳定性差异。在图8a的单类青果检测性能曲线中，基于Transformer架构的目标检测模型RF-DETR表现出惊人的早期收敛性，在10个周期前即达到稳定平台。这种快速稳定态势凸显了RF-DETR对复杂果园场景的敏捷适应能力，相较YOLOv12X等传统CNN模型实现了显著突破。

同样地，图8b展示了多类别检测场景下的训练进程。在此，RF-DETR同样展现出更优的收敛性，约20个周期即达到稳定状态，远早于其CNN对照模型——后者仍在持续寻求平衡。RF-DETR在单类别检测中更快的收敛速度

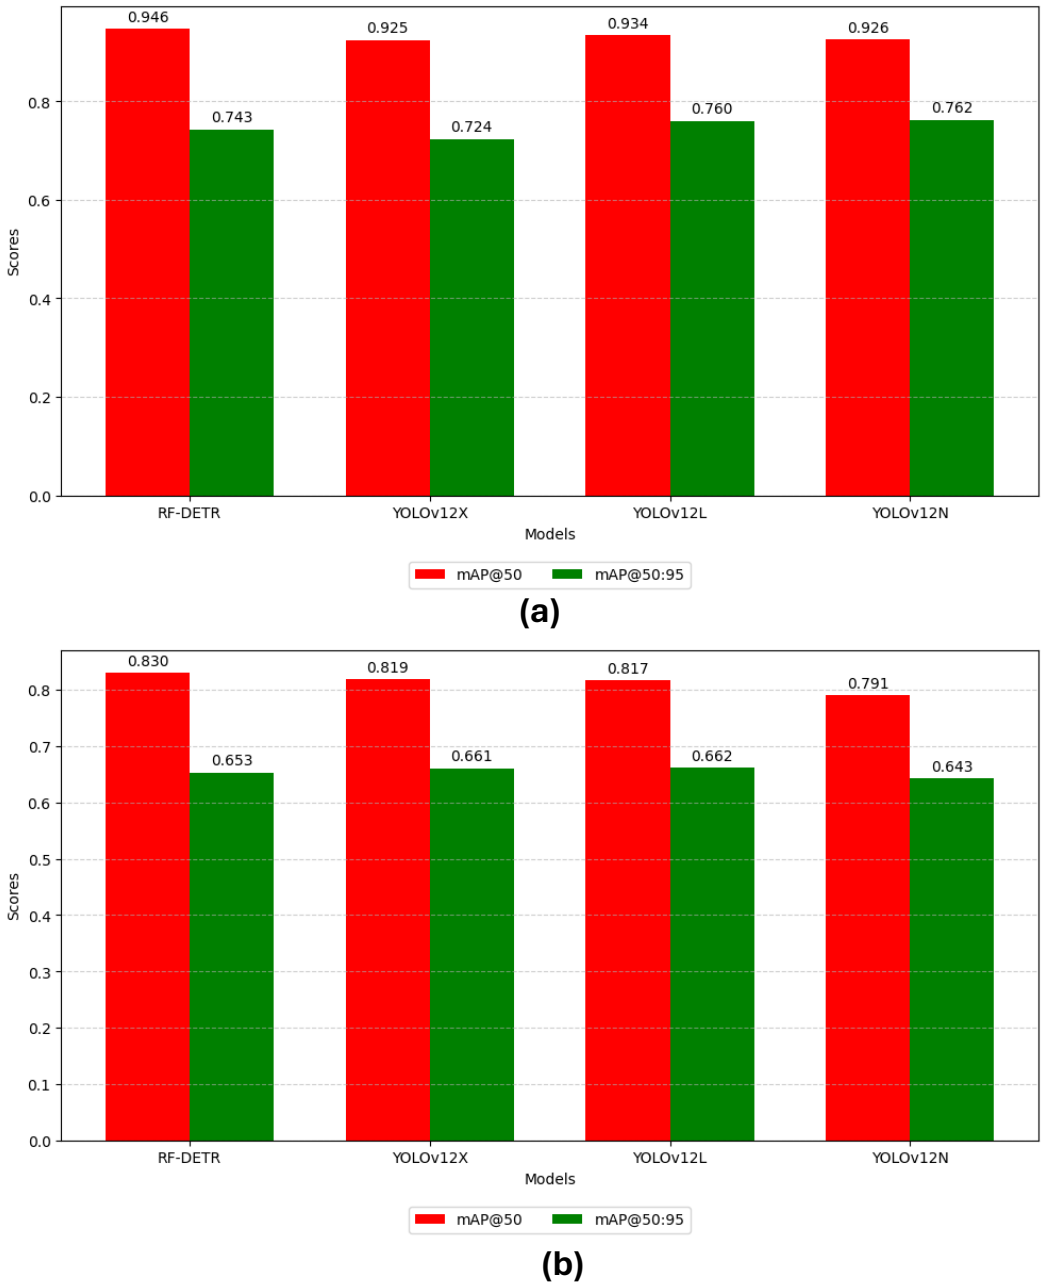

图7　使用RF-DETR与YOLOv12目标检测模型进行青果检测的平均精度均值(mAP)对比：a) mAP@50 {v*}　或单c　类别检测。b) 多类别检测的mAP@50和mAP@50:95

多类别设置体现了Transformer技术在高效处理动态和视觉杂乱环境中的固有优势。

以下五点观察凸显了在目标检测任务中采用基于Transformer的模型（如RF-DETR）的若干关键优势：

1. 加速学习曲线：RF-DETR能够快速达到峰值性能，减少了训练所需的计算资源和时间，从而提升生产力并降低运营成本。 2. 稳定性能：该模型始终保持一致的准随时间推移的准确性，表明其对抗过拟合的稳健性以及从有限周期训练中良好泛化的能力。

3. 适应性：RF-DETR的架构显然非常适合复杂的检测环境，例如精准农业中普遍存在的遮挡和物体外观多变的情况。

4. 高效资源利用：通过快速收敛，RF-DETR最大限度地提升了计算资源的利用率，使得在相同的计算预算下能够执行更多任务。

5. 边缘部署：模型的快速适应与稳-

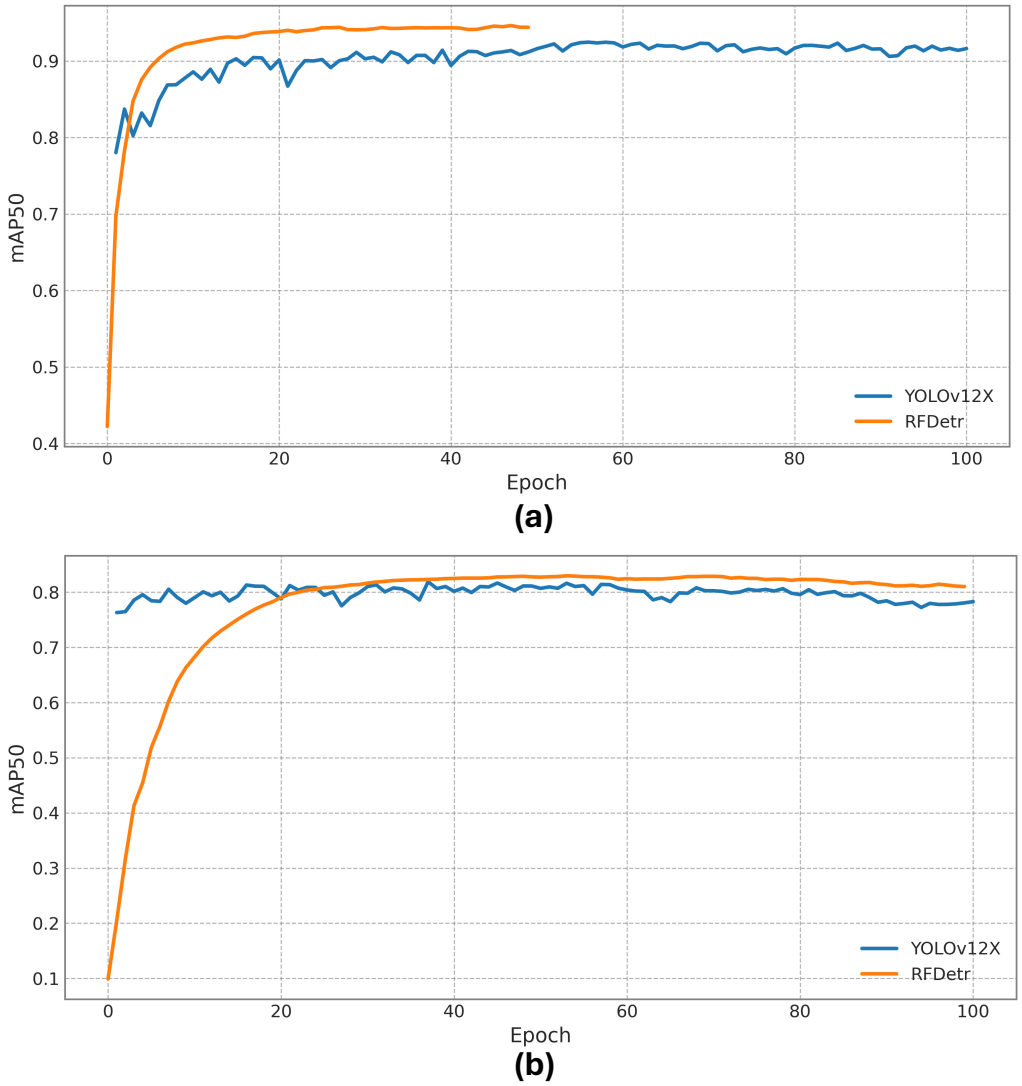

图8：训练动态与模型收敛性分析：目标检测模型的mAP@50随训练轮次变化曲线。(a) 单类青果检测展示了RF-DETR与YOLOv12X模型在训练周期内的性能轨迹。(b) 多类青果检测对比了两模型在整个训练期间的收敛模式

出色的性能使其非常适合部署在计算资源和电力有限的边缘设备中。

4. 讨论

绿色果实检测技术的进步与计算机视觉领域的最新发展紧密相连，其中每个新模型迭代都引入了更精细的能力，尤其是在复杂的农业环境中。值得注意的贡献包括[31,49]的研究，它们对YOLOv11和YOLOv8进行了比较分析，重点关注这些模型在分割被遮挡与未遮挡未成熟绿色果实方面的效能。同样地，[50]探索了利用YOLOv8结合三维点云数据的几何形状拟合进行尺寸估算的技术，旨在提升产量预测和作物管理决策的准确性。这些研究凸显了持续不断的在多变果园环境中提升检测系统准确性与效率的努力。

在此背景下，我们的研究采用了RF-DETR模型，该模型在检测性能上树立了新的标杆。基于Transformer架构的RF-DETR实现了0.9464的mAP@50，超越了YOLOv12，展现出卓越的空间检测精度，尤其在部分可见及伪装条件下表现突出[51]。该模型在训练过程中快速收敛的特性，进一步凸显了其高效性，标志着相对于传统CNN模型的重大进步。

视觉语言模型（VLMs）与开放词汇检测的融合，标志着检测系统向更动态、更适应性的方向迈出了关键一步。如[52,53]所述，这些技术无需重新训练即可识别更广泛的水果类型及特征，这种适应性对于管理至关重要。

农业环境的典型多样性条件，其中果实外观及光照、遮挡等环境因素差异显著。采用融合多种感官数据类型的多模态学习方法，有望解决诸如伪装和标签模糊性等长期存在的难题。探索半监督和小样本学习范式可减少对大量标注数据集的依赖，从而更快适应新的果园环境[54]。此外，部署轻量级Transformer变体和高效视觉语言模型(VLMs)以实现实时田间应用将至关重要。这些进步将推动开发能提供实时分析的移动或边缘系统，这对即时农业决策至关重要[55]。这些领域的持续发展必将打造出不仅精度极高、还能进行语义和上下文理解的检测系统。此类系统将引领精准农业的新一轮创新浪潮，确保检测技术不仅高效，而且足够稳健，能适应自然果园环境的复杂动态变化。

5. 结论

本研究对基于Transformer的RF-DETR和基于CNN的YOLOv12两种目标检测模型在复杂视觉环境下的商业果园绿果检测进行了深入评估。研究过程包括采集真实场景图像、为单类别及多类别检测任务准备带有遮挡标注的数据集，并在标准化条件下评估模型性能。对比指标涵盖精确率、召回率、F1分数以及平均精度均值（mAP@50和mAP@50:95）。研究进一步分析了训练动态特征，发现RF-DETR展现出更快的收敛速度，在较少的训练周期内即可达到稳定性能，这一优势突显了RF-DETR在适应果园环境多变条件的同时，仍能在长期训练阶段保持准确性的卓越效能。

主要发现：

- 单类别检测：RF-DETR目标检测模型展现了卓越性能，其mAP@50最高达到0.9464，在复杂背景中有效定位并检测出绿色果实。尽管YOLOv12N以0.7620的mAP@50:95位居榜首，但在杂乱和遮挡场景下，RF-DETR始终保持更精准的检测能力。

- 多类别检测：RF-DETR在区分遮挡与非遮挡果实方面表现卓越，其mAP@50最高达到0.8298。而YOLOv12L在mAP@50:95指标上略胜一筹，取得了0.6622的成绩，展现了在复杂遮挡条件下更优的分类精度。

- 模型训练动态与收敛性：RF-DETR目标检测模型因其快速训练收敛性，特别是在单类别场景下，仅需不到10个周期即达到稳定状态，这充分展示了基于Transformer架构在处理动态视觉数据时的高效性与鲁棒性。

致谢

本研究由美国国家科学基金会和美国农业部国家食品与农业研究所通过“农业人工智能研究所”计划（资助编号AWD003473）资助。我们衷心感谢孟志超、Astrid Wimmer、Randall Cason、Diego Lopez和Giulio Diracca在数据准备方面的工作；感谢Martin Churuvija和Priyanka Upadhyaya在本项目数据收集过程中提供的宝贵后勤支持。特别感谢Dave Allan为本研究实验开放商业果园的准入权限。

声明

作者声明无利益冲突。

参考文献

[1] M. Masmoudi, H. Ghazzai, M. Frikha, Y. Massoud, 面向自动驾驶应用的物体检测学习技术, 见: 2019年IEEE国际车辆电子与安全会议(ICVES), IEEE, 2019年, 第1–5页. [2] M. Hnewa, H. Radha, 自动驾驶车辆在雨天条件下的物体检测: 最新技术与新兴方法综述, IEEE信号处理杂志 38 (2020年) 53–67. [3] R. Elakkiya, V. Subramaniyaswamy, V. Vijayakumar, A. Mahanti, 基于混合物体检测对抗网络的宫颈癌诊断医疗系统, IEEE生物医学与健康信息学杂志 26 (2021年) 1464–1471. [4] P. K. Mishra, G. Saroha, 视频监控系统中物体检测与跟踪的研究, 见: 2016年第三届可持续发展全球计算国际会议(INDIACom), IEEE, 2016年, 第221–226页. [5] C. M. Badgujar, A. Poulose, H. Gan, 基于YOLO算法的农业物体检测: 文献计量与系统综述, 农业计算机与电子 223 (2024年) 109090. [6] I. Sa, Z. Ge, F. Dayoub, B. Upcroft, T. Perez, C. McCool, Deepfruits: 基于深度神经网络的水果检测系统, 传感器 16 (2016年) 1222. [7] P. Singh, R. Krishnamurthi, 基于物联网的实时物体检测系统用于作物保护与农田安全, 实时图像处理杂志 21 (2024年) 106. [8] L. Yang, T. Noguchi, Y. Hoshino, 基于RGB-D相机与YOLO物体检测AI模型的南瓜采摘机器人开发, 农业计算机与电子 227 (2024年) 109625. [9] J. Gu, Z. Wang, J. Kuen, L. Ma, A. Shahroudy, B. Shuai, T. Liu, X. Wang, G. Wang, J. Cai, 等, 卷积神经网络的最新进展, 模式识别 77 (2018年) 354–377.

[10] D. Nimma, Z. Zhou, Intelpvt：基于智能补丁的金字塔视觉变换器用于目标检测与分类，《国际机器学习与控制论期刊》15卷（2024年）1767–1778页。

[11] H. Liu, Y. Zhan, J. Sun, Q. Mao, T. Wu, 一种基于Transformer的特征补偿与局部信息增强端到端害虫检测模型，《农业中的计算机与电子》231卷 (2025年) 109920.

[12] Y. Zang, W. Li, J. Han, K. Zhou, C. C. Loy, 基于多模态大语言模型的上下文目标检测, 国际计算机视觉杂志 133 (2025) 825–843.

[13] S. Fu, Q. Yang, Q. Mo, J. Yan, X. Wei, J. Meng, X. Xie, W.-S. Zheng, LLMDet：在大语言模型监督下学习强大的开放词汇目标检测器，arXiv预印本 arXiv:2501.18954 (2025)。 [14] C.-Y. Fu, M. Shvets, A. C. Berg, RetinaMask：通过学习预测掩码免费提升最先进单阶段检测性能，arXiv预印本 arXiv:1901.03353 (2019)。 [15] M. Tan, R. Pang, Q. V. Le, EfficientDet：可扩展高效的目标检测，载于《IEEE/CVF计算机视觉与模式识别会议论文集》，2020年，第10781–10790页。 [16] J. Redmon, S. Divvala, R. Girshick, A. Farhadi, YOLO：统一实时目标检测，载于《IEEE计算机视觉与模式识别会议论文集》，2016年，第779–788页。 [17] R. Sapkota, Z. Meng, M. Churuvija, X. Du, Z. Ma, M. Karkee, YOLOv11、YOLOv10、YOLOv9与YOLOv8在复杂果园环境中幼果检测与计数的综合性能评估，arXiv预印本 arXiv:2407.12040 (2024)。 [18] K. He, G. Gkioxari, P. Dollár, R. Girshick, Mask R-CNN，载于《IEEE国际计算机视觉会议论文集》，2017年，第2961–2969页。 [19] X. Dai, Y. Chen, J. Yang, P. Zhang, L. Yuan, L. Zhang, Dynamic DETR：基于动态注意力的端到端目标检测，载于《IEEE/CVF国际计算机视觉会议论文集》，2021年，第2988–2997页。 [20] X. Zhu, W. Su, L. Lu, B. Li, X. Wang, J. Dai, Deformable DETR：端到端目标检测的可变形Transformer，arXiv预印本 arXiv:2010.04159 (2020)。 [21] J. Hosang, R. Benenson, B. Schiele, 学习非极大值抑制，载于《IEEE计算机视觉与模式识别会议论文集》，2017年，第4507–4515页。 [22] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, S. Zagoruyko, 基于Transformer的端到端目标检测，载于《欧洲计算机视觉会议》，Springer，2020年，第213–229页。 [23] X. Ren, D. Ramanan, 基于稀疏编码直方图的目标检测，载于《IEEE计算机视觉与模式识别会议论文集》，2013年，第3246–3253页。 [24] Y. Xie, W. Zhang, C. Li, S. Lin, Y. Qu, Y. Zhang, 通过稀疏表示与在线字典学习的判别性目标跟踪，《IEEE控制论汇刊》44 (2013) 539–553。 [25] K. O’shea, R. Nash, 卷积神经网络导论，arXiv预印本 arXiv:1511.08458 (2015)。 [26] D. Soydaner, 神经网络中的注意力机制：起源与发展，《神经计算与应用》34 (2022) 13371–13385。 [27] A. Khan, Z. Rauf, A. Sohail, A. R. Khan, H. Asif, A. Asif, U. Farooq, Vision Transformer及其CNN-Transformer混合变体综述，《人工智能评论》56 (2023) 2917–2970。 [28] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamar´a, M. A. Fadhel, M. Al-Amidie, L. Farhan, 深度学习综述：概念、CNN架构、挑战、应用与未来方向，《大数据期刊》8 (2021) 1–74。 [29] S. Chen, Y. Liu, X. Gao, Z. Han, MobileFaceNets：移动设备上高效精准的实时人脸验证CNN，载于《中国生物特征识别会议》，Springer，2018年，第428–438页。 [30] R. Girshick, J. Donahue, T. Darrell, J. Malik, 用于精确目标检测与语义分割的丰富特征层次结构，载于《IEEE计算机视觉与模式识别会议论文集》，2014年，第580–587页。 [31] R. Sapkota, M. Karkee, 对比YOLOv11与YOLOv8在复杂果园环境中遮挡与非遮挡未成熟绿色果实的实例分割表现，arXiv预印本 arXiv:2410.19869 (2024)。 [32] Y. Tian, Q. Ye, D. Doermann, YOLOv12：以注意力为核心的实时目标检测器，arXiv预印本 arXiv:2502.12524 (2025)。 [33] R. Sapkota, R. Qureshi, M. F. Calero, C. Badjugar, U. Nepal, A. Poulose, P. Zeno, U. B. P. Vaddevolu, S. Khan, M. Shoman等，YOLOv10溯源：YOLO系列十年全面回顾，arXiv预印本 arXiv:2406.19407 (2024)。 [34] R. Sapkota, M. Karkee, 基于LLM生成合成数据改进的YOLOv12增强苹果检测及与YOLOv11、YOLOv10的基准测试，arXiv预印本 arXiv:2503.00057 (2025)。 [35] Z. Meng, X. Du, R. Sapkota, Z. Ma, H. Cheng, YOLOv10-Pose与YOLOv9-姿态：实时草莓茎秆姿态检测模型，《工业计算机》165卷（2025年）104231页。[36] 刘伟、D. Anguelov、D. Erhan、C. Szegedy、S. Reed、傅佳伟、A. C. Berg，SSD：单次多框检测器，载于《计算机视觉–ECCV 2016：第14届欧洲会议论文集，第一部分》，荷兰阿姆斯特丹，2016年10月11-14日，Springer出版社，2016年，第21-37页。[37] 林泰宇、P. Goyal、R. Girshick、K. He、P. Dollár，密集目标检测的焦点损失，《IEEE国际计算机视觉会议论文集》，2017年，第2980-2988页。[38] 王栋、李政、杜晓、马志、刘旭，基于非局部可变形DETR的无人机视角农田障碍物检测，《农业》12卷（2022年）1983页。[39] 林浩、刘杰、李翔、魏磊、刘洋、韩冰、吴钊，DCEA：基于集中可变形注意力的端到端SAR图像舰船检测DETR，《IEEE应用地球观测与遥感精选期刊》（2024年）。[40] 宗政、宋歌、刘洋，协作混合分配训练的DETRs，《IEEE/CVF国际计算机视觉会议论文集》，2023年，第6748-6758页。[41] 张毅、吴越、徐浩、谢宇、张阳，采用Dropkey改进的Co-DETR及其在热作业检测中的应用，《并行计算：实践与经验》37卷（2025年）e70020。[42] 方毅、廖博、王旭、方杰、齐健、吴锐、牛杰、刘伟，你只需看一个序列：通过目标检测重新思考视觉中的Transformer，《神经信息处理系统进展》34卷（2021年）第26183-26197页。[43] 赵毅、吕伟、徐松、魏杰、王刚、党强、刘洋、陈杰，实时目标检测中DETRs超越YOLOs，《IEEE/CVF计算机视觉与模式识别会议论文集》，2024年，第16965-16974页。[44] M. Minderer、A. Gritsenko、A. Stone等，简单开放词汇目标检测，《欧洲计算机视觉会议》，Springer出版社，2022年，第728-755页。[45] G. Heigold、M. Minderer等，Video OWL-ViT：视频中时间一致性的开放世界定位，《IEEE/CVF国际计算机视觉会议论文集》，2023年，第13802-13811页。[46] 王博、黄凯、李斌等，EffOWT：高效迁移视觉语言模型至开放世界跟踪，arXiv预印本arXiv:2504.05141（2025年）。[47] 张浩、李飞、刘松等，DINO：改进去噪锚框的端到端目标检测DETR，arXiv预印本arXiv:2203.03605（2022年）。[48] P. Robicheaux等，RoboFlow100-VL：视觉语言模型多领域目标检测基准，RoboFlow（2025年）。[49] R. Sapkota等，基于LLM生成数据集的零样本自动标注与实例分割：消除深度学习模型开发中的实地成像与人工标注，arXiv预印本arXiv:2411.11285（2024年）。[50] R. Sapkota等，商用果园中基于YOLOv8与形状拟合技术的未成熟青苹果检测与尺寸测量，《IEEE Access》12卷（2024年）第43436-43452页。[51] R. Sapkota等，基于YOLO11与视觉Transformer的商用苹果园未成熟青果三维姿态估计（机器人疏果应用），arXiv预印本arXiv:2410.19846（2024年）。[52] 刘强、孟浩等，基于优化可变形检测Transformer的青苹果检测器，《农业》15卷（2024年）75页。[53] R. Sapkota等，多模态大语言模型在图像、文本及语音数据增强中的应用综述，arXiv预印本arXiv:2501.18648（2025年）。[54] 刘强、吕杰等，基于MAE-YOLOv8的复杂果园环境下青脆李小目标检测，《农业计算机与电子技术》226卷（2024年）109458页。[55] 吕杰、吴钊等，FCAE-YOLOv8n：未成熟葡萄串目标检测方法，《新西兰作物与园艺科学杂志》（2024年）1-19页。